

亮点

SRL：结合 SLIP 模型与强化学习的敏捷机器人跳跃

胡晓文, 叶林奇, 朱雨迪, 邵晨悦, 李然坤, 李清都, 彭艳

- 一种融合 SLIP 模型与强化学习的混合 SRL 框架, 用于腿式机器人跳跃。
- 六阶段运动调制, 以增强跳跃稳定性与动力学性能。
- 相比基于 SLIP 的模型预测控制与纯强化学习方法, 具有更高的成功率和训练效率。

通过仿真和真实世界实验验证, 实现了精确的轨迹跟踪。

SRL: 结合 SLIP 模型与强化学习的敏捷机器人跳跃

小文胡^{a,1}, 林奇叶^{a,*,2}, 宇迪朱^{b,3}, 晨月邵^{b,4}, 然坤李^{a,5}, 清都李^{b,6} 和岩彭^{a,7}

^aInstitute of Artificial Intelligence, Shanghai University, Shangda Road 99, Baoshan District, 200444, Shanghai, China

^bInstitute of Machine Intelligence, University of Shanghai for Science and Technology, Jungong Road 516, Yangpu District, 200093, Shanghai, China

文章信息

Keywords: 机器人跳跃
SLIP 模型 强化学习
四足机器人 双足机器人

ABSTRACT

机器人跳跃在搜救和物流等应用中至关重要，这些场景中跨越障碍物和提高移动效率是关键。弹簧负载倒立摆（SLIP）模型利用简化的弹簧-质量动力学，自然编码了具有生物学合理性的弹跳运动，但由于其对接触和关节动力学的理想化假设，在不规则地形上的性能会下降。与此同时，强化学习（RL）能够适应多样且复杂的环境，但通常需要大量来自无引导探索的数据。SLIP 的物理基础基线与 RL 的适应能力具有互补优势，这激发了一种克服各自局限性的混合框架。因此，我们提出了弹簧负载强化学习（SRL），它将基于 SLIP 的前馈控制信号与 RL 驱动的实时反馈相结合，实现了机器人跳跃的持续优化。实验结果表明，与基线方法相比，SRL 能够以更少的训练时间实现更稳定的跳跃，平均位置跟踪误差保持在 0.1 米以下，速度跟踪误差在目标值的 $\pm 3\%$ 以内。通过双足和四足机器人的地面与楼梯跳跃仿真，以及仿真到仿真和仿真到现实的验证，SRL 展现了对各种任务要求和环境复杂性的鲁棒适应性，突显了其在实际部署中的潜力。

1. 引言

随着机器人在高风险救援任务到仓库物流等多样化场景中的日益普及，机器人执行复杂动作（如跳跃 [1, 2], ）的能力变得愈发关键。跳跃不仅使机器人能够克服重大障碍，例如沟壑和高架平台，还能显著提升在非结构化地形中的移动性和避障能力 [3–6]。

当代机器人跳跃控制策略大致可分为模型驱动方法，如仿生控制器 [7–13]、SLIP 模型 [14–16]，和模型预测控制（MPC）[17–22]；以及数据驱动方法，主要是 RL [23, 24]。模型驱动方法，特别是基于 SLIP 的方法，能够高效捕捉能量存储与释放动力学，从而实现具有物理基础的跳跃运动。然而，其适用性常因过度简化的假设（例如忽略地面摩擦和多关节腿部动力学）而受到限制，这削弱了其在真实世界不平坦地形中的适应性 [25–27]。

为了解决这些局限性，数据驱动方法（如强化学习）提供了一种替代方案，通过与环境的交互自主优化控制策略。强化学习在各种运动任务中展现出卓越的适应性。然而，由于缺乏物理先验知识，其依赖试错学习的方式往往导致样本效率低下和策略探索不稳定。在机器人跳跃中，这会导致低效的运动策略和增加的训练成本，阻碍了实际部署。

为了弥合这一差距，我们提出了 SRL，一种将 SLIP 模型与强化学习相结合的混合控制框架，以实现高效性和适应性。在 SRL 框架中，SLIP 模型作为前馈控制的基础，利用简化的弹簧-质量动力学为跳跃运动生成高效的参考轨迹。

*通讯作者: hwx2035143846@shu.edu.cn (胡晓伟); yelinqi@shu.edu.cn (叶林奇); 221240082@st.usst.edu.cn (李宇); 13736413526@139.com (邵晨); rankunli@shu.edu.cn (李冉坤); liqd@usst.edu.cn (李强东); pengyan@shu.edu.cn (彭燕) ORCID(s):

此外，我们设计了一个基于强化学习的反馈模块，采用近端策略优化（PPO）实现，用于生成纠正动作，以提高在非结构化地形上的稳定性和鲁棒性。PPO 智能体持续处理环境观测信息，包括身体姿态、速度和足部位置，并输出对基于 SLIP 的参考轨迹的反馈修正。最终的控制信号通过加权融合机制，将 SLIP 生成的前馈指令与强化学习导出的反馈修正相结合，平衡了预测效率与自适应灵活性。为确保精确的运动执行，输出控制信号进一步由比例 - 微分（PD）控制器进行微调，以调节关节力矩，实现平滑稳定的跳跃。通过这种模型驱动与数据驱动控制的结构化集成，SRL 实现了稳健且高效的机器人跳跃，有效缓解了两种单独方法的局限性。

我们的贡献总结如下：

我们提出了 SRL，一种用于机器人跳跃的混合控制框架，该框架集成了六状态有限状态机（FSM）、结构化观测和相位特定奖励，将 SLIP 模型的物理先验与强化学习的适应性相结合；

我们通过在双足和四足机器人上的广泛仿真验证了 SRL，展示了其相较于各种基线方法在学习效率和稳定性方面的优越性；

我们进一步通过仿真到仿真和仿真到真实的实验验证了 SRL，实现了卓越的轨迹跟踪精度，并在真实世界中展示了双足机器人 15 厘米的跳跃高度和 20 厘米的前向距离。

2. 相关工作

当前实现机器人跳跃的主流方法包括几种。首先，仿生控制方法模仿动物的跳跃动作，结合模型预测技术来精确跟踪和优化轨迹 [7, 9, 18, 31, 32]。尽管这种方法能够真实地再现自然跳跃行为，但它高度依赖高精度控制和传感技术，因此在复杂动作中实施起来具有挑战性 [10–12]。其次，SLIP 模型使用简化的弹簧和质点系统，有效捕捉跳跃和行走的能量动态 [14–16, 33–36]。其结构简单且易于实现，但由于模型过度简化，难以处理各种环境中的精确跳跃控制 [25–27]。MPC 通过预测未来状态来优化控制策略，使机器人能够在复杂环境中执行跳跃 [17–22]。虽然 MPC 在精确控制方面表现出色，但其计算复杂度高，对实时性能要求较高。深度强化学习（DRL）[23, 37]，通过与环境的交互，能够在连续动作空间中学习最优策略，适应非线性和未知挑战 [38–42]。尽管 DRL 具有自适应和自学习能力，但学习过程通常需要大量的计算资源。

在上述方法中，SLIP 模型因其简单性和在捕捉腿部动力学关键特征方面的有效性而受到研究人员的青睐 [43]。Geyer 和 Saranli [44] 通过他们的研究加强了 SLIP 模型在双足步态生成中的应用。Xie 等人 [36] 提出了具有可调腿刚度和踝关节的有限足可变弹簧负载倒立摆模型（VSLIP-FF），以实现柔顺的双足行走。He 等人 [26] 验证了 SLIP 模型在四足机器人奔跑控制中的有效性，通过全面的动力学分析实现了稳定的高速运动。

尽管 SLIP 模型在模拟基本跳跃动力学方面有效，但其在适应复杂环境方面的局限性使得需要整合其他先进技术来增强机器人系统的实用性和适应性。近年来，强化学习已成为机器人领域完成复杂任务的关键技术，特别是在没有预设具体指令的场景中展现出独特优势。通过与环境的实时交互和试错过程，强化学习使机器人能够探索并学习最优或接近最优的决策策略。这种多功能性使得强化学习在机械臂控制和自主导航等多个领域得到了广泛应用 [23, 24]。此外，通过深度确定性策略梯度（DDPG）算法的实现，强化学习在连续动作空间中显示出显著潜力，有效促进了跳跃等复杂动作的生成 [38, 39]。而且，强化学习逐渐展现出其在实现机器人跳跃能力方面的潜力 [24, 37]。

据我们所知，尽管在各个领域取得了显著进展，但将 SLIP 模型与强化学习相结合以实现更复杂环境中自主且高效的跳跃仍是一个尚未充分探索的领域。




图 1: 用于机器人跳跃任务的 SRL 控制框架概览, 集成了 SLIP 模型、强化学习与仿真环境。SRL 将 SLIP 模型的物理运动动力学与强化学习的适应性相结合, 以在具有不同扰动的平地、楼梯和箱子等复杂环境中优化跳跃性能。

3. 方法

3.1. SRL 结构

本研究提出了一种新颖的机器人跳跃控制框架 SRL, 该框架将 SLIP 模型与强化学习相结合, 如图 1 所示。SRL 由三个核心组件组成: 1) SLIP 模型, 2) 强化学习模块, 以及 3) 仿真环境。SLIP 模型负责生成前馈控制信号, 这些信号通过逆运动学求解器转换为具体的电机指令。强化学习模块通过处理环境观测和奖励信号, 不断优化控制策略, 生成实时反馈控制。最终的控制信号是前馈与反馈输出的加权组合, 并通过 PD 控制器进一步微调以实现精确运动。SRL 已在双足和四足机器人的仿真以及选定的真实环境中得到验证, 展示了其在多种跳跃任务中的适应性和卓越性能。

3.2. SLIP 模型

SLIP 模型如图 1 左上角所示, 由一个连接单弹簧的质点构成, 代表一条简化的虚拟腿。该模型通过动态质量 - 弹簧系统模拟腿式运动。我们开发了一个六状态有限状态机 (图 2), 通过状态依赖的参数调制实现稳定的跳跃模式, 包括在不同运动阶段动态调整弹簧刚度、阻尼系数和原始长度。每个状态下质心所受的力可由以下方程表示:

$$F_i = -k_i \Delta L - c_i v_m, \quad (1)$$

其中 $i \in \{-1, 0, 1, 2, 3, 4\}$ 表示状态机模式, $\Delta L = (\|p_m - p_f\| - \|p_{m0} - p_{f0}\|)$ 表示质心与足部之间距离相对于初始值的变化量, v_m 是质心的速度, k_i 和 c_i 分别是依赖于状态的刚度和阻尼系数。

3.2.1. Initialization Phase (State -1)

在初始化阶段, 机器人设定质心 (p_m) 和足部 (p_f) 的初始位置, 并根据 p_m 与 p_f 之间的位移计算初始力 F_{-1} 。初始化完成后, 状态转换至下一阶段。




图 2: 基于 SLIP 模型构建的六状态有限状态机, 每个状态代表跳跃周期中的一个关键阶段。

3.2.2. Ground Contact Phase (State 0)

在地面接触阶段, 机器人的脚与地面接触, 腿部像弹簧一样压缩, 产生力 F_0 将质心向上推。力的大小由质心与脚之间的位移 ΔL 以及单位方向向量 $\hat{n}$ 决定。当位移 ΔL 变得足够小且质心速度的垂直分量 $(v_m)_y > 0$ 满足条件时, 状态转换到跳跃加速阶段。

3.2.3. Jump Acceleration Phase (State 1)

在此阶段, 机器人进一步增加力 F_1 以加速质心向上, 确保机器人能够离开地面并进入飞行阶段。该阶段主要负责为机器人提供足够的动能以完成跳跃。当位移 ΔL 超过阈值时, 状态转换到飞行阶段。

3.2.4. Flight Phase (State 2)

在飞行阶段, 机器人离开地面进入自由运动状态。此阶段无外力作用。质心 (p_m) 的运动由惯性主导, 而足部位置 (p_f) 则根据先前的相对位移进行调整, 以确保正确的着陆位置。当 $(v_m)_y < 0$ 且足部接近地面时, 状态转换至下一阶段。此阶段无外力作用。

3.2.5. Landing Preparation Phase (State 3)

在此阶段, 机器人开始逐渐接触地面, 施加缓冲力 F_3 以减缓质心的下降速度。当质心的垂直速度 $(v_m)_y$ 开始上升时, 机器人过渡到恢复阶段。此阶段施加较小的力以缓冲着陆。

3.2.6. Recovery Phase (State 4)

在恢复阶段, 机器人重新建立与地面的接触, 并根据初始位移计算力, 以将质心和足部恢复至其原始相对位置。当质心 (p_m) 和足部 (p_f) 的位置接近初始状态时, 状态转换回状态 -1, 开始新的跳跃循环。

3.3. 机器人逆运动学

为了将理论上的 SLIP 模型应用于实际机器人, 我们采用解析逆运动学方法来确定每个关节的最优角度。以双足机器人为例, 根据 SLIP 模型获得机器人质心 (p_m) 和足部 (p_f) 的目标位置, 并据此计算其髋关节、膝关节和踝关节的相应角度。

首先, 计算质心与足部之间的距离 d_1 , 并利用三角关系确定髋关节角度:

$$dc_1 = \arccos\left(\frac{L_1^2 + d_1^2 - L_2^2}{2L_1d_1}\right) + \arcsin\left(\frac{(p_m - p_f)_z}{d_1}\right), \quad (2)$$

其中 L_1 和 L_2 分别是大腿和小腿的长度, $(p_m - p_f)_z$ 表示质心与足部沿 z 轴的位移。

接下来, 使用以下公式计算膝关节角度 dc_2 :

$$dc_2 = -\arccos\left(\frac{L_1^2 + L_2^2 - d_1^2}{2L_1L_2}\right) - dc_1. \quad (3)$$

最后, 踝关节角度 dc_3 由髋关节和膝关节角度之和确定:

$$dc_3 = dc_2 + dc_1. \quad (4)$$

通过这些方程, IK 方法能够快速准确地调整双足机器人的关节角度, 确保跳跃过程中足部的正确定位和姿态。

3.4. 强化学习

在我们之前的工作 [45], 中, 我们提出了一种名为 “教学式学习” 的学习框架, 该框架整合了受人类学习过程启发的前馈和反馈控制机制。该方法在机器人运动学习中已被证明高效、灵活且具有泛化能力。在当前研究中, 我们基于这种 “教学式学习” 方法设计了一种扩展的控制系统架构, 并将其与强化学习 (具体为 PPO [28–30]) 相结合, 以优化机器人的跳跃任务。PPO 是一种广泛使用的策略梯度算法, 特别适用于机器人运动等连续控制任务。通过使用裁剪的替代目标函数, 它确保了稳定的策略更新, 防止了可能破坏学习稳定性的过激变化。这使得在复杂环境中能够实现更优的收敛性和鲁棒性能。

前馈信号设计: 我们系统中的前馈信号源自 SLIP 模型, 记为 $\mathbf{a}_{ff}(t) = \mathbf{f}(\text{SLIP}, t)$, 并作为控制器的初始参考轨迹。具体而言, 通过逆运动学求解器获得的关节角度被用作神经网络的输入。对于双足机器人, 这包括髋关节、膝关节和踝关节的俯仰角。对于四足机器人, 由于设计不包含踝关节, 仅使用髋关节和膝关节的角度。

动作空间: 机器人的动作由前馈控制信号与强化学习算法产生的反馈控制信号组合生成。在每个时间步, 计算关节控制信号。反馈信号 $\mathbf{a}_{fb}$ 与前馈信号 $\mathbf{a}_{ff}$ 的加权和构成最终的目标关节角度配置:

$\mathbf{a}_t = \mathbf{a}_{ff} + k_b \times \mathbf{a}_{fb}$ 。最后, 使用 PD 控制器将该目标角度转换为关节扭矩, 确保跳跃动作的精确执行。

状态空间: 在我们的状态空间 $\mathbf{O}_t$ 中, 智能体在跳跃过程中观测机器人的关键动态参数, 从而能够精确调整其运动。状态空间包括以下观测值: 机器人本体在局部坐标系中的线速度 $\mathbf{v}_{base}$ 和角速度 $\boldsymbol{\omega}_{base}$, 以及俯仰角 θ_{pitch} 和横滚角 θ_{roll} 。此外, 还包含关节角度偏差 $\Delta a_1, \Delta a_2, \dots, \Delta a_n$, 即前馈信号 (SLIP 模型的目标角度) 与实际关节角度之间的差值。同时观测关节速度 $v_1, v_2, \dots, v_n$ 以监测关节的动态状态。这些观测值为智能体提供了对机器人姿态和运动的全面理解, 使其能够在复杂跳跃任务中动态调整动作以保持稳定性和精度。

奖励函数: 在我们的机器人跳跃任务中, 奖励函数对于确保精确且稳定的运动控制至关重要。奖励函数的具体实现通过以下组件进行描述:

1) **存活奖励:** 该奖励确保机器人在每个时间步保持活跃, 这对于完成长期跳跃任务至关重要。

$$r_{live} = 1. \quad (5)$$

表 1 所提出的 SRL 框架的关键控制与奖励参数

Parameter	Biped	Quadruped	Reward Weight	Early Stage	Late Stage
k_b	30	$[10, 30, 60]^\dagger$	w_1	2	1
k_p	0.1	0.02	w_2	0.5	1
k_y	0.5	2	w_3	0	1
k_r	0.1	0.02	w_4	1	1

[†] For the quadruped robot, per-leg feedback gains are 10, 30, and 60 for the hip, thigh, and knee joints, respectively.

2) **姿态奖励**：该奖励通过惩罚俯仰、偏航和滚转角度的偏差，确保机器人在空中和着陆时的稳定性。

$$r_{ori} = -k_p \cdot |\theta_{pitch}| - k_y \cdot |\theta_{yaw}| - k_r \cdot |\theta_{roll}|, \quad (6)$$

其中 θ_{pitch} 是俯仰角偏差， θ_{yaw} 是偏航角偏差， θ_{roll} 是滚转角偏差， k_p 、 k_y 、 k_r 分别是俯仰、偏航和滚转角度的系数。

3) **速度奖励**：该奖励通过惩罚机器人实际速度与预期速度之间的偏差，确保其在跳跃过程中保持平滑运动。

$$r_{vel} = -\|\mathbf{v}_{actual} - \mathbf{v}_{expected}\|, \quad (7)$$

其中 $\mathbf{v}_{actual}$ 是机器人当前速度， $\mathbf{v}_{expected}$ 是任务预期速度。

4) **同步奖励**：该奖励通过惩罚双腿关节角度的差异，确保运动同步。

对于双足机器人：

$$r_{syn} = -\sum_{i=1}^N |a_i^{left} - a_i^{right}|. \quad (8)$$

对于四足机器人：

$$r_{syn} = -\sum_{i=1}^N (|a_i^{FL} - a_i^{FR}| + |a_i^{RL} - a_i^{RR}|). \quad (9)$$

5) **足部位置跟踪奖励**：该奖励最小化机器人足部位置与目标位置之间的偏差，确保每一步都遵循预定轨迹。

$$r_{pos} = -\sum_{j=1}^M \|\mathbf{p}_j^{actual} - \mathbf{p}_j^{target}\|, \quad (10)$$

其中 $\mathbf{p}_j^{actual}$ 是腿 j 的实际足部位置， $\mathbf{p}_j^{target}$ 是目标足部位置。

6) **总奖励**：总奖励是所有单个奖励的加权组合。

$$r_{total} = r_{live} + w_1 r_{ori} + w_2 r_{vel} + w_3 r_{syn} + w_4 r_{pos}, \quad (11)$$

其中 w_1 、 w_2 、 w_3 和 w_4 分别是方向、速度、同步性和足部位置奖励的权重系数。控制参数和奖励权重总结于表 1。

终止条件：如果机器人“摔倒”，即俯仰角 θ_{pitch} 或横滚角 θ_{roll} 超过 30 度，则终止该回合。若时间步长达到 1000，该回合也结束。

网络与超参数：PPO 算法使用的网络架构和训练超参数分别如表 2 和表 3 所示。

表 3 双足与四足机器人 PPO 超参数

表 2 双足与四足机器人网络架构

Hyperparameter	Value
Actor Hidden Layer	[512, 512, 512]
Critic Hidden Layer	[512, 512, 512]
Input Observation Dimension	28 / 32
Output Action Dimension	10 / 12
Activation Function	ReLU

Hyperparameter	Value
Discount Factor	0.995
GAE Discount Factor	0.95
Minibatch Size	2024 / 2048
Timesteps per Rollout	20240 / 20480
Epochs per Rollout	3
Entropy Bonus Coefficient	0.005
Value Loss Coefficient	1.0
Clip Range	0.2
Learning Rate	0.0003
Environments	32




图 3：左图：双足机器人随机距离跳跃的奖励演化；右图：固定距离跳跃中纯强化学习与 SRL 的学习效率对比。

4. 实验

4.1. 仿真设置

在本研究中，我们使用 Unity 引擎和 ML-Agents 工具包进行仿真与训练实验。仿真以 0.01 秒的时间步长运行，对应 100Hz 的控制频率。为加速训练过程，我们并行部署了 32 个智能体实例，以确保高效的策略学习。

我们选择了两种机器人来验证我们的方法：由上海卓宇机器人研发的 X02-lite 双足机器人，以及由杭州宇树科技研发的 Unitree Go2 四足机器人。这些机器人代表了典型的双足和四足设计，非常适合评估 SRL 的泛化能力。

4.2. 训练过程

4.2.1. Phase-Based Training Strategy

训练过程分阶段进行，以逐步将重点从稳定性转向速度和效率。例如，在双足机器人随机距离跳跃任务的训练过程中，奖励函数的权重参数 w_1 、 w_2 、 w_3 和 w_4 在不同阶段进行调整，如图 3 左侧部分所示，并总结于表 1。初始阶段，通过为方向奖励分配更高的权重来强调稳定性。随着训练的进行，奖励权重逐渐调整，优先考虑速度而非方向，旨在提高机器人的速度和跳跃效率，同时保持基本稳定性。这种分阶段的奖励塑造策略使策略能够在不同跳跃距离下从稳定运动过渡到速度优化性能。

表 4 基线对比与消融实验

Method	Training Steps (10^6)		Success Rate	
	Biped	Quadruped	Biped	Quadruped
(a) Baseline				
SLIP-based MPC	N/A	N/A	0.680	0.752
RL-only (PPO)	7.2	3.8	0.913	0.957
Ours (SRL)	5.7	1.1	0.985	0.998
(b) Ablations				
Ours	5.7	1.1	0.985	0.998
w/o FSM Structure	7.5	3.8	0.803	0.886
w/o Velocity Reward	6.2	1.6	0.895	0.912

4.2.2. *Jumping Tasks Design*

我们使用双足和四足机器人执行了固定距离与随机距离跳跃任务。固定距离任务（如 0.1 米、0.2 米）通过持续的目标训练稳步提升策略性能，而随机距离任务（双足机器人 0-0.3 米）则要求机器人在连续短距离跳跃后突然适应长距离跳跃（如 0.3 米），从而严格检验策略的动态适应能力。双足训练因重心较高，需在距离变化时同步维持稳定与调整运动，因此更侧重跳跃过程中的平衡控制；相比之下，四足机器人稳定性更高，这促使我们为其设计更具挑战性的任务。为此我们开展了跳上箱体的任务——该任务在水平跳跃基础上引入垂直高度变化，全面验证了 SRL 框架在多维运动场景中的鲁棒性。

4.3. 性能评估

4.3.1. *Baseline Comparison*


表 4 展示了三种不同控制方法（基于 SLIP 的 MPC、纯强化学习（PPO）以及我们的 SRL）在学习效率上的全面对比。由于奖励结构存在根本性差异，直接比较 SRL 与纯强化学习方法之间的奖励值并无意义。因此，我们聚焦于更高层次的性能指标——即训练步数和成功率——以实现对学习效率更有效且更具洞察力的评估。训练步数指达到收敛策略所需的总学习更新次数，该策略定义为在最大回合长度 1000 的条件下，持续实现回合长度超过 950 且奖励水平稳定。成功率则计算为 1000 次测试试验中未跌倒的成功跳跃比例（例如，成功率 0.998 对应 998 次成功试验）。

基于 SLIP 的 MPC 方法取得了中等性能，双足机器人的成功率为 68.0%，四足机器人为 75.2%。虽然这证明了将生物力学先验知识融入控制的有效性，但缺乏在线学习限制了其鲁棒性和适应性。相比之下，仅使用强化学习的方法表现出显著提升的性能，双足机器人成功率达到 91.3%，四足机器人达到 95.7%，但代价是训练时间较长（分别为 720 万步和 380 万步）。我们提出的 SRL 方法进一步改进了这些结果，取得了最高的成功率——双足机器人 98.5%，四足机器人 99.8%——同时所需的训练步数显著减少（分别为 570 万步和 110 万步），如图 3 右侧部分所示。这种训练复杂度的降低表明，将分析先验知识与强化学习相结合不仅提升了性能，还显著加速了学习收敛。


4.3.2. *Ablation Study*

为了验证 SRL 架构中每个核心组件的贡献，我们通过移除六状态有限状态机结构和速度奖励进行了消融研究。所有变体均在相同的实验设置下进行训练和评估。如表 4 所示，移除任一组件都会导致训练步数增加和成功率下降，这凸显了相位感知控制和速度跟踪对于高效稳定跳跃的重要性。

在“无 FSM”设置中，离散的相位转换机制被禁用。跳跃周期改为由预定义的基于余弦的振荡器生成，产生一个具有固定周期和连续性的平滑周期信号



(a) Fixed-distance jumping.



(b) Random-distance jumping.

图 4: 双足机器人在固定距离跳跃中的表现, 展示了躯干速度、躯干位置的绝对跟踪误差以及踝关节的相对跟踪误差。

用于跳跃运动的前馈关节参考。这种时间驱动公式用固定频率的节律模式取代了状态依赖的相位切换。由于缺乏自适应相位调制, 控制器依赖于固定的节律信号, 这削弱了相位协调和运动稳定性, 导致跳跃性能下降。

移除速度奖励会减慢收敛速度并降低稳定性, 表明速度跟踪为鲁棒控制提供了必要的指导。

定量分析显示, 移除 FSM 结构使训练步数从 570 万增加到 750 万, 成功率从 98.5% 降至 80.3%; 而移除速度奖励则导致训练步数为 620 万, 成功率为 89.5%。这些结果表明, 相位感知控制和速度跟踪均显著提高了样本效率和最终性能, 充分验证了所提出的 SRL 框架。

4.4. 仿真结果

双足机器人: 如图 4 所示, 展示了双足机器人在固定距离和随机距离跳跃任务中的表现。该图比较了机器人身体速度与目标速度, 以及身体和末端执行器的跟踪误差。在固定距离跳跃任务中, 机器人有效跟踪了目标速度, 达到 2m/s 的峰值速度。然而, 随着时间的推移, 位置跟踪误差开始累积。相反, 在随机距离跳跃任务中, 跳跃距离的变化使机器人更容易纠正其位置跟踪误差, 尽管这导致位置跟踪精度略有下降。





图 5：四足机器人在固定距离和随机距离跳跃任务中的表现，展示了躯干速度、躯干位置的绝对跟踪误差以及足部的相对跟踪误差。




图 6：双足和四足机器人的固定距离跳跃仿真。橙色和绿色分别表示目标状态和实际状态。

精度。总体而言，在两项任务中，双足机器人在跟踪目标速度方面表现出强大的能力，在 10 秒内将身体跟踪误差保持在 0.2 米以内。

尽管足部执行器在跳跃过程中偶尔会出现周期性误差尖峰，但分析表明，这些峰值主要发生在起跳和着陆时刻，尤其是在起跳后立即出现，此时机器人




图 7：双足（左）和四足（右）机器人在随机距离跳跃任务中的仿真，展示了身体和脚踝 / 足部的运动轨迹。

腿部关节承受了最大的爆发力，其身体速度达到峰值。由于系统动态灵敏度的提高，即使是微小的位置误差也会被放大。尽管图中显示了较大的误差尖峰，但这些误差本质上是瞬态的（持续时间小于 100 毫秒），发生在无地面接触的飞行阶段，并未导致长期不稳定。其他阶段的快速调整成功地在平均意义上补偿了这些误差，将误差维持在 0 到 0.1 米的范围内。在执行跳跃任务的四足机器人中也观察到了类似现象（图 5）。

图 6 展示了双足机器人在固定距离跳跃任务中的身体和脚踝轨迹，清晰地呈现了机器人在整个任务中的运动模式。图 7 展示了双足机器人在随机距离跳跃任务中的表现。该图清晰地展示了机器人灵活适应不同跳跃距离的能力，展现了其卓越的敏捷性和跳跃能力。这种对不同指令的动态适应性进一步证明了 SRL 在处理复杂多变条件时的有效性和精确性。

四足机器人：与双足机器人相比，四足机器人在相同时间内能够完成更多次跳跃，并达到更高的身体速度，最大速度为 3 米 / 秒。与双足情况类似，四足机器人在固定距离跳跃任务中表现出更好的速度跟踪能力，但位置跟踪误差随时间累积。详细结果见图 5。

四足机器人在固定距离跳跃任务中的仿真结果如图 6 所示。在随机距离跳跃任务中（如图 7 所示），机器人同样表现出灵活适应不同跳跃距离的能力，展现出优异的稳定性和跳跃效率。

在跳箱实验中，四足机器人表现出色（如图 8 所示）。尽管由于协调四条腿以适应不平整的复杂性，身体绝对位置误差随时间增加




图 8：四足机器人在跳箱实验中的表现。左侧显示绝对身体位置误差和相对足部误差，右侧显示身体和足部的高度。




图 9：四足机器人在跳箱实验中的仿真。

地形中，机器人仍能将相对足部误差大部分保持在 0.05 米以内。此外，跳跃过程中身体和足部的高度（y 坐标）表明，机器人在上台阶时成功调整了姿态并伸展腿部以应对垂直位移。四条腿的轨迹基本同步，该图清晰显示机器人能够成功跳上高度为 0.35 米的箱子。图 9 展示了跳箱过程中身体和足部轨迹的仿真，清晰呈现了机器人在整个任务中的协调性和运动模式。

上述结果证实了我们的 SRL 框架在各种运动任务和平台上的有效性。值得注意的是，由于不同跳跃场景下的控制需求不同，当前策略是针对每个特定任务分别训练的。探索一种能够通过高级指令泛化到不同任务的统一策略，将是未来工作的重要方向。




图 10: 实验中使用的 X02-lite 人形机器人 (上海达闼机器人), 身高 168 厘米, 总质量 28 千克。(a) 真实机器人。(b) Mujoco 模型。(c) 简化连杆模型 (重点关注 10 自由度的腿部)。

表 5 域随机化参数

Parameter	Range[Min,Max]
Base Mass	$[-3, 3]$ kg
CoM	$[-0.15, 0.15]$ m
Ground Friction	$[0.5, 1.5]$
Restitution	$[0.2, 1.0]$
Push Interval	4 s
Push Velocity (XY)	$[0, 0.5]$ m/s
Push Angular Velocity	$[0, 0.4]$ rad/s
Motor Strength	$[0.9, 1.2] \times \text{default}$ Nm
Motor O set	$[-0.05, 0.05]$ rad $\times$ default rad
Joint Kp	$[0.8, 1.3] \times \text{default}$
Joint Kd	$[0.5, 1.5] \times \text{default}$
Gravity Interval	7 s
Gravity Impulse Duration	1.0 s
Gravity Range	$[-0.5, 0.5] \times \text{default}$ m/s ²

4.5. 真实世界实验

为了进一步验证所提出的 SRL 框架, 我们使用双足机器人平台进行了真实世界实验, 并将结果与仿真结果进行了比较。实验中使用的物理机器人是 X02-lite 双足机器人 (图 10)。

X02-lite 总高度为 168 厘米, 臂展为 167 厘米, 与普通人比例非常接近。它重 28 千克, 下半身有两个 35 厘米的腿部段——大腿和小腿。该系统包含 26 个自由度 (DOF), 每条腿有 5 个独立驱动的关节, 包括一个峰值扭矩可达 180 牛米的膝关节。关节位置通过双编码器配置进行测量, 为运动控制提供高精度反馈。底层控制以 1 千赫兹运行, 实现快速响应的关节动力学。环境感知通过立体视觉系统和 YIS320 惯性测量单元实现, 该单元结合了三轴微机电系统加速度计和陀螺仪, 用于实时三维姿态估计。为了更好地利用这些传感器测量值并估计线速度, 我们实现了一个接触辅助不变扩展卡尔曼滤波器 (CI-EKF) 框架 [46]。这是一种基于李群理论的对称感知观测器设计, 已被证明




图 11: 训练策略在仿真（Isaac Gym 和 Mujoco）与真实世界实验中的性能对比，展示了成功的迁移。机器人实现了最大跳跃高度 15 厘米、跳跃距离 20 厘米以及峰值速度 2 米 / 秒。

提供了优于标准四元数扩展卡尔曼滤波器的估计性能。估计的速度在真实机器人部署中作为强化学习策略的输入。

在训练与仿真阶段，为提升所学策略向真实场景的迁移能力，我们采用了 Humanoid Gym 框架 [47]，并使用了 Isaac Gym 和 Mujoco 平台。训练流程与基于 Unity 的仿真保持一致，包含相同的前馈控制、观测空间和奖励函数。在整个训练过程中，对多种物理参数应用了域随机化，以增强策略对环境变化和硬件缺陷的鲁棒性。具体的域随机化参数总结于表 5。

训练过程始于在 IsaacGym 中训练策略。我们通过调整域随机化参数进一步优化策略，将其迁移至 MuJoCo 评估性能，随后通过仿真到现实的转换部署到 X02-lite 机器人上。图 11 展示了来自 Isaac Gym、MuJoCo 和真实世界的结果。

在真实世界测试中，机器人成功执行了跳跃任务，紧密复现了仿真性能。实验过程中，机器人实现了最大跳跃高度 15 厘米、单次跳跃距离 20 厘米以及峰值速度 2 米 / 秒。




图 12：一个步态周期内的平均身体高度对比：参考值、仿真值与真实世界值。

表 6：不同设置下（参考值、仿真值与真实世界值）一个周期内的平均关键性能指标。

Setup	Peak Velocity (m/s)	Jump Height (m)	Flight Time (s)
Reference	1.998	0.153	0.718
Simulation	2.011	0.127	0.723
Real-world	2.003	0.150	0.721

为了进一步量化仿真到现实的迁移性能，我们比较了机器人在三种设置（参考值、仿真值和真实世界值）下单个步态周期内的平均基座高度——如图 12 所示。尽管整体运动模式已成功迁移，但在腾空和触地转换阶段观察到了幅度和相位上的微小偏差。这些差异可能源于硬件限制、传感器噪声和估计误差的综合作用——尤其是在腾空阶段，CI-EKF 提供的线速度估计会发生漂移，这会影​​响策略对机器人状态的感知，并导致轻微的跟踪误差。

表 6 总结了机器人在三种不同设置下，一个步态周期内跳跃的平均关键性能指标。所有设置下的峰值速度几乎相同（0.0 m/s）。仿真跳跃高度比实际测试低约 15%（0.127 米对比 0.150 米）。这一差异可能源于仿真环境的局限性，例如简化的接触模型。所有设置下的腾空时间保持相对一致（0.72 秒），表明即使在仿真中，腾空阶段的持续时间也得到了很好的保留。

这些结果表明向真实场景迁移具有良好前景，值得进一步研究实际部署。

5. 结论

本文提出 SRL，一种将 SLIP 模型与强化学习相结合的控制框架，用于优化机器人跳跃性能。SLIP 模型生成基础跳跃动力学，而强化学习增强环境适应性。通过在双足和四足机器人上执行固定距离和随机距离跳跃任务，验证了该框架的有效性。仿真和真实世界实验表明，其定位精度达到厘米级（平均轨迹跟踪误差 < 10 厘米），速度跟踪误差在目标值的 $\pm 3\%$ 以内，且四足机器人能够攀爬 0.35 米高的台阶。由于四足机器人硬件平台的安全性和执行器限制，本文未包含在四足机器人上的真实世界验证。

当前局限性包括长时间任务中的误差累积以及硬件部署不稳定。此外，尽管 SRL 理论上支持生成任意三维轨迹并通过强化学习执行三维跳跃，但出于硬件安全考虑，我们目前将实验限制在二维空间。未来工作将专注于改进持续

稳定性、开发高效的仿真到现实策略，以及将应用扩展到三维跳跃。所提出的 SRL 框架为动态机器人控制研究提供了一种高效且适应性强的解决方案。

声明

基金资助本研究得到上海市科学技术委员会资助（项目编号：24511103304）。

数据与材料可用性所有相关数据均包含在本文中。**利益冲突**作者声明不存在竞争利益。**伦理批准与参与同意**不适用。**出版同意**不适用。

CRedit 作者贡献声明

胡晓文：概念化、方法论、软件、形式分析、调查、验证、撰写——初稿。**叶林奇**：概念化、监督、资金获取、资源、项目管理、撰写——审阅与编辑。**朱宇迪**：软件、验证、数据整理。**邵晨月**：方法论、软件、形式分析。**李然坤**：调查、数据整理。**李庆度**：监督、资源、验证。**彭艳**：监督、资源、撰写——审阅与编辑。

参考文献

- [1] X. Mo, W. Ge, M. Miraglia, F. Inglese, D. Zhao, C. Stefanini, D. Romano, 跳跃运动策略：从动物到仿生机器人, *Applied Sciences* 10 (23) (2020) 8607. doi:10.3390/app10238607.[2] J.-S. Koh, E. Yang, G.-P. Jung, S.-P. Jung, J. H. Son, S.-I. Lee, P. G. Jablonski, R. J. Wood, H.-Y. Kim, K.-J. Cho, 水面跳跃：水龟和机器昆虫的表面张力主导跳跃, *Science* 349 (6247) (2015) 517–521. doi:10.1126/science.aab1637.[3] C. Yi, X. Chen, Y. Zhang, Z. Yu, H. Qi, Y. Liu, Q. Huang, 使用带足部结构的简化模型模拟人形机器人垂直跳跃的地面反作用力以进行足部设计, *Journal of Bionic Engineering* 21 (1) (2024) 112–125. doi:10.1007/s42235-023-00429-8.[4] X. Wang, W. Guo, Z. He, R. Li, F. Zha, L. Sun, 通过在线质心轨迹优化和高动态运动控制器实现人形机器人仿生跳跃, *Journal of Bionic Engineering* 21 (6) (2024) 2759–2778. doi:10.1007/s42235-024-00586-4.[5] Z. Zhao, S. Sun, H. Huang, Q. Gao, W. Xu, 基于运动功能和强化学习的人形机器人连续跳跃步态设计与控制, *Procedia Computer Science* 250 (2024) 51–57. doi:10.1016/j.procs.2024.11.008.[6] Y. Liu, X. Chen, Z. Yu, H. Qi, C. Yi, 结合质心动力学和全身运动学的单次序列轨迹优化用于人形机器人垂直跳跃, *Biomimetics* 9 (5) (2024) 274. doi:10.3390/biomimetics9050274.[7] G. Ribak, 昆虫启发跳跃机器人：跳跃稳定性的挑战与解决方案, *Current Opinion in Insect Science* 42 (2020) 32–38. doi:10.1016/j.cois.2020.09.001.[8] K. Y. Su, J. Z. Gul, K. H. Choi, 一种功能梯度青蛙软体机器人的仿生跳跃运动, 2017 年第 14 届国际普适机器人与环境智能会议 (URAI), IEEE, 2017, pp. 675–676. doi:10.1109/URAI.2017.7992792.[9] M. Afschrift, E. Van Asseldonk, M. Van Mierlo, C. Bayon, A. Keemink, L. D' Hondt, H. Van Der Kooij, F. De Groote, 使用仿生外骨骼控制器辅助行走平衡, *Journal of Neuroengineering and Rehabilitation* 20 (1) (2023) 82. doi:10.1186/s12984-023-01205-9.[10] D. Ezekiel, R. Samikannu, O. Matsebe, 用于不确定气动 MIMO 系统控制器整定 / 参数估计的仿生跳蛛优化, *Chaos Theory and Applications* 6 (3) (2024) 205–217. doi:10.51537/chaos.1396823.[11] H. Elliott, X. An, M. Wang, 一种仿生跳跃机器人：设计、建模与实验测试, 自主机器人系统年度会议 (TAROS), Springer, 2024, pp. 164–170. doi:10.1007/978-3-031-72062-8_15.[12] M. Kabir, A. Anand, P. Sundaravadivel, Hop-bot: 一种模块化机器人运动与稳定性的仿生方法, 2024 年 IEEE 国际信息技术会议 (EIT), IEEE, 2024, pp. 285–290. doi:10.1109/eIT60633.2024.10609916.[13] J. Hong, C. Yeo, S. Bae, J. Hong, S. Oh, 基于 SLIP 模型的鲁棒四足机器人控制, 2024 年 IEEE/RSJ 国际智能机器人与系统会议 (IROS), IEEE, 2024, pp. 14219–14224. doi:10.1109/IROS58592.2024.10802545.[14] G. Piován, K. Byl, 基于可达性的主动 SLIP 模型控制, *The International Journal of Robotics Research* 34 (3) (2015) 270–287. doi:10.1177/0278364914552112.[15] G. Piován, K. Byl, 通过部分反馈线性化和两元件腿驱动策略的 SLIP 模型动力学近似与控制, *IEEE Transactions on Robotics* 32 (2) (2016) 399–412. doi:10.1109/TRO.2016.2529649.[16] H. Hamzaçebi, I. Uyanik, Ö. Morgül, 基于部分反馈线性化的双足步行模型分析与控制, *Bioinspiration & Biomimetics* 19 (5) (2024) 056004. doi:10.1088/1748-3190/ad5cb6.[17] H.-W. Park, P. M. Wensing, S. Kim, MIT Cheetah 2 跨越障碍物, *Robotics and Autonomous Systems* 136 (2021) 103703. doi:10.1016/j.robot.2020.103703.[18] D. Ahn, B.-K. Cho, 通过模型预测控制的在线跳跃运动生成, *IEEE Transactions on Industrial Electronics* 69 (5) (2021) 4957–4965. doi:10.1109/TIE.2021.3078396.

[19] G. Ji, J. Mun, H. Kim, J. Hwangbo, 动态鲁棒腿式运动的控制策略与状态估计器协同训练, IEEE Robotics and Automation Letters 7 (2) (2022) 4630–4637. doi:10.1109/LRA.2022.3151396.[20] Z. He, J. Wu, J. Zhang, S. Zhang, Y. Shi, H. Liu, L. Sun, Y. Su, X. Leng, Cdm-mpc: 一种用于双足机器人跳跃的集成动态规划与控制框架, IEEE Robotics and Automation Letters 9 (7) (2024) 6672–6679. doi:10.1109/LRA.2024.3408487.[21] Z. Xu, J. Xie, K. Hashimoto, 基于模型预测控制的仿人步态与双足机器人跳跃运动生成, Biomimetics 10 (1) (2025) 17. doi:10.3390/biomimetics10010017.[22] Z. Fu, Z. Yu, X. Chen, L. Han, P. Gergondet, J. Zhang, Q. Huang, 基于滑模正则化预测控制的连续双足跳跃, IEEE/ASME Transactions on Mechatronics (2024). doi:10.1109/TMECH.2024.3515151.[23] J. Kober, J. A. Bagnell, J. Peters, 机器人学中的强化学习: 综述, The International Journal of Robotics Research 32 (11) (2013) 1238–1274. doi:10.1177/0278364913495721.[24] C. Tao, M. Li, F. Cao, Z. Gao, Z. Zhang, 一种用于双足机器人跳跃优化的多目标协同深度强化学习算法, Advanced Intelligent Systems 6 (1) (2024) 2300352. doi:10.1002/aisy.202300352.[25] M. Hutter, C. D. Remy, M. A. Höpinger, R. Siegwart, 基于铰接式机器人腿的 SLIP 奔跑, 2010 年 IEEE/RSJ 国际智能机器人与系统会议, IEEE, 2010, pp. 4934–4939. doi:10.1109/IROS.2010.5651461.[26] X. He, X. Li, X. Wang, F. Meng, X. Guan, Z. Jiang, L. Yuan, K. Ba, G. Ma, B. Yu, 基于 SLIP 模型的四足机器人奔跑步态与控制, Biomimetics 9 (1) (2024). doi:10.3390/biomimetics9010024.[27] P. M. Wensing, D. E. Orin, 基于 SLIP 模型的类人机器人弹跳控制, 机构学、机器人学设计与教育研究进展 (2013) 265–274. doi:10.1007/978-3-319-00398-6_21.[28] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov, 近端策略优化算法, arXiv 预印本 arXiv:1707.06347 (2017). doi:10.48550/arXiv.1707.06347.[29] C. Yu, A. Velu, E. Vinitzky, J. Gao, Y. Wang, A. Bayen, Y. Wu, PPO 在合作多智能体游戏中的惊人效果, 神经信息处理系统进展 35 (2022) 24611–24624.[30] Y. Zhao, T. Wu, Y. Zhu, X. Lu, J. Wang, H. Bou-Ammar, X. Zhang, P. Du, Zsl-RPPO: 基于循环近端策略优化的四足机器人挑战性地形零样本学习, arXiv 预印本 arXiv:2403.01928 (2024). doi:10.48550/arXiv.2403.01928.[31] Z. Zhang, J. Zhao, H. Chen, D. Chen, 仿生跳跃机器人综述: 起飞、空中姿态调整与着陆缓冲, Applied Bionics and Biomechanics 2017 (1) (2017) 4780160. doi:10.1155/2017/4780160.[32] C. Zhang, W. Zou, L. Ma, Z. Wang, 仿生跳跃机器人: 综合综述, Robotics and Autonomous Systems 124 (2020) 103362. doi:10.1016/j.robot.2019.103362.[33] G. Garofalo, C. Ott, A. Albu-Schäer, 基于双足 SLIP 模型的完全驱动机器人行走控制, 2012 年 IEEE 国际机器人与自动化会议, IEEE, 2012, pp. 1456–1463. doi:10.1109/ICRA.2012.6225272.[34] M. Shahbazi, R. Babuka, G. A. Lopes, 基于弹簧负载倒立摆的行走与奔跑统一建模与控制, IEEE Transactions on Robotics 32 (5) (2016) 1178–1195. doi:10.1109/TRO.2016.2593483.[35] J. Rummel, Y. Blum, A. Seyfarth, 具有弹簧腿的稳健高效行走, Bioinspiration & Biomimetics 5 (4) (2010) 046004. doi:10.1088/1748-3182/5/4/046004.[36] S. Xie, X. Li, H. Zhong, C. Hu, L. Gao, 基于有限足变刚度弹簧负载倒立摆模型的柔顺双足行走, 2021 年第六届 IEEE 先进机器人与机电一体化国际会议 (ICARM), IEEE, 2021, pp. 667–672. doi:10.1109/ICARM52023.2021.9536096.[37] H. Sang, S. Wang, Lunarleap 机器人: 3M 架构增强的深度强化学习方法用于低重力环境下四足机器人跳跃, Journal of Aerospace Engineering 37 (6) (2024) 04024076. doi:10.1061/JAEEZ.ASENG-5619.[38] G. Bellegarda, C. Nguyen, Q. Nguyen, 基于深度强化学习的稳健四足跳跃, Robotics and Autonomous Systems 182 (2024) 104799. doi:10.1016/j.robot.2024.104799.[39] G. Bellegarda, M. Sha ee, M. E. Özberk, A. Ijspeert, 四足蛙: 连续四足跳跃的快速在线优化, 2024 年 IEEE 国际机器人与自动化会议 (ICRA), IEEE, 2024, pp. 1443–1450. doi:10.1109/ICRA57147.2024.10610141.[40] G. Bellegarda, A. Ijspeert, CPG-RL: 学习用于四足运动的中央模式生成器, IEEE Robotics and Automation Letters 7 (4) (2022) 12547–12554. doi:10.1109/LRA.2022.3218167.[41] X. B. Peng, M. Andrychowicz, W. Zaremba, P. Abbeel, 基于动力学随机化的机器人控制仿真到现实迁移, 2018 年 IEEE 国际机器人与自动化会议 (ICRA), IEEE, 2018, pp. 3803–3810. doi:10.1109/ICRA.2018.8460528.[42] Q. Zhou, G. Li, R. Tang, Y. Xu, H. Wen, Q. Shi, 基于深度强化学习的蝗虫仿生机器人稳定跳跃控制, Biomimetics 9 (9) (2024) 548. doi:10.3390/biomimetics9090548.[43] R. J. Full, D. E. Koditschek, 模板与锚点: 腿式陆地运动的神经力学假说, Journal of Experimental Biology 202 (23) (1999) 3325–3332. doi:10.1242/jeb.202.23.3325.[44] H. Geyer, U. Saranli, 基于弹簧负载倒立摆的步态, 载于: A. Goswami, P. Vadakkepat (编), 类人机器人学: 参考手册, Springer, Dordrecht, 2019, pp. 923–947. doi:10.1007/978-94-007-6046-2_43.[45] L. Ye, Y. Cheng, J. Li, X. Wang, B. Liang, Y. Peng, 从认知到实践: 通过指令学习掌握多样化运动技能, Biomimetic Intelligence and Robotics (2026) 100286.[46] R. Hartley, M. Gha ari, R. M. Eustice, J. W. Grizzle, 接触辅助不变扩展卡尔曼滤波用于机器人状态估计, The International Journal of Robotics Research 39 (4) (2020) 402–430. doi:10.1177/0278364919894385.[47] X. Gu, Y.-J. Wang, J. Chen, Humanoid-Gym: 面向类人机器人的零样本仿真到现实迁移强化学习, arXiv 预印本 arXiv:2404.05695 (2024). doi:10.48550/arXiv.2404.05695.