

VMTS: 面向双足机器人多地形运动的视觉辅助师生强化学习

陈福, 万瑞, 刘沛东, 郑南星和周波*

摘要——双足机器人因其拟人化设计, 在各种应用中展现出巨大潜力, 但其控制却受限于结构的复杂性。目前, 大多数研究聚焦于基于本体感知的方法, 这些方法缺乏应对复杂地形的能力。虽然视觉感知对于在人类主导的环境中运行至关重要, 但其集成进一步增加了控制的复杂性。最近的强化学习方法在增强腿式机器人运动方面显示出前景, 尤其是基于本体感知的方法。然而, 地形适应性, 特别是对于双足机器人而言, 仍然是一个重大挑战, 大多数研究集中在平坦地形场景上。在本文中, 我们提出了一种新颖的专家混合教师-学生网络强化学习策略, 该策略通过一种简单而有效的方法, 增强了基于视觉输入的师生策略的性能。我们的方法将地形选择策略与教师策略相结合, 相比传统模型实现了更优越的性能。此外, 我们引入了教师网络和学生网络之间的对齐损失, 而不是强制要求严格相似性, 以提升学生在多样化地形中导航的能力。我们通过在 Limx Dynamic PI 双足机器人上进行实验验证了我们的方法, 证明了其在多种地形类型上的可行性和鲁棒性。

索引术语——双足机器人, 强化学习, 视觉感知控制

I. 引言

双足机器人因其类人结构, 在各个应用领域展现出巨大的潜力和价值。然而, 其设计固有的复杂性给控制带来了持续的挑战。此外, 为了在人类为中心的环境中有效运作, 视觉感知起着关键作用。然而, 视觉输入的整合进一步加剧了控制任务的难度。

在过去的几十年里, 众多研究人员在该领域提出了各种先进方法 [1]–[4]。其中最著名的是波士顿动力的 Atlas 机器人, 它能够执行各种复杂的动作 [5]–[7]。然而, 这些方法大多依赖于集成里程计来生成在线地图, 并且需要大量时间进行离线规划, 通常导致泛化性能有限。

最近, 强化学习在腿式机器人控制方面取得了令人瞩目的成果, 展示了该领域的显著进展 [8]–[13]。目前, 研究



图1. 我们开发了一种端到端基于视觉的强化学习控制策略, 用于双足机器人, 使其能够克服多种地形, 例如15厘米高度差、30度斜坡和草地。

关于腿式机器人的强化学习主要集中于本体感觉。Lee 等人 [8] 率先在腿式机器人上提出了师生网络学习方法。在师生网络中, 拥有特权信息的教师策略在第一阶段进行训练。在第二阶段, 仅依赖本体感觉数据的学生策略模仿教师策略的动作。这种方法使学生策略在仅利用必要信息的情况下, 能够达到与教师策略非常接近的性能, 因此成为一种被广泛研究的方法 [10], [14], [15]。与师生两阶段训练方法不同, 也有许多方法仅需要单阶段训练过程。DreamWaQ [9] 提出了使用变分自编码器 (VAE) 来估计状态的隐式表示。Wang 等人 [16] 将此估计方法应用于双足机器人, 并评估了估计状态对机器人运动性能的影响。Fu 等人 [17] 提出在训练过程中引入编码本体感觉信息的特权学习, 并将此方法应用于移动操作任务。Wang 等人 [18] 提出了一种同时训练教师网络和学生网络的方法, 该方法在最小化对教师策略影响的同时, 显著提升了学生策略的性能。然而, 在缺乏外部感知的情况下, 克服地形对于腿式机器人, 尤其是双足机器人而言, 仍然是一个重大挑战。因此, 当前对双足机器人的研究主要集中在平坦地形环境上。

本工作得到了国家自然科学基金 (NnSF) 的资助, 项目编号为 62073075。(通讯作者: 周波。) 作者单位: 东南大学自动化学院, 南京 210096 (电子邮箱: chenfu010728@gmail.com; wanrui@seu.edu.cn; 220242151@seu.edu.cn; 220221836@seu.edu.cn; zhoubo@seu.edu.cn)。




图 2. 训练概览。在第一阶段，网络输入包括本体感觉信息、机器人周围一米半径内的高度图以及准确的物理参数。此外，利用地形分类和特权信息来调整专家混合的权重，从而促进可靠教师策略的训练。在第二阶段，输入信息仅包含当前的深度图像和本体感觉数据。学生策略的训练通过使用 Barlow Twins 对齐学生策略和教师策略的编码表示，同时采用监督学习引导学生策略模仿教师策略的输出。

引入外部感知有助于克服地形挑战，但同时也增加了训练腿式机器人的难度。尽管如此，近期的进展已经催生了几种有前景的解决方案[19]–[26]。具有外部感知的腿式机器人强化学习同样被分为教师-学生策略和单阶段训练方法。在单阶段训练框架中，Luo等人 [21] 扩展了DreamWaQ [9]，通过引入深度图像并采用基于VAE的方法来隐式估计机器人周围的高度图。与此同时，Yu等人 [22] 提出了一种利用深度图像和历史观测来显式估计高度图和身体状态的方法，使四足机器人能够克服楼梯、陡坡和大间隙等具有挑战性的地形。然而，单阶段训练方法存在两个主要局限：在Isaac Gym [27]中获取视觉感知的难度极大，以及直接学习环境地图的挑战。因此，当前关于具有外部感知的腿式机器人强化学习的研究主要集中在教师-学生策略框架上。[19] 率先提出使用在线生成的高度图作为外部输入，使学生策略能够模仿教师策略的行为，并取得了良好的实验结果。[24] 引入了直接使用深度图像作为

外部输入，无需在线生成高度图。[25] 采用航点作为跟踪目标以提升运动性能。[26]将跑酷技术应用于人形机器人，成功使其能够跨越更高的平台和间隙。

然而，这种两阶段训练范式的局限性在于，由于输入信息的差异，学生策略无法完全模仿教师策略的行为，这甚至可能影响学生策略本身。此外，由于当前大多数训练方法将不同地形视为单一任务并采用相同的策略网络，它们忽略了在不同地形条件下可能出现的潜在冲突，从而导致性能下降。

在本文中，我们提出了一种新颖的专家混合教师-学生强化学习策略，通过一种简单的方法提升了基于视觉输入的师生策略的性能。受 [28]和 [29]的启发，我们引入了专家混合模型以及Barlow Twins。通过将地形选择策略与教师策略相结合，我们的方法优于传统的师生模型。此外，我们的方法侧重于对齐教师与学生之间的输入信息，而非强制它们完全相同，从而提升了学生在多样化地形中导航的能力。我们将算法部署在Limx Dynamic P1双足机器人上，并在多种地形上进行了测试。

I总之, ^{本文的主要贡} h_献 ibuti如下 f thi ^{该论文的研究内容如下:} follows:

- 首先, 我们的框架将专家混合模型与师生策略学习相结合, 其中教师策略根据地形的不同自适应地调整其策略, 为腿式机器人提供了一种新颖的视觉辅助强化学习框架。
- 其次, 与以往直接将教师策略蒸馏到学生策略的方法不同, 我们在蒸馏之前引入了教师与学生之间观测特征空间的隐式对齐与冗余减少, 从而提升了学生策略的性能。
- 最后, 我们提出了一种平滑足部轨迹跟踪奖励函数, 以缩小仿真到现实差距, 并通过全面的仿真与物理实验验证了我们方法的整体有效性与优越性。

II. 方法

A. 概述

如图2所示, 我们提出的框架包含三个主要组成部分: 教师策略、学生策略和专家混合模型。由于单阶段训练中资源消耗高且难以有效学习视觉特征, 我们选择了两阶段师生策略。学生策略的输入仅包含策略部署所需的数据, 而教师策略的输入除了本体感觉信息外, 还融入了仿真环境中可获取的其他特权信息。教师策略采用近端策略优化 (PPO) 算法 [30] 进行优化。此外, 专家混合模型 (详见第二节-B) 已被证明能提升多任务学习性能, 因此被集成到教师策略中, 以改善其在多种地形上的表现。在学生策略的训练过程中, 采用 Barlow Twins (详见第二节-C) 对齐编码特征空间, 同时强制学生策略模仿教师策略的动作, 使其能够逼近教师策略的行为。

1) 教师策略: 教师策略 s_t 的输入包括本体感觉观测 o_t 、周围高度图 m_t , 以及从模拟器中获取的物理参数 o_p , 例如质量、速度和摩擦系数。

$$s_t = \langle o_t, o_p, m_t \rangle \quad (1)$$

本体感觉观测 o_t 是一个 29 维向量, 包含直接从惯性测量单元获取的角速度 w_t 和重力向量 g_t 、关节位置 θ_t 、关节速度 $\dot{\theta}_t$ 、上一时间步的动作 a_t 、用户指令 c_t , 以及足部的参考接触相位 p_t 。

$$o_t = \langle w_t, g_t, \theta_t, \dot{\theta}_t, a_t, c_t, p_t \rangle \quad (2)$$

这里, p_t 表示足部的参考接触相位, 基于 [12] 引入, 作为周期为 0.5 秒的方波函数, 旨在解决缺乏脚掌的有足机器人所面临的平衡挑战。

2) 学生策略: 学生策略的输入包括历史本体感觉观测 o_t^H 以及通过卷积神经网络和循环神经网络处理的深度信息 d_t 。

3) 价值网络: 评估网络 s_t 的输入与教师网络相同。因此, 教师策略训练的损失函数为:

$$\mathcal{L} = \mathcal{L}^{ppo,s} + \mathcal{L}^{value} \quad (3)$$

4) 动作空间: 输出动作 a_t 是一个 6 维向量, 对应双足机器人的 6 个关节, 表示目标位置与默认关节位置之间的偏差。相应地, 关节的 PD 控制定义如下:

$$\tau = k_p \times (a_t - \theta_d) - k_d \times \dot{\theta} \quad (4)$$

B. 专家混合模型

为了实现跨多种地形的运动控制, 我们采用了类似于 [13], 的课程训练方法, 将地形分为几种类型, 例如平坦地面、斜坡、崎岖地形和楼梯, 如图3所示。每种地形类型的难度会随着训练过程中机器人性能的提升而逐步增加, 例如通过增大坡度角、楼梯高度或地面粗糙度。然而, 在不同地形上进行训练可能会影响策略在这些地形类型上的表现。受 [28], 启发, 我们在训练教师策略时引入了专家混合模型。我们将专家数量设为 4 个。地形类别和观测输入的编码器采用三层全连接网络。经过多头注意力和 Softmax 处理后, 输出结果与专家混合模型相乘, 从而得到最终的教师策略编码。因此, 专家混合模型的选择机制表示如下:

$$a_1, a_2, a_3, a_4 = \text{Softmax}(W(g(s_t, t_p))) \quad (5)$$

这里, t_p 表示地形类别, a_i 表示专家权重, W 表示注意力, 而 g 指的是全连接网络。

C. Barlow Twins

在学生策略训练阶段, 如 [19], 所述, 教师策略的输出监督学生策略的输出, 同时教师策略中的特权信息进一步监督学生策略的编码信息, 以促进对教师行为的模仿。我们采用了类似的方法; 然而, 我们并非直接强制学生的编码信息与教师的编码信息匹配, 而是利用 Barlow Twins [29] 方法来对齐学生编码与教师编码的特征空间, 而非强制它们精确接近。因此, 学生训练过程的损失函数可以表示为:

$$\mathcal{L} = \text{MSE}(\hat{a}_t, a_t) + \sum_i (1 - C_{ii})^2 + \lambda \sum_i \sum_{i \neq j} (1 - C_{ij})^2 \quad (6)$$

表I 奖励函数元素




图 3. 地形类型

这里, $\hat{a}_t$ 表示教师策略的输出, $\hat{a}_t$ 表示学生策略的输出, C 指的是学生编码 Z_a 与教师编码 Z_b 之间的互相关矩阵。

III. 训练细节

A. 奖励函数设计

为了实现双足机器人的稳定运动, 我们参考 [18]设计了如表I所示的奖励函数。其中, f_{feet} 表示足底接触力, h 表示身体高度, t_{air} 表示足部腾空时间, p_{left} 和 p_{right} 表示左右足部在身体坐标系中的位置, h_{feet}^{max} 表示足部抬升最大高度, $n_{collision}$ 表示碰撞点数量, τ 表示关节力矩, q_{hip} 表示髋关节位置。为了在训练过程中促进足部平稳着地, 我们对足底接触力施加了惩罚。然而, 由于模拟器中足底接触力测量存在固有的不准确性, 我们在足部距离地面一定距离时, 对其垂直速度施加额外的惩罚, 以补充力惩罚, 从而实现相同目标。该惩罚的表达式如下:

$$r^{fv} = v_z^{feet} \times (h_{feet} < 0.05) \quad (7)$$

由于点足双足机器人缺乏足板结构, 保持平衡变得具有挑战性。因此, 我们引入 [12], 中描述的足部参考相位, 并在机器人的足部相位偏离参考相位时对其进行惩罚。

奖励	公式	权重
线速度跟踪	$\exp(-4 v_{xy}^{cmd} - v_{xy} ^2)$	7.5
角速度跟踪	$\exp(-4 w_{xy}^{cmd} - w_z ^2)$	4.0
线速度 (z轴)	$\dot{v}_z^2$	-0.5
角速度 (xy平面)	w_{xy}^2	-0.06
朝向	g^2	-6.0
基座高度	$ h^{target} - h $	-10.0
关节加速度	$\dot{q}^2$	-2.5×10^{-7}
动作频率	$ a_t - a_{t-1} _2^2$	-0.01
足部腾空时间	$ \max(t_{air}, t_{min}) $	60
关节力矩	$ \tau _2^2$	-2.5×10^{-5}
足底接触力	$ f_{feet} - f_{max} _2^2$	-0.01
足间距	$ p_{left} - p_{right} _2^2$	-100
足部不平衡高度	$ h_{left}^{max} - h_{right}^{max} $	-60
足部不平衡腾空时间	$ t_{left}^{max} - t_{right}^{max} $	-300
碰撞	$n_{collision}$	-30
关节力矩限制	$\max(\tau - \tau_{limit}, 0)$	-0.1
目标足高	$ h_{feet}^{target} - h_{feet} $	-6.0
足部位置 (x)	$ p_x^{left} - p_x^{right} $	-3.0
髋部位置	$ q_{hip} - q_{hip}^{default} $	-1.5
足部接触数量	r^{fn}	2.5
线速度平滑	$ \dot{v}_{xy}^t - \dot{v}_{xy}^{t-1} $	-0.05
生存	$t_{survival}$	-0.05
足部速度	r^{fv}	-0.5

奖励公式如下:

$$r^{fn} = \sum_i^N (1 \times (C_i = S_i) + (-1) \times (C_i \neq S_i)) \quad (8)$$

$$C_i = \begin{cases} 0 & \text{if } \sin(\frac{2\pi t}{T} + \theta) \geq 0 \\ 1 & \text{if } \sin(\frac{2\pi t}{T} + \theta) < 0 \end{cases} \quad (9)$$

$$\theta = \begin{cases} 0 & \text{if } i = left \\ \pi & \text{if } i = right \end{cases} \quad (10)$$

这里, N 表示足部数量, C_i 表示第 i 个足部的参考相位, S_i 表示第 i 个足部的实际相位, 周期 $T=0.5s$ 。

由于双足机器人在训练过程中倾向于持续抬高脚部高度以尝试穿越各种地形, 这种行为不利于保持平衡。因此, 为了在训练中约束脚部高度并确保足部轨迹的平滑性, 我们设计了以下参考足部轨迹:

$$h_{feet,i}^{target} = \frac{1}{2} \max(h_{feet}^{max} \times (1 - \cos(\frac{4\pi t}{T})), 0) \times \neg C_i \quad (11)$$

这里, h_{feet}^{max} 表示最大足部高度。

B. 环境设置

我们采用 NVIDIA Isaac Gym [27]作为仿真环境, 并行训练了8192个机器人, 教师策略和学生策略均使用了8192个机器人。教师策略在大约4000个训练回合后收敛, 在RTX 3090 GPU上耗时约3小时。在训练学生策略时, 由于视觉信息在Isaac Gym中占用大量内存且获取时间较长,

表II 参数设置

参数	数值	Unit
基座高度	0.66	m
脚部高度	0.03	m
动作尺度	0.25	-
降采样	4	-
K_p	40.0	N/rad
K_d	2.0	$N \cdot s/rad$
线速度范围 (x)	[-0.5, 0.5]	m/s
线速度范围 (y)	[-0.2, 0.2]	m/s
角速度范围 (y)	[-0.5, 0.5]	rad/s

表三 域随机化

参数	范围	Unit
有效载荷质量	[-1, 2]	Kg
质心偏移	[-3,3]×[-2,2]×[-3,3]	cm
K_p 因子	[0.8,1.2]	N/rad
K_d 因子	[0.8,1.2]	$N \cdot s/rad$
摩擦	[0.2,1.6]	-
恢复系数	[0.0,1.0]	-
步进延迟	[0, 15]	ms
推送速度 (xy)	0.5	m/s
相机位置	[-5,5]×[-10,10]	mm
相机角度 (俯仰)	[-1,1]	deg
相机视场角	[86,88]	deg

训练时间显著增加。具体而言，在教师策略基础上训练学生策略4000个回合，耗时约120小时。为解决此问题，我们利用 NVIDIA Warp [31]在地形初始化时存储地形网格数据。在获取深度图像时，我们采用基于机器人相机位姿和物理属性的光线投射方法，而非仅依赖Isaac Gym的视觉数据获取。这一改进利用NVIDIA Warp进行深度图像检索，将学生策略的训练时间缩短至约16小时。在训练过程中，机器人的某些训练参数，如PD参数、目标基座高度、足端高度等，按表II所示进行配置。

C. 域随机化

为了增强模型的泛化能力并缩小仿真到现实的差距，从而便于将在仿真中训练的模型部署到真实机器人上，我们对仿真中机器人的某些物理参数在指定范围内进行了阈值随机化。这些参数包括PD控制器增益、摩擦系数、关节质量、相机参数等。阈值随机化的具体设置见表III。

IV. 实验

A. 仿真实验

为了评估所提出方法的有效性，我们与几种替代方法进行了比较




图4. 具有视觉辅助的双足机器人在仿真中的运动时序图。图的下半部分展示了机器人运动过程中通过NVIDIA Warp和光线投射获得的深度图像。

在仿真环境中进行。所有方法均在第三节B部分描述的不同设置下进行训练，并保持奖励函数不变。比较仅通过修改网络架构和损失函数来进行。这些方法的详细描述如下：

- 盲策略：输入仅包含本体感觉信息，并使用近端策略优化（PPO）算法进行训练。
- 教师-学生策略（TS）：两阶段教师-学生策略以深度图像和本体感觉信息作为输入。首先训练教师策略，随后训练学生策略。该方法的详细描述见[25]。
- PIE：单阶段策略在训练模型的同时，显式或隐式地预测速度、身体高度和高度图等信息，具体参考 [21]。

为确保公平比较，对于单阶段训练方法，我们选取了总计8000次迭代的数据。对于两阶段训练方法，我们从每个阶段选取4000次迭代，共计8000次迭代，其中第一阶段4000次迭代，第二阶段4000次迭代。

我们选取平均奖励和地形等级作为训练过程中的评估指标。平均奖励用于指示训练任务的质量，而地形等级则评估机器人克服各种地形的能力。我们的方法及其他几种方法在训练过程中的平均奖励曲线和地形等级曲线分别如图5和图6所示。

图5展示了在训练过程中，我们的教师策略的奖励超过了TS-教师。学生策略的奖励受教师策略性能的影响，因此我们的学生策略相比TS-学生获得了更高的奖励。相比之下，PIE由于预测了速度等变量，更关注速度项，从而在奖励函数中为速度项分配了更高的权重。因此，我们方法的最终奖励与PIE非常接近。图6显示，我们的学生策略的地形等级超过了TS-学生。尽管PIE引入了地形预测，但它仍然难以有效克服具有挑战性的地形。因此，我们的




图5. 我们的方法及其他几种方法在训练过程中的奖励曲线。




图7. TS策略在训练过程中的地形等级曲线，结合了Barlow Twins方法以及我们提出的方法。




图6. 我们的方法及其他几种方法在训练过程中的地形等级曲线。

学生策略的地形等级超过了PIE，而PIE的表现优于盲策略。

为了验证对齐模块（Barlow Twins）对学生策略的影响，我们比较了TS策略、带对齐模块的TS策略以及我们提出的方法的地形等级。结果如图7所示，表明带对齐模块的策略的地形等级超过了原始TS策略，但仍未达到我们方法的性能水平。



图8. 双足机器人在草地上进行机动和转向。

表IV 评估结果

方法	速度误差	高度误差	生存时间
盲策略	0.929	0.076	84.675
PIE	0.546	0.084	87.111
TS	0.673	0.097	88.601
Ours	0.535	0.071	88.485
我们的方法（无Barlow）	0.554	0.079	88.652
我们的方法（无MoE）	0.593	0.093	87.011

在仿真中，我们在多个地形上部署了128个机器人，并采用固定比例，以评估不同策略在速度跟踪、100秒内平均生存时间以及高度跟踪误差方面的表现，这些被视为基本性能指标。结果展示在表IV中。在仿真实验

中，我们的框架在基本用户指令跟踪和生存时间方面均优于教师-学生策略和PIE策略。在无Moes的情况下，我们的策略在速度跟踪性能上略低于PIE，这归因于PIE对机器人状态的实时估计。然而，在无Barlow Twins的情况下，我们的策略相比TS策略有显著提升，尽管其速度跟踪误差仍略高于PIE策略。

B. 真实世界实验

我们将我们的方法部署在配备六自由度机身、惯性测量单元和D435i传感器的Limx Dynamics P1机器人上，并在多种地形上进行了测试。




图9. 双足机器人在检测到障碍物后调整步态以跨越障碍。图中红色圆圈标示机器人自主抬升脚部高度以通过该地形。

地形。

如图8所示，我们在草地上部署了我们的策略。尽管柔软的草地无法提供与平坦表面相同的稳定摩擦和弹性，但双足机器人仍能实现稳定运动和转向。

为了验证机器人识别并跨越障碍物的能力，我们评估了其穿越楼梯及高于当前地面高度的表面的能力。如图9所示，当机器人检测到可跨越的障碍物时，它会增加足部的抬升高度以确保稳定通过。跨越障碍后，机器人降低脚部高度以维持稳定性。这表明，在视觉支持下，我们的策略使机器人能够有效导航越过障碍物。如图10所示，未使用相机深度图像作为输入的策略极易因与未知地形发生意外接触而摔倒。



图10. 机器人在盲策略行走时未能自主抬升脚部高度而摔倒。图中红色圆圈标示了足部与台阶垂直部分发生接触的位置。

增强双足机器人的稳定性，并开发动态路径规划策略。

V. 结论与未来工作

我们提出了一种新颖的基于视觉的强化学习策略，该策略结合了专家混合模型、对比学习和师生模型，其性能略优于仅使用师生模型。我们通过仿真对比和实际部署验证了该方法的有效性，展示了其穿越各种地形的能力。然而，所选双足平台固有的不稳定性，例如难以维持稳定速度，给我们的实验带来了重大挑战。此外，当前工作仅限于控制层面，未涉及轨迹规划。因此，未来的工作将聚焦于

参考文献

- [1] A. Hornung 和 M. Bennewitz, “自适应细节层次规划用于高效仿人机器人导航”, 载于 2012 年 IEEE 国际机器人与自动化会议。IEEE, 2012 年, 第 997–1002 页。
- [2] A. Stumpf, S. Kohlbrecher, D. C. Conner 和 O. von Stryk, “使用黑盒行走控制器在粗糙地形任务中监督双足机器人步态规划”, 载于 2014 年 IEEE-RAS 国际仿人机器人会议。IEEE, 2014 年, 第 287–294 页。
- [3] D. Kanoulas, A. Stumpf, V. S. Raghavan, C. Zhou, A. Toumpa, O. Von Stryk, D. G. Caldwell 和 N. G. Tsagarakis, “使用曲面接触补丁在粗糙地形上进行双足机器人步态规划”, 载于 2018 年 IEEE 国际机器人与自动化会议 (ICRA)。IEEE, 2018 年, 第 4662–4669 页。
- [4] L. Rossini, E. M. Hoffman, S. H. Bang, L. Sentis 和 N. G. Tsagarakis, “一种包含动态障碍物避让的仿人行走实时方法”, 载于 2023 年 IEEE-RAS 第 22 届国际仿人机器人会议 (Humanoids)。

- IEEE, 2023年, 第1–8页。[5] S. McCrory, B. Mishra, J. An, R. Griffin, J. Pratt 和 H. E. Sevil, “基于可通行性评估的粗糙地形仿人机器人路径规划”, arXiv预印本 arXiv:2203.00602, 2022年。[6] D. Calvert, B. Mishra, S. McCrory, S. Bertrand, R. Griffin 和 J. Pratt, “快速区域上的快速自主双足行走行为”, 载于2022年 IEEE-RAS第21届国际仿人机器人会议 (Humanoids)。IEEE, 2022年, 第24–31页。[7] 波士顿动力。(2018年10月) 跑酷阿特拉斯。访问日期: 2025年1月2日。[在线]。网址: <https://www.youtube.com/watch?v=LikxFZZO2sk> [8] J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun 和 M. Hutter, “在挑战性地形上学习四足运动”, 《科学机器人》, 第5卷, 第47期, 文章编号 eabc5986, 2020年。[9] I. M. Aswin Nahrendra, B. Yu 和 H. Myung, “DreamWaQ: 通过深度强化学习结合隐式地形想象学习鲁棒四足运动”, 载于2023年IEEE国际机器人与自动化会议 (ICRA), 2023年, 第5078–5084页。[10] A. Kumar, Z. Fu, D. Pathak 和 J. Malik, “RMA: 腿式机器人快速运动适应”, arXiv预印本 arXiv:2107.04034, 2021年。[11] G. B. Margolis 和 P. Agrawal, “Walk these ways: 通过行为多样性调整机器人控制以实现泛化”, 载于机器人学习会议。机器学习研究会议论文集, 2023年, 第22–31页。[12] X. Gu, Y.-J. Wang 和 J. Chen, “Humanoid-gym: 基于零样本仿真到现实迁移的仿人机器人强化学习”, arXiv预印本 arXiv:2404.05695, 2024年。[13] N. Rudin, D. Hoeller, P. Reist 和 M. Hutter, “使用大规模并行深度强化学习在几分钟内学会行走”, 载于机器人学习会议。机器学习研究会议论文集, 2022年, 第91–100页。[14] A. Kumar, Z. Li, J. Zeng, D. Pathak, K. Sreenath 和 J. Malik, “为双足机器人自适应快速运动适应”, 载于2022年IEEE/RSJ国际智能机器人与系统会议 (IROS), 2022年, 第1161–1168页。[15] W. Wei, Z. Wang, A. Xie, J. Wu, R. Xiong 和 Q. Zhu, “基于运动适应的步态条件双足运动学习*”, 载于2023年IEEE-RAS第22届国际仿人机器人会议 (Humanoids), 2023年, 第1–7页。[16] Z. Wang, W. Wei, R. Yu, J. Wu 和 Q. Zhu, “理解鲁棒仿人机器人运动学习中的关键估计”, arXiv预印本 arXiv:2403.05868, 2024年。[17] Z. Fu, X. Cheng 和 D. Pathak, “深度全身控制: 学习操作与运动的统一策略”, 载于机器人学习会议。机器学习研究会议论文集, 2023年, 第138–149页。[18] H. Wang, H. Luo, W. Zhang 和 H. Chen, “CTS: 用于腿式运动的并发教师-学生强化学习”, 《IEEE机器人与自动化快报》, 第9卷, 第11期, 第9191–9198页, 2024年。[19] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun 和 M. Hutter, “在野外学习四足机器人的鲁棒感知运动”, 《科学机器人》, 第7卷, 第62期, 文章编号 eabk2822, 2022年。[20] D. Hoeller, N. Rudin, D. Sako 和 M. Hutter, “Anymal跑酷: 学习四足机器人的敏捷导航”, 《科学机器人》, 第9卷, 第88期, 文章编号 eadi7566, 2024年。[21] S. Luo, S. Li, R. Yu, Z. Wang, J. Wu 和 Q. Zhu, “PIE: 基于隐式-显式学习框架的腿式机器人跑酷”, 《IEEE机器人与自动化快报》, 2024年。[22] R. Yu, Q. Wang, Y. Wang, Z. Wang, J. Wu 和 Q. Zhu, “基于地形重建的行走: 学习穿越危险稀疏立足点”, arXiv预印本 arXiv:2409.15692, 2024年。[23] H. Lai, J. Cao, J. Xu, H. Wu, Y. Lin, T. Kong, Y. Yu 和 W. Zhang, “基于世界模型的视觉腿式运动感知”, arXiv预印本 arXiv:2409.16784, 2024年。[24] Z. Zhuang, Z. Fu, J. Wang, C. Atkeson, S. Schwaertfeger, C. Finn 和 H. Zhao, “机器人跑酷学习”, arXiv预印本 arXiv:2309.05665, 2023年。[25] X. Cheng, K. Shi, A. Agarwal 和 D. Pathak, “腿式机器人极限跑酷”, 载于2024年IEEE国际机器人与自动化会议 (ICRA)。IEEE, 2024年, 第11443–11450页。[26] Z. Zhuang, S. Yao 和 H. Zhao, “仿人机器人跑酷学习”, arXiv预印本 arXiv:2406.10759, 2024年。[27] V. Makoviychuk, L. Wawrzyniak, Y. Guo, M. Lu, K. Storey, M. Macklin, D. Hoeller, N. Rudin, A. Allshire, A. Handa 等, “Isaac Gym: 基于GPU的高性能机器人学习物理仿真”, arXiv预印本 arXiv:2108.10470, 2021年。[28] S. Lan, R. Zhang, Q. Yi, J. Guo, S. Peng, Y. Gao, F. Wu, R. Chen, Z. Du, X. Hu 等, “带时间注意力的对比模块用于多任务强化学习”, 神经信息处理系统进展, 第36卷, 2024年。[29] J. Zbontar, L. Jing, I. Misra, Y. LeCun 和 S. Deny, “Barlow Twins: 通过冗余减少实现自监督学习”, 载于国际机器学习大会。机器学习研究会议论文集, 2021年, 第12310–12320页。[30] J. Schulman, F. Wolski, P. Dhariwal, A. Radford 和 O. Klimov, “近端策略优化算法”, arXiv预印本 arXiv:1707.06347, 2017年。[31] M. Macklin, “Warp: 用于GPU仿真和图形的高性能Python框架”, <https://github.com/nvidia/warp>, 2022年3月, 英伟达GPU技术大会 (GTC)。