



署名-非商业性使用-禁止演绎 2.0 韩国

使用者只有在遵守以下条件的前提下，方可自由地

- 复制、分发、传送、展示、表演及广播本作品。


必须遵守以下条件：



署名. 您必须标明原始作者.



非商业性使用。您不得将此作品用于商业目的。



禁止演绎。您不得对此作品进行改编、变形或加工。

- 在重新使用或分发本作品时，必须明确标示适用于本作品的许可条款。¹ 若获得著作权人的另行许可，则上述条件不适用。

依据著作权法享有的使用者权利不受上述内容影响。

这是对[许可协议（法律文本）](#)的通俗易懂的摘要。

[免责声明](#) 

硕士论文

基于状态恢复模型的深度强化学习在双轮双足机器人仿真到现实差距弥合中的应用

Jae hyung Cho (조 재 형) 融合IT工程系
浦项科技大学 2026年

基于状态恢复模型的深度强化学习控制器在两轮双足机器人仿真-现实差距克服中的应用

基于状态恢复模型的深度强化学习在双轮双足机器人仿真到现实差距弥合中的应用

Deep Reinforcement Learning with State Restoration
基于状态恢复模型的深度强化学习在双轮双足机器人
中弥补仿真到现实差距的研究
Model for Bridging the Sim-to-Real Gap in
Two-Wheeled Bipedal Robot

by

Jae hyung ~~Choi~~ ~~Hyung Cho~~ 浦项科技大学
Department of Convergence IT Engineering
Pohang University of Science and Technology

A thesis submitted to the faculty of the Pohang University of Science and
Technology in partial fulfillment of the requirements for the degree of Master
of Science in the IT Engineering

Pohang, Korea 2025年12月19日

经 理 S
12. 19. 2025
) 学术顾问批准

Approved by

Soohee Han (Signature)

Academic advisor



Deep Reinforcement Learning with State Restoration
Model for Bridging the Sim-to-Real Gap in
Two-Wheeled Bipedal Robot

Jaehyung Cho

The undersigned have examined this thesis and hereby certify its acceptability
of acceptance for a master's degree from POSTECH

12/5/2025

Committee Chair

Sooheon Han

(Seal)

Member

Sangwook Kim

(Seal)

Member

Member

Poogyoon Park

(Seal)





摘要

在真实机器人上部署运动策略仍然具有挑战性, 因为机载传感器仅能提供部分观测, 并且由于仿真到现实差距, 在仿真中训练的策略在硬件上往往会性能下降。本论文研究针对执行混合轮式-腿式运动的双轮双足机器人的仿真到现实深度强化学习, 其中耦合的轮-腿动力学和间歇性接触导致了部分可观测性, 使得瞬时测量不足以形成用于稳定控制的马尔可夫状态。

我们提出了一种状态恢复模型 (SRM), 该模型从观测历史中重建一个增强的、类似状态的潜在表示。SRM 经过训练以近似仿真中可用的特权全状态信息, 并集成到非对称演员-评论家训练流程中: 演员网络以恢复的表示为条件, 而评论家网络在训练期间利用特权信息。

我们在FlaminGO (一款8自由度两轮双足机器人) 上评估了所提出的方法, 遵循仿真 → 仿真 → 真实的流程: 在Isaac Lab中的Isaac Sim进行训练, 在MuJoCo中进行跨模拟器验证, 并在硬件上部署。在跨模拟器和真实世界实验中, 与未使用SRM训练的基线相比, SRM改善了指令速度跟踪并减少了稳态偏差, 包括在接近零指令下更稳定的定点保持行为。这些结果

表明，从时间上下文中恢复类状态表示可以缓解部分可观测性引起的模糊性，并提高混合运动的仿真到现实迁移鲁棒性。

目录

I. 引言	1
II. 预备知识	3
2.1 强化学习.3 2.2 双轮双足机器人设计.3 2.3 仿真到现实迁移.5	
III. 方法	6
3.1 状态恢复模型.6 3.1.1 架构与训练过程.6 3.1.2 学习架构配置.7 3.1.3 学习混合运动策略.10 3.1.4 混合运动策略配置.11	
IV. 实验	14
4.1 实验设置.14 4.1.1 仿真 → 仿真 → 真实管线.14 4.1.2 真实世界测量设置.15 4.1.3 评估协议.15 4.2 实验结果.16 4.2.1 训练性能比较.16 4.2.2 仿真到仿真结果 (Isaac Sim → MuJoCo).16 4.2.3 真实世界速度跟踪性能.19	
V. 结论	22
VI. 附录	23
6.1 训练超参数.23 6.2 真实世界完整轨迹.24 6.3 SRM-PPO训练伪代码.25	
摘要 (韩语)	27



表格列表

2.1 机器人组件规格.4 3.1 状态组成与可观测性.9 3.2 HLP的域随机化参数与配置.12 3.3 混合运动策略的奖励函数与权重.13 4.1 阶跃输入指令的速度跟踪性能（仿真到仿真）.17 4.2 真实世界前向速度跟踪误差.19 4.3 零指令下的真实世界定点保持误差.21 6.1 关键训练超参数（网络与优化）.23

图目录

1.1 FlaminGO机器人：一种采用轮腿混合机构的新型多模态运动机器人。机器人每侧包含4个自由度——髋关节、肩关节、腿关节和轮关节——共计8个自由度.	2
3.1 状态恢复模型 (SRM) 架构概览。可观测状态 s_t^o	
代表现实场景中的传感器可访问数据，包括关节位置、速度、角速度、欧拉角、先前动作和命令。在仿真中，特权完整状态 s_t^f 包含额外信息，例如接触力、关节力矩、基座高度和环境特征。在训练过程中，基于 GRU 的编码器将 s_t^o 映射到重构状态 $\hat{s}_t^f$ ，近似于 s_t^f 。演员网络操作于 $\hat{s}_t^f$ 之上，利用丰富的状态信息来弥合仿真到现实差距，并实现稳健的决策。评论家网络使用 s_t^f 评估策略，同时 SRM 通过最小化重构损失和奖励一致性损失，使 $\hat{s}_t^f$ 与 s_t^f .	9
3.2 混合运动策略学习框架概述。SRM 从模拟器观测中重构完整状态 ($\hat{s}_t^f$)，并将其作为输入提供给混合运动策略以 50 赫兹的频率运行。该策略网络是一个全连接神经网络，包含三个隐藏层，分别有 512、256 和 128 个 ReLU 激活节点。该网络输出关节级位置和速度目标 ($q_1, q_2, \dots, q_8, \dot{q}_8$)，通过动态切换行走和滚动运动以适应多变地形，从而实现稳健的混合运动。滚动运动以适应多变地形。	10
4.1 评估流程：在仿真中训练（使用 Isaac Lab 的 Isaac Sim），跨仿真器验证（MuJoCo），以及最终在真实机器人上的部署。	15
4.2 有无 SRM 的策略训练性能比较。上图显示了平均回合奖励，下图显示了前向速度跟踪奖励 $w^{\text{速}}(v_x)$.	17
4.3 有无 SRM 情况下对阶跃输入指令的前向速度响应（仿真到仿真），显示使用 SRM 后稳态误差减小。	18
4.4 具有代表性的真实世界前向速度跟踪结果。更多试验的完整轨迹见附录 6.2。	20

4.5 零指令下的真实世界定点保持 ($v_x^{\text{cmd}} = 0$) .	21
6.1 用于定性参考的完整真实世界轨迹.	24

I. 引言

在真实机器人上部署运动策略具有挑战性，因为机载观测通常无法完全代表稳定控制所需的基础状态。这种部分可观测性通常被形式化为部分可观测马尔可夫决策过程（POMDP），其中稳健的决策制定通常需要随时间整合信息，而非依赖单一的瞬时观测 [1]。此外，在仿真中训练的策略在硬件上常常性能下降，这是由于仿真到现实差距造成的，该差距源于未建模动力学、传感器噪声、延迟、执行器带宽限制以及参数变化等差异 [2, 3]。部分可观测性与仿真到现实不匹配共同构成了可靠现实世界运动 [4, 5] 的根本障碍。

这些障碍对于结合轮子和腿的混合运动系统尤为突出。虽然轮子在平坦地形上提供高效移动，腿可以应对台阶和崎岖地面等不连续地形，但将滚动动力学与间歇接触相结合会产生耦合行为和过渡场景，这些对感知和地形变化非常敏感 [6]。因此，许多混合系统依赖模式依赖启发式方法（例如，分离的滚动和步进控制器），这些方法需要大量调参，并且在过渡时可能性能下降 [6]。基于模型的方法，如模型预测控制（MPC） [7, 8]，进一步依赖于接触、摩擦、执行器动力学和延迟的精确模型，并且可能对建模错误和未预料的环境变化敏感。

深度强化学习（DRL）已成为一种替代方案，用于学习运动行为并减少人工设计，展示了在腿关节系统中的仿真到硬件迁移能力 [4, 5]。在典型流程中，策略在仿真中（通常使用 PPO [9]）进行优化，然后部署到硬件上。然而，稳健的部署仍然依赖于解决仿真到现实不匹配和部分可观测性 [2, 3, 1] 这两个问题。

为了缓解仿真到现实不匹配，先前的工作通过在训练中引入域随机化 [2] 和动力学随机化 [3] 来增加变异性。同时，部分可观测性促使利用时间上下文，循环或基于记忆的强化学习方法已被用于在部分可观测环境中总结观测历史 [10]。基于这些思路，我们开发了一个基于深度强化学习的仿真到现实框架，用于混合运动，该框架结合了域/动力学随机化 [2, 3] 与一个状态恢复模型（SRM）。SRM 通过整合当前感官输入与时间上下文，从观测历史中重建一个增强的、类状态潜在表示，从而在仅凭观测不足以推断马尔可夫状态时减少歧义 [11, 10]。

我们在受火烈鸟关节结构启发的多模态运动机器人 **FlaminGO** 上评估了所提出的框架（图1.1）。



图1.1: FlaminGO机器人: 一种采用轮腿混合机构的新型多模态运动机器人。机器人每侧包含4个自由度 (DoF) ——髋关节、肩关节、腿关节和轮关节——共计8个自由度。

FlaminGO将轮式移动与腿部关节运动相结合，以应对楼梯和不平坦地面。每侧具有4个自由度，总计8个自由度。该驱动系统仅使用8个执行器，而典型的四足机器人通常需要12个 [11, 12, 13]。

本工作的贡献总结如下：

- **多模态机器人设计：**我们设计并实现了FlaminGO，一款8自由度双轮双足机器人，它结合了轮式移动与腿部关节运动，能够在多种地形上实现混合运动。
- **基于DRL的仿真到现实框架：**我们为混合运动建立了一套仿真训练与迁移流程，并引入域/动力学随机化以降低仿真到现实的敏感性 [2, 3]。
- **部分可观测性下的状态恢复：**我们提出SRM，从观测历史中重建类状态潜在表示，从而提升当观测本身无法完全表征底层状态时的鲁棒性 [1, 10]。

II. 预备知识

2.1 强化学习

为了实现FlaminGO机器人的混合运动，我们将控制问题建模为马尔可夫决策过程（MDP），由元组 (S, A, P, R, γ) 定义。其中， S 表示机器人的运动学和动力学状态， A 表示包含电机命令的动作空间， $P(s'|s, a)$ 描述转移动力学， $R(s, a)$ 是评估给定状态-动作对优劣的奖励函数， γ 是平衡即时奖励与未来奖励的折扣因子。在每个时间步 t ，机器人观测其状态 s_t ，根据策略 $\pi(a|s)$ 选择动作 a_t ，转移到新状态 s_{t+1} ，并获得奖励 r_t 。目标是优化策略 π^* 以最大化期望累积奖励。

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right], \quad (2.1)$$

其中 γ 是平衡即时奖励与未来奖励的折扣因子。

为了解决以MDP形式表述的控制问题，我们采用近端策略优化（PPO）[9]，一种策略梯度算法，以其在学习过程中兼顾稳定性与效率而著称。PPO通过将更新约束在安全范围内来迭代优化策略，确保训练过程中的稳定进展。其裁剪机制降低了不稳定更新的风险，使其特别适用于复杂的机器人任务。PPO的目标函数如下：

$$\mathcal{L}^{PPO}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (2.2)$$

其中 $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ 表示概率比， $\hat{A}_t$ 是优势估计值， ϵ 是裁剪参数。

2.2 双轮双足机器人设计

FlaminGO是一款专为混合运动设计的双轮双足机器人，结合了轮式移动与腿部关节运动。机器人每侧配备四个驱动关节（髋关节、肩关节、腿关节和轮关节），共计8个自由度。髋关节和肩关节由Robstride RS03[14]单元驱动，减速比为9:1，额定扭矩为20.0 Nm，峰值扭矩为60.0 Nm。腿关节采用Robstride RS03并配备外部齿轮模块（减速比13.5:1），额定扭矩为30.0 Nm，峰值扭矩为90.0 Nm。在轮式驱动方面，轮关节由

Robstride RS06[14] 执行器驱动，减速比为9:1，额定扭矩为12 Nm，峰值扭矩为36 Nm。机载计算由 NVIDIA Jetson Orin Nano 8GB 单板计算机（SBC）完成，惯性传感由 AHRS EBIMU-9DOFV5-R3 IMU 提供。机器人由三星SDI 21700 50S电池组供电，配置为13S1P。

机械设计针对混合运动场景，使机器人能够在平坦地形上高效滚动，并通过协调腿部关节运动与轮式驱动跨越楼梯或不平地面等障碍。表2.1总结了关键组件与规格参数。平台基础重量为10.5千克，包含所有组件后的总重量为18.5千克。

表 2.1: 机器人组件规格

组件名称	规格
关节执行器（髋关节、肩关节）	Robstride RS03 额定扭矩：20.0 Nm 峰值扭矩：60.0 Nm 减速比：9:1
关节执行器（腿关节）	Robstride RS03（带外部齿轮模块） 额定扭矩：30.0 Nm 峰值扭矩：90.0 Nm 减速比：13.5:1
关节执行器（车轮）	Robstride RS06 额定扭矩：12 Nm 峰值扭矩：36 Nm 减速比：9:1
单板计算机 (SBC)	NVIDIA Jetson Orin Nano 8GB
惯性测量单元 (IMU)	AHRS EBIMU-9DOFV5-R3
电池	三星SDI 21700 50S 13s 1p
底座重量	10.5 千克
总重量	18.5 千克

2.3 仿真到现实迁移

仿真到现实迁移旨在通过缩小仿真到现实差距，将在仿真中训练的策略部署到真实机器人上。该差距指因仿真与真实动力学之间的差异（例如未建模效应、感知噪声、延迟及参数变化）导致的性能下降。为减小这一差距，我们采用以下技术：

- **域随机化**：我们对仿真中的物理参数（例如质量属性、摩擦力、执行器增益和传感器噪声）进行随机化，以训练能够泛化到各种真实世界条件下的策略 [2]。
- **状态恢复模型 (SRM)**：为了解决部分可观测性问题，我们利用SRM从观测历史中重建一个增强的、类状态潜在表示。通过将当前传感输入与时间上下文相结合，SRM为策略提供了一个紧凑的替代状态，该状态比瞬时观测信息更丰富，从而提高了在噪声和不完整测量下的鲁棒性。
- **潜在状态变换**：我们使用一个循环信念编码器将原始观测转换为潜在向量，该编码器随时间聚合本体感觉和外感受信号。这种潜在表示支持在部分可观测性下的状态估计，并使策略能够以结构化的方式整合有噪声的外感受输入 [15]。

通过结合域随机化与基于历史信息的潜在状态推断，训练出的策略能够容忍动力学不匹配和感知限制，从而支持混合运动的可靠部署。后续章节的实验结果将评估这些组件如何在实际操作中缩小仿真到现实差距。

III. 方法

3.1 状态恢复模型

在真实世界场景中，由于传感器限制或不可观测的动力学因素，机器人通常只能在获取部分状态观测的环境下运行。这种部分可观测性可能导致次优决策，并阻碍基于强化学习的控制策略的性能，尤其是在从仿真向现实迁移时。在仿真中，特权状态信息（如精确的物理状态或动力学参数）可以轻易获取，但这些信息在真实世界部署中通常不可用。这种差异带来了一个重大挑战，即所谓的仿真到现实差距，导致在仿真中训练的策略难以有效泛化到现实世界。

为应对这一挑战，我们采用了一种非对称演员-评论家框架[16]，其中评论家网络在训练期间利用特权信息来评估动作，而演员网络仅基于可观测状态运行。尽管有此改进，但在部署期间缺乏特权信息仍可能限制演员网络的性能。

如图3.1所示，状态恢复模型 (SRM) 通过从可观测状态 s_t^o 重建一个增强状态 $\hat{s}_t^f$ 来弥合这一差距。该增强状态近似于特权完整状态 s_t^f ，确保演员网络在现实环境中做出稳健且一致的决策。SRM 使用重建损失和奖励一致性损失的组合进行训练，具体内容将在后续章节中描述。

3.1.1 架构与训练过程

GRU编码器处理部分可观测状态以估计特权观测，并按如下方式重建完整状态：

$$s_t^p = \text{GRU}_{\text{encoder}}(s_t^o) \quad (3.1)$$

$$\hat{s}_t^f = (s_t^o) || (s_t^p), \quad (3.2)$$

其中 s_t^o 表示时间 t 的部分可观测输入， $\hat{s}_t^f$ 是重构完整状态。GRU编码器处理序列输入 s_t^o 以捕获时间依赖性并生成预测隐藏状态 s_t^p 。重构完整状态 $\hat{s}_t^f$ 随后通过拼接 s_t^o 和 s_t^p 获得，作为 s_t^f 的近似。

SRM使用基于恢复的损失函数进行训练，该函数最小化恢复状态 $\hat{s}_t^f$ 与完整状态 s_t^f 之间的差异。恢复损失定义为：

$$\mathcal{L}_{\text{reconstruction}}(\hat{s}_t^f, s_t^f) = \begin{cases} \frac{1}{2}(\hat{s}_t^f - s_t^f)^2 & \text{if } |\hat{s}_t^f - s_t^f| \leq 1.0, \\ 1.0(|\hat{s}_t^f - s_t^f| - 0.5) & \text{otherwise} \end{cases} \quad (3.3)$$

确保重构状态在训练过程中紧密逼近评论家网络所使用的特权信息。

为了进一步提升任务特定性能，SRM引入了奖励一致性损失。该损失最小化使用完整状态 s_t^f 和重构状态 $\hat{s}_t^f$ 计算得到的奖励之间的差异，从而对齐两个状态中与任务相关的特征：

$$\mathcal{L}_{\text{reward}} = \|R(s_t^f, a_t) - R(\hat{s}_t^f, a_t)\|^2 \quad (3.4)$$

训练SRM的总损失表示为：

$$\mathcal{L}_{\text{SRM}} = \mathcal{L}_{\text{reconstruction}} + \mathcal{L}_{\text{reward}} \quad (3.5)$$

3.1.2 学习架构配置

SRM利用评论家网络和演员网络的不同状态表示，以解决训练和部署过程中可用信息的不对称性。表3.1总结了特权观测（ s_t^p ）与作为SRM输入的部分可观测状态（ s_t^o ）之间的差异。

可观测的(s_t^o) 表示在现实场景中可直接从传感器获取的信息，提供了机器人状态的部分视图：

- 关节位置(q_i)：表示机器人关节的角度位置，以弧度为单位进行测量（rad）。
- 关节速度($\dot{q}_i$)：表示每个关节的角速度，提供以弧度/秒为单位的旋转速度信息（rad/s）。
- 基座角速度($\omega_{x,y,z}$)：测量机器人基座沿其各轴的旋转速度，以弧度/秒为单位表示（rad/s）。
- 基座欧拉角($\phi_{x,y,z}$)：使用滚转角、俯仰角和偏航角（以弧度为单位）描述机器人的姿态（rad）。
- 先前动作(a_t)：追踪上一时间步执行的动作，为决策提供时间上下文。

- 命令($cmd_{\dot{x}, \dot{y}, \omega_z}$): 表示提供给机器人的高级速度和方向指令。
- 历史缓冲区($\mathcal{H}_k$): 存储从时间步 $t - k$ 到当前时间步 t 的状态, 为机器人的决策过程提供时间上下文。
- 特权状态(s_t^p) 仅在仿真期间可访问, 该状态提供了对策略优化至关重要的更丰富信息:
- 基座线速度(v_x): 表示机器人基座沿x轴的前向速度, 以米每秒(m/s)为单位测量。
- 当前奖励(R_t): 指示机器人收到的即时奖励, 反映了当前动作的有效性。
- 抬升掩码(L_i): 一个布尔传感器数据, 指示机器人是否检测到路缘或台阶, 用于调整混合运动。
- 基座高度(p_z): 指定机器人基座相对于地面的垂直位置, 以米(m)为单位测量。

通过从 s_t^o 重构 $\hat{s}_t^f$, SRM对齐了演员网络与评论家网络之间的状态表示, 从而减少了因缺乏特权数据而导致的差异。重构状态 $\hat{s}_t^f$ 使演员网络能够在真实环境中做出稳健且一致的决策。此外, 在SRM专注于重构状态的同时, 奖励在塑造任务特定行为中的作用将在第3.1.3节中进一步详述。最后, 完整的SRM-PPO训练流程(包括轨迹收集、SRM优化(重构损失和奖励一致性损失)以及PPO策略/价值更新)以伪代码形式提供于附录6.3。



表 3.1: 状态组成与可观测性

状态组件	可观测的 (s_t^o)	特权状态 (s_t^p)
关节位置 (q_i)	✓	
关节速度 ($\dot{q}_i$)	✓	
基座角速度 ($\omega_{x,y,z}$)	✓	
基座欧拉角 ($\Theta_{x,y,z}$)	✓	
先前动作 (a_t)	✓	
命令 ($cmd_{\dot{x},\dot{y},\omega_z}$)	✓	
历史缓冲区 ($\mathcal{H}_k$)	✓	
基座线速度 (v_x)		✓
当前奖励 (R_t)		✓
抬升掩码 (L_i)		✓
基座高度 (p_z)		✓




图 3.1: 状态恢复模型 (SRM) 架构概览。可观测状态 s_t^o 代表真实世界场景中的传感器可访问数据, 包括关节位置、速度、角速度、欧拉角、先前动作和命令。在仿真中, 特权完整状态 s_t^f 包含额外信息, 如接触力、关节力矩、基座高度和环境特征。训练期间, 基于 GRU 的编码器将 s_t^o 映射到重构状态 $\hat{s}_t^f$, 近似于 s_t^f 。演员网络基于 $\hat{s}_t^f$ 运行, 利用丰富的状态信息来弥合仿真到现实差距, 并实现稳健的决策。评论家网络使用 s_t^f 评估策略, 同时 SRM 最小化重构损失和奖励一致性损失, 以使 $\hat{s}_t^f$ 与 s_t^f 对齐。

3.1.3 学习混合运动策略

HLP旨在通过动态整合行走与滚动模式，实现无缝的混合运动。该策略采用全连接神经网络实现，包含三个隐藏层，分别具有512、256和128个ReLU激活节点。它处理由SRM生成的 $\hat{s}_t^f$ 重构完整状态，以输出关节级位置和速度目标 ($q_1, q_2, \dots, q_8$)，从而实现稳健且自适应的控制。




图3.2: 混合运动策略学习框架概览。SRM从模拟器观测中重建完整状态 ($\hat{s}_t^f$)，并将其作为输入提供给以50赫兹运行的混合运动策略。策略网络是一个全连接神经网络，包含三个隐藏层，分别具有512、256和128个ReLU激活节点。该网络输出关节级位置和速度目标 ($q_1, q_2, \dots, q_8, \dot{q}_8$)，通过动态切换行走和滚动运动来适应多变地形，从而实现稳健的混合运动。

3.1.4 混合运动策略配置

混合运动策略被配置为通过利用观测数据、应用域随机化以及结合结构化奖励机制，在模拟环境和真实环境中运行。配置的关键要素概述如下：

观测与域随机化

HLP 利用从机器人重构完整状态中获得的观测值， $\hat{s}_t^f$ ，如 SRM 架构中所定义（见第 3.1.2 节）。这些观测值的详细分解，包括其单位和维度，见表 3.2。

为了增强在真实世界条件下的鲁棒性和适应性，在训练过程中应用了域随机化。通过引入观测参数和环境动态的变异性，HLP 暴露于广泛的随机化马尔可夫决策过程中。这种方法减少了对模拟环境的过拟合，并使策略能够在部署期间处理未见过的场景。域随机化参数涵盖了机器人的内部状态和外部环境因素，总结于表 3.2。

为了增强在真实世界条件下的鲁棒性和适应性，在训练过程中应用了域随机化。通过引入观测参数和环境动态的变异性，HLP 暴露于广泛的随机化马尔可夫决策过程中。这种方法减少了对模拟环境的过拟合，并使策略能够在部署期间处理未见过的场景。域随机化参数涵盖了机器人的内部状态和外部环境因素，总结于表 3.2。

奖励函数

奖励函数 R_t 旨在通过处理任务特定目标和正则化约束来优化 HLP。总奖励表示为：

$$R_t = r_{t,cmd_{x,y}}^{track} + r_{t,cmd_z}^{track} + r_{t,v_z}^{reg} + r_{t,\omega_{x,y}}^{reg} + r_{t,q_i}^{reg} + r_{t,\tau_i}^{reg} + r_{t,\dot{q}_i}^{reg} + r_{t,a_t}^{reg} + r_{t,p_z}^{reg}, \quad (3.6)$$

其中 $r_{t,cmd_{x,y}}^{track}$ 追踪 x 和 y 方向上的期望线速度，而 r_{t,cmd_z}^{track} 追踪围绕 z 轴的期望角速度以实现航向控制。正则化项包括 r_{t,v_z}^{reg} ，它惩罚垂直速度以维持稳定性，以及 $r_{t,\omega_{x,y}}^{reg}$ ，它惩罚围绕 x 和 y 轴的角速度以最小化不必要的基座旋转。关节位置由 r_{t,q_i}^{reg} 进行正则化，以确保它们保持在允许范围内，而 r_{t,τ_i}^{reg} 惩罚过大的关节力矩以提升能效。此外， $r_{t,\dot{q}_i}^{reg}$ 惩罚关节加速度以减少机械应变，并且 r_{t,a_t}^{reg} 正则化

表3.2: HLP的域随机化参数与配置

参数	Dim	Unit	范围	算子
q_i	6	rad	$[-0.04, 0.04]$	加性
$\dot{q}_i$	8	弧度/秒	$[-1.0, 1.0]$	加性
$\phi_{x,y,z}$	3	rad	$[-0.125, 0.125]$	加性
$\omega_{x,y,z}$	3	弧度/秒	$[-1.0, 1.0]$	加性
$v_{x,y,z}$	3	弧度/秒	$[-0.15, 0.15]$	加性
p_z	1	m	$[-0.05, 0.05]$	加性
τ_i	8	Nm	$[-0.25, 0.25]$	加性
$\ddot{q}_i$	8	弧度/ s^2	$[-1.75, 1.75]$	加性
H_t	64	m	$[-0.025, 0.025]$	加性
$cmd_{x,y,z}$	3	m/s	$[-2.0, 2.0]$	加性
$delay_{system}$	-	ms	$[0.0, 20.0]$	加性
$friction_{static}$	-	μ	$[0.3, 1.0]$	缩放
$friction_{dynamic}$	-	μ	$[0.6, 1.0]$	缩放
$mass_{body}$	-	kg	$[-1.25, 3.5]$	加性
$push$	-	s	$[10.0, 15.0]$	加性

动作变化率以确保平滑控制输入。最后, r_{t,p_z}^{reg} 鼓励机器人的基座高度保持在稳定范围内, 以获得更好的地形适应性。

这些奖励组件的详细数学定义见表格

e 3.3.

表3.3: 混合运动策略的奖励函数与权重

奖励	公式 (r_t)	权重 (w)	参数 (ξ)
$r_{t,cmd_{x,y}}^{track}$	$w \cdot \exp(-\xi \cdot \ cmd_{x,y} - v_{x,y}\ ^2)$	2.0	4.0
$r_{t,cmd_{\omega_z}}^{track}$	$w \cdot \exp(-\xi \cdot \ cmd_{\omega_z} - \omega_z\ ^2)$	1.0	4.0
r_{t,v_z}^{reg}	$-w \cdot \ v_z\ ^2$	0.1	-
$r_{t,\omega_{x,y}}^{reg}$	$-w \cdot \ \omega_{x,y}\ ^2$	0.05	-
r_{t,q_i}^{reg}	$-w \cdot \ q_{2i} - \xi\ ^2, i \in \{0, 1, 2, 3\}$	0.2	q_{2i+1}
r_{t,q_i}^{reg}	$-w \cdot \ q_i - \xi\ ^2$	0.1	目标
r_{t,τ_i}^{reg}	$-w \cdot \ \tau_i\ ^2$	0.05	-
$r_{t,\dot{q}_i}^{reg}$	$-w \cdot \ \dot{q}_i\ ^2$	0.001	-
r_{t,a_t}^{reg}	$-w \cdot \ a_t - a_{t-1}\ ^2$	$5.0 \cdot 10^{-4}$	-
r_{t,p_z}^{reg}	$-w \cdot \ p_z - \xi\ ^2$	20.0	0.40187

IV. 实验

4.1 实验设置

本节描述了用于验证所提出的基于SRM的框架的评估流程和实验设置，涵盖以下三个方面：(i) 仿真训练，(ii) 跨仿真器迁移，以及(iii) 真实世界部署。具体而言，我们遵循仿真 → 仿真 → 真实 流程，即策略在高通量仿真器中进行训练，然后在独立的物理引擎中验证，最后部署到物理机器人上（图4.1）。在仿真方面，我们使用基于NVIDIA Isaac Sim[17]构建的Isaac Lab，并在MuJoCo [18]中评估迁移效果。

4.1.1 仿真 → 仿真 → 真实管道

阶段 1：在仿真中训练。训练在仿真环境中进行，以实现快速、安全且可扩展的轨迹生成。我们使用 PPO [9]在 Isaac Lab [17]中训练运动策略；关键的网络架构和优化超参数总结于附录 6.1。训练期间，我们通过 (i) 平均回合奖励和 (ii) 任务特定跟踪奖励项（例如，前向速度跟踪）来监控学习进度。此外，我们进行了一项消融实验，在相同设置下训练两个策略：使用 SRM 和不使用 SRM。这使我们能够比较学习动态（例如，奖励增长率和固定步数下的最终奖励），并量化 SRM 是否在部分可观测性下改善了优化。

阶段 2：仿真到仿真验证。在硬件部署之前，训练好的策略在 MuJoCo [18]中进行评估，以减少仿真器特定过拟合，并验证学习到的行为是否能在不同的物理引擎下复现（图 4.1）。此阶段为真实世界实验前的速度跟踪和稳定性测试提供了一个受控的验证步骤。具体来说，我们评估了在一系列指令前向速度范围内的步进指令跟踪，并在相同的指令配置文件下比较了 SRM 与基线。

阶段三：仿真到真实部署。最后，将策略迁移至物理机器人，并在真实世界试验中评估其指令速度跟踪能力及实际感知约束下的稳定性。

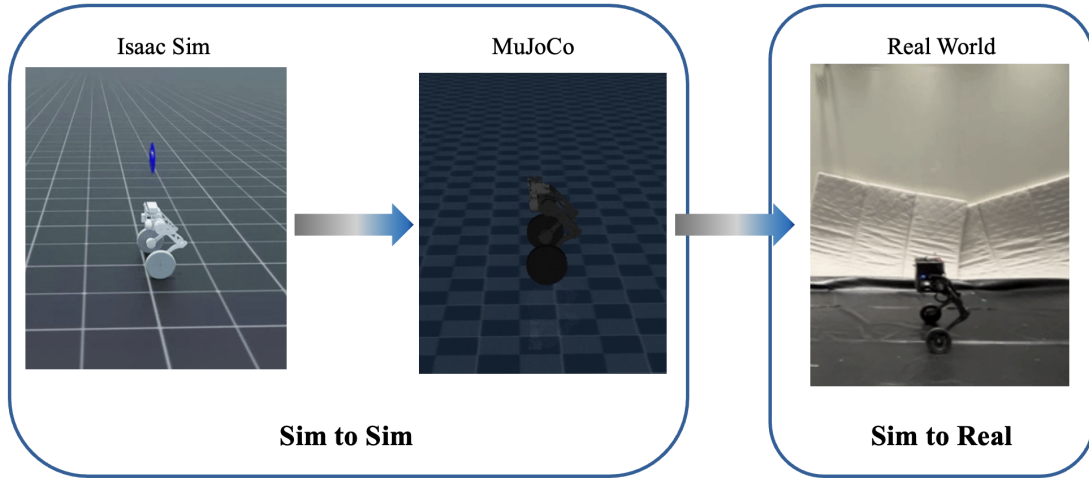


图 4.1: 评估流程: 在仿真中训练 (使用 Isaac Lab 的 Isaac Sim), 跨仿真器验证 (MuJoCo), 以及最终在真实机器人上部署。

4.1.2 真实世界测量设置

为量化硬件上的跟踪性能, 我们通过外部动作捕捉测量来估算机器人的线速度。具体而言, 线速度是根据OptiTrack标记点位置, 采用一阶前向欧拉差分计算得出:

$$\mathbf{v}(t_k) \approx \frac{\mathbf{p}(t_k) - \mathbf{p}(t_{k-1})}{\Delta t}, \quad \Delta t = t_k - t_{k-1}. \quad (4.1)$$

此过程对应于一阶数值微分积分的显式 (前向) 欧拉法 [19]。在我们的设置中, 所得速度估计的近似测量误差为 0.06 m/s。

4.1.3 评估协议

在仿真器和真实世界实验中, 我们主要通过使用阶跃指令场景的指令速度跟踪测试来评估控制器。每次试验包括 (i) 一个指令前向速度配置文件, 以及 (ii) 测量得到的前向速度响应。我们在指令信号与测量信号之间进行时间对齐后计算跟踪误差。

指令配置文件。我们评估覆盖代表性前向速度范围 (例如, 仿真中为 0.5–1.0m/s) 的阶跃指令, 以测试瞬态响应和稳态调节。同一类阶跃输入用于跨仿真器验证和真实世界试验, 以保持整个评估流程中评估条件的一致性。

M指标。对于每次试验, 我们在固定的评估范围内报告时域跟踪误差:

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{k=1}^T (v_x(t_k) - v_x^{\text{cmd}}(t_k))^2}, \quad \text{MAE} = \frac{1}{T} \sum_{k=1}^T |v_x(t_k) - v_x^{\text{cmd}}(t_k)|. \quad (4.2)$$

为了区分阶跃响应的瞬态和稳态行为，我们额外在固定持续时间的终端窗口（例如，试验的最后2秒）上计算稳态指标，记为 w 均方根误差和 w 平均绝对误差。这种窗口评估降低了对初始瞬态的敏感性，并强调了恒定指令下的最终跟踪精度。

4.2 实验结果

我们按照仿真 → 仿真 → 真实评估流程报告实验结果。除非另有说明，我们比较在相同设置下训练的两个策略：一个是在无SRM条件下训练的基线，另一个是在有SRM条件下训练的提出方法。我们评估了以下三个方面：(i) 训练性能，(ii) 仿真到仿真迁移（Isaac Sim → MuJoCo）下的速度跟踪性能，以及 (iii) 真实机器人上的速度跟踪性能。

4.2.1 训练性能比较

为了分析SRM对策略学习的影响，我们比较了在相同训练设置下，有和无SRM训练的策略的奖励进展。图4.2展示了在10,000个训练步数内，平均回合奖励和前向线速度 (v_x) 的跟踪奖励的演变过程。

在10,000步时，使用SRM训练的策略获得了更高的平均奖励（48.03），而未经SRM训练的策略为45.19。此外， v_x 跟踪奖励在有SRM（1.8347）的情况下略高于无SRM（1.8037）。这些结果与SRM能够从部分观测中提供更具信息性的状态表示这一观点一致，从而改善了优化和与跟踪相关的奖励项。

4.2.2 仿真到仿真结果（Isaac Sim → MuJoCo）

接下来，我们报告仿真到仿真结果，通过在独立物理引擎（MuJoCo）中执行学习策略来评估跨仿真器鲁棒性。该评估降低了仿真器特定过拟合的风险，并重点关注阶跃输入下的指令速度跟踪。

速度跟踪性能

为了在仿真到仿真设置中定量评估前向速度跟踪，我们在三个指令速度（0.5、0.75和1.0 m/s）下进行了阶跃指令测试。我们在表4.1中报告了调节时间和稳态误差。调节时间定义为机体前向速度保持在指令速度的 $\pm 5\%$ 范围内所需的时间。稳态误差定义为稳态机体速度与指令速度之间的绝对差值。后




图4.2：有无SRM策略的训练性能对比。上图显示平均回合奖励，下图显示前向速度跟踪奖励 (v_x)。

表4.1：阶跃输入指令的速度跟踪性能（仿真到仿真）。

命令 (米/秒)	条件	调节时间 (秒)	稳态误差 (米/秒)
0.50	使用 SRM	0.62	0.0002
	不使用 SRM	0.50	0.1058
0.75	使用 SRM	0.68	0.0020
	不使用 SRM	0.60	0.0771
1.00	使用 SRM	0.76	0.0039
	不使用 SRM	0.74	0.0295

在所有测试速度下，SRM 显著降低了稳态误差。例如，在指令前向速度为 0.5 m/s 时，稳态误差从 0.1058 m/s 降至 0.0002 m/s。在 1.0 m/s 时，误差从 0.0295 m/s 降至 0.0039 m/s。在这些测试中，SRM 的调节时间略有增加，表明在实现更低稳态偏差的同时，瞬态响应更为保守。




图4.3: 有无SRM（仿真到仿真）情况下对阶跃输入指令的前向速度响应，显示使用SRM后稳态误差减小。

表4.2: 真实世界前向速度跟踪误差。

条件	RMSE	MAE	w_{RMSE}	w_{MAE}
使用SRM (提出的)	0.291831	0.230260	0.109146	0.090787
不使用SRM (基线)	0.673222	0.649399	0.631776	0.596709

4.2.3 真实世界速度跟踪性能

我们通过在物理机器人上运行学习策略，并使用第 4.1.2 节中描述的基于 OptiTrack 的程序来估计前向速度，从而评估仿真到真实部署。我们通过比较指令前向速度 v_x^{cmd} 和测量响应 v_x 来报告跟踪行为，并使用标准跟踪误差指标总结性能。其他试验的完整时间序列图见附录 6.2。



定量比较


表4.2总结了所提出的SRM策略与未使用SRM训练的基线的真实世界跟踪误差。由于在硬件运行中难以完美复现完全相同的命令轨迹，我们的比较是在相同的评估协议（时间对齐、评估范围和指标定义）下进行的，而非要求每次试验使用相同的命令序列。

在评估范围内，SRM将均方根误差从0.673222 降低至**0.291831**，并将平均绝对误差从0.649399 降低至**0.230260**。此外，最后2秒内的稳态跟踪性能也显著提升： w_{RMSE} 从0.631776 降至**0.109146**， w_{MAE} 从0.596709 降至**0.090787**。这些结果表明，SRM在硬件上同时改善了整体跟踪精度和最终调节行为。


定性行为

图4.4展示了SRM策略与基线的代表性真实世界试验，包括对齐的命令/响应轨迹及相关的误差汇总。尽管硬件运行之间的确切命令序列有所不同，但两次试验均展示了典型的阶梯式命令变化，并突出了跟踪行为的定性差异。在所示试验中，SRM策略表现出更小的跟踪偏差和更低的稳态偏差，这与表4.2中的定量比较结果一致。更多实际世界图见附录6.2。





(a) 使用SRM（本文提出）。




(b) 未使用SRM（基线）。

图4.4：具有代表性的真实世界前向速度跟踪结果。更多试验的完整轨迹见附录6.2。




零指令下的定点保持

为进一步检验零指令下的稳定性，我们评估了指令前向速度保持在 $v_x^{\text{cmd}} = 0$ 时的定点保持行为。图4.5展示了具有代表性的真实世界试验。采用SRM时，测得的前向速度接近零且波动较小，而未采用SRM的基线则表现出明显的漂移，包括在零指令区间内出现持续的向后运动。



(a) 采用SRM（本文方法）。



(b) 未采用SRM（基线）。

图4.5：零指令下的真实世界定点保持（ $v_x^{\text{cmd}} = 0$ ）。

表4.3总结了跟踪误差。与基线相比，SRM策略实现了显著更小的误差，这与图4.5中漂移的减少相一致。

表4.3：零指令下的真实世界定点保持误差

条件	RMSE	MAE
使用 SRM（建议方案）	0.013634	0.009517
不使用 SRM（基线）	0.672472	0.694215

V. 结论

在本研究中，我们探讨了部分可观测性下混合轮式-腿式运动的仿真到现实的深度强化学习。我们引入了一个状态恢复模型 (SRM)，该模型从观测历史中重建类状态潜在表示，并将其用于调节在仿真中训练的混合运动策略。

在提出的仿真 → 仿真 → 真实 评估流程中，与未使用SRM训练的基线相比，SRM改善了指令速度跟踪并减少了稳态偏差。在真实机器人实验中，SRM策略在接近零指令下表现出更小的跟踪误差和更稳定的驻留行为，这表明从时间上下文中恢复类状态表示可以缓解部分可观测性带来的模糊性，并支持更可靠的从仿真到硬件的迁移。

若干局限性为未来工作指明了具体方向。SRM恢复的量中，除速度相关效应外的具体贡献尚未被分离出来，这尤其因为SRM近似于特权全状态信息，其中可能包含奖励相关信号以及接触或高度相关量；需要进行系统性消融实验，以确定哪些恢复组件对观察到的增益负责。此外，当前的真实世界评估反映了标称运行条件，因此需要更广泛的压力测试（例如负载变化、表面/摩擦变化以及外部扰动）来表征鲁棒性包络和失效模式。最后，重建与奖励一致性目标的结合可能会引入对奖励设计以及仿真与现实之间奖励尺度不匹配的敏感性，这促使我们开展研究，通过重新加权或移除奖励一致性项并扰动奖励组件来评估行为稳定性。

VI. 附录

6.1 训练超参数


表6.1总结了实验中使用的网络架构以及PPO/SRM超参数。

表 6.1: 关键训练超参数（网络与优化）。


类别	设置
随机种子	42
展开长度	每个环境的步数 = 24
训练范围	最大迭代次数 = 5000
策略/价值主干网络	Actor-Critic MLP（演员-评论家）
Actor隐藏层维度	(512, 256, 128)
Critic隐藏层维度	(512, 256, 128)
激活函数	ELU
策略初始化噪声	初始化噪声标准差 = 1.0
算法	SRM-PPO (SRMPPO)
学习率	1×10^{-3} (自适应调度)
折扣因子/广义优势估计	$\gamma = 0.99, \lambda = 0.95$
PPO裁剪	裁剪参数 = 0.2
熵系数	0.01
价值损失系数	1.0
优化	5 轮次, 4 小批量
KL目标	期望KL = 0.01
梯度裁剪	最大梯度范数 = 1.0
SRM主干网络	GRU (SRM网络=gru)
SRM输入维度	srm输入维度=32
SRM隐藏维度	256
SRM输出维度	5
SRM层数	1
历史堆叠	策略堆叠数=2, 评论家堆叠数=2

6.2 真实世界完整轨迹

本附录提供了真实世界实验的额外完整时间序列轨迹，补充了第4.2节中展示的代表性结果。



(a) 使用SRM（本文提出的方法）。



(b) 未使用SRM（基线）。

图6.1: 用于定性参考的完整真实世界轨迹。

6.3 SRM-PPO训练伪代码

算法1总结了所提出的SRM-PPO框架的训练循环。在每次迭代中，我们使用策略网络 $\pi_\theta(a_t | s_t^o)$ 在仿真中收集轨迹数据，其中 s_t^o 表示部署时可用的部分可观测输入。在训练期间，评论家网络额外接收仅在仿真中可访问的特权全状态信息 s_t^f 。在收集 T 步后，我们使用广义优势估计（GAE）计算回报 R_t 和优势值 A_t ，参数为 (γ, λ) 。

在优化过程中，每个小批量执行两次耦合更新。首先，更新SRM参数 ψ ，以从观测历史 $s_{t-k:t}^o$ 中重构一个特权状态下的完整状态近似值 $\hat{s}_t^f$ 。SRM目标结合了重构损失（使 $\hat{s}_t^f$ 与 s_t^f 对齐）和奖励一致性损失（使从重构状态计算的奖励与从特权状态计算的奖励对齐）：

$$\mathcal{L}_{\text{SRM}} = \mathcal{L}_{\text{reconstruction}}(\hat{s}_t^f, s_t^f) + \mathcal{L}_{\text{reward}}(R(\hat{s}_t^f, a_t), R(s_t^f, a_t)).$$

其次，通过PPO使用裁剪替代目标更新策略/价值参数 θ ，同时训练价值函数以回归回报 R_t ，并在训练期间使用评论家输入 s_t^f 。这种交替进行的SRM更新和PPO更新鼓励演员网络在恢复的状态表示上运行，同时保留PPO的稳定性优势。

算法1 SRM-PPO训练

需要：策略/价值参数 θ , SRM参数 ψ , 轨迹收集步数 T , PPO超参数 $(\gamma, \lambda, \epsilon)$

1: 当训练时执行

- 2: 初始化轨迹缓冲区 $\mathcal{D} \leftarrow \emptyset$
- 3: 对于 $t = 1$ 到 T 执行
- 4: 观察演员输入 s_t^o (部分) 和评论家输入 s_t^f (特权状态, 仅限模拟器)
- 5: 采样 $a_t \sim \pi_\theta(\cdot | s_t^o)$ 并在模拟器中执行
- 6: 接收奖励 r_t 和完成标志 d_t
- 7: 将 $(s_t^o, s_t^f, a_t, r_t, d_t, \text{日志 } \pi_\theta(a_t | s_t^o))$ 存储到 $\mathcal{D}$ 中
- 8: 结束循环
- 9: 计算回报 R_t 和优势值 $\hat{A}_t$ 从 $\mathcal{D}$ 使用 GAE(γ, λ)
- 10: 对于每个小批量 $\mathcal{B} \subset \mathcal{D}$ 进行若干轮次 执行

SRM更新

- 11: $\hat{s}_t^f \leftarrow \text{SRM}^\psi(s_{t-k:t}^o)$
- 12: $\mathcal{L}_{\text{reconstruction}} \leftarrow \mathcal{L}_{\text{Huber}}(\hat{s}_t^f, s_t^f)$
- 13: $\mathcal{L}_{\text{reward}} \leftarrow \left\| R(s_t^f, a_t) - R(\hat{s}_t^f, a_t) \right\|^2$
- 14: $\mathcal{L}_{\text{SRM}} \leftarrow \mathcal{L}_{\text{reconstruction}} + \mathcal{L}_{\text{reward}}$
- 15: 通过最小化 $\mathcal{L}_{\text{SRM}}$ 来更新 ψ

PPO更新

- 16: $\rho \leftarrow \exp(\log \pi_\theta(a | s^o) - \log \pi_{\text{old}}(a | s^o))$
 - 17: $\mathcal{L}_\pi \leftarrow \mathbb{E} \left[\max \left(-\rho \hat{A}, -\text{clip}(\rho, 1 - \epsilon, 1 + \epsilon) \hat{A} \right) \right]$
 - 18: $\mathcal{L}_v \leftarrow \mathbb{E} [(V_\theta(s^f) - R)^2]$
 - 19: 通过最小化 $\mathcal{L}_\pi + \mathcal{L}_v$ 来更新 θ
 - 20: 结束循环
 - 21: 结束当型循环
-

요약문

在真实世界机器人中稳定执行行走策略仍具挑战性，原因在于受限的传感器观测导致难以完全观测状态，且仿真中学习的策略可能因仿真-现实差距而在实际硬件上性能下降。本论文针对执行轮腿混合驱动的两轮双足机器人，探讨如何将仿真中学习的深度强化学习策略迁移至真实机器人。该问题因轮-腿耦合动力学与间歇性接触而凸显部分可观测性特征，仅凭单次观测难以构建稳定控制所需的马尔可夫状态。

为了解决这一问题，本文提出了一种状态恢复模型 (State Restoration Model, SRM)，该模型能够从观测历史中恢复出与状态相当的潜在表示。SRM 通过学习近似仅在仿真中可用的特权信息 (完整状态)，并集成到非对称演员-评论家 (asymmetric actor-critic) 学习框架中。在训练过程中，评论家网络利用特权信息评估策略，而演员网络则接收 SRM 恢复的表示作为输入，从而在真实环境中也能做出一致的决策。

所提出的方法在FlaminGO 8自由度两轮双足机器人上进行了验证。在Isaac Sim中学习策略后，在独立物理引擎MuJoCo中进行交叉仿真器验证，并最终通过从仿真 → 到仿真 → 再到现实的流程部署到实际机器人上进行评估。实验结果表明，应用SRM的策略相比未使用SRM的基准方法，在速度指令跟踪性能上有所提升，稳态偏差减小，尤其是在接近零指令时的静止保持行为更加稳定。这表明，利用时间上下文恢复近似状态表征的方法能够缓解部分可观测性带来的不确定性，并提升混合驱动模式下仿真-现实迁移鲁棒性。

参考文献

[1] Kaelbling, Leslie Pack, Michael L. Littman, and Anthony R. Cassandra. “Planning and acting in partially observable stochastic domains.” *人工智能* 101(1-2): 99–134 (1998).[2] Tobin, Josh, et al. “Domain randomization for transferring deep neural networks from simulation to the real world.” In *2017年IEEE/RSJ国际智能机器人与系统大会论文集* (2017).[3] Peng, Xue Bin, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. “Sim-to-Real Transfer of Robotic Control with Dynamics Randomization.” In *2018年IEEE国际机器人与自动化大会论文集* (2018).[4] Tan, Jie, et al. “Sim-to-Real: Learning Agile Locomotion For Quadruped Robots.” In *机器人学：科学与系统大会* (2018).[5] Hwangbo, Jemin, et al. “Learning agile and dynamic motor skills for legged robots.” *科学机器人学* 4(26): eaau5872 (2019).

[6] Bjelonic, Marko, Victor Klemm, Joonho Lee, 等. “轮腿机器人综述.” 载于自然场景中的机器人技术, 网络与系统讲义, 第530卷, 第83–94页。施普林格 (2023年)。

[7] Grandia, Ruben, 等. “面向力矩控制腿式机器人的反馈模型预测控制.” 载于2019年 *IEEE/RSJ国际智能机器人与系统大会 (IROS)* 论文集 (2019年)。

[8] Ding, Yanran, 等. “四足机器人动态运动的无表示模型预测控制.” *IEEE机器人学汇刊* 37(4): 1154–1171 (2021).[9] Schulman, John, 等. “近端策略优化算法.” *arXiv预印本* arXiv:1707.06347 (2017).[10] Hausknecht, Matthew, 和 Peter Stone. “部分可观测马尔可夫决策过程的深度循环Q学习.” *arXiv预印本* arXiv:1507.06527 (2015).[11] Biswal, Priyaranjan, 和 Prases K. Mohanty. “四足步行机器人开发：综述.” *艾因夏姆斯工程学报* 12(2): 2017–2031 (2021).

[12] Hutter, Marco, 等. “Anymal——一种高机动性动态四足机器人.” 载于 2016年 *IEEE/RSJ*智能机器人与系统国际会议 (*IROS*) 论文集 (2016).

[13] Shin, Young-Ha, 等. “KAIST HOUND的设计: 一种通过齿轮系混合整数非线性优化实现快速高效运动的四足机器人平台.” 载于《2022年*IEEE*国际机器人与自动化大会 (*ICRA*) 论文集》(2022).

[14] RobStride. 产品信息. GitHub仓库, 访问日期: 2025年12月24日. https://github.com/RobStride/Product_Information.

[15] Miki, Takahiro, 等. “在野外环境中学习四足机器人的鲁棒感知运动.” 《科学·机器人学》7(62): eabk2822(2022).

[16] Pinto, Lerrel, 等. “用于基于图像的机器人学习的非对称演员-评论家.” arXiv预印本 arXiv:1710.06542 (2017).

[17] Mittal, Mayank, Pascal Roth, 等. “Isaac Lab: 用于多模态机器人学习的GPU加速仿真框架.” arXiv预印本 arXiv:2511.04831 (2025).

[18] Todorov, Emanuel, Tom Erez, 和 Yuval Tassa. “MuJoCo: 一种用于基于模型的控制的物理引擎.” 载于 *IEEE/RSJ*国际智能机器人与系统大会 (*IROS*) 论文集, 第5026–5033页 (2012年)。

[19] Burden, Richard L., and J. Douglas Faires.数值分析. 第9版, Brooks/Cole, Cengage Learning (2010年)。

致谢

为硕士学位论文画上句号之际，回首过去两年多的学位历程。初踏研究者之路时的期待与迷茫仿佛就在昨日，而今已站在这段旅程的终点。虽为深化学术造诣而不懈努力，仍感诸多不足，不免留有遗憾。然而，正是得益于众多师长与友人的帮助，弥补了这些不足，促使我不断成长，才得以收获今日的成果。谨借此篇幅，表达我的感激之情。

首先，谨向韩秀熙教授致以深深的敬意与感谢，感谢您以深邃的研究洞察力和温暖的人格，为不足的我开启了学术之路。您所展现的对研究的热情以及细致入微的指导与鞭策，成为我学习作为研究者应具备态度的坚实基础。在未来的道路上，我将铭记您的教诲，努力成为一名精进不懈的研究者。同时，衷心感谢在百忙之中欣然担任学位评审，并为我的研究提供宝贵建议、助其更上一层楼的金相宇教授和朴富坚教授。

也向与我同甘共苦、成为研究室生活重要支柱的CoCEL成员们表达感谢。无论是在研究内外都作为坚实后盾的CoCEL首席技术官、人工智能大师张元哥，CoCEL理事兼我珍贵的浦项伙伴尚贤，AI团队组长兼可靠支柱的钟秀哥，非常善良的智硕哥，一起熬夜帮助我的敏宰和俊英，作为课程坚实后盾的控制专家东亨，因机器人而心灵相通的数学家敏宗，直到最后实验都全力相助的流形工匠镇宇，共同拥有许多回忆的胜贤哥，无人机团队组长兼可靠的人类GPT智浩，以及为研究室注入新活力的成敏、俊浩、根英、惠玲，可靠的申日哥等所有同事，因为有你们，我才能笑着克服那些艰难的时刻。尽管研究领域各不相同，也感谢通过研讨会分享宝贵想法并给予鼓励的无人机团队、SLAM团队、能源团队的各位。

最后，我要向始终以无限的信任与爱支持我、站在我身边的父亲和母亲，献上言语无法表达的感激之情。同时，也向一直默默为我加油的哥哥表达谢意。祝愿我们家庭的前程充满健康与幸福。正是因为有家人们无私的支持，我才能坚定不移地专注于学业。我将永远做一个可靠的儿子和弟弟，以回报这份爱。

谨以此论文，祝愿所有守护在我身边的珍贵缘分幸福安康。

简历

姓名: JaeHyungCho

教育背景

2024年3月 – 2026年2月 浦项科技大学 融合IT工程系 (硕士)

2022年3月 – 2023年2月 Dealim大学 机电工程系 (学士) 2017年3月 – 2022年2月
Dealim大学 汽车工程系 (专业学士)

经历

2025年4月 – 首席执行官, COCELO公司 2025年1月 – 2025年12月 智能制造创新研发项目 (基于AI的钢结构生产管理), 中小企业与初创企业部。 2024年9月 – 2025年9月 战略性产学合作项目, 浦项科技大学-三星电子产学研研究中心。 2024年5月 – 2025年6月 基于AI的抓斗式卸船机 (GTSU) 开发, 产业科学技术研究院 (RIST)。

所属机构

计算控制工程实验室 (CoCEL), 融合IT工程系, 浦项科技大学, 韩国。

