

OGMP: 面向敏捷与多功能机器人控制的 Oracle 引导多模式策略

Lokesh Krishna, Nikhil Sobanbabu, 和 Quan Nguyen

摘要 — 强化学习在机器人控制中的有效性依赖于任务特定先验知识和启发式方法的定制化整合, 以实现高效探索, 这给其直接应用于复杂任务带来了挑战, 并需要一种统一的方法。在这项工作中, 我们定义了一类通用的先验知识, 称为 Oracle, 它在训练过程中以闭环方式被查询时生成状态参考。通过将允许的状态限制在 Oracle 假设的范围内, 我们提出了一种任务无关的 Oracle 引导策略优化方法。为了增强模块化, 我们引入了任务关键模式, 表明掌握一组紧凑模式及其转换的策略可以处理无限时域任务。例如, 要在无限长的跑道上完成跑酷, 策略必须学会跳跃、跨越、踱步以及在这些模式之间有效转换。我们使用 16 自由度的动态双足机器人 HECTOR, 在具有挑战性的双足控制任务 (跑酷和跳水) 中验证了该方法。我们的方法为每个任务生成单一策略, 在仿真中解决了跨不同轨道的跑酷以及从高达 2m 的不同高度进行的全向跳水问题, 展示了多功能的敏捷性。我们展示了跑酷从仿真到真实世界的成功迁移, 包括跨越高达腿长 105% 的间隙、跳过高达机器人标称高度 20% 的障碍物、以高达 0.6 米 / 秒的速度踱步, 以及在真实机器人上这些模式之间的有效转换。

I. 引言

深度强化学习在合成混合驱动和欠驱动腿式机器人的控制策略方面取得了显著成功 [1], 特别是在使天生稳定的四足机器人实现极限跑酷 [2]–[4], 敏捷 [5], 且鲁棒 [6] 的运动方面。遵循一种常见理念: 1) 定义详尽的观测空间, 2) 设计任务特定的奖励和 / 或课程, 3) 进行策略蒸馏, 以及 4) 广泛随机化, 这些方法在每个步骤中都依赖于任务特定的技巧, 缺乏系统化的机器人控制方法。具体而言, 由于深度强化学习方法是无约束优化的准求解器, 它们容易陷入异常且针对特定情况的局部最优。因此, 实践者常常借助任务特定的奖励塑造 [2], [5], [6] 和启发式方法 [3] 来实现结构化探索并达到预期性能。此外, 机器人控制的既定方法是特权训练和策略蒸馏: 利用特权信息训练教师策略 [3][4], 通过强化学习求解伪马尔可夫决策过程, 并将其蒸馏为针对真实部分可观测马尔可夫决策过程的单一策略。相比之下, 我们的目标是通过在真实部分可观测马尔可夫决策过程中进行由先验知识引导的结构化探索来寻找最优策略。




图 1: OGMP 概述: Oracle 引导的策略优化及所应用任务的可视化。训练后的 OGMP π_{parkour} 在仿真和真实机器人上执行敏捷跑酷。 π_{dive} 在仿真中从 2 米高平台执行前空翻跳水。附带的视频结果位于: [link](#)

引导策略优化 (GPO) 旨在提高样本效率并缓解不良局部最优问题。GPO 方法要么是控制引导型或参考引导型。控制引导型方法需要控制轨迹: [7], [8] 采用先验控制器和策略 - 轨迹约束, 同时 [9], [10] 交替进行轨迹优化并最小化强化学习方差。[11]–[13] 展示了四足运动, 但依赖于预先存在的基于模型的控制, 限制了复杂任务 (如跑酷)。参考引导型方法如 [14]–[18] 使用形态相似的状态参考轨迹来引导强化学习学习相应的最优动作, 用于角色控制。然而, 使用预先生成的开环参考时, 策略探索被限制在演示场景内, 从而阻碍了从零开始的强化学习方法 [1]–[3], 中出现的涌现行为 (如恢复), 这些方法探索全阶动力学和仿真中具有挑战性的随机化, 这对真实机器人控制至关重要。因此, 我们提出了一种使用闭环状态参考生成器 (oracle) 的参考引导策略优化, 该生成器可从任何状态动态查询生成参考, 并引入一种新颖的超参数来解决复杂任务中的局部最优问题。

或者, 模仿学习 (IL) 被证明是一种可靠的任务无关策略, 用于通过熟练的人类遥操作提供动态一致的演示来实现机器人操作, 从而解决预期任务 [19]。相比之下, 我们用于运动的演示是动态不一致的, 只能部分解决任务, 这对直接应用模仿学习构成了挑战。例如, 要让双足机器人完成跑酷, 我们可能有跑步、跳跃和

从人类运动捕捉中跳跃存在源 - 目标不匹配导致的形态学差异问题 [20]。此外，对部分演示（如奔跑、跳跃等）的简单模仿并不能保证解决总体任务（如跑酷），这需要经过强化学习训练的高级策略来实现过渡和涌现行为 [20]–[22]。除了演示之外，机器人任务还拥有丰富的先验知识，如启发式方法 [23]、任务 / 运动规划器 [24]，和基于模型的控制器 [25]，这些都可以指导学习，从而产生规范化的行为 [13]。虽然模仿此类先验的想法已有研究，但我们提出在状态空间中围绕先验解构建一个“信任区域”。因此，我们对先验的“信任”程度越高，信任区域就可以越紧凑，反之亦然。通过形式化定义一类通用的先验：预言机，可以通过将策略的允许状态空间限制在预言机假设解的局部邻域内，来执行预言机引导的策略优化。实验表明，正确选择这一边界有助于逃离错误的局部最优解，在涌现行为与规范化行为之间实现理想平衡，非常适合机器人控制，使其在实践中成为一个有效的超参数。

另一方面，解决复杂任务需要行为的多模态性。经典的多模态控制 [26][27] 涉及在一组有限的预设计控制器之间切换以处理高级任务，从而创建伪混合系统。学习方法让控制中的多模态性隐式涌现 [3], [5]，缺乏系统性的综合方法。[22] 提出将演示数据集编码到潜在空间，并通过潜在条件训练多技能策略。然而，技能的概念定义不清。例如，解决一个任务不仅需要掌握离散模式（如行走、跳跃），还需要同一模式的连续参数变化（如速度、高度）以及技能间的过渡。[2] 为四足机器人跑酷训练了多个低级控制器和一个高级模式切换策略，这需要多样化的奖励塑造和训练流程。[28] 表明，“固定”的单模态控制器集合限制了复杂的过渡机动，因此引入了一个单一的多模态策略来掌握一组模式及其过渡，以零样本方式处理新任务。与此方法一致，我们旨在通过参考引导的策略优化，实现一个单一策略，该策略学习有限数量的模式，同时具备“无限”的参数变化和过渡能力。与切换固定控制器不同，我们假设参考引导的探索能更好地适应涌现的控制模式。为此，我们首先将任务关键的多模态性作为将任务分解为其主要模式的方法，并将其转录到我们提出的 OGMP 框架中。因此，本文的主要贡献有两点：

- Oracle 引导的多模式策略：一种面向任务中心控制综合的理论框架，利用 Oracle 引导的优化，通过有界探索和任务关键的多模态性有效搜索，实现多功能控制。
- 在需要多功能性的敏捷双足控制任务（如跑酷和跳水）上的实验验证。

每个任务使用单一策略，展示了执行任务关键模式多种变体的能力，这些模式在仿真和 16 自由度双足机器人 Hector 的真实机器人上得以实现。

本文其余部分结构如下：第 II 节介绍我们框架的理论发展，第 III 节讨论将所提框架应用于双足控制任务，随后第 IV 节展示实验结果、分析和消融研究。

II. ORACLE 引导的多模式策略

本节介绍我们的理论框架，包含两个协同思想：

Oracle 引导的策略优化和任务关键的多模态性。具体而言，我们旨在通过将探索限制在 Oracle 的局部邻域内，并设计多种行为模式及其转换的学习，来有效剪除不期望的局部最优解，从而有效解决任务。

1) Oracle 引导的策略优化（OGPO）：设 $\mathcal{T}$ 为一个具有任务参数集 $\psi_{\mathcal{T}} \in \Psi_{\mathcal{T}}$ 的无限时域任务。充分求解 $\mathcal{T}$ 需要在任务参数分布 $p(\psi_{\mathcal{T}})$ 上最大化任务目标 $J_{\mathcal{T}}$ 。给定相关的状态空间（或任务空间）， $x \in \mathcal{X}$ 令 x_t ， $x[a, b]$ 分别表示时刻 t 的状态和从时刻 $t \in [a, b]$ 开始的状态轨迹。我们将 Ξ 定义为一个滚动时域 Oracle，它从任意给定状态（ x_t ）出发，针对任意任务变体（ $\psi_{\mathcal{T}}$ ），提供未来直到 Δt 的有限时域状态轨迹（ $x^{\Xi}[t, t + \Delta t]$ ），使得 $x^{\Xi}[t, t + \Delta t]$ 始终处于最优状态轨迹的 ϵ - 邻域内。形式上，

$$x^{\Xi}[t, t + \Delta t] = \Xi(x_t, \psi_{\mathcal{T}}) \quad (1a)$$

$$\text{s.t. } \exists x^{\Xi}[t, t + \Delta t] \quad \forall (x_t, \psi_{\mathcal{T}}) \quad (1b)$$

$$\|x_t^{\Xi} - x_t^*\|_W < \epsilon \quad \forall t \in [0, \infty) \quad (1c)$$

其中 ϵ 是最大偏差界，对于给定对 $(\mathcal{T}, \Xi)$ 是一个常数，而 W 是一个对角权重矩阵¹。我们的目标是在 Ξ 的引导下，从策略类 Π 中获得能够充分求解 $\mathcal{T}$ 的最优策略 π^* 。由于 Ξ 在状态空间中提供了参考，我们建议将 π 的允许状态约束在 Oracle 引导的 ρ - 邻域内。形式上，

$$\pi^* := \arg \max_{\pi \in \Pi} J_{\mathcal{T}} \quad (2a)$$

$$\text{s.t. } \|x_t^{\pi} - x_t^{\Xi}\|_W < \rho \quad \forall t \in [0, \infty) \quad (2b)$$

其中 x^{π} 是执行策略 π 时访问的状态， ρ 是 Oracle 引导探索的允许状态边界。通过上述设置，可以观察到图 2i 中可视化的有界允许状态集由下式给出

$$x_t^{\pi} \in \{x \mid \|x_t^{\Xi} - x_t^*\| - \rho \leq \|x - x_t^*\| \leq \|x_t^{\Xi} - x_t^*\| + \rho\} \quad (3)$$

因此，应选择 ρ 使得 x_t^{π} 对于 x_t^{Ξ} 是可达的，这要求式 3 中的下界为非正数。因此如图 2ii 所示，为使 x_t^{π} 处于

¹注意， $x^*[0, \infty]$, ϵ 是未知的，仅用于构建概念性论证




图 2: Oracle 有界探索

π 、 ρ 的允许状态必须满足

$$(x_t^* \text{ is reachable by } x_t^\pi) \implies \rho \geq \|x_t^\pi - x_t^*\| \quad (4)$$

根据定义 (公式 1.c)，由于 $\|x_t^\pi - x_t^*\| < \epsilon$ ，选择足够的 ρ 以始终满足公式 4，是

$$\rho \geq \epsilon \quad (5)$$

ϵ 是 x^π 的最大偏差，具有低 ϵ 的 Oracle 将生成更接近 x^* 的参考，因此探索可以被限制在紧密邻域内，以滤除目标景观中的大多数局部最优。相反，对于具有高 ϵ 的“差”Oracle，应有足够的搜索空间供 π 围绕 x^π 探索并收敛到 x^* 。从公式 5 可知，当 $\epsilon \rightarrow \infty$ 时，优化是无引导的，因此需要 $\rho \rightarrow \infty$ （标准强化学习设置）。反之，当 $\epsilon \rightarrow 0$ 时，可以选择任意小的 ρ 满足公式 5，通过局部化搜索来避免局部最优，同时仍能收敛到 x_t^* 。在实践中，由于 ϵ 未知，我们对任何给定的 $(\mathcal{T}, \Xi)$ 在 ρ 上进行网格搜索。

2) 任务关键的多模态性：学习解决任务 $\mathcal{T}$ 的策略，可以看作是在任务空间中掌握一组时空轨迹的“束”，对应于 $\psi_T \in \Psi_T$ 。简单任务允许直接构建满足公式 1 的 Oracle。然而，复杂且无限时域的任务使得 Ψ_T 变得棘手。例如，用于无限跑酷的 Oracle 需要预先知道无限长的赛道，这并不实际。为解决此问题，我们将模态定义为保持某些空间和/或时间不变性的有限时空片段。就像在跑酷中，跳跃和腾跃等模态无论位置或时间如何都保持一致。因此，我们定义一组有限的模态 $\mathbb{M}$ ，其时间长度为 Δt ，对 $\mathcal{T}$ 至关重要。每个 $m \in \mathbb{M}$ （如跳跃）可以有连续参数 Ψ_m （如跳跃高度）。那么模态参数集 $\Psi_{\mathbb{M}} := \bigcup_{i=1}^{|\mathbb{M}|} \Psi_{m_i}$ 与任务参数集的关系为 $\Psi_T := \Psi_{\mathbb{M}}^N$ ，其中 N 是时域数量。因此，通过掌握 $\mathbb{M}$ （跳跃、腾跃和步态）中的模态以及在不同 $\Psi_{\mathbb{M}}$ （速度、距离和高度）上的转换，任务 $\mathcal{T}$ （无限跑酷， $N \rightarrow \infty$ ）可以如图 3.a 所示得到解决。

III. 设计方法

本节介绍了使用 OGMP 进行双足控制任务（跑酷和跳水）的设计方法，如图 3 所示。对于给定任务，我们首先定义任务关键模式——例如跑酷中的跳跃、腾跃和步态——并为每种模式设计参考生成方案。

$\mathcal{T} : J_T$		$(m, \Psi_m) \in (\mathbb{M}, \Psi_{\mathbb{M}})$
		Mode Parameters
dive: 360° ip and land	settle	$\{\}$
	ip	$\{(r, h)\}$
	pace	$\{v\}$
	jump	$\{(w, h)\}$
parkour: traverse the track indefinitely	leap	$\{(w, d)\}$

表 I: 任务描述及对应的任务关键多模态。参数可视化见图 4。

(图 3.a)。通过遍历模式参数集，我们利用预言机生成包含多样化行为的自定义数据集，并训练模式编码器以构建用于指令条件化的紧凑潜在空间 (图 3.c)。最后，我们训练一个由预言机引导的多模态策略 (图 3.d)。在策略优化过程中，定期查询预言机以在线生成参考，将策略的搜索空间限制在参考的局部邻域内，从而实现有效探索 (图 3.b)。上述方法详细说明如下。

A. 任务描述：

我们将所提出的框架应用于两个双足控制任务：跑酷和跳水，这两个任务具有不同的目标和多模态程度，如表 I 所示。请注意，任务关键多模态的选择由用户定义，表 I 仅反映了我们的选择。从表 I 可以看出， J_T 是任务相关的。近期在四足跑酷 [2], [3], 和运动 [1], [6] 方面的尝试显示了一些形态良好的候选方案用于 J_T ，尽管这些方案具有特定情境性。通常，合理的 J_T 可能难以设计 (例如跳水任务)；一个令人信服的统一替代方案是“跟踪”预言机的最优解 ϵ 邻域参考。因此，我们提出最小化任务无关的替代目标： $\tilde{J}_T := \sum_{t=0}^{\infty} \|x_t^\pi - x_t^*\|$ 。 $\tilde{J}_T$ 的适用性将在第 IV-B 节中研究，并在第 III-C 节中提出一个奖励函数以实现等效的最大化目标。

B. 预言机设计

对于任何运动任务，一个简单的预言机启发式方法是从初始状态到目标状态对相关状态变量进行线性插值。在跑酷中，为了沿赛道前进，航向位置可以沿赛道线性插值，同时适应地形高度，如图 4 (左) 所示。对于俯冲动作，预言机可以对基座高度和相应的旋转自由度从 0° 到 360° 进行线性插值。将此启发式预言机命名为 Ξ_{li} (图 4)，其高 ϵ 是显而易见的，因为生成的假设未考虑系统的惯性和重力。因此，需要能够捕捉混合系统主导动力学的预言机。为此，我们使用了简化单刚体 (SRB) 模型 [25] 的修改版本，其世界坐标系中的动力学方程如下：

$$m(\ddot{p} + g) = \sum_{i=1}^2 f_i, \quad \frac{d}{dt}(I\omega) \approx I\dot{\omega} = \sum_{i=1}^2 (r_i \times f_i + \tau_i) = \sum_{i=1}^2 \bar{\tau}_i \quad (6)$$

$$x_{t+1} = Ax_t + But, \quad y_{t+1} = Cx_t, \quad u_t = [f_1, f_2, \bar{\tau}_1, \bar{\tau}_2]^T \quad (7)$$




图 3: 设计方法概述: a) 将任务分解为其模式及模式参数集 b) 通过围绕 Oracle 参考局部邻域的有界允许状态空间进行引导探索 c) 模式编码器: 一个在自定义模态数据集上通过最小化重构损失训练的 LSTM 自编码器 d) 在任务环境中使用 Oracle 引导的策略优化训练的多模式策略




图 4: 不同模式下来自多个 Oracle 的基准高度参考轨迹

其中 $\ddot{p}, \omega$ 是机器人质心加速度和角速度, r_i, f_i, τ_i 是来自第 i^{th} 个接触点的位置、力和力矩向量, m, I, g 是质量、惯性矩和重力。通常, r_i 来自预定义的接触时序, 导致时变动力学。由于根据定义, Oracle 无需提供现实的控制, 我们定义了一个辅助控制 $\bar{\tau}_i$, 包含整体力矩, 使动力学变为时不变。此外, 通过考虑一个时间窗口内的平均参考方向, 使旋转矩阵和旋转速率矩阵保持恒定。基于这些对公式 6 的近似以及离散化, 在当前时间窗口内得到一个线性时不变系统, 其中 $x_t \in \mathbb{R}^{13}, y_t, u_t \in \mathbb{R}^{12}$ 分别是重力增强状态、相关输出和控制向量。因此, Oracle 可以针对两个不同阶段构建: 飞行阶段和接触阶段。在飞行阶段, 由于没有接触, $u_t = 0$; 而在接触阶段, 可以使用任意优化器针对给定目标 $u_t = u_t^*$ 计算最优控制。参考状态轨迹通过应用相应控制并前向仿真公式 7 获得。使用 Ξ_{li} 作为二次跟踪目标的参考,

在 LTI 系统上, 通过预览控制 [29] 和 LQR 优化分别得到 Oracle Ξ_{prev} 和 Ξ_{lqr} , 其 ϵ 小于 Ξ_{li} , 如图 4 所示

C. 多模式策略:

模式编码器: 我们训练了一个模式编码器 ξ , 基于多样化的运动模式, 以获得一个紧凑的条件空间, 便于指挥我们的策略。与 [28], 编码器类似, $z = \xi(x[t, t + \Delta t])$ 将轨迹空间映射到潜在空间 (维度 $z = 2$)。通过从模式参数集 Ψ_M 和一组初始状态 $\mathbb{X}_0$ 中均匀采样, 我们通过查询预言机生成了一个丰富且平衡的模式数据集, Ξ 如图 3.c 所示。在自定义数据集上最小化一个 32 神经元单隐藏层 LSTM 自编码器的重构损失, 生成了一组具有结构化聚类的潜在模式点, 如图 3.c 所示。

模式条件策略: 我们为固定策略选择的动作空间来自 [28]。鉴于系统固有的部分可观测性, 对于观测空间 $o_t \in \mathcal{O}$, 我们选择 $o_t = [\tilde{x}_t, z_t, c_t, h_t]$, 其中 $\tilde{x}_t$ 是机器人的本体感觉反馈, z_t 是潜在模式指令, c_t 是时钟信号, [28] 而 h_t 是可选的基于任务的反馈 (如跑酷中的地形扫描)。用于任务无关的替代跟踪目标的每步奖励定义为

$$\begin{aligned} r_t &:= r_{\text{track}} + r_{\text{regulation}} \\ r_{\text{regulation}} &:= 0.05e^{-0.01\|u_t\|} - 0.3 \cdot \mathbf{1}(\text{if non-toe contact}) \\ r_{\text{track}} &:= 0.475e^{-5\|e_{rp}\|} + 0.475e^{-5\|e_{ro}\|} \end{aligned} \quad (8)$$

其中 e_{rp} 、 e_{ro} 是基座位置和方向的误差。因此, r_{track} 最小化任务空间中的误差, 而 $r_{\text{regulation}}$ 对运动进行正则化以增强从仿真到现实的迁移。请注意, 对于跨任务 (跑酷和潜水) 的多样化模式, 奖励权重保持不变, 这暗示了引导学习带来的算法鲁棒性。所提出的允许状态约束




图 5: OGMP (π_{parkour}) 的关键帧展示了模式转换 (从左到右), 活动模式的颜色标记为: 蓝色表示步态, 红色表示跳跃, 绿色表示弹跳。

(第二节) 被编程为终止条件, 终止回合: $= 1$ ($\|x_t^T - x_t^E\|_W > \rho$)。 W_{11} 和 W_{33} 分别设置为 1 用于跑酷和跳水任务, 其余条目为零。为了解决由此产生的随机视界 POMDP, 我们使用现成的 PPO 来训练策略: 每层 128 个节点, 2 层 LSTM 网络, 其中每个回合是任务 ψ_T 的任意变体, 从 Ψ_T 中均匀采样。

IV. 结果

A. 性能

为了实现极致的敏捷性和模式多样性, 每个任务训练一个单一的多模式策略: π_{parkour} 用于跑酷, π_{dive} 用于跳水。补充视频和图 1 展示了 π_{parkour} 成功导航具有随机放置的障碍物和间隙的挑战性跑酷赛道, 展示了在跳跃长度和弹跳高度上的多样敏捷性。 π_{dive} 执行来自不同高度的全方位跳跃, 并平滑过渡到着陆。尽管缺乏驱动自由度的参考, π_{dive} 学习了一种涌现行为, 即蜷曲和伸展腿部以进行跳跃和着陆, 调节躯干角速度和着陆冲击。如视频所示, π_{parkour} 显著偏离了神谕的参考以找到最优行为, 但由于神谕约束, 最终产生了正则化的运动。 π_{parkour} 的模式和转换的仿真到现实迁移可以在图 1、5 和补充视频中看到。

1) 敏捷性: 为了对敏捷性进行定量基准测试, 我们报告了性能指标的样本均值: 最大航向加速度 (M.H.A)、弗劳德数 (M.F)、最大航向速度 (M.H.S)、回合长度 (E.L), 在表 II 中测量了 100 个回合的展开。我们定义了一个测试环境, 跑道长度为 10 米, 跑酷的回合长度为 400 步, 跳水的回合长度为 150 步。在每种情况下, 只有当达到回合长度或机器人摔倒 (地形相对基座高度 < 0.3 米) 时, 回合才会终止。

metric, units	z_t	z_t, c_t	h_t	h_t, c_t	h_t, z_t	h_t, z_t, c_t
M.H.A	4.7g	3.5g	3.2g	3.6g	3.5g	3.1g
M.H.S (v)	1.4	1.57	1.66	1.74	1.74	1.77
M.F ($\frac{v^2}{g \cdot l}$)	0.48	0.56	0.64	0.69	0.70	0.72
% E.L	0.18	0.43	0.63	0.80	0.66	0.84

表 II: 不同观测空间下 π_{parkour} 变体的估计指标

平均而言, 我们发现 π_{parkour} 能够达到 4.7g 的加速度, 航向速度为 1.77 米/秒, 弗劳德数

在 0.48 – 0.72 之间, 同时完成如表 II 所示的 84% 的赛道。 π_{parkour} 沿赛道动态前进, 通过精确的足部落点和起跳避免保守运动, 从而实现敏捷机动。测得的弗劳德数及由此产生的运动与 [30], 一致, 其中在双足运动中观察到从节能步行到敏捷跳跃步态的转变, 其值约为 0.5。


2) 模式多功能性: 由于我们训练中定义的 Ψ_M 是一个紧凑集合, 我们利用它来可视化 π_{parkour} 在模式参数上的泛化能力。通过扩展 Ψ_M 并为每个参数定义更高的测试范围, 我们测试了域内 (ID) 和域外 (OD) 的泛化能力。对该测试集进行离散化处理, 我们评估了 π_{parkour} , 并在图 6ii 中绘制了不同尺寸障碍物和间隙的未折扣回报。不同的障碍物和间隙需要不同幅度的跳跃和腾跃, 展示了我们策略的多功能性。训练集 Ψ_{jump} 和 Ψ_{leap} 是每个图中黑色边界内的区域。因此, π_{parkour} 在黑色边界内 (ID) 的变体上表现出一致的性能, 同时通过跳跃和腾跃跨越黑色边界外 (OD) 未见过的地形变体来外推其技能, 如补充视频和图 6ii 所示。

B. 消融实验与分析


最后, 我们分析了替代 $\tilde{J}_T$ 的选择以及影响性能 (通过未折扣回报衡量) 的设计选择。对于跑酷而言, 一个潜在的真实目标 J_T 是沿赛道的位移。因此, 使用 $\tilde{J}_T$ 的有效性可以通过其与 J_T 的差异来量化。

观测空间的选择 (o_t): 对观测空间组件的消融 (不包括 $\tilde{x}_t$) 表明, 具有 c_t 的变体始终优于其对应版本 (图 6i.a)。缺少 h_t 的变体目光短浅且行为激进, 加速度更高 (表 II), 因为它们纯粹依赖压缩后的 z_t 进行地形反馈, 这使得它们不如地形感知变体。从图 6i.a 中, 我们观察到潜在条件化并未提升性能 (见 $[h_t, c_t]$ 和 $[z_t, h_t, c_t]$), 因此它纯粹用于分析和可重用性。然而, 条件化的 π_{parkour} 可以在推理过程中将 oracle 用作闭环反应式规划器, 从而将系统驱动到指令模式。从图 6i.a 和 b 中, J_T 和 $\tilde{J}_T$ 的相似趋势表明观测空间变化并未造成差异。

oracle 的选择 (Ξ): 三种 oracle, 即 Ξ_{ii} 、 Ξ_{iqr} 和 Ξ_{prev} , 在最大偏差上呈现非递增趋势



(i) 估计的替代目标 ($\tilde{J}_T$) 和真实目标 (J_T) 与以下因素的关系: 1) 观测空间, o_t (a 和 b), 2) 具有不同允许状态边界的预言机, Ξ_ρ (c), 3) 视界长度, Δt (d 和 e), 以及 4) 允许状态边界, ρ (f 和 g)。在 b、e 和 g 中, J_T 的上界用红色标记。(ii) π_{parkour} 在执行不同幅度的跳跃和腾跃时 (包括在穿越不同尺寸的障碍块和间隙时进入和离开 Ψ_M) 的未折扣回报热力图。



(iii) 运动轨迹比较: 1) 预言机的选择 (a, b, c), 其中 Ξ_{li} 、 Ξ_{lqr} 失败, 只有 Ξ_{prev} 成功完成从 2m 高台侧身跳入水; 2) 视界长度 (d, e, f), 最长的视界 ($\Delta t = 30dt$) 实现了所需的敏捷性能; 3) 允许状态边界 (g, h, i), 较紧的边界 ($\rho = 0.1$) 和较宽松的边界 ($\rho = 0.8$) 均失败。(iv) 不同 ρ 在固定 PPO 超参数下的训练曲线。

图 6: 消融与分析

边界, ϵ 。由于最优探索边界 (ρ^*) 取决于 ϵ , 我们对每个预言机将 ρ 从 0.1 变化到 0.8。对于跑酷, 不同预言机未表现出显著性能差异 (见视频结果)。然而, 对于跳水, Ξ_{prev} 变体表现显著更好 (图 6i.c 和 6iii.c)。较紧的边界 ($\rho = 0.1$) 对 Ξ_{prev} 效果最佳, 因为它具有最低的 ϵ 。相反, 较高的探索偏差 ($\rho = 0.4$) 对 Ξ_{lqr} 和 Ξ_{li} 效果最佳。因此,

$$\epsilon_{li} \geq \epsilon_{lqr} \geq \epsilon_{prev} \implies \rho_{li}^* \geq \rho_{lqr}^* > \rho_{prev}^*, \text{ 确认了公式 5。}$$

预言家视野范围的选择 (Δt): 我们评估了不同视野范围下的策略性能: $\Delta t = 7dt$ 、 $15dt$ 和 $30dt$ 用于跑酷任务。最短的视野 $\Delta t = 7dt$ 导致短视行为, 保持高 $\tilde{J}_T$ 但低 J_T , 因为它通过利用高重规划频率保持静止

(图 6iii.d 和 6i.d,e), 这也被 [13] 观察到。虽然向前推进, $\Delta t = 15dt$ 未能预判更远的地形, 导致准静态操作 (图 6iii.e)。相反, $\Delta t = 30dt$ 使机器人能够高效地从一块砖跳到另一块砖, 展现出敏捷性并达到最优结果 (图 6iii.f)。增加 Δt 使 $\tilde{J}_T$ 与真实任务目标 J_T 对齐 (图 6i.d,e)。

允许状态边界的选择 (ρ): 对于跑酷中的 Ξ_{prev} , 我们将 ρ 从 0.05 变化到 0.8 (图 6i.f 和 g)。我们发现了一个最优的 $\rho^* = 0.5$, 性能在此值附近下降。对于 $\rho < \rho^*$, 最优解可能位于 ρ 邻域之外 (图 6iii.g 和图 6iv)。相反, $\rho > \rho^*$ 增加了 $\epsilon + \rho$ 内的局部最优, 导致次优解 (高 $\tilde{J}_T$), 如图 6iii.i 中 $\rho = 0.8$ 所示, 策略停滞不前而不前进 (低 J_T)。图 6iv 中的训练曲线显示, $0.1 \leq \rho \leq 0.6$ 收敛到全局最优, 而其余则停留在局部最优。注意 $\rho \rightarrow \infty$ 是标准 PPO。

因为它优化了 $\tilde{J}_T$ 而不受 Ξ 引导。无引导的普通 PPO ($\rho = 10^{10}$) 陷入了与 $\rho = 0.8$ 相同的局部最优。因此, 预言家引导的优化通过正确选择 ρ , 帮助标准 PPO 逃离局部最优。

V. 结论

本文介绍了一种通过先验有界允许状态和任务关键多模态性来引导策略优化的框架, 以应对复杂任务。单个 OGMP (每项任务) 成功解决了敏捷双足跑酷和跳水问题, 展现了多功能的敏捷性。未来工作将致力于扩展到接触丰富的开放世界移动操作任务。此外, 通过将可达状态限制在状态空间的子集内, 我们放弃了 OGMP 成为全局策略的可能性。因此, 任何处于 oracle 参考的 ρ 邻域之外的状态都可能导致失败。由于当前的深度强化学习方法缺乏全局收敛保证, 这一限制并非严格约束, 但突显了未来需要更强算法扩展的必要性。

参考文献

- [1] J. Siekmann, K. Green, J. Warila, A. Fern, and J. Hurst, “Blind Bipedal Stair Traversal via Sim-to-Real Reinforcement Learning,” in *RSS*, 2021.
- [2] D. Hoeller, N. Rudin, D. Sako, and M. Hutter, “Anymal parkour: Learning agile navigation for quadrupedal robots,” *Science Robotics*, 2024.
- [3] X. Cheng, K. Shi, A. Agarwal, and D. Pathak, “Extreme parkour with legged robots,” in *RoboLetics: Workshop @CoRL 2023*, 2023.
- [4] Z. Zhuang, Z. Fu, J. Wang, C. G. Atkeson, S. Schwertfeger, C. Finn, and H. Zhao, “Robot parkour learning,” in *CoRL*, 2023.
- [5] N. Rudin, D. Hoeller, M. Bjelonic, and M. Hutter, “Advanced skills by learning locomotion and local navigation end-to-end,” in *IEEE IROS*, 2022.

- [6] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, and M. Hutter, “在野外学习四足机器人的鲁棒感知运动,” *Science Robotics*, 2022.[7] S. Levine 和 V. Koltun, “引导策略搜索,” 第 30 届国际机器学习会议论文集 (S. Dasgupta 和 D. McAllester 编), 第 28 卷, 机器学习研究论文集, (美国佐治亚州亚特兰大), 第 1–9 页, PMLR, 2013 年 6 月 17–19 日.[8] S. Levine 和 V. Koltun, “通过轨迹优化学习复杂神经网络策略,” 第 31 届国际机器学习会议论文集 (E. P. Xing 和 T. Jebara 编), 第 32 卷, 机器学习研究论文集, (中国北京), 第 829–837 页, PMLR, 2014 年 6 月 22–24 日.[9] I. Mordatch 和 E. Todorov, “结合函数逼近和轨迹优化的优势,” *机器人学: 系统与科学会议论文集*, (美国伯克利), 2014 年 7 月.[10] R. Cheng, A. Verma, G. Orosz, S. Chaudhuri, Y. Yue, 和 J. Burdick, “用于降低方差强化学习的控制正则化,” 第 36 届国际机器学习会议论文集 (K. Chaudhuri 和 R. Salakhutdinov 编), 第 97 卷, 机器学习研究论文集, 第 1141–1150 页, PMLR, 2019 年 6 月 9–15 日.[11] J. Carius, F. Farshidian, 和 M. Hutter, “Mpc-net: 一种基于第一性原理引导的策略搜索,” *IEEE 机器人与自动化快报*, 第 5 卷, 第 2 期, 第 2897–2904 页, 2020.[12] S. Gangapurwala, A. Mitchell, 和 I. Havoutis, “用于动态四足机器人运动的引导约束策略优化,” *IEEE 机器人与自动化快报*, 第 5 卷, 第 2 期, 第 3642–3649 页, 2020.[13] F. Jenelten, J. He, F. Farshidian, 和 M. Hutter, “Dtc: 深度跟踪控制,” *Science Robotics*, 2024.[14] X. B. Peng, P. Abbeel, S. Levine, 和 M. van de Panne, “Deepmimic: 基于示例的物理角色技能深度强化学习,” *ACM Trans. Graph.*, 第 37 卷, 第 143:1–143:14 页, 2018 年 7 月.[15] X. B. Peng, Z. Ma, P. Abbeel, S. Levine, 和 A. Kanazawa, “Amp: 用于风格化物理角色控制的对抗性运动先验,” *ACM Trans. Graph.*, 第 40 卷, 2021 年 7 月.[16] E. Vollenweider, M. Bjelonic, V. Klemm, N. Rudin, J. Lee, 和 M. Hutter, “通过强化学习中多个对抗性运动先验的高级技能,” *ICRA 2023*, 第 5120–5126 页.[17] Z. Li, X. B. Peng, P. Abbeel, S. Levine, G. Berseth, 和 K. Sreenath, “用于多功能、动态和鲁棒双足运动控制的强化学习,” 2024.[18] Z. Luo, J. Wang, K. Liu, H. Zhang, C. Tessler, J. Wang, Y. Yuan, J. Cao, Z. Lin, F. Wang, J. Hodgins, 和 K. Kitani, “Smpolympics: 用于物理模拟人形机器人的运动环境,” 2024.[19] C. Chi, S. Feng, Y. Du, Z. Xu, E. Cousineau, B. Burchfiel, 和 S. Song, “扩散策略: 通过动作扩散进行视觉运动策略学习,” 2023.[20] S. Bohez, S. Tunyasuvunakool, P. Brakel, F. Sadeghi, L. Hasenclever, Y. Tassa, E. Parisotto, J. Humplik, T. Haarnoja, R. Hafner, 等, “模仿与再利用: 从人类和动物行为中学习可重复使用的机器人运动技能,” *arXiv 预印本 arXiv:2203.1713*, 2022.[21] T. Haarnoja, B. Moran, G. Lever, S. H. Huang, D. Tirumala, J. Humplik, M. Wulfmeier, S. Tunyasuvunakool, N. Y. Siegel, R. Hafner, M. Bloesch, K. Hartikainen, A. Byravan, L. Hasenclever, Y. Tassa, F. Sadeghi, N. Batchelor, F. Casarini, S. Saliceti, C. Game, N. Sreendra, K. Patel, M. Gwira, A. Huber, N. Hurley, F. Nori, R. Hadsell, 和 N. Heess, “通过深度强化学习为双足机器人学习敏捷足球技能,” *Science Robotics*, 第 9 卷, 第 89 期, 文章编号 eadi8022, 2024.[22] L. Hasenclever, F. Pardo, R. Hadsell, N. Heess, 和 J. Merel, “CoMic: 互补任务学习与模仿用于可重用技能,” *ICML, PMLR*, 2020.[23] M. H. Raibert, “腿式机器人,” *ACM 通讯*, 第 29 卷, 第 6 期, 第 499–514 页, 1986.[24] J. Norby 和 A. M. Johnson, “动态腿式机器人的快速全局运动规划,” 2020 年 IEEE/RSJ 国际智能机器人与系统会议 (IROS), 2020.[25] J. Li 和 Q. Nguyen, “基于力和力矩的模型预测控制实现双足机器人高度动态运动,” *IEEE CDC*, 2021.[26] T. Koo, G. Pappas, 和 S. Sastry, “带约束系统的多模态控制,” 第 40 届 IEEE 决策与控制会议论文集 (Cat. No.01CH37228), 第 3 卷, 第 2075–2080 页, 2001.[27] E. Asarin, O. Bournez, T. Dang, O. Maler, 和 A. Pnueli, “有效线性系统切换控制器的综合,” *IEEE 论文集*, 第 88 卷, 第 7 期, 第 1011–1025 页, 2000 年.[28] L. Krishna 和 Q. Nguyen, “学习多模态双足 locomotion 与隐式过渡: 一种通用策略方法,” 载于 *IEEE IROS*, 2023 年.[29] M. Murooka, M. Morisawa 和 F. Kanehiro, “基于预览控制的人形多接触运动质心轨迹生成与稳定,” *IEEE RAL*, 2022 年.[30] R. M. Alexander, “双足与四足动物的步态,” *IJRR*, 1984 年。