

在挑战性地形上学习四足运动

JOONHO LEE^{1,*}, JEMIN HWANGBO^{1,2,†}, LORENZ WELLHAUSEN¹, VLADLEN KOLTUN³, 以及MARCO HUTTER¹

¹机器人系统实验室, 苏黎世联邦理工学院, 苏黎世, 瑞士²机器

人与人工智能实验室, 韩国科学技术院, 大田, 韩国³智能系统

实验室, 英特尔, 圣克拉拉, 加利福尼亚州, 美国

†该工作的主要部分是在其于1期间完成的*通讯作者:

jolee@ethz.ch

本文为《科学机器人》第5卷第47期eabc5986号 (2020年) 的录用版本, DOI:

10.1126/scirobotics.abc5986

地球上一些最具挑战性的环境, 四足动物可以进入, 但自主机器却难以企及。腿部运动可以极大地扩展机器人学的操作领域。然而, 传统的腿部运动控制器基于精心设计的状态机, 这些状态机显式触发运动基元和反射的执行。这些设计在复杂性不断攀升的同时, 却未能达到动物运动的通用性和鲁棒性。在此, 我们提出了一种在具有挑战性的自然环境中实现腿部运动的极其鲁棒的控制器。我们提出了一种将本体感觉反馈融入运动控制的新颖解决方案, 并展示了从仿真到自然环境的卓越零样本泛化能力。该控制器通过仿真中的强化学习进行训练, 基于一个处理本体感觉信号流的神经网络。经过训练的控制​​器已带领两代ANYmal四足机器人进入各种自然环境, 这些环境超出了此前腿部运动领域已发表工作的能力范围。该控制器在训练中从未遇到过的条件下仍能保持其鲁棒性: 可变形地形 (如泥地和雪地)、动态立足点 (如碎石) 以及地面障碍物 (如茂密植被和湍急水流)。本项工作为机器人学开辟了新前沿, 并表明在更简单的领域中进行训练即可在自然环境中实现极端鲁棒性。

1. 引言

腿部运动能够极大地拓展机器人学的应用范围。地球上大部分干燥陆地是轮式和履带式机器无法通行的, 这些机器在挑战性地形上的稳定性会受到严重损害。而四足动物则能够到达我们星球上一些最偏远的地区。它们可以在自身运动学可达范围内选择安全的立足点, 并迅速根据环境改变其运动学状态。腿式机器人有潜力穿越其动物对应物所能通行的任何地形。

迄今为止, 尚无已发表的研究成果展示过如图1所示, 在多样化且具有挑战性的自然环境中实现动态运动。这些环境具有高度不规则的轮廓、可变形地形、湿滑表面以及地面障碍物。在此类条件下, 现有已发表的控制器会出现频繁的足部打滑、失去平衡, 并最终导致灾难性故障。由于无法获取关于地形物理特性的真实信息, 这一挑战变得更加严峻。相机和激光雷达等外部传感器无法可靠地测量摩擦和柔顺性等物理特性, 会受到植被、雪地和水体等障碍物的阻碍, 并且可能不具备足够的覆盖范围和时间分辨率来捕捉由机器人自身引起的变化, 例如机器人足下松散地面的崩塌。在这些条件下, 机器人必须主要依赖本体感觉——即对自身身体

构型的高时间分辨率感知。为应对诸如意外地面接触、地形变形和足部打滑等不可预见事件, 控制器必须快速生成满足多重目标的全身轨迹: 平衡、避免自碰撞、应对外部干扰以及运动。虽然动物能本能地解决这一复杂的控制问题, 但在机器人学中, 这仍是一个悬而未决的挑战。

在不平坦地形上实现腿部运动的传统方法催生了日益复杂的控制架构。许多方法依赖于精细的状态机来协调运动基元和反射控制器 [1–5] 的执行。为了触发状态间的转换或反射的执行, 许多系统会显式估计诸如地面接触与打滑 [6–8] 等状态。这种估计通常基于经验调优的阈值, 在遇到泥地、雪地或植被等未建模因素时可能变得不稳定。其他系统在足部使用接触传感器, 这在现场条件下可能变得不可靠 [9–11]。总体而言, 用于崎岖地形上腿部运动的传统系统, 随着考虑的场景增多, 其复杂性不断升级, 开发和维护变得极其费力, 并且仍然容易受到边界情况的影响。

无模型强化学习 (RL) 最近已成为开发腿部运动技能的一种替代方法 [12–14]。强化学习的思想是调整控制器以优化一个



图 1. 所提出的运动控制器在多种具有挑战性环境中的部署

ts.

给定奖励函数。优化过程基于控制器自身执行时获取的数据进行,并随着经验积累而改进。强化学习已被用于简化运动控制器的设计、自动化设计流程的某些环节,以及学习那些无法通过先前方法工程实现的行为 [12–15]。

然而,强化学习在腿部运动中的应用在很大程度上仍局限于实验室环境和条件。我们先前的工作展示了运动与恢复行为的端到端学习——但仅限于实验室内的平坦地面 [12]。其他研究也开发了用于腿部运动的强化学习技术,但同样主要聚焦于实验室环境中的平坦或中等纹理表面 [13, 14, 16–19]。

本文提出了一种用于挑战性地形上盲态四足运动的极其鲁棒的控制器。该控制器仅使用来自关节编码器和惯性测量单元的 proprioceptive 测量值,这些是腿式机器人最耐用、最可靠的传感器。控制器的运行情况如图1和视频1所示。该控制器被用于驱动两代ANYmal四足机器人 [20],在多种超越先前腿式机器人学已发表工作范畴的条件下运行。该控制器能够可靠地小跑通过泥地、沙地、碎石、茂密植被、雪地、流水以及各种其他越野地形。同一控制器还被用于我们参加DARPA地下挑战赛城市赛段的参赛作品。在所有部署中,同一代机器人在所有条件下均由完全相同的控制器驱动,无需针对不同环境进行任何调参。

与许多先前将无模型强化学习应用于腿部运动的方法类似,我们在仿真中训练控制器 [12, 14, 16]。先前的研究已确立了一系列成功将腿式运动控制器从仿真迁移到物理机器的实践方法。其一是对物理系统进行真实建模,包括执行器 [12]。其二是对仿真与现实之间存在差异的物理参数进行随机化,从而使控制器能够适应物理部署中可能出现的各种条件范围,而无需事先精确建模这些条件 [21]。

我们也采用了这些思路,但发现它们并不足以在崎岖地形上实现鲁棒运动。因此,我们引入并验证了多个额外要素,这些要素对于实现所展示的技能至关重要。第一个要素是采用不同的策略架构。与先前工作中常见的基于机器人当前状态快照的多层感知机 (MLP) 不同,我们使用序列模型,具体来说时序卷积网络 (TCN) [22],它基于本体感受状态的扩展历史生成驱动指令。我们不使用显式的接触与滑移估计模块(这些模块在挑战性场景中往往表现脆弱);相反,TCN学会根据需要从本体感受历史中隐式推理接触和滑移事件。

实现所展示结果的第二个重要理念是特权学习 [23]。我们发现,直接通过强化学习训练崎岖地形运动策略并不成功:监督信号稀疏,且所提出的网络无法在合理的时间预算内学会运动。因此,我们将训练过程分解为两个阶段。首先,我们训练一个能够访问特权信息的教师策略,即地形和机器人与其接触的真实知识。特权信息使策略能够快速实现高性能。然后,我们利用这个特权教师来指导一个纯本体感知学生控制器的学习,该控制器仅使用真实机器人上可用的传感器。这种特权学习协议通过仿真实现,但由此产生的本体感受策略并不局限于仿真,而是部署在物理机器人上。

第三个被证明对实现所述



图2. 若干特定部署场景。(A–F) 对湿滑和可变形地形的零样本泛化。(G) DARPA地下挑战赛城市赛段(下楼梯)。台阶高度为18厘米,斜率为 $\sim 45^\circ$ 。

鲁棒性水平至关重要的理念是自动课程,它根据控制器在训练过程不同阶段的表现自适应地合成地形。本质上,地形被合成后,控制器能够在穿越它们的同时变得更加鲁棒。我们评估参数化地形的可穿越性,并使用粒子滤波来维持中等难度地形参数的分布 [24, 25],该分布会随着神经网络的学习而自适应调整。训练条件逐渐变得更加具有挑战性,最终产生一个将敏捷性与前所未有的韧性相结合的全向控制器。

由此产生的腿式运动控制器比现有文献中的任何同类控制器都更加鲁棒。值得注意的是,该控制器在零样本泛化设置中始终有效。也就是说,当在训练中从未遇到过的条件下进行测试时,它仍然保持鲁棒性。我们的仿真训练仅使用刚性地形和一小部分程序化生成的地形轮廓(如丘陵和台阶)。然而,当部署在物理四足机器人上时,该控制器成功处理了可变形地形(泥地、苔藓、雪地)、动态立足点(在杂乱的室内环境中踩踏滚动的木板,或现场中的碎片)以及地面障碍物,如茂密植被、碎石和湍急水流。我们的方法和结果为腿式机器人学开辟了新的前沿,并表明物理世界的非凡复杂性可以被驯服,而无需脆弱且费力的建模,也无需在现场条件下进行危险且昂贵的反复试验。

2. 结果

视频1总结了所提出工作的成果。我们已将训练好的运动控制器部署在两代ANYmal机器人上: ANYmal-B (图2D–G) 和ANYmal-C (图2A–C及图3)。这些机器人具有不同的运动学、惯性和执行器。

自然环境

所提出的控制器已部署在多种自然环境中,如图1和视频1及S1所示。这些环境包括陡峭的




图 3. 室内环境中的评估。 (A) 不稳定碎片上的运动。机器人踩上松散木板（以红色和蓝色突出显示），这些木板在机器人足部下脱落。(B) 该策略展现出足部卡住反射，并克服了 16.8 厘米高的台阶。(C) 该策略学会了无论接触位置如何，都能妥善处理障碍物。此处展示了在摆动相期间，当小腿中部遇到障碍物时的反应。(D) 针对台阶和负载的控制实验。我们的控制器和基线 [1, 26] 被指令在有无 10 公斤负载的情况下越过台阶行走。(E) 不同台阶高度的成功率。每种条件下的成功率基于 10 次试验评估。(F) 平坦地形上不同指令方向的平均线速度。0° 指机器人的前方。阴影区域表示 95% 置信区间。(G) 平坦地形上不同指令方向的平均航向误差。阴影区域表示 95% 置信区间。

数量	控制器	地形		
		Moss	Mud	植被
平均速度 (米/秒)	Ours	0.452	0.338	0.248
	基线	0.199	0.197	–
平均 机械 COT	Ours	0.423	0.692	1.23
	基线	0.625	0.931	–

表1. 自然环境中运动性能对比。 机械运输成本通过执行器输出的正机械功率计算得出。

山路、流动溪流、泥地、茂密植被、松散碎石、雪覆盖的山丘以及潮湿森林。图2A-F进一步突出了若干具体场景。这些环境具有策略在训练期间未曾经历的特征。地形可能变形或崩塌，表面材料属性存在显著变化。由于植被、碎石和粘性泥地，机器人的腿部频繁受到扰动。现有使用相机或激光雷达的地形估计管道[27]在雪地（图2A）、水域（图2C）或茂密植被（图2F）环境中会失效。我们的控制器不依赖外部感觉，因此不受此类故障影响。该控制器基于本体感觉观测的历史记录学习全向运动，并在从未经历过的地形特征上进行零样本部署时表现出鲁棒性。

我们将所提出的控制器与最先进基线在森林环境中进行了比较。[1, 26] 该基线能够穿越平坦且无障碍的区域，但在遇到松散树枝、茂密植被和泥地时频繁失败，如电影S1所示。我们的控制器在这些实验中从未失败。

我们在三种条件下（苔藓、泥地和植被）对所提出的控制器和基线进行了定量评估（图2D-F）。我们测量了运动速度和能效。结果报告在表格1中。所提出的控制器在所有条件下均实现了更高的运动速度。我们计算了无量纲的运输成本（COT），以比较不同速度范围内控制器的效率。我们将机械运输成本定义为 $\sum_{12 \text{ actuators}} [\tau \dot{\theta}] / (mgv)$ 。 τ 表示关节扭矩， $\dot{\theta}$ 是关节速度， mg 是总重量， v 是运动速度。该数量表示执行器每单位重量和单位运动速度所施加的正机械功率 [28]。如表格1所示，所提出的控制器能效更高，其运输成本低于基线。

表格1中报告的定量评估低估了两种控制器之间的差异，因为它仅测量了基线控制器成功运动时的速度和能量效率。基线的灾难性故障并未计入这些测量中：当基线失败时，由人类操作员将其重置为更稳定的配置。由于茂密植被和其他因素导致的基线控制器灾难性故障如电影S1所示。我们的控制器未出现此类故障。

DARPA地下挑战赛

我们的控制器被CERBERUS团队用于DARPA地下挑战赛城市赛段（图2G）。它取代了该团队过去使用的基于模型的控制器 [1, 26]。比赛的目标是开发能够快速测绘、导航和搜索复杂地下环境（包括隧道、城市地下和洞穴网络）的机器人系统。人类

操作员在比赛期间不得物理协助机器人；仅允许远程操作。因此，运动控制器需要在长时间任务中无故障运行。据我们所知，这是首次在如此竞争性的现场部署中使用通过无模型强化学习训练的四足运动控制器。

所提出的控制器驱动两台ANYmal-B机器人完成了四次60分钟的任务。在整个比赛过程中，该控制器表现出零故障率。比赛期间其中一台机器人穿越的陡峭楼梯如图2G所示。

室内实验

我们进一步在布满松散碎片的室内环境中评估了所提出控制器的鲁棒性，如图3A所示。支撑面不稳定，机器人的足部频繁打滑。这种条件常见于灾难现场和建筑工地，而这些正是未来腿式机器人预期要运行的环境。

结果如图3A和视频S2所示。机器人在该区域全向移动。所提出的控制器能够在变化的支撑面上稳定运动。这种鲁棒性水平超越了以往针对ANYmal机器人的控制器 [1, 26]，并且与当前最先进的技术水平相当 [2, 29]。

学习到的控制器展现出一种足部卡住反射，如图3B和视频S3所示。该策略纯粹通过本体感觉观测识别出足部被卡住，并将足部抬升越过障碍物。这种反射在训练过程中并未以任何方式指定：它们是自适应地发展出来的。这使所提出的方法区别于传统控制器设计方法，后者明确构建了此类反射，并通过更高级别的状态机来协调其执行 [1, 3]。图3B中所示的台阶高16.8厘米，高于机器人在平坦地形上正常行走时的足部离地高度。在平坦地形上，左前腿和右前腿的最大足部离地高度分别为12.9厘米和13.6厘米¹，而在足部卡住的情况下，这一高度分别增加到22.5厘米和18.5厘米。我们的控制器还学会了在上台阶时调整后腿轨迹。在平坦地形上，左后腿和右后腿的最大足部离地高度分别为13.5厘米和9.06厘米，当前腿位于台阶上方时，这一高度分别增加到16.6厘米和15.9厘米。进一步的分析见材料与方法部分。另请注意，我们的控制器学习到的反射更为通用，并不局限于特定的接触事件。图3C展示了控制器在摆动相期间对小腿中部碰撞的响应。在此情况下，卡住事件并非由足部接触信号指示，而使用足部接触事件作为触发器的脚本控制器将无法妥善处理这种情况。另一方面，我们的控制器将本体感觉流作为一个整体进行分析，并且在训练时未对可能的接触位置做出假设。因此，它能够学会对任何影响机器人身体构型的障碍物和扰动做出反应。

现在我们重点将所提出的方法与基线控制器在受控设置中进行比较。[1, 26] 我们首先在单步台阶的诊断设置中比较控制器的鲁棒性，如图3D所示。每次试验中，机器人直线驶向一个台阶，持续10秒。如果机器人用前腿和后腿都成功越过台阶，则该试验视为成功。我们对每个台阶高度进行了10次试验，并计算了成功率。由于基线控制器以期望的基座线速度作为输入，我们指令了0.2米/秒和0.6米/秒的前进速度。0.6米/秒是基线的最大速度。成功率如图3E所示。所提出的控制器在上台阶和下台阶方面均优于基线。基线对足部卡陷表现出高敏感性，这常常导致摔倒，如视频S3所示。

¹我们分别用L、R、F、H表示左、右、前、后，以简洁地指代某条腿。例如，“左前腿”即指左前腿。

我们还在存在显著模型失配的情况下测试了控制器。我们附加了一个10公斤的负载,如图3D和[视频S4](#)所示。该负载占机器人总重量的22.7%,并且在训练过程中从未模拟过。如图3E所示,尽管存在模型失配,所提出的控制器仍能越过高达13.4厘米的台阶。而基线在带有负载的情况下,无论以何种指令速度都无法越过任何台阶。

随后,我们在平坦地面上评估了带负载情况下各控制器的跟踪性能。我们向每个控制器下达了8个方向的指令,并测量了运动速度与跟踪误差。基线控制器的目标速度固定为0.4米/秒,这与所提出控制器的工作速度相近。在图3F中,我们展示了各控制器的速度曲线。我们的控制器在所有方向上均能以约0.4米/秒的速度运动,且在带负载时表现相似。相比之下,基线控制器的运动速度随方向变化,这可以从各向异性速度曲线中看出,并且带负载时速度曲线明显偏离中心。图3G展示了每个指令方向上控制器的航向误差。航向误差是指令速度与机器人基座速度之间的夹角。所提出控制器的航向误差始终小于基线控制器,无论是否带负载。基线控制器在横向上的误差达到 $\sim 30^\circ$,并且当指令速度为(0.6米/秒)时,基线控制器失效,如[电影S4](#)所示。相比之下,所提出控制器的平均航向误差无论是否带负载均保持在 10° 以内。我们得出结论:所提出的控制器对模型失配具有更强的鲁棒性。

接下来,我们测试对足部打滑的鲁棒性。为了引入打滑,我们使用了一块湿润白板[1]。结果如[电影S5](#)所示。基线方法很快失去平衡,剧烈摆动腿部并摔倒。相比之下,所提出的控制器能够适应湿滑地形,并成功沿指令方向移动。

3. 讨论

所呈现的结果显著推进了腿式机器人学领域的已发表技术现状。除了结果本身,本文提出的方法还具有广泛的应用前景。在我们工作之前,可能存在一种假设,即仿真训练从根本上受到仿真环境在模拟物理世界复杂性方面的局限性的制约。当前技术在模拟柔顺接触、打滑以及可变形和易碎地形方面的能力严重受限。因此,泥地、雪地、茂密植被、汹涌水流等许多现象都超出了机器人仿真框架[30–32]的能力范围。无模型强化学习算法的样本复杂度(通常需要数百万个时间步进行训练)进一步加剧了这一挑战,因为它排除了对每个时间步可能需要数秒计算量的框架的依赖。

我们的工作表明,模拟物理世界中惊人的多样性可能并非必要。我们的训练环境仅包含刚性地形,没有柔顺性或植被等地面障碍物。然而,在此环境中训练的控制器成功应对了部署时遇到的各种现场条件。

我们看到了若干局限性以及未来工作的机遇。首先,所提出的控制器仅表现出小跑步态。这比自然界中四足动物发现的步态模式范围更窄[33]。步态模式在一定程度上受到机器人运动学和动力学的约束,但ANYmal机器人在物理上具备多种步态能力[26]。我们推测,强调多样性的训练协议和目标可以激发这些步态。

其次,所提出的控制器完全依赖于本体感觉。

这是一个显著的优势,因为该控制器对传感器套件的假设很少,并且当外部感觉失效时不易发生故障。事实上,现有研究已经论证,盲(本体感觉)控制器应构成腿式运动堆栈的基础[3]。然而,盲运动本质上存在局限性。如果机器被指令走下悬崖,它就会照做。即使在不太极端的条件下,机器人的步态也相当保守,因为它在运动时必须通过身体来感知环境。未来工作的一个重要机遇是,将所提出的方法作为开发混合本体-外部感觉控制器的起点。这种控制器将像许多动物一样,即使在视觉和其他外部感觉受到干扰时也能运动,但在提供外部感觉数据时会加以利用。这将使腿式机器能够自主穿越可能存在悬崖等致命元素的环境,并在更安全的条件下提高速度和能量效率。

更广泛地说,所呈现的结果加速了腿式机器在轮式和履带式机器人无法到达、对人类危险或难以进入的环境中的部署,同时所提出的方法论为在仿真中训练复杂机器人系统并将其部署到丰富而复杂的物理世界中开辟了新的前沿。

4. 材料与方法

A. 概述

本文所提出的控制器的主要目标是使机器人能够按照指令在崎岖地形上移动。指令可由人类操作员或高层导航控制器发出。与许多现有工作[12, 14, 16]侧重于跟踪基坐标系的目标速度 $({}^B_{IB}\hat{v}_T)$ 不同,在我们的公式中,仅将方向 $({}^B_{IB}\hat{v}_T)$ 提供给控制器。原因在于,在挑战性地形上,目标速度的可行范围往往不明确。例如,机器人下坡可以比上坡走得更快。

指令向量定义为 $\langle ({}^B_{IB}\hat{v}_T)^{xy}, (\hat{\omega}_T)_z \rangle$ 。第一部分是基坐标系中的目标水平方向 $({}^B_{IB}\hat{v}_T)^{xy} := \langle \cos(\psi_T), \sin(\psi_T) \rangle$,其中 ψ_T 是基坐标系中指令方向的偏航角。停止指令定义为 $\langle 0.0, 0.0 \rangle$ 。第二部分是转向方向 $(\hat{\omega}_T)_z \in \{-1, 0, 1\}$ 。1表示沿基坐标系 z 轴逆时针旋转。

图4给出了我们方法的概述。[23] (图4A)。我们首先训练一个教师策略,该策略能够获取关于地形的特权信息。然后,将这个教师策略蒸馏到一个不依赖特权信息的本体感受学生策略中。特权教师策略仅限于仿真中使用,而学生策略则部署在物理机器上。我们的方法与Chen等人[23]的方法的一个区别在于,我们不依赖专家演示来训练特权策略;相反,教师策略是通过强化学习来训练的。

特权教师模型基于多层感知机(MLPs),它接收关于机器人当前状态、地形属性以及机器人与地形接触的信息。该模型计算出一个表示当前状态的潜在嵌入 l_t ,以及一个动作 a_t 。训练目标是对在指定方向上的运动给予奖励。

教师策略训练完成后,用于监督一个本体感受的学生策略。学生模型是一个时序卷积网络(TCN)[22],它接收一个序列的 N 个本体感受观测作为输入。学生策略通过模仿进行训练。 l_t 和 a_t 由教师策略计算得出,用于监督学生。如图4A所示。




图 4. 所提出方法的概述。(A) 两阶段训练过程。首先，在仿真中使用强化学习训练一个教师策略。该策略可以访问在现实世界中无法获得的特权信息。接着，一个本体感受学生策略通过模仿教师进行学习。该学生策略基于本体感受感官输入流进行决策，不使用特权信息。(B) 自适应地形课程在训练过程中合成难度适中的地形。粒子滤波用于维护一个地形参数分布，这些参数对策略而言具有挑战性但可穿越。(C) 运动控制器的架构。学习到的本体感受策略通过运动学残差来调制运动基元。关节PD控制器的经验模型有助于在物理机器上部署。

训练在仿真中的程序化生成地形上进行。地形通过自适应方式合成，以便根据当前训练策略的技能水平促进学习。我们定义了一种地形的可穿越性度量，并开发了一种基于采样的方法，在训练过程中选择难度合适的地形。我们使用粒子滤波来维持地形参数的适当分布。如图4B所示。地形课程在教师训练和学生训练期间均会应用。

我们的控制架构如图4C所示。我们采用策略调制轨迹生成器架构 [34] 来为运动生成提供先验知识。神经网络策略通过合成残差位置指令来调制腿部相位和运动基元。

仿真使用了机器人关节PD控制器的学习动力学模型 [12]。这有助于策略从仿真迁移到现实。在仿真中完成训练后，本体感受控制器可直接部署在物理腿式机器上，无需微调。

运动合成

我们现在详细阐述图4C中所示的控制架构。该架构分为运动生成和跟踪两部分。我们控制器的输入包括指令向量以及一系列本体感受测量值，例如基座速度、朝向和关节状态。该控制器不使用任何外部感受输入（例如，没有触觉传感器、相机或深度传感器）。输入也不包含任何手工设计的特征，如足部接触状态或估计的地形几何。控制器输出关节位置目标。

我们的运动生成策略基于周期性腿相位。先前的工作通常利用预定义的足部接触时间表 [2, 26, 35]。我们为每条腿定义一个周期性相位变量 $\phi_i \in [0.0, 2\pi)$ ，该变量在 $\phi \in [0.0, \pi)$ 时表示接触相位，在 $\phi \in [\pi, 2\pi)$ 时表示摆动相。在每个时间步 t ， $\phi_i = (\phi_{i,0} + (f_0 + f_i)t) \pmod{2\pi}$ 其中 $\phi_{i,0}$ 是初始相位， f_0 是公共基频，而 f_i 是第 i 条腿的频率偏移。我们希望当 $f_0 + f_i \neq 0$ 时，腿部表现出周期性运动，并在接触相位中与地面接触。我们将 f_0 设置为 1.25 Hz，这是先前为小跑步态开发的传统控制器所使用的值 [26]。

目标足位置，即运动生成模块的输出，定义在足部的水平坐标系 [35] 中 ($H_i, i \in \{1, 2, 3, 4\}$)。 H_i 是一个参考坐标系，位于第 i 条腿的髌关节下方。该距离等于腿的标称可达范围。该坐标系的 z 轴 (H_z) 平行于 e_g ，而 $H^i x$ 是基座 x 轴 (B_x) 在水平面上的投影，即该坐标系与机器人具有相同的偏航角。 H_i 的横滚角和俯仰角与基座解耦。这一运动学技巧减少了基座姿态对足部运动的影响 [35]，从而稳定了训练。在 H_i 中定义输出，可以在策略训练初期，当基座运动因随机动作而不稳定时，减少过早终止的情况。另一个好处是，我们可以在策略训练期间，将随机策略的动作分布分解为横向和垂直方向。我们在横向方向上施加了更大的噪声，以促进沿地面的探索。

我们采用PMTG架构 [34] 将神经网络集成到控制器中。我们的实现包含四个相同的足端轨迹生成器 (FTG) 和一个神经网络策略。FTG是一个函数 $F(\phi): [0.0, 2\pi) \rightarrow \mathbb{R}^3$ ，为每条腿输出足部位置目标。当 f_i 非零时，FTG驱动垂直步态运动。 $F(\phi)$ 的定义见补充章节S3。

策略输出 f_i 和目标足部位置残差 ($\Delta r_{f_i, T}$)，第 i 条腿的目标足部位置为 $r_{f_i, T} := F(\phi_i) + \Delta r_{f_i, T}$ 。

跟踪控制通过解析逆运动学 (IK) 和关节位置控制实现。每个在 H_i 中定义的足位置目标

首先在机器人基坐标系中表示，然后通过解析逆运动学计算关节位置目标。关节位置目标随后由关节位置PD控制器进行跟踪。采用解析逆运动学的主要原因是最大化计算效率，并复用现有的位置控制执行器模型 [6, 15] 以支持仿真到现实迁移。

教师策略

我们将控制问题建模为马尔可夫决策过程 (MDP)。MDP是一种用于建模离散时间控制过程的数学框架，其中状态和结果的演化部分具有随机性。一个MDP由状态空间 $\mathcal{S}$ 、动作空间 $\mathcal{A}$ 、标量奖励函数 $\mathcal{R}(s_t, s_{t+1})$ 以及转移概率 $P(s_{t+1}|s_t, a_t)$ 定义。学习智能体根据其策略 $\pi(a_t|s_t)$ 选择动作 a_t ，并从环境中获得奖励 r_t 。强化学习框架的目标是找到最优策略 π^* ，以最大化无限时间范围内的折扣奖励总和。

假设环境对教师完全可观测，我们将运动控制建模为MDP，并使用现成强化学习方法 [36] 求解。本节将提供教师训练的MDP定义，该定义由状态空间、动作空间、转移概率和奖励函数的元组构成。

状态定义为 $s_t := \langle o_t, x_t \rangle$ ，其中 o_t 是从机器人可获取的测量向量， x_t 是现实世界中通常不可获取的特权信息。详细定义见表S4。 o_t 包含指令、朝向、基座扭转、关节位置与速度、 ϕ_i 、 f_i 、 s 以及先前足部位置目标。 o_t 中包含在 -0.01秒和 -0.02秒时测量的关节位置误差和速度，这与关节级PD控制器学习模型的输入相同。该信息使策略能够利用执行器动力学 [12]。为编码腿部相位，我们使用 $\langle \cos(\phi), \sin(\phi) \rangle$ 代替 ϕ ，这是一种平滑且唯一的角度表示。先前足部位置目标也会反馈给策略，用于计算下文将解释的目标平滑度奖励。当学生控制器部署时， o_t 中的量被替换为本体感觉传感器的读数，基座速度和朝向由状态估计器 [37] 提供。 x_t 包含直接从物理引擎接收的无噪声信息。 x_t 主要包含与足地交互相关的信息，如地形轮廓、足部接触状态与力、摩擦系数以及训练期间施加的外部干扰力。具体而言，我们使用每个足部周围9个扫描点的高程来表示地形轮廓，这些扫描点沿半径为10厘米的圆对称分布（如图4所示）。

动作 (a_t) 是一个16维向量，由腿部频率和足部位置残差组成。

奖励函数的定义使得强化学习智能体在更快地向目标前进时获得更高的奖励。奖励函数的详细说明见补充章节S4。

策略网络由两个多层感知机块构成，如图4A所示。多层感知机编码器将 x_t 嵌入到一个潜在向量 $\tilde{l}_t$ 中。 $\tilde{l}_t$ 指令和机器人状态不包含在 x_t 中，因此 $\tilde{l}_t$ 仅包含与地形和接触相关的特征。我们假设 $\tilde{l}_t$ 驱动自适应行为，例如根据地形的轮廓改变足部离地高度。然后 $\tilde{l}_t$ 和 o_t 被提供给后续的多层感知机层以计算动作。

信任区域策略优化 (TRPO) [36] 算法用于训练。我们使用的超参数见表S7。

学生策略

本体感受学生策略仅能访问 o_t 。这里的一个关键假设是，潜在特征 $\tilde{l}_t$ 可以（部分地）从

本体感觉观测值的时间序列 h_t 中恢复，该序列定义为 $h_t := o_t \setminus \{f_0, \text{关节历史, 先前足部位置目标}\}$ 。

学生策略采用时序卷积网络 (TCN) [22] 编码器。TCN编码器的输入为 H

$$\{ \begin{matrix} t-1 & & t-N-1 \end{matrix} \} \quad = \quad h, \dots, h,$$

其中 N 是历史长度。该编码器为全卷积结构，由三个扩张因果卷积层与步进卷积层交错组成，后者用于降低维度。架构细节见表S5和表S6。

我们采用TCN架构，因为它能够透明地控制输入历史长度，支持长历史记录，并且已知对超参数设置具有鲁棒性 [22]。与循环神经网络架构的比较见补充章节S8。

学生策略通过监督学习进行训练。损失函数定义为

$$\mathcal{L} := (\bar{a}_t(o_t, x_t) - a_t(o_t, H))^2 + (\bar{l}_t(o_t, x_t) - l_t(H))^2. \quad (1)$$

带有横线标记的量 ($\bar{\cdot}$) 表示由教师生成的目标值。我们采用数据集聚合策略 (Dagger) [38]。具体而言，训练数据通过学生策略滚动执行轨迹生成。对于每个访问到的状态，教师策略计算其嵌入和动作向量 ($\bar{\cdot}$)。教师策略的这些输出被用作对应状态的监督信号。我们使用的超参数见表S8。

自适应地形课程

我们的方法受强化学习智能体的自动课程学习 (ACL) 启发 [25, 39]。配对开放式开拓者 (POET) 方法 [25] 为二维双足智能体生成多样化的参数化地形。该方法采用最小准则 (MC) [24, 40]，旨在选择既不过于困难也不过于简单的环境参数：通过选择能产生中等范围奖励的任务参数来实现这一点。Florensa等人 [39] 同样为强化学习智能体选择可实现但具有挑战性的目标。

我们的方法同样实现了一种训练课程，该课程逐步修改环境参数的分布，使得策略能够持续提升运动技能并泛化到新环境。我们的工作与POET不同，因为POET旨在可能问题空间中进行开放式搜索，并演化出一组专门化的智能体，而我们则致力于获得一个单一的通用智能体。

图4B展示了训练环境中使用的地形类型。每个地形由参数向量 $c_T \in \mathcal{C}$ 生成。这些地形在补充材料第S5节中有详细描述。我们的ACL方法使用粒子滤波器来近似期望的 c_T 的分布。

我们首先描述如何在仿真中评估给定的 c_T 。我们不直接使用奖励函数来评估学习进度 [25, 41–43]，而是通过生成地形的可穿越性来评估 c_T ，该可穿越性定义为穿越地形的成功率。我们发现可穿越性比奖励函数更直观，因为奖励函数由多个通常无界的多个目标组成。我们首先定义一个标注函数 v 为

$$v(s_t, a_t, s_{t+1}) = \begin{cases} 1 & \text{if } v_{pr}(s_{t+1}) > 0.2 \\ 0 & \text{if } v_{pr}(s_{t+1}) < 0.2 \vee \text{termination} \end{cases} \quad (2)$$

对于从 s_t 到 s_{t+1} 的状态转移， $v_{pr}(s_{t+1})$ 表示在时间步 $t+1$ 时基座速度与指令方向的内积。如果 π 能够以超过0.2米/秒的速度沿指令方向移动，则认为该方向上的地形是可通行的。该阈值是一个超参数；0.2米/秒约为我们机器人最大速度的三分之一。可穿越性定义为

$$Tr(c_T, \pi) = \mathbb{E}_{\xi \sim \pi} \{v(s_t, a_t, s_{t+1} \mid c_T)\} \in [0.0, 1.0], \quad (3)$$

其中 ξ 指由 π 生成的轨迹。这遵循了先前工作 [44] 中对经验可行性的定义。

我们地形生成方法的目标是找到具有中等范围可穿越性 ($Tr(c_T, \pi) \in [0.5, 0.9]$) 的 c_T 。其基本原理是合成既不太简单也不太困难的地形。我们将地形期望度定义如下：

$$Td(c_T, \pi) := \Pr(Tr(c_T, \pi) \in [0.5, 0.9]) \quad (4)$$

$$= \mathbb{E}_{\xi \sim \pi} \{Tr(c_T, \pi) \in [0.5, 0.9]\}, \quad (5)$$

其中0.5和0.9是用于最小/最大可穿越性的固定阈值。

我们使用粒子滤波器在训练过程中跟踪高期望度 c_T 的分布。我们构建了一个粒子滤波问题，其中我们通过一组有限采样点 ($c_T^k \in \mathcal{C}, k \in 1, \dots, N_{particle}$) 来近似满足 $Tr(c_T, \pi) \in [0.5, 0.9]$ 的地形参数分布。我们的算法基于序列重要性重采样 (SIR) 粒子滤波器建模，并基于以下假设。

1. 在参数空间中，具有相似 $Tr(\cdot, \pi)$ 的地形参数在欧几里得距离上彼此接近。
2. 在由 $\mathcal{C}$ 的某个区域内的 c_{TS} 生成的地形上训练的策略，将学会对附近的地形参数进行插值。
3. $c_{T,0}, c_{T,1}, \dots$ 构成一个马尔可夫过程，其中 $c_{T,j} = \{c_{T,j}^1, c_{T,j}^2, \dots, c_{T,j}^{N_{particle}}\}$ 在迭代 j 处。

第一个假设源于这样的洞察：地形参数是可以插值的，例如，随着台阶高度的增加，楼梯的难度也会增加。第二个假设证明了使用来自 $\mathcal{C}$ 的离散样本来训练一个在 $\mathcal{C}$ 的某个区域上具有泛化能力的策略是合理的。最后一个假设对于构建粒子滤波器是必要的。

重要性权重 w^k 是为每个 c_T^k 定义的，并且元组集合 $\langle c_T^k, w^k \rangle$ 近似于目标分布 (c_{TS} 具有 $Tr(c_T, \pi) \in [0.5, 0.9]$)。我们定义测量变量 y_j^k ，使得如果 $Tr(c_{T,j}^k, \pi) \in [0.5, 0.9]$ ，则 $y_j^k = 1$ 。那么上述定义的地形期望度就变成了测量概率。

$$\Pr(y_j^k | c_{T,j}^k) = \Pr(Tr(c_{T,j}^k, \pi) \in [0.5, 0.9]) = Td(c_{T,j}^k, \pi). \quad (6)$$

在实际实现中，测量概率通过策略训练期间收集的样本的经验期望来计算：

$$\Pr(y_j^k | c_{T,j}^k) \approx \sum \frac{\mathbb{1}(Tr(c_{T,j}^k, \pi) \in [0.5, 0.9])}{N_{traj}}, \quad (7)$$

其中 N_{traj} 表示使用 $c_{T,j}^k$ 生成的轨迹数量。这些轨迹也用于策略训练。因此，我们的方法不需要额外的评估步骤来推进地形参数的课程。重采样的方式是，选择第 k 个样本的概率等于归一化重要性权重 $w^k / \sum_{i=1}^{N_{particle}} w^i \in [0, 1]$ 。

转移模型是 $\mathcal{C}$ 中的随机游走。采样点的每个参数以固定概率 $p_{transition}$ 偏移至其相邻值。这满足了第三个假设 (马尔可夫过程)，因为每个参数的演化仅依赖于当前值和随机采样的噪声。为了改善探索，我们对 $\mathcal{C}$ 进行了边界限定和离散化，以缩小搜索空间。初始样本 ($c_{T,0}^k$) 要么从 $\mathcal{C}$ 中均匀采样，要么集中在几乎平坦的地形上。

实现细节和训练过程的概述见补充材料第S2节和补充材料中的算法S1。




图 5. 消融研究。 我们使用不同的随机种子对每个模型进行了 5 次训练。误差条表示 95% 置信区间。(A) 测试设置。机器人被指令在指定方向（黑色箭头）上前进 10 秒。我们对每个测试进行了 100 次试验。在台阶测试中，如果机器人用前腿和后腿都越过台阶，则该试验被视为成功。机器人以随机关节配置初始化。斜坡测试的初始偏航角从 $U(-\pi, \pi)$ 中采样，其他测试则从 $U(-\pi/6, \pi/6)$ 中采样。足部与地面之间的摩擦系数从 $U(0.4, 1.0)$ 中采样。外力在横向方向上施加 5 秒。(B-D) TCN- N 编码器中记忆长度 N 的重要性。(E-G) 特权训练的重要性。(F) 教师（灰色）和未经特权训练直接训练的 TCN-20 学生（红色）的学习曲线。作为对比，蓝线表示经过特权训练的 TCN-20 学生的平均奖励。奖励是通过在每个策略在均匀采样地形上运行来计算的。(H-J) 自适应课程的重要性。




图 6. 涌现的足部卡住反射分析。FT 表示左前足首次接触台阶（足部卡陷事件）。（A）左前足撞击台阶后，在随后的摆动相中表现出更高的足部离地高度以越过台阶（ii-iv）。（B）从 TCN 嵌入重建的地形信息。红色椭球体：足部周围估计的地形形状。椭球体中心表示估计的地形高程，垂直长度代表不确定性（标准差）。黑色箭头：接触足处的地形法线。红色锥体：法线估计的不确定性。蓝色球体：估计的接触足。（C）不同时刻的输入显著性。峰值显示 TCN 策略关注发生在约 2.1 秒的足部卡陷（FT）事件。橙色曲线（平坦地形）显示了在相似步态相位下平坦地形上计算的显著性值。（D）在 3.4 秒时跨输入通道展开的显著性图。红色框表示左前腿与台阶碰撞时刻的关节测量值。

方法验证

我们通过消融研究来论证方法中每个组成部分的合理性：（1）在学生策略中使用序列模型，（2）特权训练，以及（3）自适应地形课程。

本体感觉控制中的记忆

我们通过时序卷积网络架构评估了在控制器中融入本体感觉记忆的重要性 [22]。令TCN- N 表示感受野为 N 个时间步的时序卷积网络。我们使用的网络架构在表S5中有详细说明。我们在旨在聚焦特定能力的诊断设置中测试了控制器。具体来说，我们测试了在斜坡地面上的全向运动、离散台阶的跨越以及对外部干扰的鲁棒性（图5A）。

图5B-D总结了记忆长度 N 的重要性。在这些实验中， N 从1（对应20毫秒记忆）变化到100（2秒本体感觉记忆）。后者是我们部署的控制器中使用的默认设置。

如图5B所示，在均匀斜坡设置中，记忆长度没有显著影响。但记忆长度对控制器跨越台阶的能力有显著影响（图5B-C）。记忆长度更长的控制器能够处理更高的台阶。如图5C所示，当后腿遇到台阶时，记忆受限的控制器失败率特别高。记忆长度更长的控制器还会调整后腿轨迹，以确保更高的足部离地高度。

图5D显示，记忆长度更长的控制器对外部干扰具有更强的鲁棒性。我们在直线行走过程中，对基座横向施加了持续5秒的外部50N力，并评估了由此产生的运动方向偏差。TCN-100控制器的偏差比TCN-1降低了35.5%。

特权训练

我们现在评估特权训练的重要性。作为基线，我们直接训练一个TCN-20策略，而不采用两阶段特权训练协议。该策略使用与教师训练相同的奖励和超参数，通过TRPO [36] 进行训练。我们将此基线与通过特权学习训练的相同TCN-20架构进行比较。

结果总结于图5E-G。图5E显示基线未能通过诊断测试：它无法在斜坡上移动或跨越台阶。图5F显示，在训练期间，基线获得的奖励无法与拥有特权信息的教师MLP架构或通过特权学习训练的本体感觉TCN-20架构（与基线相同，无特权信息）相媲美。图5G显示了训练期间的平均回合长度，这表明基线未能学会平衡和移动。

自适应地形课程

我们现在评估自适应地形课程对教师训练的影响。用于训练的地形（具体包括丘陵、台阶和楼梯）如图4B所示。作为基线，我们使用从表S2中指定的均匀采样随机生成的地形训练了一个教师 C 。如图5H所示，在没有自适应课程的情况下训练时，测试地形上的成功率显著较低。图5I显示，没有自适应课程训练的模型的平均回合长度更短（图5J）。这是因为均匀采样更可能抽取到当前训练策略无法成功穿越的地形。在这些地形上，策略会提前失败，从而获得较少的训练信号。自适应课程调节采样地形的难度，以最大化每个回合的教学收益。我们在补充章节S6中提供了对自适应课程的额外评估。

涌现行为的进一步分析

这里我们进一步分析本体感受策略如何适应不同情境。

为了研究本体感受策略如何感知环境，我们训练了一个解码器网络，该网络从训练好的TCN策略的中间层输出中重建特权信息 $x_t \in X$ 。 x_t 包含学生策略无法直接观测的信息，例如接触状态、地形形状和外部干扰。对于足部接触状态的分类，我们采用标准的交叉熵损失函数。对于其他状态的回归，我们预测每个分量的均值 m_i 和标准差 σ_i ，并使用负高斯对数似然损失来量化TCN表征中编码的不确定性 [45]:

$$\mathcal{L} = \sum_{i \in \dim(X \setminus \text{contact states})} \frac{(m_i - m_i^{gt})^2}{2\sigma_i^2} + \log(\sigma_i) \quad (8)$$

并添加了权重衰减。上标 gt 指仿真中生成的真实值。请注意，在解码器训练期间，策略网络的参数是固定的。因此，解码器网络不用于策略训练。它仅用于洞察TCN策略在训练后所编码的信息。

在图6中，我们展示了足部卡住反射运动（图6A）和重建的特权信息的快照。在图6B中，我们展示了重建的地形几何和足部接触状态。当左前足与台阶碰撞时，前腿前方的估计高程增加，其不确定性也随之增长（i+ii）。在足部卡住反射过程中，估计高程和法向量会适应台阶（iii+iv）。成功上台阶后，地形不确定性仍然较高（v），表明对整体崎岖地形的预期。此外，解码器网络能够检测到与水平面和垂直面的足部接触，同时成功识别正面碰撞，如估计地形法向量所示（i + iii）。从本体感受历史的编码中重建显式环境信息的能力，有力地表明TCN策略学会了构建环境的内部表征，并将其用于决策。我们在补充章节S7中提供了更多重建特权信息的示例。

然后我们分析本体感受策略如何利用历史观测信息。我们计算输入 $H \in \mathbb{R}^{60 \times N}$ 的显著性图，并可视化策略在克服台阶 [46] 时对输入中每个元素的敏感度。 H 的每一列是一个本体感受测量值 $h \in \mathbb{R}^{60}$ ，我们堆叠了 N 个测量值（历史长度 = 0.02 秒 $\times$ N ）。我们将第 i 个测量值（ $i \in [0, N]$ ）的显著性值定义为

$$M_i = \sum_{j \in \text{channels}} (|d((r_{f,T})_z) / dH_{i,j}|) \in \mathbb{R}, \quad (9)$$

其中 $(r_{f,T})_z$ 指的是足 f 的高度指令。我们计算了 $(r_{f,T})_z$ 的值，因为我们关注的是足部离地高度的变化。 M_i 可以解释为输出对第 i 个测量值的敏感度。由于我们使用一维卷积处理时间维度，输出为 $\mathbb{R}^N$ ，即 H 的每一行被视为一个通道。

在图6C中，我们可以看到，在足部卡陷事件（FT）发生时，显著性值在抬腿过程中保持较高水平。该策略在足部卡陷时刻直接获取测量数据，并在随后的摆动相中加以利用。这一点由图6D中的红色方框突出显示。该策略关注足部卡陷事件时测量的左前腿关节状态。

5. 致谢

资金该项目部分由英特尔智能系统网络、瑞士国家科学基金会 (SNF) 通过国家机器人研究能力中心、欧洲研究理事会 (ERC) 根据欧盟地平线2020研究与创新计划 (资助协议编号 852044和780883) 提供资助。本研究是ANYmal研究的一部分, 该社区致力于推动腿式机器人学的发展。**作者贡献**J.L提出了训练和控制方法的主要思路, 实现了控制器, 搭建了仿真环境, 并训练了控制策略。J.L进行了室内实验。J.H协助搭建了仿真环境。J.L和L.W共同进行了室外实验。J.L、J.H、L.W、M.H和V.K完善了思路, 参与了实验设计, 并分析了数据。**利益冲突**作者声明不存在竞争性利益。**数据与材料可用性**评估论文结论所需的所有 (其他) 数据均可在论文或补充材料中找到。其他材料可在 https://github.com/leggedrobotics/learning_四足机器人_运动_在_具有挑战性的_地形_补充。

补充材料

第S1节 术语表 第S2节 实现细节 第S3节 足端轨迹生成器 第S4节 教师策略训练的奖励函数 第S5节 参数化地形 第S6节 自适应地形课程的定性评估 第S7节 不同情境下特权信息的重建 第S8节 循环神经网络学生策略 第S9节 学生训练中潜在表示损失的消融实验 算法S1. 基于自动地形课程的教师训练 图S1. 自适应课程示意图。图S2. 不同情境下重建的特权信息。图S3. 本体感受控制器的神经网络架构对比 表S1. 训练的计算时间 表S2. 模拟地形的参数空间 C 表S3. 自动地形课程的超参数 表S4. 本体感受控制器的状态表示与特权信息 表S5. 神经网络架构 表S6. 学生策略的网络参数设置与训练时间 表S7. 教师策略训练的超参数 表S8. 学生策略训练的超参数 表S9. 解码器训练的超参数 [视频S1. 森林部署](#) [视频S2. 不稳定碎片上的运动](#) [视频S3. 台阶实验](#) [视频S4. 负载实验](#) [视频S5. 足端打滑实验](#)

非结构化地形中的基于事件运动, 2018年IEEE国际机器人与自动化大会 (ICRA) (IEEE, 2018)。3. M. Focchi, R. Orsolino, M. Camurri, V. Barasuol, C. Mastalli, D. G. Caldwell, C. Semini. 存在外部扰动和可变感知质量时的崎岖地形启发性规划。机器人研究进展: 从实验室到市场 (Springer, 2020), 165–209。4. J. Reher, W. Ma, A. D. Ames, 基于柔顺性的Cassie双足机器人动态行走, 欧洲控制会议, 2589–2595 (IEEE, 2019)。5. Y. Gong, R. Hartley, X. Da, A. Hereid, O. Harib, J. Huang, J. W. Grizzle, Cassie双足机器人的反馈控制: 行走、站立和骑乘赛格威, 美国控制会议, 4559–4566 (IEEE, 2019)。6. J. Hwangbo, C. D. Bellicoso, P. Fankhauser, M. Hutter, 通过融合动力学和微分/正向运动学信息进行概率足部接触估计, 2016年IEEE/RSJ国际智能机器人与系统大会 (IROS), 3872–3878 (IEEE, 2016)。7. M. Camurri, M. Fallon, S. Bazeille, A. Radulescu, V. Barasuol, D. G. Caldwell, C. Semini, 用于四足机器人状态估计的概率接触估计和冲击检测, IEEE机器人与自动化快报1023–1030 (2017)。8. M. Focchi, V. Barasuol, M. Frigerio, D. G. Caldwell, C. Semini. 四足机器人的滑移检测与恢复。机器人研究 (Springer, 2018), 185–199。9. M. Blösch, C. Gehring, P. Fankhauser, M. Hutter, M. A. Hoepflinger, R. Siegwart, 不稳定和湿滑地形上腿式机器人的状态估计, 2013年IEEE/RSJ国际智能机器人与系统大会, 6058–6064 (IEEE, 2013)。10. C. Gehring, C. D. Bellicoso, S. Coros, M. Bloesch, P. Fankhauser, M. Hutter, R. Siegwart, 四足机器人在斜坡上的动态小跑, 2015年IEEE/RSJ国际智能机器人与系统大会 (IROS), 5129–5135 (IEEE, 2015)。11. R. Hartley, J. Mangelson, L. Gan, M. G. Jadidi, J. M. Walls, R. M. Eustice, J. W. Grizzle, 通过组合正向运动学和预积分接触因子进行腿式机器人状态估计, 2018年IEEE国际机器人与自动化大会 (ICRA), 1–8 (IEEE, 2018)。12. J. Hwangbo, J. Lee, A. Dosovitskiy, D. Bellicoso, V. Tsounis, V. Koltun, M. Hutter, 学习腿式机器人的敏捷和动态运动技能, 科学机器人第eaau5872页 (2019)。13. T. Haarnoja, S. Ha, A. Zhou, J. Tan, G. Tucker, S. Levine, 通过深度强化学习学习行走, 机器人: 科学与系统 (2019)。14. Z. Xie, P. Clary, J. Dao, P. Morais, J. Hurst, M. van de Panne, 学习Cassie的运动技能: 迭代设计与仿真到现实, 机器人学习会议 (2019)。15. J. Lee, J. Hwangbo, M. Hutter, 基于深度强化学习的四足机器人鲁棒恢复控制器, *arXiv:1901.07517* (2019)。16. J. Tan, T. Zhang, E. Coumans, A. Iscen, Y. Bai, D. Hafner, S. Bohez, V. Vanhoucke, 仿真到现实: 学习四足机器人的敏捷运动, 机器人: 科学与系统 (2018)。17. Y. Yang, K. Caluwaerts, A. Iscen, T. Zhang, J. Tan, V. Sindhwani, 腿式机器人的数据高效强化学习, 机器人学习会议 (2019)。18. S. Ha, P. Xu, Z. Tan, S. Levine, J. Tan, 以最少人力投入在现实世界中学习行走, *arXiv:2002.08550* (2020)。19. X. B. Peng, E. Coumans, T. Zhang, T.-W. Lee, J. Tan, S. Levine, 通过模仿动物学习敏捷机器人运动技能, *arXiv:2004.00784* (2020)。20. M. Hutter, C. Gehring, D. Jud, A. Lauber, C. D. Bellicoso, V. Tsounis, J. Hwangbo, K. Bodie, P. Fankhauser, M. Bloesch, R. Diethelm, S. Bachmann, A. Melzer, M. A. Höpflinger, ANYmal——一种高机动性动态四足机器人, IEEE/RSJ国际智能机器人与系统大会, 38–44 (IEEE, 2016)。21. X. B. Peng, M. Andrychowicz, W. Zaremba, P. Abbeel, 基于动力学随机化的机器人控制仿真到现实迁移, IEEE国际

参考文献

1. F. Jenelten, J. Hwangbo, F. Tresoldi, C. D. Bellicoso, M. Hutter, 在湿滑地面上的动态运动, IEEE机器人与自动化快报4170–4176 (2019)。
2. G. Bledt, P. M. Wensing, S. Ingersoll, S. Kim, 接触模型融合用于

- 机器人与自动化大会 (ICRA) (IEEE, 2018)。22. S. Bai, J. Z. Kolter, V. Koltun, 《通用卷积网络与循环网络在序列建模中的实证评估》, *arXiv:1803.01271* (2018)。23. D. Chen, B. Zhou, V. Koltun, P. Krähenbühl, 《学习作弊》, 机器学习会议 (2019)。24. J. C. Brant, K. O. Stanley, 《最小准则协同演化: 一种开放式搜索的新方法》, 遗传与演化计算会议, 第67–74页 (2017)。25. R. Wang, J. Lehman, J. Clune, K. O. Stanley, 《配对开放式开拓者 (POET): 无限生成日益复杂多样的学习环境及其解决方案》, *arXiv:1901.01753* (2019)。26. C. D. Bellicoso, F. Jenelten, C. Gehring, M. Hutter, 《通过在线非线性运动优化实现四足机器人的动态运动》, *IEEE机器人与自动化快报* 第2261–2268页 (2018)。27. P. Fankhauser, M. Bloesch, C. Gehring, M. Hutter, R. Siegwart, 《基于机器人中心的高程地图构建与不确定性估计》, 移动服务机器人学 (World Scientific, 2014), 第433–440页。28. S. Collins, A. Ruina, R. Tedrake, M. Wisse, 《基于被动动态行走器的高效双足机器人》, 科学第1082–1085页 (2005)。29. Ghost Robotics, 《Vision 60: V60腿式机器人最新盲态压力测试》, www.youtube.com/watch?v=tQsLauQWp8M (2019)。30. J. Hwangbo, J. Lee, M. Hutter, 《求解接触动力学的逐接触迭代方法》, *IEEE机器人与自动化快报* 第895–902页 (2018)。31. E. Coumans等, 《Bullet物理引擎》, 开源: bulletphysics.org (2013)。32. R. Smith等, 《开放动力学引擎》, 开源: ode.org (2005)。33. R. M. Alexander, 动物运动原理 (普林斯顿大学出版社, 2003)。34. A. Iscen, K. Caluwaerts, J. Tan, T. Zhang, E. Coumans, V. Sindhwani, V. Vanhoucke, 《调制轨迹生成器的策略》, 机器学习会议, 第916–926页 (2018)。35. V. Barasuol, J. Buchli, C. Semini, M. Frigerio, E. R. De Pieri, D. G. Caldwell, 《面向挑战性地形的四足运动反应式控制器框架》, 2013年IEEE国际机器人与自动化大会, 第2554–2561页 (IEEE, 2013)。36. J. Schulman, S. Levine, P. Abbeel, M. Jordan, P. Moritz, 《信任区域策略优化》, 国际机器学习大会, 第1889–1897页 (2015)。37. M. Bloesch, M. Hutter, M. A. Hoepflinger, S. Leutenegger, C. Gehring, C. D. Remy, R. Siegwart, 《腿式机器人状态估计——腿部运动学与惯性测量单元的一致性融合》, 机器人学第17–24页 (2013)。38. S. Ross, G. Gordon, D. Bagnell, 《将模仿学习与结构化预测简化为无遗憾在线学习》, 国际人工智能与统计大会, 第627–635页 (2011)。39. C. Florensa, D. Held, X. Geng, P. Abbeel, 《强化学习智能体的自动目标生成》, 国际机器学习大会, 第1514–1523页 (2018)。40. J. Lehman, K. O. Stanley, 《修正演化计算抽象: 最小准则新颖性搜索》, 遗传与演化计算会议, 第103–110页 (2010)。41. T. Matisen, A. Oliver, T. Cohen, J. Schulman, 《师生课程学习》, *IEEE神经网络与学习系统汇刊* (2019)。42. W. Yu, G. Turk, C. K. Liu, 《学习对称低能耗运动》, *ACM图形学汇刊 (TOG)* 第144页 (2018)。43. I. Akkaya, M. Andrychowicz, M. Chociej, M. Litwin, B. McGrew, A. Petron, A. Paino, M. Plappert, G. Powell, R. Ribas等, 《用机器人手解魔方》, *arXiv:1910.07113* (2019)。44. R. O. Chavez-Garcia, J. Guzzi, L. M. Gambardella, A. Giusti, 《从仿真中学习地面可穿越性》, *IEEE机器人与自动化快报* 第1695–1702页 (2018)。45. A. Kendall, Y. Gal, 《贝叶斯深度学习用于计算机视觉需要哪些不确定性?》, 神经信息处理系统进展, 第5574–5584页 (2017)。46. K. Simonyan, A. Vedaldi, A. Zisserman, 《深入卷积网络: 可视化图像分类模型与显著性图》, *arXiv:1312.6034* (2013)。47. G. A. Pratt, M. M. Williamson, 串联弹性执行器, *IEEE/RSJ国际智能机器人与系统大会*, 399–406 (1995)。48. R. M. Smelik, K. J. De Kraker, T. Tutenel, R. Bidarra, S. A. Groenewegen, 地形建模的程序化方法综述, *CASA三维高级媒体在游戏与模拟中的研讨会论文集*, 25–34 (2009)。49. A. Lagae, S. Lefebvre, R. Cook, T. DeRose, G. Drettakis, D. S. Ebert, J. P. Lewis, K. Perlin, M. Zwicker, 程序化噪声函数综述, 计算机图形学论坛, 2579–2600 (Wiley在线图书馆, 2010)。50. J. Chung, C. Gulcehre, K. Cho, Y. Bengio, 门控循环神经网络在序列建模上的实证评估, *arXiv:1412.3555* (2014)。51. R. J. Williams, J. Peng, 循环网络轨迹在线训练的高效基于梯度的算法, 神经计算490–501 (1990)。52. D. P. Kingma, J. Ba, Adam: 一种随机优化方法, 国际学习表征会议 (2015)。

补充材料

S1. 术语表

$\hat{(\cdot)}$ 归一化向量 $\dot{(\cdot)}$ 一阶导数 $\ddot{(\cdot)}$ 教师的量 $(\cdot)_T$ 目标量 CABv B框架相对于A框架的线速度 $\dot{(\cdot)}$ 在C框架中表示 c_T 地形参数向量 ω 角速度 τ 关节扭矩 θ 关节角度 ψ 偏航角 ϕ 腿部相位 f 腿部频率 r_f 足的线性位置 e_s 重力向量 H 水平框架 g_i 第*i*个可能接触对的间隙函数 I_c 所有接触的索引集 $I_{c,body}$ 身体接触的索引集 $I_{c,foot}$ 足部接触的索引集 I_{swing} 摆腿的索引集 $|\cdot|$ 集合的基数或 l_1 范数 $\|\cdot\|$ l_2 范数

S2. 实现细节

RaiSim模拟器 [30] 用于刚体与接触动力学仿真。执行器网络 [12] 针对每个机器人进行训练，以模拟关节处的串联弹性执行器（SEA） [47]。执行器模型的输入是一个6维实值向量，包含当前时间步*t*的关节位置误差和速度，以及对应*t* - 0.01秒和*t* - 0.02秒的两个过去状态。特征选择按照 [12]中的方法进行。

多项研究表明，对动态属性进行随机化能够提升策略的鲁棒性 [12, 16]，因此我们也对若干物理量进行了随机化处理，并且教师策略在训练过程中可以获取这些值。我们在训练中施加了扰动，对足部与地形之间的摩擦系数进行了随机化，并在观测值中加入了加性噪声。

教师策略的训练过程如算法S1所示。超参数列于表S3中。在我们的地形课程实现中，我们每 $N_{evaluate}$ 次策略迭代更新一次课程，以降低方差。我们假设在 $N_{evaluate}$ 次迭代内，策略的性能是相似的。通过这种较慢的更新速率，公式6中的测量概率变为

$$\Pr(y_j^k | c_{T,j}^k) \approx \frac{\sum_{N_{evaluate}} \sum_{N_{traj}} \mathbb{1}(Tr(c_{T,j}^k, \pi) \in [0.5, 0.9])}{N_{traj} N_{evaluate}}. \quad (10)$$

此外，我们利用回放记忆来防止粒子滤波器退化，并避免灾难性遗忘。

控制器通过一个状态机实现，用于在“静止站立”状态和运动状态之间切换。当零指令持续0.5秒时，我们将基频 f_0 设置为零，这会停止FTGs，使机器人在地形上静止站立。当给出方向指令或为进行扰动抑制而使得基座线速度超过0.3米/秒时， f_0 被设置为1.25赫兹。该状态机包含在训练环境中。

在部署过程中，基础速度和朝向由状态估计器估算，该估计器依赖于惯性测量和腿部运动学 [37]。

神经网络策略以400赫兹的频率在集成于机器人的板载CPU（Intel i7-5600U，2.6–3.2GHz，双核64位）上运行。TensorFlow C++ API用于板载推理。

算法S1. 基于自动地形课程的教师训练

```

1: 初始化一个回放记忆，从 $N_{particle}$   $c_{T,0}$ 中均匀采样  $C(S2)$ ,  $i, j = 0$ .
2: 重复
3:   对于  $0 \leq k \leq N_{evaluate}$  执行
4:     对于  $0 \leq l \leq N_{particle}$  执行
5:       对于  $0 \leq m \leq N_{traj}$  执行
6:         使用  $c_{T,j}$  生成地形
7:         在随机位置初始化机器人
8:         运行策略  $\pi_i$ 
9:         计算每个状态转移的可遍历性标签
           状态转移（公式2）
10:        保存分数和轨迹
11:      使用 TRPO [36] 更新策略
12:       $i = i + 1$ 
13:    for  $0 \leq l \leq N_{particle}$  do
14:      计算每个的测量概率
        参数  $c_{T,j,s}$ （公式9）
15:    for  $0 \leq l \leq N_{particle}$  do
16:      更新权重  $w_j = \frac{P(y_i^l | c_{T,j})}{\sum_m P(y_i^m | c_{T,j})}$ 
17:    重采样  $N_{particle}$  参数
18:    将  $c_{T,j,s}$  追加到回放记忆
19:    for  $0 \leq l \leq N_{particle}$  do
20:      以  $p_{replay}$  概率，从回放记忆中采样
21:      以  $p_{transition}$  概率，将  $c_{T,j}$  移动至相邻值
        在  $C$  中。
22:     $j = j + 1$ 
23: 直到收敛

```

S3. 足端轨迹生成器

足部轨迹定义为

$$F(\phi_i) = \begin{cases} (h(-2k^3 + 3k^2) - 0.5)^{H_i} z & k \in [0, 1] \\ (h(2k^3 - 9k^2 + 12k - 4) - 0.5)^{H_i} z & k \in [1, 2] \\ -0.5^{H_i} z & \text{otherwise,} \end{cases} \quad (11)$$

其中 $k = 2(\phi_i - \pi)/\pi$ ， h 是最大足高的参数。摆动相中的每个分段 ($k \in [0, 2)$) 是一个三次埃尔米特样条，连接最高点和最低点，且在连接点处一阶导数为零。其他周期函数（如 $h_i \sin(\phi_i)$ ）也可用于FTG。通过一组命理调整的 ϕ_i ， $\phi_i = 0$ 到 2π 。

h 和 ϕ_i ，四足机器人可以稳定地原地踏步。在我们的设置中， f, h, m 和 $U(\cdot)$ 中采样。

S4. 教师策略训练的奖励函数

奖励函数定义为 $0.01 r_{pr} + 0.02 r_{bc} + 0.025 r_s + 2 \cdot 10^{-5} r_{\tau} + 0.05 r_{lv} + 0.05 r_{av} + 0.04 r_b + \dots$ 。各项定义如下。

• 线速度奖励 (r_{lv})：该项最大化 $v_{pr} = (BIBv)_{xy} \cdot (BIB^T v_T)_{xy}$ ，即基座线速度在指令方向上的投影。

$$r_{lv} := \begin{cases} \exp(-2.0(v_{pr} - 0.6)^2) & v_{pr} < 0.6 \\ 1.0 & v_{pr} \geq 0.6 \\ 0.0 & \text{zero command} \end{cases} \quad (12)$$

速度阈值定义为0.6米/秒，这是现有控制器在平坦地形上能达到的最大速度 [26]。

- 角速度奖励 (r_{av}): 当沿基座 z 轴的 $(BIB \hat{\omega}_T)_z$ 非零时，我们激励智能体尽可能快地转动。其定义为

$$r_{av} := \begin{cases} \exp(-1.5(\omega_{pr} - 0.6)^2) & \omega_{pr} < 0.6 \\ 1.0 & \omega_{pr} \geq 0.6 \end{cases} \quad (13)$$

其中 $\omega_{pr} = (BIB \omega)_z \cdot (BIB \hat{\omega}_T)_z$ 。

- 基座运动奖励 (r_b): 该项惩罚与目标方向正交的速度以及横滚和俯仰角速率，以确保基座在运动过程中保持稳定。

$$r_b := \exp(-1.5v_o^2) + \exp(-1.5\|(BIB \omega)_{xy}\|^2) \quad (14)$$

其中 $v_o = \|(BIB v)_{xy} - v_{pr} \cdot (BIB \hat{v}_T)_{xy}\|$ 。当给出停止指令时， v_o 被替换为 $\|(BIB v)\|$ 。

- 足部离地奖励 (r_{fc}): 当腿部处于摆动相时，即 $\phi_i \in [\pi, 2\pi)$ ，机器人应将相应足部抬升高于周围环境以避免碰撞。我们首先将此类无碰撞足集合定义为 $\mathcal{F}_{clear} = \{i: r_{f,i} > \max(H_{scan,i}), i \in I_{swing}\}$ ，其中 $H_{scan,i}$ 是第 i 个足部周围的扫描高度集合。则离地代价定义为

$$r_{fc} := \sum_{i \in I_{swing}} (\mathbb{1}_{\mathcal{F}_{clear}}(i) / |I_{swing}|) \in [0.0, 1.0]. \quad (15)$$

- 身体碰撞奖励 (r_{bc}): 我们希望惩罚机器人身体部位与地形之间的不良接触，以避免硬件损坏。

$$r_{bc} := -|I_{c,body} \setminus I_{c,foot}|. \quad (16)$$

- 目标平滑度奖励 (r_s): 对目标足部位置的二阶有限差分导数的幅度进行惩罚，以使生成的足部轨迹更加平滑。

$$r_s := -\|(r_{f,d})_t - 2(r_{f,d})_{t-1} + (r_{f,d})_{t-2}\|. \quad (17)$$

- 扭矩奖励 (r_τ): 我们惩罚关节扭矩，以防止在部署过程中损坏关节执行器，并降低能耗 ($\tau \propto$ 电流)。

$$r_\tau := -\sum_{i \in joints} |\tau_i|. \quad (18)$$

S5. 参数化地形

生成能够呈现足部打滑和足部卡陷等代表性挑战的训练环境至关重要。为了高效地合成随机地形，我们使用了程序化生成技术 [48]。该方法允许我们通过改变一组地形参数 $c_T \in \mathcal{C}$ 来生成大量不同的地形。下文将描述本工作中使用的三种地形生成器。地形可视化效果见图4B，参数空间 $\mathcal{C}$ 的定义见表S2。

- 丘陵地形基于Perlin噪声 [49]。该地形通过三个参数生成：粗糙度、Perlin噪声的频率以及Perlin噪声的振幅。输出高度图 hm 中每个元素的高度定义为 $hm[i, j] := \text{Perlin}(c_{T,2}, c_{T,3})[i, j] + U(-c_{T,1}, c_{T,1})$ 。在此地形上训练时，策略会经历平滑斜坡和足部打滑。

- 台阶地形由高度随机的方形台阶组成。对于每个 $c_{T,1}$ 乘 $c_{T,1}$ 的区块，其高度从 $U(0, c_{T,2})$ 中采样。在此地形上，策略会经历离散的高度变化和足部卡陷。

- 楼梯地形是一种宽度和高度固定的阶梯。机器人初始位于楼梯中部的平坦段（见图4B）。

参数范围的设定考虑了机器人的运动学特性，例如台阶高度应低于腿长。在训练过程中，每个回合都会使用不同的随机种子重新生成地形。

S6. 自适应地形课程的定性评估

自适应课程的行为如图S1所示。图S1A-C聚焦于丘陵地形类型。该地形有三个参数：粗糙度、频率和振幅。可穿越性（公式3）与期望度（公式4）之间的关系如图S1A-B所示。不期望的地形要么过于简单，要么过于困难，如图S1A最左侧和最右侧面板所示。图S1B-C显示，粒子滤波器拟合了期望地形的潜在分布，该分布在频率-振幅边缘分布（中间）中呈现弓形。图S1D聚焦于楼梯地形类型，展示了训练过程中地形参数的演化。粒子滤波器拒绝了代表短而陡台阶的参数（左上区域）。课程最初侧重于宽而浅的台阶（中间面板，特别是第50-60次迭代），随后将分布扩展到包含更窄的台阶（最右侧面板）。

S7. 不同情境下特权信息的重建

在图S2中，我们展示了不同情境下解码得到的特权信息。图S2A显示了在穿越湿滑白板时足部与地形之间的估计摩擦系数，如电影S5所示。当第一只足开始打滑时 (i)，估计值立即下降，在整个穿越过程中保持较低水平 (ii)，并在机器人返回正常地面约2秒后上升 (iii)。外部扰动和地形信息也可以从TCN嵌入中重建。如图S2B所示，当施加未知的10kg负载时，解码器检测到向下的外力。在穿越如图S2C所示的茂密植被时，它检测到与运动方向相反的力，这促使策略进行反推并穿过植被。在图S2C和图S2D所示的自然地形中，高程估计的不确定性显著较高，这表明TCN策略编码了地形的粗糙度。

S8. 循环神经网络学生策略

我们对本体感受策略 [22] 采用了TCN架构。作为对比，我们还评估了一种带有门控循环单元 (GRU) 的循环网络 [50]。相关架构在表格S5和S6中进行了详细说明。训练GRU学生策略的损失函数定义如下：

$$\mathcal{L} := (\bar{a}_t(o_t, x_t) - a_t(o_t))^2 + (\bar{l}_t(o_t, x_t) - l_t(o_t))^2. \quad (19)$$

为了提升训练的性能与计算效率，我们实现了截断式时间反向传播 (Truncated BPTT) [51]。

图S3展示了在图5A所示诊断设置上的性能表现。总体而言，基于GRU的控制器性能介于TCN-20与TCN-100之间。在斜坡设置中，其性能与TCN-100相当，但在台阶实验中，基于GRU的控制器未能达到TCN-100的性能水平。

TCN的主要优势在于训练效率。与GRU相比，TCN的训练时间要快得多。计算时间报告于表格S1中。


S9. 学生训练中潜在表示损失的消融实验

我们检验了公式1中学生策略训练损失函数中第二项的影响，该项是潜在向量 l_t 的平方误差损失。作为基线，我们使用以下损失函数训练学生策略：


$$\mathcal{L} := (\bar{a}_t(o_t, x_t) - a_t(o_t, H))^2, \quad (20)$$

该函数仅模仿教师的输出。


结果如图S3中‘TCN-100朴素模仿学习’所示。在均匀斜坡设置和外部干扰下，性能相当。另一方面，消融版本在台阶上的成功率较低。



图S1. 自适应课程示意图。(A) 丘陵地形的示例。色标表示期望度；深蓝色代表低期望度。(B) 根据完全训练好的教师策略生成的1000条轨迹估算的地形期望度。红色十字标记对应A中展示的示例。(C) 在教师训练的最后100次迭代中，由粒子滤波器采样的地形剖面分布。(D) 训练过程中楼梯地形参数的演化。



图S2. 不同情境下重建的特权信息。(A) 穿越湿白板时足部与地形之间的估计摩擦系数。阴影区域表示95%置信区间。(B-D) 不同场景下外部扰动与地形信息的重建。蓝色箭头：施加于躯干的估计外力。红色椭球体：足部周围的地形形状估计。椭球体中心表示估计的地形高程，垂直长度代表不确定性（1个标准差）。每只足部周围沿半径为10厘米的圆对称放置8个椭球体。黑色箭头：接触足处的地形法线。



图S3. 本体感受控制器的神经网络架构比较。我们使用不同的随机种子对每个模型进行了5次训练。误差条表示95%置信区间。'TCN-100朴素模仿学习'指使用朴素模仿学习方法（不含潜在表示损失，即公式19）训练的TCN-100网络。

Name	Time
教师策略训练	≈ 12小时
学生策略训练	≈ 4小时
自适应地形课程	2.9秒

表S1. 训练的计算时间

训练。学生策略采用TCN-100架构。训练在一台配备i7-8700K CPU和Geforce RTX 2080 GPU的台式机上进行。

p

地形	网格尺寸	摩擦系数	参数 (c_T)	范围
丘陵	0.2 米	$\mathcal{N}(0.7, 0.2)$	粗糙度 (米) 频率 振幅 (m)	[0.0, 0.05] [0.2, 1.0] [0.2, 3.0]
<i>Slippery Hills</i>	0.2 m	$\mathcal{N}(0.3, 0.1)$	粗糙度 (m) 频率 振幅 (m)	[0.0, 0.05] [0.2, 1.0] [0.2, 3.0]
台阶	0.02 米	$\mathcal{N}(0.7, 0.2)$	步宽 (米) 台阶高度 (米)	[0.1, 0.5] [0.05, 0.3]
楼梯	0.02 米	$\mathcal{N}(0.7, 0.2)$	步宽 (米) 台阶高度 (米)	[0.1, 0.5] [0.02, 0.2]

表S2. 参数空间 C 用于模拟地形。

$\mathcal{N}$ (均值, 标准差) 表示该值从均值为均值、标准差为标准差的高斯分布中采样。摩擦系数被裁剪至不低于0.1。

参数	数值
粒子数量 ($N_{particle}$)	每种地形类型10个
转移概率 ($p_{transition}$)	0.8
每条粒子的轨迹数 (N_{traj})	6
地形参数更新率 ($N_{evaluate}$)	10
从回放记忆采样的概率 ($Preplay$)	0.05

表S3. 自动地形课程的超参数。

Data	维度	x_t	o_t	h_t
期望方向 ($((I_B^B \hat{v}_d)^{xy})$)	2		✓	✓
期望转向方向 ($((I_B^B \hat{\omega}_d)z)$)	1		✓	✓
重力向量 (eg)	3		✓	✓
基座角速度 ($(I_B^B \omega)$)	3		✓	✓
基座线速度 ($(I_B^B v)$)	3		✓	✓
关节位置/速度 ($\theta_i, \dot{\theta}_i$)	24		✓	✓
FTG相位 ($\sin(\phi_i), \cos(\phi_i)$)	8		✓	✓
FTG频率 ($\dot{\phi}_i$)	4		✓	✓
基频 (f_0)	1		✓	
关节位置误差历史	24		✓	
关节速度历史	24		✓	
足部目标历史 ($((r_{f,d})_{t-1,t-2})$)	24		✓	
各足地形法线	12	✓		
各足周围高度扫描	36	✓		
足部接触力	4	✓		
足部接触状态	4	✓		
大腿接触状态	4	✓		
小腿接触状态	4	✓		
足地摩擦系数	4	✓		
施加于基座的外力	3	✓		

表格 S4. 本体感受控制器的状态表示（上）与特权信息（下）

层	教师		TCN-N学生		GRU学生		解码器
输入	o_t	x_t	o_t	h (60×N)	o_t	o_t	$\langle o_t, l_t \rangle$
1	id	双曲正切函数(72)	id	1D卷积 膨胀 1	id	GRU(68)	relu(196)
2	id	双曲正切函数(64)	id	一维卷积步长2	拼接		输出
3	拼接		id	一维卷积膨胀2	双曲正切函数(256)*		-
4	双曲正切函数(256)*		id	一维卷积步长2	双曲正切函数(128)*		-
5	双曲正切函数(128)*		id	一维卷积膨胀4	双曲正切函数(64)*		-
6	双曲正切函数(64)*		id	一维卷积步长2	输出*		-
7	输出*		id	双曲正切函数(64)	-		-
8	-		拼接		-		-
9	-		双曲正切函数(256)*		-		-
10	-		双曲正切函数(128)*		-		-
11	-		双曲正切函数(64)*		-		-
12	-		输出*		-		-

表S5. 神经网络架构。除非另有说明，卷积层的膨胀和步长均为1。滤波器大小固定为5。标记有 * 的层在教师训练后从教师复制到学生网络。恒等映射指的是恒等映射。TCN-N架构使用膨胀因果卷积 [22]。每个卷积层后都接一个ReLU激活函数。

模型	序列长度	通道数	参数量	随机梯度下降时间 (秒)
TCN-1	1	60	161960	9.22e-3 ($\pm 1.78e-3$)
TCN-20	20	44	158300	2.11e-2 ($\pm 1.24e-3$)
TCN-100	100	34	158070	5.07e-2 ($\pm 1.94e-3$)
GRU	100*	-	159640	1.52e-1 ($\pm 1.89e-2$)

表S6. 学生策略的网络参数设置与训练时间。随机梯度下降时间指在表S8给定的批量大小下，执行一次随机梯度下降更新所需的计算时间。计算时间以经验均值±标准差的形式呈现。*GRU网络的序列长度指用于截断BPTT的序列长度 [51]。

参数	数值
折扣因子	0.995
KL散度阈值	0.01
最大回合长度	400
共轭梯度阻尼	1e-1
共轭梯度迭代	50
折扣因子	0.995
批量大小	80000
总迭代次数	10000

表S7. 教师策略训练的超参数。

参数	TCN-N	GRU
初始学习率	5e-4	2e-4
学习率衰减	exp(0.995, 100)	
最大回合长度	400	
批量大小	20000	10000
小批次	5	
轮次	4	
总迭代次数	4000	

表S8. 学生策略训练的超参数。exp(a,b) 表示指数衰减，其定义为 $lr_0 * a^{updates/b}$ 。使用 Adam [52] 优化器。

参数	数值
初始学习率	1e-4
学习率衰减	exp(0.99, 100)
批量大小	20000
小批次	2
轮次	10
总迭代次数	1000
权重衰减	$l2$ -范数, 1e-4

表S9. 解码器训练的超参数。exp(a,b)表示指数衰减，其定义为学习率₀ * $a^{updates/b}$ 。Adam [52] 优化器被使用。