

通过强化学习实现鲁棒且多功能的双足跳跃控制

Zhongyu Li¹, Xue Bin Peng², Pieter Abbeel¹, Sergey Levine¹, Glen Berseth^{3,4}和Koushil Sreenath¹加州大学伯克利分校, ²西蒙菲莎大学, ³蒙特利尔大学, ⁴Mila 邮箱: zhongyu.li@berkeley.edu, xbpeng@sfu.ca, pabbeel@cs.berkeley.edu, svlevine@eecs.berkeley.edu, glen.berseth@mila.quebec, koushils@berkeley.edu




图1: 双足机器人Cassie使用所提出的目标条件化控制策略执行的典型动态跳跃动作。从左至右: (a) 机器人跳过1.4米并降落在指定目标处; (b) 机器人跳跃至机器人前方0.88米、地面以上0.44米的目标位置; (c) 机器人原地跳跃并转向 55° , 同时接收原地转向指令 60° 。这些策略在仿真中训练并直接部署到硬件上, 无需进一步调整。视频地址: <https://youtu.be/aAPSZ2QFB-E>。

摘要——本文旨在通过使一个受控的双足机器人能够在真实世界中执行鲁棒且多变的动态跳跃, 从而突破双足机器人的敏捷性极限。我们提出了一种强化学习框架, 用于训练机器人完成多种跳跃任务, 例如跳向不同位置和方向。为了提升这些具有挑战性任务的性能, 我们开发了一种新的策略结构, 该结构编码了机器人的长期输入/输出历史, 同时提供对短期输入/输出历史的直接访问。为了训练一个多功能的跳跃策略, 我们采用了一种多阶段训练方案, 该方案针对不同目标包含不同的训练阶段。经过多阶段训练后, 该策略可直接迁移到真实的双足Cassie机器人上。在不同任务上的训练以及探索更多样化的场景, 能够产生高度鲁棒的策略, 这些策略可以利用所学的多样化机动动作, 在实际部署中从扰动或不良着陆中恢复。所提策略的这种鲁棒性使得Cassie能够在真实世界中成功完成各种具有挑战性的跳跃任务, 例如立定跳远、跳上高台以及多轴跳跃。

I. 引言

自双足机器人诞生之初, 一个挥之不去的问题便是: 我们如何让这类复杂的机器人通过敏捷且稳健的动作 [23, 53] 穿越复杂环境? 例如, 创建能够使双足机器人跳跃特定距离或到达不同高度的敏捷控制器, 可以显著提升其在非结构化环境中的机动性。然而, 跳跃是一项对双足机器人而言极具挑战性的控制技能。在立定跳远过程中, 机器人需要将身体推离地面并脱离接触, 跃入一个欠驱动飞行阶段, 然后在双腿着陆时重新建立接触。在

着陆时, 机器人不仅要承受巨大的冲击冲量, 还必须稳定着陆并保持站立。所有这些事件都发生在极短的时间内 (通常不到2秒)。这些事件导致了一个混合系统, 该系统在不同接触构型的模式之间切换 (例如, 起飞、飞行和着陆阶段)。规划并控制这种不连续的动力学特性, 尤其是对于高维度、非线性且欠驱动的双足机器人而言, 是一项极具挑战性的任务 [52]。当机器人需要精确着陆在给定目标上时, 这一挑战会进一步加剧, 因为机器人必须在起飞时产生精确的平移和角动量, 才能降落在目标位置 [73]。

基于模型的最优控制框架在控制双足机器人 (包括跳跃) 方面取得了显著进展, 但它们依赖于精心构建的机器人模型和复杂的接触动力学 [30, 39, 57]。这些方法通常需要手动设计任务特定控制结构 [9, 20, 76], 和简化动力学模型, 这只能粗略近似机器人的全阶动力学。此外, 通常需要预定义或预计算的接触序列来降低在线优化复杂度

[46, 47, 71]。这些局限性使得以往基于模型的方法只能让像Cassie这样的力矩控制双足机器人执行固定的跳跃 [71, 72]。通过利用机器人的全阶动力学, 无模型强化学习在四足机器人的高动态运动控制方面已展现出一定成功 [26, 42, 49]。然而, 与天生

表I: 与先前在真实世界中针对双足机器人Cassie使用最优控制 (OC) 或强化学习 (RL) 进行跳跃控制的研究工作的基准测试。

	受控 着陆姿态	Apex 足部离地高度	最长 飞行阶段	最大跳跃距离				
				向前	向后	横向	转向	抬升
OC [71] 的非周期跳跃	No	0.18米	0.42秒	~0.5米*	0m	0m	0°	0m
OC [72] 的非周期跳跃	No	0.15米	0.33秒*	~0.3米*	0m	0m	0°	0m
基于强化学习的周期性跳跃 [60]	No	~0.16米*	0.33秒*	~0.5米*	0m	0m	0°	~0.15米*
我们的 (基于强化学习的非周期性跳跃)	Yes	0.47米	0.58秒	1.4m	-0.3米	±0.3米	±55°	0.44米

*论文中未提供该数值，所列数值是基于与附带视频中背景环境的对比粗略估算得出。

更稳定的四足机器人相比，基于强化学习的方法在应用于双足机器人以在真实世界中执行更具动态性和激进性的动作时仍然面临困难。鉴于最相关的先前基于强化学习的系统仅能让Cassie执行周期性跳跃 [60]，如何在真实世界中实现更具动态性的双足技能（例如可能比周期性运动更具挑战性的立定跳远）仍是一个悬而未决的问题 [20, 。第I节]。

A. 本文目标

本文旨在探索为双足机器人构建一个鲁棒且多功能的跳跃控制器的可能性，使其能够着陆于不同的目标位置（如图1所示），并通过强化学习验证不同机动动作学习所带来的优势。我们将技能定义为一种腿部运动方式，例如行走、跳跃或奔跑。我们进一步将任务定义为运用某种运动技能来实现一个目标。例如，一个任务可以是以期望速度行走（技能）的任务（目标），或者如本文所述，实现跳跃（技能）至目标构型（目标）的任务。我们使用术语目标条件化来指代一种能够根据给定目标执行多种跳跃任务（例如跳过各种期望距离和/或方向）的策略。我们假设，通过探索不同的跳跃任务，一个多功能的跳跃控制器可以更加鲁棒，因为它允许机器人利用更多样化的已学任务来在动态机动过程中保持稳定性。例如，为了从着陆时巨大的地面冲击中恢复，机器人可以快速切换到另一个已学任务，例如跳跃到不同位置，这比简单地继续执行原始行为能够实现更平稳的恢复。

B. 贡献

本工作的核心贡献在于开发了首个系统，使真实世界中具备全尺寸力矩控制的双足机器人能够执行具有受控着陆位置的多功能跳跃动作。该机器人首先在仿真环境中通过强化学习和域随机化进行训练。训练过程无需显式指定接触序列，学习算法会自动针对不同跳跃目标发展出相应的接触序列。为了成功将此类动态动作的学习技能从仿真迁移至真实世界，我们采用了两个新的设计决策。首先，我们提出了一种新的策略结构，该结构在编码机器人长期输入输出历史的同时，也提供对短期输入输出历史的直接访问。通过以端到端方式训练模型，我们

证明了此类结构能够超越先前提出的架构（图5）。其次，我们证明，通过针对多样化目标范围训练控制器，利用从不同跳跃任务中习得的动作从不稳定状态中恢复，能够提升控制器的鲁棒性。我们表明，仅针对单一跳跃目标进行训练难以轻易获得这种鲁棒性（图6）。结合这两种技术，我们使双足Cassie机器人在真实世界中能够：

（1）执行多次激进跳跃，例如跳远（向前1.4米）和跳高至0.44米高的平台（图1）；（2）完成多种敏捷的多轴双足跳跃（图7、图9）；（3）利用多样化的习得跳跃动作从外部扰动或冲击中恢复（图9）。我们希望本文能成为推动更丰富、更动态、更鲁棒的腿部运动技能发展的一个步骤。

II. 相关工作

先前针对跳跃等动态运动技能的研究，可大致分为基于模型的最优控制和基于模型的强化学习两类。表I将我们的工作与双足机器人Cassie上最相关的先前研究进行了比较。

1) 基于模型的最优控制在腿式跳跃中的应用：先前基于模型的腿式跳跃控制方法通常构建一个分层优化方案，该方案包括利用机器人动力学和地面接触的详细模型进行离线轨迹优化 [10, 12, 46, 63]，以及利用机器人动力学简化模型的在线控制器 [45, 55, 65, 72]。为了优化需要在不同动力学模式间切换的跳跃轨迹，通常有两种常用解决方案：(i) 依赖人工指定的接触序列 [9, 19, 29, 47, 71]，这种方法难以扩展到不同的跳跃距离和/或方向；或(ii) 利用接触隐式优化 [8, 14, 33, 52, 77]，通过接触进行规划，以避免轨迹中断或使用计算成本高昂的混合整数规划

[1, 11, 12]。然而，由于优化带来的计算挑战，上述两种方法在腿式机器人上仍局限于离线计算。正如我们在本工作中所示，通过针对不同跳跃目标进行离线训练，Cassie能够在在线执行过程中自动生成合适的接触序列，以实现稳健的跳跃。

在非周期动态跳跃的控制方法中，许多先前的工作需要单独的着陆控制器来稳定机器人，使其免受巨大着陆冲击的影响 [20, 25, 46, 71]。然而，这种方法通常需要接触估计器，并需要融合嘈杂的机器人本体感觉测量数据

来估计接触状态，这本身可能就是一个具有挑战性的问题 [22, 38, 51]。此外，尽管有一些先前的尝试针对低维度的单腿机器人 [66, 73]和四足机器人 [45]，（主要在仿真中 [45, 66]，）实现了精确的跳跃控制，但大多数关于双足跳跃的先前工作仅关注着陆位置不受控制的单次垂直跳跃 [20, 65, 71, 72]。在这项工作中，所提出的跳跃控制器展示了在没有位置反馈或显式接触估计的情况下控制双足机器人着陆姿态的能力。

2) 无模型强化学习在腿式运动控制中的应用：近年来，我们见证了利用深度强化学习在真实世界中为四足机器人 [5, 16, 34, 40]和双足机器人 [7, 37, 54, 59, 70, 75]学习运动控制器的激动人心的进展。由于通常很难通过强化学习训练一个单一策略来执行各种任务 [28]，许多先前的工作专注于为腿式机器人学习单目标策略 [6, 42, 49, 74]，例如仅以恒定速度向前行走 [16, 31, 69]。已有一些努力旨在获得更通用的策略，例如以不同步态、不同速度行走，同时遵循不同指令 [17, 18, 35, 54]，但由于缺乏步态先验，这需要更广泛的调参。为机器人提供针对不同目标的不同参考运动可能有所帮助，但需要对参考运动进行额外的参数化（例如，步态库） [3, 24, 27, 37]，策略蒸馏 [70]，或运动先验 [15, 50, 67]。还有一系列研究致力于为腿式机器人显式提供接触序列 [4, 41, 58, 60]。然而，此类方法具有规定性，几乎没有给机器人偏离接触计划的机会，限制了其应对扰动的灵活性。在这项工作中，我们展示了一种多功能策略能够通过智能地利用各种已学任务来应对扰动，从而增强跳跃策略的鲁棒性。

3) 腿式机器人的仿真到现实迁移：为了解决基于强化学习方法的仿真到现实迁移问题，一些工作尝试直接在真实世界中训练策略 [21, 62, 68]，但大多数先前的工作，特别是针对动态技能的研究，利用仿真器通过广泛的动力学随机化来训练腿式机器人 [48]，然后零样本迁移到真实世界 [16, 31, 34, 37, 60] 或使用真实世界数据进行微调 [27, 49, 61]。由于在人形尺度双足机器人的硬件上进行 rollout 成本高昂，我们采用了零样本迁移方法。为实现这一目标，有两种广泛采用的技术：(i) 通过向机器人提供本体感受的短期历史 [16, 24, 37] 或长期历史 [48, 58, 59] 进行端到端策略训练；(ii) 师生训练，首先通过强化学习利用环境的特权信息获得教师策略，然后使用该策略监督仅能访问机载可用观测的学生策略的训练 [18, 26, 31, 34, 40, 75]，这显示出优于端到端训练方法的优势 [31, 32]。然而，我们在此表明，对于双足机器人的动态控制，通过使用新提出的策略结构以端到端方式训练机器人，我们可以实现比

师生方法更好的学习性能，后者将训练过程分离，导致训练时间和数据增加。

III. 背景与预备知识

在本节中，我们将简要介绍实验平台 Cassie 以及目标条件强化学习的背景知识。

A. Cassie 的浮动基座模型

本研究使用 Cassie 作为实验平台。Cassie（见图1）是一款真人大小的双足机器人，高约1.1米，重31公斤。它是一个动态欠驱动系统，每条腿上有5个驱动电机（外展 q_1 、旋转 q_2 、大腿 q_3 、膝盖 q_4 和脚趾 q_7 ）以及2个由板簧连接的被动关节（小腿 q_5 和跗骨 q_6 ）。我们将电机位置记为 $\mathbf{q}$

$\mathbf{m} = [q_{1,2,3,4,7}] \in \mathbb{R}^{10}$ 。浮动基座（骨盆）的自由度可以用平移位置（矢状 q_x 、横向 q_y 、垂直 q_z ）和旋转位置（横滚 q_ψ 、俯仰 q_θ 、偏航 q_ϕ ）来表示。机器人总共有20个自由度 $\mathbf{q} \in \mathbb{R}^{20}$ 。关于 Cassie 配置的更多细节，请读者参阅 [71, 图 2]。Cassie 上可观测的关节位置记为 $\mathbf{q}^o = [q_\psi, \theta, \phi, \mathbf{q}_m, \dot{q}_{x,y,z}, \dot{\mathbf{q}}_m] \in \mathbb{R}^{26}$ ，这些数据可通过机载关节编码器和惯性测量单元获取，而基座线速度 $\dot{q}_{x,y,z}$ 则可通过扩展卡尔曼滤波器 [70] 进行估计。

B. 强化学习背景与目标条件策略

我们将运动控制问题建模为马尔可夫决策过程。在每个时间步 t ，智能体（即，机器人）观察环境状态 $\mathbf{s}_t$ ，策略 π 基于状态生成动作上的分布 $\pi(\mathbf{a}_t | \mathbf{s}_t)$ 。随后，智能体执行从策略中采样的动作 $\mathbf{a}_t$ ，与环境交互，观测环境的新状态 $\mathbf{s}_{t+1}$ ，并接收奖励 r_{t+1} 。强化学习的目标是最大化智能体在一个回合 $\mathbb{E}[\sum_{t=0}^T \gamma^t r_t]$ 内获得的期望累积奖励（回报），其中 γ 是折扣因子， T 是回合长度。为了获得能够完成不同目标的策略，我们提供一个目标 $\mathbf{c}$ 来参数化任务，策略 $\pi(\mathbf{a}_t | \mathbf{s}_t, \mathbf{c})$ 随后也基于给定目标 $\mathbf{c}$ 进行条件化，以执行不同的任务。

任务参数化：在我们的跳跃任务中，目标 $\mathbf{c}$ 指定了期望跳跃的目标指令 $\mathbf{c} = [c_x, c_y, c_z, c_\phi]$ ，该指令包含水平面上的目标位置 $c_{x,y}$ 、垂直方向上的抬升 c_z ，以及智能体落地后的转向方向 c_ϕ ，这些均基于机器人跳跃前的姿态计算，即，在机器人起始姿态的局部坐标系中。请注意，抬升 c_z 的变化定义为地面高度的变化，而非机器人基座高度的变化。

IV. 多功能跳跃的多阶段训练

我们现在描述用于开发目标条件跳跃策略的多阶段训练框架。训练环境是在使用 MuJoCo [13, 64] 的 Cassie 仿真中开发的。




图2: 训练机器人在真实世界中执行多样化跳跃技能的示意图, 从单个跳跃动画的参考运动开始。该框架包含三个阶段。在第一阶段, 我们专注于训练机器人从零开始模仿动画并执行单跳。当机器人能够熟练完成单目标后, 我们在每个训练回合中随机化分配给机器人的目标 (使其降落在不同位置以及不同的转向方向/抬升高度)。经过这两个阶段的训练后, 我们广泛随机化仿真环境中的动力学属性, 以提升机器人在从仿真到实际的零样本迁移过程中的鲁棒性。

A. 多阶段训练示意图概述

我们的目标是开发一种用于跳跃技能的运动控制策略, 使其能够执行针对不同位置的目标跳跃。然而, 由于跳跃本身具有挑战性, 直接训练一个策略从零开始执行多种跳跃可能很困难。我们观察到, 从零开始训练策略以执行多种跳跃往往会导致机器人采取非常保守的行为, 甚至无法学会跳跃。因此, 我们采用了一种包含3个阶段的多阶段训练方案, 如图2所示: (1) 单目标训练, (2) 多目标训练, 以及(3) 动力学随机化。所有阶段的训练均在仿真中进行, 但正如我们在实验中所展示的, 最终得到的模型可以直接部署在实际的Cassie机器人上。在第一阶段, 模型针对单个目标 $\mathbf{c}$ 进行训练, 即原地跳跃。此阶段的训练结果是一个从零开始训练、专门用于仿真中单一任务的策略。接下来, 在阶段2, 每个回合的目标 $\mathbf{c}$ 被随机化, 以训练机器人跳跃到不同的目标位置。在此阶段, 重点主要是在仿真环境中执行指定的任务。最后, 在阶段3, 我们在仿真环境中引入广泛的域随机化, 同时随机化目标, 以提高策略的鲁棒性和泛化能力, 从而实现仿真到现实的迁移。在每个阶段, 马尔可夫决策过程的奖励和回合设计可能会有所不同, 以便为给定阶段的目标产生更有效的策略。

在本节剩余部分, 我们将重点解释训练中阶段2和阶段3的细节, 这两个阶段共享相同的奖励和回合设计, 并涵盖多目标训练和域随机化。阶段1训练在超参数选择上有所不同, 详见附录A。

B. 参考运动

为了初始化训练过程, 我们提供了一个单一跳跃参考运动。该参考运动是一个由人类创作的

表II: 奖励 r_t 的组件列表, 该奖励是所列各项的加权求和。每个项的权重根据跳跃阶段和训练阶段进行调度。

奖励组件 $\mathbf{r}$	权重 $\mathbf{w}$			
	第一阶段		阶段2、3	
	$t \leq T_J$	$t > T_J$	$t \leq T_J$	$t > T_J$
参考运动跟踪				
运动位置: $r(\mathbf{q}_m, \mathbf{q}_m^r(t))$	15	15	7.5	15
骨盆高度: $r(q_z, q_z^r(t) + c_z)$	5	5	3	3
脚部高度: $r(e_z, e_z^r(t) + c_z)$	10	10	10	10
任务完成				
骨盆位置: $r(q_x, y, c_x, y)$	12.5	12.5	15	15
骨盆速度: $r(\dot{q}_x, y, \dot{q}_x^d, y)$	0	3	12.5	12.5
朝向: $r(q_\psi, \theta, \phi, [0, 0, c_\phi])$	12.5	12.5	10	10
角速率: $r(\dot{q}_\psi, \theta, \phi, [0, 0, \dot{q}_\phi^d])$	3	3	10	10
平滑				
地面冲击: $r(F_z, 0)$	5	0	10	0
扭矩消耗: $r(\tau, 0)$	3	3	3	15
电机速度: $r(\dot{\mathbf{q}}_m, 0)$	0	15	0	25
关节加速度: $r(\ddot{\mathbf{q}}, 0)$	3	10	0	5
动作变化: $r(\mathbf{a}_t, \mathbf{a}_t + 1)$	0	0	10	10

Cassie原地跳跃动画, 在3D创作套件 [36], 中创建, 如图2所示。该动画跳跃的最高点足部高度为0.5米, 最高点骨盆高度为1.1米, 时间跨度为 T_J 1.66秒 (即, $T_J = 1.66$)。该参考运动仅是一个对智能体而言运动学可行的运动, 并未优化为动力学可行。在跳跃动画结束后, 参考运动将设置为机器人的固定站立姿态。

C. 奖励

奖励函数的设计对于鼓励机器人敏捷跳跃至关重要。我们进一步将一个阶段内的奖励分为两个阶段: 着陆前 ($t \leq T_J$) 和着陆后 ($t > T_J$), 并且奖励需要根据这些阶段而变化, 因为期望的机器人行为不同: 执行激进跳跃与静止站立。

我们在此定义一个函数:

$$r(u, v) = \exp(-\alpha \|u - v\|_2^2) \quad (1)$$

其中 $r(u, v) \in (0, 1]$ 定义了一个奖励组件, 用于鼓励两个向量 u 和 v 尽可能接近, 并通过 $\alpha > 0$ 来平衡各单位的尺度。智能体在每个时间步获得的奖励 r_t 是不同组件的加权求和, 即 $r_t = (\mathbf{w} / \|\mathbf{w}\|_1)^T \mathbf{r} \in [0, 1]$ 。分量向量 $\mathbf{r}$ 和权重向量 $\mathbf{w}$ 详见表II。此处使用的奖励包含三个主要组件: 参考运动跟踪、任务完成和平滑项。

智能体被鼓励通过 $r(\mathbf{q}_m, \mathbf{q}_m^r(t))$ 跟踪参考电机位置, 通过 $r(q_z, q_z^r(t) + c_z)$ 跟踪骨盆高度, 以及通过 $r(e_z, e_z^r(t) + c_z)$ 跟踪当前时间步 t 的脚部高度。然而, 如表II所示, 在多目标训练期间, 参考运动跟踪项的权重相对较小, 因为我们希望智能体能够推断出多样化的动作, 例如跳跃到不同位置, 而原地跳跃参考运动可能不再合理。

相反, 任务完成奖励旨在多目标训练中主导其他奖励。我们首先引入 $r(q_x, y, c_x, y)$ 和 $r(q_\psi, \theta, \phi, [0, 0, c_\phi])$, 以鼓励智能体到达目标位置和朝向并保持在那里,

以便在落地后完成指定任务c。此外，引入骨盆线速度跟踪 $r(\dot{q}_{x,y}, \dot{q}_{x,y}^d)$ 和角速率跟踪 $r(\dot{q}_{\psi,\theta,\phi}, [0, 0, \dot{q}_{\phi}^d])$ 来塑造稀疏任务奖励，其中 $\dot{q}_{x,y}^d = c_{x,y}/T_J$ 和 $\dot{q}_{\phi}^d = c_{\phi}/T_J$ 。此外，尽管任务不包含骨盆翻滚角和俯仰角 $q_{\psi,\theta}$ ，但将它们最小化至零有助于稳定机器人的骨盆。

我们进一步引入了一个平滑项，其重要性低于任务完成，但权重高于运动跟踪项。例如，我们鼓励机器人在跳跃过程中通过 $r(F_z, 0)$ 减少地面冲击力 F_z ，通过电机速度奖励 $r(\dot{\mathbf{q}}_m, 0)$ 和关节加速度奖励 $r(\ddot{\mathbf{q}}, 0)$ 抑制落地后身体的振荡，并通过 $r(\tau, 0)$ 提高能效。此外，通过在机器人落地后对扭矩消耗和电机速度奖励赋予相对较大的权重 ($t > T_J$)，强调了保持静止站立姿态的重要性。这是因为在阶段3引入动力学随机化会使环境变得嘈杂，并导致站立时身体姿态出现振荡。我们还在阶段2和阶段3中引入了一个额外组件——动作变化奖励 $r(\mathbf{a}_t, \mathbf{a}_{t+1})$ ，以进一步平滑机器人为了跳跃长距离而可能执行的激进动作。

备注1：尽管奖励的切换时间 (T_J) 是固定的，且未针对跳跃到不同位置进行调整，但正如我们的实验所示，机器人学会了针对不同目标的不同飞行时间（图7b）。

D. 回合设计

仅仅精心设计奖励可能还不够，因为鼓励智能体跳跃本身就充满挑战。机器人在学习跳跃时，可能始终无法稳定自身。因此，机器人很容易采用非常保守但稳定的行为，因为这样能快速提升回报。例如，机器人可能只是站立或原地跳跃，未能完成任务，却仍能获得一些次优回报。为防止这种情况，我们注意到，对回合进行谨慎设计也有助于训练动态跳跃动作。

在多目标训练的各阶段中，最大回合长度设置为2500个时间步，持续76秒。在此类回合中，机器人在随机站立时间间隔后被指令跳跃到随机目标，这些随机值均为均匀采样。任务从 $c_x \sim U(-0.5, 1.5)$ 米、 $c_y \sim U(-1.0, 1.0)$ 米、 $c_z \sim U(-0.5, 0.5)$ 米和 $c_{\phi} \sim U(-100^\circ, 100^\circ)$ 中采样，站立阶段分布为 $U(1, 15)$ 秒。这种“跳跃↔站立”的切换会重复进行。这种设计可以通过在一个回合内重复跳跃，提高学习策略对不同初始状态的鲁棒性。此外，与要求智能体在 $t = 0$ 处跳跃的第一阶段相比，从阶段2开始，机器人在每个回合开始时大概率会以站立技能启动。

如果机器人摔倒（骨盆高度低于 $q_z < 0.55$ 米或跗关节触地），该回合将提前终止，以防止其获得更多奖励。我们还强调

足部高度跟踪和任务完成对机器人的重要性，通过以下条件提前终止回合：(i) 足部高度跟踪误差 $|e_z - e_z^d|$ 大于设定的界限 E_e （即0.32米），或(ii) 机器人在着陆后未到达给定目标 ($t > T_J$)，当 $[||q_{x,y} - c_{x,y}||_2, |q_{\phi} - c_{\phi}|] > E_t$ 且 $E_t = [0.35 \text{ 米 } 35^\circ]$ 时。请注意，我们的任务完成误差界限 E_t 相对较小，而对足部高度跟踪误差 E_e 的容忍度较大。通过这种设计，机器人可以偏离参考足部轨迹，为不同任务寻找更优的足部高度轨迹。同时，机器人将有更强的动力通过靠近目标着陆并在更长的回合中获得更多奖励来完成的任务。

备注2：选择较大的足部跟踪误差容限 E_e 也允许机器人在落地后进行小幅跳跃。机器人因足部高度跟踪奖励而被鼓励站立，但可以动态切换到跳跃，包括在 E_e 范围内跳跃到不同位置，以获得更好的鲁棒性。我们并未专门训练或鼓励智能体为了鲁棒性而偏离指定任务。

在训练的第一阶段，单跳为策略引入了执行跳跃行为的归纳偏置。在后续训练阶段，通过结合提前终止条件和运动模仿奖励，这种归纳偏置引导机器人倾向于跳跃到不同目标，而不是使用行走等其他技能。

E. 动力学随机化

为了在仿真到现实迁移中取得成功，我们在阶段3对环境动力学参数引入了广泛的随机化。被随机化的动力学属性完整列于附录B的表III中。在此阶段训练期间，每个回合中，每个动力学参数的值均从表III所列范围内均匀采样。我们考虑了导致仿真到现实差距的三个来源：（1）建模误差，（2）传感器噪声，以及（3）运行强化学习策略的高层计算机与机器人底层计算机之间的通信延迟。

为了增强策略对建模误差的鲁棒性，我们对地面摩擦、机器人的关节阻尼、连杆质量和惯性以及连杆质心位置进行随机化处理。具体而言，为了处理仿真与硬件之间电机动力学的误差，我们设置了更大的关节阻尼上限（默认值的4倍），以近似模拟硬件上的电机老化问题。我们还对关节级PD控制器中使用的PD增益进行随机化处理（因为我们的策略输出目标电机位置）。其范围是默认值的 $\pm 30\%$ 。这种变化能够使机器人训练时接触到的电机响应多样化，并增强在硬件部署过程中对电机动力学变化的鲁棒性。此外，针对Cassie腿部通过板簧连接被动关节的特点 $q_{5,6}$ ，弹簧参数至关重要，因为在起飞和着陆阶段它们会产生显著位移。因此，我们引入了20%的不确定性




图3: 目标条件跳跃策略 π_θ 的架构。策略输出期望的电机位置 $\mathbf{q}_m^d$ ，由关节级PD控制器生成电机扭矩 τ 作用于机器人。策略的输入包括：指定着陆目标的目标 $\mathbf{c}$ 、为机器人提供参考轨迹短时预览的参考运动 $\mathbf{q}_t^r$ ，以及机器人输入（机器人动作 $\mathbf{a}_{t-1}$ ）和输出（机器人反馈 $\mathbf{q}_t^o$ ）的4时间步短历史。策略还接收一个长期2秒的输入输出历史，该历史首先由一维卷积神经网络编码。策略以33 Hz频率更新，其余部分以2 kHz频率运行。

在训练过程中对弹簧刚度进行随机化。我们通过实验发现，电机动力学和弹簧刚度的随机化对于双足跳跃技能在仿真到现实迁移中的成功具有不可忽视的影响。

来自关节编码器、惯性测量单元的传感器噪声以及基座线速度的估计误差，在每个回合中模拟为均值从表III采样的高斯噪声。

V. 训练设置

现在，我们通过多阶段训练流程优化强化学习，从而构建控制策略。

A. 策略架构

我们的策略 π_θ 由一个参数为 θ 的深度学习表示。如图3所示，它包含两个组件：一个由多层感知机（MLP）表示的基础网络，以及一个由一维卷积神经网络（CNN）表示的长期历史编码器。该策略以33 Hz的频率运行。每个动作 $\mathbf{a}_t$ 指定了机器人的目标电机位置 $\mathbf{q}_m^d$ 。该动作首先通过一个低通滤波器（LPF） [15, 37, 49]，在应用于关节级PD控制器之前平滑电机目标，并进一步补充平滑奖励。PD控制器以2 kHz的频率运行，生成电机扭矩 $\tau \in \mathbb{R}^{10}$ 以驱动关节运动。

在时间步 t ，策略的输入包含四个组成部分：目标 $\mathbf{c}$ （在第三节B部分介绍）、参考轨迹的预览 $\mathbf{q}_t^r$ 、先前动作和状态（机器人的输入/输出）的短期历史，以及最近2秒的长期输入输出历史。参考轨迹的预览 $\mathbf{q}_t^r = [\mathbf{q}_z^r(t), \mathbf{q}_m^r(t+1), \mathbf{q}_m^r(t+4), \mathbf{q}_m^r(t+7)]$ 作为机器人观测的一部分提供，包含当前参考骨盆高度 $q_z^r(t)$ 以及在未来第1、4和7个时间步采样的参考电机位置 $\mathbf{q}_m^r$ 。将未来参考轨迹的一段作为输入提供给策略，使其能够获取更多信息，例如未来的关节位置、速度及其他高阶项，这一方法已在 [37, 49, 61] 中使用。为了闭合控制回路，我们为机器人提供直接访问

机器人过去4个时间步（约0.12秒）的短期输入输出历史（ $\mathbf{q}_{t-4:t}^o, \mathbf{a}_{t-4:t-1}$ ）。输入输出历史使策略能够从过去的观测中推断系统的动力学特性。任务 $\mathbf{c}$ 、参考运动 $\mathbf{q}_t^r$ 以及当前时间步 t 的短期输入输出历史，将直接作为输入传递给基础多层感知机。

对于仿真到现实迁移，短期历史可能不足以提供足够的信息来控制高维系统上的动态机动。例如，在跳跃过程中，着陆事件受到起飞前获得的角动量的影响，而这两个事件之间的间隔可能远长于0.12秒。因此，我们以过去2秒的长期输入输出历史的形式增加了一个额外输入，其中包含66个时间步的过去观测和动作测量值（ $\mathbf{q}_{t-65:t}^o, \mathbf{a}_{t-66:t-1}$ ）。该长期输入输出历史的时间跨度旨在覆盖一次跳跃的持续时间，以帮助策略隐式推断机器人的动力学、运动轨迹和接触情况。为了编码这一长序列的观测，我们使用一维CNN将其压缩为潜在表示，然后作为输入提供给基础MLP。正如我们将在图5中看到的，长期和短期历史对于获得更好的学习性能都是必需的。

在本工作中，CNN编码器包含2个隐藏层，其 [卷积核大小、滤波器大小、步长] 分别为 [6, 32, 3] 和 [4, 16, 2]，采用 *relu* 激活函数且无填充。CNN的输出被展平并拼接至基础多层感知机的输入中。该多层感知机具有两个隐藏层，每层包含512个 *tanh* 单元，其后接一个输出层，用于表示高斯动作分布的均值，其固定标准差为 $0.1I$ 。

B. 训练细节

根据经验，我们发现对于没有躯干的Cassie而言，同时执行转向和跳跃至不同高度非常困难。由于这一硬件限制，我们选择训练两个独立的目标条件策略：一个专门用于无高度变化跳跃的平地策略，即， $c_z = 0$ ；以及一个训练用于在不转向的情况下跳跃至不同高度平台的离散地形策略（ $c_\phi = 0$ ）。

近端策略优化（PPO） [56] 用于在仿真中训练所有策略 π_θ ，其价值函数由一个2层多层感知机表示，该感知机可以访问真实观测。由于不同训练阶段的复杂度差异，三个阶段分别以6000次、12000次和20000次迭代进行训练。每次迭代收集65536个样本的批次。

VI. 仿真验证

在介绍了我们用于训练目标条件跳跃策略的方法后，接下来将在仿真环境（MuJoCo）中验证所提方法。本节旨在探讨两个问题：（1）与先前工作中使用的模型相比，所提策略架构有何优势；（2）与单目标训练相比，多任务训练是否能进一步提升策略的鲁棒性，




图4: 用于训练双足跳跃策略的基线策略结构示意图。(a) 我们的方法: 图3中详细讨论的所提出的结构。(b) 残差策略, 其输入结构与我们的方法相同, 但输出一个添加到参考电机位置 [34, 70] 的残差项。(c) 仅长历史策略, 该策略仅能访问长期输入输出历史(我们仍向基础网络提供机器人即时反馈, 如Peng等人 [48] 所建议)。(d) 仅短历史策略, 该策略仅提供短期输入输出历史 [37]。我们还与RMA [31]/教师-学生 [34] 训练策略进行了比较, 其中(e) 专家策略首先通过强化学习训练, 能够访问特权环境信息(表III), 随后通过监督学习用于训练(f) RMA (学生) 策略。RMA还可以通过强化学习使用(g) A-RMA [32] 进一步微调。虽然原始RMA [31] 或TS [34], 中未包含短期输入输出历史, 但在此基准测试中将其纳入以实现公平比较。如果模块的参数未更新, 则将其着色。虚线表示参数被复制。

使机器人能够利用更多样化的动作从不稳定状态或未知扰动中恢复。

A. 基线

为回答第一个问题, 我们将所提策略架构与图4所示的几个基线模型进行了基准测试。所有策略均使用多目标进行训练, 即, 跳跃至不同着陆位置和转向方向(无海拔变化), 采用图2所示的训练示意图, 并使用3个不同的随机种子进行训练。基线模型的详细信息见附录C。

为回答第二个问题, 我们使用所提策略结构获得了两个单目标策略, 具体如下:

- **单目标:** 一个在单一原地跳跃任务上训练的策略, 并进行了表III所列的广泛动力学随机化。
- **带扰动的单目标:** 一个与单目标策略相似的策略, 但额外训练了施加在机器人骨盆上的随机扰动扳手(六自由度)。外力和扭矩从 $[-20N, -5Nm]$ 到 $[20N, 5Nm]$ 范围内均匀采样, 并在随机时间间隔(从 $[0.1, 2.0]$ 秒起)内施加于机器人骨盆。

我们基于两个指标对这些基线进行比较: (1) 第VI-B节中的学习性能, 以及(2) 对第VI-C节中训练分布之外的动力学参数的泛化能力。这两个指标对于仿真到现实迁移至关重要, 因为第一个指标展示了策略在训练期间的表现, 而第二个指标则评估了对环境变化的鲁棒性——这些变化在训练中未被考虑, 正如仿真到现实迁移过程中可能出现的情况。




图5: 在阶段3(带动力学随机化的多目标训练)中, 由不同策略结构训练的学习曲线基准测试。曲线为使用3个随机种子训练得到的平均归一化回报, 彩色区域则覆盖了不同种子间的最小值和最大值。归一化回报通过回报除以最大回合长度计算, 取值范围为 $[0, 1]$ 。我们的方法表现出与用于监督RMAs且能访问特权环境参数的专家策略相似的性能。A-RMA表现出次优性能, 但与所提方法相比需要显著更多的样本, 其次是RMA。仅短历史或仅长历史的策略显示出相似的学习性能, 但在回报方面略逊于RMA。残差策略表现最差, 因为添加到策略动作中的参考运动阻碍了智能体探索更多样化的机动动作。

B. 策略结构选择

图5展示了使用我们的策略结构和基线在阶段3(带动力学随机化的多目标学习)中的学习曲线。早期训练阶段(第一阶段学习单一任务和阶段2学习多任务)的学习曲线见附录D中的图10。每个训练阶段均使用相同的超参数和奖励函数。

根据图5(以及图10), 紫色曲线所示的残差结构在所有训练阶段中表现出最差的学习性能。原因在于我们提供的参考运动是一种动态不可行动画, 这可能导致机器人花费更多精力学习纠正这些默认运动, 并阻碍其探索更多样化的轨迹以及推断超出参考运动范围的运动。

仅使用短历史(橙色曲线)和仅使用长历史(蓝色曲线)的基线显示出相似的学习性能。但如果我们将两者结合, 通过为策略提供长历史编码器和对短历史的直接访问, 从而形成我们的方法, 学习性能可以得到大幅提升, 如图5中的红色曲线所示。这表明, 仅向策略提供长历史是不够的, 因为机器人可能需要即时反馈, 而这种反馈可能被长历史编码器所掩盖。通过为策略提供对短历史的直接访问可以解决这一问题, 并且智能体能够学会同时利用这两种信息。

备注3: 我们注意到, 还有其他工作使用带有LSTM [48, 58, 59] 或TCN [34] 的RNNs来编码长期输入输出历史。我们假设, 为策略提供




图6: 三种策略的鲁棒性比较, 分别为: (i) 使用动力学随机化训练的单一任务 (原地跳跃) 策略, (ii) 使用动力学随机化和随机扰动训练的单一任务策略, 以及 (iii) 使用动力学随机化但不含随机扰动的多任务训练策略 (本文提出)。三种策略的测试场景均超出其训练设置。单目标策略无法稳定机器人, 即便是经过大量扰动训练的策略也是如此。而通过多样化跳跃任务训练但未引入扰动的目标条件策略, 能够利用已学技能成功稳定机器人。该目标条件策略能够偏离指令 (原地跳跃), 利用横向跳跃来抵抗横向外力, 并执行两次向前跳跃以适应前向质心偏移。

对短历史的<直接访问>并不局限于1D CNN编码器, 也适用于其他能够捕捉时序信息的神经网络结构, 如TCN、LSTM、GRU和Transformer。在本工作中, 我们选择1D CNN是因为它更易于训练。

我们的方法与RMA/教师-学生 (TS) 策略 (绿色曲线) 之间的对比也颇具意义。在采用动力学随机化训练目标条件策略的过程中, 我们的方法与专家策略相比仅表现出轻微的性能下降。这实际上凸显了我们方法的优势, 因为它可以零样本迁移到真实世界, 而需要特权信息的专家策略则无法做到。在专家策略训练完成后, RMA和A-RMA分别经过3000次迭代和5000次迭代的训练, 如图5所示。我们发现, 由于回归损失的存在, RMA相比专家策略出现了较大的性能下降, 而A-RMA则需要对基础策略进行微调以进一步提升回报。RMA的回报优于仅使用短历史或仅使用长历史的策略, 这与先前研究 [31, 32] 的发现一致。然而, 即使A-RMA收敛后, 其回报仍略逊于我们的方法, 且RMA和A-RMA需要额外的训练和显著更多的样本。

备注4: RMA [31] 或TS [34] 的原始实现仅向机器人提供最近一次的输入/输出对 [31] 或最近的状态反馈 [34], 此外还有长期历史编码器。在图4的RMA/TS实现中, 我们添加了短期输入输出历史, 这可以提升学习性能, 以便进行公平比较。此外, RMA和A-RMA中使用的长期输入输出历史编码器与所提方法中使用的相同, 如图11b所示, 其学习性能优于 [31, 32] 中提出的原始编码器。

结果总结: 通过上述消融研究, 我们可以总结出三个能够提升我们动态运动控制案例中学习性能的因素: (1) 使用期望运动位置作为动作空间 (而非残差), (2) 除了长期机器人输入输出历史外, 还向策略提供对短期输入/输出历史的直接访问, 以及 (3) 以端到端方式训练策略, 而非将训练过程分为教师和学生。这种组合构成了我们提出的方法。

C. Verstiale Policy 的优势

为了验证多目标训练带来的优势, 我们进一步将我们的目标条件策略与单目标策略进行了比较。这两个单目标策略与所提出的策略使用相同数量的样本进行训练, 并采用了动力学随机化, 其学习曲线记录在图11a中。在仿真测试中, 我们命令机器人在一个未经训练的环境中进行原地跳跃。如图6所示, 我们进行了两项测试: (1) 对机器人骨盆施加持续的横向扰动力, 以及 (2) 将所有连杆的质心设置为在三个维度上偏离默认位置 +8 厘米, 而其他动力学参数则设置为默认值。

在这两项测试中, 单目标策略均无法控制机器人, 而目标条件策略则成功稳定了机器人并执行了跳跃。具体而言, 使用单目标训练的策略在站立阶段就直接失败, 即使其中一个策略经过了大量外部扰动的训练, 这些扰动通过使机器人偏离标称跳跃来“迫使”其探索更多动作。相反, 使用多目标 (如向前跳跃和横向跳跃) 训练的策略, 在训练过程中没有扰动, 却能泛化所学任务, 利用这些任务稳定机器人, 并在未收到指令的情况下选择最佳的跳跃动作。例如, 当被指令原地跳跃时, 目标条件策略利用其学到的横向跳跃来稳定机器人以应对横向力 (图6a(iii)), 并涌现出两次向前跳跃以适应前向方向上的质心误差 (图6b(iii))。这一基准测试凸显了多任务学习的优势, 使得策略更加鲁棒。

通过在仿真中进行广泛的消融研究, 我们表明所提策略结构和多目标训练相比其他策略结构或单目标策略, 显著提升了策略的鲁棒性。

VII. 实验

我们现在将在仿真中训练得到的目标条件策略部署到实际硬件上, 包括针对不同目标训练、可跳跃至不同位置和转向方向的平地策略, 以及




图7: 使用所提出的目标条件策略, Cassie执行不同跳跃的快照。快照按时间戳对齐。图中的标签指示给定的着陆目标。(a) 使用专门针对平坦地面的单一策略, 机器人能够 (i) 原地跳跃并转向 -60° , (ii) 向后跳跃0.3米, 以及 (iii) 向前跳跃1米。在1米跳跃过程中, 机器人在第一次跳跃后着陆于0.5米处, 利用前跳到达目标。(b) 机器人使用单一的离散地形策略跳跃到不同位置和抬升高度。该单一策略可以针对不同任务改变接触计划。例如, 1.4米向前跳跃 (ii) 的飞行阶段最长, 而机器人跳上0.44米高抬升 (i) 时飞行阶段最短。在所有这些跳跃中, 机器人无需全局位置反馈即可着陆于目标 (标签) 处, 且误差极小。

专门用于跳跃至不同位置和抬升高度的离散地形策略, 均部署在Cassie机器人硬件上。如图1所示, 两种策略均能在无需微调的情况下, 成功在真实世界中控制机器人。

除了具备成功实现仿真到现实迁移的能力外, 本节旨在验证两个假设: 1) 在仿真中训练的策略是否能在真实世界中完成相同任务; 2) 目标条件策略在迁移到真实世界后, 是否仍能利用已学任务来稳定机器人。相关实验可最佳地通过随附视频 (

<https://youtu.be/aAPSZ2QFB-E>) 观看。请注意, 在所有实验中, 机器人不具备全局位置反馈, 即, 一旦开始移动, 它便不知道与着陆目标的距离, 也不知道与地面的距离。

A. 真实世界中的任务完成

我们首先在机器人上测试了平地策略, 执行三项不同的任务: 原地跳跃同时转向负60度、向后跳跃0.3米, 以及向前跳跃以落在前方1米处的目标点。如图7a所示, 在该目标条件策略的控制下, 机器人能够完成所有三项任务。例如, 在转向任务中, 机器人在空中跳跃时旋转至 -55° , 并降落在与起跳点相同的位置 (图7a(i)中地面上的标签标记处)。在向后跳跃任务中, 与前一任务不同, 机器人在起跳前身体向后倾斜 (图7a(ii)中0.6-0.7秒), 并准确降落在目标标签处。为了向前跳跃1米, 机器人采用了不同的动作: 在飞行阶段前身体前倾, 并以更大的力量蹬地, 这使得飞行阶段和行进距离都比前两项任务更长。我们还观察到, 机器人首先

落在0.5米处的标记点, 但在腿部触地后迅速进行了一次前跳 (图7a(iii)中1.6秒), 最终落在1米处的目标标签上。我们注意到, 这种连续跳跃动作在使用机器人标称动力学模型的仿真中并未出现。这一实验突显了所提策略的两个有利特性: 它能够 (1) 适应不同的系统动力学 (从仿真到实际), 以及 (2) 偏离参考运动并利用多次接触来完成给定任务 (跳跃至目标点)。

随后, 我们通过三项任务验证了离散地形策略: 向前跳跃1米、1.4米, 以及跳跃至一个位于前方0.88米、离地0.44米的目标, 如图7b所示。该实验展示了策略控制机器人跨越距离/抬升高度以精确着陆于给定目标的能力。我们注意到, 该策略能够调整机器人的机动方式/接触计划, 以跨越不同的距离/抬升高度。例如, 与1米跳跃 (图7b(iii)) 相比, 机器人在1.4米跳跃 (图7b(ii)) 中起飞更早而着陆更晚。这种变化是合理的, 因为机器人需要更长的飞行阶段/更大的起飞速度才能着陆于更远的位置。此外, 当指令要求机器人跳上0.44米高的平台时, 与1.4米跳跃 (图7b(ii)中0.6秒处) 相比, 该策略在飞行阶段初期 (图7b(i)中0.8秒处) 的跳跃更趋垂直, 同时将机器人腿部抬升得更高以实现更高跳跃。值得注意的是, 机器人接触平台的时间远早于其他地面跳跃, 但这一单一策略仍能通过不同的着陆事件稳定机器人。此外, 这三项实验均表明, 由所提策略控制的机器人能够精确着陆于给定目标 (图7b中的标签位置), 这极具挑战性。因为机器人在飞行阶段的运动呈弹道特性, 且起飞时的微小




图8: 当机器人在仿真和真实世界中执行原地跳跃并转向 -60° 时, 其关节位置的变化曲线。我们观察到仿真与真实环境之间关节曲线的较大偏差, 例如, 由板簧驱动的被动跗关节在仿真到现实迁移过程中表现出显著差异。此外, 真实世界中的飞行阶段相比仿真有所延迟。这些误差凸显了较大的仿真到现实差距, 但我们的策略对此具有鲁棒性, 并成功控制机器人到达指定目标。

误差可能导致着陆目标出现较大偏差。在这些实验中, 所提策略能够适应机器人硬件的动力学特性, 在起飞过程中调整机器人姿态, 并加速至能使机器人着陆于目标的速度。

备注5: 在跳远过程中 (如图7b(ii)所示), 机器人蹬地时身体以较大角度向前倾斜, 下落时双腿向前摆动, 并在落地后相对于接触点向前旋转身体。这种动作与人类运动员进行立定跳远 [44, 图1A] 时的表现非常接近。与人类相似, 我们机器人的跳远技能也是在训练中习得的, 这与我们提供的原地跳跃参考运动截然不同。

B. 仿真到现实差距

为了进一步理解图7中机器人跳跃实验成功的难度, 我们仔细审视了仿真到现实差距。我们记录了机器人在仿真中 (使用标称动力学参数) 和实际硬件上跳跃时的关节位置曲线。图8展示了使用平地策略进行转向任务 (-60° , 图7a(i)) 的曲线。根据记录的曲线, 机器人的实际关节位置在仿真 (蓝色曲线) 与真实世界 (红色曲线) 之间存在较大偏差。例如, 跗骨关节位置 q_6 在仿真与现实之间的最大误差超过0.35弧度, 考虑到该关节非主动驱动, 而是由标称刚度为1250牛米/弧度的板簧驱动, 这极大地影响了机器人的动力学特性。在其他关节中也观察到类似的偏差, 例如旋转关节 q_2 、大腿关节 q_3 和膝关节 q_4 , 这些关节在跳跃和转向过程中起关键作用, 并且在图12记录的离散地形策略实验中同样存在偏差。这种差异凸显了仿真与真实世界之间的巨大鸿沟, 但也展示了尽管存在如此大的差距, 我们在第四节中介绍的方法仍能保持鲁棒性, 并成功控制机器人完成任务。

C. 目标条件策略实现多样且鲁棒的机动动作

为了进一步挑战所提出的控制策略的极限, 我们进行了更多动态跳跃实验, 如图9和图13所示。如图9a所示, 使用单一平地策略, 机器人执行了多种动态跳跃动作, 例如原地跳跃 (图9a(i))、侧向跳跃 (图9a(iii)), 以及多轴跳跃, 如融合侧向与前向跳跃 (图9a(iv)) 和前向、侧向与转向 (图9a(v))。在这些多轴跳跃中, 机器人展示了更复杂的动作。例如, 如图9a(v)所示, 机器人在向前跳跃并转向以落在前方0.5米、机器人左侧0.2米且转向 -45° 的目标时, 同时向侧向倾斜。在一些具有挑战性的任务中, 机器人在以不稳定状态着陆后, 会利用小跳跃来调整其身体姿态, 如图9a(iv)(v)所示。

此外, 为了测试策略的鲁棒性, 我们在机器人跳跃最高点时, 对其骨盆施加了一个向后扰动力, 如图9a(ii)所示。由于这种扰动, 机器人在下降过程中会向后倾斜, 落地后其两个脚趾上仰, 这使得机器人相对于接触点处于欠驱动状态。然而, 机器人在落地后迅速执行了一个向后跳跃动作, 该动作是在多目标训练中习得的。通过这次跳跃, 机器人能够在飞行阶段调整其身体姿态, 随后稳定落地。在此测试中, 我们给机器人的目标是原地跳跃, 有趣的是, 为了从摔倒中恢复, 机器人偏离了这一目标。

备注6: 由所提出的跳跃策略控制的机器人, 展现出 not 依赖预定义接触计划的能力, 能够在落地后断开接触, 并在需要利用冲击来稳定自身时重新建立接触。这种能力类似于接触隐式轨迹优化 [8, 14, 33, 52, 77]。尽管此类优化方案仍需为腿式机器人进行离线计算, 但我们的工作实现了在线完成。




图9: Cassie使用所提策略执行各种动态跳跃的快照。(a) 机器人能够在平坦地面上执行多种多轴跳跃。它展示了通过偏离指令的原地跳跃并利用从向后跳跃任务中学到的机动动作, 从向后外部扰动 (ii) 中稳定机器人的能力。机器人还在着陆后利用涌现式弹跳来稳定自身, 以应对巨大的冲击力, 如 (iv) 和 (v) 所示。(b) 使用单一的离散地形策略, 机器人不仅可以原地跳跃 (i), 还可以跳跃到不同高度的不同位置 (ii) (iii) (iv)。

在对图9b所示的离散地形策略进行的额外测试中, 机器人展现出精准落在不同给定目标上的能力。虽然指令距离和抬升的变化相对较小, 但该策略仍展现出调整机器人起跳动作以跳跃至给定目标的能力。

VIII. 基于强化学习的腿式运动控制设计选择的讨论

在本节中, 我们讨论通过使用强化学习开发双足机器人跳跃控制器所获得的经验教训。我们希望这能为未来将强化学习应用于腿部运动的研究提供有益的见解。

短期历史补充了长期历史: 提供机器人输入 (策略的动作) 和/或输出 (测量反馈) 的长期历史已被用于

在基于强化学习的机器人控制的许多先前工作中 [31, 34, 48, 58, 59]。虽然这些先前系统展示了使用长期历史相较于仅使用当前状态反馈的优势 [48, 59], 但相较于短历史的优势 [37, 43, 49] 并未得到研究。在这项工作中, 我们证明结合短期历史与长期历史是有益的。图5中的消融研究表明, 仅提供长期输入输出历史 (图4c) 可能不够充分, 即使结合了历史编码器之外的机器人当前状态观测 (类似于 [31, 34, 48]) 也是如此。此类方法的学习性能与仅使用短期历史的多层感知机策略 (图4d) 相比没有显著差异, 如图5所示。我们的架构 (图4a) 表现出更好的学习性能, 因为它能够直接访问短期历史, 同时拥有一个长期历史编码器。在实际

时间控制中，机器人最近的反馈和策略输出（输入/输出）可能比更早时间点的观测更为重要。尽管这些近期信息也是长期历史的一部分，但它们可能被模糊化，难以从长期历史编码器的压缩潜在表示中提取。短期历史为模型提供了对最近观测的直接访问。因此，所提方法在图5中表现出最佳学习性能的原因之一并非使用了长期历史，而是短期历史与长期历史的结合。除了跳跃之外，这一设计决策也可能有益于其他运动技能。

编码环境参数还是机器人的输入/输出历史？ 尽管所提出的架构（图4a）除了引入短期输入/输出历史外，可能与RMA [31] 或教师/学生（TS）框架 [34] 的架构相似（后者也包含长期历史编码器，如图4e、f所示），但本工作中时间编码器的目标与这些方法不同 [31, 34]。RMA或TS中的长期输入/输出历史编码器旨在通过匹配教师策略预测的外部参数来估计人工选择的环境参数（例如，地面摩擦和机器人模型参数）。相比之下，所提出的方法将长期输入/输出历史编码器与基础策略联合训练，并学习直接利用机器人过去的输入/输出轨迹进行控制。其优势在于，机器人的输入/输出历史除了环境参数外，还隐式包含了更多信息，例如碰撞事件和接触力/力矩。这样，机器人有更多自由度从长期输入/输出历史中提取信息，而不受限于估计预先选定的环境参数。这就是所提出的方法相比RMA/TS有所改进的原因——RMA/TS将训练分为不同的教师和学生阶段，并且还需要通过A-RMA进行额外的微调阶段，这需要更多的训练时间和数据，如图5所示。我们还想指出，RMA/TS方法在与视觉等外部传感器结合时可能具有优势 [2, 43]，而所提出的方法可能不具备这一点。

鲁棒性源于多功能性：我们观察到，先前一些基于强化学习的周期性行走技能运动控制器在实际部署中表现出高度鲁棒的行为，包括对外部扰动 [37, 41] 或地形变化 [31, 34, 43]的鲁棒性。对于本文研究的非周期性动态跳跃技能，基于强化学习的策略也展现出显著的鲁棒性，如图9a(ii)所示。这一现象引发了一个有趣的问题：鲁棒性从何而来，以及在使用强化学习进行腿式运动控制时，我们如何提高鲁棒性？虽然此前很少有研究探讨鲁棒性的这一来源，但本文在第六节C部分进行了消融研究。图6清晰地表明，鲁棒性的一个来源是多目标训练：从不同跳跃任务中学习到的多功能基于强化学习的策略，能够泛化所学任务，以从意外扰动（图6a(iii)）或偏离标称轨迹（图6b(iii)）中恢复。这种鲁棒性无法

通过广泛的动力学随机化轻易获得，当策略仅限于单一跳跃任务时（图6a(i)、图6b(i)），即使额外增加外部扰动的随机化（图6a(ii)、图6b(ii)）也是如此。这一结果表明，除了常用的动力学随机化之外，多样化任务（例如跳跃到不同目标或以不同速度行走）可以进一步提高基于强化学习的控制策略的鲁棒性，这是仿真到现实迁移过程中的一个理想特性。

IX. 结论

在这项工作中，我们提出了一种基于强化学习的系统，用于在真实世界的双足机器人上学习多种高动态跳跃动作。我们将双足跳跃问题形式化为一个参数化任务集，并开发了一个在仿真中训练但可直接部署到真实世界的目标条件策略。为了应对具有挑战性的多目标学习问题，我们采用了多阶段训练方案，将问题划分为三个子问题，并通过不同的训练阶段分别解决每个子问题。我们证明，通过多目标训练，机器人能够泛化所学任务，从而在巨大的着陆冲击力或未知扰动下产生鲁棒的涌现恢复行为。通过多目标训练获得的鲁棒性也促进了仿真到现实迁移过程，这是仅通过单目标训练难以实现的。此外，我们提出了一种能够提升学习性能的策略架构。我们的框架使真实的Cassie机器人能够执行一系列具有挑战性的跳跃任务，例如跳跃到不同位置、跳跃到不同评估点，以及在跳跃过程中融合多轴运动。我们在某些实验中偶尔观察到的一个局限性是，机器人在跳跃后会出现振荡。这可能是由于单一策略同时处理动态跳跃和静止站立所带来的挑战。未来，将这种目标条件跳跃策略与更复杂的感知系统相结合，以更高的机动性穿越复杂环境，将是一个有趣的研究方向。

致谢

本研究部分得到了美国国家科学基金会（NSF）资助项目CMMI-1944722以及加拿大高等研究院（CIFAR）的支持。作者衷心感谢Ayush Agrawal博士、Xuxin Cheng、陈嘉明、Xiaoyu Huang、Yiming Ni、Lizhi Yang以及张必可的慷慨帮助。

参考文献

- [1] Bernardo Aceituno-Cabezas, Carlos Mastalli, Hongkai Dai, Michele Focchi, Andreea Radulescu, Darwin G Caldwell, Jos'e Cappelletto, Juan C Grieco, Gerardo Fernandez-Lopez, 和 Claudio Semini. 通过混合整数凸优化实现鲁棒多足运动的同步接触、步态与运动规划。 *IEEE机器人与自动化快报*, 3(3):2531–2538, 2017年。

[2]Ananye Agarwal, Ashish Kumar, Jitendra Malik, 和 Deepak Pathak. 利用自我中心视觉在挑战性地形中进行腿部运动. *arXiv预印本 arXiv:2211.07638*, 2022年. [3] Ryan Batke, Fangzhou Yu, Jeremy Dao, Jonathan Hurst, Ross L Hatton, Alan Fern, 和 Kevin Green. 针对强化学习优化单刚体模型的双足机动. 载于2022年*IEEE-RAS*第21届国际仿人机器人会议 (*Humanoids*), 第714–721页, 2022年. [4] Guillaume Bellegarda 和 Auke Ijspeert. CPG-RL: 学习四足运动的中枢模式发生器. *IEEE机器人与自动化快报*, 7(4):12547–12554, 2022年. [5] Guillaume Bellegarda, Yiyu Chen, Zhuochen Liu, 和 Quan Nguyen. 通过深度强化学习实现四足机器人的鲁棒高速奔跑. 载于2022年*IEEE/RSJ*国际智能机器人与系统大会 (*IROS*), 第10364–10370页, 2022年. [6]Miroslav Bogdanovic, Majid Khadiv, 和 Ludovic Righetti. 利用轨迹优化演示实现鲁棒运动的无模型强化学习. 机器人与人工智能前沿, 9, 2022年. [7]Guillermo A Castillo, Bowen Weng, Wei Zhang, 和 Ayonga Hereid. 在3D Digit双足机器人上使用强化学习的鲁棒反馈运动策略设计. 载于2021年*IEEE/RSJ*国际智能机器人与系统大会 (*IROS*), 第5136–5143页, 2021年. [8] Iordanis Chatzinikolaïdis, Yangwei You, 和 Zhibin Li. 使用可解析接触模型的可变地面运动接触隐式轨迹优化. *IEEE机器人与自动化快报*, 5(4):6357–6364, 2020年. [9] Hua Chen, Bingheng Wang, Zejun Hong, Cong Shen, Patrick M Wensing, 和 Wei Zhang. 轮式双足机器人跳跃的欠驱动运动规划与控制. *IEEE机器人与自动化快报*, 6(2):747–754, 2020年. [10] Hongkai Dai, Andr es Valenzuela, 和 Russ Tedrake. 结合质心动力学与完整运动学的全身运动规划. 载于2014年*IEEE-RAS*国际仿人机器人会议, 第295–302页, 2014年. [11] Yanran Ding, Chuankheng Li, 和 Hae-Won Park. 基于混合整数凸优化的单腿动态运动规划. 载于2018年*IEEE/RSJ*国际智能机器人与系统大会 (*IROS*), 第1–6页, 2018年. [12] Yanran Ding, Chuankheng Li, 和 Hae-Won Park. 基于混合整数凸规划的多足机器人跳跃运动学动态运动规划. 载于2020年*IEEE/RSJ*国际智能机器人与系统大会 (*IROS*), 第3998–4005页, 2020年. [13] OSU DRL. cassie-mujoco-sim, 2023年. 网址: <https://github.com/osudrl/cassie-mujoco-sim>. [14] Luke Drnack 和 Ye Zhao. 鲁棒轨迹优化

tion over uncertain terrain with stochastic complementarity. *IEEE机器人与自动化快报*, 6(2):1168–1175, 2021.[15]Alejandro Escontrela, Xue Bin Peng, Wenhao Yu, Tingnan Zhang, Atil Iscen, Ken Goldberg, and Pieter Abbeel. 对抗性运动先验是复杂奖励函数的良好替代品. In 2022年*IEEE/RSJ*国际智能机器人与系统大会 (*IROS*), pages 25–32, 2022.[16] Gilbert Feng, Hongbo Zhang, Zhongyu Li, Xue Bin Peng, Bhuvan Basireddy, Linzhu Yue, Zhitao Song, Lizhi Yang, Yunhui Liu, Koushil Sreenath, et al. Genloco: 四足机器人通用运动控制器. *arXiv预印本 arXiv:2209.05309*, 2022.[17] Zipeng Fu, Ashish Kumar, Jitendra Malik, and Deepak Pathak. 最小化能耗导致腿式机器人步态的出现. *arXiv预印本 arXiv:2111.01674*, 2021.[18]Zipeng Fu, Xuxin Cheng, and Deepak Pathak. 深度全身控制: 学习用于操作和运动的统一策略. *arXiv预印本 arXiv:2210.10044*, 2022.[19]Scott Gilroy, Derek Lau, Lizhi Yang, Ed Izaguirre, Kristen Biermayer, Anxing Xiao, Mengti Sun, Ayush Agrawal, Jun Zeng, Zhongyu Li, et al. 四足机器人通过受限障碍物的优化跳跃自主导航. In 2021年*IEEE*第17届自动化科学与工程国际会议 (*CASE*), pages 2132–2139, 2021.[20] Dip Goswami and Prahlad Vadakkepat. 具有稳定着陆的平面双足跳跃步态. *IEEE机器人学汇刊*, 25(5):1030–1046, 2009.[21]Tuomas Haarnoja, Sehoon Ha, Aurick Zhou, Jie Tan, George Tucker, and Sergey Levine. 通过深度强化学习学习行走. *arXiv预印本 arXiv:1812.11103*, 2018.[22]Ross Hartley, Maani Ghaffari, Ryan M Eustice, and Jessy W Grizzle. 用于机器人状态估计的接触辅助不变扩展卡尔曼滤波. 国际机器人研究杂志, 39(4):402–430, 2020.[23] Masato Hirose and Kenichi Ogawa. 本田仿人机器人开发. 皇家学会哲学汇刊A辑: 数学、物理与工程科学, 365(1850):11–19, 2007.[24]Xiaoyu Huang, Zhongyu Li, Yanzhen Xiang, Yiming Ni, Yufeng Chi, Yunhao Li, Lizhi Yang, Xue Bin Peng, and Koushil Sreenath. 通过强化学习创建动态四足机器人守门员. *arXiv预印本 arXiv:2210.04435*, 2022.[25]Se Hwan Jeon, Sangbae Kim, and Donghyun Kim. MIT迷你猎豹的在线最优着陆控制. In 2022年国际机器人与自动化会议 (*ICRA*), pages 178–184, 2022.[26] Gwanghyeon Ji, Juhyeok Mun, Hyeongjun Kim, and Jemin Hwangbo. 控制策略与状态估计器的并行训练, 用于动态鲁棒腿式运动。

and a state estimator for dynamic and robust legged locomotion. *IEEE机器人与自动化快报*, 7 (2):4630–4637, 2022.[27]Yandong Ji, Zhongyu Li, Yinan Sun, Xue Bin Peng, Sergey Levine, Glen Berseth, and Koushil Sreenath. 使用四足机器人的分层强化学习实现精确足球射门技能。In *2022年IEEE/RSJ国际智能机器人与系统大会 (IROS)*, pages 1479–1486, 2022.[28]Dmitry Kalashnikov, Jacob Varley, Yevgen Chebotar, Benjamin Swanson, Rico Jonschkowski, Chelsea Finn, Sergey Levine, and Karol Hausman. MT-Opt: 大规模连续多任务机器人强化学习。 *arXiv预印本 arXiv:2104.08212*, 2021.[29] Benjamin Katz, Jared Di Carlo, and Sangbae Kim. Mini Cheetah: 推动动态四足控制极限的平台。In *2019年国际机器人与自动化会议 (ICRA)*, pages 6295–6301, 2019.[30] Daniel E Koditschek and Martin Buehler. 简化跳跃机器人的分析。 *国际机器人研究杂志*, 10(6):587–605, 1991.[31] Ashish Kumar, Zipeng Fu, Deepak Pathak, and Jitendra Malik. RMA: 腿式机器人的快速运动适应。 *arXiv预印本 arXiv:2107.04034*, 2021.[32] Ashish Kumar, Zhongyu Li, Jun Zeng, Deepak Pathak, Koushil Sreenath, and Jitendra Malik. 为双足机器人适配快速运动适应。In *2022年IEEE/RSJ国际智能机器人与系统大会 (IROS)*, pages 1161–1168, 2022.[33] Benoit Landry, Joseph Lorenzetti, Zachary Manchester, and Marco Pavone. 用于接触规划的双层优化: 一种半直接法。In *机器人研究: 第19届国际研讨会ISRR*, pages 789–804, 2022.[34]Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. 在挑战性地形上学习四足运动。 *科学机器人*, 5 (47):eabc5986, 2020.[35] Quanyi Li, Zhenghao Peng, Haibin Wu, Lan Feng, and Bolei Zhou. 通过策略剖析实现人机共享控制。 *arXiv预印本 arXiv:2206.00152*, 2022.[36] Zhongyu Li, Christine Cummings, and Koushil Sreenath. Animated Cassie: 一个动态可关联的机器人角色。In *2020年IEEE/RSJ国际智能机器人与系统大会 (IROS)*, pages 3739–3746, 2020.[37] Zhongyu Li, Xuxin Cheng, Xue Bin Peng, Pieter Abbeel, Sergey Levine, Glen Berseth, and Koushil Sreenath. 用于双足机器人鲁棒参数化运动控制的强化学习。In *2021年IEEE国际机器人与自动化会议 (ICRA)*, pages 2811–2817, 2021.[38] Tzu-Yuan Lin, Ray Zhang, Justin Yu, and Maani Ghaffari. 使用不变卡尔曼滤波和学习接触事件的腿式机器人状态估计。In *第五届年度*

机器人学习会议, 2021年。[39] Zachary Manchester 和 Scott Kuindersma. 变分接触隐式轨迹优化。载于 *机器人研究: 第18届国际研讨会 ISRR*, 第985–1000页, 2020年。[40] Gabriel Margolis, Ge Yang, Kartik Paigwar, Tao Chen 和 Pulkit Agrawal. 基于强化学习的快速运动。载于 *机器人: 科学与系统*, 2022年。[41]Gabriel B Margolis 和 Pulkit Agrawal. Walk these ways: Tuning robot control for generalization with multiplicity of behavior. 载于 *机器人学习会议*, 2022年。[42] Gabriel B Margolis, Tao Chen, Kartik Paigwar, Xiang Fu, Donghyun Kim, Sangbae Kim 和 Pulkit Agrawal. 从像素学习跳跃。载于 *第五届机器人学习年度会议*, 2021年。[43]Takahiro Miki, Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun 和 Marco Hutter. 学习四足机器人在野外鲁棒的感知运动。载于 *科学机器人*, 7(62):eabk2822, 2022年。[44] Mark P Moresi, Elizabeth J Bradshaw, David Greene 和 Geraldine Naughton. 使用站立和反应性跳远评估青少年女性运动员。载于 *运动生物力学*, 10(02):73–84, 2011年。[45] Chuong Nguyen, Lingfan Bao 和 Quan Nguyen. 通过轨迹优化和模型预测控制在踏脚石上实现腿式机器人连续跳跃。载于 *arXiv预印本 arXiv:2204.01147*, 2022年。[46] Quan Nguyen, Matthew J Powell, Benjamin Katz, Jared Di Carlo 和 Sangbae Kim. MIT猎豹3号机器人的优化跳跃。载于 *2019年国际机器人与自动化大会 (ICRA)*, 第7448–7454页, 2019年。[47] Hae-Won Park, Patrick M Wensing, Sangbae Kim 等. 高速四足机器人自主跑跳越障的在线规划。载于 *机器人: 科学与系统*, 2015年。[48]Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba 和 Pieter Abbeel. 带动力学随机化的机器人控制仿真到现实迁移。载于 *2018年IEEE国际机器人与自动化大会 (ICRA)*, 第3803–3810页, 2018年。[49] Xue Bin Peng, Erwin Coumans, Tingnan Zhang, Tsang-Wei Lee, Jie Tan 和 Sergey Levine. 通过模仿动物学习敏捷的机器人运动技能。载于 *arXiv预印本 arXiv:2004.00784*, 2020年。[50] Xue Bin Peng, Ze Ma, Pieter Abbeel, Sergey Levine 和 Angjoo Kanazawa. AMP: 用于风格化物理角色控制的对抗性运动先验。载于 *ACM图形学交易 (TOG)*, 40(4):1–20, 2021年。[51]Samuel Pfrommer, Mathew Halm 和 Michael Posa. ContactNets: 使用平滑隐式表示学习不连续接触动力学。载于 *机器人学习会议*, 第2279–2291页。PMLR, 2021年。[52]Michael Posa, Cecilia Cantu 和 Russ Tedrake. 一种通过接触进行刚体轨迹优化的直接方法

研究, 33(1):69–81, 2014. [53] M. H. Raibert, M. A. Chepponis 和 H. Benjamin Brown. 使用三维单腿跳跃机进行平衡实验. 国际机器人研究杂志, 3(2):75–92, 1984年6月. [54] Diego Rodriguez 和 Sven Behnke. Deepwalk: 通过深度强化学习实现全向双足步态. 载于2021年IEEE国际机器人与自动化会议(ICRA), 第3033–3039页, 2021年. [55] Martin Rutschmann, Brian Satzinger, Marten Byl 和 Katie Byl. 用于崎岖地形机器人跳跃的非线性模型预测控制. 载于2012年IEEE/RSJ智能机器人与系统国际会议, 第1859–1864页, 2012年. [56] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford 和 Oleg Klimov. 近端策略优化算法. *arXiv预印本 arXiv:1707.06347*, 2017年. [57] Andr e Seyfarth, Hartmut Geyer 和 Hugh Herr. 摆腿回缩: 一种用于稳定奔跑的简单控制模型. 实验生物学杂志, 206(15):2547–2555, 2003年. [58] 邵业成、金永斌、刘贤伟、何伟彦、王洪涛和杨伟. 通过相位引导控制器学习四足机器人的自由步态转换. *IEEE机器人与自动化快报*, 7(2):1230–1237, 2021年. [59] Jonah Siekmann, Srikar Valluri, Jeremy Dao, Lorenzo Bermillo, 段和磊, Alan Fern 和 Jonathan Hurst. 学习基于记忆的控制以实现人尺度双足运动. *arXiv预印本 arXiv:2006.02402*, 2020年. [60] Jonah Siekmann, Yesh Godse, Alan Fern 和 Jonathan Hurst. 通过周期性奖励组合实现所有常见双足步态的仿真到现实学习. 载于2021年IEEE国际机器人与自动化会议(ICRA), 第7309–7315页, 2021年. [61] Laura Smith, J Chase Kew, Xue Bin Peng, 河世勋, Jie Tan 和 Sergey Levine. 持续学习的腿式机器人: 在真实世界中微调运动策略. 载于2022年国际机器人与自动化会议(ICRA), 第1593–1599页, 2022年. [62] Laura Smith, Ilya Kostrikov 和 Sergey Levine. 公园漫步: 20分钟内通过无模型强化学习学会行走. *arXiv预印本 arXiv:2208.07860*, 2022年. [63] 宋志涛、岳林柱、孙广利、凌一虎、魏宏硕、桂林海和刘云辉. 一种用于四足跳跃的最优运动规划框架. 载于2022年IEEE/RSJ国际智能机器人与系统大会(IROS), 第11366–11373页, 2022年. [64] Emanuel Todorov, Tom Erez 和 Yuval Tassa. MuJoCo: 用于基于模型控制的物理引擎. 载于2012年IEEE/RSJ国际智能机器人与系统会议, 第5026–5033页, 2012年. [65] Barkan Ugurlu, Jody A Saglia, Nikos G Tsagarakis 和 Darwin G Caldwell. 共振频率跳跃: 一种用于双足机器人的轨迹生成技术

弹性关节. 在2012 IEEE国际机器人与自动化会议, 第1436–1443页, 2012年. [66] Ivo Vataavuk 和 Zdenko Kova ci c. 基于质心动力学双层优化的精确跳跃规划. 在2021 IEEE国际机器人与自动化大会(ICRA), 第3026–3032页, 2021年. [67] Eric Vollenweider, Marko Bjelonic, Victor Klemm, Nikita Rudin, Joonho Lee 和 Marco Hutter. 通过强化学习中多个对抗性运动先验实现的高级技能. *arXiv预印本 arXiv:2203.14912*, 2022年. [68] Philipp Wu, Alejandro Escontrela, Danijar Hafner, Ken Goldberg 和 Pieter Abbeel. Daydreamer: 物理机器人学习的世界模型. *arXiv预印本 arXiv:2206.14176*, 2022年. [69] Zhaoming Xie, Glen Berseth, Patrick Clary, Jonathan Hurst 和 Michiel van de Panne. 基于深度强化学习的Cassie反馈控制. 在2018 IEEE/RSJ国际智能机器人与系统大会(IROS), 第1241–1246页, 2018年. [70] Zhaoming Xie, Patrick Clary, Jeremy Dao, Pedro Morais, Jonathan Hurst 和 Michiel Panne. 为Cassie学习运动技能: 迭代设计与仿真到现实迁移. 在机器人学习会议, 第317–329页. PMLR, 2020年. [71] Xiaobin Xiong 和 Aaron D Ames. 双足跳跃: 基于优化控制的降阶模型嵌入. 在国际智能机器人与系统大会(IROS), 第3821–3828页, 2018年. [72] William Yang 和 Michael Posa. 冲击不变控制及其在双足运动中的应用. 在2021 IEEE/RSJ国际智能机器人与系统大会(IROS), 第5151–5158页, 2021年. [73] Justin K Yim 和 Ronald S Fearing. Salto-1p 飞行阶段控制的精确跳跃极限. 在2018 IEEE/RSJ国际智能机器人与系统大会(IROS), 第2229–2236页, 2018年. [74] Fangzhou Yu, Ryan Batke, Jeremy Dao, Jonathan Hurst, Kevin Green 和 Alan Fern. 通过仿真到现实强化学习实现动态双足机动. *arXiv预印本 arXiv:2207.07835*, 2022年. [75] Wenhao Yu, Visak CV Kumar, Greg Turk 和 C Karen Liu. 双足运动的仿真到现实迁移. 在2019 IEEE/RSJ国际智能机器人与系统大会(IROS), 第3503–3510页, 2019年. [76] Chi Zhang, Wei Zou, Liping Ma 和 Zhiqing Wang. 仿生跳跃机器人: 综合评述. 机器人与自主系统, 124:103362, 2020年. [77] Yifan Zhu, Zherong Pan 和 Kris Hauser. 使用双层优化与学习到的可变形接触进行接触隐式轨迹优化. 在2021 IEEE国际机器人与自动化大会(ICRA), 第9921–9927页, 2021年.

A. 第一阶段训练

1) 奖励：第一阶段的奖励设计如表II所示。在第一阶段，为了启动针对单个跳跃目标的训练，我们激励机器人模仿原地跳跃动画。因此，电机位置和脚部高度的跟踪奖励权重远高于其他项，以完成跳跃并在之后保持静止。我们还包含了任务完成项，但由于此阶段任务是固定的，即， $\mathbf{c} = \mathbf{0}$ ，该项更多地是鼓励机器人原地跳跃并稳定其骨盆朝向。在此阶段，我们还设置了一个平滑项作为奖励的一小部分，并且没有设置动作变化奖励，以防止机器人在训练早期采取静止行为。

2) 回合设计：在初始训练阶段，回合长度被设计为750个时间步，对应23秒。智能体被要求在 $t = 0$ 处跳跃，并站立至结束。如果允许机器人在回合开始时站立，机器人可能会专注于学习简单的站立技能，而未能探索跳跃动作。此外，请注意，跳跃阶段通常不到2秒，但我们设置了23秒的回合。这是因为如果回合较短，机器人可能很好地学习跳跃，但会忽视站立技能，从而导致机器人采取不良动作，例如着陆后继续跳跃。设置如此长的回合可以激励机器人学习稳健且稳定的站立技能，以便在回合中获得更好的回报。第一阶段的提前终止条件与多目标训练阶段不同，但摔倒条件除外。在此阶段，脚部高度跟踪误差界限 E_e 较小（0.22米），而任务完成误差界限 E_t 则大得多（ $[1.0, 45^\circ]$ ）。这是因为我们希望在此训练初期通过抬脚来推动机器人跳跃，而完成该任务在此阶段并非主要关注点。

B. 动力学随机化细节

本文所使用的动力学参数及随机化范围详情列于表III。请注意，噪声范围相对较小（例如关节位置测量中的 0.1° 和关节速度中的 0.5° ），这是因为我们发现Cassie机器人上的机载传感器可靠性较高，因此采用较小的边界以降低训练复杂度。对于传感器噪声较大的机器人，建议在训练过程中使用更大的噪声边界。


C. 基线模型细节

我们对比的模型结构详情如下：

• **我们的方法**（图4a）：长期输入输出历史通过CNN编码，而短期输入输出历史直接作为输入提供给基础多层感知机。策略直接输出期望运动位置。CNN编码器和MLP基础网络联合训练。• **残差**（图4b）：策略与所提出的结构相同，但策略输出是一个残差项，该残差项被添加到

表III：动力学随机化范围

参数	范围
地面摩擦系数	[0.3, 3.0]
关节阻尼	[0.3, 4.0] Nms/rad
弹簧刚度	[0.8, 1.2] $\times$ 默认
连杆质量	[0.5, 1.5] $\times$ 默认
连杆惯性	[0.7, 1.3] $\times$ 默认
骨盆（根部）质心位置	[-0.1, 0.1] 米 $q_{x,y,z}$
其他连杆质心位置	[-0.05, 0.05] 米 $\times$ 默认
电机PD增益	[0.7, 1.3] $\times$ 默认
电机位置噪声均值	[-0.002, 0.002] 弧度
电机速度噪声均值	[-0.01, 0.01] 弧度/秒
陀螺仪旋转噪声均值	[-0.002, 0.002] 弧度
线速度估计误差	[-0.04, 0.04] 米/秒
通信延迟	[0, 0.025] 秒



(a) 阶段1：学习单一目标 (b) 阶段2：学习多个目标

图10：早期阶段中，由不同策略结构使用3个随机种子训练得到的学习曲线基准。曲线记录了使用不同种子获得的归一化回报均值，不同种子之间的最小值和最大值构成彩色区域的边界。所提出的方法在训练的早期阶段（包括从零开始学习单一目标（阶段1）和阶段2中的多目标学习）均表现出最佳性能。

当前时间步的参考电机位置上，即， $q_m^d = \mathbf{a}_t + q_m^r(t)$ ，该方法用于 [34, 70]。请注意，策略将参考运动作为输入。• **仅长历史**（图4c）：策略仅具有由CNN编码的长期输入输出历史，这是 [31, 34]中使用的基线。注意，我们仍按照Peng等人的建议 [48]，将当前时间步的机器人反馈直接提供给MLP基础网络。• **仅短历史**（图4d）：策略具有短期输入输出历史，但没有长期输入输出历史CNN编码器，该方法用于 [37]，并作为 [32]中的基线。• **RMA/教师-学生**：首先使用强化学习训练一个能够访问特权环境信息（列于表III）的专家（教师）策略（图4e）。特权信息由MLP编码为8维外部向量。然后，该专家策略用于监督RMA（学生）策略的训练，该学生策略使用从专家策略复制而来的MLP基础网络，同时使用长期输入输出历史编码器来预测教师的外部向量。这种两阶段训练方案用于 [31, 34]，并在其他工作中也被采用，例如 [18, 26, 40]。• **A-RMA**（图4g）：在标准RMA训练之后，固定长期输入输出历史编码器的参数，并按照Kumar等人提出的方法 [32]，使用强化学习对MLP基础网络进行进一步微调。RMA和A-RMA也都配备了短期输入输出历史，这是本工作为公平比较而新增的内容。

D. 早期阶段的学习性能

根据图5，在没有动力学随机化的训练阶段（阶段1和2），我们的方法表现出与能够获取特权环境信息的专家策略相似甚至略优的学习性能。




图11: 附加学习曲线。




图12: 使用离散地形策略, 在仿真和真实世界中, 当机器人被指令向前跳跃0.88米并抬升到0.44米高的台阶时, 其关节位置的变化曲线。




图13: 附加实验展示了Cassie使用单一平地策略跳跃到不同目标的情况。

(第一阶段, 图10a), 在更复杂的多目标训练阶段(阶段2)中, 仅使用短历史和仅使用长历史的学习性能(蓝色曲线)表现出相似的学习性能。

E. 附加学习曲线

第IV-E节详述的带有动力学随机化的单目标策略的学习曲线记录在图11a中。使用不同长历史编码器训练RMAs的结果记录在图11b中。[31, 32] (原始)中使用的RMA的长期输入输出编码器(一维卷积神经网络)结构与本文使用的不同。它有3个隐藏层, 每层的[卷积核大小、滤波器大小、步长] 分别为 [8, 32, 4], [5, 32, 1], 和 [5, 32, 1], 并采用零填充。

F. 附加硬件实验

更多实验结果展示在图12和图13中。这些结果展示了平地策略在真实机器人Cassie上完成更具挑战性跳跃任务的能力。

这是因为长期输入输出历史能够提供比专家策略中使用的动力学参数更多的信息, 例如机器人的起飞轨迹, 这将有助于确定更好的着陆机动。尽管仅使用短历史的策略(橙色曲线)在训练初期显示出更快的学习曲线,