

面向多功能、动态与鲁棒双足运动控制的强化学习

Zhongyu Li¹, Xue Bin Peng², Pieter Abbeel¹, Sergey Levine¹, Glen Berseth^{3,4}, Koushil Sreenath^{1,1} 加州大学伯克利分校² 西蒙菲沙大学³ 蒙特利尔大学⁴ Mila- 魁北克人工智能研究所




图 1: Cassie, 一款力矩控制的人形双足机器人, 通过我们框架开发的控制器执行多种运动技能。我们提出了一种统一的强化学习框架, 能够为多种高度动态的技能训练出鲁棒且敏捷的控制器, 例如 (a) 行走、(b) 跑步和 (c) 跳跃。所提出的双历史策略架构与训练系统开发的控制策略能够适应机器人动力学的变化, 从而使得学习到的策略在仅经过仿真训练后, 无需进一步的真实世界调优即可直接迁移到真实机器人。更多实验结果可在补充视频中最佳观看, 这些视频总结于表 I。

摘要 — 本文全面研究了利用深度强化学习为双足机器人创建动态运动控制器的方法。我们不仅关注单一运动技能, 而是开发了一种通用的控制解决方案, 可用于一系列动态双足技能, 从周期性行走和跑步到非周期性跳跃和站立。我们基于强化学习的控制器采用了一种新颖的双历史架构, 同时利用机器人的长期和短期输入 / 输出历史。这种控制架构通过所提出的端到端强化学习方法进行训练, 在仿真和现实世界的多种技能中始终优于其他方法。本研究还深入探讨了所提出的强化学习系统在开发运动控制器时引入的适应性和鲁棒性。我们证明, 所提出的架构能够通过有效利用机器人的输入 / 输出历史, 适应时不变动力学变化和时变变化 (例如接触事件)。此外, 我们确定任务随机化是鲁棒性的另一个关键来源, 有助于更好的任务泛化和对干扰的顺应性。最终的控制策略可成功部署在 Cassie (一款力矩控制的人形双足机器人) 上。这项工作通过广泛的实际实验, 突破了双足机器人敏捷性的极限。我们展示了多种运动技能, 包括: 鲁棒站立、多功能行走、快速跑步 (演示 400 米短跑), 以及多种跳跃技能, 如立定跳远和跳高。

I. 引言

人类环境多样且主要针对双足运动而设计, 因此双足机器人领域的总体目标是开发能够可靠地在这些环境中运行的机器人。本文旨在解决实现这一目标的一个瓶颈: 为高维类人双足机器人的多样化、敏捷且稳健的腿部运动技能 (如行走、奔跑和跳跃) 开发一种控制解决方案。

敏捷且稳健的腿部运动技能, 例如行走、奔跑和跳跃。

尽管对双足机器人运动的研究已持续数十年 (例如, [1]), 但开发一个能够实现多种运动技能稳健控制的通用框架仍然是一个开放性问题。挑战源于双足机器人欠驱动动力学的复杂性以及每种运动技能特有的接触规划。首先, 由于浮动基座和由此产生的欠驱动动力学, 双足机器人需要与环境接触才能移动。持续且难以建模的接触会导致轨迹不连续, 因此需要在模式转换期间进行接触模式规划和稳定。然而, 由于双足机器人的高维度和非线性, 利用其全阶动力学模型进行运动规划和控制计算成本高昂, 且难以用于在线应用。其次, 双足运动技能的多样性 (无论是周期性还是非周期性) 给开发简单通用的框架带来了重大挑战。例如, 与行走不同, 奔跑由于存在重复的飞行阶段 (机器人处于欠驱动状态) 而更加复杂。对于行走或奔跑等周期性技能, 我们可以通过允许在多个步态周期内进行小幅修正来实现轨道稳定性 [2]。然而, 跳跃等非周期性运动缺乏这种固有稳定性, 这再次带来了额外挑战, 因为需要有限时间稳定性 [3], 而着陆时巨大的冲击力进一步加剧了这一问题。

在这项工作中, 我们通过利用强化学习 (RL) 来应对上述挑战, 为具有高维、非线性动力学特性的真实世界机器人创建控制器。这些控制器能够利用机器人的

本体感觉信息以适应机器人不确定的动力学特性，这些特性可能因磨损而随时间变化。这些控制器能够泛化到新环境和新场景，通过利用双足机器人的敏捷性，在面对意外情况时展现出鲁棒的行为。此外，我们的框架提供了一种通用方法，用于复现多种双足 locomotion 技能。

A. 本文目标

对于扭矩控制的人形双足机器人而言，其高维度和非线性特性起初可能看似是开发有效控制器的巨大障碍。然而，这些特性也可以成为优势，通过机器人的高维动力学实现复杂的敏捷动作。我们的目标是为此类双足机器人开发一个通用控制框架，以释放其全部潜力。该框架的目标是在对最终动作进行有限预设的前提下，在现实世界中实现一系列动态双足 locomotion 技能。我们考虑的技能如图 所示，包括稳健站立、行走、奔跑和跳跃。这些技能还可用于执行多样化的任务，包括以不同速度和高度行走、以不同速度和方向奔跑，以及跳向不同目标，同时在实际部署中保持鲁棒性。为实现这一目标，我们采用无模型强化学习，使机器人能够通过系统全阶动力学的试错进行学习。除了实际实验外，我们还深入分析了使用强化学习进行腿式 locomotion 控制的优势，并详细研究了如何有效构建学习过程以利用这些优势，例如适应性和鲁棒性。

B. 术语定义

首先，我们将建立本文中用于描述腿式 locomotion 各个方面的术语。术语“技能”用于表征特定类型的 locomotion，包括行走、奔跑和跳跃等行为。机器人随后可以利用这些技能执行各种“任务”，这些任务由给定目标定义。例如，这些任务可以包括行走时跟随不同目标速度、奔跑时以不同角度转弯，或跳跃时跳向不同目标位置。我们使用术语“通用策略”来描述能够通过一种或多种 locomotion 技能完成多种任务的控制策略。

C. 贡献

本工作推进了双足机器人腿部运动控制领域的发展，主要贡献如下：

开发了一种通用双足运动控制的新框架：我们引入了一个适用于双足机器人的通用强化学习框架，该框架在多种运动技能上均有效，涵盖行走和跑步等周期性技能、跳跃等非周期性技能以及站立等静态技能。所得到的控制器可以直接

部署在真实机器人上，无需在物理系统上进行任何额外调整或训练。

基于强化学习的控制策略的新颖设计选择：我们提出了一种用于非循环强化学习策略的新型双历史架构，该架构将机器人的长、短输入 / 输出历史与显式长度相结合，用于基于强化学习的控制。当与所提出的训练策略（即联合训练带有短历史的基础策略与长历史编码器）相结合时，该架构在学习动态双足运动控制方面展现出最先进的性能，并在各种运动技能中提供一致的益处，这些已在仿真和真实世界实验中得到验证，详见第七节，并在第十一节 A 中讨论。

实证研究强化学习控制器中的适应性：在控制理论界，已有显著努力将自适应控制与强化学习相结合，例如 [4]。在本工作中，我们进行了详细的实证研究，以探究通过强化学习开发的控制策略的适应性。我们表明，强化学习带来的适应性不仅包括动力学中的时不变偏移，还包括接触事件等时变变化。我们不仅在仿真中验证了这一点（如第八节所述），还通过若干真实世界（零样本迁移）实验进行了验证，例如使用双足机器人进行最小漂移的原位行走和定向跳跃，详见第十节。

提升强化学习控制器的鲁棒性：我们的研究在基于强化学习的控制策略中引入了一个新的鲁棒性维度。除了机器人学中常用的动力学随机化之外，[5]，我们证明任务随机化通过在广泛的任务上训练策略，显著增强了鲁棒性，实现了任务泛化。这种方法与动力学随机化不同，为机器人提供了抗干扰能力，这一点在第九节的仿真和真实世界实验中得到了验证。

广泛的实际验证与新型双足运动能力的展示：我们的系统能够使用人形双足机器人 Cassie 在真实世界中复现多种运动技能，详见第十节。Cassie 能够以极小的跟踪误差跟踪各种指令，并对意外干扰具有显著的鲁棒性，包括行走（图 14、18a）、奔跑（图 20、24）和跳跃（图 25、27）。此外，我们展示了双足机器人的新型能力，例如使用不同技能进行鲁棒的站立恢复（图 11）、长时间内控制性能一致的鲁棒行走（图 17、19）（图 14）、使用奔跑控制器完成 400 米短跑（图 20），以及执行多种双足跳跃（图 25、26），包括立定跳远和立定跳高（图 25）。相关实验在表一提供的补充视频中展示。

本文基于我们在《机器人学：科学与系统》上发表的初步工作 [6]，该工作聚焦于双足跳跃。我们将强化学习框架扩展到涵盖更广泛的技能，证明了其既适用于跳跃等非周期性技能，也适用于行走和奔跑等周期性技能。该框架的有效性通过大量实验在这些技能上得到了一致的验证。

表 I: 本文包含的补充视频。

Vid.	Content	Link
1	Summary video	https://youtu.be/sQEnDbET75g
2	Complete 400m dash	https://youtu.be/wzQtRaXjvAk
3	Suppl. walking experiments	https://youtu.be/vUewNUtSG3c
4	Suppl. running experiments	https://youtu.be/ad3ZrvUzbXM
5	Suppl. jumping experiments	https://youtu.be/aAPSZ2QFB-E

真实世界实验。此外，增加的消融研究和基准测试进一步探讨了我们的框架中的设计决策，揭示了增强基于强化学习的运动控制中适应性和鲁棒性的关键要素。

我们希望这项工作能够成为在现实世界中创建鲁棒、多功能且动态的双足运动控制的里程碑，为未来强化学习在腿部运动控制及其他复杂系统中的应用提供见解和指导。

II. 相关工作

双足机器人的运动控制需要解决一个紧密耦合运动规划与全身控制的问题。以往的研究大致可分为两类主要方法：（1）基于模型的最优控制（OC），以及（2）无模型的强化学习（RL）。虽然本研究基于强化学习，但以下综述对基于模型的最优控制和无模型强化学习领域的相关研究给予了同等关注。我们希望这能为腿部运动控制的最新趋势提供一个简洁的概述，对来自两个视角的读者都有参考价值，并重点关注双足机器人。在作为本实验平台的 Cassie 机器人的具体案例中，我们在表 II 中概述了其运动控制最相关的研究工作。

A. 基于模型的双足机器人最优控制

双足机器人的运动控制可以表述为一个最优控制（OC）问题 [25, 式（1）]，其中机器人的动力学模型作为运动约束出现。为了管理求解约束优化问题的计算复杂度，该方法通常采用级联优化框架，从生成时域参考轨迹开始，到低层运动控制和即时反应控制，各阶段控制频率逐步提高，并采用不同的建模选择。

1) 模型选择：可以利用机器人的全阶动力学和接触模型来优化双足机器人的轨迹及特定行为对应的输入 [26, 27, 28]。然而，由于双足机器人通常具有高维非线性动力学，详细模型的使用通常局限于离线优化。值得注意的是，混合零动力学（HZD）方法 [2] 利用双足机器人的全阶模型离线设计具有吸引力的周期性步态，并在线反馈控制器强制执行虚拟约束 [29, 10, 7]。对于在线轨迹优化，需要简化机器人动力学的降阶模型。各种降阶模型，例如质心动力学 [30]，线性倒立摆（LIP）[31] 及其变体如 SLIP [32]、ALIP [18]、H-LIP [19]，

被用于降阶动力学的在线优化，例如质心（CoM）和 / 或压力中心（CoP）[33, 34, 35]。这些模型还支持轨迹跟踪控制 [36, 37, 18]。反应式控制器，如全身控制（WBC, [38]），将这些降阶状态转换为关节级输入，作为一个快速求解的二次规划（QP）运行，考虑各种约束，而无需像 [39, 40, 41] 那样在时域上展开全阶动力学。然而，这种级联 OC 方法由于降阶模型的局限性以及 / 或在线控制器无法重新规划全身动作，未能充分利用机器人的潜在敏捷性。我们的工作通过在机器人全阶动力学上直接学习，并利用无模型强化学习近似求解 OC 问题，克服了这些局限性。由此产生的控制器能够充分发挥底层系统的全部敏捷潜力。

2) 接触规划：腿式机器人需要与环境建立和断开接触。接触时产生的速度跳跃使得机器人的轨迹不光滑。这使得求解一个决定每条腿在整个运动过程中接触模式的 OC 问题变得具有挑战性 [42]。为简化这一问题，许多研究（包括上述大部分工作）预先为特定的运动技能（如行走 [43, 26, 19]、跑步 [44, 45, 46]，和跳跃 [3, 47, 48]）定义了固定的接触序列。然而，预先手工设计的接触序列可能并非最优。例如，不同的跳跃任务可能需要不同的接触时间表，如更长的飞行时间以实现更远的跳跃。因此，有研究通过计算成本高昂的混合整数规划将接触规划与轨迹优化相结合 [49, 50]。也有研究尝试避免使用显式离散变量，通过施加互补约束 [51, 42, 52] 或利用双层优化 [53, 54, 55]，从而产生接触隐式方法。然而，鉴于双足机器人高维非线性的动力学特性，显式或隐式的接触规划仍然局限于离线优化。正如我们将看到的，我们的方法能够在实际部署中实时选择接触计划。

3) 对不同运动技能的可扩展性：基于模型的 OC 在各种双足运动技能和任务中的可扩展性是一个重大挑战，这主要是由于机器人模型和控制框架的任务特定性 [56]。例如，将用于控制 2D 双足行走的 HZD 方法扩展到跑步 [57] 或 3D 行走 [45] 需要付出相当大的努力来寻找合适的周期性步态，然后设计特定的控制器来稳定它们。此外，HZD 对周期性步态稳定性的依赖限制了其向非周期性技能（如跳跃）的扩展。这种局限性在基于 LIP 的方法中同样存在，这些方法需要为行走 [58] 和跑步 [59] 建立单独的框架和模型，而跳跃技能则因 LIP 假设质心高度近似恒定而被排除在外，如 [44] 所示。尽管通过其他精心设计的级联 OC 框架在不同跳跃阶段实现了原地跳跃，例如 [60] 针对每种不同的跳跃任务，但这些方法需要从头开始进行离线轨迹优化，并且常常忽略横向或转弯运动。此外，开发一个能够管理多种技能的单一基于模型的控制器极具挑战性。

表 II: 我们的工作与先前在双足机器人 Cassie 上实现真实世界运动控制器的研究对比。我们的工作介绍了一个通用控制框架, 用于在现实世界中实现多样化的周期性和非周期性双足运动技能, 包括稳健行走与站立、快速奔跑以及多用途跳跃。

Walking Skill						
Previous Literature	Implementation	Variable Velocity	Variable Height	Consistency over Time	Consistent Perturbation	Change of Terrain
[7]	HZD, Model: Full-order	Yes	No	No	No	No
[8, 9]	HZD, Model: Full-order	Yes	Yes	No	No	No
[10]	HZD, Model: Full-order	Yes	No	Not demonstrated	Not demonstrated	No
[11]	RL, Model-free	Yes	No	Not demonstrated	Not demonstrated	No
[12]	RL, Model-free	Forward walking only	No	Not demonstrated	Not demonstrated	No
[13]	RL, Model-free	Yes	Yes	Not demonstrated	Yes (untrained)	No
[14]	RL, Model-free	Yes	No	Not demonstrated	Not demonstrated	Yes (small, trained)
[15]	RL, Model-free	Yes	No	Not demonstrated	Not demonstrated	Yes (trained)
[16]	RL, Model-free	Forward walking only	No	Not demonstrated	Yes (trained)	No
[17]	RL, Model-free	Sharp turn only	No	Not demonstrated	Not demonstrated	No
[18]	OC, Model: ALIP	Yes	No	Not demonstrated	Not demonstrated	Yes (unmodeled)
[19]	OC, Model: H-LIP	Yes	Yes	Not demonstrated	Not demonstrated	Yes (small, unmodeled)
[20]	OC, Model: Centroidal	Yes	No	Not demonstrated	Not demonstrated	Yes (small, unmodeled)
Ours	RL, Model-free	Yes	Yes	Yes	Yes (untrained)	Yes (small, untrained)
Running Skill						
Previous Literature	Implementation	Controlled Velocity	Transition from/to Standing	100m Dash Finish Time	400m Dash Finish Time	Uneven Terrain
[14]	RL $\ddagger$	No	Not demonstrated	Not demonstrated	Not demonstrated	Yes (small, trained)
[21]	OC $\ddagger$	Yes	Not demonstrated	Not demonstrated	Not demonstrated	No
[22]	RL with noticeable light phase	No	Only transit from standing	24.73s	Not capable of turning	No
Ours	RL with noticeable light phase	Yes, w/ sharp turn (untrained)	Yes	27.06s	2 min 34 sec	Yes (large, trained)
$\ddagger$ Although being termed as running, the demonstrated light phase, foot clearance during light, and speed in the real world are not comparable to the rest of the work listed here.						
Jumping Skill						
Previous Literature	Implementation	Targeted Landing	Apex Foot Clearance	Longest Flight Phase	Maximum Leap Distance (Forward, Backward, Lateral, Turning, Elevation)	
[23]	Aperiodic Hop by OC $\ddagger$	No	0.18m	0.42s	In-place	
[24]	Aperiodic Hop by OC $\ddagger$	No	0.15m*	0.33s*	In-place	
[14]	Periodic Hop by RL $\ddagger$	No	0.16m*	0.33s*	Tracking a forward speed	
[21]	Aperiodic Jump by OC	No	0.42m*	0.33s*	(0, 0, 0, 0, 0.41m)	
Ours	Aperiodic Jump by RL	Yes	0.47m	0.58s	(1.4m, -0.3m, $\pm 0.3m$, $\pm 55^\circ$, 0.44m)	
$\ddagger$ The demonstrated light phase, apex foot clearance, and the resulting impacts upon landing are not comparable with the rest, so we use “hop” to distinguish from a “jump”.						
* Not provided in the paper and the listed value is roughly estimated from the accompanying video.						

现实世界中多样化的目标导向双足跳跃任务。这是因为除了完成跳跃外, 控制器还需要快速适应机器人硬件的动力学特性, 并在起跳时产生精确的平移速度, 以便降落在不同位置的目标点上, 如本研究所示。¹ 基于模型的最优控制领域, 如 [21], 等研究所示, 正在开发对冲击具有不变性的通用跟踪控制器方面取得有希望的进展。这些控制器可能能够处理不同的接触序列, 如行走、奔跑和跳跃, 但仍依赖于特定任务优化轨迹。

B. 基于无模型强化学习的腿部运动控制

深度强化学习的最新进展为在现实世界中为四足机器人创建运动控制器带来了令人兴奋的进展, 例如 [63, 64, 65, 66]。然而, 由于双足机器人天生稳定性较差, 适用于四足机器人的方法可能无法直接应用于双足系统, 如 [67] 所示。因此, 在双足机器人社区中, 针对高维非线性挑战, 采用了不同的强化学习策略。

1) 控制策略结构: 在基于强化学习的运动控制中, 控制策略的结构很大程度上受观测值构建方式的影响, 特别是通过仅使用机器人状态历史 (无机器人输入历史) 或输入 / 输出历史 (同时包含机器人输入和输出)。对于四足机器人, 关于使用的历史长度尚未达成共识: 范围从 1 到 15 个时间步的短输入 / 输出历史 [68, 69, 70] 到超过 50 个时间步的仅状态历史 [71, 72, 73] 或输入 / 输出历史 [74]。策略 (神经网络) 架构的选择取决于

关于历史长度, MLP 适用于较短历史, 而循环单元则用于较长序列。在四足机器人上的实际部署表明, 这些不同历史长度下的性能相当。对于双足机器人, 观察到一种向更长历史长度发展的趋势, 从需要残差动作

[75, 11, 76, 77], 的单时间步状态反馈, 到短输入 / 输出历史 [13], 再到更长的纯状态历史序列 [12] 或输入 / 输出历史 [67, 78]。虽然如 [5] 所建议的那样, 利用长历史进行机器人控制是一种常见策略, 但大多数先前的消融研究侧重于通过 MLP 对比长历史与即时状态或输入 / 输出反馈, 例如 [5, 71, 74, 12], 而对较短输入 / 输出历史的探索较少。最近的一项研究 [79], 报告称, 在双足人形机器人控制中, 短状态历史比长历史能带来更好的学习性能, 这与我们在本工作中的发现一致。这引发了一个问题: 虽然长历史有望提升基于强化学习的控制性能, 但如何充分利用其优势? 我们的研究提出了一种有效的解决方案: 双历史方法。

2) 仿真到现实的迁移: 有一些尝试使用强化学习直接在机器人硬件上收集数据并训练, 例如 [80, 81, 82], 也有替代方案利用仿真中的预训练阶段并在硬件上进行微调, 如 [83, 84, 85], 其中大多数部署在小型四足机器人上。然而, 对于人类尺寸的双足机器人, 在硬件上进行 rollout 成本高昂, 因此更倾向于将多样化的动态双足技能直接从仿真迁移到硬件。实现零样本迁移需要在仿真中进行广泛的动力学随机化, 如 [5, 83] 所建议。在随机动力学下训练策略主要有两种方法: (1) 使用机器人测量值或输入 / 输出历史进行端到端训练, 该方法已应用于像 [12, 14, 13], 这样的双足机器人; (2) 策略蒸馏, 通过分离的训练阶段, 一个能够访问特权环境信息的专家策略监督

¹ 尽管工业界 (如波士顿动力公司, 见专利 [62]) 已有尝试使用基于模型的最优控制来解决类似问题, 但详细报告有限。作为一篇研究论文, 我们关注的是已发表的发现。

利用本体感觉反馈训练学生策略。该方法最初针对小型伺服控制双足机器人开发, 如 [86], 所述, 后通过教师 - 学生 (TS, [71]) 或 RMA [74], 等策略适配到四足机器人, 并在四足机器人领域广泛使用 (例如, [87, 88, 89])。尽管策略蒸馏在四足运动控制中具有优势 [74], 但其在扭矩控制双足机器人上的应用需额外微调阶段, 如 [67] 所述。在本工作中, 我们证明端到端训练是开发涵盖多种动态运动技能的双足机器人控制器的更有效方法。

3) 对不同运动技能的可扩展性: 利用强化学习通过单一策略学习多样化运动技能或任务面临挑战, 这源于需要针对不同任务优化多个目标, 如 [90] 所述。最初, 该领域的研究聚焦于固定任务的单一技能, 例如仅向前行走 ([83, 12, 74])。在开发能够执行多任务的单技能策略时, 已考虑通过提供不同指令来跟踪不同行走速度而不指定参考运动的方法, 如 [68, 87, 91] 所示。虽然该方法对四足机器人可行, 但需要大量奖励调整, 且可能因维度更高而不适用于双足机器人。对于双足机器人, 已考虑提供参数化参考运动 [13] 或从任务特定策略进行策略蒸馏 [11] 等方法。部分方法还涉及指令化周期性接触序列, 从而产生多样化但周期性的双足步态, 如 [14] 所示。然而, 预设的接触序列限制了机器人优化接触策略以提升稳定性的潜力。此外, 当此类策略尝试完成特定任务时会呈现局限性, 导致后续工作需要针对不同行为进行专门训练。这包括需要手动调整策略以在快速直线奔跑与站立 [22]、负重 [16], 或行走中急转弯 [17] 之间切换。另有其他尝试旨在创建单一策略以执行多样化技能 (无论是否周期性), 用于双足人形机器人, 如 [92] 在仿真中开发的对抗性运动先验方法。尽管该方法已成功迁移至真实四足机器人 (如 [69, 93, 94]), 但由于更大的仿真到现实差距, 更具动态性的双足技能能否迁移至现实世界仍是未解问题。鉴于这些挑战, 我们的工作对双足机器人的多功能性上取得了平衡。我们专注于开发能够执行多样化任务的技能特定控制策略, 同时保持适用于不同技能开发的通用框架。

III. 概述

在本节中, 我们概述了整篇论文及所提出的用于通用双足运动控制的强化学习系统, 如图 2 所示。首先, 在第四节中, 我们介绍了利用机器人输入 / 输出历史记录在运动控制中的重要性。本节从控制与强化学习两个角度展示了机器人的长输入 / 输出历史记录能够在实时控制过程中实现系统辨识与状态估计。由此引出了

本工作的核心: 一种利用双足机器人长期和短期输入 / 输出历史双历史的新控制架构, 该架构在第五节中介绍。具体来说, 这种控制架构不仅利用长期历史, 还利用了机器人的显式短期历史。所提出的双历史结构能够有效利用机器人的历史, 因为长期历史带来了适应性 (在第八节中验证), 而短期历史通过实现更好的实时控制补充了长期历史的使用 (在第七节中证实)。这种由深度神经网络表示的控制策略, 在第六节中通过无模型强化学习进行优化。由于本文旨在开发一种能够使用高度动态运动技能完成多样化任务的控制器, 第六节中的训练以仿真中的多阶段训练为特点。这种训练策略提供了一个结构化的课程, 从机器人专注于固定任务的单任务训练开始, 接着是使训练任务多样化的任务随机化, 最后是改变机器人动力学参数的动力学随机化。这种训练策略能够提供一种通用的控制策略, 可以执行大量任务并零样本迁移到机器人硬件上。此外, 任务随机化还可以通过在不同学习任务之间的泛化来增强最终策略的鲁棒性。我们表明, 这种鲁棒性导致了对于干扰的顺从行为, 这与动力学随机化带来的鲁棒性是“正交”的。这一点在第九节中得到了验证。

通过使用这一框架, 我们为双足机器人 Cassie 获得了针对行走、奔跑和跳跃的技能特定多功能策略。我们在第 X 节中广泛地在现实世界中评估了这些控制策略的有效性。正如我们将看到的, 由于所提出的控制架构的自适应性, 最终策略能够以最小的模拟到现实世界退化完成各种任务, 并在长时间跨度 (超过一年) 内保持一致性。由于所提出的训练策略带来的鲁棒性, 特别是任务随机化, 最终策略在面对实时和现实世界中的意外干扰时展示了复杂的恢复机动。我们进一步在第 XI 节的讨论中总结了本工作开发过程中的见解和经验教训, 随后在第 XII 节进行总结并展望未来工作。

IV. 背景

在本节中, 我们介绍主要实验平台 Cassie 及其动力学模型。然后, 我们将双足运动控制问题构建为部分可观测马尔可夫决策过程 (POMDP), 为使用强化学习训练策略奠定基础。我们还强调了从基于模型的控制和无模型强化学习两个角度, 在反馈控制中融入机器人输入输出 (I/O) 历史的重要性。

A. Cassie 机器人模型

1) 浮动基座坐标: 如图 3 所示, Cassie 是一个人类大小的双足机器人, 站立高度




图 2: 本文概述。首先, 第四节介绍了运动控制问题的公式化表述以及利用机器人输入 / 输出历史的重要性。基于双历史的多功能双足运动技能控制架构的细节在第五节中介绍, 随后在第六节中讨论了训练方案。然后, 在第七节中进行了详细研究以验证所提出策略结构的优势, 第八节探讨了适应性的来源, 第九节研究了基于强化学习的控制器中观察到的鲁棒行为的来源。第十节展示了使用所提出的基于强化学习的运动控制器使 Cassie 能够执行稳健的站立、行走、奔跑和跳跃技能的广泛实验。第十一节为有兴趣应用强化学习训练双足机器人的读者提供了见解和讨论。

高度 1.1 米, 重 31 公斤。左腿和右腿各有 7 个关节, 包括外展 q_1 、旋转 q_2 、大腿 q_3 、膝盖 q_4 、小腿 q_5 、跗骨 q_6 和脚趾俯仰 q_7 。总共 14 个关节 ($q_j \in \mathbb{R}^{14}$)。其中, $q^{L/R} 1, 2, 3, 4, 7$ 由电机驱动 (记为 $q_m \in \mathbb{R}^{10}$), 而小腿和跗骨关节 ($q_{5,6}^{L/R}$) 是被动的, 通过板簧连接, 如图 3 所示。Cassie 有一个浮动基座 q_b , 具有 6 个自由度, 即平移位置 q_x, y, z 和旋转位置 q_ϕ, θ, ψ 。整个系统的广义坐标 q 可以表示为 $q = [q_b, q_j] \in \mathbb{R}^{20}$ 。

可观测状态: 由于机器人是一个二阶机械系统, 我们可以将机器人的状态表示为其广义坐标 q 及其时间导数 $\dot{q}$ 。然而, 只有一部分状态可以通过机器人机载传感器可靠地测量或估计。我们将可观测状态记为 $o \in \mathbb{R}^{26}$, 它包含电机位置及其速度 ($q_m, \dot{q}_m$), 这些分别由关节编码器测量和估计。基座方向 $q_{\phi, \theta, \psi}$ 可通过 IMU 测量, 基座线速度 $\dot{q}_{x, y, z}$ 可通过如 [11] 中使用的扩展卡尔曼滤波器估计。

2) 全阶动力学模型: Cassie 具有浮动基座, 总共 $n = 20$ 个自由度, 以及 $n_a = 10$ 个驱动关节, 其动力学方程可通过欧拉 - 拉格朗日方法得到:

$$\mathbf{M}(q)\ddot{q} + \mathbf{C}(q, \dot{q})\dot{q} + \mathbf{G}(q) = \mathbf{B}\tau + \kappa_{sp}(q, \dot{q}) + \zeta_{ext}, \quad (1)$$

其中 $\mathbf{M} \in \mathbb{R}^{n \times n}$ 、 $\mathbf{C} \in \mathbb{R}^{n \times n}$ 和 $\mathbf{G} \in \mathbb{R}^n$ 分别表示广义质量矩阵、离心力和科里奥利力矩阵以及广义重力。(1) 式的右侧包含系统输入, 包括广义控制输入 (电机扭矩) $\tau \in \mathbb{R}^{n_a}$ (由 $\mathbf{B} \in \mathbb{R}^{n \times n_a}$ 分配)、状态相关的弹簧扭矩 $\kappa_{sp}(q, \dot{q})$ 以及广义外力 ζ_{ext} 。 ζ_{ext} 汇总了所有来自环境的外力, 包括表示为 $\mathbf{J}_c^T \mathbf{F}_c$ 的足底接触力以及施加到机器人上的任何关节级摩擦力或扰动。具体来说, 对于接触力, $\mathbf{J}_c(q) \in \mathbb{R}^{n_c \times n}$ 是接触雅可比矩阵, 接触力 (n_c) 的维度会随着机器人与地面接触的支撑腿数量不同而变化 (范围从无支撑腿到双支撑腿)。

3) 系统辨识与自适应控制: 对于像 Cassie 这样的双足机器人的运动控制, 我们可以借鉴系统辨识和自适应控制的思想, 这些方法能够适应机器人动力学的变化。一种方法是利用过去系统的输入和输出 (I/O 历史) 序列来辨识系统参数并随时间改变控制律, 参见 [95, 第 9] 章。例如, 对于由 (1) 式支配的动力系统 (双足机器人), 通过利用机器人的输入序列 (τ) 和输出序列 (o), 并假设系统状态 (q 及其时间导数) 可以由 o 的序列近似 (如 [96], 中推导的那样), $\mathbf{M}$ 、 $\mathbf{C}$ 、 $\mathbf{G}$ 、 κ 中的建模参数以及外力 ζ_{ext} 可以被辨识, 因此 (1) 式中的控制策略可以相应调整。自适应控制有两种主要设计选择: 间接方法和直接方法。在间接方法中, 首先显式估计系统参数 (参见 [97]), 然后基于辨识出的参数间接调整控制律。相比之下, 直接方法则直接基于系统的 I/O 历史改变控制律。虽然这两种方法各有优缺点 (如 [4], 中所述), 间接方法可能难以处理未知或难以辨识的系统参数。因此, 在本文中, 我们选择通过无模型强化学习开发控制策略, 从双足机器人的 I/O 历史中学习, 以直接适应机器人全阶模型 (1) 的变化。我们的方法旨在与直接自适应控制类别保持一致, 而不同于 Teacher-Student [71] 或 RMA [74] 等需要估计预设系统参数的策略, 这些策略可被视为间接方法。

B. 强化学习预备知识

1) 将腿部运动控制建模为部分可观测马尔可夫决策过程: 双足机器人的运动控制可以建模为部分可观测马尔可夫决策过程 (POMDP)。在每个时间步 t , 环境处于状态 s_t , 智能体 (即, 机器人) 从环境中获得观测 o_t , 执行动作 a_t 并与环境交互, 环境转移到新状态 s_{t+1} , 智能体获得奖励 r_{t+1} 。该过程将重复进行, 直到长度为 T 的回合结束。在 POMDP 中, 机器人只能获取环境的部分信息, 例如, 双足机器人只能访问可观测状态 o , 而非完整

环境状态，包括完整的坐标 $\mathbf{q}$ 及其时间导数，如第 IV-A1 节所述。在部分可观测马尔可夫决策过程（POMDP）中，观测值 $\mathbf{o}_t$ 由观测函数 $O(\mathbf{o}_t|\mathbf{s}_t, \mathbf{a}_{t-1})$ 获得，该函数同时依赖于当前环境状态和智能体已采取的动作。强化学习的目标是通过寻找最优策略 π^* 来最大化期望回报 $\mathbb{E}[\sum_{t=0}^T \gamma^t r_t]$ ，该策略在每个时间步选择动作 $\mathbf{a}_t$ 。期望回报是智能体在一个回合中收集的折扣奖励之和，其中 γ 表示折扣因子。

2) 利用输入 / 输出历史求解 POMDP：求解 POMDP 可以表述为寻找最优策略 π^* ，该策略将过程历史映射到最优动作。时间步 t 处的过程历史包含智能体观测值和动作的完整历史，即 $\{<\mathbf{o}_t, \mathbf{a}_{t-1}>, <\mathbf{o}_{t-1}, \mathbf{a}_{t-2}>, \dots, <\mathbf{o}_1, \mathbf{a}_0>\}$ [98]。在控制语境中，这对应于机器人的输入 / 输出历史。一种方法是在每个时间步通过贝叶斯滤波器从过程历史更新信念状态，然后将 POMDP 转化为信念状态 MDP。另一种方法是构建一个有限状态控制器（FSC）该控制器通过内部状态存储智能体过去的观测值和动作记忆，以构成并优化策略图 [98, 第 4] 章。虽然寻找最优策略需要完整历史，但计算上难以处理。相反，可以在 FSC 中保留有限记忆，并近似求解 POMDP（见 [99]）。所有这些方法都利用机器人的过程历史（即输入 / 输出历史）来求解 POMDP。因此，我们选择训练一个具有固定长度 h 的机器人输入 / 输出对有限记忆的策略，即 $\pi(\mathbf{a}_t|\mathbf{o}_{t:t-h}, \mathbf{a}_{t-1:t-h-1})$ 。此外，在本工作中，为使机器人能够完成多种目标，我们使用指令 $\mathbf{c}$ 对任务进行参数化，策略 $\pi(\mathbf{a}_t|\mathbf{o}_{t:t-h}, \mathbf{a}_{t-1:t-h-1}, \mathbf{c}_t)$ 现在同时依赖于机器人的输入 / 输出历史和给定的指令 $\mathbf{c}_t$ 。

3) 任务参数化：不同的运动任务通过一个命令进行参数化，且这种参数化可能因不同的运动技能而异。对于行走技能，命令 $\mathbf{c}_{\text{walk}} \in \mathbb{R}^4$ 定义为 $[q_{x,y}^d, q_{z,\psi}^d]$ ，分别指定了矢状面 q_x^d 和横向 q_y^d 方向上的期望行走速度、期望行走高度 q_z^d 以及期望转向偏航角 q_ψ^d 。对于奔跑技能，命令表示为 $\mathbf{c}_{\text{run}} = [q_{x,y}^d, q_\psi^d] \in \mathbb{R}^3$ 。对于跳跃，命令 $\mathbf{c}_{\text{jump}} \in \mathbb{R}^4$ 定义为 $[q_{x,y,\psi}^d, e_z^d]$ ，分别指定了目标平面位置 $q_{x,y}^d$ 、转向角度 q_ψ^d 以及机器人落地后垂直跳跃方向上的高度变化 e_z^d 。

V. 基于输入 / 输出历史的双足运动控制器

在本节中，我们描述了所提出的双足机器人通用控制框架，该框架利用机器人的双输入 / 输出历史作为基本要素，以实现向具有不确定动力学环境的迁移。该控制架构是本研究开发的强化学习系统的基础，将在仿真和现实世界中展现出控制性能方面的优势。




图 3: 所提出的基于强化学习的控制器架构，该架构利用了机器人的输入（ $\mathbf{a}$ ）和输出（ $\mathbf{o}$ ）（I/O）双历史。控制策略 π_θ 以 33 Hz 的频率运行，处理 2 秒长的 I/O 历史。这些数据首先通过一维卷积神经网络沿时间轴进行编码，然后与基础多层感知机合并。此外，一个跨越 4 个时间步的短历史直接输入到基础多层感知机中，并与特定技能参考运动 $\mathbf{q}_t^r$ 以及参数化任务的可变命令 $\mathbf{c}_t$ 相结合。策略输出期望的电机位置 $\mathbf{q}_m^d$ 作为机器人的动作，然后通过低通滤波器进行平滑处理。这些滤波后的输出被关节级 PD 控制器（以 2 kHz 运行）用于指定电机扭矩 τ 。该架构适用于各种运动技能，如站立、行走、奔跑和跳跃。该图还标注了 Cassie 的广义坐标，包括主动关节（ $q^{L/R}_{1,2,3,4,7}$ ，标记为红色）和被动关节（ $q^{L/R}_{5,6}$ ，标记为蓝色）。

控制框架：我们的运动控制策略由具有参数 θ 的深度神经网络表示。相同的策略架构将用于各种不同的运动技能，因此其设计旨在尽量减少特定技能的设计选择。如图 3 所示，策略输出机器人期望的电机位置 $\mathbf{q}_m^d \in \mathbb{R}^{10}$ ，即智能体的动作 $\mathbf{a}_t$ 。该动作首先通过低通滤波器（LPF）进行平滑处理 [83]，其细节在附录 A 中讨论。滤波后的动作随后由关节级 PD 控制器用于计算将施加到机器人驱动关节上的电机扭矩 τ 。策略以 33 Hz 的频率进行查询，而 PD 控制器则以更高的 2 kHz 频率运行。

每个时间步 t 的策略输入由四个部分组成：给定指令 $\mathbf{c}_t$ 、参考运动 $\mathbf{q}_t^r$ 、机器人的短期输入 / 输出历史 $<\mathbf{o}_{t:t-4}, \mathbf{a}_{t-1:t-4}>$ ，以及机器人的长期输入 / 输出历史 $<\mathbf{o}_{t:t-65}, \mathbf{a}_{t-1:t-66}>$ 。时变指令 $\mathbf{c}_t$ （如第 IV-B3 节所定义）表示机器人使用所需运动技能要完成的任务。运动技能由当前时间步 t 的技能特定参考运动 $\mathbf{q}_t^r$ 的预览指定。它包括机器人期望的电机位置 $\mathbf{q}_t^r = [\mathbf{q}_m^d(t+1), \mathbf{q}_m^d(t+4), \mathbf{q}_m^d(t+7)]$ ，这些位置在向前 1、4 和 7 个时间步处采样。参考运动的预览向机器人传达即将到来的期望轨迹，帮助其避免短视。如果期望的基础高度未包含在指令 $\mathbf{c}_t$ 中（例如在跑步和跳跃时），则参考运动 $\mathbf{q}_t^r(t)$ 中的当前基础高度也会包含在 $\mathbf{q}_t^r$ 中。

机器人输入 / 输出历史的使用：除了上述观测值外，观测值还包括机器人输入和输出（I/O）的历史记录，用于控制策略。如图 3 所示，输入由期望的电机位置（机器人的动作 $\mathbf{a}$ ）表示，而

机器人的可观测状态（记为 $\mathbf{o}$ ，详见第 IV-A1 节）代表了输出。该历史信息通过两个流进行处理，我们称之为双历史方法。第一个流提供机器人最近四个时间步的输入 / 输出（I/O）历史，直接作为基础网络的输入。这段约 0.1 秒的短历史为机器人提供了实时控制所需的近期反馈。除短历史外，一个跨越两秒的较长 I/O 历史也作为策略的输入。该长历史包含 66 对机器人 I/O 数据（ $\langle \mathbf{o}_{t-k}, \mathbf{a}_{t-k-1} \rangle, k \in [0, 65] \cap \mathbb{Z}$ ）。这段长 I/O 历史更有助于识别系统动力学，涵盖低通滤波器（LPF）、PD 控制器、由公式 (1) 描述的机器人本体及其状态估计器等要素。这种结构使控制器能够有效利用短期和长期 I/O 历史信息。充分利用这两类信息至关重要。长期历史有助于系统辨识和状态估计推断，尤其适用于飞行阶段中的弹道运动。短期历史从两个角度也很重要：它能提供机器人近期测量的显式反馈，这对实时控制至关重要；同时能帮助机器人判断过去信息的重要性（某些情况下过去信息可能并不重要）。如第 VII 节所示，这种双历史结构显著提升了双足运动控制的性能。

策略表示细节：如图 3 所示，策略架构 π_θ 包含两个主要组件：一个由多层感知机（MLP）建模的基础网络，以及一个由一维卷积神经网络（CNN）建模的长期历史编码器，该编码器计算长历史的嵌入表示并作为基础网络的输入。基础 MLP 有两个隐藏层，每层包含 512 个 $\tanh$ 单元。一维 CNN 编码器包含两个隐藏层，其配置定义为 [卷积核大小、滤波器数量、步长]，分别为 [6, 32, 3] 和 [4, 16, 2]，均采用 relu 激活函数且无填充。66 时间步的长期 I/O 历史通过该 CNN 编码器沿时间轴进行时序卷积，然后压缩为潜在表示，再作为输入提供给基础 MLP。基础 MLP 的输出层包含 $\tanh$ 单元，用于指定归一化动作（相对于电机范围）的高斯分布均值。动作分布的标准差由固定值 0.1I 指定。

不同技能通用策略结构：图 3 中介绍的控制策略结构是一种通用设计，可广泛应用于多种运动技能，如站立、行走、奔跑和跳跃。为了训练不同运动技能的策略，用户只需向策略提供不同的参考动作和指令，而策略的底层架构保持不变。在本文中，所有实验将使用相同的控制策略架构。




图 4：多阶段训练框架，用于获得可零样本迁移到现实世界的多功能控制策略。该框架从单任务训练阶段开始，在此阶段机器人被鼓励模仿具有固定目标的单一参考动作。随后是任务随机化阶段，该阶段扩展了机器人学习的任务范围，并促进任务泛化，从而形成多功能策略。一旦机器人熟练掌握了各种运动任务及其转换，便会引入广泛的动力学随机化，以增强策略的鲁棒性，实现从仿真到现实的迁移。该框架适用于多种双足运动技能，包括行走、奔跑和跳跃，并适用于从不同来源（如轨迹优化、人体动作捕捉和动画）学习特定技能的参考动作。

VI. 面向多功能运动控制器的多阶段训练

在构建双足运动控制器之后，我们在本节中的下一步是开发一个通过强化学习训练控制策略的通用框架。与控制结构类似，该训练框架不仅限于单一特定运动技能，而是适用于多种技能。该框架旨在仿真环境中训练机器人，并无需进一步微调即可迁移到机器人硬件上。

A. 概述

通过单一控制策略训练机器人完成多样化任务是一项挑战。当处理高度动态的运动动作（如不同奔跑速度或跳跃到不同位置）且机器人支撑有限时，这一挑战更加严峻。在此类场景中，机器人往往难以有效学习，并可能采取过于保守的策略（例如仅站立）来规避挑战。因此，我们开发了一种多阶段训练策略，结合结构化课程以促进多功能运动控制策略的训练。该策略可总结为如图 4 所示的三个阶段：（1）单任务训练，（2）任务随机化，以及（3）动力学随机化。在第一阶段，我们专注于训练机器人从零开始掌握一项运动技能，使用固定指令。主要目标是使机器人具备掌握技能本身的能力，例如仅向前行走、向前奔跑，

或原地跳跃，同时避免不良的机动策略。在第二阶段，我们引入多样化的指令，鼓励机器人利用已掌握的技能执行大量任务，以发展出多功能策略。在机器人于简单仿真环境中表现出熟练度后，第三阶段在仿真中实施广泛的动力学参数随机化。此过程旨在增强策略的鲁棒性，确保从仿真到机器人硬件的零样本迁移成功。

POMDP 的设计（包括奖励和回合设计等方面）在不同阶段可能确实有所不同，以服务于特定目标。然而，整体的多阶段训练方案仍然是开发不同运动技能的通用方法，并且正如我们将看到的，该方法仅需更改技能特定的参考运动和学习不同技能的超参数。

结合站立技能：学习双足机器人的站立技能对于在现实世界中部署非常有用，因为机器人可能在行走、奔跑或跳跃后需要停下来。在非周期性跳跃技能的背景下，机器人学习在着陆后阶段保持站立姿态，同时掌握跳跃技能。然而，这种站立技能并未为行走和奔跑等周期性技能引入。为解决这一差距，在第二阶段，我们引入了一个额外的子阶段，使机器人在获得多功能策略后能够学习过渡到站立（并返回），具体细节见附录 B。虽然先前的方法已探索使用单独的策略进行此类过渡，如 [22]，所示，我们的工作展示了使用单一策略在站立与其他运动技能之间过渡的优势。这种方法不仅能实现快速过渡，还能使机器人泛化所学运动技能，显著提高站立时的鲁棒性。

B. 参考运动

对于每种运动技能，我们提供一个或一组参考运动，这些运动提供了机器人要执行的运动机动类型的示例。如图 4 所示，我们的框架可以容纳多样化的参考运动来源，包括来自轨迹优化、动作捕捉和关键帧动画的参考运动。

轨迹优化：对于行走技能，我们利用轨迹优化方法生成一个参考运动库，该库基于机器人的全阶动力学描述了多种周期性行走步态。生成的步态库由行走指令

$[\dot{q}_x^d, \dot{q}_y^d, \dot{q}_z^d]$ 参数化，范围从 $[-1.0, -0.3, 0.65]$ 到 $[1.0, 0.3, 1.0]$ ，包含 1331 个不同的参考运动。每个参考运动由每个驱动电机的 B'ezier 轨迹集合表示，具有固定的行走周期时长（0.8 秒）。生成步态库过程的更详细描述见 [8, 第 III-B 节] 和 [26]。请注意，在构建参考步态库时，我们不考虑转向偏航指令 $\dot{q}_\psi^d$ 。

动作捕捉：用于跑步技能的参考运动来源于从

人类演员 [100] 收集的动作捕捉数据。我们使用逆运动学将原始人类运动重新定位到 Cassie 的形态上。此过程涉及匹配人类与机器人之间关键点（如骨盆和脚趾）的运动。关于重新定位过程的更多细节见 [8, 第 II-B 节]。请注意，我们只有一个单一的周期性跑步参考运动，平均速度为 3 米/秒，腾空时脚部离地间隙约为 0.1 米，没有横向或转弯运动。我们还重新定位了一个单一的从跑步到站立的过渡人类运动，作为 Cassie 在两种行为之间转换的参考运动。

动画：我们使用动画技术为跳跃技能提供参考运动。机器人的跳跃运动直接在 3D 动画创作套件中手工制作。与跑步类似，我们只提供一个单一的原地跳跃动画作为参考运动，其最高脚部高度为 0.5 米，跳跃时长 $T_J = 1.66$ 秒，并以站立姿势结束。对于有兴趣为双足机器人创建动画的读者，请参考 [8]。

请注意，我们并未执行轨迹优化来将从动作捕捉或动画中获得的运动学可行参考运动转换为机器人动力学可行的运动。

C. 奖励

我们现在制定奖励函数 r_t ，智能体在每个时间步 t 接收该函数，以鼓励机器人执行所需的运动技能并完成所需任务。在本工作中，智能体接收的奖励 r_t 是多个奖励分量的加权和 $\mathbf{r}$ ，即， $r_t = (\mathbf{w}/\|\mathbf{w}\|_1)^T \mathbf{r}$ ，其中分量向量 $\mathbf{r}$ 和权重向量 $\mathbf{w}$ 列于表 III 中。 $\mathbf{r}$ 中的每个元素均采用以下格式：

$$r(\mathbf{u}, \mathbf{v}) = \exp(-\alpha \|\mathbf{u} - \mathbf{v}\|_2). \quad (2)$$

通过最大化 (2)，机器人被激励去最小化两个向量 $\mathbf{u}$ 和 $\mathbf{v}$ 之间的距离。在 (2) 中，每个项引入不同的缩放因子 $\alpha > 0$ 以归一化单位，从而得到输出范围 (0, 1]。

1) 奖励分量：奖励 r_t 包含三个关键项：（1）运动跟踪，（2）任务完成，以及（3）平滑。每个项由若干独立的奖励分量组成，每个分量服务于特定目标，详见表 III。

运动跟踪：运动跟踪项旨在激励智能体遵循特定技能的参考运动。该目标通过多个分量实现，包括电机位置奖励 $r(\mathbf{q}_m, \mathbf{q}_m^r(t))$ 、全局骨盆高度 $r(q_z, q_z^r(t) + \delta_z)$ 以及每个时间步的全局足部高度 $r(\mathbf{e}_z, \mathbf{e}_z^r(t) + \delta_z)$ 。在参考垂直位移中加入 δ_z 以考虑地形高度的变化，例如当机器人在奔跑时遇到变化的地形（ $\delta_z :=$ 随时间变化的地形高度）或跳跃到不同高度时（ $\delta_z :=$ 不随时间变化的目标抬升高度）。奖励中使用了部分特权环境信息，例如机器人的全局高度 q_z 、足部高度 $\mathbf{e}_z$ 或地形高度。

表 III: 用于训练双足机器人在不同技能和训练阶段中的奖励函数组成部分 $\mathbf{r}$ 及其各自权重 $\mathbf{w}$ 。针对不同组成部分提供了一个名义权重向量, 需要根据技能和训练阶段进行调整, 主要受任务多样性 (针对单一目标训练与多样化目标训练) 以及是否存在飞行阶段的影响。奖励调优过程相对简化, 因为在多阶段训练中, 三种不同双足运动技能中仅有 24 个奖励项 (共 72 个) 发生变化。空白单元格表示对应的名义值无变化。

Reward Component $\mathbf{r}$	Nominal Value	Weight $\mathbf{w}$					
		Walking Skill		Running Skill		Jumping Skill	
		Stage 1	Stage 2, 3	Stage 1	Stage 2, 3	Stage 1	Stage 2, 3
Motion Tracking							
Motion position: $r(\mathbf{q}_m, \mathbf{q}_m^r(t))$	15						-7.5
Pelvis height: $r(q_z, \dot{q}_z^r(t) + \delta_z)$	5						-2
Foot height: $r(\mathbf{e}_z, \mathbf{e}_z^r(t) + \delta_z)$	10	-7	-7				
Task Completion							
Pelvis position: $r(q_{x,y}, q_{x,y}^d)$	7.5	-1.5	-1.5			+5.5	+7.5
Pelvis velocity: $r(\dot{q}_{x,y}, \dot{q}_{x,y}^d)$	15					-15	-2.5
Pelvis orientation: $r(\cos(q_{\phi,\theta,\psi}, [0, 0, \dot{q}_{\psi}^d]), 1)$	10	-2.5	+2.5	-5		+2.5	
Pelvis angular rate: $r(\dot{q}_{\phi,\theta,\psi}, [0, 0, \dot{q}_{\psi}^d])$	3				+4.5		+7
Smoothing							
Foot Impact: $r(F_z, 0)$	10	-7				-5	
Torque: $r(\boldsymbol{\tau}, 0)$	3						
Motor velocity: $r(\dot{\mathbf{q}}_m, 0)$	0				+3		
Joint acceleration: $r(\ddot{\mathbf{q}}, 0)$	3						-3
Change of action: $r(\mathbf{a}_t, \mathbf{a}_{t+1})$	3			+2	+2	-3	+7

δ_{z0} 。这些项使机器人在训练过程中更好地了解环境和当前状态, 但被排除在智能体的观测之外。我们将在奖励中频繁看到这种对特权信息的利用。

任务完成: 我们在奖励中引入任务完成项, 以确保机器人利用所获得的运动技能完成指定任务。在该项中, 我们通过包含 $r(\dot{q}_{x,y}, \dot{q}_{x,y}^d)$ 和 $r(\dot{q}_{\phi,\theta,\psi}, [0, 0, \dot{q}_{\psi}^d])$ 分别激励机器人使其运动与期望速度和转向率对齐。此外, 我们在奖励中引入了全局位姿跟踪组件 $r(q_{x,y}, q_{x,y}^d)$ 和 $r(\cos(q_{\phi,\theta,\psi} - [0, 0, \dot{q}_{\psi}^d]), 1)$ 。注意, 对于朝向跟踪项, 我们选择将 1 与朝向误差的余弦值在 $[-\pi, \pi]$ 范围内匹配, 以避免机器人在 $-\pi$ 和 π 之间过渡时出现奇异性。此外, 由于本工作不考虑机器人横滚角和俯仰角的变化 ($q_{\phi,\theta}$), 我们将 $q_{\phi,\theta}^d$ 及其变化率 $\dot{q}_{\phi,\theta}^d$ 设为零, 这有助于稳定机器人的骨盆。对于周期性行走和跑步技能, 首先提供期望速度 $\dot{q}_{x,y,\psi}^d$, 并通过随时间积分相应指令来计算位置项 $q_{x,y,\psi}$ 。相反, 对于非周期性跳跃技能, 首先指定期望的 (时不变) 着陆目标 $q_{x,y,\psi}$, 并引入平均速度项以将稀疏的位置奖励塑形为 $\dot{q}_{x,y,\psi}^d = q_{x,y,\psi}^d / T_J$, 其中 T_J 为跳跃时间跨度。

平滑项: 最后, 我们还添加了一个平滑项, 以阻止机器人学习生硬的行为。我们通过 $r(F_z, 0)$ 激励机器人减少冲击力, 通过 $r(\boldsymbol{\tau}, 0)$ 降低能耗, 通过最小化电机速度 $r(\dot{\mathbf{q}}_m, 0)$ 产生平滑运动, 通过 $r(\ddot{\mathbf{q}}, 0)$ 抑制关节加速度, 并调节动作的变化 $r(\mathbf{a}_t, \mathbf{a}_{t+1})$ 。

2) 奖励权重: 通过采用不同的权重选择 $\mathbf{w}$, 我们可以强调某些奖励项对机器人性能更为关键, 同时降低其他项的重要性, 从而影响机器人习得的动作。在这项工作中, 尽管涵盖了不同的动态

运动技能, 并且每个技能包含多个训练阶段, 我们证明了奖励组件及其相关权重值符合统一的选择 (即, 表 III 中的标称值), 适用于不同的技能和阶段。这种同质化可以通过根据调节特定权重的一般原则进行一些调整来实现, 详见表 III 及下文介绍。

不同阶段的权重: 在阶段 1 中, 涉及从零开始对特定运动技能进行初始训练, 我们重点训练机器人掌握所需技能。因此, 运动跟踪项的权重在奖励中占主导地位, 鼓励机器人紧密模仿参考运动。随着机器人熟练掌握所需技能, 进入阶段 2 (命令随机化) 时, 我们可以调整任务完成项的权重, 使其超过其他项。这一调整旨在激励机器人完成不同任务, 尤其是超出参考运动范围的任务, 例如在行走之外执行转弯动作、超出单一跑步参考运动的各种跑步和转弯速度, 以及超出单一原地跳跃动画的各种着陆目标。为了防止机器人在初始训练期间采取过于保守的行为, 平滑项的权重保持相对较低。随着机器人巩固其运动技能, 该项可以逐渐增加以优化机器人的动作。但该项在多个阶段中始终是最低的。

不同技能之间的权重: 如表 III 所示, 不同运动技能之间的权重差异通常不大, 主要区别在于技能中是否存在腾空阶段。值得注意的是, 在跑步和跳跃等涉及显著腾空阶段的技能中, 运动跟踪项对于脚部高度 $r(\mathbf{e}_z, \mathbf{e}_z^r(t) + \delta_z)$ 的权重比行走技能更大。此外, 为了鼓励机器人应对腾空阶段带来的挑战, 同时

为了偏离参考动作以探索多样化的任务，我们为任务完成项分配了更高的权重。平滑项在不同技能间基本保持一致，但进行了一些调整，例如将动作项 $r(\mathbf{a}_t, \mathbf{a}_{t+1})$ 更改为增强跑步和跳跃等剧烈运动的平滑效果。

D. 回合设计

1) 统一方法：在本研究开发的所有多样化运动技能和训练阶段中，回合设计保持一致且统一。回合时长设置为 2500 个时间步，对应总时长 76 秒。在引入可变任务的第二阶段，我们在随机时间间隔（1 秒到 15 秒之间）后随机化指令。每个任务均匀随机化指令的具体范围详见附录 C 中的表 VI。请注意，我们采用较长的回合周期，以使机器人能够探索不同任务之间转换的更多场景。

对于跳跃等非周期性任务的第一阶段，回合长度有一个例外。在这种情况下，回合长度被调整为覆盖完整的轨迹（例如，跳跃动作 1.66 秒），并显著延长，以使机器人学会在落地后保持最后的站立姿势。在本工作中，跳跃的第一阶段训练使用了 750 个时间步（22 秒）。

2) 提前终止条件：在双足机器人上训练动态运动技能时，仅依赖奖励设计可能不够。机器人可能仍会表现出不良行为，尽管获得了次优回报，例如保持站立姿势而不进行运动，因为机器人可以轻易通过这种方式获得部分奖励。为解决此问题，除了标准终止条件（如机器人摔倒（ $q_z < 0.55\text{m}$ ）或附关节 $q_6^{L/R}$ 触地）外，我们在所有技能和阶段中增加了两个额外的终止条件，如下所述。

足部高度跟踪容差：如果机器人足部高度与其参考运动之间的偏差超过阈值 E_e ，则情节将提前终止，即，如果 $|\mathbf{e}_z - \mathbf{e}_z^*(t) - \delta_z| > E_e$ 。经验发现，该条件在促进涉及飞行阶段的运动技能（如奔跑和跳跃）的发展方面特别有效。如果没有针对运动跟踪的这一条件，尤其是在训练的初始阶段，机器人往往会大部分时间停留在地面上。对于缺乏飞行阶段的技能（如行走），仍然可以加入这一条件，尽管可能并非必要。

任务完成容差：我们通过引入一个基于机器人偏离指令基座位置和姿态的条件，向机器人强调任务完成的重要性， $|q_{x,y,\psi} - q_{x,y,\psi}^d| > E_t$ ，其中 E_t 是可接受的跟踪误差阈值。对于行走和奔跑，我们持续检查该条件，以鼓励机器人减少累积的跟踪误差。在跳跃的情况下，该条件在机器人落地后进行评估，激励机器人跳向指定目标。

表四：动力学随机化范围。向机器人基座引入模拟外部扰动或加入可变地形是可选的，但建议仅在机器人学会处理一般动力学随机化之后进行。然而，对于高度动态的技能（如非周期性跳跃），外部扰动可能不会增强鲁棒性，反而可能阻止机器人学习有意义的动作。

Parameters	Range
Dynamics Randomization (General)	
Ground Friction Coefficient	[0.3, 3.0]
Joint Damping Ratio	[0.3, 4.0] Nms/rad
Spring Stiffness	[0.8, 1.2] $\times$ default
Link Mass	[0.5, 1.5] $\times$ default
Link Inertia	[0.7, 1.3] $\times$ default
Pelvis (Root) CoM Position	[-0.1, 0.1] m in $q_{x,y,z}$
Other Link CoM Position	[-0.05, 0.05] m $\times$ default
Motor PD Gains	[0.7, 1.3] $\times$ default
Motor Position Noise Mean	[-0.002, 0.002] rad
Motor Velocity Noise Mean	[-0.01, 0.01] rad/s
Gyro Rotation Noise	[-0.002, 0.002] rad
Linear Velocity Estimation Error	[-0.04, 0.04] m/s
Communication Delay	[0, 0.025] s
External Perturbation (Optional)	
Force & Torque	[-20, 20] N & [-5, 5] Nm
Elapsed Time Interval (Walking)	[0.1, 3.0] s
Elapsed Time Interval (Running)	[0.1, 1.0] s
Randomized Terrain (Optional)	
Terrain Type	Waved, Slopes, Stairs, Steps

不同阶段的容差：误差阈值 E_e 和 E_t 可能需要根据训练进展进行调整，具体取决于机器人对所需运动技能的熟练程度。例如，足部高度跟踪误差阈值 E_e 可能在初始阶段（阶段 1）从严格约束开始，并在后续阶段逐步放宽。理想情况下，该条件最终可以完全移除。这一策略为机器人在后期阶段探索多样化动作提供了更大的灵活性，从而超越所提供的参考运动的能力。相比之下，跟踪误差阈值 E_t 可以在训练过程中逐渐减小，因为机器人变得更加擅长运动，并能更加强调任务完成。尽管技能多样，我们在多个训练阶段中观察到这种容差调整的一致趋势。

E. 动力学随机化

如图 4 所示，在训练阶段 3 中，我们在仿真环境中引入随机化的动力学参数，以训练一个能够保持鲁棒性并将已获得的运动技能泛化以应对动力学建模与测量不确定性的策略。该训练的目标是实现从仿真到动力学参数不确定的真实世界场景的成功迁移。在每个回合中，如表 IV 所详述，动力学参数从各自的均匀分布中采样。

具体而言，为应对建模不确定性，我们引入了建模参数的广泛随机化，包括地面摩擦系数、机器人关节阻尼比，以及每个连杆的质量、惯性和质心位置。对于采用板簧连接被动关节的 Cassie 机器人，引入 $\pm 20\%$ 的板簧刚度随机化对于成功的仿真到现实迁移至关重要，特别是对于跑步和跳跃等涉及弹簧大幅压缩的技能。我们还

将随机化引入关节级 PD 控制器的 PD 增益中，在其默认值基础上增加 $\pm 30\%$ 的偏差范围。这种随机化独立应用于每个关节级 PD 控制器。这激发了运动响应的多样性，能够模拟现实场景中不确定电机动力学的影响，包括电机老化和退化，这被证明有助于促进仿真到现实的迁移。

为了解决测量不确定性，我们向可观测状态 $\mathbf{o}_t$ 添加模拟噪声。该噪声建模为正态分布，其均值从表 IV 指定的范围内均匀采样。请注意，鉴于 Cassie 硬件上可靠的传感器（如关节编码器和 IMU），我们应用的测量噪声范围较小。然而，对于配备较低质量传感器的机器人，可能需要更宽的模拟噪声范围。此外，我们模拟了策略与机器人实时计算机之间的通信延迟（由零阶保持器引起），这会影响发送动作和接收观测的时间。对于高度动态的运动，如跳跃和奔跑，延迟在仿真到现实的差距中起着重要作用，而在实时控制中处理延迟的能力对稳定性至关重要。

上述随机化策略一致地应用于各种运动技能。此外，我们还研究了训练中使用其他随机化来源的情况，包括随机扰动和随机地形，具体如下所述。

随机扰动的使用：在我们的研究中，我们探索了将随机外部扰动 wrench 应用于机器人骨盆，假设这可以创造更多样化的训练场景，并通过使机器人偏离其标称轨迹来增强鲁棒性。这种扰动（通常是脉冲力）包含随机持续时间的力和扭矩，如表 IV 所指定，可以在训练过程中模拟。然而，我们发现，虽然这种方法可以增加策略在现实应用中的鲁棒性，但它引入了复杂且难以选择的超参数，并使训练过程复杂化。对于行走，频繁的扰动导致对扰动场景的过度强调，损害了机器人在正常行走步态中的表现。在奔跑中，较长时间的扰动阻碍了机器人学习有效步态的能力。因此，我们对行走和奔跑采用了不同的时间间隔，如表 IV 所示。此外，对于跳跃技能或从运动到站立的过渡，这些扰动被证明更加成问题，阻止了机器人获得有意义的跳跃或站立能力。因此，我们选择在跳跃和过渡到站立技能的训练中排除外部扰动。

使用随机地形：如果控制策略旨在使机器人能够穿越不平坦的地形，那么在训练过程中模拟地形变化至关重要。我们开发了一种算法，利用参数化高度图随机生成各种类型的地形，包括波形地形（以正弦函数为特征）、斜坡地形、单调楼梯和随机台阶，如表 IV 所列。重要的是

要注意的是，我们的控制策略不包含视觉，因此机器人必须根据其输入 / 输出历史来适应地形变化，这使得问题更具挑战性。建议仅在机器人通过其他动力学随机化训练得足够熟练之后，再引入地形随机化，以避免过高的学习复杂度。在本研究中，我们以跑步技能为例引入了地形随机化。

F. 训练细节

我们基于 [101, 102]，使用 MuJoCo 在上述环境中开发了 Cassie 的仿真。所有控制策略的训练均在仿真中采用 [103] 提出的近端策略优化（PPO）进行。控制策略（演员）如第五节所述，其价值函数由一个能够访问真实观测值的双层 MLP 表示。鉴于不同训练阶段和技能的复杂度各异，各阶段和技能的训练迭代次数也有所不同。迭代次数及其他超参数分别见附录 D 中的表 VII 和表 VIII。

至此，我们已介绍了所提出的用于学习多功能、鲁棒且动态双足运动技能的强化学习框架的设计细节。接下来，我们将验证几个关键设计组件。

VII. 策略架构的优势

在本节中，我们首先通过对其设计选择进行广泛的消融研究，评估所提出的双足运动控制框架在第五部分中的优势。这一评估从两个关键角度展开：（1）在具有广泛随机动态参数的挑战性模拟环境中的学习性能，以及（2）在真实机器人上进行模拟到现实迁移时的控制性能，无需任何调整。模拟提供了一个受控环境，用于测试控制架构在系统动力学大幅变化时学习控制策略的能力，而真实世界实验则允许我们评估在机器人硬件固定但不确定的动态条件下的控制效果。正如我们将展示的，我们提出的双历史控制架构和训练系统表现出最佳的学习性能和模拟到现实的迁移效果。

A. 基线方法

我们将所提出的控制器结构与下面列出的其他基线方法进行比较，如图 5 所示。这些基线方法的选择包括对本工作中提出的若干设计选择的消融：（1）动作空间的选择，（2）仅使用机器人输入 / 输出历史或状态反馈历史，（3）历史长度（长历史或短历史），（4）双历史或仅长历史，（5）端到端训练或策略蒸馏。实验中使用的模型包括：

- **我们的方法**（图 5a）：如图 3 所示，我们的架构同时利用短期和长期输入 / 输出历史，其中长期历史由 CNN 编码，而短期历史直接输入基础 MLP。CNN 和 MLP 联合训练，策略输出指定期望的电机位置。

- **残差方法**（图 5b）：该架构与我们的提议一致，但其输出表示一个残差项，该残差项




图 5: 我们提出的以及各种基于强化学习的双足机器人运动控制策略架构的基线方法示意图。图 5a, 我们的方法集成了短期和长期的输入 / 输出历史, 基础 MLP 和长历史编码器联合训练以指定电机位置。图 5b, 残差方法与我们的架构一致, 但在参考电机位置上增加了一个残差项。图 5c, 仅状态反馈基线使用我们的模型结构, 但仅依赖机器人状态历史, 排除输入历史。图 5d, 仅长历史方法依赖长输入 / 输出历史而不使用短输入 / 输出历史, 而仅短历史方法 (图 5e) 仅关注短期输入 / 输出历史, 排除 CNN 编码器。RMA/ 教师 - 学生方法利用两阶段策略蒸馏, 专家 (教师) 策略 (图 5f) 指导 RMA (学生) 策略

(图 5g) 的训练, 该策略可通过 A-RMA (图 5h) 改进, A-RMA 引入了一个额外阶段, 其中基础 MLP 被微调, 同时保持长输入 / 输出历史编码器的参数固定。值得注意的是, 本研究中的所有专家、RMA 和 A-RMA 策略都将短期输入 / 输出历史纳入基础 MLP, 这是本工作中的一项新修改, 以便与我们的方法进行公平比较。所有这些架构都将指令和参考运动作为基础 MLP 的输入, 如图 3 所示, 为简洁起见此处省略。

然后将其加到当前时间步的参考电机位置上, 即 a)。这种方法在先前工作中有所采用, 例如。值得注意的是, 机器人通过参考运动作为输入, “知道” 当前要添加的参考电机位置。

仅状态反馈 (图 5c): 该变体保留了与我们的方法相同的模型结构和动作空间。然而, 它在观测上的不同之处在于仅依赖历史状态 (机器人的输出历史), 省略了机器人的输入历史。这种选择, 即不使用短期历史, 在先前工作中更为常见, 例如。

• **仅长历史** (图 5d): 该策略架构仅依赖由 CNN 编码的长期输入 / 输出历史。此配置作为 [74] 中的基线。如 [5] 所述, 基础 MLP 可直接访问机器人即时 (上一时间步) 的状态反馈。为简洁起见, 在本工作中, 仅长历史指提供最新观测 (状态反馈) 以及长历史编码器的方法, 该编码器可使用不同的神经网络架构建模。

• **仅短历史** (图 5e): 该策略仅依赖短期输入 / 输出历史, 排除长期输入 / 输出历史 CNN 编码器。此方法用于 [13] 中的双足运动控制, 并在四足控制 (如 [70, 69, 65]) 中更为常见。

• **RMA/ 教师 - 学生**: 该架构利用策略蒸馏方法, 包含两个训练阶段。首先, 通过 RL 训练一个专家 (教师) 策略 (图 5f), 该策略可访问特权环境信息 (见表 IV)。特权信息由 MLP 编码器编码为 8 维外部向量。此专家 (教师) 策略仅能在仿真中使用。其次, 专家策略用于监督 RMA (学生) 策略 (图 5g) 的训练。RMA 策略复制专家策略的基础 MLP, 并仅

学习利用长输入 / 输出历史编码器来估计教师的外部向量。这种策略蒸馏方法用于 [71, 74], 并在四足运动控制中被广泛采用。

• **A-RMA** (图 5h): 在 RMA 训练之后, 引入一个额外的训练阶段。在此阶段, 长输入 / 输出历史编码器的参数保持固定, 而基础 MLP 通过 RL 再次更新, 如 [67] 所述。值得注意的是, 在实现过程中, 本研究中所有专家、RMA 和 A-RMA 策略均将短输入 / 输出历史纳入基础 MLP, 这是本工作中的一项新修改, 旨在与我们的方法进行公平比较。

对于本工作中研究的每种运动技能 (行走、奔跑和跳跃), 使用我们提出的方法和基线方法, 我们通过第 VI 节介绍的相同多阶段训练框架获得了 3 个策略。这些策略来自相同的超参数选择, 但使用了不同的随机种子。每种策略架构都进行了此操作。换句话说, $3 \times 3 \times 8 = 72$ 获得了不同的控制策略, 代表 3 种运动技能、3 个随机种子、8 种策略架构, 并在下文进行了评估。

B. 学习性能

我们首先通过检查各自的学习曲线, 在仿真中将我们的方法与各种基线方法进行基准测试。我们的重点在于第 3 阶段的训练性能, 如图 6 所示, 这是最具挑战性的阶段, 涉及随机任务和动力学参数。对第 3 阶段的特别强调还源于其在仿真到现实迁移中的关键作用, 这是我们研究中控制真实双足机器人的核心问题。

1) 基准分析: 如图 6 所示, 不同运动技能的学习性能保持一致, 具体分析和总结如下。

动作选择: 我们观察到, 当策略产生残差项 (紫色曲线) 而不是直接指定期望的电机位置时, 不同运动技能的学习性能持续下降。尽管添加的参考动作可能最初加速所需技能的学习, 但添加的参考动作也可能给机器人带来额外的运动。因此, 策略需要花费更多精力来纠正添加的动作, 而不是有效控制机器人, 这在机器人探索超出参考动作的机动时变得更加问题重重。因此, 我们建议读者重新考虑在运动控制中使用残差学习, 无论添加的动作是针对动态可行性 (如行走) 优化, 还是仅限于运动学可行性 (如奔跑或跳跃)。

我们还考虑了另一种动作空间选项: 关节级力矩。强化学习已被用于学习四足和双足机器人的力矩控制, 如 [64] 和 [104] 所示。然而, 力矩控制的高更新频率要求, 例如 [104] 中的 250 Hz, 限制了其利用大量机器人输入 / 输出历史的能力。先前使用力矩控制的方法因此被限制为单时间步的机器人反馈。稍后我们将证明, 更长的输入 / 输出历史 (如 2 秒) 可以提高基于强化学习的控制器的适应性, 但记录和学习如此长的历史




图 6: 使用图 5 所示不同策略结构设计的学习性能。该性能在第三阶段训练期间进行评估, 该阶段同时包含任务随机化和动力学随机化。这些曲线代表来自三个不同随机种子的不同策略训练的平均归一化回合回报, 阴影区域表示最小和最大回报之间的范围。请注意, 跳跃策略没有进行扰动训练, 因为这会使机器人无法学习动态跳跃技能。我们提出的方法在不同技能上始终优于其他基线。值得注意的是, 我们策略的性能与专家策略相当, 后者可以访问特权信息但无法在现实世界中部署。相比之下, 残差方法显示出最差的回报。仅使用长历史记录相比仅依赖短历史记录的策略并没有带来明显优势。事实上, 仅使用短历史记录的策略甚至优于仅使用长历史记录的方法。此外, 即使采用像我们这样的双历史方法, 省略机器人的输入历史 (仅使用状态反馈) 也不会比仅使用短输入 / 输出历史有所改进。学生或 RMA 方法在双足运动控制中表现出显著的回归损失; 特别是在跑步等动态技能中, RMA 无法学习。这表明有必要使用 A-RMA 阶段进行进一步训练, 尽管它需要更多的训练样本, 并且与我们的方法相比回报略低。

对于高频扭矩控制器而言, 长历史记录计算成本高昂, 因为动作 (机器人输入) 历史需要以与控制器相同的频率更新。因此, 我们的基准测试侧重于能够在较低频率下有效运行的策略。

观测选择: 我们提出的方法 (红色曲线) 考虑了机器人的输入 / 输出历史, 与仅依赖机器人输出历史的基线 (粉色曲线) 进行比较, 揭示了一个重要发现: 省略机器人的输入 (动作) 历史会导致学习性能下降, 即使采用相同的策略架构和训练方法也是如此。换句话说, 在观测中仅提供机器人状态反馈的历史是不够的。这一比较说明了在通过无模型强化学习开发控制策略时, 利用机器人的输入和输出历史的关键作用。这种组合的输入 / 输出历史对于控制策略执行系统辨识和状态估计以推断机器人的系统参数和状态至关重要, 从而增强其对不确定动力学和外部扰动的适应性。这一重要性在我们的工作中尤为突出, 因为我们使用有限且带有噪声的延迟测量 (部分可观测性) 来应对高度非线性高维系统 (双足机器人) 的控制。

长历史与短历史: 当仅利用长 I/O 历史 (蓝色曲线) 时, 学习性能无法超越仅使用短 I/O 历史 (橙色曲线) 或其他策略。然而, 当我们按照所提出的方法, 让基础 MLP 直接访问短 I/O 历史, 同时配备长历史编码器时, 最终的学习性能表现出显著提升。这种改进源于实时控制场景, 其中短历史对于获取机器人最近的 I/O 轨迹信息至关重要。虽然长历史也包含这些短期信息, 但在经过编码器后可能变得模糊。因此, 在基础 MLP 中为策略提供显式的短历史访问, 补充了长历史的利用。进一步讨论见第 XI-A 节。此外, 在附录 E 中, 我们探讨了不同历史长度对时间编码的影响。我们发现增加历史长度可以提升训练性能, 但改进会随着历史变长而趋于平缓, 甚至可能因引入冗余信息而阻碍运动控制训练。在本研究开发的所有技能中, 2 秒的历史长度表现始终良好。

对于机器人最近 I/O 轨迹的信息至关重要。虽然长历史也包含这些短期信息, 但在经过编码器后可能变得模糊。因此, 在基础 MLP 中为策略提供显式的短历史访问, 补充了长历史的利用。进一步讨论见第 XI-A 节。此外, 在附录 E 中, 我们探讨了不同历史长度对时间编码的影响。我们发现增加历史长度可以提升训练性能, 但改进会随着历史变长而趋于平缓, 甚至可能因引入冗余信息而阻碍运动控制训练。在本研究开发的所有技能中, 2 秒的历史长度表现始终良好。


备注 1: 在附录 F 中, 我们探讨了使用不同时间编码器 (如 TCN [71] 和 LSTM [12]) 对训练性能的影响。我们发现, 对于编码显式历史长度的非循环策略 (如 TCN), 双历史方法始终能提升学习性能。然而, 对于循环策略 (如 LSTM), 双历史方法并未显著帮助学习。此外, 循环策略往往比非循环策略更容易收敛到次优策略, 并且对不同 MDP (运动技能) 的超参数调优更为敏感。

需要澄清的是, 我们的目的并非质疑特定时间编码结构或长历史的使用。相反, 我们强调的是在处理长历史数据时纳入短历史的重要性, 而长历史数据可以通过多种结构进行编码。

与策略蒸馏方法的比较: 我们的方法将长历史编码器与基础 MLP (红色曲线) 联合训练, 与策略蒸馏方法的比较



图 7: 由图 5 所示不同方法训练的不同策略控制的双足机器人 Cassie 实验快照。测试目标是控制机器人原地行走, 即 $(\dot{q}_x^d, \dot{q}_y^d, \dot{q}_\psi^d) = \mathbf{0}$ 。每张快照由初始化后同一 $1^{\text{st}}, 4^{\text{th}}, 7^{\text{th}}$ 秒拍摄的三帧图像组成。我们的方法表现出较小的漂移 (如图所示, 机器人未离开初始位置), 优于其他方法, 这些方法均导致明显的矢状面和 / 或横向漂移 (用白色箭头标出)。此外, 残差策略未能控制机器人保持稳定步态。这一基准测试凸显了我们提出的架构在零样本迁移后适应真实机器人动力学以实现更好跟踪性能的优势。这些结果在不同随机种子训练的不同策略上保持一致, 如图 8 所示。



(a) 使用与仿真中测试的相同策略的跟踪性能 (零速度) 条形图。(b) 使用获得的行走策略在机器人硬件上测试的跟踪性能 (零速度) 条形图。

图 8: 在仿真 (图 8a) 和真实世界 (图 8b) 的原地行走实验中, 使用不同方法 (图 5) 获得的不同策略的跟踪性能条形图。记录了使用来自不同随机种子但相同方法训练的策略的速度跟踪误差 (平均绝对误差, MAE, $\|\dot{q}_{x,y}\|_2$) 和方向跟踪误差 (MAE, q_ϕ, θ, ψ)。它们分别用绿色和蓝色条形表示。条形高度是三个随机种子的平均跟踪误差, 误差条代表这三个测试的标准差。我们排除了残差方法, 因为它无法维持稳定步态。尽管在仿真中所有方法表现相似, 但当将相同策略迁移到硬件时, 我们的方法在速度跟踪误差和方向跟踪误差上始终优于其他方法。这凸显了所提方法在适应真实世界机器人动力学方面的能力。

将基础 MLP 与历史编码器分开训练的方法 (绿色曲线) 凸显了采用正确训练策略的重要性。我们观察到, RMA (学生) 策略相较于专家策略表现出显著退化, 这主要是由于利用机器人长期历史来估计预选环境参数 (编码到外部向量中) 时存在不可避免的误差。这种 RMA 性能的下降在处理具有挑战性的运动技能 (如跑步) 时尤为突出, 导致其无法学习。A-RMA 通过使用冻结的估计编码器对基础 MLP 进行微调, 可以提升 RMA 性能, 但与我们提出的方法相比仍略有不足, 尽管其训练样本数量显著更多。在编码器难以估计环境参数的跑步场景中, A-RMA 本质上复现了仅使用短期历史策略 (橙色曲线) 的结果, 避免了使用长期历史。值得注意的是, 尽管存在其他可能增强 RMA 学习的方法, 如 [66], 但我们提出的方法始终展现出与专家策略 (即学生策略的理论上限) 相似的性能。重要的是, 我们的方法可在现实世界中部署, 而专家策略则无法实现。

C. 案例研究: 原地行走实验

我们进一步在现实世界中针对图 5 所示的各种方法训练的策略进行了案例研究。我们选择评估控制 Cassie 机器人在无任何调参或全局位置反馈条件下维持原地行走步态的行走策略。这一相对简单的场景可以为训练策略的自适应性提供宝贵见解。如果策略无法适应真实机器人的动力学特性, 即使能有效维持机器人的行走步态, 也可能导致明显的漂移。

如图 7 所示, 结果凸显了显著差异。我们提出的方法展现出明显更低的跟踪误差, 并成功维持了机器人的原地行走, 在矢状面和侧向均观察到最小漂移。相比之下, 使用相同样本数量训练的仅长期历史、仅短期历史以及仅状态反馈的双历史策略, 均导致机器人向左产生显著漂移。此外, RMA 表现出最明显的矢状面偏移, 即使在零速度指令下也会以快速向前行走。虽然 A-RMA 减少了这种矢状面漂移, 但仍存在相当大的侧向移动。此外, 残差策略无法在真实机器人上维持稳定步态。对应的视频记录在表 I 的视频 3 中。

由于我们从不同的随机种子中获得了三个不同的训练策略，我们在使用机器人标称模型的仿真和真实世界中分别测试了这些策略在相同原地行走任务上的表现，并在图 8 中比较了统计结果。评估了机器人在 10 秒测试中的速度 ($\|\dot{q}_{x,y}\|_2$) 和基座姿态 ($q_{\phi,\theta,\psi}$) 跟踪误差 (平均绝对误差, MAE)。需要注意的是,除了指令中包含的转向偏航角 (q_{ψ}) 外,我们还评估了机器人骨盆(基座)侧倾角 q_{ϕ} 和俯仰角 q_{θ} 的跟踪误差。这样做是为了观察哪种控制策略能更好地将机器人稳定在较小的基座侧倾和俯仰运动范围内,因为这些角度理论上应为零。如图 8a 所示,在仿真中原地行走指令下,所有通过不同方法训练的策略在低速和浮动基座姿态方面均表现出相似的良好跟踪性能 (RMA 除外)。然而,当迁移到真实硬件上时 (图 8b), 其他方法表现出显著的速度漂移和浮动基座旋转跟踪误差。例如,仅使用长历史信息的策略在稳定机器人骨盆方面表现最差,出现较大的浮动基座姿态,但在仿真中其基座振荡最小。A-RMA 虽然在仿真中能最好地维持机器人位置,但在真实硬件上会导致机器人明显向左漂移。相比之下,我们的方法实现了更好的仿真到现实迁移性能,性能退化最小,并在指令跟踪和浮动基座稳定方面持续表现出更优的控制性能。这凸显了我们的方法在适应机器人硬件动力学方面的优势。

因此,我们可以得出结论,所提出的方法在弥合仿真与现实差距方面表现出色,在真实环境中有效控制机器人方面展现了更好的性能。

D. 结果总结

为了实现通过强化学习获得动态双足运动技能,本节的结果表明控制策略结构应遵循以下设计选择:(1)让策略直接指定电机级指令,而非使用残余项;(2)利用机器人输入和输出的历史信息,而非仅依赖机器人状态反馈;(3)在使用机器人输入/输出历史时,倾向于包含长期历史,但同时为基础策略中补充短期历史以增强性能,从而形成双历史方法;(4)以端到端方式训练基础策略和历史编码器,因为与策略蒸馏方法相比,这能带来更好的性能,降低训练复杂度和样本需求。

这些设计选择催生了我们提出的策略结构,在模拟中展示了各种动态运动技能上始终最佳的学习性能,并在现实世界中提供了改进的控制结果。

VIII. 适应性的来源

为了理解所提出的方法为何在具有挑战性的

执行具有变化环境参数的动态运动技能场景中展现出更好的学习性能优势,我们深入研究了编码器为长输入/输出历史提供的潜在表示,如图 9 和附录 G 所示。这些结果是在模拟中获得的。我们将看到,利用长输入/输出历史的编码器能够在我们的所有运动技能中捕捉到时变事件和动力学参数中的时不变变化。

A. 时变嵌入


在本小节中,我们观察到来自长输入/输出历史编码器的潜在嵌入能够有效适应时变的外部干扰或运动任务,隐式地估计所有三种不同运动技能中的接触事件和/或外力。

周期性奔跑:利用所提方法获得的奔跑策略,我们记录了从站立姿态启动并跟随 3 米/秒恒定奔跑速度指令持续 15 秒的潜在嵌入。在 8 至 11 秒期间,对机器人基座施加了 40 牛的后向持续扰动。潜在值随时间的变化如图 9a 所示。


由于奔跑是一种周期性技能,一旦步态稳定(如图 9a 中 2 秒后所示),潜在嵌入也呈现出周期性模式。此外,扰动的存在引入了潜在嵌入的变化(绿色虚线框内),展示了捕捉时变扰动的能力。

此外,我们发现了两个有趣的潜在维度,如图 9a 中红色线条和曲线图所示。这两个潜在在信号与机器人左右脚的冲击力表现出强相关性。具体而言,这两个潜在维度的值变化趋势与仿真中记录的地面真实冲击力一致,当对应力为零时(相应脚处于摆动相),其值也降至零。这一结果凸显了控制腿足机器人的一项关键且具挑战性的能力:接触估计,因为轨迹在接触时会发生突变。


隐式接触估计的优势在外部扰动存在时(如图 9a 绿色虚线框内所示)这两个潜在维度的变化中变得更加明显。尽管地面冲击力的大小未变,但这两个潜在值在扰动期间移至较低包络线,并在扰动移除后恢复至先前包络线。虽然这一变化的确切解释尚不明确(因其完全通过数据学习得到),但可能归因于以下概念:外部扰动和地面反作用力均可视为施加于机器人的广义外力 ζ_{ext} ,如机器人全阶动力学方程(1)所隐含。机器人可能通过提供的长输入输出历史,无意识地将这些外力共同嵌入这些信号中并用于控制,而无需显式的人工工程。对于周期性行走技能,这种长历史编码器的类似能力也被观察到,我们在附录 G 中进行了简要分析。




(a) (上) 跑步过程中长期输入 / 输出历史编码器后的记录潜在表示。(下) 两个选定维度 (上图中标记为红线) 与机器人每只脚上记录冲击力的比较。



(c) (上) 跳跃过程中长期输入 / 输出历史编码器后的记录潜在表示。(下) 两个选定维度 (上图中标记为红线) 与机器人双脚记录总冲击力的比较。



(b) The blue plot shows the robot's latent representation with default dynamics parameters during running. The red plots indicate changes in the same region under different dynamics.



(d) 蓝色曲线显示了机器人在默认动力学参数下跳跃时的潜在表示。红色曲线表示在不同动力学条件下同一区域的变化。

图 9: 仿真环境 (MuJoCo) 中的适应性测试。我们评估了双足跑步 (图 9a) 和跳跃 (图 9c) 过程中长期输入 / 输出历史编码器输出的潜在表示轮廓, 其中颜色越浅表示相对值越大。在历史编码器初始化后 (前 2 秒), 潜在嵌入的变化在不同活动 (如跑步与跳跃或站立)、特定跳跃目标以及存在外部扰动时均显著。两个潜在值 (顶部图中红色水平线标示) 在底部图中绘制, 以显示潜在空间也捕捉了冲击力的变化。为了对时不变动力学参数进行消融研究, 我们检查了图 9a 和图 9c 中红色框内 (标记为放大区域) 的相同区域, 并在图 9b 和图 9d 中展示了机器人分别进行匀速跑步和原地跳跃时的这些区域。默认动力学下的潜在表示显示了机器人标称模型在未对动力学进行任何更改、未引入噪声或延迟时的这些区域。相对于默认动力学的潜在变化显示了当我们逐一调整每个连杆的质心位置 (标记为质心位置)、连杆质量 (连杆质量)、每个电机使用的 PD 增益 (PD 增益)、地面摩擦 (摩擦)、关节阻尼比 (阻尼)、通信延迟 (延迟) 和噪声水平 (噪声) 时, 相同区域的增量变化。在这些图中, 颜色越深表示变化越大。这表明潜在嵌入能够反映动力学的不同变化, 同时有效滤除引起微小变化的噪声。尽管环境发生显著变化, 任务完成误差 (E_t) 和运动跟踪误差 (E_m) 等控制性能指标仅表现出轻微退化, 展示了使用所提出控制器对动态变化的适应性。我们进一步在附录 H 中可视化了相应的显著性图。

非周期性跳跃: 尽管实现了周期性奔跑和行走技能, 我们也发现了 I/O 历史编码器在非周期性技能 (如跳跃) 中捕捉时变信息的类似能力。如图 9c 所示, Cassie 被指令每 3 秒执行不同的跳跃任务, 从原地跳跃开始, 到 1.4 米向前跳跃, 接着是 0.5 米侧向跳跃, 以及一个 -60° 的跳跃加转身, 然后站立。

记录的时间演化潜在表示揭示了跳跃阶段 (具有更多变化和非零信号) 与站立阶段 (信号变化较小) 之间的明显对比。此外, 对于不同的跳跃任务, 跳跃阶段的潜在值也有所不同, 如图 9c 所示。

此外, 我们发现了两个潜在维度

that

与跳跃过程中的接触事件强烈相关, 如红色线条所示并绘制于图 9c 中。与人类通常期望跳跃过程中只有一个二元接触变量 (要么接触要么不接触) 不同, 机器人学会了利用两个不同的信号: 起跳事件和着陆事件, 分别由潜在值 1 和潜在值 2 估计, 如图 9c 所示。例如, 潜在值 1 开始增加并在总接触力达到零之前降至零 (表明机器人开始起跳), 而潜在值 2 仅在机器人着陆的时刻变得活跃。此外, 在向前跳跃过程中, 机器人在着陆后执行了一个小跳, 潜在值 2 在该额外跳跃期间出现了一个额外的峰值。这种分离的起跳和着陆信号可以为控制双足跳跃技能提供更具信息性的线索, 考虑到

飞行和着陆阶段控制复杂性的差异。

B. 动力学变化的自适应嵌入

我们现在评估潜在嵌入如何随（时不变的）机器人动力学模型变化而变化，具体而言，是公式 (1) 中 $\mathbf{M}$ 、 $\mathbf{C}$ 、 $\mathbf{G}$ 、 κ 以及雅可比矩阵的改变，或是测量值受损（包括噪声和延迟）的情况。利用上述奔跑策略，我们聚焦于图 9a 中红色块突出显示的周期性模式的一个片段。当使用默认动力学模型控制机器人时，观察到的放大模式如图 9b 所示。

我们在同一任务（跟踪 3 米 / 秒指令）中使用相同的奔跑策略进行消融研究，并改变动力学参数。具体而言，我们每次调整一个特定的建模参数，例如连杆质心位置（所有连杆增加 8 厘米）、连杆质量（所有连杆增加 30 %）、关节阻尼比（默认值的 8 倍）、每个电机上使用的 PD 增益（比默认值高 40 %），以及降低地面摩擦力（静摩擦比设为 0.5 以模拟光滑地面）。如图 9b 所示，与默认模型获得的模式相比，这些动力学参数的每次变化都会导致潜在嵌入发生显著偏移。然而，评估控制性能指标，如任务完成度（机器人实际速度与期望速度之间的跟踪误差 E_t ）和运动跟踪（机器人实际电机位置与参考运动之间的运动偏差 E_m ），显示变化极小。

在跳跃和行走技能中也进行了类似的消融研究，分别记录在图 9d 和附录 G 中。具体而言，在利用所获得的跳跃策略进行原地跳跃任务时，我们修改了与奔跑任务中相同的动力学参数，导致不同动力学模型的潜在嵌入呈现出不同的模式。尽管存在这些变化，控制性能指标，如任务完成度（着陆位置与期望位置之间的误差 E_t ）和运动跟踪误差 E_m ，也显示出极小的变化。

在评估受损测量对潜在嵌入的影响时，控制和观测中的延迟（0.025 秒）在跑步和行走中引起了明显变化，如图 9b 和图 32b 所示。令人惊讶的是，引入显著更大的噪声（比训练时使用的上限大两倍，如表 IV 所列）并未对所有跑步、跳跃和行走技能的潜在嵌入产生显著影响。这一结果突显了长历史编码器在有效滤除附加的零均值噪声方面的功效，这种能力也可能得益于 CNN 结构。

C. 结果总结

这项消融研究突显了所提出控制器的适应性。凭借历史编码器从输入 / 输出历史中捕获有意义信息的能力，该控制器能够适应时变事件（如外部扰动或接触）以及时不变动力学参数的变化，并滤除测量噪声，从而以最小的性能下降有效执行控制任务。

这种能力解释了为何所提出的结构在具有大范围动力学参数随机化的挑战性训练环境中表现出色。值得注意的是，为了充分利用机器人长输入 / 输出历史带来的优势，需要合适的结构（双历史方法）和训练策略（端到端训练），如第七节所述。

IX. 多功能策略的优势与鲁棒性的来源

我们现在验证本研究的另一个关键发现，即在仿真和现实世界中，使用强化学习获得运动控制器时鲁棒性的来源。我们的发现表明，在双足运动控制中，一个能够执行多种任务的单一多功能策略可以显著提高鲁棒性，相比于专注于单一任务的策略。这是通过任务随机化和泛化实现的。

A. 基线方法

我们在所有四种不同的运动技能（包括站立、行走、跑步和跳跃）上，对所提出的通用策略和特定任务基线进行了基准测试。针对这四种技能中的每一种，我们分别训练了三种策略，具体如下：

- **单一任务**：仅使用单一固定任务和动力学随机化（不包括模拟扰动）训练的策略。对于行走，任务是以 0.6 米 / 秒的速度向前行走；对于跑步，任务是以 3 米 / 秒的速度跑步；对于跳跃，任务是原地跳跃；对于站立，任务是保持静止站立。
- **单一任务带扰动**：使用与单一任务策略相同的固定任务和动力学随机化进行训练，但额外加入了模拟扰动进行训练的策略。
- **通用策略（我们的方法）**：训练用于处理表 VI 中详述的完整指令（任务）范围的策略，采用动力学随机化但不包含任何扰动。对于行走和跑步的通用策略，它们还学习了运动与站立之间的转换。

所有策略均采用图 3 所示的策略结构，并在第六节 E 部分介绍的相同动力学随机化范围内进行训练，直至收敛。对于使用模拟扰动训练的策略，其扰动范围也与表 IV 中指定的相同。

上述策略是通过三种不同方法训练的示例：（1）动力学随机化（单任务策略训练时不加入模拟扰动），（2）扰动训练（单任务策略在动力学随机化过程中加入扰动进行训练），以及（3）任务随机化（多功能策略）。通常，扰动训练被视为一种额外的动力学随机化。

B. 鲁棒性来源

我们首先在仿真环境中进行验证，该环境提供了一个受控且安全的平台来评估控制策略的鲁棒性。在此验证中，我们将展示多功能运动策略的鲁棒性来源于




图 10: 仿真环境 (MuJoCo) 中的鲁棒性测试。我们利用第 IX-A 节开发的基线方法进行消融研究, 以评估鲁棒性与任务随机化之间的关系。绿色边界框表示策略成功控制机器人且未摔倒的场景。机器人在执行固定运动任务 (如以 0.6 米 / 秒行走、3 米 / 秒跑步或原地跳跃) 时, 受到持续扰动力的作用 (方向由红色箭头标示) 或所有连杆质心位置偏移 (机器人整体质心概念性地用红点表示)。专注于单一任务的策略, 即使经过广泛的动力学随机化, 也无法应对这些分布外场景。通过额外的扰动训练, 机器人可以在行走时保持稳定, 如图 10a(ii) 和图 10b(ii) 所示。然而, 对于跑步或跳跃等更具动态性的技能, 此类策略效果较差, 如图 10c(ii) 和图 10f(ii) 所示。相比之下, 经过多种任务训练的多功能策略, 即使没有特定的扰动训练, 也表现出更好的鲁棒性。机器人在外部扰动或质心偏移下会改变步态, 例如采用侧向行走步态 (图 10a(iii)) 和后退行走步态 (图 10b(iii)), 凸显了多功能控制器的顺应性。这种顺应性在跑步和跳跃中同样可见 (图 10c(iii) 和图 10f(iii)), 这是在具有挑战性的鲁棒性测试中取得成功的关键。

两个关键因素: (1) 由动力学随机化引入的训练随机化动力学参数的泛化能力, 以及 (2) 多种训练运动任务的泛化能力, 从而赋予机器人显著的顺应性, 这得益于任务随机化。

对于我们开发的每种运动控制策略 (包括行走、跑步和跳跃), 我们在两种不同的不确定性条件下进行测试:


(1) 在机器人骨盆上施加一个持续力, (2) 在机器人的所有连杆上引入质心位置的显著偏差, 如图 10 所示。需要注意的是, 这些不确定性超出了训练过程中使用的界限, 如表 IV 所示。例如, 与训练过程中使用的脉冲扰动不同, 这里我们施加的是持续扰动, 并且质心位置偏移量大于训练场景中涵盖的范围。这些分布外测试的结果如图 10 所示。

以行走任务为例: 当机器人被指令向前行走并面临 22N 的持续侧向拉力时, 一个专门针对向前行走的单任务策略会因侧向扰动将机器人推离其训练分布而失败, 如图 10a(i) 所示。然而, 如果机器人使用扰动进行训练,

采用单任务策略, 它可以在这种力作用下向前行进, 仅产生微小的侧向偏差, 如图 10a(ii) 所示。相比之下, 使用一个未经扰动训练但经过多种行走任务训练的多功能策略, 机器人仍然能够稳定并执行向前行走任务, 尽管方式有所不同。这从图 10a(iii) 中可以明显看出, 机器人显著向右偏移, 利用学到的侧向行走技能来补偿外力, 从而产生一种顺应性步态。


在所有连杆上施加 -8 厘米的质心位置偏移时也观察到类似结果。未经扰动或其他任务训练, 即使经过随机化质心训练, 机器人也无法处理这种偏差, 如图 10b(i) 所示。当经过扰动训练后, 由于机器人学会了在向后力作用下稳定, 它利用这种学到的控制策略来对抗向后的质心位置偏移, 并以降低的速度继续向前行走, 如图 10b(ii) 所示。然而, 使用未经扰动训练的多功能策略, 机器人反而利用向后行走步态来抵消向后的质心偏移, 如图 10b(iii) 所示。

请注意, 我们并非试图论证扰动训练不如任务随机化。例如, 在行走任务中, 使用单一任务和扰动训练的机器人




(a) Standing skill only (b) With perturbation (c) Trained with both walking skill and standing skill (trained without perturbation)

图 11: 真实世界中双足站立技能的鲁棒性测试。如果机器人仅使用站立技能进行训练, 无论是否经过广泛的动力学随机化 (图 11b) 或未经过模拟扰动 (图 11a), 当被推离支撑区域时, 机器人往往会摔倒。相比之下, 使用我们通用策略 (同时训练行走和站立技能, 如图 11c 所示) 的机器人表现出更好的鲁棒性。尽管在站立过程中未经过扰动训练, 但机器人在被向前推时能自发地断开接触, 并利用其泛化的行走技能恢复站立姿态。此类对比视频记录在表 I 中的视频 3 中。



(a) 在站立过程中受到扰动后, 利用多种行走技能 (侧向行走、后退行走和改变高度) 进行的复杂恢复操作



(b) Robust standing maneuver aided by running skills

(c) 借助跳跃技能实现的鲁棒站立操作

图 12: 真实世界中通过通用策略实现的鲁棒双足站立技能。机器人在站立时, 能智能地断开接触并根据需要调用习得的运动技能。例如, 如图 12a 所示, 当受到扰动时, 机器人偏离站立指令, 自主地在一个长时域内运用一系列接触和变化的行走技能, 以恢复站立姿势。这种源于任务随机化的鲁棒性增强了真实世界的部署能力。例如, 在向站立状态过渡时 (如图 12b), 机器人利用在跑步中习得的侧步技能, 帮助从踩到轨道护板的状态中恢复。同样, 借助图 12c 中的通用跳跃技能, 机器人在从不稳定状态落地后断开接触, 在空中调整姿态以实现更好的着陆, 所有这些均无需依赖任何人为定义的接触序列。

与由通用策略控制的机器人 (图 10a(iii)、10b(iii)) 相比, 这些机器人表现出更优的完成任务能力 (图 10a(ii)、10b(ii) 中跟踪误差更小)。因此, 在动力学随机化过程中仍建议加入外部扰动, 作为任务随机化的补充。然而, 来自模拟动力学的鲁棒性提升不如任务随机化显著, 尤其是在跑步和跳跃等更具动态性的任务中。

如图 10c(i)(ii) 所示, 在跑步过程中受到 30 N 的恒定向前扰动时, 仅通过单一任务训练的策略无法维持稳定步态, 无论采用何种广泛的动力学随机化和额外的扰动训练。相比之下, 使用经过更快跑步训练的多功能策略的机器人能够适应此类扰动, 如图 10c(iii) 所示。在跑步过程中出现 +8 厘米质心位置偏移 (图 10d)、跳跃过程中的侧向扰动 (通过侧向跳跃) 和向前质心位置偏移 (通过向前跳跃) 等场景中 (图 10e、10f), 也观察到了类似结果。请注意, 所有这些多功能策略均未经过模拟

扰动训练。

这些研究突显了强化学习策略鲁棒性的两个不同来源:

- (1) 通过特定模拟动力学 (包括外部扰动) 训练, 可以在扩展的场景范围内发挥作用, 但将机器人限制在训练任务中;
- (2) 通过多样化任务集训练, 使机器人能够泛化所学任务以获得更强的鲁棒性和顺应性, 即使没有广泛的动力学随机化。

C. 案例研究: 鲁棒站立实验

我们在真实世界中进行了一项案例研究, 以深入了解通过强化学习开发的控制策略中鲁棒性的根本来源。该案例研究聚焦于评估站立技能的表现。

在此场景中, 如图 11 所示, 我们在机器人保持站立姿态时对其骨盆施加外部向前扰动。当策略仅针对站立技能进行训练时, 无论是否经过外部扰动训练, 如果机器人被迫倾斜超出其支撑区域, 它都会持续失去平衡, 如记录所示。




图 13: 通过不同方法增强鲁棒性的训练分布概念示意图。在部署阶段（如红色曲线所示），我们希望由强化学习策略控制的机器人能够在其轨迹训练分布范围内运行。当训练聚焦于单一任务时，训练分布被限制在该任务特有的标称轨迹内（黄色区域）。引入包含模拟扰动或不同地形的广泛动力学随机化可扩展该分布，但扩展仍以固定任务为中心。任务随机化通过使机器人能够学习并泛化不同任务（以不同淡黄色区域标记）的多种控制策略，显著拓宽训练分布（橙色区域）。值得注意的是，任务随机化可与动力学随机化结合，进一步扩大训练分布并增强策略的鲁棒性。

在图 11a、11b 中。相反，当我们采用同样经过站立技能训练的通用行走策略，并在机器人站立时对其施加类似的前向扰动（如图 11c 所示），机器人最初会前倾。然而，一旦机器人开始倾斜超出其支撑区域，它会展现出智能的恢复动作：通过断开接触转换为行走步态，执行包括向前和向后行走在内的若干步，然后平稳地恢复为站立姿态。值得注意的是，这一转换过程无需任何人工指令，因为提供的唯一参考动作仅为站立动作。此外，在使用该行走策略训练站立技能时，我们并未模拟外部扰动。

在现实部署中，具备稳健的站立能力极具优势。例如，当机器人站立时受到侧向扰动（如图 12a 所示），它会运用多种行走技能恢复平衡并重新站立。这一复杂过程——通过不同行走动作降低重心后恢复站立姿态——凸显了策略在长时域恢复操作中的能力。值得注意的是，这种精妙的恢复动作并非专门训练所得，而是多用途策略的自然涌现。该优势同样延伸至其他技能：采用多用途奔跑策略时（如图 12b 所示），机器人从奔跑状态急停并踏上轨道护栏（记录于图 12b）。在保持平衡的前提下，机器人迅速脱离护栏，运用学习奔跑技能时习得的侧步技巧，随后维持稳定站立姿态。类似地，在多用途跳跃策略中（图 12c），机器人在完成复杂多轴跳跃后出现不稳定着陆时，会执行从多样化跳跃任务中习得的修正跳跃动作。

以便在空中更好地自我修正，并拥有更稳定的着陆构型。这些结果可以在表 I 所列的视频中更清楚地看到。

D. 从训练分布理解鲁棒性

上述发现可以在图 13 中概念性地说明，类似于控制理论中不变集的概念。为了有效控制机器人，强化学习策略需要应对部署过程中遇到的一系列干扰。当机器人的轨迹处于其训练分布内时，无模型强化学习策略可能特别有效，因为该策略是专门针对此类场景进行训练和优化的。单任务策略的训练分布有限，仅集中于该任务，而使用带/不带扰动的随机动力学进行训练可以扩展这一分布，如图 13 所示。然而，如图 10 所示，动力学随机化仅适度扩展了这一分布，主要增强了单任务方案内的鲁棒性。相比之下，任务随机化显著拓宽了训练分布。通过使机器人能够处理多样化的任务，这种方法可以有效扩展训练后机器人输入/输出轨迹的范围。当在部署过程中遇到干扰时，机器人仍可保持在此增强后的训练分布内，如图 13 所示。当在任务随机化之后结合动力学随机化时（如我们工作中图 4 所示），训练分布可以进一步大幅扩展，从而增强强化学习策略的鲁棒性。


备注 2：动力学随机化的范围不能任意大，因为它会在训练过程中引入显著挑战（机器人可能无法学习到有意义的技能）。本工作中使用的动力学随机化范围（表 IV）对 Cassie 机器人来说已足够具有挑战性，这可以从图 6 中收敛的训练回报较低得到证明。如 [105] 所示，进一步增加动力学随机化存在局限性。因此，任务随机化可以被视为一种“正交”的方式来提高鲁棒性，而不是进一步推动动力学随机化的范围。

E. 结果总结


总之，与仅专注于特定任务的策略相比，多功能策略在鲁棒性方面表现出显著提升，这一点在仿真和现实世界中均得到了验证。这种增强的鲁棒性源于它们能够泛化所学任务，并在不局限于遵循给定指令的情况下找到更好的应对意外情况的方法，最终实现更好的稳定性。在基于强化学习的运动控制中，鲁棒性的一个关键来源是执行多功能任务的能力。因此，建议在未来的腿部运动控制开发中采用任务随机化，以多样化训练过程中的任务。

X. 现实世界中的动态双足运动


我们现在在现实世界中广泛评估所获得的多功能策略，用于行走、跑步和跳跃。所有



(a) 2022 年 8 月 9 日进行的可变指令跟踪实验。在（纵向速度 $\dot{q}_x^d$ 、横向速度 $\dot{q}_y^d$ 、行走高度 q_z^d ）方向上的跟踪误差（平均绝对误差，MAE）分别为（0.10 m/s、0.10 m/s、0.06 m）。



(b) Experiments on variable command tracking conducted on June 30, 2023, 325 days after the one conducted Fig. 14a using the same controller without any tuning. The tracking errors (MAE) in the ($\dot{q}_x^d$, $\dot{q}_y^d$, q_z^d) directions are (0.10 m/s, 0.08 m/s, 0.06 m), respectively



(c) 2023 年 12 月 14 日进行的可变指令跟踪实验，该实验距离图 14a 中的实验已有 492 天，且使用了相同的控制器，未进行任何调整。在（ $\dot{q}_x^d$ 、 $\dot{q}_y^d$ 、 q_z^d ）方向上的跟踪误差（MAE）分别为（0.11 m/s、0.09 m/s、0.05 m）。

图 14：图 14a 记录了在现实世界中，机器人使用所获得的多功能行走控制器可靠地跟踪变化指令的快照。期望指令和实际估计值在实验过程中被机载记录，并绘制在下部。蓝色虚线对应现实世界中帧的相应间隔。机器人能够以相当高的精度跟踪不同的期望指令，包括变化的纵向速度 $\dot{q}_x^d$ 、横向速度 $\dot{q}_y^d$ 和行走高度 q_z^d ，在长时间测试中跟踪误差较小。类似的可变指令跟踪实验在较长时间跨度后也进行了，例如图 14c 中 325 天后的实验和图 14b 中 492 天后的实验。尽管经过如此长的时间，机器人硬件因磨损而发生变化，但相同的基于强化学习的控制器仍然能够有效地控制机器人以相似的跟踪误差跟踪变化指令，无需在现实世界中进行任何调整。

这些策略能够在模拟训练后，无需进一步调整即可在现实世界中有效控制机器人。此外，实验的主要目标是评估所提出方法的两个基本方面：（1）所获得策略对现实世界中实际机器人动力学的适应性，通过有效控制真实机器人完成指定任务，如同在模拟中一样；（2）策略在应对现实世界中不同不确定性时的鲁棒性，通过利用各种学习到的任务来实现。

A. 行走实验

我们现在在 Cassie 机器人上检验多功能行走策略。以下实验均由同一个控制器完成。正如我们将看到的，所获得的行走策略在长时间跨度内对机器人硬件展现出一致的控制性能，并具有显著的鲁棒性和柔顺性。

1) 跟踪性能：该策略展示了可靠跟踪变化、快速指令的能力，并在超过一年的长时间内保持了一致的控制性能。这一结果彰显了所提出策略的适应性，能够适应真实机器人的动力学特性，如下文所述。

可变指令：如图 14a 所示，行走策略展示了有效控制机器人跟随多样化指令的能力，包括矢状面和横向速度的变化以及行走高度的变化。在整个测试过程中，通过平均绝对误差评估的跟踪误差保持在合理较低水平。在各项指标上的平均绝对误差分别为 0.10 米 / 秒、0.10 米 / 秒和 0.06 米。此外，如图 15 所示，该策略展现出可靠的控制能力，使机器人能够准确跟踪顺时针或逆时针的转向指令。




图 15: 真实世界中的快照, 展示了机器人使用与图 14 相同的控制器可靠地跟踪各种转向偏航指令 q_{ψ}^d 。下方记录了期望转向角度和实际转向角度, 虚线对应真实世界中的相应帧。机器人能够执行逆时针和顺时针方向的完整转向。




图 16: 使用相同的行走策略, 机器人从站立状态过渡到快速向前行走 (图 16a) 或向后行走 (图 16b) 并返回站立状态的快照。较早的帧显示得更淡。机器人的指令和实际矢状速度记录在图 16c 中。这展示了机器人能够通过单一指令从静止站立快速切换到动态快速行走, 并平稳过渡回站立状态, 即使在快速行走等动态机动中也是如此。

长时间跨度内的一致性: 机器人硬件, 尤其是双足机器人, 会因长期磨损而不断变化。例如, 关节摩擦可能因运行中的冲击而变化, 且由于双足机器人自由度数量多且运行时间长, 这些变化会累积。因此, 依赖硬件上调谐的控制增益的控制器 (如大多数基于模型的控制器) 通常需要手动更新以应对这些硬件变化。相比之下, 我们提出的基于强化学习的行走策略能够适应变化的机器人动力学, 无需在硬件上调谐即可控制机器人。这种适应性体现在该策略在长时间内持续表现良好, 即使在 325 天和 492 天后仍能保持跟踪可变指令的能力, 如图 14c 和图 14b 所示。与早期测试 (图 14a) 相比, 在这两次测试中, 跟踪误差 (MAE) 在 $(\dot{q}_x, \dot{q}_y, \dot{q}_z)$ 上的变化分别为 (+0 米/秒, -0.02 米/秒, +0 米) 和 (+0.01 米/秒, -0.01 米/秒, -0.01 米), 测试时间跨度较长 (超过 2 分钟), 且指令组合不同。尽管在此期间机器人动力学发生了显著累积变化, 但图 14a 中的同一控制器仍能有效管理不同的行走任务, 仅出现极小的

跟踪误差退化。

快速行走: 除了先前展示的中等速度行走外, 该策略还展现出控制机器人执行向前和向后快速行走动作的能力, 如图 16 所示。机器人能够从静止状态快速过渡到向前行走, 平均速度达到 1.14 米/秒, 以跟踪 1.4 米/秒的指令, 并按要求迅速返回站立位置, 如图 16a 所示, 数据记录在图 16c 中。值得注意的是, 在从零速度的站立姿态过渡时, 机器人能够在保持步态稳定性的同时, 以相当大的加速度快速摆动腿部, 以跟随阶跃输入指令。在快速向后行走 (图 16b) 中也观察到类似的能力, 机器人从站立姿态无缝转换, 执行平均速度为 -0.5 米/秒的向后行走步态, 完成指定的 -1 米/秒行走任务, 随后在收到指令后迅速返回站立位置。

2) 鲁棒行走机动: 我们进一步测试了行走策略的鲁棒性, 所提出的策略在应对环境的各种变化时表现出显著的鲁棒性, 如下所示。

不平坦地形 (未经训练): 尽管行走策略并未专门针对穿越不平坦地形进行训练,





图 17: 机器人 Cassie 在鲁棒性测试中的快照, 通过向后行走越过小型多变地形 (如楼梯 (图 17a) 或斜坡 (图 17b))。快照按时间戳对齐。尽管策略并未专门针对地形变化进行训练, 但在现实场景中, 它成功维持了稳定的行走步态, 并在地面高度变化时表现出鲁棒性, 如这组快照所示。



(a) Recovery maneuvers using the proposed RL-based controller from lateral perturbation

图 18: 机器人行走对抗未知扰动的鲁棒性测试。使用所提出的基于强化学习的通用策略, 如图 18a 所示, 尽管机器人被侧向推动并加速至 -0.5 米 / 秒, 它仍能维持稳定的行走步态, 并通过向相反方向行走来补偿这种侧向冲量。相应的侧向速度 $\dot{q}_y$ 记录在图的底部。此外, 平面位置 (q_y, q_x) 被估计, 点以逐渐加深的颜色显示, 表示记录时间越晚。相比之下, 使用 Cassie 制造商提供的基于模型的控制 (图 18b), 机器人在类似的侧向推动后摔倒。

在仿真地形中, 它在部署时对不同的高度变化表现出显著的鲁棒性。如图 17 所示, 机器人能够有效地在小楼梯或下坡上向后行走。值得注意的是, 机器人没有任何地形高度传感器。这种能力源于策略在行走于不同高度时对接触时机或接触力的变化具有鲁棒性, 这得益于控制器中不需要显式估计或控制接触。

对随机扰动的鲁棒性: 在此测试中, 我们评估了所提出的通用行走策略在两种外部扰动下的鲁棒性: (1) 持续时间小于 1 秒的脉冲扰动; (2) 持续时间超过 3 秒 (长于控制器输入 / 输出历史长度) 的持续扰动。

对于脉冲扰动情况, 我们在机器人行走时从不同方向对其施加短时间的扰动。如图 18a 所示的一个例子, 当机器人在原地行走时, 施加了一个显著的横向扰动力, 导致其产生 0.5 米 / 秒的显著横向速度峰值。尽管受到此力, 机器人仍能迅速从横向偏移中恢复。如图 18a 所示, 机器人灵巧地向相反横向方向移动, 有效补偿了扰动, 并恢复了稳定的原地行走步态。

在持续扰动测试中, 当机器人被指令原地行走时, 一名人类对机器人基座施加持续力并将其向

随机方向拖拽。示例可见图 19a, 当机器人以正常高度行走时, 对 Cassie 的基座施加了持续的横向拖拽力。在另一项测试中, 如图 19b 所示, 机器人以较低高度行走, 其基座受到一个方向在矢状面上随机变化的持续力。在这些测试中, 尽管被指令原地行走, 机器人并未失去平衡, 而是通过跟随这些力的方向表现出对外部力的顺从性。这些顺从性实验展示了所提出的基于强化学习的策略在控制双足机器人方面的优势, 适用于安全人机交互等潜在应用。

更多场景, 包括更多脉冲扰动和持续随机扰动, 记录在表 I 所附的视频 3 中。在所有进行的测试中, 机器人展示了其鲁棒性, 与第九节仿真验证中观察到的结果一致。其根本原因在于机器人对横向、向前、向后行走、转弯等多种任务进行了广泛学习。这种任务随机化使机器人能够将从学习各种任务中获得的知识泛化, 以从当前指令任务中发生的偏差中恢复。

与基于模型的控制对比: 我们通过强调所提出行走策略的优势,

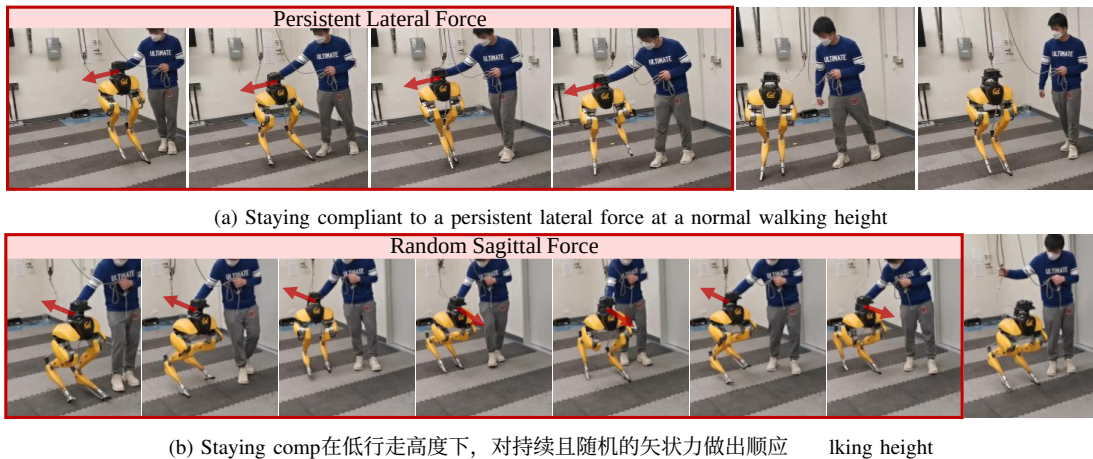


图 19: 在现实世界中使用所提出的多功能行走策略进行顺应性测试的快照。红色箭头表示施加力的方向。在图 19a 中, 机器人以正常高度行走, 一名人类对 Cassie 的基座施加持续 (超过 3 秒) 的侧向力, 并将机器人拖向右侧。在图 19b 中, 机器人处于低行走高度, 一名人类对机器人基座施加持续但随机的力, 并在矢状方向上来回拖动机器人。在这些测试中, 尽管被指令原地行走, 机器人通过沿持续外力方向行走而不失去平衡, 展示了顺应性。力移除后, 机器人返回指令任务。

将其与基于模型的行走控制器进行比较, 具体来说, 是制造 Cassie 的公司所使用的基于模型控制器。如图 18b 所示, 当机器人由该基于模型控制器控制并受到侧向扰动时, 该控制器无法维持控制, 导致摔倒。这是因为控制器中使用的模型未考虑外部扰动 (这也难以估计), 且基于模型控制器无法处理如此大的建模误差。在持续扰动测试中, 该基于模型控制器也无法稳定机器人。这些实验记录在表 I 的视频 3 中。在 [106] 最近的工作中, 对腿式机器人进行了系统性的扰动测试, 更广泛地纳入此类测试将是有趣的。然而, 这超出了本文的范围。此外, 如视频所示, 当指令机器人跟踪零速度且未手动调整增益时, 基于模型控制器会导致机器人出现明显的侧向漂移 (在人类操作员扰动之前), 而所提出的强化学习策略在没有使用真实世界数据训练的情况下, 表现出更好的跟踪性能 (使机器人保持原地行走)。然而, 基于模型控制器产生的踩踏力比强化学习策略更小且更有利。我们希望这些实验能帮助读者更好地理解基于模型最优控制和无模型强化学习方法在双足运动控制中的优缺点。

3) 结果总结: 总之, 通过所提方法得到的通用行走策略能够有效控制双足机器人 Cassie 在现实世界中执行多种任务, 并在长时间 (超过一年) 的使用中保持一致性。结果表明, 机器人能够跟踪不同的行走速度、改变行走高度、向不同方向转弯、执行快速行走以及从站立状态过渡到行走状态或反之。该策略在面对地形高度变化和外部扰动 (包括冲击力和随机但持续的力) 等挑战时也表现出显著的鲁棒性。


持续的力)。

B. 跑步实验


我们现在评估使用所提方法在现实世界中开发的通用跑步策略。获得了三种特定的跑步策略: (1) 在平地上训练的通用策略; (2) 100 米短跑微调策略, 在通用策略收敛后训练, 专注于完成 100 米短跑。该策略加入了一个额外的终止条件, 如果机器人无法在 25 秒内完成 100 米短跑, 则提前结束回合; (3) 不平地形策略, 在通用策略收敛后开发, 并集成了表 IV 中列出的额外地形随机化。所有策略都经过多种跑步和转弯速度 (如表 VI 所列) 以及从站立技能过渡的训练。正如我们将看到的, 使用所获得的双足跑步策略, 我们在 2 分 34 秒内完成了 400 米短跑, 在 27.06 秒内完成了 100 米短跑, 跑步上坡达到 10° , 以及更多。

1) 400 米短跑: 我们首先评估通用跑步策略在标准户外跑道上完成 400 米短跑, 如图 20 所示。在整个测试中, 机器人被命令以一致的速度 3.5 米/秒的速度跑步, 同时响应由人类操作员给出的不同转弯指令以导航跑道。如图 20a 和表 I 中的视频 2 所示, 该策略能够从站立位置平滑过渡到跑步步态 (图 20a1)。机器人成功加速到平均估计跑步速度 2.15 米/秒², 达到峰值估计速度 3.54 米/秒, 如图 20b 所示。

我们注意到, 当机器人高速奔跑时, 矢状速度存在显著的状态估计误差。以 154 秒完成 400 米的平均速度为 2.6 米/秒, 而估计的平均速度为 2.15 米/秒。这种误差在后续讨论的 100 米短跑中更为明显。因此, 我们强调这些记录是估计值而非真实值。我们将在附录 I 中进一步阐述这一点。




(a) Snapshot of 400 米短跑。数字与机器人快照及其在跑道上的对应位置相匹配。



(b) 400 米短跑期间记录的数据。显示了机器人的矢状速度 $\dot{q}_x$ 、横向速度 $\dot{q}_y$ 和转弯偏航角 q_ψ 。

图 20: 利用我们开发的多功能奔跑策略, Cassie 在双足机器人领域成功完成了 400 米短跑, 用时 2 分 34 秒。该短跑在加州大学伯克利分校的爱德华兹体育场完成。这得益于单一奔跑策略, 使机器人能够从站立姿态过渡到快速奔跑步态, 平均速度 2.15 米 / 秒, 峰值速度 3.54 米 / 秒。在整个短跑过程中, 机器人还以平均横向速度 0.05 米 / 秒 (横向速度指令为零) 保持该速度。此外, 机器人能够精确跟踪变化的转弯指令, 平均跟踪误差 (MAE) 为 5.95 度。这种精确的转弯指令跟踪对于成功完成 400 米短跑至关重要, 因为机器人需要在奔跑时可靠转弯。在奔跑过程中, 我们持续观察到明显的腾空阶段, 如图 20a 所示。机器人还能够完成短跑后过渡回站立状态, 如矢状速度日志 (图 20b) 和表 I 中的视频 2 所记录。



(a) 奔跑过程中跟踪变化的矢状速度 (b) 奔跑过程中跟踪变化的横向速度 (c) 奔跑过程中的急转弯。此场景 (跟踪非平滑转弯角度) 未经过专门训练。

图 21: 使用与图 20 中完成 400 米短跑相同的控制策略, 在真实世界实验中跟踪奔跑过程中的变化指令。利用多功能策略, 机器人能够跟踪变化的矢状速度 $\dot{q}_x$ (图 21a) 和横向速度 $\dot{q}_y$ (图 21b)。此外, 机器人能够在奔跑过程中执行急转弯, 如图 21c 所示。机器人可在 2 秒内、使用 5 步转弯 90 度, 如图 21c 中的日志和对应快照所示。值得注意的是, 机器人在训练过程中并未针对这种急转弯场景进行专门训练。这些实验也记录在表 I 中的视频 4 中。

策略成功地在整个 400 米跑过程中持续保持期望速度, 并准确遵循

变化的转向指令。图 20b 中观察到的转向角平均跟踪误差 (MAE) q_ψ 为 5.95




图 22: 使用微调后的跑步策略, Cassie 以快速跑步步态完成 100 米短跑。图 22a 显示机器人能够从静止站立过渡到快速跑步步态, 在 2 秒内通过激进动作从 0 米 / 秒加速到 3 米 / 秒。在图 22b 所示的巡航阶段, 机器人保持快速且稳定的跑步步态。相应的指令和估计矢状速度记录在图 22c 中。机器人在 28 秒内完成这次短跑, 平均速度为 3.57 米 / 秒。

度。在整个 400 米跑过程中, 尽管跑步速度和转弯角度变化, 如图 20a 所示, 仍存在显著的腾空阶段。这种持续的腾空阶段将我们的跑步步态与快速行走步态区分开来, 并在控制上带来了显著更大的挑战。然而, 控制器成功地在较长时间 (154 秒) 内稳定维持了这种动态跑步步态。

此外, 在 400 米跑过程中, 尽管检测到一些横向漂移, 如图 20b 所示, 机器人仍能保持平均横向速度为 0.05 米 / 秒。虽然平均横向速度相对可忽略, 但机器人确实出现了横向速度较高的时刻, 有时超过 1 米 / 秒, 这可能是由于真实环境中的不规则接触所致。然而, 策略在横向跑步技能方面的训练使机器人能够纠正这些偏差, 展示了策略在面对此类意外横向运动时维持稳定性的鲁棒性。

由所提出的跑步策略控制的 Cassie 成功在 2 分 34 秒内完成了 400 米跑, 并随后能够过渡到站立姿势, 如视频中所记录。这是人形双足机器人完成完整 400 米一圈跑的新能力。

2) 跑步时跟踪变化指令: 利用相同的多功能策略, 机器人还能在快速奔跑时可靠地跟踪变化指令, 例如图 21a 所示的矢状速度 $\dot{q}_x$ 和图 21b 记录的横向速度 $\dot{q}_y$ 。相应的实验记录在视频中。

4 在表 I 中。注意, 在图 20b (偏航转向 q_ψ)、21a (矢状速度)、21b (横向速度) 进行的每次测试中, 只有指令的一个维度在变化。通过比较这些测试的记录日志, 我们观察到, 一个维度的指令变化不会影响对其他维度恒定指令的跟踪控制性能。这表明 $\dot{q}_x$ 、 $\dot{q}_y$ 和 q_ψ 维度是解耦的, 这很有趣, 因为这是在现实世界中高度非线性的双足机器人的快速奔跑控制中实现的。

我们进一步进行了一次急转弯测试, 机器人接收到偏航指令的阶跃变化, 从 0 度直接变为 90 度, 如图 21c 所示。机器人能够响应这样的阶跃指令, 并在 2 秒内用 5 步完成 90 度急转弯, 使用如图 21c 所示的自然奔跑步态。值得注意的是, 机器人并未针对这种急转弯场景进行专门训练, 因为在训练期间只提供了变化率限制在 30 度 / 秒的平滑偏航角指令, 如表 VI 所列。多功能策略能够泛化所学的各种转向任务, 并直接迁移完成这样的急转弯测试。这进一步凸显了获得多功能策略的优势, 因为之前的工作如 [17] 需要训练一个独立的策略才能在行走时执行类似的急转弯。

3) 跑 100 米短跑: 我们现在评估针对 100 米短跑微调后的奔跑策略, 如图 22 所示。我们进行了 3 次测试, 其结果被记

表 V: 真实世界中 100 米短跑三次试验完成时间记录。

Trial	Completion Time (s)
1	27.06
2	27.99
3	28.28

详见表 V 及表 I 中的视频 1 和视频 4。通过部署所提出的跑步策略, 机器人以约 28 秒完成了 100 米短跑, 最快跑进 27.06 秒。如图 22a 所示, 机器人在 1.8 秒内从静止站立姿态快速过渡到快速跑步步态, 采用了我们在人类跑步运动员中常见的过渡动作。在巡航阶段(图 22b), 机器人保持了快速跑步步态, 峰值估计速度达到 4.2 米/秒, 并呈现出显著的腾空阶段, 如图 22c 记录的数据所示。

4) 在非平坦地形上跑步(已训练): 我们接着检验针对非平坦地形微调的跑步策略。如图 23a 所示, 由所提出的跑步策略控制的机器人成功穿越了不同坡度的地形, 且无需显式的地形高度估计或外部传感器。地形测试涵盖了具有挑战性的变化, 从矢状面 7° 倾斜坡开始, 接着是横向平面 3° 斜坡、矢状面更陡的 10° 倾斜坡, 最后以平坦地面结束。尽管地形复杂, 机器人仍保持了稳定的跑步步态, 如图 23b 所示, 机器人大腿和膝关节的收敛极限环 ($q^{L/R}_{3,4}$) 在这些不同高程上均表现出一致性。机器人能够改变步态以适应不同地形, 这源于其对输入/输出历史的使用, 隐式地包含了接触事件和定位信息。值得注意的是, 即使在穿越这些具有挑战性的地形时, 机器人仍保留了腾空阶段, 如图 23a 所示, 这表明其能够维持跑步步态, 避免退化为支撑更多但速度较慢的行走步态。这是人类尺寸双足机器人首次在大型非平坦地形上实现(含腾空阶段的)奔跑。

5) 鲁棒奔跑机动: 在实际部署中, 观察到了所开发的跑步策略在处理各种扰动场景时的鲁棒性。例如, 在图 24a 中, 机器人由其 100 米短跑微调策略控制, 此时安全绳产生的突然脉冲扰动力导致机器人突然减速、向左倾斜并扭转。尽管发生了这一意外事件, 但经过模拟扰动和包括转弯在内的多种奔跑任务训练的机器人能够保持稳定, 并迅速恢复到稳定的跑步步态。使用通用奔跑策略也进行了类似的测试, 同时对机器人施加了横向扰动, 如图 24b 所示。机器人没有失去平衡, 而是采用横向跑步步态来补偿这种横向扰动。这些实验记录在表 I 的视频 4 中。这些场景突显了通过所提出的任务随机化获得的多功能奔跑策略的鲁棒性, 尤其是在

应对机器人在现实场景中高速奔跑时出现的意外干扰方面尤为有益。


6) 结果总结: 总之, 从所提出方法中导出的奔跑策略在现实场景中展示了对双足机器人 Cassie 的有效控制。它们展现了管理各种奔跑和转弯速度、仅基于本体感觉反馈适应地形变化、以及从站立姿势无缝过渡和恢复的能力。凭借这些奔跑策略, Cassie 在 100 米短跑中达到了 4.2 米/秒的显著峰值速度, 并在 27.06 秒内完成; 在 2 分 34 秒内完成了 400 米跑; 并穿越了不平坦地形, 同时表现出对意外干扰的鲁棒性。

C. 跳跃实验

我们现在评估所提出的多功能跳跃策略。我们获得了两种策略: (1) 地面策略, 专门用于在不同位置跳跃并在平地上执行转弯 ($e_z^d = 0$); 以及 (2) 离散地形策略, 专注于跳跃到各种高架平台而不执行转弯 ($q_\psi^d = 0$)。采用这两种独立策略的理由源于动态跳跃技能带来的挑战。根据我们的经验发现, 训练机器人同时执行跳跃到高架平台和转弯是困难的。正如我们将看到的, 所提出的跳跃策略实现了多种不同的双足跳跃, 包括 1.4 米远跳和跳上 0.44 米高的平台。

1) 跳跃与转身: 我们首先评估了地面策略的性能, 如图 25a 所示。通过这一单一的跳跃策略, 机器人仅需改变指令, 即可执行各种指定的目标跳跃, 例如原地跳跃并转身(图 25ai)、向后跳跃以落在后方 0.3 米处(图 25aia), 以及跳向前方 1 米处的目标(图 25aiii)。机器人能够通过精确降落在标记为地面纸标签的目标上来完成任务。仔细观察可以发现, 机器人能够调整其起跳姿态以遵循不同的指令。例如, 当需要落在后方目标时, 它会向后倾斜; 而在执行向前跳跃时, 则会向前倾斜。机器人还能够执行更多样化的跳跃组合, 这些组合沿不同轴运动。例如, 图 26c 记录了一次代表性的跳跃, 机器人执行了一次多轴跳跃, 需要同时向前、侧向跳跃并转身。我们在附录 J 和表 I 的视频 5 中报告了更多类型的跳跃(总共 12 种不同的跳跃), 所有这些跳跃均由这一单一的地面跳跃策略实现。

2) 跳跃至高处平台: 接着, 我们评估了离散地形策略, 以控制机器人跨越不同距离和高度的跳跃能力。如图 25b 所示, 机器人能够精确跳跃至不同位置的目标, 例如前方 1 米处(图 25biii)或前方 1.4 米处(图 25bii), 以及不同高度, 包括 0.44 米高的平台(图 25bi, 考虑到机器人高度仅为 1.1 米)。通过单一的



(a) Snapshot of the robot running on varying terrains

(b) Recorded phase plots of thigh and knee joints

图 23: 机器人在没有任何地形先验知识或高程估计的情况下, 在各种地形上奔跑。图 23a 记录了机器人在不同坡度地形上的奔跑情况, 从矢状方向的 7° 上坡开始, 接着是横向的 3° 斜坡, 然后是矢状方向的 10° 上坡, 最后过渡到平坦地面。该图最左侧一列展示了这些不同的地形类型。尽管地形多变, 机器人始终能够适应并保持稳定的奔跑步态, 具有明显的腾空阶段, 如图右侧列所示。图 23b 记录了机器人大腿和膝关节的相应相图 ($q^{L/R}_{3,4}$ 相对于 $\dot{q}^{L/R}_{3,4}$, 这些关节在运动控制中起主导作用), 显示出收敛的极限环。

通过离散地形策略, 机器人能够针对不同的跳跃目标调整其起跳动作, 并在着陆时有效管理巨大冲击后的角动量以保持稳定性。除了立定跳远 (向前 1.4 米) 和立定跳高 (0.44 米高度) 外, 我们还在该范围内进行了一系列不同的跳跃任务, 包括原地跳跃 (最高点离地间隙约 0.4 米) 以及跨越不同矢状距离跳上不同高度的平台。这些任务均使用同一策略完成, 如图 26 所示。值得注意的是, 使用同一控制器实现的 1.4 米立定跳远和跳上 0.44 米高平台, 是类人尺寸双足机器人领域中的新型运动能力。

3) 鲁棒跳跃机动: 我们通过图 27 所示的示例, 展示了所提方法获得的跳跃策略的鲁棒性。采用平坦地面策略, 我们命令机器人执行原地跳跃。在跳跃最高点, 我们施加了一个向后冲量扰动, 如图 27a 所示。这一显著扰动导致机器人偏离了其标称的原地跳跃轨迹 (如图 27b 所示), 使其着陆姿态发生显著变化。结果, 机器人以向后倾斜的姿势着陆, 脚趾上翘试图稳定自身。这种姿态带来了巨大挑战, 因为机器人变得欠驱动且几乎失去平衡。然而, 由于跳跃策略已训练为能够执行向后跳跃 (如前文图 25a_{ii} 所示), 机器人迅速调整了其预期着陆轨迹并执行了一次向后跳跃。通过这一

通过调整, 机器人能够更好地在空中修正其姿态, 以便在下次落地时达到更有利的构型。

需要注意的是, 跳跃策略从未经过专门训练来处理扰动。因此, 本实验突显了多功能跳跃策略的优势。机器人展示了将其学到的多样化任务泛化到实际部署中的能力, 从而制定出更优的机动和接触计划, 而非严格遵循给定任务。这详细报告了双足机器人在现实世界中执行跳跃时成功从扰动中恢复的过程, 说明了任务随机化的重要性。

备注 3: 通过使用行走、奔跑和跳跃的多功能策略, 机器人展现出在线自主制定接触策略的能力, 从而偏离了参考运动 (隐式) 提供的接触计划。这种能力增强了稳定性和鲁棒性。例如, 在跳跃实验中, 机器人常常在落地后断开接触并执行小跳, 以实现更好的落地构型, 如图 27 所示。这种能力在其他技能中也很明显, 例如站立 (图 11c)、行走 (与参考运动中的单支撑相反, 具有显著的双支撑阶段, 如图 17b 所示) 以及奔跑 (机器人并未严格遵循周期性奔跑参考运动的接触顺序, 如图 22 所示)。这种涌现的能力与接触隐式优化 (如 [42, 52, 53], 所追求的目标) 相一致。虽然这些先前的方法仅在双足机器人上实现了离线优化, 但我们的工作真实双足机器人上实现了在线优化。

备注 4: 我们注意到, 在跳跃实验中, 机器人在大幅跳跃后站立时偶尔会出现振荡,




图 24: 捕捉机器人在快速冲刺 100 米时意外受到扰动瞬间的快照, 展示了我们开发的多功能奔跑策略的鲁棒性。各帧画面与对应时间戳对齐。由于安全绳向后拉扯, 机器人速度骤降并开始侧倾, 同时基座偏航角出现显著漂移。尽管偏离了标称奔跑轨迹, 但通过广泛动力学随机化训练与多功能任务 (包括带横向与转向指令的低速奔跑) 增强的策略鲁棒性, 使机器人能够维持稳定并自行修正。

跳跃。这是由于学习单一强化学习策略同时掌握动态非周期性跳跃技能与静态站立技能存在挑战。跳跃过程中习得的特征可能偏向高加速运动, 难以轻易改变策略行为以实现完美静态站立。这也揭示了获取统一策略以学习所有不同运动技能 (融合动态与静态技能) 的挑战。但需指出, 跳跃策略仍能抑制站立时的此类振荡, 尽管需要更长的显著时间, 如补充视频 (视频 5) 所示。

4) 结果总结: 我们在真实世界中演示了 19 种不同的双足跳跃, 涵盖多种落地点、转向和高度变化。这些跳跃仅通过两种多功能策略实现: 平地策略与离散地形策略。通过大量真实世界实验, 我们以跳跃技能为例阐述了所提方法的两个关键方面。首先, 展示了所提策略的自适应性。机器人能够在飞行阶段后精准降落在指定目标点, 且无需全局位置反馈。为此, 机器人必须在起跳时产生精确动量。通过完成这些多样化跳跃任务, 基于强化学习的控制策略主要利用长期输入 / 输出历史, 展现了对机器人硬件动力学的自适应性, 从而控制机器人实现精确的起跳平移速度以着陆目标。其次, 强调了策略的鲁棒性。尽管未经扰动训练, 机器人仍能通过运用习得的敏捷恢复任务, 对跳跃过程中的意外扰动做出响应。

十一、如何训练你的双足机器人: 讨论

在详细阐述了我们的方法论、分析以及针对一系列双足运动技能通过强化学习实现的鲁棒、动态与多功能控制策略的实验后, 我们现在转向讨论在整个开发过程中学到的关键经验。我们的目标是提供有价值且普遍适用的见解, 以指导未来在复杂动态系统 (特别是双足和类人机器人) 中使用强化学习进行运动控制的研究。

以下部分的结构如下: (1) 我们首先在第十一节 A 部分讨论利用机器人输入 / 输出历史的重要性, 以及如何有效使用它 (通过使用双历史策略学习直接自适应控制)。

(2) 在第十一节 B 部分, 我们展示虽然正确使用机器人的输入 / 输出历史赋予控制器自适应性, 但通过任务随机化可以提高控制器的鲁棒性。(3) 在第十一节 C 部分, 我们提供强化学习可以带来的几个“额外好处”, 例如运动推理与优化, 以及接触规划。我们以关于通用控制策略与任务特定控制策略的小型辩论结束本次讨论。

A. 如何使用机器人的历史?

机器人的长输入 / 输出历史很重要: 在现有的基于强化学习的运动控制文献中, 关于如何使用机器人的历史尚未达成共识: 是使用短历史还是长历史, 是仅使用状态反馈的历史还是状态与动作对的历史。我们的研究清楚地证明了提供机器人输入和输出的长历史的好处, 尤其是在像双足机器人这样的高维高度非线性系统中。这种方法基于机器人的全阶动力学 (1), 表明输入 / 输出历史序列在识别待控制的动态系统方面更具信息量。这




图 25: 双足机器人 Cassie 使用两种单一多功能策略执行各种激进跳跃动作的快照。每一帧都对应相应的时间戳, 图中的纸标签代表期望的着陆目标。在图 25a 中, 使用平地策略, (i) 机器人能够原地跳跃并转向, (ii) 向后跳跃, 以及 (iii) 向前跳跃, 并准确降落在目标 (纸标签) 上。在 1 米前跳过程中, 机器人有趣地在首次着陆后额外向前跳了一步, 在第二次尝试中到达目标。这一额外动作在使用机器人标称模型的仿真中并未观察到。在图 25b 中, 使用离散地形策略, (iii) 机器人也能够执行 1 米前跳。此外, (ii) 机器人可以执行大幅度的立定跳远, 准确降落在 1.4 米前方, 以及 (i) 跳上一个高出地面 0.44 米且前方 0.88 米的高台。

这一论断得到了我们消融研究 (图 6) 的支持, 其中采用更长输入 / 输出历史的策略在实现不同运动技能时, 处理随机化动力学参数方面优于使用较短历史或仅状态长历史的策略。此外, 分析长输入 / 输出历史编码器的潜在嵌入 (图 9) 揭示, 它可以隐式捕获诸如接触事件、外力、系统动力学参数变化等信息, 甚至更多。这一发现引人入胜, 表明通过无模型强化学习优化, 并合理利用机器人的输入 / 输出, 可以学习提取用于动态控制的关键信息。

短历史补充长历史: 虽然长输入 / 输出历史可以改善控制性能, 但若没有适当的公式化, 其有效性有限。我们的消融研究 (图 6) 表明, 仅使用长输入 / 输出历史并不优于采用短历史的策略, 这与 [79] 的报告一致。我们发现, 为了充分利用长历史的优势, 有效的方法是将短输入 / 输出历史直接提供给基础 MLP, 绕过长历史编码器, 这被称为双历史方法。这一修改显著提升了各种运动技能的学习性能 (图 6), 并在真实世界实验中优于其他方法 (图 7)。虽然长历史已在基于强化学习的运动控制中被引入, 但短历史的补充使用是一种新颖的方法。许多先前的工作缺乏对基础策略的这一补充, 可能忽略了在实时控制复杂机器人时的一个关键元素——近期输入 / 输出历史。当仅使用长输入 / 输出历史时, 近期事件可能在长历史编码后的潜在嵌入中变得模糊, 而通过将显式短输入 / 输出历史与长历史编码器结合, 可以解决这一问题。这种显式的近期输入 / 输出反馈也有助于在我们选择使用长历史时应对非马尔可夫性质。

机器人输入 / 输出历史。此外, 虽然长历史更有利于系统辨识和状态估计, 但短时特征更有利于对长历史编码器产生的高频估计进行去噪。尽管对于静态机械臂 [5] 或四足机器人 [71] 等较简单系统, 这种方法可能并非必需 (如先前研究所示), 但对于我们工作中双足机器人这类更复杂的动态系统, 这种双历史方法的优势十分显著。另外, 虽然双历史方法能够通过训练非循环策略 (利用显式长度的历史序列) 来提升学习效果, 但我们发现, 在双足运动控制方面, 它难以辅助循环策略的训练。详情见附录 F。

我们学习的是鲁棒控制器还是自适应控制器? : 强化学习中的自适应性并非新概念, 控制理论界已有显著努力将自适应控制与强化学习相结合, 例如 [4]。另一方面, 许多基于强化学习的运动控制研究已在实际应用中展现出鲁棒性, 有人将其归因于通过动力学随机化训练的策略的鲁棒性, 也有人归因于强化学习中的自适应性。该领域的许多研究者都好奇究竟哪个属性发挥了关键作用。这一好奇心促使我们在本工作中开展了广泛的实证研究, 以探究强化学习策略的自适应性与鲁棒性。我们证明, 在基于强化学习的控制器中, 这两个方面可能源于不同来源: 自适应性可源于对机器人输入 / 输出历史的合理利用, 而鲁棒性则可通过任务随机化引入。动力学随机化则处于中间地带: 为了对不同动力学具有鲁棒性, 策略可以通过随机化动力学进行训练, 从而学会有效利用历史 (如果提供) 来适应动力学变化。




图 26: 使用所提出的多功能跳跃策略进行更多样化双足跳跃的快照。地面上的纸标签指示着陆目标。使用与图 25a 相同的平地策略, 机器人还能够执行侧向跳跃 (图 26a 中向右 0.3 米)、对角跳跃 (图 26b 中向前 0.3 米并向左 0.3 米), 以及一种复杂的跳跃动作, 同时融合了向前 (0.5 米)、侧向 (0.2 米) 和转向 (-45°) (图 26c)。使用与图 25b 相同的离散地形策略, 机器人还可以原地跳跃 (图 26d), 跳跃到分别位于 (图 26e) 前方 0.88 米和上方 0.17 米、(图 26f) 前方 0.88 米和上方 0.32 米, 以及 (图 26g) 前方 0.64 米和上方 0.32 米的目标位置。




图 27: 使用多功能平地策略进行跳跃时的鲁棒性测试快照。在图 27a 中, 机器人在原地跳跃达到最高点时受到了意外的向后扰动。这与图 27b 形成对比, 后者中机器人在无扰动情况下执行相同任务, 作为基线。尽管由于扰动在着陆时向后倾斜, 机器人自发地执行了一个向后跳跃——这是它在其他任务 (如向后跳跃) 中学到的动作——并成功在着陆后保持平衡。这种鲁棒性仅通过任务随机化实现, 因为跳跃策略并未在模拟扰动下进行训练。

我们想学习什么, 直接自适应控制还是间接自适应控制? : 认识到正确使用长输入 / 输出历史的价值, 我们提供了一种替代方法的讨论: 利用历史来估计选定的环境参数以进行控制。这种方法被称为教师 - 学生 (TS) 训练策略 [71] 或 RMA [74], 可视为强化学习版本的间接自适应控制。然而, 对于实时动态运动控制, 我们的发现表明, 一种直接自适应控制方法——将长输入 / 输出历史直接集成到控制器中, 而不显式估计模型参数——能产生更好的性能, 这得到了以下证据的支持。

结果见第七节。当我们考虑通过我们提出的方法获得的 historyencoder (图 9) 的能力时, 其背后的根本原因变得更加清晰。它不仅适应时不变建模参数, 还能捕捉机器人认为重要的关键信息, 如时变接触事件。这与 TS 或 RMA 方法形成对比, 后者仅限于估计建模参数, 在诸如双足奔跑 (图 6) 等具有挑战性的任务中可能会遇到估计错误或失败。与将基础控制策略和历史编码器分开训练的 TS 和 RMA 相比, 我们的方法无需专家监督即可进行端到端训练。

赋予机器人更多自由去探索和利用有用信息。

B. 多能性提升鲁棒性

除了通过合理利用机器人长输入 / 输出历史带来的适应性外, 使用强化学习进行运动控制的另一个关键优势是鲁棒性。当策略通过动力学随机化训练时, 它们能够对环境变化(如从仿真到现实的迁移)保持鲁棒。然而, 我们的研究表明, 强化学习策略的鲁棒性远不止于此, 任务随机化作为另一项关键策略浮现出来。

我们的消融研究(图 10)支持了这一观点。虽然动力学随机化扩展了机器人在特定任务内训练时的轨迹范围, 但它并未显著改变训练分布。例如, 在站立策略中进行大量随机化, 并不能让机器人获得行走或跳跃恢复等新的运动技能(图 11、12)。而任务随机化则以不同方式赋予鲁棒性。通过在多样化任务(如变化行走速度或跳跃目标)上进行训练, 机器人学会了泛化并利用这些已学任务, 即使没有特定的动力学随机化, 也能辅助恢复, 如图 10 所示。有趣的是, 机器人对干扰的响应因鲁棒性的来源而异。在大量动力学随机化下, 它倾向于遵循指令任务; 而使用通过任务随机化训练的多能策略时, 它对外部干扰表现出更多的顺从性, 偏离给定的指令。

尽管以往一些基于强化学习的运动控制研究无意中实现了多能策略, 并将其鲁棒性的成功主要归因于动力学随机化, 但我们的研究区分了鲁棒性的来源。我们建议在未来的强化学习应用中增加任务随机化, 以实现鲁棒的运动控制。

C. 探索强化学习能为腿部运动控制带来什么

在本小节中, 我们旨在更广泛地探讨强化学习在控制复杂动态系统方面的潜力(及其局限性)。

轨迹优化与运动推理: 通过使用强化学习控制高维双足机器人, 参考运动常被用于实现自然步态, 正如我们工作中所展示的那样。虽然有先前的研究尝试基于机器人动力学模型进行轨迹优化以获取参考运动, 例如 [107] 以及本工作中的行走策略, 但我们也表明, 这种“预优化”对于基于强化学习的控制来说可能并非必要。例如, 我们在双足跑步和跳跃方面的工作, 仅使用了运动学上可行的重定向人体运动与动画, 结果表明, 只要动作空间未被添加的参考运动破坏(如图 6 中的残差方法), 机器人就能通过试错学习贴近参考运动并保持动态稳定性。这表明强化学习能够联合学习轨迹优化与实时控制。此外, 我们的工作证明, 强化学习还能使机器人推断出超出所提供的

参考运动范围的动作。例如, 机器人可以从单一参考运动中学到变化多样的跑步或跳跃动作, 这通过任务随机化和目标条件策略实现。然而, 使用单一参考运动有其局限性。例如, 如果我们仅提供一个前向跳跃的参考运动, 机器人仅基于任务完成奖励来学习后向跳跃将变得困难。因此, 选择一个有效的单一参考运动需要其相对无偏, 例如本工作中使用的原地跳跃运动。

运动(与接触)规划: 在我们的真实世界实验中(第 X 节), 我们观察到大量实例, 其中机器人展示了执行一系列变化动作并伴随不同接触序列以进行恢复的能力。例如, 当从站立姿势受到扰动时, 机器人会施加多种不同的行走步态以恢复站立, 而无需在线运动或接触序列调度器(图 12a)。这反映了更长时域的运动规划能力, 区别于其以 33 赫兹运行的实时运动控制。跳跃实验(如图 26c、27a)进一步支持了这一点。这些观察表明, 当提供不变的参考运动时, 强化学习策略能够在部署过程中自主为不同任务开发接触序列。这一能力也暗示, 向策略指定接触序列可能不太有利, 因为(腿部)机器人将拥有更少的自由度来探索更优的接触模式以增强稳定性和鲁棒性。简而言之, 利用强化学习进行接触至关重要的腿部运动控制的优势在于, 能够在不显式考虑接触的情况下进行控制。

学习统一控制策略的可能性: 鉴于本工作中开发的所有策略都使用相同的控制架构和训练流程, 因此有可能获得针对不同技能的统一策略。这一可能性进一步得到支持, 因为在所有动态行走、奔跑和跳跃策略中, 我们都将其与一项独特的技能——静态站立——相结合。例如, 实现奔跑与站立技能之间转换的策略, 展示了在该频谱内学习不同技能(如较慢速度的行走)的潜力。通过使用精心设计的 MDP 以及附录 B 中介绍的新技能训练附加阶段, 可以实现将站立技能与其他技能相结合。然而, 如果采用这种相对简单的方法, 随着机器人可能遭受灾难性遗忘问题, 持续添加不同的新技能将具有挑战性。

如 [92] 所述, 使用对抗性运动先验 (AMP) 可能有助于获得一个统一的控制策略, 用于多样化的运动技能, 无需专门调整运动跟踪奖励。然而, 将 AMP 应用于激进的真实世界双足运动仍然是一个挑战。基于 GAN 的方法容易发生模式崩溃, 并且难以模仿在短时间内发生的激进运动。行动策略可以通过模仿跳跃的部分动作来“欺骗”判别器, 而不执行完整的运动。双足机器人较大的仿真到现实差距进一步加剧了这一问题。

开发这种统一策略的另一种潜在方法可以

可以通过持续强化学习来不断学习新技能,例如 [108],或者利用由特定技能策略收集的离线数据集进行模仿学习,例如 [109]。然而,利用这些方法提高双足机器人的鲁棒性并克服仿真到现实的差距仍然是一个悬而未决的问题。一种实用的方法可能是学习在不同预训练的技能特定策略之间进行转换,例如 [110]。无论采用哪种方式,本文提出的针对技能特定策略的方法都提供了一个坚实的起点。

泛化与精度:在我们的研究中,我们展示了强化学习在动态运动控制中许多泛化能力的实例,涵盖了各种任务和动力学参数。虽然控制精度并非主要关注点,但在双足跳跃等技能中,它变得显而易见。在这些任务中,机器人成功跳至指定目标(第 X-C 节),这需要精确的起飞平移速度以实现准确着陆。然而,使用一个能处理多种任务和动力学变化的策略来实现完美的精确控制仍然是一个悬而未决的问题。例如,在现实世界的快速奔跑任务中,以微小误差跟踪特定的矢状速度具有挑战性(图 22c)。然而,像基础模型这样的泛化运动控制策略的优势在于,它为在特定下游任务(如精确控制)上进行进一步微调提供了一个坚实的起点。另一方面,针对精度优化的控制器可能仅限于微调后的任务。我们呈现这些权衡供读者思考,强调了基于强化学习的动态运动控制中泛化与精度之间的平衡。

XII. 结论与未来工作

总之,本文对使用深度强化学习开发双足机器人多功能、鲁棒且动态的运动控制器进行了全面研究。本文引入了一种双历史方法,将机器人的输入/输出(I/O)历史整合到基于强化学习的控制器中,并强调了其重要性。我们展示了所提出的基于强化学习的控制器的适应性和鲁棒性,特别强调了设计良好的长 I/O 历史编码器如何能够适应时不变的动力学变化以及时变事件(如变化的接触)。此外,任务随机化通过鼓励机器人完成不同任务来探索更广泛的场景,显著增强了鲁棒性,补充了通过传统动力学随机化实现的鲁棒性。所提出的方法在双足机器人 Cassie 上得到了充分验证,成功地在现实世界中实现了多功能且鲁棒的行走、奔跑和跳跃技能。这些实验包括多项最先进的结果,例如在长时间跨度(459 天)内保持稳定性能的行走控制、在 400 米短跑和复杂地形中展示的多功能奔跑能力,以及包括最远 1.4 米前向跳跃和 0.44 米高跳跃在内的大量跳跃任务。

未来,我们希望该方法能够扩展到人形机器人,使其也能利用上半身运动实现敏捷性和稳定性。此外,将深度视觉

直接集成到运动控制器中可以通过一种直接的方式实现,即在所提出的控制架构中,额外的深度编码器可以与机器人的输入/输出历史编码器协同工作。我们鼓励读者也在自己的双足机器人上尝试这种用于视觉控制的设置。随着本工作的进展,我们认为在实现人类尺寸双足机器人有效运动控制方面的大部分实际问题都可以得到解决。对于双足机器人社区而言,一个令人兴奋的方向是将双足运动与双臂操作相结合,以应对长时域的操作-移动任务,从而开辟该领域的新可能性。

致谢

本工作部分得到了美国国家科学基金会(NSF)资助号 CMMI-1944722、人工智能研究所(The AI Institute)以及加拿大高等研究院(CIFAR)的支持。作者感谢 Xuxin Cheng 在本工作初期开发中的帮助。作者感谢 Daniel Wong 为 Cassie 设计的跑鞋。作者还要感谢 Bike Zhang、Jiaming Chen、Lizhi Yang、Xiaoyu Huang、Yiming Ni、Yufeng Chi、Akshay Thirugnanam、Yuanzhuo Li、曾军博士以及 Ayush Agrawal 博士在实验中的帮助。

参考文献

- [1] M. H. Raibert, M. A. Chepponis, and H. B. Brown, "Experiments in balance with a 3d one-legged hopping machine," *International Journal of Robotics Research*, vol. 3, no. 2, pp. 75 – 92, June 1984.
- [2] E. R. Westervelt, J. W. Grizzle, and D. E. Koditschek, "Hybrid zero dynamics of planar biped walkers," *IEEE transactions on automatic control*, vol. 48, no. 1, pp. 42–56, 2003.
- [3] D. Goswami and P. Vadakkepat, "Planar bipedal jumping gaits with stable landing," *IEEE Transactions on Robotics*, vol. 25, no. 5, pp. 1030–1046, 2009.
- [4] A. M. Annaswamy, "Adaptive control and intersections with reinforcement learning," *Annual Review of Control, Robotics, and Autonomous Systems*, vol. 6, pp. 65–93, 2023.
- [5] X. B. Peng, M. Andrychowicz, W. Zaremba, and P. Abbeel, "Sim-to-real transfer of robotic control with dynamics randomization," in *2018 IEEE international conference on robotics and automation (ICRA)*, 2018, pp. 3803–3810.
- [6] Z. Li, X. B. Peng, P. Abbeel, S. Levine, G. Berseth, and K. Sreenath, "Robust and versatile bipedal jumping control through reinforcement learning," *Robotics: Science and Systems XIX, Daegu, Republic of Korea*, 2023.
- [7] Y. Gong, R. Hartley, X. Da, A. Hereid, O. Harib, J.-K. Huang, and J. Grizzle, "Feedback control of a cassie bipedal robot: Walking, standing, and riding a segway," in *2019 American Control Conference (ACC)*. IEEE, 2019, pp. 4559–4566.
- [8] Z. Li, C. Cummings, and K. Sreenath, "Animated cassie: A dynamic relatable robotic character," in

- 2020 年 IEEE/RSJ 国际智能机器人与系统大会 (IROS), 2020 年, 第 3739–3746 页。[9] L. Yang, Z. Li, J. Zeng, and K. Sreenath, “贝叶斯优化与混合零动力学相遇: 双足运动控制的安全参数学习”, 载于 2022 年国际机器人学与自动化大会 (ICRA)。IEEE, 2022 年, 第 10456–10462 页。[10] J. Reher and A. D. Ames, “用于顺应性混合零动力学行走的控制李雅普诺夫函数”, arXiv 预印本 arXiv:2107.04241, 2021 年。[11] Z. Xie, P. Clary, J. Dao, P. Morais, J. Hurst, and M. Panne, “为 Cassie 学习运动技能: 迭代设计与仿真到现实迁移”, 载于机器人学习大会。PMLR, 2020 年, 第 317–329 页。[12] J. Siekmann, S. Valluri, J. Dao, L. Bermillo, H. Duan, A. Fern, and J. Hurst, “为人形尺度双足运动学习基于记忆的控制”, 载于机器人科学与系统, 2020 年。[13] Z. Li, X. Cheng, X. B. Peng, P. Abbeel, S. Levine, G. Berseth, and K. Sreenath, “用于双足机器人鲁棒参数化运动控制的强化学习”, 载于 2021 年 IEEE 国际机器人学与自动化大会 (ICRA)。IEEE, 2021 年, 第 2811–2817 页。[14] J. Siekmann, Y. Godse, A. Fern, and J. Hurst, “通过周期性奖励组合实现所有常见双足步态的仿真到现实学习”, 载于 2021 年 IEEE 国际机器人学与自动化大会 (ICRA)。IEEE, 2021 年, 第 7309–7315 页。[15] J. Siekmann, K. Green, J. Warila, A. Fern, and J. Hurst, “通过仿真到现实强化学习实现盲态双足楼梯穿越”, 机器人科学与系统, 2021 年。[16] J. Dao, K. Green, H. Duan, A. Fern, and J. Hurst, “在未感知动态负载下双足运动的仿真到现实学习”, 载于 2022 年国际机器人学与自动化大会 (ICRA)。IEEE, 2022 年, 第 10449–10455 页。[17] F. Yu, R. Batke, J. Dao, J. Hurst, K. Green, and A. Fern, “通过仿真到现实强化学习实现动态双足转向”, 载于 2022 年 IEEE-RAS 第 21 届国际类人机器人大会 (Humanoids)。IEEE, 2022 年, 第 903–910 页。[18] Y. Gong and J. W. Grizzle, “双足运动反馈控制中的零动力学、摆模型与角动量”, 动态系统、测量与控制杂志, 第 144 卷, 第 12 期, 第 121006 页, 2022 年。[19] X. Xiong and A. Ames, “基于 H-LIP 步态合成与步态稳定的三维欠驱动双足行走”, IEEE 机器人学汇刊, 第 38 卷, 第 4 期, 第 2405–2425 页, 2022 年。[20] A. Agrawal, “腿式机器人的基于模型设计: 预测控制与强化学习”, 博士论文, 加州大学伯克利分校, 2022 年。[21] W. Yang and M. Posa, “冲击不变控制: 最大化冲击过程中的控制权限”, arXiv 预印本 arXiv:2303.00817, 2023 年。[22] D. Crowley, J. Dao, H. Duan, K. Green, J. Hurst, and A. Fern, “优化双足机器人 100 米短跑运动, 并与人类跑步进行比较”, 载于 2023 年 IEEE 国际机器人与自动化大会 (ICRA)。IEEE, 2023, 第 12205–12211 页。[23] X. Xiong and A. D. Ames, “双足跳跃: 基于优化控制的降阶模型嵌入”, 载于 2018 年 IEEE/RSJ 国际智能机器人与系统大会 (IROS)。IEEE, 2018, 第 3821–3828 页。[24] W. Yang and M. Posa, “冲击不变控制及其在双足运动中的应用”, 载于 2021 年 IEEE/RSJ 国际智能机器人与系统大会 (IROS)。IEEE, 2021, 第 5151–5158 页。[25] P. M. Wensing, M. Posa, Y. Hu, A. Escande, N. Mansard 和 A. Del Prete, “动态腿式机器人的基于优化控制”, IEEE 机器人学汇刊, 2023。[26] A. Hereid, O. Harib, R. Hartley, Y. Gong 和 J. W. Grizzle, “使用 c-FROST 的快速轨迹优化及其在 Cassie 系列动态行走双足机器人上的演示”, 载于 2019 年 IEEE/RSJ 国际智能机器人与系统大会 (IROS), 2019, 第 4722–4729 页。[27] M. Fevre, P. M. Wensing 和 J. P. Schmiedeler, “基于 CasADi 的快速双足步态优化”, 载于 2020 年 IEEE/RSJ 国际智能机器人与系统大会 (IROS)。IEEE, 2020, 第 3672–3678 页。[28] T. Marcucci, M. Gabiccini 和 A. Artoni, “针对具有非预定接触序列的铰接体的两阶段轨迹优化策略”, IEEE 机器人学与自动化快报, 第 2 卷, 第 1 期, 第 104–111 页, 2016。[29] A. Hereid, C. M. Hubicki, E. A. Cousineau 和 A. D. Ames, “动态类人运动: 一种可扩展的 HZD 步态优化公式”, IEEE 机器人学汇刊, 第 34 卷, 第 2 期, 第 370–387 页, 2018。[30] D. E. Orin, A. Goswami 和 S.-H. Lee, “类人机器人的质心动力学”, 自主机器人, 第 35 卷, 第 161–176 页, 2013。[31] S. Kajita, F. Kanehiro, K. Kaneko, K. Yokoi 和 H. Hirukawa, “三维线性倒立摆模型: 双足行走模式生成的简单建模”, 载于 2001 年 IEEE/RSJ 国际智能机器人与系统大会。拓展机器人技术在下个千年的社会角色 (目录号 01CH37180), 第 1 卷。IEEE, 2001, 第 239–246 页。[32] J. Rummel, Y. Blum, H. M. Maus, C. Rode 和 A. Seyfarth, “具有柔性腿的稳定鲁棒行走”, 载于 2010 年 IEEE 国际机器人与自动化大会。IEEE, 2010, 第 5250–5255 页。[33] M. Vukobratović 和 B. Borovac, “零力矩点——其三十五年历程”, 国际类人机器人学杂志, 第 1 卷, 第 01 期, 第 157–173 页, 2004。[34] J. Pratt, T. Koolen, T. De Boer, J. Rebula, S. Cotton, J. Carff, M. Johnson 和 P. Neuhaus, “基于捕获性的腿式运动分析与控制, 第二部分: 应用于 M2V2 下半身类人机器人”, 国际

- 国际机器人研究杂志, 第 31 卷, 第 10 期, 第 1117–1133 页, 2012 年。[35] P. Fernbach, S. Tonneau, O. Stasse, J. Carpentier, and M. Taïx, “C-croc: 多接触场景下腿式机器人质心动力学轨迹的连续凸优化方法,” *IEEE Transactions on Robotics*, 第 36 卷, 第 3 期, 第 676–691 页, 2020 年。[36] S. Kuindersma, F. Permenter, and R. Tedrake, “一种用于稳定动态运动的可靠求解的二次规划,” 载于 2014 年 IEEE 国际机器人与自动化大会 (ICRA)。IEEE, 2014 年, 第 2589–2594 页。[37] E. Daneshmand, M. Khadiv, F. Grimmering, and L. Righetti, “具有摆动脚动力学的变时域 MPC 用于双足行走控制,” *IEEE Robotics and Automation Letters*, 第 6 卷, 第 2 期, 第 2349–2356 页, 2021 年。[38] L. Sentis and O. Khatib, “一种用于在人类环境中操作的人形机器人全身控制框架,” 载于 2006 年 IEEE 国际机器人与自动化会议论文集 (ICRA 2006)。IEEE, 2006 年, 第 2641–2648 页。[39] F. L. Moro and L. Sentis, “人形机器人的全身控制,” *Humanoid Robotics: A reference*, Springer, Dordrecht, 2019 年。[40] K. Bouyarmane and A. Kheddar, “使用多目标控制器合成具有变化接触配置的模拟人形机器人运动,” 载于 2011 年 IEEE/RSJ 国际智能机器人与系统大会。IEEE, 2011 年, 第 4414–4419 页。[41] P. M. Wensing and D. E. Orin, “人形机器人质心动力学的改进计算及其在全身控制中的应用,” *International Journal of Humanoid Robotics*, 第 13 卷, 第 1 期, 第 1550039 页, 2016 年。[42] M. Posa, C. Cantu, and R. Tedrake, “一种通过接触进行刚体轨迹优化的直接方法,” *The International Journal of Robotics Research*, 第 33 卷, 第 1 期, 第 69–81 页, 2014 年。[43] S. Caron, A. Kheddar, and O. Tempier, “使用全身导纳控制实现 HRP-4 人形机器人爬楼梯稳定,” 载于 2019 年国际机器人与自动化大会 (ICRA)。IEEE, 2019 年, 第 277–283 页。[44] T. Takenaka, T. Matsumoto, T. Yoshiike, and S. Shirokura, “双足机器人实时运动生成与控制——第二篇报告: 跑步步态模式生成,” 载于 2009 年 IEEE/RSJ 国际智能机器人与系统大会。IEEE, 2009 年, 第 1092–1099 页。[45] K. Sreenath, H.-W. Park, I. Poulakakis, and J. W. Grizzle, “将主动力控制嵌入兼容混合零动力学中实现 Mabel 上的稳定快速奔跑,” *The International Journal of Robotics Research*, 第 32 卷, 第 3 期, 第 324–345 页, 2013 年。[46] W.-L. Ma, S. Kolathaya, E. R. Ambrose, C. M. Hubicki, and A. D. Ames, “使用 Durus-2D 进行双足机器人奔跑: 弥合理论与实验之间的差距,” 载于第 20 届国际会议论文集混合系统: 计算与控制, 2017 年, 第 265–274 页。[47] M. Chignoli, D. Kim, E. Stanger-Jones, and S. Kim, “麻省理工学院人形机器人: 用于杂技行为的设计、运动规划与控制”, 载于 2020 年 IEEE-RAS 第 20 届国际人形机器人会议 (Humanoids)。IEEE, 2021 年, 第 1–8 页。[48] H. Qi, X. Chen, Z. Yu, G. Huang, Y. Liu, L. Meng, and Q. Huang, “基于质心角动量控制与冲击吸收的人形机器人垂直跳跃”, *IEEE Transactions on Robotics*, 2023 年。[49] R. Deits and R. Tedrake, “基于混合整数凸优化的不平坦地形足迹规划”, 载于 2014 年 IEEE-RAS 国际人形机器人会议。IEEE, 2014 年, 第 279–286 页。[50] A. Ibanez, P. Bidaud, and V. Padois, “从混合整数模型预测控制中涌现人形行走行为”, 载于 2014 年 IEEE/RSJ 国际智能机器人与系统会议。IEEE, 2014 年, 第 4014–4021 页。[51] H. Dai, A. Valenzuela, and R. Tedrake, “基于质心动力学与完整运动学的全身运动规划”, 载于 2014 年 IEEE-RAS 国际人形机器人会议。IEEE, 2014 年, 第 295–302 页。[52] L. Drnach and Y. Zhao, “基于随机互补性的不确定地形鲁棒轨迹优化”, *IEEE Robotics and Automation Letters*, 第 6 卷, 第 2 期, 第 1168–1175 页, 2021 年。[53] B. Landry, J. Lorenzetti, Z. Manchester, and M. Pavone, “通过接触规划的双层优化: 一种半直接方法”, 载于机器人研究: 第 19 届国际研讨会 ISRR, 2022 年, 第 789–804 页。[54] Y. Zhu, Z. Pan, and K. Hauser, “利用学习可变形接触的接触隐式轨迹优化与双层优化”, 载于 2021 年 IEEE 国际机器人与自动化会议 (ICRA), 2021 年, 第 9921–9927 页。[55] S. Le Cleac’h, T. A. Howell, S. Yang, C.-Y. Lee, J. Zhang, A. Bishop, M. Schwager, and Z. Manchester, “快速接触隐式模型预测控制”, *IEEE Transactions on Robotics*, 2024 年。[56] A. Meduri, P. Shah, J. Viereck, M. Khadiv, I. Havoutis, and L. Righetti, “Biconmp: 用于全身运动规划的非线性模型预测控制框架”, *IEEE Transactions on Robotics*, 第 39 卷, 第 2 期, 第 905–922 页, 2023 年。[57] K. Sreenath, H.-W. Park, I. Poulakakis, and J. W. Grizzle, “用于 Mabel 上稳定、高效和快速双足行走的顺应性混合零动力学控制器”, *The International Journal of Robotics Research*, 第 30 卷, 第 9 期, 第 1170–1193 页, 2011 年。[58] X. Da, O. Harib, R. Hartley, B. Griffin, and J. W. Grizzle, “从欠驱动双足步态的二维设计到三维实现: 带速度跟踪的行走”, *IEEE Access*, 第 4 卷, 第 3469–3478 页, 2016 年。[59] T. Takenaka, T. Matsumoto, and T. Yoshiike, “双足机器人的实时运动生成与控制——第一报: 行走步态模式生成”, 载于

- 2009 年 IEEE/RSJ 国际智能机器人与系统大会。IEEE, 2009, 第 1084–1091 页。[60]M. G. Boroujeni, E. Daneshman, L. Righetti, 和 M. Khadij, “双足机器人行走与奔跑的统一框架,” 载于 2021 年第 20 届国际先进机器人大会 (ICAR). IEEE, 2021, 第 396–403 页。[61] K. Kojima, Y. Kojio, T. Ishikawa, F. Sugai, Y. Kakiuchi, K. Okada, 和 M. Inaba, “一种面向动态运动以减轻重量的机器人设计方法: 人形机器人 JAXON3-P 的设计与跳跃运动的实现,” 载于 2019 年 IEEE-RAS 第 19 届国际人形机器人大会 (Humanoids). IEEE, 2019, 第 586–593 页。[62]R. Deits, S. Kuindersma, M. P. Kelly, T. Koolen, Y. Abe, 和 B. Stephens, “机器人运动与在线轨迹优化,” 2022 年 12 月 29 日, 美国专利申请号 17/358,628。[63]G. Margolis, G. Yang, K. Paigwar, T. Chen, 和 P. Agrawal, “通过强化学习实现快速运动,” 载于机器人学: 系统与科学, 2022。[64]S. Chen, B. Zhang, M. W. Mueller, A. Rai, 和 K. Sreenath, “学习四足机器人运动的力矩控制,” 载于 2023 年 IEEE-RAS 第 22 届国际人形机器人大会 (Humanoids), 2023, 第 1–8 页。[65] G. Feng, H. Zhang, Z. Li, X. B. Peng, B. Basireddy, L. Yue, Z. Song, L. Yang, Y. Liu, K. Sreenath 等人, “Genloco: 四足机器人通用运动控制器,” 载于机器人学习大会。PMLR, 2023, 第 1893–1903 页。[66] Z. Fu, X. Cheng, 和 D. Pathak, “深度全身控制: 学习操作与运动的统一策略,” 载于机器人学习大会。PMLR, 2023, 第 138–149 页。[67] A. Kumar, Z. Li, J. Zeng, D. Pathak, K. Sreenath, 和 J. Malik, “为双足机器人适配快速运动适应,” 载于 2022 年 IEEE/RSJ 国际智能机器人与系统大会 (IROS), 2022, 第 1161–1168 页。[68]J. Hwangbo, J. Lee, A. Dosovitskiy, D. Bellicoso, V. Tsounis, V. Koltun, 和 M. Hutter, “为腿式机器人学习敏捷与动态运动技能,” 科学机器人, 第 4 卷, 第 26 期, 第 eaau5872 页, 2019。[69] A. Escontrela, X. B. Peng, W. Yu, T. Zhang, A. Iscen, K. Goldberg, 和 P. Abbeel, “对抗性运动先验可作为复杂奖励函数的良好替代,” 载于 2022 年 IEEE/RSJ 国际智能机器人与系统大会 (IROS). IEEE, 2022, 第 25–32 页。[70]X. Huang, Z. Li, Y. Xiang, Y. Ni, Y. Chi, Y. Li, L. Yang, X. B. Peng, 和 K. Sreenath, “通过强化学习创建动态四足机器人守门员,” 载于 2023 年 IEEE/RSJ 国际智能机器人与系统大会 (IROS), 2023, 第 2715–2722 页。[71]J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, 和 M. Hutter, “在复杂地形上学习四足运动,” 科学机器人, 第 5 卷, 第 47 期, p. eabc5986, 2020。[72] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, 和 M. Hutter, “在野外环境中学习四足机器人的鲁棒感知运动,” 《科学机器人》, 第 7 卷, 第 62 期, p. eabk2822, 2022。[73] Y. Shao, Y. Jin, X. Liu, W. He, H. Wang, 和 W. Yang, “通过相位引导控制器学习四足机器人的自由步态转换,” 《IEEE 机器人与自动化快报》, 第 7 卷, 第 2 期, pp. 1230–1237, 2021。[74] A. Kumar, Z. Fu, D. Pathak, 和 J. Malik, “Rma: 腿式机器人的快速运动适应,” 《机器人学: 系统与科学》, 2021。[75] Z. Xie, G. Berseth, P. Clary, J. Hurst, 和 M. van de Panne, “基于深度强化学习的 Cassie 反馈控制,” 载于 2018 年 IEEE/RSJ 国际智能机器人与系统会议 (IROS). IEEE, 2018, pp. 1241–1246。[76] D. Rodriguez 和 S. Behnke, “Deepwalk: 基于深度强化学习的全向双足步态,” 载于 2021 年 IEEE 国际机器人与自动化大会 (ICRA), 2021, pp. 3033–3039。[77] G. A. Castillo, B. Weng, W. Zhang, 和 A. Hereid, “基于强化学习的级联运动策略设计用于鲁棒三维双足运动,” 《IEEE Access》, 第 10 卷, pp. 20135–20148, 2022。[78] I. Radosavovic, T. Xiao, B. Zhang, T. Darrell, J. Malik, 和 K. Sreenath, “基于强化学习的现实世界人形机器人运动,” 《科学机器人》, 第 9 卷, 第 89 期, p. eadi9579, 2024。[79] R. P. Singh, Z. Xie, P. Gergondet, 和 F. Kanehiro, “利用电流反馈学习人形机器人双足行走,” 《IEEE Access》, 2023。[80] T. Haarnoja, S. Ha, A. Zhou, J. Tan, G. Tucker, 和 S. Levine, “通过深度强化学习学会行走,” 《机器人学: 系统与科学 (RSS)》, 2019。[81]P. Wu, A. Escontrela, D. Hafner, P. Abbeel, 和 K. Goldberg, “白日梦者: 用于物理机器人学习的世界模型,” 载于《机器人学习会议》. PMLR, 2023, pp. 2226–2240。[82] L. Smith, I. Kostrikov, 和 S. Levine, “在公园散步: 20 分钟内通过无模型强化学习学会行走,” 《机器人学: 系统与科学 (RSS) 演示》, 第 2 卷, 第 3 期, p. 4, 2023。[83] X. B. Peng, E. Coumans, T. Zhang, T.-W. Lee, J. Tan, 和 S. Levine, “通过模仿动物学习敏捷的机器人运动技能,” 《机器人学: 系统与科学 (RSS)》, 2020。[84] L. Smith, J. C. Kew, X. B. Peng, S. Ha, J. Tan, 和 S. Levine, “持续学习的腿式机器人: 在现实世界中微调运动策略,” 载于 2022 年国际机器人与自动化大会 (ICRA). IEEE, 2022, pp. 1593–1599。[85] T. Westenbroek, F. Castaneda, A. Agrawal, S. Sastry, 和 K. Sreenath, “用于鲁棒高效机器人强化学习的李雅普诺夫设计,” 载于第六届机器人学习年度会议, 2022。[86] W. Yu, V. C. Kumar, G. Turk, 和 C. K. Liu, “双足运动的仿真到现实迁移,” 载于 2019 年 iee/rsj

- 国际智能机器人与系统会议 (IROS), 2019 年, 第 3503–3510 页。[87] Z. Fu, A. Kumar, J. Malik, and D. Pathak, “最小化能量消耗导致腿式机器人步态的出现”, 载于第五届机器人学习年会, 2021 年。
- [88] G. Ji, J. Mun, H. Kim, and J. Hwangbo, “控制策略与状态估计器的并发训练用于动态鲁棒腿式运动”, IEEE 机器人与自动化快报, 第 7 卷, 第 2 期, 第 4630–4637 页, 2022 年。
- [89] G. B. Margolis and P. Agrawal, “多方式行走: 通过行为多样性调整机器人控制以实现泛化”, 载于机器人学习会议。PMLR, 2023 年, 第 22–31 页。
- [90] D. Kalashnikov, J. Varley, Y. Chebotar, B. Swanson, R. Jonschkowski, C. Finn, S. Levine, and K. Hausman, “Mt-opt: 大规模连续多任务机器人强化学习”, arXiv 预印本 arXiv:2104.08212, 2021 年。
- [91] X. Cheng, A. Kumar, and D. Pathak, “腿作为操纵器: 将四足敏捷性推至运动之外”, 载于 2023 年 IEEE 国际机器人与自动化大会 (ICRA), 2023 年, 第 5106–5112 页。
- [92] X. B. Peng, Z. Ma, P. Abbeel, S. Levine, and A. Kanazawa, “Amp: 用于风格化物理角色控制的对抗性运动先验”, ACM 图形学交易 (ToG), 第 40 卷, 第 4 期, 第 1–20 页, 2021 年。
- [93] J. Wu, Y. Xue, and C. Qi, “在潜空间中学习四足机器人的多种步态”, arXiv 预印本 arXiv:2308.03014, 2023 年。
- [94] Y. Li, J. Li, W. Fu, and Y. Wu, “在四足机器人上学习敏捷双足运动”, arXiv 预印本 arXiv:2311.05818, 2023 年。
- [95] I. D. Landau, R. Lozano, M. M’ Saad, and A. Karimi, 自适应控制: 算法、分析与应用。Springer Science & Business Media, 2011 年。
- [96] D. Lim, M.-J. Kim, J. Cha, D. Kim, and J. Park, “用于浮动基座机器人的本体感受外部力矩学习及其在类人机器人运动中的应用”, 载于 2023 年 IEEE/RSJ 国际智能机器人与系统会议 (IROS), 2023 年。
- [97] L. Ljung, “系统辨识”, 载于信号分析与预测。Springer, 1998 年, 第 163–173 页。
- [98] M. T. Spaan, “部分可观测马尔可夫决策过程”, 载于《强化学习: 最新技术》。斯普林格出版社, 2012 年, 第 387–414 页。
- [99] N. Meuleau, L. Peshkin, K.-E. Kim 和 L. P. Kaelbling, “针对部分可观测环境学习有限状态控制器”, 载于《第十五届人工智能不确定性会议论文集》, 1999 年, 第 427–436 页。
- [100] SFU, “SFU 运动捕捉数据库”, <https://mocap.cs.sfu.ca/>, 2018 年。
- [101] E. Todorov, T. Erez 和 Y. Tassa, “Mujoco: 用于基于模型控制的物理引擎”, 载于《2012 年 IEEE/RSJ 国际智能机器人与系统会议》, 2012 年, 第 5026–5033 页。
- [102] DRL, “cassie-mujoco-sim”, 2023 年。[在线] 可获取: <https://github.com/osudrl/cassie-mujoco-sim>
- [103] J. Schulman, F. Wolski, P. Dhariwal, A. Radford 和 O. Klimov, “近端策略优化算法”, arXiv 预印本 arXiv:1707.06347, 2017 年。
- [104] D. Kim, G. Berseth, M. Schwartz 和 J. Park, “基于扭矩的深度强化学习用于双足机器人的任务与机器人无关学习及仿真到现实迁移”, 《IEEE 机器人与自动化快报》, 2023 年。
- [105] Z. Xie, X. Da, M. Van de Panne, B. Babich 和 A. Garg, “动力学随机化再探讨: 四足运动案例研究”, 载于《2021 年 IEEE 国际机器人与自动化大会 (ICRA)》。IEEE, 2021 年, 第 4955–4961 页。
- [106] B. van Marum, A. Shrestha, H. Duan, P. Dugar, J. Dao 和 A. Fern, “重新审视鲁棒人形站立与行走的奖励设计与评估”, arXiv 预印本 arXiv:2404.19173, 2024 年。
- [107] M. Bogdanovic, M. Khadiv 和 L. Righetti, “利用轨迹优化演示进行鲁棒运动的无模型强化学习”, 《机器人学与人工智能前沿》, 第 9 卷, 文章号 854212, 2022 年。
- [108] S. Liu, M. Xu, P. Huang, X. Zhang, Y. Liu, K. Oguchi 和 D. Zhao, “基于群体对称性的连续视觉强化学习”, 载于《机器人学习会议》。PMLR, 2023 年, 第 222–240 页。
- [109] X. Huang, Y. Chi, R. Wang, Z. Li, X. B. Peng, S. Shao, B. Nikolic 和 K. Sreenath, “Diffuseloco: 基于离线数据集的扩散模型实现实时腿部运动控制”, arXiv 预印本 arXiv:2404.19264, 2024 年。
- [110] Y. Lee, S.-H. Sun, S. Somasundaram, E. S. Hu 和 J. J. Lim, “通过学习过渡策略组合复杂技能”, 载于《国际学习表征会议》, 2018 年。




图 28: 关于使用低通滤波器作为动作滤波器从头训练原地跳跃技能的消融研究。不使用低通滤波器时, 训练回报 (蓝色曲线) 远低于使用低通滤波器的方法 (我们的方法, 红色曲线)。这两个策略使用了完全相同的超参数和训练设置。其根本原因在于, 不使用低通滤波器时, 基于强化学习的策略更难抑制高频抖动运动。

附录

A. 使用动作滤波器的优势

我们在策略输出后使用了低通滤波器, 作为动作滤波器。本工作中使用的低通滤波器是截止频率为 4 Hz 的巴特沃斯低通滤波器。低通滤波器已广泛应用于控制工程, 包括基于模型的最优控制方法和无模型强化学习方法, 用于腿式运动。低通滤波器可以进一步平滑基于强化学习策略的动作, 从而补充表 III 中列出的平滑奖励。我们通过训练一个原地跳跃策略 (单任务训练) 进行了消融研究, 其中不使用低通滤波器, 结果仍然能够跳跃, 但由于产生的抖动运动, 学习性能 (收敛回报) 更差, 如图 28 所示。如果去掉低通滤波器, 我们需要增加平滑项的权重, 以突出整个运动平滑性的重要性。然而, 如果平滑项在整个奖励组成中占据过大权重, 机器人可能容易学习到静止不动的次优行为, 而无法探索跳跃等动态技能。因此, 低通滤波器有助于减轻这种奖励调优负担。此外, 由于低通滤波器仅有助于抑制动作 (策略输出) 中的高频变化, 整个系统仍可能出现振荡 (例如, 由于较大的关节速度), 因此平滑奖励对于平滑整个闭环系统仍然是必要的。这两部分相互补充。

B. 学习结合站立技能

使机器人能够学习站立以及其他运动技能对于实际应用非常有用, 因为在机器人不移动时, 回收物理机器人硬件是必不可少的。

对于行走技能, 在机器人经过任务随机化阶段掌握了多种行走任务后, 我们增加了一个子阶段。在此训练子阶段的回合中, 在行走一段随机时间后, 会指令机器人执行站立技能, 并且将持续到回合结束。机器人通过两个变化被告知要执行站立: (1) 输入到控制策略的参考运动被更改为

一个标称的站立运动 (参考运动的预览现在是三个相同站立电机位置的堆叠), 以及 (2) 奖励被设计为鼓励执行静态站立技能。站立的奖励与表 III 中列出的用于训练动态运动技能的公式相同, 并且平滑项 (如电机速度和动作变化) 的权重增加, 其他项保持不变。增加的平滑权重是为了鼓励机器人保持静态站立姿势。在机器人掌握了行走、站立以及从行走任意状态过渡到站立技能后, 我们可以进入动力学随机化阶段。从这一阶段开始, 站立技能将仅在行走训练的中途引入, 并持续一段随机有限的时间。通过这种方式, 机器人还可以学习从站立回到行走的过渡。

对于奔跑技能, 此子阶段的 POMDP 设计与行走技能类似。然而, 由于从快速奔跑过渡到站立更具挑战性, 我们提供了一个额外的从奔跑过渡到站立的参考运动, 该运动来自人类动作捕捉数据重定向。这可以促进过渡阶段的训练。对于跳跃技能, 由于它是一种非周期性的技能, 并且要求机器人在落地后保持站立姿势, 我们不需要这样的额外训练子阶段。

该方法也可能有助于通过单一策略组合不同的运动技能 (如将行走、奔跑和跳跃结合起来)。这有望解决为高动态腿部运动控制开发多技能策略的问题。我们将其视为本工作的一个可能扩展方向。

C. 不同技能的指令范围

表 VI: 不同技能的指令范围。

Task Parameters	Range
Walking	
Sagittal Velocity $\dot{q}_x^d$	[-1.5, 1.5] m/s
Lateral Velocity $\dot{q}_y^d$	[-0.6, 0.6] m/s
Turning Velocity $\dot{q}_\psi^d$	[-45, 45] deg/s
Walking Height q_z^d	[0.65, 1.0] m
Running	
Sagittal Velocity $\dot{q}_x^d$	[2.0, 5.0] m/s
Lateral Velocity $\dot{q}_y^d$	[-0.75, 0.75] m/s
Turning Velocity $\dot{q}_\psi^d$	[-30, 30] deg/s
Jumping	
Sagittal Landing Location q_x^d	[-0.5, 1.5] m
Lateral Landing Location q_y^d	[-1.0, 1.0] m
Turning Direction at Landing q_ψ^d	[-100, 100] deg
Change of Elevation e_z^d	[-0.5, 0.5] m


本工作中开发的三种运动技能 (行走、奔跑和跳跃) 的指令训练范围详见表 VI。在训练回合中, 给定指令从所列范围内均匀抽取。

D. 训练中使用的超参数

用于开发不同运动技能的训练 (PPO) 迭代次数详见表 VII。此外, PPO 的超参数报告于表 VIII, 且在不同运动技能中保持一致。

TABLE VII: Number of Training Iterations used for Different Locomotion Skills. Each iteration collects a batch of 65536 samples.

Walking				
Single-Task 6000	Task Randomization 8000	Combining Standing 2000	Dynamics Randomization 8000	Added Perturbation Training 5000
Running				
Single-Task 6000	Task Randomization 18000	Combining Standing 5000	Dynamics Randomization 15000	Added Perturbation Training 5000
Jumping				
Single-Task 6000	Task Randomization 12000		Dynamics Randomization 20000	



(a) 采用双历史方法的 TCN (Dual Hist.) 与仅使用 TCN (Long Hist. Only)。
 (b) 采用双历史方法的 LSTM (Dual Hist.) 与仅使用 LSTM (Long Hist. Only)。

图 30: 在训练具有动力学随机化的单任务行走策略 (以固定速度向前行走, 完成单阶段训练后) 时, 使用不同神经网络架构编码器机器人输入 / 输出历史的学习性能。对于仅使用长历史的方法, 我们仍在时间编码器旁提供明确的即时状态反馈。如图 30a 所示, 通过采用所提出的双历史方法, 即向 TCN 编码器提供明确的短期输入 / 输出历史, 学习性能远优于仅使用 TCN。TCN 编码了 2 秒的机器人输入 / 输出历史, 具有 3 层, 滤波器大小为 [34,34,34], 内核大小为 5, 膨胀基数为 2, 步长为 2, 并使用 ReLU 激活函数, 如 [71] 所建议。图 30b 显示, 双历史方法对基于 LSTM 的策略并无帮助。LSTM 编码器具有 1 层 128 个单元。然而, 在使用为 LSTM 调优的超参数时, 采用双历史方法的 TCN 和仅使用长历史方法的性能均优于基于 LSTM 的策略。这表明 LSTM 可能仅学会利用近期短期历史, 并收敛到更次优的策略。




图 31: 使用相同神经网络 (包括 LSTM 架构及 [12] 中使用的相同超参数) 从零开始训练行走 (红色曲线) 和跳跃 (蓝色曲线) 技能的学习性能。结果表明, 虽然 LSTM 可以学习行走技能, 但可能难以学习像跳跃这样高度动态的运动技能 (显示为平坦曲线)。这并非暗示 LSTM 无法学习非周期性的跳跃技能, 而是强调其不同 MDP (不同运动技能) 下对超参数调优的敏感性。这与本工作中使用的非循环策略 (如 1D CNN) 形成对比, 后者由于训练简便, 对所有不同技能采用统一的超参数集。

表 VIII: PPO 训练中使用的超参数。这些超参数在不同运动技能中保持一致。

Hyperparameter	Value
PPO iteration batch size	65536
PPO clip rate	0.2
Optimization step size (both actor and critic)	$1e^{-4}$
Optimization batch size	8192
Optimization epochs	2
Discount factor (γ)	0.98
GAE smoothing factor (λ)	0.95

E. 不同历史长度使用的比较




图 29: 在训练带有动力学随机化的单任务跑步策略时, 使用不同长度的机器人输入 / 输出历史的学习性能。所有这些策略均采用了所提出的基于双历史的方法。当将机器人历史的显式长度从 1 秒 (粉色曲线)、2 秒 (红色曲线, 如本工作所用) 增加到 3 秒 (蓝色曲线) 时, 我们观察到学习性能的提升。然而, 如果继续增加历史长度, 例如到 4 秒 (深蓝色曲线), 学习性能的改善可能会趋于饱和。

我们进行了一项消融研究, 以探究不同历史长度对需要指定历史长度的非递归策略的影响。以双足跑步训练为例, 图 29 展示了在广泛的动力学参数和不同长度的机器人输入 / 输出历史下, 训练单任务跑步策略 (已完成第一阶段训练) 的学习性能。

如图 29 所示, 增加历史长度, 例如从 1 秒增加到 2 秒, 或从 2 秒增加到 3 秒, 持续提升了学习性能。这种改进是因为更长的输入 / 输出历史提供了更多关于机器人动力学参数的信息, 有助于更好的状态估计。然而, 持续延长历史长度可能并不总是有益的, 因为它可能引入机器人需要过滤掉的冗余信息。当历史长度进一步增加时, 学习性能的下降证明了这一点。




图 32: 在仿真环境 (MuJoCo) 中对所获行走策略的自适应性测试。机器人被指令以 0.6 米 / 秒的速度向前行走, 无侧向或转向运动, 且高度为正常高度 (0.95 米)。图 32a 记录了策略的长输入 / 输出历史编码器在 15 秒内的潜在嵌入。在 8 至 11 秒期间, 对机器人基座施加了 30 牛的外部向后扰动力。我们可以观察到存在扰动时潜在嵌入的变化。下图显示了两个选定潜在维度与机器人冲击力或接触事件之间的强相关性。图 32b 显示了在相同行走任务中, 潜在嵌入 (图 32a 中红色边界框标记的相同放大区域) 随不同动力学参数变化的情况。这些消融研究与图 9b 中进行的实验相同。控制性能指标, 即跟踪误差 E_t 和运动跟踪误差 E_m , 在动力学参数大幅变化时表现出微小变化。

长度从 3 秒增加到 4 秒, 如图 29 所示。在双足运动控制中, 记住更早发生的事件不那么关键, 更长的历史可以为机器人提供更多训练样本以提取有用信息。因此, 我们建议使用覆盖相对较短时间跨度的历史长度, 例如本工作中使用的 2 秒, 以便在双足运动控制学习中获得更稳定的训练和相对良好的性能。对于有兴趣将本方法应用于其机器人的读者, 为特定任务找到最优历史长度可能是有益的, 但我们建议从 2 秒的历史长度开始, 该长度在本工作中已得到广泛测试。

F. 不同时间编码器使用比较

为了探究不同神经网络结构编码机器人长期输入输出历史的效果, 我们进行了消融研究, 并基于 TCN 和 LSTM 对策略进行了基准测试。TCN 是一种非递归结构, 用于编码时间信息, 在 [71], 中被采用; 而 LSTM 作为一种递归结构, 则被用于其他双足运动控制研究中, 例如 [12]。为消除实现不佳等潜在干扰因素, 我们采用了 [12], 开源发布的训练算法 (PPO 和递归 PPO) 及训练超参数, 这些方法为后续多项研究 (如 [15, 14, 22]) 奠定了基础。MDP 设计 (训练环境) 则使用了本工作开发的行走与跳跃场景。

如图 30a 所示, 在 TCN 编码器基础上为基础策略提供 4 时间步的短时 I/O 历史记录, 相比单独使用 TCN 能显著提升学习性能 (同时仍为基础策略提供即时上一状态反馈, 即 [71] 中采用的形式)。这表明双历史方法能够持续增强编码外部信息的非递归结构的学习性能。

隐式历史长度。注意在此比较中, 我们使用了与 [71] 中表 S5 相同的 TCN 实现。

相反, 如图 30b 所示, 基于 LSTM 的策略无论是否提供短期历史数据均未表现出显著改进。此外, 即便 TCN 使用了为 LSTM 调优的超参数, 该策略仍倾向于收敛至比 TCN 策略更低的回报平台期。这可能表明 LSTM 编码器更倾向于关注近期短期历史而忽略更早的历史信息。尽管 LSTM 隐藏状态仅在回合结束时重置, 但其可能快速收敛至主要关注近期历史的次优策略, 这解释了为何额外提供短期历史数据无法提升性能, 以及为何 LSTM 的表现逊于经过显式训练以利用长期历史的 TCN。该观察结果与 [71] 和 [79] 中的发现一致。

此外, 将基于 LSTM 的策略扩展到学习跳跃技能导致了训练失败, 即使使用了与 [12] 相同的架构和超参数——这些参数在本工作中复现了相同的行走技能, 如图 31 所示。请注意, 我们并非断言 LSTM 无法学习跳跃这类非周期性技能, 但若不在训练过程中仔细调整超参数, 这确实很困难。相比之下, 我们的方法提供了一种直接且通用的学习多种技能的途径, 所有任务均使用统一的超参数。在完成行走训练后, 我们未对跳跃或跑步调整任何超参数。

总之, 双历史方法持续有助于记录显式机器人历史 (如 TCN 和 1D CNN 等非循环策略) 的策略的学习性能, 但并未改善 LSTM 等循环策略。此外, 循环策略对不同 MDP (如运动控制) 的超参数调优敏感, 且可能更容易收敛到次优策略。因此, 基于双历史的方法




图 33: 在 15 秒测试中, 当机器人 (a) 奔跑或 (b) 行走且存在 8 至 11 秒的扰动时, MLP 基座相对于整个输入的显著性图。针对长历史编码器潜在嵌入的显著性图放大区域在 (c) 奔跑和 (d) 行走中详细展示。这些与图 9 和图 32 报告的测试相同。颜色较亮的像素表示 MLP 基座更关注该值 (显著性更高)。这些图显示, 产生策略动作的 MLP 基座更关注短输入 / 输出历史, 尤其是最新观测值, 突显了短输入 / 输出历史在输入中的重要性。此外, 若仔细观察编码后的长输入 / 输出历史 (c,d), 机器人也能关注潜在嵌入的不同区域以应对环境变化, 从而调整其输出。因此, 这表明包含长输入 / 输出历史也是有益的, 这也为图 6 中进行的基准测试提供了见解。

非循环策略可能更适用于双足运动控制案例。

性能变化很小。这表明行走策略具有适应性。

G. 行走策略的潜在可视化

所提方法获得的行走策略的自适应性测试结果如图 32 所示。该自适应性测试与第 VIII 节讨论的奔跑策略测试类似, 评估了当机器人以 0.6 米 / 秒的恒定前进速度行走时, 长输入 / 输出历史编码器后潜在嵌入的变化。结果与第 VIII 节其他技能测试中观察到的一致: 我们表明潜在嵌入能够捕捉外部扰动和接触事件等时变变化 (图 32a) 以及时不变动力学偏移 (图 32b)。在动力学偏移的消融研究中, 当动力学参数变化时潜在嵌入会有所不同, 但最终的控制

H. 显著性图

为了进一步理解策略如何根据环境变化调整其动作, 我们可视化了如图 33 所示的显著性图, 该方法参考自 [71]。显著性图反映了每个输入维度对神经网络输出的重要程度 (即, 策略关注的重点所在)。

如生成最终策略动作的 MLP 基座显著性图所示, 机器人更关注短输入输出历史, 尤其是最近的观测值, 这凸显了短输入输出历史的重要性 —— 无论是在奔跑 (图 33a) 还是行走 (图 33b) 过程中。

我们可以仔细观察同一测试中整个显著性图的放大区域 (编码的长历史信息)




图 34: 在高速奔跑模拟中, 使用机器人机载速度估计器 (基于 EKF) 产生的大估计误差。图中, 机器人由所提出的奔跑策略控制, 以跟踪模拟中的可变指令 (黑色虚线), 估计的矢状速度记录为红线, 而机器人的实际奔跑速度记录为蓝线。真实速度从模拟器中获得。尽管在低速 (如 2 米 / 秒) 下结果准确, 但在高速区域 (3 米 / 秒以上), 估计速度与真实速度相比显示出显著误差。机器人的实际速度趋向于估计速度的上包络线。在实际实验中, 我们只能访问状态估计器, 并报告其结果, 如图 20b 中的奔跑速度跟踪结果所示。这一比较表明, 机器人在现实世界中的实际奔跑速度比报告的估计值更快, 且更接近指令。




图 35: 使用相同平地跳跃策略的更多双足跳跃。地面上的纸标签指示跳跃目标。

奔跑 (图 9a) 和行走 (图 32a) 的显著图。针对编码的长历史, 显著图对长历史嵌入的不同部分有不同的关注点

在奔跑 (图 33c) 或行走 (图 33d) 过程中存在外部扰动时, 长历史编码器的显著图。这进一步表明, 所提出的强化学习策略可以利用长历史信息来针对不同控制场景调整动作, 即长输入 / 输出历史是有用的。

从图 6 的广泛消融研究中, 我们观察到根据历史使用情况的不同, 学习性能和模拟到现实迁移存在差异。无论是移除短输入 / 输出历史 (即使保留最受关注的最近观测, 即图 5d 中的仅长历史), 还是移除长输入 / 输出历史 (仅短历史, 图 5e), 都会导致性能下降。这些针对整个输入空间的显著图揭示了其背后的原因。

I. 高速奔跑中估计器的误差

在本节中, 我们展示了在高速奔跑中使用的状态估计器 (EKF) 的估计误差。在图 34 中, 我们比较了从仿真中获得的机器人地面真实矢状速度 $\dot{q}_x$ 与估计器给出的相应估计速度。在高速奔跑 (超过 3 米 / 秒) 时, 我们观察到估计器存在较大的估计误差, 而在实际实验中我们只能获取该估计器的数据。这表明机器人在现实世界中的实际奔跑速度比记录的估计速度更快, 并且可能是估计值的上包络线。当比较估计速度与机器人的实际平均速度 (行驶距离 / 经过时间) 时, 这一较大的估计误差得到了进一步证实。这表明在高速奔跑期间, 实际跟踪误差比实验日志所显示的要小。这也说明了在训练过程中需要包含该估计器, 以便让机器人利用这个不精确估计器产生的观测数据进行训练。尽管如此, 由于仿真到现实的差距以及机器人硬件的限制, 机器人在高速奔跑区域仍然存在明显的跟踪误差。我们指出, 利用强化学习为动态双足运动技能开发可靠的状态估计器可能是一项有趣的未来工作。

J. 多样化的双足跳跃

使用与第 X-C 节中展示的各种双足跳跃相同的着地跳跃策略, 我们进一步评估了在现实世界中跳跃到其他不同目标的能力, 如图 35 所示。