

基于选择性对抗运动先验的强化学习实现人形机器人多步态学习

吴远野^{1*}、王科毅^{1*}、叶林奇¹、邢博洋²

摘要 — 在统一的强化学习框架中为人形机器人学习多样化的运动技能仍然具有挑战性，因为不同步态在稳定性和动态表现力方面存在冲突需求。我们提出了一种多步态学习方法，使机器人能够使用一致的策略结构、动作空间和奖励公式掌握五种不同的步态——行走、正步、跑步、爬楼梯和跳跃。关键贡献在于一种选择性对抗运动先验（AMP）策略：AMP 应用于周期性、稳定性关键的步态（行走、正步、爬楼梯），在这些步态中它加速收敛并抑制异常行为，而在高度动态的步态（跑步、跳跃）中则有意省略，因为其正则化会过度约束运动。策略通过 PPO 在仿真中结合域随机化进行训练，并通过零样本仿真到现实迁移部署在物理 12 自由度人形机器人上。定量比较表明，选择性 AMP 在所有五种步态上均优于统一 AMP 策略，在稳定性重点步态上实现了更快的收敛、更低的跟踪误差和更高的成功率，同时不牺牲动态步态所需的敏捷性。

I. 引言

人形机器人有望在人类设计的环境中运行，但实现这一潜力需要具备自适应执行多种运动行为的能力 [1]。实际部署不仅需要行走以实现高效移动，还需要跑步以快速移动、跳跃以跨越间隙或越过障碍、爬楼梯以进行多层导航，以及诸如正步等用于结构化或仪式场景的专门步态。每种步态对控制系统提出了根本不同的要求：行走强调能效和稳定平衡，跑步需要快速发力并管理腾空阶段，跳跃要求在短时间内产生最大垂直冲量，爬楼梯需要精确的落脚点和间隙控制，而正步则需要持续的腿部伸展和严格的姿态约束。核心挑战不仅在于孤立地学习每种步态，更在于一个共享策略架构、观测空间和奖励结构的统一框架内学习它们。

强化学习已成为一种引人注目的方法，用于学习复杂的运动技能，而无需显式的分析模型。通过与物理

模拟器进行大规模交互，强化学习智能体能够发现难以手工设计的控制策略，尤其适用于像人形机器人这样的欠驱动、高自由度系统 [2]。与传统基于模型的控制相比，强化学习的关键优势在于其能够在统一的优化过程中处理非线性动力学、接触切换和执行器限制。近期研究已展示了令人印象深刻的单一步态能力，包括在平坦和不平坦地面上的稳健行走、具有足部间隙的楼梯穿越以及基本的扰动恢复 [3], [4]。然而，这些研究通常为每个任务训练一个独立的策略，且每个策略都通过其自身的奖励设计和超参数配置进行调优。将强化学习扩展到单一框架下的多种步态引入了新的困难：策略必须协调不同行为之间的冲突动力学，奖励函数必须在运动特性差异巨大的步态间保持有效，且观测空间必须为所有行为编码足够的信息，而不会对任何单个步态变得冗余或具有误导性 [5]。

对抗性运动先验（AMP）解决了基于强化学习的运动控制中的一个关键难题——生成自然、稳定的运动，使其能够良好地迁移到硬件上 [6]。通过训练一个判别器来区分智能体生成的运动片段与参考运动片段，AMP 将策略正则化到所展示的类人行为分布上。这已被证明能减少关节抖动、改善足部放置的一致性，并产生与真实执行器动力学更兼容的平滑轨迹 [7], [8]。然而，现有采用 AMP 的工作是统一进行的：一旦引入 AMP 模块，它在整个训练过程中对所有行为都保持激活。这引出了一个重要但尚未充分探索的问题：AMP 是否总是有益的，或者对于某些步态类型它可能适得其反？

我们的观察是，AMP 的有效性关键取决于目标步态的特性。AMP 擅长强化周期性、重复性的运动模式，且关节幅度适中——这正是行走、正步和爬楼梯的特征。对于这些步态，参考运动分布与期望的策略输出高度匹配，对抗性奖励提供了稳定的归纳偏置，加速收敛并抑制异常行为。相反，对于需要大幅度关节运动、快速加速和爆发性动力学的步态——如奔跑和跳跃——可用的人类运动参考有限，AMP 判别器的正则化可能成为不必要的约束。在这些情况下，

* 这些作者对本文贡献相同。¹ 吴宇、王凯、叶林奇任职于上海大学未来技术学院，上海 200444（通信作者：叶林奇，邮箱：yelinqi@shu.edu.cn）² 邢波任职于国家级与地方共建仿人机器人创新中心，上海 201203

策略需要探索参考流形之外的空间，以发现充分利用机器人执行器能力的方案，而 AMP 惩罚项可能阻止智能体达到必要的运动极限。

这种不匹配促使我们采用一种选择性方法：与其普遍应用 AMP 或完全舍弃它，我们建议在有益处的地方使用它，在有害处的地方禁用它。这一策略需要理解哪些步态特征符合 AMP 假设，哪些偏离了它，并为每种运动模式做出明智的决策。

本文的贡献如下：

- 1) 一个**统一的强化学习框架**，该框架基于正弦关节参考轨迹跟踪，使用一致的策略架构和奖励函数，学习人形机器人的五种实用步态——行走、正步、跑步、跳跃和爬楼梯。所有步态共享相同的观测空间、网络结构和奖励公式，仅在参考轨迹参数和奖励权重上有所不同。
- 2) 一种**选择性对抗性运动先验策略**，该策略将 AMP 应用于周期性、稳定性关键的步态，同时在高动态、敏捷的步态中省略它。我们提供的实证分析表明，AMP 能提高行走类步态的收敛速度和跟踪精度，但会限制跑步和跳跃的运动幅度与表现力。
- 3) **完整的真实机器人验证**，涵盖所有五种步态，并包括跟踪误差、收敛速度、成功 / 摔倒率以及 AMP 与非 AMP 性能的定量比较。我们在物理人形机器人平台上部署了每个学习到的策略，为多步态学习提供了可复现的真实机器人基线。

II. 方法论

A. 概述

我们提出一个统一的强化学习框架，用于训练一个 12 自由度人形机器人的五种不同运动步态：行走、正步走、跑步、跳跃和爬楼梯。该框架包含三个主要组成部分。首先，采用统一的强化学习公式，包含一致的观测空间、动作空间和奖励结构，用于训练所有五种步态，每种步态仅通过其正弦参考轨迹参数和奖励权重配置加以区分。其次，应用选择性对抗运动先验策略：对于周期性、稳定性关键的步态（行走、正步走、爬楼梯）启用对抗运动先验，而对于高度动态的步态（跑步、跳跃）则禁用。第三，在仿真中通过广泛域随机化训练的策略直接部署在物理人形机器人上，无需微调。图 1 展示了整体流程。

B. 强化学习公式

我们将每个步态学习任务建模为一个马尔可夫决策过程，由元组 $(S, A, r, \gamma, \rho_0)$ 定义。所有五种步态共享相同的马尔可夫决策过程结构，仅在




图 1. 多步态学习流程概览。根据步态类型，在仿真中启用或禁用对抗运动先验进行策略训练，然后部署到物理机器人上。

参考轨迹生成、奖励权重参数以及 AMP 配置。

- 1) 状态空间：策略在每个时间步接收的观测空间 t 由本体感觉状态、参考信号和指令输入组成。每帧观测向量 $o_t \in \mathbb{R}^{50}$ 由以下分量拼接而成：

- **基础线速度** $v_b \in \mathbb{R}^3$ ：以机器人本体坐标系表示，缩放因子为 2.0。
- **速度指令** $c \in \mathbb{R}^3$ ： x 和 y 方向的目标线速度以及绕 z 轴的角速度。
- **相位编码** $\phi \in \mathbb{R}^2$ ：当前步态相位的正弦编码 $[\sin(2\pi\phi_t), \cos(2\pi\phi_t)]$ 。
- **基础角速度** $\omega_b \in \mathbb{R}^3$ ：以本体坐标系表示，缩放因子为 0.25。
- **投影重力向量** $g_p \in \mathbb{R}^3$ ：世界坐标系下的重力向量 $[0, 0, -1]^\top$ 经过基座方向旋转后的结果。
- **关节位置误差** $q_e \in \mathbb{R}^{12}$ ：当前关节位置与默认站立构型之间的差值。

- **关节速度** $\dot{q} \in \mathbb{R}^{12}$: 缩放因子为 0.05。
- **上一动作** $a_{t-1} \in \mathbb{R}^{12}$: 上一时间步执行的动作。

相位变量 $\phi_t \in [0, 1]$ 按 $\phi_{t+1} = (\phi_t + \Delta t / T_{\text{cycle}}) \bmod 1$ 推进, 其中 T_{cycle} 是步态特定的周期时间。

参考关节轨迹通过相位变量进行编码。对于周期性步态（行走、正步走、跑步、爬楼梯），参考轨迹为正弦形式：

$$s = \sin(2\pi\phi_t) \quad (1)$$

$$q_{\text{ref}}^{\text{L,hip}} = -s \cdot \mathcal{K}_{s < 0} \quad (2)$$

$$q_{\text{ref}}^{\text{L,knee}} = 2s \cdot \sigma \cdot \mathcal{K}_{s < 0} \quad (3)$$

其中 σ 是目标关节位置缩放因子（行走和跑步为 0.26, 正步走为 0.28），当 $s > 0$ 时右腿与左腿镜像对称且符号相反。每种步态通过其（ T_{cycle} , 支撑相比比例）组合调节该模式：行走（0.8 秒, 0.6），正步走（0.7 秒, 0.45），跑步（0.4 秒, 0.35），爬楼梯（0.7 秒, 0.6）。

对于跳跃步态，采用分段式 4.0 秒周期轨迹，包含五个阶段：下蹲（ $\phi < 0.30$, 正弦²膝关节屈曲）、起跳（0.30–0.42, 快速伸展）、腾空（0.42–0.48, 保持伸展）、落地（0.48–0.75, 冲击吸收与恢复）和站立（ $\phi \geq 0.75$, 默认姿态）。课程学习在 2000–10000 次 PPO 迭代中逐步增加下蹲深度。

为了捕捉时间动态，策略接收连续 $N = 21$ 个观测帧的历史记录，堆叠成维度为 $50 \times 21 = 1050$ 的单一输入。这使得无需显式计算导数即可隐式估计速度和加速度。

评论家接收一个扩展观测 s_t ，其中额外包含仅仿真可用的特权信息：基座线速度和角速度、投影重力、指令、关节位置误差、关节速度、动作、相位编码、摩擦系数、足部接触掩码、站立掩码、关节跟踪误差、推力、足部垂直速度和足部离地间隙。该特权向量（每帧 73 维）在 5 帧上堆叠，并与地形高度测量值（187 个点）拼接，总计 552 维。

2) 动作空间：策略输出一个 12 维动作向量 $a_t \in \mathbb{R}^{12}$ ，对应 12 个驱动自由度（每条腿 6 个：髋关节俯仰、髋关节横滚、髋关节偏航、膝关节、踝关节俯仰、踝关节横滚）的目标关节位置偏移。目标关节位置计算如下：

$$q_{\text{target}} = a_t \cdot k_{\text{action}} \cdot k_{\text{gain}} + q_{\text{default}} \quad (4)$$

其中 k_{action} 是动作缩放因子（行走 / 爬楼梯为 0.25, 跑步为 0.3, 正步走为 0.4）， $k_{\text{gain}} = \tau_{\text{max}} / K_P$ 是每个关节的增益，用于根据关节的刚度和扭矩限制对动作输出进行归一化。

目标位置被发送至 PD 控制器：

$$\tau = K_P(q_{\text{target}} - q) - K_D\dot{q} \quad (5)$$

对于行走类步态，比例增益 K_P 范围为 75 至 280 N·m/rad（髋关节俯仰和膝关节为 280, 髋关节横滚为 240, 髋关节偏航为 75, 踝关节为 75），微分增益 K_D 范围为 5 至 14 N·m·s/rad。正步走采用显著更高的刚度（髋关节俯仰 450, 膝关节 800, 髋关节横滚 300, 髋关节偏航 150, 踝关节 200）和阻尼（膝关节 K_D 高达 40），而跑步则采用适度增加（髋关节俯仰和膝关节为 300, 髋关节横滚 240, 髋关节偏航 100, 踝关节 80）。计算出的扭矩被裁剪至 URDF 中 effort 字段指定的每个关节最大限制（60–150 N·m）。策略以 50 Hz 执行，而 PD 控制器以 200 Hz 运行（抽取因子为 4）。指数移动平均滤波器对动作进行平滑处理，5–10 个时间步的随机动作延迟模拟真实世界延迟。

3) 奖励函数：所有步态共享统一的奖励公式。每个时间步的总奖励为加权和：

$$r_{\text{total}} = \sum_i w_i r_i \quad (6)$$

奖励项分为四类：

(1) **关节跟踪奖励**。主要目标跟踪参考轨迹。对于周期性步态，髋关节和膝关节的跟踪奖励计算为双指数和：

$$r_{\text{track}} = 0.15 \sum_{j \in \{\text{hip, knee}\}} \sum_{i \in \{\text{L, R}\}} \left(e^{-4e_{ij}^2} + e^{-20e_{ij}^2} \right) \quad (7)$$

其中 $e_{ij} = q_{ij} - q_{\text{ref}, ij}$ 为关节误差，膝关节项仅在摆动阶段施加掩码。行走和跑步使用通用跟踪权重 $w_{\text{track}} = 2.0$ ，鹅步使用 4.0（ $\sigma = 0.15$ 与 0.2 相比更严格），单独的膝关节奖励增加 $w = 3.0$ （行走）或 25.0（鹅步）。对于跳跃，单一跟踪奖励（ $w = 20.0$ ）计算所有 12 个关节的均方误差。

(2) **基座平衡与姿态奖励**。包括朝向奖励（行走和跑步为 $w = 3$ ，鹅步为 5.0，跳跃为 15.0）、基座高度奖励（ $w = 2$ ），以及线速度跟踪（行走 $w = 5.0$ 、鹅步 8.0、跑步 20.0、跳跃 0.0）和角速度跟踪（ $w = 3.5$ ）。

(3) **运动平滑性奖励**。动作平滑性惩罚一阶和二阶变化（行走和跑步为 $w = -0.01$ ，鹅步为 -0.001 ）、关节速度（ $w = -10^{-4}$ ）以及额定扭矩（行走每侧 $w = -0.02$ ，鹅步 -0.03 ，跑步 -0.05 ）。鹅步额外增加腿部伸直度（ $w = 12.0$ ）、小腿抬起（ $w = 8.0$ ）和脚部踢出（ $w = 6.0$ ）项。

(4) **安全性与步态特定奖励**。当基座接触地面或 |横滚角| > 0.8 弧度、|俯仰角| > 1.0 弧度时触发摔倒终止。施加膝盖碰撞惩罚。周期性步态包括足部摆动高度（ $w = 2$ ）和交替足部摆动（ $w = 6.0$ 用于正步走）。跳跃使用专门奖励：跳跃高度目标（ $w = 150.0$ ，以 0.275 米为中心的高斯奖励，并带有站立阶段惩罚以防止意外小跳），垂直起飞速度（ $w = 120.0$ ，分段非线性：低于 1.0 米 / 秒时线性斜坡，二次

上述)，以及同步的足部接触（ $w = 20.0$ ），同时惩罚水平速度（ $w = -15.0$ ）。

关键设计原则是，所有步态使用相同的奖励公式——多样性源于参考规范、权重调整和步态特定项，而非结构差异。

C. 选择性对抗运动先验策略

1) AMP 简要回顾：对抗运动先验（AMP）将对抗模仿学习与强化学习相结合，以生成类似于一组参考演示的动作。该方法引入了一个判别器网络 D_ϕ ，该网络经过训练，能够区分来自专家运动片段的状态转换与策略在执行过程中产生的状态转换。

判别器架构是一个具有隐藏维度 [1024, 512, 256] 和 ReLU 激活函数的三层 MLP。判别器的输入是当前状态 s_t 与下一状态 s_{t+1} 的拼接，捕捉单个状态转换。判别器输出一个标量 $\text{logit}D(s_t, s_{t+1})$ ，该值被转换为奖励信号：

$$r_{\text{AMP}} = \alpha \cdot \max\left(0, 1 - \frac{1}{4}(D(s_t, s_{t+1}) - 1)^2\right) \quad (8)$$

其中 α 是缩放 AMP 奖励幅度的每个步态的系数。该奖励随后与任务奖励进行线性插值：

$$r_{\text{combined}} = (1 - \beta) \cdot r_{\text{AMP}} + \beta \cdot r_{\text{task}} \quad (9)$$

其中 $\beta \in [0, 1]$ 控制 AMP 正则化与任务优化之间的平衡。

判别器通过二元交叉熵损失结合梯度惩罚进行训练，以保证稳定性：

$$\mathcal{L}_D = \mathbb{E}_{\text{policy}}[(D+1)^2] + \mathbb{E}_{\text{expert}}[(D-1)^2] + \lambda \cdot \mathbb{E}_{\text{expert}}[\|\nabla_{(s,s')} D\|^2] \quad (10)$$

其中梯度惩罚系数 $\lambda = 10$ 。参考运动数据由采集到的人体运动序列组成，经过处理后得到 200,000 个预加载的状态转移样本。

2) 我们的选择标准：我们方法的核心洞察在于，AMP 的正则化效果对某些步态有益，但对其他步态有害。我们提出了一种基于运动特征的逐步态选择标准：

AMP 应用于：行走、正步走和爬楼梯。这些步态具有周期性，运动周期明确且重复，关节幅度适中，稳定性是首要关注点。对于这些步态，参考运动分布与期望的策略输出高度匹配，对抗性奖励提供了稳定的归纳偏置，加速收敛、抑制异常行为，并生成与真实执行器动力学兼容的更平滑的关节轨迹。AMP 系数 α 和插值系数 β 针对每种步态进行调整：行走和爬楼梯使用 $\alpha = 0.3$ 、 $\beta = 0.8$ ；正步走使用 $\alpha = 0.6$ 、 $\beta = 0.7$ 。

（更高的 α 以强化独特的直腿风格；更低的 β 以允许更大的 AMP 影响）。

AMP 不适用于：奔跑和跳跃。这些步态涉及较大的关节运动范围，可能超出可用参考数据的范围，并且需要快速加速和爆发性动力学。对于奔跑，设置 $\alpha = 0.0$ 和 $\beta = 1.0$ 完全移除 AMP，使策略能够自由利用执行器的全部扭矩能力（膝关节扭矩高达 150 N·m）来发现高速策略。类似地，跳跃使用 $\alpha = 0.0$ 、 $\beta = 1.0$ ，并禁用对称损失（ $\text{sym loss} = \text{False}$ ），以允许在起跳过程中产生不对称的力。在这两种情况下，AMP 判别器会因偏离参考分布而惩罚策略，从而主动抑制达到足够速度或跳跃高度所需的极端运动。

总结：AMP 提高了稳定性但限制了表现力；我们根据步态特征自适应地选择其使用。表 I 总结了每种步态的配置。

表 I 每种步态的选择性 AMP 配置。

Gait	α	β	Sym Loss
Walking	0.3	0.8	True
Goose-stepping	0.6	0.7	True
Running	0.0	1.0	True
Stair climbing	0.3	0.8	True
Jumping	0.0	1.0	False

D. 训练流程

1) 仿真训练：所有策略均使用近端策略优化（PPO）算法 [9] 在 Isaac Gym 物理仿真器 [5] 中训练，配备 4096 个并行环境。演员网络使用具有隐藏层 [512, 256, 128] 和 ELU 激活函数的多层感知机。评论家网络共享相同架构。PPO 算法每次迭代运行 5 个学习周期，分为 4 个小批量，学习率为 5×10^{-4} ，折扣因子为 $\gamma = 0.99$ ，GAE 参数为 $\lambda = 0.95$ 。KL 散度目标设为 0.01，并采用自适应学习率调度。训练最多进行 40,000 次迭代，经验观测归一化器在训练过程中在线更新 [10]。

2) 域随机化：为了弥合仿真与现实的差距，我们在训练过程中应用了广泛的域随机化。以下参数在每个回合的环境层面进行随机化：

- **接触属性：**静摩擦和动摩擦统一从 [0.2, 1.5] 中采样；回弹系数从 [0.0, 1.0] 中采样。
- **基座质量：**在标称质量基础上扰动 [-2, +5] 千克。
- **连杆惯性：**每个连杆独立按 [0.5, 1.8] 缩放。
- **质心：**在每个轴上偏移 [-0.1, 0.1] 米。
- **电机强度：**随机化为 [0.7, 1.0]（行走 / 爬楼梯）、[0.8, 1.2]（跑步 / 正步走）或 [0.9, 1.1]（跳跃）。

- **PD 增益**: K_P 缩放 [0.8, 1.2], K_D 缩放 [0.8, 1.2]。
- **关节属性**: 关节摩擦 [0.3, 1.5], 阻尼 [0.3, 4.0], 电枢 [0.8, 1.2]。
- **动作延迟**: 动作延迟随机时间步数, 范围从 [5, 10], , 模拟控制延迟。
- **外部扰动**: 对基座施加随机冲量, 最大线速度 2.0 米 / 秒, 角速度 1.5 弧度 / 秒, 间隔 10 秒。
- **初始状态**: 关节位置在重置时缩放 [0.5, 1.5] 并偏移 [-0.1, 0.1] 弧度。

对动作延迟采用课程学习: 在训练过程中, 最小延迟从 2 个时间步逐渐增加到 5 个时间步, 从较温和的设置开始以促进初始学习, 并逐步增加难度。

3) 仿真到现实迁移: 训练好的策略通过零样本迁移部署在物理人形机器人上——无需在真实硬件上进行微调。部署流程包括:

- 1) 策略导出: 将训练好的演员网络与经验观测归一化器一起导出为 ONNX 格式, 作为一个单一推理模块, 并通过机器人板载计算机上的 ONNX 运行时加载。
- 2) 板载执行: 策略以 50 Hz 的频率在机器人板载计算机上运行, 接收来自外部 IMU (角速度和姿态) 和关节编码器 (位置和速度) 的本体感受观测。由于硬件上无法直接测量基座线速度, 相应的观测通道设置为零, 依靠观测历史堆栈隐式捕获速度信息。

3) PD 控制: 关节扭矩由板载 PD 控制器以 500 Hz 的频率计算, 使用策略输出的目标位置。在转换为关节目标之前, 采用截止频率为 50 Hz 的一阶低通滤波器对策略动作进行平滑处理。

训练过程中应用的域随机化确保了策略对仿真与现实动力学之间的差异具有鲁棒性, 包括电机响应、接触行为和传感器噪声等方面的差异。

III. 实验

实验视频可在 <https://linqi-ye.github.io/video/lite.mp4> 查看

A. 实验设置

实验在 Lite 11 仿人下肢平台上进行, 该平台提供 12 个驱动关节, 涵盖双侧髋、膝、踝的自由度。所有策略均在 Isaac Gym 中训练, 然后部署到实体机器人上进行验证。我们考虑了五种运动模式: 行走、正步、爬楼梯、跑步和跳跃。爬楼梯包括上楼梯和下楼梯, 而跳跃则包括原地双脚起跳及随后的落地恢复。所有任务共享相同的策略接口: 一个 12 维动作向量、一个 50 维每帧观测值以及一个 21 帧的历史

堆叠, 从而形成 1050 维的策略输入。因此, 步态的多样性是通过参考轨迹、奖励分配和运动先验配置来诱导的, 而不是通过改变控制架构。

所有任务使用统一的仿真和控制框架。物理步长为 0.005 秒, 策略每四个仿真步长更新一次, 有效控制周期为 0.02 秒。底层执行由 PD 位置控制器处理, 该控制器将策略生成的关节目标偏移量转换为驱动指令。所有实验均使用 PPO 算法。除跳跃任务使用稍高的熵系数以适应更强的探索需求外, 其余任务共享相同的基础超参数。主要训练设置总结于表 II。

任务环境和先验设置根据步态特征进行定义。行走、正步和跑步主要在平坦或低复杂度地形上训练, 爬楼梯在三角网格楼梯上结合课程学习进行训练, 而跳跃则在平坦地形上训练, 以强调垂直冲量生成、空中稳定和落地恢复。选择性 AMP 是实验设计的核心: 行走、正步和爬楼梯属于 AMP 组, 而跑步和跳跃则在无 AMP 的情况下训练。这种划分反映了以下观察: 周期性、稳定性导向的运动受益于运动先验, 而高度动态的运动则更依赖于表达自由度和任务驱动的优化。为提高仿真到现实的迁移鲁棒性, 整个训练过程中应用了域随机化, 包括摩擦力、附加质量、质心扰动、电机强度、PD 增益、惯性、关节摩擦、关节阻尼、初始关节缩放和偏置以及动作延迟。爬楼梯使用更强的地形课程, 而跳跃则采用更保守的随机化范围。

B. 评估指标

为了从优化和执行两个角度评估多步态策略, 我们考虑了关节跟踪质量、收敛速度、任务可靠性、训练稳定性和姿态稳定性。性能不仅仅取决于是否产生了运动, 还取决于学习到的运动是否符合预期的结构、在训练过程中是否稳定收敛, 以及在执行过程中是否保持可控。

关节跟踪指标表征了策略在多大程度上保留了每种步态预期的运动学组织。对于行走、正步和爬楼梯, 它主要反映支撑相和摆动相之间的协调性; 对于奔跑和跳跃, 它反映了在高速或爆发性动力学下维持目标运动模式的能力。收敛步数量化了达到稳定状态所需的优化成本。在统一公式下, 能在较少迭代次数内稳定的任务更容易优化, 而需要更多迭代次数的任务则对接触切换、姿态恢复或时间协调提出了更高的要求。

在执行时, 成功率和跌倒率描述了任务可靠性。高成功率表明机器人能够

表 II 五种步态任务的主要训练配置

Gait	# Envs	Obs. Dim.	Act. Dim.	Sim Step	Control Period	num.steps_per_env	Max Iterations	AMP Group
Walking	4096	1050	12	0.005 s	0.02 s	24	40001	AMP
Goose-stepping	4096	1050	12	0.005 s	0.02 s	24	20001	AMP
Stair climbing	4096	1050	12	0.005 s	0.02 s	24	40001	AMP
Running	2048	1050	12	0.005 s	0.02 s	24	40001	No AMP
Jumping	2048	1050	12	0.005 s	0.02 s	24	11000	No AMP

持续维持目标步态，而高跌倒率通常表明对初始条件、节奏控制或动态恢复的敏感性。训练误差表征优化的平滑性：较低的误差通常对应更稳定的参数更新，而持续较大的误差则表明更强的振荡和更高的不确定性。姿态稳定性衡量全身控制质量。较高的姿态稳定性对应较小的躯干振荡、更平滑的横滚 - 俯仰调节以及更一致的相位转换。以下使用这些指标来比较整体步态性能以及 AMP 与非 AMP 训练之间的差异。

C. 结果与分析

1) 五种步态的整体性能：在统一的策略结构、共享的观测设计和通用的奖励组织下，所提出的框架学习并部署了五种运动模式：行走、正步、爬楼梯、奔跑和跳跃。这些任务涵盖了从低动态周期性运动到高动态爆发性运动的范围，从而测试了统一强化学习公式在显著不同步态类别上的可扩展性。

定性来看，行走呈现出规则的向前迈步模式；正步表现出预期的高抬腿和直膝摆动；爬楼梯在上下楼梯过程中保持足够的足部间隙和身体姿态；奔跑产生更短的支撑相和更强的向前推进力；跳跃则实现了从下蹲准备、快速起跳到空中稳定和落地恢复的完整运动链。图 2 展示了五种步态的代表性真实机器人图像序列。这些结果表明，统一框架不仅能够维持平衡，还能生成具有清晰差异化动态特征和风格特征的运动模式。

表 III 总结了五种步态的量化性能。报告的指标对应关节跟踪质量、收敛速度、任务可靠性、训练稳定性和姿态稳定性。由于不同步态的奖励构成和任务难度存在差异，这些值旨在表征统一框架下的训练和执行行为，而非作为跨任务的严格归一化物理量。

2) AMP 对不同步态的影响：本小节考察 AMP 在不同步态类别上的运行边界。总体而言，AMP 对于具有清晰周期结构和以稳定性为首要目标的步态最为有效，而对于




图 2. 五种学习步态的代表性真实机器人图像序列：行走、爬楼梯、正步走、跳跃和跑步。

高度动态和强爆发性运动则可能产生限制。行走、正步走和爬楼梯属于前一类：它们需要稳定的支撑 - 摆动转换、一致的关节协调以及低姿态波动。对于此类任务，运动先验减少了无效探索，通常能带来更低的跟踪误差、更平滑的奖励增长和更快的收敛。

图 3 以带 AMP 的正步走和带 AMP 的跳跃作为代表性案例进行比较。在 AMP 作用下，正步走表现出总奖励的快速增加、训练误差低以及失败率的迅速衰减。AMP 在此场景中的主要贡献并非仅仅是更高的最终回报，而是强化了周期结构和风格一致性，这对于具有明确运动学特征（如高抬腿和直膝摆动）的步态尤为重要。对于跑步而言，强 AMP 先验不一定会使策略无法完成运动，但很可能会增加行为保守性，并使解决方案偏向于更强烈正则化的运动模式。在这种情况下，学习到的行为更可能类似于平滑的快走或弱跑步模式，而非具有清晰腾空阶段、强向前推进力和大幅腿部摆动的真正爆发性步态。这一观察表明，对于高度动态的运动，过强的运动先验可能在改善运动规律性的同时，压缩了策略获取高幅度动态解的空间。相比之下，跳跃

表 III 五种步态任务的定量总结。

Gait	Joint-Tracking Metric	Convergence Steps	Estimated Success Rate	Training Error	Posture-Stability Metric	Motion Characteristic
Walking	0.40	2500	95%	10.0	2.3	Periodic and stable forward locomotion
Goose-stepping	0.94	2500	97%	5.4	1.2	High leg lift and straight-knee swing
Stair climbing	1.00	5200	85%	1.0	0.95	Stair ascent/descent with recovery
Running	0.50	3000	96%	4.8	1.3	Short stance and strong propulsion
Jumping	15.5	3000	83%	6.0	8.6	Two-foot takeoff and landing recovery




图 3. AMP 与无 AMP 对比中使用的训练曲线。(a) 带 AMP 的正步走。(b) 不带 AMP 的跳跃。每个面板报告总奖励、训练误差或辅助指标以及失败率。

依赖于较大的运动幅度、垂直冲量和空中自由度。在无 AMP 设置下，该任务仍能获得持续的奖励增长和低失败率，同时关节跟踪信号稳步改善。这表明，当保留富有表现力的探索时，仅凭任务奖励就足以驱动有效的起飞、飞行和着陆恢复。这些结果支持了 AMP 应被视为一种依赖于步态的机制，而非统一激活的模块的观点。

3) 真实机器人鲁棒性与实际性能：除了单次演示之外，该方法的工程价值体现在物理机器人上的持续执行。因此，我们从三个角度评估真实机器人的鲁棒性：长时域连续性、重复试验间的一致性，以及在轻微外部干扰或启停转换下的恢复能力。

不同步态的鲁棒性标准各不相同。对于行走和正步走，重点在于节奏一致性和受控的躯干摆动；对于爬楼梯，在于足部离地间隙、落脚点以及楼梯过渡后的姿态恢复；对于跑步，在于快速短支撑切换过程中的稳定性；对于跳跃，在于同步起跳、空中姿态控制、落地缓冲以及返回下一个运动周期。特别是，跳跃参考被明确划分为下蹲、起跳、飞行、落地和站立恢复阶段，因此鲁棒性不仅取决于离地，还取决于空中运动的质量和

落地恢复。

综合来看，真实机器人部署实验表明，学习到的策略不仅限于仿真中视觉上合理的运动，还展现出物理执行所需的连续性和可重复性。这验证了所提出的多步态人形机器人统一框架的实际可行性。

IV. 结论

本文提出了一种用于多步态人形机器人的统一强化学习框架，并结合了选择性对抗运动先验策略。在共同的策略架构和奖励函数设计下，所提出的方法学习了五种代表性步态——行走、正步、爬楼梯、奔跑和跳跃，并将其迁移至物理人形机器人平台。结果表明，运动先验对周期性、稳定性导向的步态有益，但对于依赖表现性运动生成的高动态行为，应削弱或移除运动先验。更重要的是，该框架通过结合统一的强化学习公式、步态依赖的先验选择以及真实机器人验证，为在真实人形硬件上实现多步态学习提供了实用且可复现的基线。总体而言，本研究表明，实用的人形机器人移动能力不仅依赖于更强的策略，还依赖于在共享学习框架内组织多样化行为的系统性方法。

参考文献

- [1] L. Bao, L. Humphreys, and J. C. G. Pimentel, “基于深度强化学习的机器人双足运动: 简要综述,” *arXiv 预印本 arXiv:2404.17070*, 2024.
- [2] V. Makoviychuk, L. Wawrzyniak, Y. Guo, M. Liu, K. Mack, M. Mack, G. State, B. Sundaralingam, Y. Zhu, and Y. Xian, “Isaac Gym: 用于机器人学习的高性能 GPU 物理仿真,” 载于《*NeurIPS 数据集与基准会议论文集*》, 2021.[3] X. Gu, Y.-J. Wang, and J. Chen, “Humanoid-Gym: 面向人形机器人的强化学习与零样本仿真到现实迁移,” *arXiv 预印本 arXiv:2404.05695*, 2024.[4] I. Radosavovic, T. Xiao, B. Zhang, T. Darrell, J. Malik, and K. Sreenath, “基于强化学习的真实世界人形机器人运动,” 《*科学·机器人*》, 第 9 卷, 第 89 期, 文章编号 eadi9579, 2024.[5] L. Bao, L. Humphreys, and J. C. G. Pimentel, “基于步态条件强化学习与多阶段课程的人形机器人运动,” 载于《*IEEE-RAS 国际人形机器人会议 (Humanoids)* 论文集》, 2024.[6] X. B. Peng, Z. Ma, P. Abbeel, S. Levine, and A. Kanazawa, “AMP: 用于风格化物理角色控制的对抗性运动先验,” 《*ACM 图形学交易 (SIGGRAPH)*》, 第 40 卷, 第 4 期, 第 1–20 页, 2021.[7] A. Escontrela, X. B. Peng, W. Yu, T. Zhang, A. Gen, K. Goldberg, and P. Abbeel, “对抗性运动先验可作为复杂奖励函数的良好替代,” 载于《*IEEE/RSJ 国际智能机器人与系统会议 (IROS)* 论文集》, 2022, 第 223–230 页.[8] F. Lerario, G. Nava, A. Loquercio, and D. Scaramuzza, “基于对抗性运动先验的学习行走与飞行,” 载于《*IEEE/RSJ 国际智能机器人与系统会议 (IROS)* 论文集》, 2024, 第 8976–8983 页.
- [9] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “近端策略优化算法,” *arXiv 预印本 arXiv:1707.06347*, 2017.[10] X. B. Peng, M. Andrychowicz, W. Zaremba, and P. Abbeel, “基于动力学随机化的机器人控制仿真到现实迁移,” 载于《*IEEE 国际机器人与自动化会议 (ICRA)* 论文集》, 2018, 第 3567–3574 页.