

Multi-Loco: 通过强化学习增强扩散实现多形态腿式运动的统一

杨顺鹏^{*1}, 付振^{*1}, 曹哲峰¹, 郭俊德¹, Patrick Wensing², 张伟^{1,4}, 陈华^{3,41} 中国南方科技大学。

² 美国圣母大学 ³ 中国浙江大学-伊利诺伊大学厄巴纳-香槟分校联合学院 ⁴ 中国深圳LimX

Dynamics. * 同等贡献




图1: 强化学习增强扩散策略在四种平台（双足机器人、轮式双足机器人、人形机器人和四足机器人）上的部署。实验结果表明，该统一策略能够有效控制机器人在各种不平坦地形（包括草地、斜坡、楼梯和碎石路）上运动。这些结果突显了该策略的鲁棒性和卓越的控制能力。

摘要: 由于观测/动作维度和系统动力学的差异，将运动策略泛化到具有不同形态的多种腿式机器人上是一项关键挑战。在这项工作中，我们提出了 *Multi-Loco*，一种新颖的统一框架，它将一个形态无关的生成扩散模型与一个通过强化学习（RL）优化的轻量级残差策略相结合。扩散模型从多样的跨形态数据集中捕捉形态不变的运动模式，从而提升泛化能力和鲁棒性。残差策略在所有具身形态之间共享，并优化扩散模型生成的动作，以增强任务感知性能和真实世界部署的鲁棒性。我们使用包含四种腿式机器人的丰富库，在仿真和真实世界实验中评估了我们的方法。与使用PPO的标准强化学习框架相比，我们的方法——用扩散模型和残差项替代高斯策略——实现了10.35%的平均回报提升，在轮式双足运动任务中提升幅度高达13.57%。这些结果凸显了跨形态数据和复合生成架构在学习鲁棒、泛化的运动技能方面的优势。项目网站: <https://multi-loco.github.io>

关键词: 运动，腿式机器人，多形态，扩散模型，强化学习

1 引言

将运动策略泛化到具有不同具身形态的腿式机器人上是机器人学中的一个基本挑战，但它通过实现知识复用和减少特定平台的工程工作，为可扩展、高效的学习提供了一条有前景的路径。尽管强化学习（RL）在训练运动控制器方面取得了显著进展，[1, 2, 3, 4]，但这些策略通常是每种机器人形态专门训练的。即使是运动学特征相似的机器人也需要独立的训练流程，这限制了可扩展性和知识复用。因此，运动策略和数据集仍然相互孤立，阻碍了跨具身形态的统一学习。虽然将策略直接迁移到未见过的机器人仍是一个未解决的问题，但实现策略在多样化机器人之间的泛化，是迈向可扩展的多机器人学习的关键第一步。

近年来，跨具身学习已吸引了大量研究关注 [5, 6, 7, 8]。这些开创性工作主要在机器人操作任务领域展开，旨在开发能够应对运动学、感知模态和控制接口变化的可泛化策略。然而，将这一成功经验迁移至腿部运动领域面临着独特的挑战。与操作任务不同，运动深受机器人动力学特性及其与环境的物理交互影响，这使得抽象化具身形态特定特征变得更加困难。此外，协调不同具身形态之间观测与动作维度的差异，进一步增加了模型设计的复杂性。

在本工作中，我们提出了 *Multi-LoCo*，这是一个新颖的统一框架，通过整合生成扩散模型与残差强化学习策略来解决多具身形态运动学习问题。该方法不依赖端到端基于Transformer的回归方法，而是利用扩散模型从多样化的运动数据集中学习形态不变策略，捕捉跨机器人具身形态的可泛化模式。扩散模型的输出随后由轻量级残差策略进行优化，该策略通过强化学习训练，在提升任务特定性能与适应能力的同时，保持对所有具身形态的共享性。

综上所述，我们的主要贡献如下：

- 我们提出了一种基于生成模型与强化学习融合的新型框架，以支持跨多种腿式平台的统一运动策略设计。该方法通过利用扩散模型的多模态能力，捕捉不同机器人之间的共享运动模式，并进一步借助通过强化学习训练的共享残差策略，弥合仿真到现实差距。
- 我们利用扩散模型的多模态特性，对不同具身形态下的运动行为进行条件建模。通过零填充对齐异构观测与动作空间，并在训练过程中采用掩码分数匹配，我们的框架使得单一生成策略能够泛化至多种机器人平台。
- 我们引入了一种共享残差强化学习策略，用于优化扩散模型的动作输出，以进一步弥合仿真到现实差距。通过指定任务感知奖励并采用多评论家架构，该单一残差策略能够提升给定具身形态下的运动性能，在无需针对特定具身形态进行调优的情况下，对生成先验形成有效补充。

相关工作

强化学习在腿部运动中的应用：强化学习已成为机器人学中合成鲁棒且适应性强的控制策略的有力方法，尤其是在复杂的腿部运动领域 [1, 2, 3, 4, 9, 10]。Hoeller等人 [11]展示了强化学习在四足机器人上实现敏捷跑酷行为的能力，而Lee等人 [12]则将强化学习扩展到轮腿系统，应对运动与导航的双重挑战。强化学习也被应用于全身人形机器人控制。OmniH2O [13] 结合了遥操作与强化学习，实现了灵巧的全身操作，而Hover [14] 则利用神经控制器统一了运动与操作任务。

然而，这些方法大多需要具身特定训练，在不同平台间的泛化能力有限。将强化学习与先进的生成模型（如扩散模型）相结合以增强跨具身通用性，这一方向仍有待深入探索。

扩散模型及其在机器人学中的应用：扩散模型通过学习的去噪过程优化噪声样本，逼近复杂的高维分布。Song等人 [15]建立了将扩散与随机微分方程（SDE）联系起来的理论基础，通过常微分方程求解器实现了加速采样 [16, 17]，并进一步启发了诸如Elucidated Diffusion Model (EDM)等框架 [18]。在机器人学中，扩散模型因其表示多模态行为的能力而展现出有前景的应用。Chi等人 [19] 将其应用于接触丰富的操作任务，而Huang等人 [20] 引入了DiffuseLoco，这是扩散模型在腿部运动领域最早的应用之一，展示了离线训练和鲁棒的在线控制能力。扩散模型在跨具身运动学习中的潜力仍有待进一步探索。

腿式机器人的跨具身学习：跨具身学习旨在开发能够泛化到具有不同形态、驱动和感知的机器人上的控制策略。该领域的早期工作侧重于形态特定的适应，例如GenLoco [21]，通过程序化形态随机化训练四足控制器。然而，这种方法仅限于具有固定自由度的机器人。随后的研究如ManyQuadrupeds [22]通过将中枢模式发生器与强化学习相结合，泛化到多种四足机器人形态，尽管其任务空间控制范式需要预定义的机器人特定逆运动学。为了解决形态可变性，MorAL [23]引入了一种形态感知网络 (MorphNet)，该网络从本体感受观测中编码物理信息。通过将策略学习条件化于紧凑的形态表示上，MorAL提高了鲁棒性和泛化能力。这种方法仍然依赖于显式的形态嵌入。最近，URMA [24]采用Transformer通过形态无关编码器统一控制四足机器人、双足机器人和六足机器人，展示了利用显式关节描述进行解码的有效迁移。CrossFormer [8]进一步研究了跨腿式平台的通用策略，然而它们对结构化具身描述符或每机器人模块的依赖可能会阻碍向新形态的可扩展性。

表1: 跨具身学习模型对比

方法	Morphology 不可知	Independent of 联合信息	跨 任务	生成 模型
GenLoco [21]	×	✓	×	×
ManyQuadrupeds [22]	×	×	×	×
MorAL [23]	×	×	×	×
URMA [24]	✓	×	×	×
CrossFormer [8]	✓	×	✓	×
<i>Multi-Loco</i> (提出)	✓	✓	×	✓

尽管这些方法在多实体学习中已展现出令人鼓舞的成果，但它们通常依赖显式的形态信息——例如结构描述符或每机器人观测编码器——来促进泛化。这种设计选择可能会给扩展到新机器人或在更形态无关的设置中学习带来挑战。在此背景下，旨在统一跨具身形态控制、且不依赖具身形态特定输入或架构组件的框架，仍相对较少被探索。

2 方法论

我们提出了 *Multi-Loco*，一个用于多实体运动的统一策略框架，该框架结合了生成建模与强化学习。在不依赖显式形态输入的情况下，Multi-Loco 通过通用策略结构捕捉不同机器人之间的共享运动模式。该框架包含三个组成部分：(1) 通过零填充实现的维度对齐；(2) 通过掩码去噪分数匹配训练的扩散模型；(3) 采用多评论家架构的残差强化学习策略。详细内容如下。




图2: *Multi-Loco* 框架概览。多机器人数据集通过零填充和归一化进行预处理，以对齐不同具身形态的观测与动作空间。一个共享的扩散模型通过掩码去噪分数匹配进行离线训练。在推理时，扩散模型生成动作先验，并由通过多评论家PPO训练的残差策略进行优化。每个评论家专精于一种机器人类型，而策略在所有具身形态间保持共享。

2.1 多形态观测与动作的维度对齐

多实体学习面临一个根本性挑战，即不同具身形态的观测与动作空间存在差异。为了统一策略空间，我们通过零填充将所有机器人数据对齐到共同的观测与动作空间。

$$\dim(\bar{\mathcal{O}}) = \max_{m \in \mathcal{M}} \dim(\mathcal{O}_m), \quad \dim(\bar{\mathcal{A}}) = \max_{m \in \mathcal{M}} \dim(\mathcal{A}_m)$$

其中 $\mathcal{M}$ 表示机器人具身形态的集合， $\mathcal{O}$ 和 $\mathcal{A}$ 分别是统一的观测空间和动作空间。对于任意机器人 m ，其本体感知观测 $\mathbf{o}_m \in \mathcal{O}_m$ 和动作 $\mathbf{a}_m \in \mathcal{A}_m$ 通过向未使用的维度填充零，映射到 $\bar{\mathbf{o}}_m \in \mathcal{O}$ 和 $\bar{\mathbf{a}}_m \in \mathcal{A}$ 中。同时，我们定义一个二值掩码 $\mathbf{b} \in \{0, 1\}^{\dim(\bar{\mathcal{A}})}$ ，用于指示哪些动作维度是有效的（1）或填充的（0）。例如，如果一个四足机器人的动作空间是12维，且 $\dim(\mathcal{A}) = 20$ ，则其掩码为 $\mathbf{b} = [\underbrace{1, \dots, 1}_{12}, \underbrace{0, \dots, 0}_8]$ 。

为提升异构实体间的训练稳定性，我们进一步对所有观测与动作维度应用MinMax归一化。该归一化确保了不同机器人之间的数值范围一致性，有助于扩散模型训练中实现更好的收敛，并使得共享模型参数能够有效泛化至不同缩放尺度。

该预处理在保留各具身形态结构差异的同时，标准化了观测-动作格式。由此生成的统一数据集构成了训练生成式策略模型的输入，具体内容将在下一节中阐述。

2.2 基于扩散模型的多具身形态运动统一

学习跨具身形态的鲁棒策略需要应对机器人动力学和控制策略中的多模态性。为应对这一挑战，我们提出采用扩散模型直接参数化机器人的动作分布 $\mu(\bar{\mathbf{a}}|\bar{\mathbf{o}})$ ，利用其在

样本质量和鲁棒性方面相较于变分自编码器和流模型等替代方法的显著优势，定义

于机器人的动作空间 $\bar{\mathbf{a}} \in \mathcal{A}$ 和本体感知观测空间 $\bar{\mathbf{o}} \in \mathcal{O}$ 之上。

为确保实时推理，我们采用带有轻量级扩散Transformer (DiT) 骨干网络的EDM。[25] EDM近似Stein得分函数 $\nabla_{\bar{\mathbf{a}}} \log \mu_{\sigma}(\bar{\mathbf{a}}|\bar{\mathbf{o}})$ 并通过求解常微分方程来重建样本。去噪目标为

$$\mathbb{E}_{\bar{\mathbf{a}} \sim \mu} \mathbb{E}_{\mathbf{n} \sim \mathcal{N}_{\sigma}} [\lambda(\sigma) \|D_{\theta}(\bar{\mathbf{a}} + \mathbf{n}, \bar{\mathbf{o}}, \sigma) - \bar{\mathbf{a}}\|_2^2] \quad (1)$$

其中 D_{θ} 是去噪网络。为处理填充维度，我们引入掩码去噪分数匹配，确保模型仅关注有效数据条目。这里， $\odot$ 表示逐元素乘法（哈达玛积）。

$$\mathbb{E}_{\bar{\mathbf{a}} \sim \mu} \mathbb{E}_{\mathbf{n} \sim \mathcal{N}_{\sigma}} [\lambda(\sigma) \|\mathbf{b} \odot (D_{\theta}(\mathbf{b} \odot (\bar{\mathbf{a}} + \mathbf{n}), \bar{\mathbf{o}}, \sigma) - \bar{\mathbf{a}})\|_2^2] \quad (2)$$

2.3 通过残差策略与多评论家强化学习增强扩散模型

尽管扩散模型提供了强大的先验，但它们可能无法完全捕捉细粒度动力学或任务特定变化。为解决此问题，我们引入了一个在所有机器人之间共享的残差策略

$$\mathbf{a} = \bar{\mathbf{a}}_{\text{prior}} + \Delta \mathbf{a} \quad (3)$$

其中 $\bar{\mathbf{a}}_{\text{prior}}$ 从扩散模型中采样， $\Delta \mathbf{a}$ 由通过PPO训练的残差策略 $\pi_{\theta}(\Delta \mathbf{a}|\bar{\mathbf{o}}, \bar{\mathbf{a}}_{\text{prior}})$ 预测。

为了实现跨机器人具身形态的泛化，我们训练一个由所有机器人共享的单一残差策略，同时采用多评论家PPO框架 [26, 27, 28, 29] 来解决优化冲突。具体而言，我们为每种机器人类型 $k = 1, \dots, K$ 实例化一个独立的评论家 V_{ϕ}^k ，每个评论家接收其对应的特权状态 $\mathbf{s}_t^k$ 作为输入。在训练过程中，共享策略网络 π_{θ} 通过以下损失函数进行优化：

$$J(\pi_{\theta}) = \sum_{k=1}^K \mathbb{E}_t [\bar{A}_t^k(\mathbf{s}_t^k, \mathbf{a}_t^k, \Delta \mathbf{a}_t^k) \log \pi_{\theta}(\Delta \mathbf{a}^k | \bar{\mathbf{o}}^k, \bar{\mathbf{a}}_{\text{prior}}^k)] \quad (4)$$

其中 $\bar{A}_t^k$ 表示来自第 k 个评论家的归一化优势。

每个机器人的奖励函数包括：(i) 任务特定组件（例如速度跟踪、稳定性），(ii) 正则化项（例如力矩惩罚），以及 (iii) 一个残差惩罚 $r_d(\Delta \mathbf{a}_t)$ ，该惩罚鼓励残差保持接近生成先验，从而减少过度修正。完整的奖励公式详见附录B。

在训练过程中，我们在并行环境中运行多个机器人，并在扩散采样和残差优化之间交替进行。只有残差策略进行在线更新，而扩散模型保持冻结。这种设计使得残差能够专门针对任务级反馈进行调整，同时利用共享的生成先验。

3 评估

我们进行了全面的实验，以验证两个核心假设：

- 跨形态泛化：我们的统一策略框架在相同的强化学习超参数下，控制不同形态的表现优于机器人特定基线。
- 零样本仿真到现实迁移：所提出的残差策略有效弥合了基于扩散的控制器在仿真到现实之间的差距。

我们的消融实验和真实世界部署测试解决了三个关键研究问题：

- 跨具身知识涌现：在异构具身形态上进行跨机器人训练，是否有助于涌现出通过单具身学习范式无法获得的共享运动技能？

- 性能优越性：在相同的参数约束和环境条件下训练时，我们的跨机器人策略能否在运动任务上超越针对特定形态的强化学习基线？
- 仿真到现实迁移：残差策略能否有效实现多具身形态扩散模型到物理硬件的零样本迁移？

3.1 评估设置

我们的评估框架包含四种不同的机器人，以系统性地验证跨形态泛化能力：（1）**点足双足机器人**——欠驱动动力学下的极简设计，（2）**轮式驱动双足机器人**——结合腿部与轮式模式的混合运动，（3）**全尺寸人形机器人**——具有复杂全身协调的高自由度系统，以及（4）**四足机器人**——具有多个接触点的动态四足运动。


多形态平台通过仿真和真实世界实验，对我们的统一控制框架进行了全面评估。这些测试证明了该框架在管理不同机器人形态的具身变化方面的鲁棒性和适应性。后续章节将详细介绍我们的方法以及使用这些平台进行的实验结果。

3.2 消融研究

为了证明统一框架中每个模块的重要性，我们设计了以下消融研究：

- **强化学习基线**：通过PPO训练的形态特定策略，遵循来自humanoid gym [1] 和legged gym [30] 的实现实践。
- **单机机器人扩散策略 (SR-DP)**：在单个机器人演示上训练的EDM。
- **跨机器人扩散策略 (CR-DP)**：我们的EDM变体，采用动态动作掩码，在聚合的多机器人数据集上训练。
- **带残差适应的CR-DP (CR-DP+RA)**：我们的完整方法，结合了在多机器人数据集上的掩码扩散预训练，以及后续通过共享网络参数进行的基于PPO的残差策略适应。

为确保四种方法之间的公平比较，我们在训练 CR-DP+RA 和强化学习基线时，保持了相同的强化学习参数。我们的评估协议采用通过基线强化学习训练的策略来生成用于扩散策略 (DP) 训练的回滚数据，从而在统一的环境设置中直接比较平均回报和辅助指标。



(a) 4个机器人的平均回报



(b) 人形机器人运动实验



(c) 点足双足机器人下楼梯

图3: (a) 四种机器人形态（双足机器人、人形机器人、轮式机器人、四足机器人）在地形穿越任务中的性能对比分析。SR-DP+RA相比强化学习基线平均提升10.35%（双足机器人12.49%，轮式双足机器人13.57%，四足机器人4.38%，人形机器人10.97%），而CR-DP相比SR-DP提升17.96%（双足机器人17.81%，轮式双足机器人7.52%，四足机器人20.47%，人形机器人26.02%）。(b) 人形机器人运动展示了零样本仿真到现实迁移。(c) 点足双足机器人成功下楼梯。

我们的评估指标设计如下：

- **(AR)** 平均回报：表示智能体在其生存期内（最长20秒）获得的累积强化学习回报。它反映了智能体的整体性能，综合了任务成功率和控制效率。
- **(MEL)** 平均回合长度：表示智能体在每个回合中的平均生存时长（最长20秒）。更长的回合长度意味着更好的稳定性。
- **(LVT/AVT)** 平均回合线速度/角速度跟踪奖励：表示与跟踪目标线速度/角速度相关的奖励。

表2：消融研究的跨形态性能比较

方法	点足			轮式机器人		
	MEL↑	LVT↑	AVT↑	MEL↑	LVT↑	AVT↑
基线点足	18.71 ± 0.37	1.39 ± 0.25	0.94 ± 0.17	-	-	-
SR-DP点足	14.68 ± 0.66	0.93 ± 0.37	0.71 ± 0.26	-	-	-
基线轮式	-	-	-	18.29 ± 0.37	2.48 ± 0.58	1.28 ± 0.30
SR-DP-Wheeled	-	-	-	18.63 ± 0.33	2.37 ± 0.55	1.26 ± 0.28
CR-DP（我们的）	17.28 ± 0.56	1.15 ± 0.31	0.87 ± 0.21	18.97 ± 0.35	2.54 ± 0.50	1.35 ± 0.26
CR-DP+RA（我们的方法）	18.13 ± 0.46	1.42 ± 0.29	0.97 ± 0.20	18.86 ± 0.33	2.72 ± 0.53	1.36 ± 0.28

方法	人形机器人			四足机器人		
	MEL↑	LVT↑	AVT↑	MEL↑	LVT↑	AVT↑
基线人形机器人	18.88 ± 0.43	1.57 ± 0.27	1.23 ± 0.20	-	-	-
SR-DP人形机器人	13.84 ± 0.78	1.04 ± 0.42	0.93 ± 0.34	-	-	-
基线四足机器人	-	-	-	19.79 ± 0.17	5.45 ± 0.37	4.34 ± 0.30
SR-DP四足机器人	-	-	-	16.90 ± 0.62	4.51 ± 1.25	3.32 ± 0.95
CR-DP（我们的）	17.13 ± 0.54	1.33 ± 0.36	1.17 ± 0.29	19.31 ± 0.29	5.29 ± 0.57	4.19 ± 0.47
CR-DP+RA（我们的）	19.11 ± 0.44	1.58 ± 0.28	1.35 ± 0.23	19.60 ± 0.19	5.42 ± 0.50	4.32 ± 0.41

3.2.1 通过跨具身学习涌现共享运动技能

跨具身学习涌现的共享运动技能，指的是不同形态的机器人智能体通过共享学习框架学习基本运动模式的现象。

如图4所示，我们提出的CR-DP在轮式双足机器人上相比SR-DP实现了2.67%的整体地形穿越性能提升，尤其在挑战性地形上表现突出：离散障碍物提升6.10%，粗糙斜坡提升3.87%，展示了其对复杂环境的适应性。

值得注意的是，在相同参数配置下，带残差适应的CR-DP变体在轮式




图4：不同训练设置下轮式双足机器人的地形穿越性能。(a) 仅使用离线数据集训练的扩散模型（SR-DP-Wheeled 与 CR-DP）在训练中见过的地形上的表现。(b) PPO训练基线与我们结合在线强化学习的扩散+残差策略（CR-DP+RA）之间的对比。CR-DP在崎岖地形上展现出比SR-DP-Wheeled更强的适应性，而CR-DP+RA进一步增强了鲁棒性，并在稳定性和障碍穿越方面优于PPO。

双足机器人场景中，在离散地形上实现了15.13%的提升，在粗糙斜坡上实现了11.57%的提升，整体地形导航改进达到3.46%。这一成果尤为显著，因为原始的轮式双足机器人数据集和强化学习训练参数未能实现抬腿运动——这从根本上限制了其在阶梯表面和楼梯状障碍物等不连续地形上的机动性。我们的实验表明，跨机器人

DP组件能够有效地将异构实体的地形通过专长迁移至轮式双足平台，使其能够稳定穿越具有挑战性的地形。

图3显示，CR-DP在平均回报上全面优于SR-DP，而带残差适应的CR-DP则显著超越强化学习基线性能，平均提升10.35%，在轮式双足运动任务中增益高达13.57%。这些结果有力地表明，跨机器人组件成功捕获了共享的运动技能。在四足场景中观察到一个有趣的现象：带残差适应的CR-DP在MEL和LVT/AVT奖励指标上与强化学习基线性能持平。我们推测这反映了非对称知识迁移——四足运动经验为其他形态提供了示范性指导，而来自其他形态的运动模式对四足智能体的益处有限。

3.2.2 Multi-Loco策略优于形态特定强化学习基线

如图3和表2的定量结果所示，我们的带残差适应的CR-DP框架在所有评估指标和四种机器人形态上均实现了相对于强化学习基线的一致性能优势。CR-DP的监督学习基础达到了基线强化学习最大平均回报潜力的87.78%，这与行为克隆范式的已知局限性一致 [31]。通过与残差适应（采用相同的强化学习超参数实现）的集成，该混合架构展现出显著的性能提升，达到了基线效果的113.57%。这种性能反转揭示了我们的混合学习框架的关键作用：扩散模型组件从异构机器人经验中提炼可迁移的运动技能，而残差强化学习模块则通过在线强化学习将这些技能动态适应到实体特定动力学中。

3.2.3 零样本仿真到现实迁移：鲁棒运动实验评估

我们在所有四台机器人上实现了统一的运动策略（具身形态细节见图2），并通过EtherCAT通信在Intel i9-13900HX CPU上以50Hz刷新率进行实时控制。

如图1和图3(b)(c)所示，我们的Multi-Loco策略能够在具有挑战性的环境中实现鲁棒运动能力。该框架支持在从倾斜表面到植被景观及不规则基底等多种地形几何中实现平滑的实体转换和稳定的步态生成。这种跨异构环境条件的操作一致性证实了该策略通过调整其运动模式来维持动态稳定性的能力，突显了其在非结构化真实世界环境中部署的实际可行性。

4 结论

在本工作中，我们提出了Multi-Loco，一个将生成式扩散模型与强化学习相结合的多形态腿式运动统一框架。我们的方法成功解决了跨多样化机器人实体泛化控制策略的挑战，实现了对多种硬件配置的无缝适应。

在仿真与硬件平台上的实验结果表明，该框架具备有效的泛化能力，凸显了其在动态且不可预测环境中的实际应用潜力。通过利用掩码扩散模型，Multi-Loco 优雅地处理了观测与动作空间中的差异，确保了跨多种机器人系统的可扩展性。

总之，Multi-Loco开创了一条应对多形态统一控制策略挑战的新路径，提供了一个可扩展且灵活的框架，使不同机器人具身形态能够实现稳健且自适应的运动。

5 局限性与未来工作

所提出的Multi-Loco框架在统一多种具身形态的运动策略方面展现了强劲性能，涵盖点足双足机器人、轮式双足机器人、四足机器人和人形机器人，为多形态机器人系统的通用控制策略合成奠定了坚实基础。然而，仍存在若干局限性，我们将在下文中结合潜在未来方向进行讨论。

当前框架的一个关键局限性在于其训练依赖于观测-动作配对数据集。这限制了其利用广泛可用的动作捕捉数据（例如人类或动物的运动数据）的能力，这些数据通常缺乏明确的动作标签，但编码了丰富的运动技能。未来的工作将聚焦于无动作训练范式，以整合此类运动数据，使框架能够利用更大、更多样化的数据集。

尽管Multi-Loco成功统一了针对预定义具身形态的策略，但为全新形态直接合成运动策略仍然是一个开放的挑战。未来的工作将研究如何将现有具身形态中学到的运动原理的共享表征，通过零样本适应或少样本微调扩展到新形态，从而减少大量重新训练的需求。

通过应对这些挑战，我们旨在将Multi-Loco推进为一个通用的运动合成框架，使其能够跨具身形态、任务和现实世界条件进行泛化。

参考文献

- [1] X. Gu, Y.-J. Wang, X. Zhu, C. Shi, Y. Guo, Y. Liu, and J. Chen. Advancing humanoid locomotion: Mastering challenging terrains with denoising world model learning. *arXiv预印本 arXiv:2408.14472*, 2024.[2] J. Hwangbo, J. Lee, A. Dosovitskiy, D. Bellicoso, V. Tsounis, V. Koltun, and M. Hutter. Learning agile and dynamic motor skills for legged robots. *科学机器人学*, 4(26):eaau5872, 2019.
- [3] J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, and M. Hutter. Learning quadrupedal locomotion over challenging terrain. *科学机器人学*, 5(47):eabc5986, 2020.[4] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, and M. Hutter. Learning robust perceptive locomotion for quadrupedal robots in the wild. *科学机器人学*, 7(62):eabk2822, 2022.[5] J. Yang, D. Sadigh, and C. Finn. Polybot: Training one policy across robots while embracing variability. *arXiv预印本 arXiv:2307.03719*, 2023.[6] M. Xu, Z. Xu, C. Chi, M. Veloso, and S. Song. Xskill: Cross embodiment skill discovery. In *机器人学习会议*, pages 3536–3555. PMLR, 2023.[7] O. M. Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, T. Kreiman, C. Xu, et al. Octo: An open-source generalist robot policy. *arXiv预印本 arXiv:2405.12213*, 2024.[8] R. Doshi, H. Walke, O. Mees, S. Dasari, and S. Levine. Scaling cross-embodied learning: One policy for manipulation, navigation, locomotion and aviation. *arXiv预印本 arXiv:2408.11812*, 2024.[9] H. Wang, H. Luo, W. Zhang, and H. Chen. Cts: Concurrent teacher-student reinforcement learning for legged locomotion. *IEEE机器人与自动化快报*, 2024.
- [10] X. Cheng, K. Shi, A. Agarwal, 和 D. Pathak. 腿式机器人极限跑酷. 在 *2024年IEEE国际机器人与自动化大会 (ICRA)* 中, 第11443–11450页. IEEE, 2024.

[11] D. Hoeller, N. Rudin, D. Sako, 和 M. Hutter. Anymal跑酷: 学习四足机器人的敏捷导航. 科学机器人, 9(88):eadi7566, 2024.[12] J. Lee, M. Bjelonic, A. Reske, L. Wellhausen, T. Miki, 和 M. Hutter. 学习轮式腿机器人的鲁棒自主导航与运动. 科学机器人, 9(89): eadi9641, 2024.[13] T. He, Z. Luo, X. He, W. Xiao, C. Zhang, W. Zhang, K. Kitani, C. Liu, 和 G. Shi. Omnih2o: 通用且灵巧的人到人形机器人全身遥控操作与学习. *arXiv预印本 arXiv:2406.08858*, 2024.[14] T. He, W. Xiao, T. Lin, Z. Luo, Z. Xu, Z. Jiang, J. Kautz, C. Liu, G. Shi, X. Wang, 等. Hover: 用于人形机器人的多功能神经全身控制器. *arXiv预印本 arXiv:2410.21229*, 2024.[15] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, 和 B. Poole. 基于分数的随机微分方程生成建模. *arXiv预印本 arXiv:2011.13456*, 2020.[16] J. Song, C. Meng, 和 S. Ermon. 去噪扩散隐式模型. *arXiv预印本 arXiv:2010.02502*, 2020.[17] C. Lu, Y. Zhou, F. Bao, J. Chen, C. Li, 和 J. Zhu. Dpm-solver: 约10步内扩散概率模型采样的快速常微分方程求解器. 神经信息处理系统进展, 35:5775–5787, 2022.[18] T. Karras, M. Aittala, T. Aila, 和 S. Laine. 阐明基于扩散的生成模型的设计空间. 神经信息处理系统进展, 35:26565–26577, 2022.[19] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, 和 S. Song. 扩散策略: 通过动作扩散进行视觉运动策略学习. 国际机器人研究杂志, 页码 02783649241273668, 2023.[20] X. Huang, Y. Chi, R. Wang, Z. Li, X. B. Peng, S. Shao, B. Nikolic, 和 K. Sreenath. Diffuse-loco: 基于离线数据集的实时腿部运动控制扩散方法. *arXiv预印本 arXiv:2404.19264*, 2024.[21] G. Feng, H. Zhang, Z. Li, X. B. Peng, B. Basireddy, L. Yue, Z. Song, L. Yang, Y. Liu, K. Sreenath, 等. Genloco: 四足机器人的通用运动控制器. 在机器人学习会议中, 第1893–1903页. PMLR, 2023.[22] M. Shafiee, G. Bellegarda, 和 A. Ijspeert. Manyquadrupeds: 为多种四足机器人学习单一运动策略. 在 2024年IEEE国际机器人与自动化大会 (ICRA) 中, 第3471–3477页. IEEE, 2024.[23] Z. Luo, Y. Dong, X. Li, R. Huang, Z. Shu, E. Xiao, 和 P. Lu. Moral: 学习在挑战性地形上为四足机器人实现形态自适应运动控制器. *IEEE机器人与自动化快报*, 2024.[24] N. Bohlinger, G. Czechmanowski, M. Krupka, P. Kicki, K. Walas, J. Peters, 和 D. Tateo. 一策统御: 一种面向多形态运动的端到端学习方法. *arXiv预印本 arXiv:2409.06366*, 2024.[25] W. Peebles 和 S. Xie. 基于Transformer的可扩展扩散模型. 在 *IEEE/CVF国际计算机视觉大会论文集中*, 第4195–4205页, 2023.[26] S. Mysore, G. Cheng, Y. Zhao, K. Saenko, 和 M. Wu. 多评论家演员学习: 教授强化学习策略以风格化行动. 在国际学习表征大会中, 2022.

[27] P. Xu, X. Shang, V. Zordan, and I. Karamouzas. 带任务控制的复合运动学习. *ACM图形学汇刊*, 42(4):1–16, 2023. [28] T. Huang, J. Ren, H. Wang, Z. Wang, Q. Ben, M. Wen, X. Chen, J. Li, and J. Pang. 跨多种姿态的人形机器人站立控制学习. *arXiv预印本 arXiv:2502.08378*, 2025. [29] H. Wang, Z. Wang, J. Ren, Q. Ben, T. Huang, W. Zhang, and J. Pang. Beamdojo: 稀疏立足点上的敏捷人形机器人运动学习. *arXiv预印本 arXiv:2502.10363*, 2025. [30] N. Rudin, D. Hoeller, P. Reist, and M. Hutter. 使用大规模并行深度强化学习在数分钟内学会行走. 在 *机器人学习会议*, 页码 91–100. PMLR, 2022. [31] S. Ross and D. Bagnell. 模仿学习的高效归约. 在 *第十三届国际人工智能与统计会议论文集*, 页码 661–668. JMLR研讨会与会议论文集, 2010. [32] D. Picard. Torch.manual_seed(3407)就是你所需要的一切: 论随机种子对计算机视觉深度学习架构的影响. *arXiv预印本 arXiv:2109.08203*, 2021. [33] Z. Dong, Y. Yuan, J. Hao, F. Ni, Y. Ma, P. Li, and Y. Zheng. Cleandiffuser: 用于决策中扩散模型的易用模块化库. *arXiv预印本 arXiv:2406.09509*, 2024. URL <https://arxiv.org/abs/2406.09509>.

附录

实验视频

我们在四个不同的腿式机器人平台上对我们的框架进行了全面的真实世界评估。有关详细的实证验证，我们鼓励读者观看补充视频。如实验记录所示，我们的框架展示了统一控制策略能够管理四种形态多样的腿式机器人，这些机器人具有不同的执行器配置和质量分布。这种跨平台适应性是通过我们新颖的方法实现的，该方法能够在保持动态运动性能的同时，实现稳健的策略泛化。

A 扩散模型训练与推理的细节

DDPM作为一种扩散模型，因其能够表示多模态性和复杂分布，在机器人操作和腿式机器人运动等任务中取得了显著成果。由于DDPM需要大量的去噪步数，推理时间可能相当长。对于人形机器人，扩散策略必须以至少50 Hz的频率运行，理想情况下达到100 Hz。因此，有必要加速其性能，或用DDIM、EDM或一致性模型等替代方案。在此背景下，我们选择了EDM模型，以确保高样本质量，同时最小化推理时间，从而实现高频反馈控制。

EDM（阐明扩散模型） [18] 基于方差爆炸SMLD的逆时常微分方程 [15]。为了阐明扩散模型的设计空间，EDM提出了一种更通用的形式，同时考虑了时间依赖缩放，并引入了预处理以消除去噪分数匹配中因噪声方差增加而产生的影响。EDM将去噪器 $D_\theta(\hat{\mathbf{x}}, \sigma)$ 重新参数化为以下形式

$$D_\theta(\hat{\mathbf{x}}, \sigma) = c_{\text{skip}}(\sigma)\hat{\mathbf{x}} + c_{\text{out}}(\sigma)F_\theta(c_{\text{in}}(\sigma)\hat{\mathbf{x}}, c_{\text{noise}}(\sigma)). \quad (5)$$

并且去噪分数匹配的相应目标函数变为

$$\mathbb{E}_{\mathbf{x}, \mathbf{n}} \left[\frac{c_{\text{out}}(\sigma)^2}{\sigma} \|F_\theta(c_{\text{in}}(\sigma)(\mathbf{x} + \mathbf{n}), c_{\text{noise}}(\sigma)) - \mathbf{x}_d\|_2^2 \right] \quad (6)$$

其中 $\mathbf{x}_d = (\mathbf{x} - c_{\text{skip}}(\sigma)(\mathbf{x} + \mathbf{n}))/c_{\text{out}}$ 在要求输入和输出具有单位方差的同时最小化 c_{out} ，参数的值选择如下：

$$c_{\text{noise}}(\sigma) = \ln(\sigma)/4, \quad (7a)$$

$$c_{\text{in}}(\sigma) = 1/\sqrt{\sigma_{\mathbf{x}}^2 + \sigma^2}, \quad (7b)$$

$$c_{\text{skip}}(\sigma) = \sigma_{\mathbf{x}}^2/(\sigma^2 + \sigma_{\mathbf{x}}^2), \quad (7c)$$

$$c_{\text{out}}(\sigma) = \sigma \cdot \sigma_{\mathbf{x}}/(\sigma^2 + \sigma_{\mathbf{x}}^2), \quad (7d)$$

其中 $\sigma_{\mathbf{x}}$ 是数据的方差。 [18] 表明该函数的最优选择是 $\sigma(t) = t$ ，这也是我们在工作采用的方法。因此，EDM求解以下概率流常微分方程

$$\frac{d\mathbf{x}}{dt} = \frac{\mathbf{x} - D_\theta(\mathbf{x}, \sigma)}{t} \quad (8)$$

用于采样，从 $\mathbf{x}(T) \sim \mathcal{N}(0, T^2 \mathbf{I})$ 开始，在 $\mathbf{x}(0)$ 处停止。在实践中，我们使用欧拉方法来求解此常微分方程以进行采样。

在网络架构方面，扩散模型通常使用U-Net和基于Transformer的结构。在我们的场景中，我们选择DiT（去噪Transformer）模型 [25] 作为骨干网络来拟合 $F_\theta(\cdot)$ 。填充观测 $\bar{\mathbf{o}}_t$ 作为条件变量，通过一个多层感知机（MLP）嵌入到潜在空间中，该多层感知机记为 $g(\cdot)$ 。为了将 $\bar{\mathbf{o}}_t$ 作为条件变量纳入， $D_\theta(\hat{\mathbf{x}}, \sigma)$ 被重写为 $D_\theta(\hat{\mathbf{a}}_t, \bar{\mathbf{o}}_t, \sigma)$ ，并且 $F_\theta(c_{\text{in}} \hat{\mathbf{x}}, c_{\text{noise}}(\sigma))$ 被改为 $F_\theta(c_{\text{in}} \hat{\mathbf{a}}_t, g(\bar{\mathbf{o}}_t), c_{\text{noise}}(\sigma))$ 。网络结构的详细信息可在图5中找到。




图5: 用于拟合 F_θ 的DiT网络结构。

参数	数值/描述
数据样本	
预测范围	4
观测范围	10
每台机器人最大样本数	2048000
批量大小	8192
扩散网络 (DiT)	
输入维度	20
嵌入维度 (emb dim)	128
模型维度 (d model)	256
注意力头数 (n heads)	8
网络深度 (depth)	3
时间步嵌入类型	傅里叶
MLP条件网络 $g(\cdot)$	
输入维度	683
输出维度	嵌入维度
隐藏维度 (隐藏维度)	[512, 256]
激活函数	ELU
训练参数	
学习率	3e-4
优化器	Adam
学习率调度器	余弦退火
EMA衰减率	0.999
训练轮数	500
Seed	3407 (灵感来源于 [32])

表3: 统一扩散模型的配置

算法1掩码EDM训练与推理

```
1: 初始化:
2: - 网络: DiT  $F_\theta$  和条件MLP  $g_\phi$ 
3: - EDM参数:  $\sigma_{\text{data}} = 0.5, \sigma_{\text{min}} = 0.002, \sigma_{\text{max}} = 80.0, \rho = 7.0$ 
4: - 噪声采样:  $P_{\text{mean}} = -1.2, P_{\text{std}} = 1.2$ 
5: - 训练: 批量大小 = 512, 学习率 =  $3 \times 10^{-4}$ , EMA衰减率 = 0.999
6: 过程数据预处理
7:   提取轨迹片段 (观测  $\mathbf{o}$ , 动作  $\mathbf{a}$ )
8:   应用零填充以处理变长序列
9:   计算基于分位数的MinMax归一化:
10:  - 计算每个特征维度的5%和95%分位数
11:  - 归一化至  $[-1, 1]$  范围:  $\mathbf{x}_{\text{norm}} = 2 \cdot \frac{\mathbf{x} - \mathbf{x}_{\text{min}}}{\mathbf{x}_{\text{max}} - \mathbf{x}_{\text{min}}} - 1$ 
12:   通过拼接归一化观测值和指令来创建条件向量
13:   返回归一化数据集, 归一化统计量
14: 结束过程
15: 过程 训练(数据集  $\mathcal{D}$ , 训练轮数 = 400K)
16:   对于 每个训练轮次执行
17:     对于 批次  $(\mathbf{o}, \mathbf{a}_0, \mathbf{b}) \sim \mathcal{D}$  执行
18:       采样噪声  $\sigma \sim \mathcal{N}(-1.2, 1.2^2)$ ,  $\epsilon \sim \mathcal{N}(0, I)$ 
19:       计算含噪动作  $\mathbf{a}_t = \mathbf{a}_0 + \sigma \cdot \epsilon$ 
20:       计算 EDM 预处理系数:
21:        $c_{\text{skip}} = \frac{0.5^2}{0.5^2 + \sigma^2}$ 
22:        $c_{\text{out}} = \frac{\sigma \cdot 0.5}{\sqrt{0.5^2 + \sigma^2}}$ 
23:        $c_{\text{in}} = \frac{1}{\sqrt{0.5^2 + \sigma^2}}$ 
24:        $c_{\text{noise}} = 0.25 \cdot \log \sigma$ 
25:       计算网络预测:  $D_\theta(\mathbf{a}_t, \sigma, g_\phi(\mathbf{o}))$ 
26:       计算掩码损失:  $\mathcal{L} = ((1 - \mathbf{b}) \cdot (D_\theta(\mathbf{a}_t, \sigma, g_\phi(\mathbf{o})) - \mathbf{a}_0))^2$ 
27:       应用EDM加权:  $\mathcal{L}_{\text{final}} = \left( \mathcal{L} \cdot \frac{0.5^2 + \sigma^2}{\sigma \cdot 0.5} \right)^{\frac{1}{\rho}}$ 
28:       使用Adam更新参数 ( $\eta = 3 \times 10^{-4}$ )
29:       更新指数移动平均模型参数 (速率 = 0.999)
30:     结束循环
31:   结束循环
32: 结束过程
33: 过程 推理(观测  $\mathbf{o}$ , 动作掩码  $\mathbf{b}$ , 采样步数  $S = 5$ )
34:   使用存储的统计量归一化观测
35:   初始化  $\mathbf{a}_S \sim \mathcal{N}(0, 80.0^2 \cdot I)$ 
36:   计算噪声调度:  $\sigma_i = (0.002^{1/7} + \frac{i}{S}(80.0^{1/7} - 0.002^{1/7}))^7$  对于  $i \in \{0, 1, \dots, S\}$ 
37:   对于  $i = S$  递减至 1 执行
38:     应用动作掩码:  $\mathbf{a}'_i = (1 - \mathbf{b}) \cdot \mathbf{a}_i$ 
39:     通过预处理计算网络预测
40:     常微分方程更新:  $\dot{\mathbf{a}} = \frac{\mathbf{a}_i - D_\theta(\mathbf{a}'_i, \sigma_i, g_\phi(\mathbf{o}))}{\sigma_i}$ 
41:     欧拉步:  $\mathbf{a}_{i-1} = \mathbf{a}_i - \dot{\mathbf{a}} \cdot (\sigma_i - \sigma_{i-1})$ 
42:   结束循环
43:   使用存储的统计量进行反归一化
44:   返回  $\mathbf{a}_{\text{final}}$ 
45: 结束过程
```

A.1 超参数与训练硬件

DiT模型配置和训练参数列于表3。我们的实现基于开源*CleanDiffuser* 库 [33]，该库为决策任务中的扩散模型提供了模块化且可扩展的接口。我们采用其EDM采样实现进行训练和推理。若模型在单个NVIDIA 3090 GPU上训练，总训练时间根据机器人具身形态和数据集大小在3至12小时之间。

A.2 训练与推理细节

我们的基于扩散的策略通过一个统一框架处理多种具身形态，该框架能够适应可变维度的观测与动作空间。在训练过程中，我们使用基于第5和第95百分位的MinMax归一化对所有输入进行归一化，以减轻异常值的影响。这将特征映射到共同的 $[-1, 1]$ 范围，同时保留大部分数据点的相对缩放比例。

为支持跨形态泛化，我们对观测和动作向量进行零填充，以匹配所有机器人形态中的最大维度（观测：68维，动作：20维）以及相应的维度配置。在训练和推理过程中，我们应用形态特定二值掩码 $\mathbf{b}$ ，确保只有有效维度参与损失计算和预测。具体而言，训练时损失计算如下： $\mathcal{L} = ((1 - \mathbf{b}) \cdot (D_\theta(\mathbf{a}_t, \sigma, g_\phi(\mathbf{o})) - \mathbf{a}_0))^2$

在推理过程中，我们采用欧拉方法，以5个采样步数求解常微分方程并生成动作。在每个去噪步骤中，我们应用动作掩码以确保预测一致性： $\mathbf{a}'_i = (1 - \mathbf{b}) \cdot \mathbf{a}_{i0}$

机器人	观测	动作	指令	组件
点足双足机器人	$\mathcal{O}_1 \in \mathbb{R}^{26}$	$\mathcal{A}_1 \in \mathbb{R}^6$	$\mathcal{C}_1 \in \mathbb{R}^3$	基座姿态（7维），速度（6维），关节状态（6维），步态相位（7维）
轮式双足机器人	$\mathcal{O}_2 \in \mathbb{R}^{28}$	$\mathcal{A}_2 \in \mathbb{R}^8$	$\mathcal{C}_2 \in \mathbb{R}^3$	基座姿态（7维），速度（6维），关节状态（8维），轮子状态（7维）
人形机器人	$\mathcal{O}_3 \in \mathbb{R}^{68}$	$\mathcal{A}_3 \in \mathbb{R}^{20}$	$\mathcal{C}_3 \in \mathbb{R}^3$	基座姿态（7维），速度（6维），关节状态（48维），步态相位（7维）
四足机器人	$\mathcal{O}_4 \in \mathbb{R}^{44}$	$\mathcal{A}_4 \in \mathbb{R}^{12}$	$\mathcal{C}_4 \in \mathbb{R}^3$	基座姿态（7维），速度（6维），关节状态（24维），步态相位（7维）

表4：配置特定的观测与动作空间

A.3 消融实验：扩散采样步数

我们评估了扩散采样步数对控制性能的影响。步数越少，计算时间越短，但可能降低轨迹质量。结果（图6）表明，使用 [3,5,10,15] 去噪步数能够在控制精度与采样效率之间取得平衡，且随着步数增加，收益逐渐递

超过20步的转弯。根据这一结果，我们在部署实验中选择5个去噪步数。




图6：EDM中不同采样步数的比较

A.4 消融研究：扩散训练的数据集大小

为了评估数据效率，我们在双足机器人的不同数据集大小（1%、10%、25%、50%、100%）上训练扩散模型，同时保持其他条件不变。性能随数据量呈次线性缩放，表明即使在部分数据下也具有较强的泛化能力。然而，极小的数据集（< 25%）会导致行为不稳定和地形适应能力差。




图7：双足统计：与不同数据集大小训练的EDM对比。（数据集中双足机器人样本的最大数量为2048000）

A.5 消融研究：扩散训练的数据集组成分析

我们进行了一项系统性研究，探讨在保持总数据集大小不变的情况下，不同机器人形态间的数据分布比例变化如何影响策略性能。以四种机器人类型（尖足双足机器人、轮式双足机器人、人形机器人和四足机器人）各占25%-25%-25%-25%的基线配置为基准，我们创建了四个实验条件，依次将某一类别减少至10%，同时将其他类别按比例增加至30%。随后，对由此产生的平均回报 (AR) 和平均回合长度 (MEL) 指标进行了分析，结果如图8所示。减少尖足双足机器人和四足机器人的数据分配对性能影响微乎其微，这表明其相对简单的运动任务所需训练数据极少。相反，减少轮式双足机器人的数据会导致其对应策略的性能显著下降，这可能是由于轮式运动固有的复杂性，加上来自形态差异较大的机器人类型的跨形态知识迁移有限所致。最值得注意的是，人形机器人数据减少表现出双重影响——不仅因高维观测空间训练数据减少而导致预期的自身性能下降，还意外导致轮式双足机器人性能的平均回报降低。这种跨域依赖性证实了我们正文中提出的假设，即人形机器人在增强轮式运动能力方面具有互补作用，暗示了形态迥异的系统之间此前未被认识到的协同效应。




图8：数据集组成比例对扩散策略训练的影响。基线正常比例配置（25%-25%-25%-25%）将数据平均分配给四种形态：尖足双足机器人、轮式双足机器人、人形机器人和四足机器人。通过将一种形态的份额减少至10%，同时将其他形态按比例增加至各30%，创建了四种实验变体：尖足减少（10%-30%-30%-30%）、轮式减少（30%-10%-30%-30%）、人形减少（30%-30%-10%-30%）和四足减少（30%-30%-30%-10%）。

A.6 零样本迁移至未见平台：Unitree Go2




图9：零样本迁移至Unitree Go2

为了评估在训练形态之外的泛化能力，我们直接将统一策略部署到Unitree Go2上，无需任何微调。尽管该机器人在训练中未曾出现，但该策略仍能实现稳定的前向运动，证明了模型具有与形态无关的泛化能力。详细结果和 rollout 视频可在补充视频中查看。

对于运动任务评估，平均回合长度（MEL）、运动速度跟踪（LVT）和执行器变化阈值（AVT）指标量化了任务完成质量。如表5所示，统计

CR-DP+RA在MEL（0.62 ~ 3.2%）、LVT（0.22 ~ 4.1%）和AVT（0.23 ~ 5.3%）中，配置a1与go2之间的统计上不显著的差异，证实了零样本策略迁移成功迁移至go2形态。此外，图9所示的仿真结果也证实了零样本迁移成功迁移至go2配置，证明了我们策略框架的强大泛化能力。虽然表5显示，CR-DP+RA在a1（387.57）和go2（295.96）上的平均回报（AR）存在显著差异，但我们的分析表明，这一差异主要归因于基座高度跟踪奖励模块中期望基座高度参数的不同设置。由于不同配置之间存在形态变化，最优基座高度设置应针对具体配置而定。通过减去基座高度奖励分量对该参数进行归一化后，CR-DP+RA调整后的平均回报值变为a1为306.69，go2为294.28，这表明在考虑形态差异后，两者性能相当。这一调整验证了所观察到的平均回报差距源于参数规范，而非根本性的策略局限性。

组别	方法	指标			
		AR↑	MEL↑	LVT↑	AVT↑
a1	CR-DP+平均回报	387.57±6.15	19.60±0.19	5.42±0.41	4.32±0.41
	CR-DP	325.24±8.63	19.14±0.36	5.22±0.72	4.14±0.58
go2	CR-DP+RA	295.96±5.81	18.98±0.33	5.20±0.74	4.09±0.60
	CR-DP	256.05±5.72	18.40±0.37	5.02±0.91	3.93±0.74

表5：四足机器人a1与go2的性能比较

B 强化学习残差自适应细节

虽然扩散模型为动作生成提供了强大的先验，但它们可能缺乏任务感知能力，或无法考虑细微的地形交互。为了补充生成先验，我们引入了一个通过强化学习训练的残差策略，详情如下。

我们的实现利用了NVIDIA IsaacGym的GPU加速并行仿真环境，该环境专为机器人学习设计。系统架构集成了来自humanoid gym [1] 和legged gym [30] 开源框架，实现了基于近端策略优化（PPO）的可扩展强化学习流水线。

B.1 环境设置

机器人的策略观测 $\mathbf{o}$ 包括过去10步内的速度控制指令和带有步态周期参数（不包括轮式运动）的本体感觉数据。具体来说：

- 本体感觉数据：
 - 由惯性测量单元测量的机器人姿态（朝向）和角速度。– 所有机器人肢体的关节角度和角速度。
- 速度控制指令：
 - XY平面（笛卡尔坐标）中的线速度指令。– 绕Z轴（偏航方向）的角速度指令。
- 步态周期：

由参数化正弦曲线定义的随时间变化的周期信号：

$$\text{Gait}(t) = \begin{cases} \sin\left(\frac{2\pi t}{T}\right) \\ \cos\left(\frac{2\pi t}{T}\right) \end{cases}$$

其中 T 是步态周期（完成一个周期所需的时间）， t 表示当前时间步。

PPO超参数详见表6，其中一项显著配置是禁用了价值预测裁剪。这一设计决策源于我们的混合架构，该架构集成了预训练扩散模型作为先验引导。与传统的从头训练范式相比，预训练的动态感知能力使得价值函数初始化更加稳定。

PPO参数	数值
期望KL散度	0.01
学习率	4e-4
折扣因子	0.99
GAE的Lambda参数	0.95
小批量	4
学习轮次	5
熵损失尺度	0.001
PPO裁剪范围	0.2
值预测裁剪	False
残差系数	0.2
最大迭代次数	10001
展开	24

表6: PPO统一EDM的训练参数

表7展示了我们的异构演员-评论家架构，该架构包含统一的演员网络参数和四个专用评论家网络参数。

模型-评论员双足	
激活函数	["elu" , "elu" , "elu" , "线性"]
隐藏层维度	[512, 256, 128]
模型-评论员双足轮式	
激活函数	["elu" , "elu" , "elu" , "线性"]
隐藏层维度	[512, 256, 128]
模型-评论家类人机器人	
激活函数	["elu" , "elu" , "elu" , "线性"]
隐藏层维度	[512, 256, 128]
模型-评论家四足机器人	
激活函数	["elu" , "elu" , "elu" , "线性"]
隐藏层维度	[512, 256, 128]
模型-演员	
对数标准差最大值	4.0
对数标准差最小值	-20.0
标准差初始化	1.0
激活函数	["elu" , "elu" , "elu" , "线性"]
隐藏层维度	[512, 256, 128]

表7：演员-评论家模型参数

B.2 奖励设计

我们的奖励函数由三个协调组件构成，这些组件经过系统设计，旨在实现稳健的策略学习：

- 控制运动性能的任务特定目标，如表8所示
- 处理物理约束的形态感知正则化项，如表9所示
- 一种扩散引导残差惩罚，通过预训练的运动先验强制执行动态可行性：

$$r_d(\Delta \mathbf{a}_t) = \alpha \|\Delta \mathbf{a}_t\|_1$$

其中 α 是残差惩罚的奖励系数， $\Delta \mathbf{a}_t$ 是残差动作。

奖励	表达式	Biped-Wheel	Pointed-Foot-Biped	人形机器人	四足机器人
跟踪线速度	$\exp(-\ v_b^{des} - v_b\ \times \sigma)$	4.0	2.0	2.0	6.0
角速度跟踪	$\exp(-\ \Omega_b^{des} - \Omega\ \times \sigma)$	2.0	1.5	1.5	5.0
基座高度	$\exp(-\ h_b^{des} - h_b\ \times 100)$	-	2.0	4.0	6.0
朝向	$\exp(-\ \theta_b^{des} - \theta_b\ \times 10)$	5.0	5.0	-10.0	4.0

表8：运动任务奖励

奖励	表达式	Biped-Wheel	Pointed-Foot-Biped	人形机器人	四足机器人
关节力矩	$\ \tau\ ^2$	-1.6e-4	-8e-5	-8e-5	-2e-4
功率	$ \tau \cdot \dot{q} $	-2e-5	-2e-5	-	-5e-4
关节速度	$\ \dot{q}\ ^2$	-5e-4	-	-	-
关节加速度	$\ \ddot{q}\ ^2$	-1.5e-7	-2.5e-7	-2.5e-7	-2.5e-7
线性速度Z	$\ v_z^c\ ^2$	-0.3	-0.5	-2.0	-2.0
角速度XY	$\ \Omega_{xy}\ ^2$	-0.3	-0.05	-0.05	-0.1
动作平滑度	$\ a_{k+1} + a_{k-1} - 2a_k\ ^2$	-0.03	-0.01	-0.01	-0.02
动作速率	$\ a_{k+1} - a_k\ ^2$	-0.03	-0.01	-0.01	-0.02
碰撞	$\ \mathbf{F}_c\ > 0$	-0.1	-0.02	-1.0	-10.0
接触力	$\text{clip}\{\ \mathbf{F}_l\ _2 + \ \mathbf{F}_r\ _2 - F_{max}\}_0^{400}$	-0.1	-0.1	-	-
默认关节位置	$\ q - q_0\ $	-0.05	-	3.0	2.0
足部距离	$\text{clip}(d_{foot}^{min} - d_{foot})$	-100	-100	-100	-
标称足部高度	$\exp(-\ h_{foot}^{des} - h_{foot}\ ^2 \times 200)$	4.0	-	-	3.0

表9：正则化奖励