

从认知到实践：通过指令学习掌握多样运动技能

Linqi Ye, Jiayi Li, Yi Cheng, Xianhao Wang, Bin Liang, Yan Peng

摘要—近年来，机器人学习领域取得了许多成功的尝试。对于接触丰富的机器人任务，通过强化学习来学习协调运动技能具有挑战性。模仿学习通过使用模仿奖励来鼓励机器人跟踪给定的参考轨迹，从而解决了这一问题。然而，模仿学习效率不高，且可能限制学习到的运动。在本文中，我们提出了指令学习，该方法受人类学习过程启发，具有高效、灵活和通用的特点，适用于机器人运动学习。指令学习不将参考信号用于奖励，而是直接将参考信号作为前馈动作，并与通过强化学习学习的反馈动作相结合来控制机器人。此外，我们提出了动作边界技术并移除了模仿奖励，这对高效和灵活的学习至关重要。我们比较了指令学习与模仿学习的性能，表明指令学习可以大大加快训练过程，并确保正确学习期望的运动。通过双足机器人和四足机器人的一系列运动学习示例，验证了指令学习的有效性，其中技能通常可以在几百万步内学会。此外，我们还在真实的四足机器人上进行了仿真到现实迁移和在线学习实验。指令学习展现了巨大的优势和潜力，使其成为模仿学习的一个有前景的替代方案。

索引词—强化学习，腿部运动，指令学习，四足机器人，双足机器人。

I. 引言

随着在腿式机器人 [1][2]、空中机器人 [3]、和机器人操作 [4] 中的成功应用，学习方法已被证明是机器人运动控制的有效途径。强化学习旨在通过与环境的交互以及对其响应的观测来最大化奖励。尽管已经提出了许多强大的强化学习方法，例如深度确定性策略梯度（DDPG）[5]、近端策略优化（PPO）[6]、和软演员评论家（SAC）[7]，但奖励设计仍然是一个具有挑战性的问题，尤其是在接触密集的任务中。例如，在学习腿部

运动时，简单的奖励可能导致不自然的运动行为[8]。尽管机器人可以学会快速移动和穿越障碍物，但其行为显得笨拙。

模仿学习通过将运动参考信号应用于奖励（通常从动作捕捉数据中获取）来生成自然的行为 [9]。然而，模仿学习确实存在一些缺点。首先，模仿过程是奖励驱动的，机器人从随机动作开始，并试图改进以获得更高的奖励。这个过程与人类学习过程不同。例如，在学习跳舞时，我们可以根据老师的示范或指导第一次就做出动作，只是做得不够好。然后通过更多的尝试，我们做得越来越好，正如俗话说“熟能生巧”。通过这种方式，我们可以非常高效地学习复杂的技能。然而，模仿学习通常起步非常糟糕，需要数百万次尝试才能最终掌握所需的动作。其次，模仿学习试图最小化机器人动作与参考动作之间的误差，这限制了机器人，并可能阻止其探索性能更优的行为。而对于人类学习技能而言，我们并非试图完全复制他人的行为，而是将其作为一个良好的起点，并努力使其最适合自己的。

受人类运动技能学习过程的启发，我们提出了指令学习框架。指令学习的核心是“知行合一”，即机器人从指令动作出发，通过训练不断改进。与在奖励中使用参考信号的模仿学习不同，指令学习将参考信号直接作为前馈用于动作，并应用强化学习进行修正以实现给定目标。这种学习机制使得指令学习本质上更高效且约束更少。

本文的贡献有四个方面。首先，我们提出了指令学习概念，并详细阐述了其与人类学习的相似性以及模仿学习的本质区别。尽管 [10] 已经提出了类似的前馈-反馈学习结构，但指令学习在两个方面有所不同：1) 我们通过使用折扣反馈提出了动作边界技术，这是实现快速学习的关键；2) 我们在指令学习中移除了模仿奖励，这赋予了它更大的灵活性。通过使用指令学习，机器人可以以简单的踏步运动作为前馈，学习各种运动行为。其次，我们通过一系列运动学习示例充分展示了指令学习的效率、通用性和灵活性，包括双足行走、平地行走、正步走、跳跃和单脚跳，以及四足小跑、踱步、弹跳和蹦跳。第三，我们研究了以往模仿学习研究中被忽视的另一项技术，即：

*本研究得到国家自然科学基金委员会资助，项目编号为 62003188 和 92248304。（通讯作者：Bin Liang 和 Yan Peng）代码可在 <https://github.com/Lr-2002/raisimLib> 获取。L. Ye 和 Y. Peng 任职于上海大学人工智能研究所、海洋人工智能协同创新中心，中国上海，邮编 200444。J. Li 和 Y. Cheng 任职于清华大学深圳国际研究生院智能控制与遥科学中心，中国深圳，邮编 518055。X. Wang 任职于西安电子科技大学机电工程学院，中国西安，邮编 710126。B. Liang 任职于清华大学自动化系导航与控制研究中心，中国北京，邮编 100084。

观测中的参考信号 (RO)。在大多数模仿学习研究中, 参考信号被置于奖励中而非添加到观测中, 我们认为这是导致其效率低下的根源之一。我们证明, RO 能够促进模仿学习更快、更准确地学习。然而, 即使采用 RO, 模仿学习的效率仍然不如指令学习, 这可能是由于其固有的学习机制所致。最后, 我们通过在真实四足机器人上进行仿真到现实迁移和在线学习实验, 展示了指令学习在真实系统上的可行性。得益于指令学习的高效率, 机器人只需 20 分钟即可在现实世界中学会向前行走或转弯。

II. 相关工作

A. 机器人强化学习 强化学习已

成为机器人运动控制的主流方法之一, 近年来取得了许多显著成就。Duan 等人 [11] 提出了一种将双足机器人控制与强化学习相结合的方法, 允许在任务空间中进行脚部设定点学习, 并开发了一种强化学习公式, 用于训练能够响应指定触地位置的动态步态控制器。Siekman 等人 [12] 通过周期时间变量和相应的周期性奖励函数对时间进行索引, 实现了常见的双足步态, 包括行走、跑步、单脚跳、疾驰和跳跃。引入基于学习的状态估计网络和动力学随机化, 以更好地在崎岖地形上展示快速且鲁棒的运动 [13]。Margolis 等人 [14] 使用师生训练策略和少量自适应课程更新规则, 实现了室内外快速奔跑。Hwangbo 等人 [15] 利用基于注意力的循环编码器, 整合了本体感觉和外部感觉输入。他们成功地将控制器部署在 ANYmal C 机器人上, 该机器人穿越了具有陡峭坡度、光滑表面、草地和雪地等挑战性的自然环境。Margolis 等人 [16] 提出学习一种单一策略, 该策略编码了结构化的运动策略家族, 这些策略以不同方式解决训练任务, 并演化出一个条件部分来指定任务, 从而避免奖励和环境重新设计的缓慢迭代循环。

基于强化学习的重大进展迄今已取得, 一些新框架被探索以加速学习过程。Kim 等人 [17] 发现, 在学习流程中利用约束有望取代繁重且费力的奖励工程, 并提出了一种新颖框架, 用于训练由奖励和约束共同构成的复杂机器人系统的神经网络控制器。一种利用单 GPU 大规模并行化的强化学习框架 [18] 被提出, 其训练时间相比先前工作可减少多个数量级。研究表明, 使用 NVIDIA Isaac Gym 仿真环境 [19], 复杂的现实世界机器人任务可在数分钟内完成训练。

B. 机器人模仿学习

对于机器人强化学习而言, 奖励设计是一个关键且具有挑战性的部分。对于像轨迹优化方法这样的控制器来说, 生成复杂的动作更为直观,

例如腿式机器人的后空翻, 而设计用于强化学习方法的奖励来实现这一目标则十分困难。模仿学习是一种从专家经验中获取先验模式作为简单奖励项的有效方式, 因为这些经验可能不足以直观地形成数学表达式来生成不同的运动特征, 例如保持足够的足部离地间隙和自然的行为。在某种程度上, 模仿学习利用了专家知识, 并避免了复杂的奖励设计。

实现模仿学习最简单的方法是使用模仿奖励来鼓励机器人跟随给定动作。模仿奖励是机器人状态与待跟随参考轨迹之间的误差。在 [9], 中, 从真实狗身上捕捉的运动数据被用作四足机器人的参考轨迹以实现模仿学习, 成功学习了一系列多样化的自然行为。然而, 模仿学习通常效率低下, 有时甚至学不到任何东西。因此, 参考状态初始化和提前终止技术在 [20], 中被提出, 这些技术被发现对实现高动态技能学习至关重要。此外, 在 [10], 中, 提前终止被进一步扩展为时空边界, 一旦任何时空边界被违反, 回合立即终止。模仿学习的另一个问题是, 生成的运动受限于给定的参考。为解决此问题, 在 [20] 中引入了任务奖励, 以允许对学习行为进行调整。在 [21], 中, 设计了一种带有模仿松弛的学习课程, 可以消除非理想参考轨迹的影响, 并挖掘机器人的全部潜力。

行为克隆 (BC)、逆强化学习 (IRL) 和生成对抗模仿学习 (GAIL) 也属于模仿学习 [22]。BC [23] 将策略学习视为一个监督学习问题, 通过匹配教学动作来生成状态-动作轨迹。IRL [24] 旨在通过学习相应的奖励函数来最佳地解释观察到的行为, 并通过马尔可夫决策过程求解与奖励函数更新的迭代循环来学习策略。GAIL [25] 应用生成对抗网络 [26][27] 的思想来模仿专家。它直接从数据中提取策略, 避免了学习奖励函数时的大量计算开销。Baram 等人 [28] 提出了基于模型的生成对抗模仿学习 (MGAIL) 算法, 该算法使用相对较少的专家样本和与环境交互的次数。通过引入前向模型使计算完全可微, 从而能够利用判别器的精确梯度来训练策略。Merel 等人 [29] 扩展了 GAIL, 使其能够训练通用的神经网络策略, 并从有限的示范中生成类人运动模式。Peng 等人 [30][31] 提出了对抗运动先验 (AMP), 该方法结合了对抗模仿学习和无监督学习, 以开发能够产生逼真行为的技能嵌入。无需对运动数据进行特定任务的标注或分割, 模型可以使用包含非结构化运动片段的大型数据集进行训练。Vollenweider 等人 [32] 引入了 multi-AMP, 它扩展了 AMP 的概念, 允许实现多种可离散切换的风格。他们的方法在轮腿式四足机器人的实际实验中得到了验证

，该机器人可在四足与类人构型之间切换。

C. 机器人在线学习

在机器人强化学习的标准范式中，控制器通常先在仿真环境中训练，然后迁移到真实机器人上。源于模型失配、不可预测的环境变化、控制器延迟等因素的仿真到现实差距，使得算法在真实系统中工作面临挑战。因此，研究者提出了多种技术来解决这一问题。

一种解决方案是在算法部署前增强策略在仿真中的鲁棒性。通过引入域随机化，在仿真中环境条件的分布上训练策略，以弥合“现实差距”[33]-[35]。Kumar等人[36]提出了快速运动自适应算法，该算法包含一个自适应模块作为子系统，利用机器人近期状态和动作历史的信息来估计环境配置。Zhuang等人[37]在部署前对策略进行蒸馏。他们对原始渲染深度图像和原始真实世界深度图像均应用预处理技术，以弥合视觉外观上的仿真到现实差距。Tan等人[38]引入了一种分层框架，使用高层学习策略调整底层轨迹生成器，以更好地适应地形。然而，这些算法会生成相对保守的行为，以使策略同时适应仿真和真实世界环境。

另一种解决方案是应用在线学习，即直接在现实世界中进行训练。尽管在线学习已通过机械臂等固定基座机器人上的大量数据训练[39][40]，得到成功验证，但研究人员强调，在一些浮动基座物理系统上进行调优的成本极其高昂，这些系统容易因大量的试错学习而损坏，因此样本效率和安全性问题对于腿式机器人至关重要[41]。Ha等人[42]通过开发一个安全约束强化学习框架来克服安全挑战，该框架限制了机器人躯干的俯仰角和横滚角。此外，每个回合后机器人的重置是在线学习的另一个重要问题。Yang等人[43]采用模型预测控制来处理规划延迟，并将腿部轨迹的先验知识嵌入到动作空间中，从而提出了一种方法，该方法仅需4.5分钟的真实世界数据收集即可为四足机器人学习稳健且快速的步态。Bloesch等人[44]训练一个小型类人机器人仅依靠机载传感器和有限的硬件先验知识来行走并与环境交互。如果机器人在一个回合结束时摔倒，一个稳健的预编程前馈控制器将被唤醒以使其站立。Gupta等人[45]提出了一种免重置方法，通过同时学习多个任务，因为不同的任务组合可以相互执行重置。这种技术避免了频繁的人工干预。Smith等人[46][47]提出了一种系统，通过结合自主数据收集和强化学习来实现在线运动策略微调。

III. 指令学习概念

A. 指令学习框架 指令学习框架

学习过程如图1所示。与传统强化学习中控制动作完全由神经网络决定不同，指令学习的控制动作由两部分组成：一个由神经网络学习的反馈部分，以及一个遵循指令动作的前馈部分。




图1. 指令学习框架。(A) 指令学习的前馈-反馈控制结构。(B) 动作边界示意图。

前馈部分是关于时间的关节角度轨迹，属于先验知识。反馈部分是一个神经网络，它将机器人的状态映射为动作，并通过强化学习进行训练。前馈提供了控制动作的粗略路线和初始猜测，

而反馈则根据奖励对其进行调整，以实现诸如保持平衡和向前移动等给定目标。

由于控制动作是前馈与反馈的结合，两者的影响取决于其幅度。若反馈的幅度远大于前馈，则动作由反馈主导，从而削弱了前馈的指令作用。因此，我们引入了动作边界技术，即在将反馈与前馈相加之前，先将其乘以一个比率。反馈比率决定了动作边界范围，该范围约束了反馈的幅度。通过调整反馈比率，可以指定动作的边界，从而确定动作偏离前馈动作的程度，如图1(B)所示。我们发现，反馈比率对指令学习的学习效率至关重要。借助动作边界技术，动作空间的搜索范围大幅缩小，从而能显著加速训练过程。

B. 与人类学习的关联

图2展示了受人类启发的指令学习过程。一个例子是学习游泳：初学者具备如何按顺序移动四肢的先验知识，但不知道如何根据水中身体状态协调动作。先验知识可视为前馈，而协调则是需要通过与水的互动来学习的反馈。另一个例子是婴儿学习行走。众所周知，当婴儿被竖直抱起且双脚接触坚实表面时，他们能迈出步伐，这被称为“踏步反射”[48]。踏步反射是婴儿发育的重要部分，为几个月后真正迈步做好准备。踏步反射也可视为前馈，即从父母遗传的先验知识，它与后天训练共同作用，帮助婴儿行走。




图2. 指令学习与人类学习的关联。

前馈与反馈在人类大脑中的对应物分别是知识与经验，它们分别与大脑和小脑相关。对于游泳、跳舞、骑自行车、滑雪等各种人类运动技能，我们通常先了解它（通常通过指令），然后通过练习获得经验。同样，指令学习的过程也是从认知到实践。例如，对于一个学习行走的双足机器人，我们可以将踏步运动作为前馈。然而，这对于行走来说还不够，如果将其放在地面上，机器人会摔倒。需要反馈动作来稳定运动，而这正是强化学习部分所做的事情。通过大量的试验和交互，机器人学会了保持平衡，它可以

原地踏步，并且还能以给定速度行走。在这个学习过程中，前馈对于机器人收敛到期望的行走风格非常重要。

与其他强化学习方法相比，指令学习在控制器中引入了一个额外的前馈。因此，我们现在在控制设计中有两个自由度，即奖励和前馈。前馈直接影响控制器，而奖励则通过训练逐步塑造控制器。调整前馈和奖励有助于我们实现不同的目标。例如，前馈可以轻松实现周期性运动、预定义的运动序列或给定的姿态，而奖励则有助于维持平衡和运动协调。

C. 与模仿学习的比较

指令学习和模仿学习都旨在复现某些给定的运动风格，但它们的机制确实非常不同。为了说明这一点，我们在图3中进行了生动的比较。




图3. 模仿学习与指令学习的对比。

模仿学习如同盲人学舞，学习者心中并无舞蹈动作概念（即观测）。它从零开始学习，在完整的动作空间中探索，其动作纯粹由奖励驱动。而指令学习则不同，学习者通过观察教师的动作建立舞蹈概念，随后遵循指令/示范进行学习。它在指令/示范动作周围的缩减动作空间内探索，其动作由奖励和前馈共同驱动。因此，学习机制本身决定了指令学习可以比模仿学习更高效。

IV. 腿部运动的指令学习

为验证指令学习的有效性，我们以双足机器人和四足机器人为例，应用指令学习来学习不同的运动行为。

A. 机器人模型

仿真机器人模型如图4所示。对于双足机器人，我们使用了Ranger Max（之前称为Cornell Tik-Tok [49]）的改进模型。真实的Ranger Max

每条腿只有四个关节。为了增强其能力，我们在仿真模型中增加了髋关节偏航和踝关节翻滚关节。对于四足机器人，我们使用Unitree A1模型。两款机器人的规格如下。

双足机器人：每条腿有6个主动关节。各关节的运动范围（以图4位置为零点）为（单位：度）：髋关节偏航 -30~30，髋关节翻滚 -30~30，髋关节俯仰 -60~120，膝关节俯仰 -170~10，踝关节翻滚 -30~30，踝关节俯仰 -60~60。最大关节力为200牛米。关节位置控制回路的刚度为2000，阻尼为100。

四足机器人：每条腿有3个主动关节。各关节的运动范围（以图4位置为零点）为（单位：度）：髋关节翻滚 -46~46，髋关节俯仰 -90~210，膝关节俯仰 -94.5~7.5。最大关节力为33.5牛米。关节位置控制回路的刚度为180，阻尼为8。




图4. 模拟的机器人模型。左：Ranger Max；右：Unitree A1。

B. 前馈设计

前馈是每个关节的位置参考轨迹。为简单起见，我们考虑两种常用的轨迹。

第一种是周期轨迹，其中关节以固定周期循环运动。在这种情况下，参考角度被设计为正弦信号

$$\theta_t^{ref} = \theta_0 + \Delta\theta \frac{1 - \cos(2\pi t / T)}{2} \quad (1)$$

第二种是关节从point-to-point移动到另一个位置的轨迹。在这种情况下，参考角度被设计为斜坡信号

$$\theta_t^{ref} = \theta_0 + \Delta\theta \frac{t}{T} \quad (2)$$

前馈通过将参考角度映射到brain来实现：

$$a_{ff} = 2 \frac{\theta_t^{ref} - \theta_{min}}{\theta_{max} - \theta_{min}} - 1 \quad (3)$$

其中 θ_0 是关节的参考角度，分别代表关节运动范围的下限和上限。

对于腿部运动而言，一个重要的特征是足部会周期性地上下摆动。因此，我们决定将足部摆动运动用作前馈。对于腿式机器人，通过使用不同的足部摆动序列和摆动轨迹，可以轻松学习各种步态。在本文中，我们探讨多种步态，包括双足行走、平地行走、正步

行走、单脚跳和跳跃，以及四足小跑、踱步、弹跳和腾跃。每种步态的详细前馈动作可在附带的视频中找到。对于大多数步态，我们仅使用正弦轨迹（1）来生成前馈。仅对于双足行军行走和双足单脚跳，我们结合了正弦轨迹（1）和斜坡轨迹（2）来设计前馈。

C. 学习设置

● 超参数

我们使用PPO进行强化学习。超参数为：批量大小 2048，缓冲区大小 20480，学习率 0.0003，beta 0.005，epsilon 0.2，lambda 0.95，训练轮数 3。

● 神经网络

该神经网络采用演员-评论家结构，其中演员网络是一个多层感知机（MLP），包含3个隐藏层，每层512个隐藏单元；评论家网络是一个MLP，包含2个隐藏层，每层128个隐藏单元。演员网络的输出被裁剪至-1~1。

● 观测

观测包括

$$o_t = [q_t \ \omega_t \ v_t \ \theta_t \ \dot{\theta}_t]^T \quad (4)$$

当应用RO时，观测包括

$$o_t = [q_t \ \omega_t \ v_t \ \theta_t \ \dot{\theta}_t \ \theta_t^{ref}]^T \quad (5)$$

其中 q_t 通过四元数表示，包含4个变量； ω_t 分别为机体坐标系下的机体角速度和机体线速度，各包含3个变量。分别为关节角度、关节角速度和关节参考角度，各包含12个变量（适用于双足机器人和四足机器人）。
参考ttt

● 动作

为增强动作的平滑性，将演员网络的输出通过一个低通滤波器，得到反馈动作。记演员网络的原始输出为，则反馈动作由下式得到

$$a_{fb} = 0.9a_{fb}^{last} + 0.1a_{nn} \quad (6)$$

其中 a_{fb} 是在上一时间步的值，然后，反馈动作以为权重加权，并与前馈相加，得到控制动作

$$a_t = a_{ff} + k_b a_{fb} \quad (7)$$

控制动作应处于范围 -1~1 内。

由于 a_{ff} 均位于 -1~1 范围内，我们选择在 0~2 内。然而，所获得的值可能超出 -1~1 的范围。因此，我们对其进行裁剪以计算指令关节角度

$$\theta_t^{cmd} = \theta_{min} + \frac{\text{sat}(a_t) + 1}{2} (\theta_{max} - \theta_{min}) \quad (8)$$

其中 sat 表示线性饱和函数。指令角度 θ_t^{cmd} 被发送到每个关节的位置控制环。

D. 奖励设计

由于采用了前馈，无需繁琐的奖励设计。事实上，我们发现一个简单的奖励就足以通过指令学习生成各种自然的步态。我们将奖励设计为多个组件的组合。每个组件的说明如下：

1) 模仿奖励 被设计为 (角度单位: 度)，用于鼓励关节跟踪参考值 θ_i^{ref} 。

$$r_{imit} = - \sum_i |\theta_i - \theta_i^{ref}|$$

2) 存活奖励 被设计为 r_{surv} 。机器人每个时间步因未摔倒而获得此奖励。

3) 平衡奖励 被设计为 (角度单位: 度)，用于鼓励保持身体直立。

4) 对于速度奖励，我们提供三种选项

- $r_v^{step} = -|v_{forward}| - |v_{lateral}| - |v_{vertical}|$

- $r_v^{walk} = v_{forward} - |v_{lateral}| - |v_{vertical}|$

- $r_v^{jump} = v_{forward} - |v_{lateral}| + |v_{vertical}|$

其中第一种鼓励机器人保持静止；第二种鼓励向前移动；第三种鼓励向前移动的同时上下运动。

5) 同步奖励 被设计为 (角度单位: 度)，用于鼓励双足机器人同步两条腿的运动 (表示髋关节、膝关节和踝关节的相对角度)。

$$\theta_i$$

上述奖励的组合可用于生成不同的步态。表1列出了我们针对一些常见步态所应用的奖励。

表1. 奖励设计。

步态	奖励
踏步 (四足与双足机器人)	$r_{imit} = - \sum_i \theta_i - \theta_i^{ref} $
双足机器人: 行走、平地行走、正步走	$r_{imit} = - \sum_i \theta_i - \theta_i^{ref} + r_{surv} + r_{bal}$
四足: 小跑、踱步、跳跃	$r_{imit} = - \sum_i \theta_i - \theta_i^{ref} + r_{surv} + r_{bal} + r_v^{walk}$
双足机器人: 单脚跳	$r_{imit} = - \sum_i \theta_i - \theta_i^{ref} + r_{surv} + r_{bal} + r_v^{jump}$
四足: 蹦蹦跳	$r_{imit} = - \sum_i \theta_i - \theta_i^{ref} + r_{surv} + r_{bal} + r_v^{jump}$
双足机器人: 跳	$r_{imit} = - \sum_i \theta_i - \theta_i^{ref} + r_{surv} + r_{bal} + r_v^{jump}$

备注：从表1可以看出，只有踏步运动采用了模仿奖励。指令学习实际上并不需要模仿奖励来学习运动技能。对于踏步运动，我们添加模仿奖励只是为了与模仿学习进行公平比较。移除模仿奖励不会影响指令学习对踏步运动的学习。

终止条件：如果机器人“摔倒” (或) 或时间步达到 1000，则结束训练。

V. 仿真结果

我们使用Unity ML-Agents进行仿真，该工具采用了Physix引擎。每个动作的时间步为0.01秒，对应控制频率为100 Hz。训练在CPU上运行。为加速训练，我们使用12个智能体副本进行并行训练。根据经验，完成1万步训练通常需要约10秒。

A. 步态运动学习 我们首先测试踏步运

动学习。目标是让机器人学会原地踏步并保持平衡。前馈是一个周期性踏步运动 (当机器人被悬挂时，每条腿会上下摆动，但放在地面上时会摔倒)。

● 指令学习与模仿学习对比

我们比较了四种学习方法：模仿学习 (IML)、带观测参考的模仿学习 (IML-RO)、指令学习 (INL) 以及带观测参考的指令学习 (INL-RO)。对于 IML 和 IML-RO，动作是 θ_i^{ref} 。对于 INL 和 INL-RO，动作是 θ_i^{ref} 。为了公平比较^{0.5}，我们对所有方法使用相同的奖励 (包含模仿奖励，参见表1)。奖励曲线如图5 (双足机器人) 和图6 (四足机器人) 所示。

从这两张图中，我们得到以下观察结果：

1) 对于指令学习，RO的影响可以忽略不计，因为可以看到INL和INL-RO的学习曲线几乎相同。这可能是因为参考已经通过前馈进入控制器，因此无需在观测中添加参考。

2) RO 对模仿学习至关重要。没有 RO，模仿学习几乎无法学习踏步运动，可以看到 IML 的奖励收敛到了一个更小的值 (机器人实际上学会了静止站立)。

3) 即使应用了RO，指令学习也比模仿学习高效得多。对比INL与IML-RO的结果可以看出，在初始学习过程中，INL花费更少的时间步就能达到相同的奖励，尤其是对于四足机器人而言。这表明了指令学习的高效性。此外，即使在后期学习阶段，INL仍能保持更高的奖励。




图5. 双足行走的奖励曲线。




图6. 四足行走的奖励曲线。




图7. 不同条件下的双足行走奖励曲线

k_b .

● 动作边界范围的影响

为了探究动作边界范围的影响，我们以双足机器人为例，选取不同的数值。学习结果如图7所示。可以看出，动作边界范围对学习性能有显著影响。如果范围过大（参见

$b = 1.2$.

l_r

和），则前馈的引导作用会大幅降低，学习速度明显变慢。如果范围过小（参见和），学习初期速度较快，但最终收敛到较低的奖励值。这种现象是因为动作范围过小，无法确保良好的参考跟踪，从而导致模仿奖励较低。当范围选择适当时（参见和），学习速度快，且奖励收敛到较高值。

B. 运动学习

在之前的步态运动学习中，我们采用了模仿奖励。模仿奖励的作用是鼓励机器人跟随参考轨迹。对于模仿学习而言，模仿奖励对于正确学习参考动作是不可或缺且至关重要的。然而，对于指令学习，参考动作直接用于前馈动作中，因此无需模仿奖励。事实上，移除模仿奖励有许多好处。首先，精确跟踪轨迹很困难，这会耗费训练时间并降低学习效率。其次，模仿奖励会约束动作。移除模仿奖励可以更好地释放机器人的潜力，使其能够实现其他目标，而不仅仅是跟随参考轨迹。

因此，在接下来的运动学习任务中，我们不再使用模仿奖励或RO。使用与踏步运动相同的前馈，只需改变速度奖励（详见表I）即可轻松实现运动。结果，双足机器人学会了行走，四足机器人学会了小跑。此外，通过重新组织前馈信号，机器人可以轻松学习其他步态。对于双足机器人，我们展示了行走、平地行走、正步行走、跳跃和单脚跳的学习。对于四足机器人，我们展示了小跑、踱步、弹跳和腾跃的学习。图8和图9展示了奖励曲线，我们仅对双足机器人训练了100万步，对四足机器人训练了300万步，这足以学习所有期望的步态。这表明指令学习效率极高。所得步态的截图分别如图10和图11所示。

结果也验证了指令学习的通用性。通过使用不同的前馈信号，机器人能够以简单（甚至相同）的奖励学习多样化的运动任务。此外，与模仿学习相比，指令学习中的参考信号可以简单得多，它仅粗略表征运动风格，无需非常精确，因此可以手动设计，而无需使用动作捕捉数据。




图8. 双足运动的奖励曲线。




图9. 四足运动的奖励曲线。








图10. 双足机器人学习到的运动行为。




(A) 小跑



(B) 踱步



(C) 跳跃



(D) 蹦跳

图11. 四足机器人学习到的运动行为。

C. 运动适应

除了卓越的学习效率外，指令学习的另一个优势在于其灵活性。对于传统强化学习而言，由于神经网络权重无法手动调整，若要调整已习得的运动，唯一方法是重新训练神经网络。但指令学习则不同，其前馈信号可在训练后直接调整，因此我们可以便捷地调整已习得的运动。经测试，当在一定范围内修改前馈信号时，已习得的运动仍能保持稳定。

为了说明这一点，我们以前馈的周期和振幅（对应于行走时的步态周期和步高）为例。当某个步态的训练完成后，我们逐步改变前馈的周期或振幅（独立调整），直到步态无法维持（机器人摔倒或无法前进），然后记录适应范围，如图12所示。可以看出，所有步态都存在一个可行范围。适应范围最低可至0.2，最高可达4。对于某些步态，如双足行军行走、跳跃和单脚跳，其适应范围相比其他步态更小，这可能是因为这些步态更不稳定。

指令学习的运动适应特性非常实用，使我们能够直接调整已习得的运动，从而省去重新训练的时间。这种适应能力也与人类技能学习相似。一旦我们掌握了一项运动技能，就能轻松掌握其变体。例如，我们可以改变步态频率和步态离地高度。

无需重新学习即可轻松实现。




图12. 学习到的运动对修改后前馈的适应范围。

VI. 实验结果

为了验证指令学习在实际系统中的有效性，我们在真实四足机器人上进行了仿真到现实迁移和在线学习实验。与之前的仿真相比，我们对观测做了一些细微调整。首先，我们从观测中移除了身体速度，因为它不够精确。其次，观测中的身体朝向四元数被替换为身体俯仰角和横滚角，以确保机器人在面对不同方向时的一致性。

A. 仿真到现实迁移

我们有两个小组负责仿真到现实迁移工作。一组使用Raisim软件和宇树A1机器人，另一组使用IsaacGym软件和宇树Go1机器人。



图13. A1机器人不同步态展示。从左至右：小跑、踱步、跳跃、蹦跳。




图14. GO1机器人鲁棒行走。

第一组专注于实现四类步态。我们首先尝试将学习到的策略直接迁移到真实机器人上，但由于仿真到现实差距，机器人无法保持平衡。随后，我们在训练过程中向机器人添加随机扰动，

这实现了成功迁移，但运动不够鲁棒（见图13及视频）。第二组专注于指令跟随与鲁棒行走。我们在观测和奖励中加入了身体前向速度指令和偏航速度指令，并在训练中的应用域随机化。最终，机器人能够跟随给定的速度指令，并在受到扰动时保持平衡（见图14及视频）。它还能在一定范围内适应前馈修改。

B. 在线学习

由于学习效率高，指令学习非常适合真实机器人的在线学习。在线学习从真实机器人收集数据并实时更新控制策略，因此不存在仿真到现实的问题。然而，与在仿真中学习相比，在线学习无法加速或并行训练，因此特别需要高效的学习。此外，当机器人摔倒时，在线学习中的重置操作也很麻烦。指令学习凭借其高效率和缩小的动作空间（可防止机器人摔倒），能够处理这两个问题。

回顾之前图9中的仿真结果，四足机器人可以在一百万步（时间步长0.01秒）内学习各种步态，这相当于现实时间中的2.78小时。这大约相当于一次充电的电池续航时间，是可以接受的。然而，当反馈比率为0.5时，机器人很容易摔倒。此外，随着机器人行走速度越来越快，我们需要足够大的场地来进行实验。因此，我们决定使用较小的反馈比率并缩短训练时间。

我们以小跑步态为例。机器人从原地踏步运动开始，学习转向或向前行走。每次实验前，我们首先尝试更逼真的仿真以确保可行性。仿真中取消了重置，奖励仅使用与真实机器人相同的可用数据。仿真通过后，我们将在线学习应用于真实机器人。实验场景如图15所示。

在训练过程中，机器人通过间歇性回合进行学习。每个回合大约持续5.5秒，包含三个阶段：1) 机器人行走约3.3秒；2) PPO更新；3) 机器人执行若干步以恢复至初始状态。两项在线学习任务各需约20分钟完成训练。训练期间机器人不会摔倒，仅在必要时需重新调整其位置。两次在线学习实验的奖励曲线如图16所示。



图15. 在线学习场景。




图16. 在线学习的奖励曲线。

对于转向任务，从惯性测量单元获取的机器人偏航角速度被用作奖励。为保证快速学习，我们对髋关节滚动关节应用0.15的反馈比率，对其他关节则应用0。从视频中可以看出，机器人起初有向右转的趋势，但最终成功学会了向左转。

对于向前行走任务，髋关节滚动关节的反馈比率为0，其他关节的反馈比率为0.07。该任务的一个问题是，奖励需要知道机器人的线速度，但无法直接获取。我们尝试使用卡尔曼滤波器来估计速度，该滤波器融合了加速度读数、编码器读数和接触信息，但估计性能较差

（尤其是当速度较小时），这降低了学习性能。因此，我们放弃在奖励中使用速度，转而使用腿部的角速度。我们将腿部角度定义为（分别表示髋关节俯仰角和膝关节俯仰角），即机器人身体与连接脚和髋关节的虚拟腿之间的俯仰角。然后，腿部角速度计算为两个时间步之间的腿部角度差。然后，奖励设计为，其中表示两条支撑腿的角速度，表示两条摆动腿的角速度。使用此奖励，机器人在20分钟内成功学会了向前行走。

$$\begin{aligned} & \text{腿部} \\ & \begin{matrix} 1 & 2 & 1 & 2 \\ \text{sp} & \text{sp} & \text{sw} & \text{sw} \end{matrix} \quad \mathbf{r} \\ & = \omega + \omega - \omega - \omega \end{aligned} \quad \begin{matrix} 1 & 2 \\ \text{sp} & \text{sw} \end{matrix} \quad \begin{matrix} 1 & 2 \\ \text{sp} & \text{sw} \end{matrix}$$

VII. 结论

本文提出了一种名为指令学习的新型强化学习框架，用于机器人运动技能学习，并通过一系列运动学习实例验证了其有效性。指令学习的关键组成部分包括前馈-反馈学习结构、动作边界技术以及模仿奖励消除思想，这些特点使其区别于模仿学习，并且是实现高效灵活学习的关键。前馈与反馈构成了一个知识与数据双驱动学习系统。

前馈是知识驱动的，可以立即修改；反馈是数据驱动的，需要逐步学习。指令学习的训练过程类似于人类练习，是一个从知道到做到的过程。动作边界技术将动作搜索范围约束在前馈动作周围的缩减空间中，从而使指令学习具有高效率。此外，指令学习使用简单的奖励并去除了模仿奖励。它试图通过遵循指令而非精确跟随参考轨迹来学习运动技能，这赋予了指令学习高度的灵活性。最后，指令学习还表现出良好的自适应性，即学习到的行为能够适应一组经过修改的前馈信号。

指令学习与人类学习有许多相似之处，这为我们观察人类的运动技能学习机制提供了一个有趣的视角。指令学习易于理解和实现，为高效的运动学习提供了宝贵的框架，并且在现实世界的机器人学习中具有巨大潜力。需要指出的是，我们并未特别关注提高控制器的鲁棒性，因此目前通过指令学习获得的行为不如最先进的学习控制器稳定。然而，指令学习可以与其他仿真到现实方法相结合，以增强所学控制器的鲁棒性，这对于更复杂的现实应用是必要的。

致谢

感谢Andy Ruina教授富有洞察力的讨论。感谢上海大学国家级实验工程训练教育示范中心提供的实验设施。

参考文献

- [1] J. Hwangbo, J. Lee, A. Dosovitskiy, 等, "Learning agile and dynamic motor skills for legged robots," *Science Robotics*, 第4卷, 第26期, 第eaau5872页, 2019.[2] J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun 和 M. Hutter, "Learning quadrupedal locomotion over challenging terrain," *Science Robotics*, 第5卷, 第47期, 第eabc5986页, 2020.[3] A. Loquercio, E. Kaufmann, R. Ranftl, M. Müller, V. Koltun 和 D. Scaramuzza, "Learning high-speed flight in the wild," *Science Robotics*, 第6卷, 第59期, 第eabg5810页, 2021.[4] O. M. Andrychowicz, B. Baker, M. Chociej, 等, "Learning dexterous in-hand manipulation," *The International Journal of Robotics Research*, 第39卷, 第1期, 第3-20页, 2020.[5] T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, 等, "Continuous control with deep reinforcement learning," 2015, arXiv预印本 arXiv:1509.02971.[6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, 和 O. Klimov, "Proximal policy optimization algorithms," 2017, arXiv预印本 arXiv:1707.06347.[7] T. Haarnoja, A. Zhou, P. Abbeel, 和 S. Levine, "Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor," 2018, arXiv预印本 arXiv:1801.01290.[8] N. Heess, D. TB, S. Sriram, 等, "Emergence of locomotion behaviours in rich environments," 2017, arXiv预印本 arXiv:1707.02286.[9] X. B. Peng, E. Coumans, T. Zhang, T. W. Lee, J. Tan 和 S. Levine, "Learning agile robotic locomotion skills by imitating animals," 2020, arXiv预印本 arXiv:2004.00784.

- [10] L. K. Ma, Z. Yang, X. Tong, B. Guo 和 K. Yin, “Learning and exploring motor skills with spacetime bounds,” 计算机图形学论坛, 第40卷, 第2期, 第251-263页, 2021.[11] H. Duan, J. Dao, K. Green, T. Apgar, A. Fern 和 J. Hurst, “Learning Task Space Actions for Bipedal Locomotion,” 收录于 2021年IEEE国际机器人与自动化大会 (ICRA), 中国西安, 2021, 第1276-1282页.[12] J. Siekmann, Y. Godse, A. Fern 和 J. Hurst, “Sim-to-Real Learning of All Common Bipedal Gaits via Periodic Reward Composition,” 收录于 2021年IEEE国际机器人与自动化大会 (ICRA) 中国西安, 2021, 第7309-7315页.[13] G. Ji, J. Mun, H. Kim 和 J. Hwangbo, “Concurrent Training of a Control Policy and a State Estimator for Dynamic and Robust Legged Locomotion,” IEEE机器人与自动化快报, 第7卷, 第2期, 第4630-4637页, 2022年4月, doi: 10.1109/LRA.2022.3151396.[14] G. B. Margolis, G. Yang, K. Paigwar, T. Chen, P. Agrawal, “Rapid locomotion via reinforcement learning,” 2022, arXiv预印本 arXiv:2205.02824.[15] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun, M. Hutter, “Learning robust perceptive locomotion for quadrupedal robots in the wild,” Science Robotics, 第7卷, 第62期, 第eabk2822页, 2022.[16] G. B. Margolis 和 P. Agrawal, “Walk These Ways: Tuning Robot Control for Generalization with Multiplicity of Behavior,” 收录于 第六届机器人学习会议论文集, PMLR, 2023, 第22-31页.[17] Y. Kim 等, “Not Only Rewards But Also Constraints: Applications on Legged Robot Locomotion,” 2023, arXiv预印本 arXiv:2308.12517.[18] N. Rudin, D. Hoeller, P. Reist, M. Hutter, “Learning to walk in minutes using massively parallel deep reinforcement learning,” 收录于 机器人学习会议. PMLR, 2022, 第91-100页.[19] V. Makoviychuk, L. Wawrzyniak, Y. Guo, 等, “Isaac gym: High performance gpu-based physics simulation for robot learning,” 2021, arXiv预印本 arXiv:2108.10470.[20] X. B. Peng, P. Abbeel, S. Levine 和 M. Van de Panne, “Deepmimic: Example-guided deep reinforcement learning of physics-based character skills,” ACM图形学汇刊 (TOG), 第37卷, 第4期, 第1-14页, 2018.[21] Y. Jin, X. Liu, Y. Shao, H. Wang, 和 W. Yang, “High-speed quadrupedal locomotion by imitation-relaxation reinforcement learning,” 自然机器智能, 第4卷, 第12期, 第1198-1208页, 2023.[22] J. Hua, L. Zeng, G. Li 和 Z. Ju, “Learning for a robot: Deep reinforcement learning, imitation learning, transfer learning,” 传感器, 第21卷, 第4期, 第1278页, 2021.[23] F. Torabi, G. Warnell, P. Stone, “Behavioral cloning from observation,” 2018, arXiv预印本 arXiv:1805.01954.[24] S. Arora 和 P. Doshi, “A survey of inverse reinforcement learning: Challenges, methods and progress,” 人工智能, 第297卷, 第103500页, 2021.[25] J. Ho 和 S. Ermon, “Generative adversarial imitation learning,” 神经信息处理系统进展, 第29卷, 2016.[26] I. Goodfellow, J. Pouget-Abadie, M. Mirza, 等, “Generative adversarial nets,” 神经信息处理系统进展, 第27卷, 2014.[27] A. Creswell, T. White, V. Dumoulin, K. Arulkumaran, B. Sengupta 和 A. A. Bharath, “Generative adversarial networks: An overview,” IEEE信号处理杂志, 第35卷, 第1期, 第53-65页, 2018, doi: 10.1109/MSP.2017.2765202.[28] N. Baram, O. Anschel, I. Caspi 和 S. Mannor, “End-to-end differentiable adversarial imitation learning,” 收录于 国际机器学习大会. PMLR, 2017, 第390-399页.[29] J. Merel, Y. Tassa, D. TB, 等, “Learning human behaviors from motion capture by adversarial imitation,” 2017, arXiv预印本 arXiv:1707.02201.[30] X. B. Peng, Z. Ma, P. Abbeel, S. Levine 和 A. Kanazawa, “Amp: Adversarial motion priors for stylized physics-based character control,” ACM图形学汇刊 (ToG), 第40卷, 第4期, 第1-20页, 2021.[31] X. B. Peng, Y. Guo, L. Halper, S. Levine 和 S. Fidler, “Ase: Large-scale reusable adversarial skill embeddings for physically simulated characters,” ACM图形学汇刊 (TOG), 第41卷, 第4期, 第1-17页, 2022.[32] E. Vollenweider, M. Bjelonic, V. Klemm, N. Rudin, J. Lee 和 M. Hutter, “Advanced skills through multiple adversarial motion priors in reinforcement learning,” 载于2023年IEEE国际机器人与自动化大会 (ICRA), 2023年, 第5120-5126页.[33] X. B. Peng, M. Andrychowicz, W. Zaremba, 和 P. Abbeel, “基于动力学随机化的机器人控制仿真到现实迁移,” 载于2018年IEEE国际机器人与自动化大会 (ICRA), 2018年, 第3803-3810页.[34] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, 和 P. Abbeel, “用于将深度神经网络从仿真迁移到现实世界的域随机化,” 载于IEEE/RSJ国际智能机器人与系统大会 (IROS), 2017年, 第23-30页.[35] Q. Vuong, S. Vikram, H. Su, S. Gao, 和 H. I. Christensen, “如何为强化学习策略的仿真到现实迁移选择域随机化参数?” 2019年, arXiv预印本 arXiv:1903.11774.[36] A. Kumar, Z. Fu, D. Pathak, 和 J. Malik, “RMA: 腿足机器人快速运动适应,” 2021年, arXiv预印本 arXiv:2107.04034.[37] Z. Zhuang 等, “机器人跑酷学习,” 2023年, arXiv预印本 arXiv:2309.05665.[38] W. Tan, X. Fang, W. Zhang, R. Song, T. Chen, Y. Zheng, 和 Y. Li, “基于强化学习的四足运动分层框架,” 载于IEEE/RSJ国际智能机器人与系统大会 (IROS), 2021年, 第8462-8468页.[39] S. Levine, P. Pastor, A. Krizhevsky, J. Ibarz, 和 D. Quillen, “通过深度学习和大规模数据采集学习机器人抓取的手眼协调,” 《国际机器人研究杂志》, 第37卷, 第4-5期, 第421-436页, 2018年.[40] P. Wu, A. Escontrela, D. Hafner, K. Goldberg, 和 P. Abbeel, “DayDreamer: 物理机器人学习的世界模型,” 载于机器人学习会议. PMLR, 2023年, 第2226-2240页.[41] T. Haarnoja, S. Ha, A. Zhou, J. Tan, G. Tucker, 和 S. Levine, “通过深度强化学习学会行走,” 2018年, arXiv预印本 arXiv:1812.11103.[42] S. Ha, P. Xu, Z. Tan, S. Levine, 和 J. Tan, “以最少人力在现实世界中学会行走,” 2020年, arXiv预印本 arXiv:2002.08550.[43] Y. Yang, K. Caluwaerts, A. Iscen, T. Zhang, J. Tan, 和 V. Sindhwani, “腿足机器人的数据高效强化学习,” 载于机器人学习会议. PMLR, 2020年, 第1-10页.[44] M. Bloesch 等, “迈向真实环境中的机器人学习: 双足运动案例研究,” 载于机器人学习会议. PMLR, 2022年, 第1502-1511页.[45] A. Gupta 等, “基于多任务学习的免重置强化学习: 无需人工干预学习灵巧操作行为,” 载于2021年IEEE国际机器人与自动化大会 (ICRA), 2021年, 第6664-6671页.[46] L. Smith, J. C. Kew, X. Bin Peng, S. Ha, J. Tan, 和 S. Levine, “持续学习的腿足机器人: 在现实世界中微调运动策略,” 载于2022年国际机器人与自动化大会 (ICRA), 2022年5月, 第1593-1599页.[47] L. Smith, I. Kostrikov, 和 S. Levine, “公园漫步: 基于无模型强化学习在20分钟内学会行走,” 2022年, arXiv预印本 arXiv:2208.07860.[48] K. E. Adolph 和 J. M. Franchak, “运动行为的发展,” 威利跨学科评论: 认知科学, 第8卷, 第1-2期, 第e1430页, 2017年.[49] A. Ruina, 2019年1月14日, “高效、稳健且敏捷的开源腿足机器人进行中,” https://ruina.tam.cornell.edu/research/topics/locomotion_and_robotics/Tik-Tok/index.html (访问日期: 2023年8月16日)