

EFGCL: 通过保护启发的外力引导课程学习实现动态运动学习

Keita Yoneda¹, Kento Kawaharazuka^{1,2}, Kei Okada¹

摘要— 通过强化学习 (RL) 学习腿式机器人的动态全身运动仍然具有挑战性, 因为高失败风险使得高效探索变得困难, 并常常导致学习过程不稳定。

在本文中, 我们提出了外力引导课程学习 (EFGCL), 这是一种基于物理引导原理的引导式强化学习方法, 在训练过程中引入外部辅助力。受竞技体操中保护的启发, EFGCL使智能体能够物理体验成功的运动执行, 而无需依赖特定任务的奖励塑形或参考轨迹。

在四足机器人执行跳跃、后空翻和侧空翻任务的实验中, EFGCL将跳跃任务的学习速度提升了约两倍, 并能够习得传统强化学习方法无法学习的复杂全身运动。我们进一步展示了学习到的策略可以部署到真实机器人上, 复现出与仿真中观察到的运动一致的行为。

这些结果表明, 物理引导探索能够让智能体在训练早期体验成功, 是提高动态全身运动任务学习效率的一种有效且通用的策略。

I. 引言

为了在非结构化环境中实现高水平的运动性能, 四足机器人需要能够稳定获取各种多样且复杂的运动技能的学习方法。随着强化学习 (RL) 的最新进展, 已经提出了许多方法, 使得能够稳健地学习个体行为, 例如在崎岖地形上的运动 [1]–[5]。

对于崎岖地形运动和障碍穿越等任务, 具有高成功率的学习方法已经建立。相比之下, 学习涉及高加速度和高能量的动态运动技能, 如体育动作 [6], 仍然需要大量的任务特定调优。这一困难源于高失败风险的运动本质上难以探索, 且在没有明确指导的情况下, 学习很少取得进展。

为了解决此类动态运动的学习问题, 引导强化学习 (Guided-RL) 引入了—在学习过程中提供阻力, 已被广泛研究[7]。代表性方法包括基于参考轨迹的模仿学习和奖励塑形, 后者通过精心设计的奖励函数来引导行为。

¹ 作者隶属于东京大学信息科学与技术研究生院机械信息学系, 地址: 日本东京都文京区本乡7-3-1, 邮编113-8656. [yoneda, kawaharazuka, k-okada]@jsk.imi.i.u-tokyo.ac.jp² 该作者隶属于东京大学信息科学与技术研究生院人工智能中心, 日本。




图1. 外力引导课程学习 (EFGCL) 的概念概述。在学习早期阶段施加外部辅助力, 智能体能够以更高的成功率体验运动序列。随着学习的推进, 辅助力以课程方式逐渐减少, 最终使智能体获得无需辅助即可实现目标运动的策略。

模仿学习直接模仿代表目标运动的参考轨迹, 并已越来越多地应用于动态任务 [8]–[10]。然而, 学习到的运动性能在很大程度上取决于参考轨迹的质量。诸如 Opt-Mimic [11], 等通过优化生成轨迹的方法可以提供高质量的参考, 但它们在机器人建模和目标函数设计方面会产生大量成本。另外, 像 WASABI [12] 这样的方法利用通过物理引导机器人获得的演示, 降低了数据收集成本。然而, 此类数据的质量在很大程度上取决于操作员的技能水平, 难以确保稳定性。因此, 参考轨迹的质量与其生成成本之间存在固有的权衡, 仅通过模仿学习实现高性能仍然代价高昂。

奖励塑形旨在通过设计中间奖励来促进探索, 这些中间奖励捕捉了期望行为的关键要素 [13]–[15]。然而, 确定运动的哪些方面应被定义为中间奖励高度依赖于任务且并非易事。此外, 中间奖励可能引入设计者偏差, 从而排除潜在的最优运动序列并降低学习性能 [16]。因此, [16] 建议使用稀疏奖励函数, 并通过奖励之外的设计选择来促进学习。

然而，一个用于高效探索具有高失败风险的动态运动的通用框架尚未建立。

从艺术体操中可以汲取深刻的灵感，其中动态运动是主要目标。在体操训练中，一种称为保护的技术被广泛使用，即教练在运动员练习技能时提供身体支撑 [17]。这种方法通过物理引导辅助探索过程，与仅通过奖励设计来引导行为的传统方法有着根本性的不同。

受此启发，我们提出了外力引导课程学习（EFGCL），将该原理应用于机器人强化学习（图1）。本工作的主要贡献总结如下：

- 我们提出了一种新的动态运动技能习得学习范式，采用通过外力的物理引导，而非通过奖励设计的引导。
- 我们提出了外力引导课程学习（EFGCL），该方法逐步衰减外部辅助力，并证明物理引导显著提高了探索效率。
- 通过在真实四足机器人上的学习实验，我们证明了所提出的方法是有效的，并且可迁移到真实世界环境。

II. 背景

A. 近端策略优化（PPO）

在腿式机器人的强化学习中，近端策略优化（PPO）[18] 因其训练稳定性和易于实现而被广泛使用。PPO通过基于当前策略与先前策略之间的似然比优化裁剪替代目标函数，来约束策略更新的大小，

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}, \quad a_t \sim \pi_{\theta_{\text{old}}}(\cdot | s_t),$$

从而在限制过度策略更新的同时实现稳定学习。这种更新控制对于具有高维动作空间和不稳定动力学的腿式机器人尤为有效，因为它可以防止因策略突变而导致的训练崩溃。

PPO还采用广义优势估计（GAE）[19]来估计优势 A_t 。GAE将优势计算为时间差分（TD）误差的加权和，

$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ ，其中 $\gamma \in [0, 1]$ 是折扣因子。这种公式允许在方差和偏差之间进行权衡。基于估计的 A_t ，PPO沿以下梯度方向更新策略：

$$\nabla_\theta J(\theta) \propto \mathbb{E}_{s_t, a_t \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a_t | s_t) A_t].$$

然而，在高失败风险的环境中，不成功的轨迹往往占主导地位，导致许多状态的估计状态值 $V(s_t)$ 较小。因此，TD误差 δ_t 和优势 A_t 都趋近于零，为基于梯度的更新提供的有用信息很少。

算法1 外力引导课程学习

- 1: **输入**：初始策略 π_{init} ，初始评论家 V_{init} ，辅助力 F_{assist} ，衰减步长 ε ，成功阈值 ζ
- 2: **输出**：最终策略 π_N
- 3: 初始化：

$$F_0 \leftarrow F_{\text{assist}}, \quad \pi_0 \leftarrow \pi_{\text{init}}, \quad V_0 \leftarrow V_{\text{init}}$$

- 4: 设置衰减率：

$$\alpha \leftarrow 1.0$$

- 5: **对于** $i = 0, \dots, N-1$ **执行**

- 6: 成功率 $\leftarrow 0$

- 7: **当** 成功率 $< \zeta$ **时执行**

- 8: 在辅助力 F_i 下，使用 PPO 训练 π_i 和 V_i

- 9: 更新成功率 $\leftarrow$

- 10: **结束循环**

- 11: 衰减辅助力：

$$\alpha \leftarrow \max(0, 1 - \varepsilon \times i), \quad F_{i+1} \leftarrow \alpha \times F_{\text{assist}}$$

- 12: 继承学习到的策略和价值函数：

$$\pi_{i+1} \leftarrow \pi_i, \quad V_{i+1} \leftarrow V_i$$

- 13: **结束循环**

- 14: **返回** π_N

因此，虽然PPO是一种稳定优化方法，但在难以获得成功经验的环境中，学习可能会严重停滞。

B. 课程学习

课程学习已被广泛采用，作为解决上述问题的一种代表性方法。

在课程学习中，训练始于探索风险较低的特化环境，并逐步提高任务难度或风险水平。该框架可被理解为在多个具有不同风险水平的马尔可夫决策过程（MDP）

$\mathcal{M}_i$ 上的序列学习。如果连续阶段之间动态变化和奖励结构的差异足够小，那么阶段 $\mathcal{M}_i$ 的最优策略 π_i^* 与后续阶段 $\mathcal{M}_{i+1}$ 的最优策略 π_{i+1}^* 预计会相似。也就是说，

$$\frac{\pi_{i+1}^*(a_t | s_t)}{\pi_i^*(a_t | s_t)} \approx 1, \quad a_t \sim \pi_i^*(\cdot | s_t),$$

可以被人为构造。这一性质与PPO所依据的假设一致，即较小的策略更新步骤更为可取。因此，课程学习提供了一个理论上高度契合的框架，支持使用PPO进行稳定、渐进的学习。

C. 通过加速价值函数估计稳定学习

在具有稀疏奖励的强化学习中，学习效率在很大程度上取决于价值函数能够多快地正确评估产生高奖励的动作序列。这对于诸如




图2. 用于师生学习的网络架构。(a) 教师策略以全状态（包括特权观测）作为输入，并通过强化学习进行训练。(b) 学生策略仅以机载传感器信息作为输入，并以教师策略作为监督者进行训练。

PPO等方法尤为关键，这些方法依赖价值函数进行优势估计，其中价值估计的初始准确性显著影响策略更新的方向。

一般来说，一旦观察到足够数量的高奖励轨迹，与相关状态序列 $\xi = \{s_t^{\text{high}}\}_{t=0}^N$ 对应的状态值 $V(s)$ 就会被估计为较大值。当存在此类高价值轨迹时，偏离这些轨迹的动作会产生较大的负TD误差和优势值。因此，策略会朝着抑制偏离高奖励轨迹的方向更新，从而使有效的动作序列一旦习得就更有可能被保留。

因此，价值函数能否在学习早期阶段就为近最优行为赋予高价值，是决定整体训练稳定性和效率的关键因素。为了实现这一目标，在学习的早期阶段让智能体接触大量高奖励轨迹是有效的做法。

III. 方法

A. 外力引导课程学习 (EFGCL) 概述

所提出的外力引导课程学习 (EFGCL) 提供了一个框架，可在保持稀疏奖励函数的同时实现动态任务中的稳定学习。与模仿学习或奖励塑形中修改奖励的方式不同，EFGCL通过按课程方式修改执行学习的马尔可夫决策过程 (MDP) 本身来稳定学习。

算法的整体流程总结于算法1中。EFGCL在学习早期阶段设计外部辅助力以促进任务执行（第1行），并随着训练进度逐渐衰减该辅助（第7-9行）。通过这一课程过程，智能体在辅助下经历具有高成功概率的轨迹，同时逐步过渡到自主运动生成。最终，智能体获得策略 π_N ，无需辅助即可实现目标运动（第14行）。




图3. 四足机器人KLEIYN的概述和运动学结构。(a) 整体机器人结构。(b) 每条腿的连杆和关节定义。

B. 外部辅助的设计

EFGCL首先设计有助于复现目标运动的外部辅助力。如第II-C节所述，在学习早期阶段让智能体接触大量高奖励轨迹，会诱导其倾向于保留此类轨迹。EFGCL中的外部辅助旨在人为增加这些成功轨迹的密度。

在EFGCL中，外部辅助被定义为由三个要素组成的模式：作用点 $P = \{\mathbf{p}_i\}$ 、相应的力向量 $F = \{\mathbf{f}_i\}$ 以及施加时机 $T = \{(t_i^{\text{start}}, t_i^{\text{end}})\}$ 。由于辅助的目的不是教授最优轨迹，而是引导智能体朝向高奖励状态，因此机器人只需大致实现目标运动并获得高奖励即可。因此，在本研究中，辅助力 $F_{\text{assist}}(P, F, T)$ 是针对每个任务启发式设计的。此类辅助力的允许范围将在第V-B节中详细研究。

C. 基于成功率的自适应课程调度

如第II-B节所述，课程学习受益于相邻MDP之间较小的难度差距，以确保策略转换的稳定性。EFGCL采用基于成功率的自适应课程，以防止课程更新导致的难度变化过大。

具体而言，如算法1第6-12行所示，在每个阶段重复进行PPO训练，直到成功率超过阈值 ζ 。随后，辅助力更新为

$$F_i = \alpha_i \times F_{\text{assist}}, \quad \alpha_i = \max(0, 1 - \varepsilon \times i).$$

其中 α_i 表示阶段 i 的辅助缩放因子， ε 是控制辅助减少速率的衰减步长。

该机制能够根据训练进度自动调整辅助衰减步长，同时保持关系 $\pi_{i+1}(a | s) / \pi_i(a | s) \approx 1$ 。

D. 观测的时间编码

由于EFGCL中的辅助力 $F_{\text{assist}}(P, F, T)$ 以时间依赖方式施加，智能体将辅助时机推断为内部状态至关重要。

然而，直接将经过时间 t 作为输入会导致单调递增的值，这可能引起神经网络中的尺度不匹配。

为了解决这个问题，我们引入了一个与辅助力的激活区间相一致的额外观测

F_i 。具体来说，我们定义了一个在 $[0, 1]$ 内有界的单调递增函数，即

$$\tau(t, \lambda) = \frac{\tilde{t}^3}{1 + \tilde{t}^3}, \quad \tilde{t} = \frac{t}{\lambda}.$$

此处， λ 是时间缩放参数，在本研究将其设置为力激活起始时间 $\lambda = t_{\text{start}}$ 。




图4. 为每个任务设计的辅助力模式。(a) 跳跃, (b) 后空翻, (c) 侧空翻。辅助力垂直作用于肩胛骨连杆，引导运动，在学习的早期阶段促进成功的任务执行。

IV. 学习设置

A. 机器人平台

真实世界实验使用四足机器人KLEIYN [6]进行。其外观和连杆定义如图3所示。KLEIYN总质量为18kg，高度为600mm，每条腿具有三个自由度（DoF），躯干具有一个自由度。机器人配备了惯性测量单元和关节编码器。腿部电机为准直驱执行器，最大扭矩为24.8Nm，而躯干电机的最大扭矩为48Nm。Isaac Gym [20] 用作训练模拟器。

B. 任务定义与奖励函数

为了评估EFGCL的有效性，我们定义了三个动态全身运动任务：（1）跳跃，（2）后空翻，以及（3）侧空翻。

为了避免因任务特定奖励工程而产生的任意性能提升，所有任务共享完全相同的奖励结构、权重和函数形式。只有目标变量在不同任务间有所不同：跳跃的最大高度，以及后空翻和侧空翻的旋转角度。这些目标变量仅根据其物理单位进行缩放，且不引入任何任务特定奖励调优或中间运动引导奖励。

每个任务的奖励由以下通用结构定义：

$$r_t = \rho_t^{\text{task}} + \rho_t^{\text{task}} \cdot \rho_t^{\text{stand}} + \lambda_{\omega} r_t^{\text{ang}} + r_t^{\text{common}}, \quad (1)$$

其中 $\rho_t^{\text{task}} \in [0, 1]$ 表示任务进度， ρ_t^{stand} 鼓励落地后的稳定姿态， r_t^{ang} 是抑制非目标轴旋转的正则化项，而 r_t^{common} 强制执行所有任务共享的物理约束。

唯一的任务特定差异在于 ρ_t^{task} 中目标量的定义。对于跳跃，目标是达到的最大高度，而对于后空翻和侧空翻，目标分别是围绕俯仰轴和横滚轴的旋转角度。详细定义总结在附录I中。

C. 观测

观测由两个部分组成， $\mathbf{o}_t^{\text{prop}}$ 和 $\mathbf{o}_t^{\text{priv}}$ 。

$\mathbf{o}_t^{\text{prop}}$ 表示本体感觉观测，包括关节位置 $\mathbf{q}_t \in \mathbb{R}^{13}$ 、关节速度 $\dot{\mathbf{q}}_t \in \mathbb{R}^{13}$ 、根坐标系中的重力向量 $\tilde{\mathbf{g}}_t \in \mathbb{R}^3$ 、根角速度 $\boldsymbol{\omega}_t \in \mathbb{R}^3$ 、命令输入 $c \in \mathbb{R}$ 以及时间编码 $\tau(t) \in \mathbb{R}$ 。命令输入对应于跳跃的目标跳跃高度 h^{target} ，以及后空翻和侧空翻的目标旋转角度 θ^{target} 。

$\mathbf{o}_t^{\text{priv}}$ 表示仅由教师策略使用的特权观测，包含以下任务特定信息：

- 跳跃：根高度 $h_t \in \mathbb{R}$ 以及回合开始以来的最大高度 $h_{\text{max}} \in \mathbb{R}$
- 后空翻：根高度 h_t 和根俯仰角 $\theta_{\text{pitch}} \in \mathbb{R}$
- 侧空翻：根高度 h_t 和根横滚角 $\theta_{\text{roll}} \in \mathbb{R}$

D. 辅助力设计

为每个任务设计了辅助力模式。施加时机在所有任务中共享，为 $T = \{(1.0\text{秒至}1.1\text{秒})\}$ ，而施加点 P 和力向量 F 则因任务而异。辅助力模式如图4所示。

a) 跳跃：

$$\begin{aligned} P^{\text{jump}} &= \{\mathbf{p}_{\text{FL}}^{\text{Scapula}}, \mathbf{p}_{\text{FR}}^{\text{Scapula}}, \mathbf{p}_{\text{BL}}^{\text{Scapula}}, \mathbf{p}_{\text{BR}}^{\text{Scapula}}\}, \\ F^{\text{jump}} &= \{(0, 0, f_{\text{jump}}(h^{\text{target}})/4)\} \end{aligned}$$

此处， $f_{\text{jump}}(h^{\text{target}})$ 是由目标高度 h^{target} 决定的辅助力大小。该值通过将跳跃运动建模为简单抛体运动，并计算达到目标高度所需初速度所需的平均辅助力而得。

b) 后空翻：

$$\begin{aligned} P^{\text{backflip}} &= \{\mathbf{p}_{\text{FL}}^{\text{Scapula}}, \mathbf{p}_{\text{FR}}^{\text{Scapula}}\}, \\ F^{\text{backflip}} &= \{(0, 0, 175\text{N})\} \end{aligned}$$

c) 侧空翻：

$$\begin{aligned} P^{\text{lateral}} &= \{\mathbf{p}_{\text{FR}}^{\text{Scapula}}, \mathbf{p}_{\text{BR}}^{\text{Scapula}}\}, \\ F^{\text{lateral}} &= \{(0, 0, 300\text{N})\} \end{aligned}$$

E. 自适应课程设计

采用基于成功率的课程调度策略来衰减辅助力。算法1中的成功率根据以下标准计算。

a) 跳跃：

$$|h_t^{\text{max}} - h^{\text{target}}| < 0.1 \wedge |h_t| < 0.1$$

b) 后空翻、侧空翻：

$$|\theta_t - 2\pi| < 0.3 \wedge |h_t| < 0.1$$

所有任务的成功率阈值设置为 $\zeta = 0.6$ ，衰减步长设置为 $\varepsilon = 0.01$ 。




图5. 有无EFGCL的学习曲线对比。(a) 跳跃, (b) 后空翻, (c) 侧空翻。使用EFGCL时, 学习过程稳定推进, 并在所有任务中收敛到高奖励值。未使用EFGCL时, 跳跃表现出较大的奖励方差, 而后空翻和侧空翻的学习几乎无法推进。

F. 师生学习

马尔可夫性是强化学习环境中的一个关键属性。遵循先前的工作 [2], 我们采用了师生学习架构。

师生学习包括两个阶段: 教师策略的强化学习和学生策略的监督学习, 其中教师策略充当监督者。在监督学习阶段, 学生策略通过最小化动作匹配损失和特权观测上的重建损失进行训练。由于所提出的方法与强化学习相结合, EFGCL仅在教师策略训练期间应用。整体学习结构如图2所示。

V. 实验与结果

A. 学习性能与真实机器人部署

我们将所提出的EFGCL与PPO基线在10个随机种子上进行了比较。如图5所示, EFGCL在所有任务(跳跃、后空翻和侧空翻)中均实现了稳定收敛和高奖励。相比之下, 基线未能学习翻转任务, 并在跳跃任务中表现出高方差。如图6所示, 基线常常导致不自然的姿态, 而EFGCL则获得了自然的动态运动。这一稳定的学习过程得益于自适应课程, 它根据成功率自动调整辅助力衰减(图7)。此外, 通过EFGCL学习到的策略被蒸馏并部署到四足机器人KLEIYN上。如图8所示, 仿真中观察到的动态运动在真实机器人上成功复现了所有三个任务。

B. EFGCL力设计的消融研究

为了评估EFGCL对启发式设计选择的敏感性, 我们在后空翻任务中改变了辅助力的施加点、大小和时机。图9中的结果表明, 学习在广泛的参数范围内具有鲁棒性。即使将力施加到不同的连杆(大腿或小腿)上, 或者大小在合理范围(140–210N)内变化, 也能获得成功的策略。只有在辅助力极端的情况下学习才会失败。

物理上不足(例如100N)或过大(例如250N), 或者施加时机过短(1.0秒




图6. 使用和不使用EFGCL学习到的运动快照。(a–c) 使用EFGCL, (d–f) 不使用EFGCL。使用EFGCL时, 能够获得自然且稳定的运动; 而不使用EFGCL时, 观察到不自然的姿态以及未能实现目标运动的情况。




图7. EFGCL中成功率和辅助力衰减因子的变化。(a) 跳跃任务, (b) 后空翻和侧空翻任务。辅助力的衰减速度根据成功率自动调整。



图8. 在真实四足机器人上复现学习到的运动。(a) 跳跃, (b) 后空翻, (c) 侧空翻。




图9. 辅助力设计的消融研究。(a) 施加点, (b) 力的大小, (c) 施加时机。图例中的星号 (*) 表示主要实验中使用的条件。

至1.05秒)。这些结果表明, 只要辅助大致促进目标运动, 就无需精确调参。

C. 加速评论家价值估计的评估

为验证外部引导加速评论家学习的假设, 我们分析了跳跃任务中的价值估计。图10比较了不同训练阶段下成功参考运动的价值函数输出。使用EFGCL时, 价值估计早在200次迭代时就收敛到了最终分布。相比之下, 基线方法需要超过1000次迭代才能达到相当的




图10. 使用和不使用EFGCL的价值函数估计比较。使用EFGCL时, 价值估计迅速收敛到接近最终价值函数的分布, 展示了加速且稳定的价值估计。

准确度水平, 且表现出更大的方差。这一结果证实, 在训练早期体验成功状态能显著加速价值函数估计。

VI. 讨论

A. 引导式探索的有效性与鲁棒性

实验结果表明, EFGCL通过在训练早期加速价值函数估计, 显著稳定了动态运动技能的学习。与依赖复杂奖励设计或专家数据集的奖励塑形或模仿学习不同, EFGCL通过外力形式的直接物理辅助来引导探索。

此外, 消融研究表明, 所提出的方法对辅助力设计的变化具有高度鲁棒性。只要辅助大致促进目标运动, 无需精确参数调整即可成功学习。这些结果表明, “物理体验成功”的原则为克服动态机器人强化学习中的探索挑战提供了一种通用且经济有效的策略。

B. 局限性与未来工作

本研究聚焦于验证人为使智能体体验成功运动这一原理的有效性。因此, 辅助力是基于任务特定的物理直觉设计的。尽管此类启发式设计足以应对本工作中所考虑的单次动态运动任务, 但对于更复杂和连续的运动, 设计负担可能会增加。

对于舞蹈等连续行为, 保持整体运动结构通常需要基于参考轨迹的学习。在这种情况下, 仅使用所提出的外力框架配合稀疏奖励可能不够, 将其与轨迹跟踪奖励设计或模仿学习相结合可能会更

有效。开发对复杂目标运动仍然有效的辅助力自动优化或生成方法，是未来工作的重要方向。

七、结论

受体操运动中保护动作的启发，我们提出了外力引导课程学习（EFGCL），这是一种通过衰减外力引导探索的强化学习框架。无需依赖复杂的奖励塑形或参考轨迹，EFGCL使四足机器人能够习得跳跃、翻转等标准强化学习方法难以实现的动态全身运动。

通过仿真与真实机器人实验，我们验证了仿真到现实迁移的成功，并表明物理辅助通过让智能体在训练早期体验成功状态，加速了价值函数估计。尽管当前方法依赖于启发式力设计，但结果表明，物理引导代表了一种有前景且通用的引导式探索范式，与基于奖励和基于模仿的方法互补，适用于复杂全身运动的学习。

附录一 奖励定义

表一总结了所有任务共用的奖励项及其定义。此处， P_{col} 表示用于检测与地面碰撞的连杆索引集合。该集合共包含14个连杆：身体、肩胛骨、大腿和小腿，不包括脚。指示函数 δ_t^{term} 在回合因躯干在时间 t 接触地面而终止时取值为1，否则为0。

A. 任务特定目标变量

表II展示了任务进度奖励 ρ_t^{task} 中使用的目标变量 x_t 、目标值 x^{target} 和归一化系数 s_x 的任务特定定义，如表I所示。

表I 所有任务共用的奖励项汇总

奖励项	定义
任务进度	$\rho_t^{\text{task}} \equiv \frac{\exp(-\frac{\ x_t - x^{\text{target}}\ ^2 / s_x^2}{0.01})}{\exp(-\frac{\ x_t - x^{\text{target}}\ ^2 / s_x^2}{0.01}) + \exp(-\frac{\ x_t - x^{\text{target}}\ ^2 / s_x^2}{0.25})}$
站立	
角速度正则化	$r_t^{\text{ang}} = -\ (\omega^{\text{non-target}} - t)^2\ $
碰撞惩罚	$-1.0 \times \sum_{i \in P_{\text{coll}}} (f_{i,z} > 0.1)$
终止惩罚	$-100 \times \delta_t^{\text{term}}$
关节速度惩罚	$-5 \times 10^{-4} \ \dot{\mathbf{q}}_t\ ^2$
关节加速度惩罚	$-1 \times 10^{-7} \ \ddot{\mathbf{q}}_t\ ^2$

参考文献

[1] J. Hwangbo, J. Lee, A. Dosovitskiy, D. Bellicoso, V. Tsounis, V. Koltun和M. Hutter, “学习腿式机器人的敏捷和动态运动技能”, 《科学机器人学》, 第4卷, 第26期, 2019年。[2] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun和M. Hutter, “在野外学习四足机器人的鲁棒感知运动”, 《科学机器人学》, 第7卷, 第62期, 2022年。

表II 任务进度奖励的任务特定实例化。

Task	目标变量 x_t	x^{target}	s_x
Jump	h_t^{max}	h^{target}	0.01
后空翻	θ_t^{pitch}	2π	π^2
侧空翻	θ_t^{roll}	2π	π^2

[3] Z. Zhuang, Z. Fu, J. Wang, C. Atkeson, S. Schwertfeger, C. Finn和H. Zhao, “机器人跑酷学习”, 载于机器人学习会议 (CoRL), 2023年。[4] D. Vogel, R. Baines, J. Church, J. Lotzer, K. Werner和M. Hutter, “四足机器人的稳健爬梯”, 载于2025年IEEE/RSJ智能机器人与系统国际会议 (IROS), 2025年, 第7239–7244页。[5] H. Kim, H. Oh, J. Park, Y. Kim, D. Youm, M. Jung, M. Lee和J. Hwangbo, “复杂离散地形上四足机器人的高速控制与导航”, 《科学机器人学》, 第10卷, 第102期, 第eads6192页, 2025年。[6] K. Yoneda, K. Kawaharazuka, T. Suzuki, T. Hattori和K. Okada, “Kleiny: 一种具有主动腰部、兼具运动与爬墙能力的四足机器人”, 载于2025年IEEE/RSJ智能机器人与系统国际会议 (IROS), 2025年, 第8783–8789页。[7] J. Eßer, N. Bach, C. Jestel, O. Urbann和S. Kerner, “引导强化学习: 面向高效有效的现实世界机器人学的综述与评估 [综述].”, 《IEEE机器人与自动化杂志》, 第30卷, 第2期, 第67–85页, 2022年。[8] X. B. Peng, P. Abbeel, S. Levine和M. Van de Panne, “Deepmimic: 基于物理的角色技能的示例引导深度强化学习”, 《ACM图形学汇刊》 (TOG), 第37卷, 第4期, 第1–14页, 2018年。[9] X. B. Peng, E. Coumans, T. Zhang, T.-W. E. Lee, J. Tan和S. Levine, “通过模仿动物学习敏捷机器人运动技能”, 载于机器人学: 科学与系统, 2020年7月。[10] J. Wu, G. Xin, C. Qi和Y. Xue, “利用对抗性运动先验学习稳健敏捷的腿式运动”, 《IEEE机器人与自动化快报》, 第8卷, 第8期, 第4975–4982页, 2023年。[11] Y. Fuchioka, Z. Xie和M. Van de Panne, “Opt-Mimic: 面向动态四足行为的优化轨迹模仿”, 载于2023年IEEE国际机器人与自动化会议 (ICRA), 2023年, 第5092–5098页。[12] C. Li, M. Vlastelica, S. Blaes, J. Frey, F. Grimmering和G. Martius, “通过对抗性模仿粗糙的部分演示学习敏捷技能”, 载于机器人学习会议。PMLR, 2023年, 第342–352页。[13] S. Devlin和D. Kudenko, “基于势能的奖励塑形用于多智能体系统的理论考量”, 载于第十届国际自主智能体与多智能体系统会议。ACM, 2011年, 第225–232页。[14] V. Atanassov, J. Ding, J. Kober, I. Havoutis和C. Della Santina, “基于课程表的强化学习用于四足跳跃: 一种无参考设计”, 《IEEE机器人与自动化杂志》, 2024年。[15] G. Bellegarda, C. Nguyen和Q. Nguyen, “通过深度强化学习实现稳健四足跳跃”, 《机器人与自主系统》, 第182卷, 第104799页, 2024年。[16] G. Vasan, Y. Wang, F. Shahriar, J. Bergstra, M. Jagersand和A. R. Mahmood, “重新审视目标达成强化学习中的稀疏奖励”, 《强化学习杂志》, 第4卷, 第1854页, 2024年, 第1841页起。[17] S. Sorzano, “触摸保护如何影响体操运动员的技能表现和自信心”, 硕士论文, 特伦特大学 (加拿大), 2023年。[18] J. Schulman, F. Wolski, P. Dhariwal, A. Radford和O. Klimov, “近端策略优化算法”, 2017年。[19] J. Schulman, P. Moritz, S. Levine, M. Jordan和P. Abbeel, “使用广义优势估计的高维连续控制”, 载于国际学习表征会议 (ICLR), 2016年。[20] J. Liang, V. Makoviychuk, A. Handa, N. Chentanez, M. Macklin和D. Fox, “用于分布式强化学习的GPU加速机器人仿真”, 载于机器人学习会议 (CoRL), 2018年。