

发现学习敏捷四足运动的技能切换准则

Wanming Yu
牛津大学牛津机器人研究所
wanming@robots.ox.ac.uk

Fernando Acero伦敦大学
学院计算机科学系
fernando.acero@ucl.ac.uk

Vassil Atanassov牛津大学牛津
机器人研究所
vassilatanassov@robots.ox.ac.uk

Chuanyu YangAmigaga科技有限公司
ycy0char@gmail.com

Ioannis Havoutis牛津
大学机器人研究所
ioannis@robots.ox.ac.uk

Dimitrios Kanoulas
伦敦大学学院计算机科学系
d.kanoulas@ucl.ac.uk

Zhibin Li
伦敦大学学院计算机科学系
alex.li@ucl.ac.uk

摘要

本文开发了一个分层学习与优化框架，能够学习并实现良好协调的多技能运动。学习到的多技能策略能够在跟踪任意定位目标时自动且自然地切换技能，并能迅速从故障中恢复。所提出的框架由深度强化学习过程和优化过程组成。首先，将接触模式纳入奖励项中，以学习不同类型的步态作为独立策略，无需任何其他参考。然后，学习一个高层策略，为各个策略生成权重，以在目标跟踪任务设置中组合多技能运动。技能根据与目标的距离自动且自然地切换。技能切换的适当距离被纳入奖励计算中，用于学习高层策略，并随着学习的进展由外部优化循环更新。我们首先在模拟的Unitree A1四足机器人上展示了在综合任务中成功的多技能运动。我们还将学习到的策略部署到现实世界中，展示了随着目标位置变化的小跑、跳跃、疾驰及其自然转换。此外，学习到的策略能够随时对意外故障做出反应，执行快速恢复，并成功恢复运动。与在现实世界中未能成功转换到疾驰的单一技能离散切换相比，我们提出的方法实现了所有学习到的敏捷技能，且技能转换更平滑、更连续。

关键词：多技能运动；深度强化学习；分层学习与优化；步态转换；技能切换；腿式运动；机器人学习

1 引言

动物进化出了高效的运动策略。模仿这些策略可以提升腿式运动在敏捷性、稳定性和适应性方面的表现（图1）。特别是，动物能够根据任务和环境快速切换运动技能。例如，马会随着速度变化切换不同的步态模式（Hoyt和Taylor，1981）。然而，在腿式机器人上复现多种步态及其动态可行过渡，在机器人学习与控制社区中仍然具有挑战性。此外，从各种故障中恢复的能力对于成功且稳健的实际部署至关重要，但在多技能运动研究中尚未得到充分探索。多技能框架具备在运动过程中从故障中恢复的能力（Yang等，2020），但除了小跑之外，它未能展示更多动态步态。尽管跌倒恢复在先前多项工作中已有研究（Hwangbo等，2019；Castano等，2019），但它是作为单一技能学习的，无法与其他技能结合使用。




图1：四足动物和机器人根据速度增加的需求进行协调与步态转换。(a) 猎豹在速度增加时改变步态。(b) A1 四足机器人使用我们的多技能策略实现跌倒恢复、小跑、跳跃和疾驰技能。

复现步态模式。行为克隆或模仿学习方法已被应用于从参考运动中复现各种步态。参考运动可以从动物运动中捕捉，但其种类可能有限，也可以由模型预测控制器生成（Reske等，2021），这需要领域知识和计算效率。一般来说，这类方法难以扩展到数据集之外，缺乏所学行为的鲁棒性和多样性。已有研究尝试建模或学习参数化控制策略以实现不同风格的行走。相位引导控制器被用于在四足机器人上学习行走、小跑、踱步和跳跃之间的步态转换（Shao等，2021）。单一策略被学习用于控制具有可变摆腿、姿态和速度的各种步态（Margolis和Agrawal，2023）。然而，这类方法需要手工设计控制特定的行为参数，这需要领域知识，且切换步态不够直观。

多技能运动中的生成模型。生成模型的最新进展已实现对四足机器人运动步态的低级控制。变分自编码器已被应用于学习跨运动步态的、关于摆腿高度和长度的解耦二维潜在表示（Mitchell等，2024）。给定所需的步态类型和摆动特性，该方法实现了四足机器人小跑、爬行和踱步的低级控制。此外，扩散模型已展现出通过单一策略实现多技能运动控制的能力，例如小跑、跳跃、踱步、行走和奔跑（Huang等，2024），以及行走、爬行及其转换（O’ Mahoney等，2024）。然而，这些生成模型需要专家演示，其性能依赖于数据集的质量。此外，步态类型是以控制策略的特定输入为条件的。相比之下，我们提出的分层框架覆盖了高级和低级多技能运动控制，能够自主发现步态类型。

已成为实现通用机器人任务和行为的一种有吸引力的方法。预训练的视觉语言模型（VLMs）通常侧重于高级推理和规划，以从一组现有的低级技能中进行选择（Chen等，2024）。然而，某些低级运动技能在实践中可能难以获得。也有若干尝试将预训练的大语言模型（LLMs）应用于通过低级接口（如足底接触模式）实现多种步态（Tang等，2023）。总的来说，这些在机器人应用中的基础模型要么需要精心的提示工程，要么需要大量的机器人数据进行微调。在实践中，某些情况下机器人数据可能难以获取，而大规模模型的微调可能需要大量的计算资源。

仿生多步态运动。与上述需要参考运动的方法不同，已有机器人研究应用深度强化学习方法来获取基于生物原理启发的各种标准的动物样步态转换，这些方法不需要参考运动。通过最小化能量消耗，机器人可以使用单一策略（Liang等人，2024）或层级结构（Yang等人，2022）在不同速度范围内实现行走、小跑和飞小跑之间的步态转换，以及从行走到小跑再到弹跳的步态转换（Fu等人，2021）。另一项仿生研究根据弗劳德数调节步态转换（Humphreys等人，2023）。最近的一项工作学习了在平坦地面上从行走到小跑的步态转换，以及根据可行性在跨越间隙时从小跑到跳跃的转换（Shafiee等人，2024）。然而，在上述框架中，疾驰无法在机械机器人上以高速出现或被纳入。此外，一系列工作利用中枢模式发生器（CPGs）通过深度强化学习在四足机器人上产生不同的步态。最近的工作采用了一种耦合驱动方法，通过深度强化学习来学习策略以调节中枢模式发生器（CPGs）的参数，其中根据运输成本（CoT）产生了包括疾驰在内的九种步态及其转换（Bellegarda等人，2024）。与仿生多步态运动相比，我们提出的框架能够产生疾驰步态。此外，我们的方法不受生物原理的约束，因为我们可以定义自定义成本项来优化步态切换时机。除了生物启发的标准外，我们还可以包含其他成本项，例如任务相关成本。

最先进的四足运动。一条平行的研究路线在腿式机器人上展示了令人印象深刻的动态跑酷技能（Caluwaerts 等人，2023；Cheng 等人，2024；Zhuang 等人，2023；He 等人，2024）。然而，这些工作通常侧重于引导机器人穿越一系列具有挑战性的地形和障碍物。在大多数情况下，这些导航任务中考虑的是简单的目标到达任务，而步态模式则未被纳入考量。相比之下，本文聚焦于多技能导航和控制任务，即使用各种步态模式及其转换到达任意目标。

贡献。总而言之，我们提出的方法相较于现有文献的优势包括：（1）我们不需要参考轨迹或专家演示，可以纯粹从零开始学习多技能运动；（2）类动物疾驰步态可以在高速运动时被激活；（3）多技能策略中融入了自主跌倒恢复，从而实现了高鲁棒性并减少了人工干预；（4）为机械机器人自动发现了灵活的步态切换准则。据我们所知，我们的工作为首个多技能学习与优化框架，能够兼容并整合多种高动态运动步态（尤其是疾驰），并通过自动发现的步态切换准则产生自然、动态可行的转换。我们的工作与现实世界的四足机器人上展示了四种技能，包括在多技能运动过程中任何阶段的即时跌倒恢复。总而言之，本文的贡献包括：

- 将跳跃和疾驰等高度动态的运动技能与小跑一起纳入学习一个连贯多技能策略中，无需参考轨迹。
- 在真实四足机器人上，通过一个综合的多技能策略，展示成功的小跑、跳跃和疾驰及其动态可行且连续的转换。
- 在不同步态的任何阶段实现成功的故障恢复。
- 随着运动学习过程的推进，自动发现步态切换准则。

我们的分层多技能学习与优化框架如图2所示，包括：（1）一组预训练可复用单技能神经网络策略，每个策略代表一种单一运动技能；（2）一个任务级神经网络，为每种技能生成权重以构成我们的乘法复合策略；（3）复合多技能策略；（4）外部优化循环，用于发现步态切换准则，该准则由水平面上的相对目标距离表示，分别触发从小跑到跳跃的切换，以及从跳跃到疾驰的切换。




图2：提出的多技能学习与优化框架。(a) 在深度强化学习的外循环中优化步态切换准则。(b) 多技能策略的神经网络架构。粗箭头表示策略外部的输入或输出，而普通箭头表示策略内部的输入或输出。

在以下章节中，我们首先将在第2节和第3节回顾我们的分层学习与优化框架的细节。然后，我们将在第4节中展示并分析在真实四足机器人上学习到的多技能运动策略。最后，我们将在第5节中总结我们的工作。

2 分层多技能学习框架

2.1 学习个体技能

机器人使用系统的深度强化学习框架分别学习五种个体技能，包括跌倒恢复、小跑、踱步、跳跃和疾驰。每种运动技能都是由神经网络表示的反馈控制策略，该策略通过软演员-评论家（SAC）算法（Haarnoja等人，2018）学习。我们深度强化学习框架关键组件的详细信息如下所述。

2.1.1 状态观测与动作空间

遵循学习运动技能中的关键反馈状态（Yu等，2023），Actor神经网络的状态输入包括：（1）机器人局部坐标系中的归一化重力向量，反映机器人的机体姿态；（2）基座角速度；（3）机器人航向坐标系中的基座线速度；（4）关节位置。为学习周期性运动技能，我们还加入了二维相位向量 $(\sin 2\pi\phi, \cos 2\pi\phi)$ 来表示连续的时序信息，编码周期运动中从0%到100%的相位 ϕ 。动作是十二个关节的期望关节位置，包括四条腿的髋关节横滚、髋关节俯仰和膝关节。

2.1.2 奖励设计

小跑和跳跃是通过固定期望速度学习的，而疾驰则是通过最大化速度学习的。学习各个策略的奖励函数由连续奖励和离散奖励组成

项。对于c 对于连续奖励项，我们使用径向基函数（RBF）进行如下表述

$$\varphi(x, \hat{x}, \alpha) = \exp(\alpha(\hat{x} - x)^2) \quad (1)$$

其中 x 是连续的物理量， $\hat{x}$ 是对应的参考值， α 是控制径向基函数宽度的形状参数。每个奖励项的公式和权重分别见表1和表2。

表1：用于学习四足运动技能的奖励项。

物理量	奖励项
基座姿态	$w_\phi \times \varphi(\phi, [0, 0, -1], -2.35)$
基座高度	$w_h \times \varphi(h, \hat{h}, -51.16)$
基座线速度	$w_v \times \begin{cases} v_{x_{base}}^{world^2} & \text{疾驰} \\ \varphi(v_{base}^{world}, \hat{v}_{base}^{world}, -18.42) & \text{else} \end{cases}$
关节力矩	$w_\tau \times \varphi(\tau, 0, -0.004)$
关节速度	$w_{\dot{q}} \times \varphi(\dot{q}, 0, -0.032)$
机体地面接触	$w_{bg} \times \begin{cases} \text{基座与地面接触} \\ \emptyset, \text{基座不接触地面} \end{cases}$
脚与地面接触	$w_{fg} \times \begin{cases} \text{无脚接触地面} \\ \emptyset, \text{脚接触地面} \end{cases}$
对称落脚点	$w_{pf} \times \begin{cases} \varphi(p_{foot}^{base}, \hat{p}_{foot}^{base} - 51.16) \\ \varphi(1/4 \sum_{n=1}^4 (p_{foot}^{world, n}) p_{base}^{world}, -51.16), \end{cases} \begin{matrix} \text{恢复} \\ \text{步态} \end{matrix}$
摆动与支撑	$w_{hf} \times \varphi(h_{foot}^{world}, v_{foot}^{world}, \hat{h}_{foot}^{world}, \hat{v}_{foot}^{world}, -460.50)$
偏航角速度	$w_{\dot{\psi}} \times \varphi(\dot{\psi},)$
参考足部接触	$w_f \times \begin{cases} \text{不匹配期望足部接触} \\ \emptyset, \text{匹配期望足部接触} \end{cases}$

表2：学习单一运动技能的奖励项权重。

Task	w_ϕ	w_h	w_v	w_τ	$w_{\dot{q}}$	w_{bg}	w_{fg}	w_{pf}	w_{hf}	$w_{\dot{\psi}}$	w_f
跌倒恢复	0.189	0.189	0.114	0.076	0.076	0.083	0.083	0.189	0.000	0.000	0.000
步态	0.068	0.068	0.170	0.017	0.017	0.048	0.000	0.034	0.034	0.068	0.476

2.1.3 参考足部接触奖励

表1中的最后一个奖励项，即参考足部接触奖励，是在没有参考的情况下学习不同步态类型的关键。每种步态类型的期望足部接触模式受到四足动物（Owaki和Ishiguro, 2017）的启发，如图3所示。在本文中，我们假设随着速度增加，步态依次为小跑、跳跃和疾驰，作为概念验证。需要注意的是，步态类型的顺序并非固定不变。这里我们根据各步态类型的特点在不同阶段确定相应的步态类型。

2.2 学习多技能运动

机器人的任务目标是在水平面上跟踪任意目标，并实现从小跑到跳跃再到疾驰的自然步态转换。目标由 (d_g, θ_g) 表示，水平面上的目标位置为 $(d_g \cos \theta_g, d_g \sin \theta_g)$ 。在每个回合中，我们设定一个固定目标，其中 $d_g \sim (0m, 15m)$ 和 $\theta_g \sim (-180^\circ, 180^\circ)$ 。多技能运动策略通过低级预训练个体策略的乘法组合实时合成




图3: 足底接触模式。

(Peng 等人, 2019), 依据高级门控网络的输出进行。我们将在以下章节中详细介绍每个组件的更多细节。

2.2.1 门控网络

我们的高级门控网络是一个具有两个隐藏层的全连接神经网络。每个隐藏层有256个神经元, 并使用 ReLU 激活函数。门控网络的输入包括: 重力向量、基座角速度、基座线速度、关节位置, 以及机器人与目标在水平面上的归一化距离。门控网络输出每个运动技能的权重, 这些权重之和为1。

2.2.2 复合多技能策略

在多技能运动训练过程中, 专家网络的参数从预训练单技能策略中迁移而来, 并且始终保持固定。也就是说, 只有门控网络的参数通过从设计的奖励中获得的梯度进行反向传播来更新。然后, 门控网络生成的每个运动技能的权重被应用于通过乘法组合 n 预训练单一技能来合成多技能高斯策略 $\pi(a | s, g)$:

$$\pi(a | s, g) = \frac{1}{Z(s, g)} \prod_{i=1}^n \pi_i(a | s)^{w_i(s, g)}, \quad w_i(s, g) \geq 0 \quad (2)$$

其中 $\pi_i(a | s)$ 是第 i 个单技能神经网络策略, $w_i(s, g)$ 是相应技能影响复合策略的权重, $Z(s, g)$ 是归一化因子。合成策略是 n 个高斯策略的乘法组合, 即 n 个单一技能。如 (Peng 等人, 2019) 所述, 高斯基元的乘法组合产生另一个高斯策略, 即复合策略。由于使用了高斯基元, 合成高斯策略的均值 $\mu^1, \mu^2, \dots, \mu^{12}$ 和标准差 $\sigma^1, \sigma^2, \dots, \sigma^{12}$ 计算如下:

$$\mu^j(s, g) = \frac{1}{\sum_{l=1}^n \frac{w_l(s, g)}{\sigma_l^j(s, g)}} \sum_{i=1}^n \frac{w_i(s, g)}{\sigma_i^j(s, g)} \mu_i^j(s, g) \quad (3)$$

$$\sigma^j(s, g) = \left(\sum_{i=1}^n \frac{w_i(s, g)}{\sigma_i^j(s, g)} \right)^{-1} \quad (4)$$

需要注意的是，我们采用了乘法模型而非加法模型，在分层学习框架中，如专家混合模型 (MoE) (Jacobs 等人, 1991)，以避免如 (Peng 等人, 2019) 所报道的由基元求和引起的冲突行为或混合伪影。

2.2.3 控制框架

预训练单技能策略、门控网络和复合多技能策略以25 Hz的频率运行。这些策略共同生成期望关节位置，由关节级PD控制器以1000 Hz的频率进行跟踪。PD控制器接收期望关节位置 $\hat{q}$ 、实测关节位置 q 和关节速度 $\dot{q}$ 作为输入，并输出关节力矩指令 $\tau = K_p(\hat{q} - q) + K_d(0 - \dot{q})$ 。

2.2.4 奖励设计

对于多技能学习，我们设计了三组奖励项。最重要的一组奖励项与目标跟踪 r_g 相关，另一组是参考足底接触奖励 r_f ，最后一组包括学习单一运动技能 r_e 时的其余奖励项。我们将总奖励 r 设为这些项的加权和，如下所示：

$$r = 0.6r_g + 0.2r_f + 0.2r_e. \quad (5)$$

目标跟踪奖励：我们的目标跟踪奖励由三项组成。首先，相对位置奖励 r_{p_g} ，它鼓励最小化机器人与目标在水平面 $d \geq 0$ 上的相对距离：

$$r_{p_g} = \varphi(p_{goal}^{world}, p_{base}^{world}, -0.74); \quad (6)$$

其次，机器人速度奖励 r_{v_g} ，其中期望机器人在水平面上朝向目标的速度尽可能快：

$$r_{v_g} = v^2 \quad (7)$$

第三，机器人朝向奖励 r_{ϕ_g} ，该奖励鼓励机器人朝向与目标方向对齐

1:

$$r_{\phi_g} = \varphi(u_{goal,base}^{base}, [1, 0, 0], -2.35) \quad (8)$$

其中 $u_{goal,base}^{base}$ 是从机器人基座指向目标的单位向量，在基座坐标系中表示。我们的完整目标跟随奖励为 $r_g = r_{h_z} r_{\phi} (8r_{p_g} + 4r_{v_g} + 4r_{\phi_g})$ ，当机器人更接近标称站立姿态时，该奖励会增加目标跟随奖励的权重。

参考足部接触奖励：关于表1中的参考足部接触奖励，学习不同的步态需要不同的参考接触模式。对于多技能训练，我们根据目标与机器人之间的相对距离 d 激活不同的步态，如目标跟随奖励中所述。具体来说，如果 $|d| < x_1$ ，我们使用快步接触模式作为参考来计算该奖励；如果 $x_1 \leq |d| < x_2$ ，则使用跳跃接触模式；如果 $|d| \geq x_2$ ，则使用奔跑接触模式，其中 x_1 和 x_2 是步态切换准则，我们将在第3节中通过运动学习过程之外的优化循环自动发现这些准则。此外，需要指出的是，对于单技能策略，小跑与踱步具有相似的速度范围，并且是一种更常见、更稳定的步态。因此，在训练我们的多技能策略时，当目标较近时，相关奖励项会激活小跑而非踱步。不过，从技术上讲，如果需要，踱步也可以纳入新多技能策略的训练中。

3 发现技能切换准则

在此，我们提出在运动学习过程的外循环中建立一个优化问题，以自动发现从小跑到跳跃、从跳跃到疾驰的步态切换准则。

我们采用协方差矩阵自适应进化策略（CMA-ES）（Hansen, 2016），这是一种受生物进化启发的无导数进化策略，用于优化。我们的目标是找到步态切换准则 x_1m, x_2m ，以最大化每个回合中目标跟踪奖励 r_g 的总和。优化问题表述如下：

$$\begin{aligned} \arg \min_{x_1, x_2} & \sum_{i=1}^N -r_g(x_1, x_2) \\ \text{s.t.} & \quad 0 \leq x_1 \leq 15, \\ & \quad 0 \leq x_2 \leq 15, \\ & \quad x_1 < x_2. \end{aligned}$$

其中 x_1, x_2 是决策变量，分别表示机器人与目标在水平面上的相对距离，用于激活小跑与跳跃、跳跃与疾驰步态之间的切换。 N 是一个回合中的时间步数。

4 实验结果

本节首先介绍实验设置，然后展示寻找合适步态切换准则的优化过程。接着，我们通过给定归一化目标距离输入，证明所提出的多技能策略能够实现多功能运动技能。此外，我们展示了机器人在多技能运动过程中能够随时从失败中恢复。最后，我们展示了所提出的方法在稳定性、平滑性和鲁棒性方面优于基线方法，即在单一技能之间进行手动切换。

4.1 实验设置

多技能训练设置。每个训练轮次从复合多技能策略中采样5000步，即20个回合且无提前终止；每个回合持续10秒；批大小为128；回放缓冲区大小为1e6；学习率为3e-4；权重衰减为1e-6；软目标更新为0.001；折扣因子在跌倒恢复中为0.995，在运动步态中为0.955。

技能切换准则优化设置。我们设置初始步态切换准则为 $x_1 = 2.0m$ 和 $x_2 = 5.0m$ 以热启动优化，种群规模为50，以及 $\sigma = 1.0m$ 。CMA-ES优化每进行20次内循环深度强化学习迭代，便运行一次迭代。

目标轨迹设置。在真实世界测试中，我们通过操纵杆在机器人航向坐标系中给出x轴和y轴上的归一化相对目标距离，以促进多种动态技能及其转换的出现。图4展示了一个示例目标轨迹。

速度估计。为了将在仿真中学习到的多技能策略部署到真实机器人上，感知误差和不确定性通常会导致仿真与现实世界之间的差异。与我们为学习而选择的其他状态观测不同，基座线速度无法直接获得，需要通过腿部运动学或视觉里程计进行估计，而在脚部打滑或高度动态运动期间，估计结果表现不佳（Ji等人，2022）。为此，类似于（Ji等人，2022），我们训练了一个单独的速度估计器，以便在给定更可靠状态的感知信息的情况下，获得不可用或不可靠状态的估计。状态估计器的输入为66维，包括来自IMU的俯仰角和横滚角测量得到的重力向量、两步历史的重力向量、来自IMU的基座角速度、两步历史的基座角速度、关节位置、两步历史的关节位置以及来自电机编码器的关节速度。输出为3维的估计基座线速度。估计器网络由两个隐藏层组成，每层有256个神经元，并使用ReLU激活函数。在仿真中获得运动策略后，我们收集了215000对输入-输出数据用于训练




图4：在机器人航向坐标系中给出归一化相对目标指令，以促进跌倒恢复、小跑、跳跃、疾驰及其转换。

估计器网络，采用监督学习。我们使用均方误差损失（真实速度与神经网络生成的速度估计之间的差异）进行训练，其中学习率为0.001，权重衰减为0.0005，批大小为1024。

4.2 优化技能切换准则

从图5可以看出，最佳成本值持续下降，并在27次优化迭代后达到局部最小值，此时对应的小跑-跳跃和跳跃-疾驰切换准则分别为 $x_1 = 2.2m$ 和 $x_2 = 4.3m$ 。需要注意的是，优化后的步态切换准则并不完全等同于实际步态转换发生的位置，因为它们仅被纳入奖励函数中。相反，多技能运动过程中的步态转换是通过优化后的步态切换准则自然学习得到的。




图5：多技能运动学习中步态切换准则的CMA-ES优化结果。(a) CMA-ES优化过程中的最佳成本。(b) 从小跑切换到跳跃的优化相对距离。(c) 从跳跃切换到疾驰的优化相对距离。

4.3 多技能运动与连续技能转换

借助学习到的多技能运动策略，机器人能够展示小跑、跳跃、疾驰以及必要时迅速跌倒恢复的能力，如图6(a)及随附视频所示。通过操纵杆给出的相应目标指令如图4所示。此处仅报告现实世界中的实验结果。更多仿真及鲁棒性测试请参阅随附视频。




图6：使用我们提出的方法和基线方法进行多技能运动的比较。(a) 通过遵循图4中的目标轨迹学习到的多技能运动。(b) 通过在学习的单一技能之间手动切换的基线方法。机器人在从跳跃到疾驰的离散切换后失败。

估计速度。我们展示了多技能运动20秒内机器人航向坐标系水平面上的估计速度，见图7(a)。机器人在小跑、跳跃和疾驰技能中表现出递增的速度。

专家权重。图7(b)显示了门控网络对应生成的每个单一技能策略的权重。跌倒恢复专家在恢复运动期间占主导地位。对于展示的三种运动步态，每个对应的专家在所有专家中拥有最大的权重。然而，与对应的专家占主导地位的跳跃和疾驰步态相比，小跑专家在小跑期间与其他专家更多地共同作用，共同贡献于合成策略。此外，为了详细了解每个专家在不同四足运动技能中的影响，我们可视化了四种演示技能中每个专家在不同时间步的权重。从图8中，我们可以清楚地看到每个动作的单一技能策略的组成，并且每个动作都利用了所有五个单一技能。

欧拉角。相应的横滚角和俯仰角如图9所示。当机器人遭遇跌倒时，横滚角和俯仰角起初可能变得较大，并在跌倒恢复过程中回到正常范围。在其他情况下，这两个欧拉角呈现出明显的循环模式。此外，从小跑到跳跃再到疾驰，欧拉角的幅值逐渐增大，表明运动变得更加动态。

4.4 消融研究

我们将所提出的多技能学习与优化方法与基线方法进行了比较，即在不同的技能原语之间进行手动切换。对于单一技能，小跑和跳跃是在固定期望速度下学习的，而疾驰则是通过最大化速度来学习的。在固定各专家网络参数进行多技能学习后，门控网络在较低速度范围内合成小跑运动，并以更高的实际部署成功率合成更具动态可行性的疾驰运动。更多细节请参见图6中的快照及随附视频。



图7：具有连续步态转换的多功能运动。(a) 多技能运动期间机器人的估计水平速度，以及(b) 专家权重显示每个运动利用所有五个专家，其中一个相关专家占主导地位。

对于基线方法，机器人在从跳跃手动切换到疾驰时失败，有时会因宇树机器人的电源保护而触发自动关机。在未触发电源保护而失败的情况下，我们可以手动激活跌倒恢复技能，机器人随后能够从失败状态恢复到静止站立。然而，要恢复运动，还需要从站立到小跑进行另一次离散切换，这会带来进一步的不稳定问题。相比之下，我们的多技能策略可以直接从失败状态动态地过渡到小跑，无需经过中间阶段。当在不合适的步态相位从小跑离散切换到跳跃时，后腿的膝关节在接下来的几个时间步内可能非常接近地面，或者前腿抬得很高。如图10所示，手动切换导致了动态不稳定，例如估计速度的突变。而我们的方法在实际部署中实现了更平滑、连续的步态转换。




图8: 多技能运动中, 分别在0.2秒、2.5秒、8.0秒和18.0秒时, 跌倒恢复、小跑、跳跃和疾驰五种技能原语的组合情况。




图9: 多技能运动过程中的横滚角和俯仰角。




图10：通过手动从跌倒恢复切换到小跑再到跳跃的基线方法性能。机器人未能从跳跃切换到疾驰（红色阴影区域），但随后能够从失败中成功恢复到静止站立。（a）估计的水平速度。（b）横滚角和俯仰角。

5 结论

本研究开发了一种分层学习与优化框架，以在无需任何参考轨迹或专家演示的情况下，实现具有优化步态切换准则的多技能运动。随着运动速度的增加，机器人展示了在小跑、跳跃和疾驰技能之间的连续步态转换。我们学习到的多技能策略还可以整合跌倒恢复技能，使机器人在不同步态下变得不稳定或跌倒时能够迅速恢复并继续运动。因此，机器人在远程工作空间中自主运行所需的人工干预更少，从而实现多种应用。与使用单一策略的现有端到端学习框架相比，我们的分层框架具有仿生特性，并且在针对各种任务进行微调时更加高效，因为它不需要从零开始学习来适应新任务。此外，通过在运动学习过程中优化步态切换准则，我们避免了使用带有偏见的人类知识提炼来手动指定准则。该公式可以通过定制代价函数轻松适应和推广到不同的任务或场景。

我们方法的一个局限性在于，我们发现疾驰运动中仍然存在仿真到现实的差异。在仿真中，疾驰更加稳定，不会出现任何失败。在现实世界中，我们无法确保长时间疾驰的100%成功率。这可能是由多种原因造成的。与其他运动技能相比，疾驰本质上是一种非常不稳定的运动技能，因为同一时间只有一只脚与地面接触。轻微的仿真到现实差异可能导致巨大偏差甚至失败，例如宇树A1机器人上的可变形脚垫、地面摩擦力、分布外运动的速度估计等。另一个原因是我们在真实世界测试中给出的目标指令与仿真中的不同。在仿真训练中，我们直接在世界坐标系中给出目标位置，而在现实世界中，由于缺乏身体位置反馈，我们通过操纵杆在机器人航向坐标系中给出归一化相对目标距离，这使得无法通过操纵杆复现与仿真中相同的目标指令。

在未来的工作中，我们计划进一步解决疾驰运动中的仿真到现实的差距。我们还希望研究将所提出的框架扩展到更多技能和更复杂任务的可扩展性，因为这需要更多的奖励工程。此外，由于我们提出的方法无需任何参考即可生成多技能运动数据，我们框架的一个有趣应用是为腿式机器人的通用策略（如扩散模型或OpenVLA（Kim等人，2024））的训练和微调准备数据集。

致谢

这项工作得到了UKRI未来领袖奖学金 [MR/V025333/1] (RoboHike)的支持。Fernando Acero得到了UKRI基础人工智能博士培训中心(EP/S021566/1)的支持。

参考文献

- Bellegarda, G., Shafiee, M., 和 Ijspeert, A. (2024). Allgait: 学习所有四足步态及其转换. *arXiv预印本 arXiv:2411.04787*. Caluwaerts, K., Iscen, A., Kew, J. C., Yu, W., Zhang, T., Freeman, D., Lee, K.-H., Lee, L., Saliceti, S., Zhuang, V., 等. (2023). Barkour: 以四足机器人基准测试动物级敏捷性. *arXiv预印本 arXiv:2305.14654*. Castano, J. A., Zhou, C., 和 Tsagarakis, N. (2019). 利用稳定性特征空间为轮腿式四足机器人设计跌倒恢复策略. 在2019年IEEE机器人与仿生学国际会议(ROBIO)中, 第41–46页. IEEE. Chen, A. S., Lessing, A. M., Tang, A., Chada, G., Smith, L., Levine, S., 和 Finn, C. (2024). 利用视觉语言模型进行腿式机器人适应的常识推理. *arXiv预印本 arXiv:2407.02666*. Cheng, X., Shi, K., Agarwal, A., 和 Pathak, D. (2024). 腿式机器人的极限跑酷. 在国际会议中. Fu, Z., Kumar, A., Malik, J., 和 Pathak, D. (2021). 最小化能量消耗导致腿式机器人步态的出现. 在 机器人学习会议中. PMLR. Haarnoja, T., Zhou, A., Abbeel, P., 和 Levine, S. (2018). Soft actor-critic: 基于随机策略的离策略最大熵深度强化学习. 在国际机器学习会议中, 第1861–1870页. PMLR. Hansen, N. (2016). CMA进化策略: 教程. *arXiv预印本 arXiv:1604.00772*. He, T., Zhang, C., Xiao, W., He, G., Liu, C., 和 Shi, G. (2024). 敏捷但安全: 学习无碰撞的高速腿式运动. 在机器人学: 系统与科学中. Hoyt, D. F. 和 Taylor, C. R. (1981). 马的步态与运动能量学. 自然, 292(5820):239–240. Huang, X., Chi, Y., Wang, R., Li, Z., Peng, X. B., Shao, S., Nikolic, B., 和 Sreenath, K. (2024). Diffuse-loco: 基于离线数据集的扩散实时腿式运动控制. 在 机器人学习会议中. Humphreys, J., Li, J., Wan, Y., Gao, H., 和 Zhou, C. (2023). 四足运动的仿生步态转换. *IEEE机器人与自动化快报*. Hwangbo, J., Lee, J., Dosovitskiy, A., Bellicoso, D., Tsounis, V., Koltun, V., 和 Hutter, M. (2019). 学习腿式机器人的敏捷和动态运动技能. *科学机器人学*, 4(26):eaau5872. Jacobs, R. A., Jordan, M. I., Nowlan, S. J., 和 Hinton, G. E. (1991). 局部专家自适应混合. *神经计算*, 3(1):79–87. Ji, G., Mun, J., Kim, H., 和 Hwangbo, J. (2022). 控制策略与状态估计器的并发训练用于动态且稳健的腿式运动. *IEEE机器人与自动化快报*, 7(2):4630–4637. Kim, M. J., Pertsch, K., Karamcheti, S., Xiao, T., Balakrishna, A., Nair, S., Rafailov, R., Foster, E., Lam, G., Sanketi, P., 等. (2024). OpenVLA: 一个开源的视觉-语言-动作模型. *arXiv预印本 arXiv:2406.09246*. Liang, B., Sun, L., Zhu, X., Zhang, B., Xiong, Z., Li, C., Sreenath, K., 和 Tomizuka, M. (2024). 自适应能量正则化用于自主步态转换和节能四足运动. *arXiv预印本 arXiv:2403.20001*.

Margolis, G. B. 和 Agrawal, P. (2023)。Walk these ways: 通过行为多样性调优机器人控制以实现泛化。见机器人学习会议, 第22–31页。PMLR。Mitchell, A. L., Merkt, W., Papatheodorou, A., Havoutis, I., 和 Posner, I. (2024)。Gaitor: 学习跨步态统一表示以实现真实世界四足运动。见机器人学习会议。PMLR。O’ Mahoney, R., Mitchell, A. L., Yu, W., Posner, I., 和 Havoutis, I. (2024)。使用扩散模型进行四足运动的离线适应。*arXiv预印本 arXiv:2411.08832*。Owaki, D. 和 Ishiguro, A. (2017)。一种从行走过渡到小跑再到疾驰表现出自发步态转换的四足机器人。科学报告, 7(1): 1–10。Peng, X. B., Chang, M., Zhang, G., Abbeel, P., 和 Levine, S. (2019)。Mcp: 使用乘法组合策略学习可组合分层控制。神经信息处理系统进展, 32。Reske, A., Carius, J., Ma, Y., Farshidian, F., 和 Hutter, M. (2021)。基于MPC的模仿学习用于四足多步态控制。见2021年IEEE国际机器人与自动化会议 (ICRA), 第5014–5020页。IEEE。Shafiee, M., Bellegarda, G., 和 Ijspeert, A. (2024)。可行性导致在具有挑战性的地形上学习敏捷四足运动时步态转换的出现。自然通讯, 15(1): 3073。Shao, Y., Jin, Y., Liu, X., He, W., Wang, H., 和 Yang, W. (2021)。通过相位引导控制器学习四足机器人的自由步态转换。IEEE机器人与自动化快报。Tang, Y., Yu, W., Tan, J., Zen, H., Faust, A., 和 Harada, T. (2023)。Saytap: 语言到四足运动。*arXiv预印本 arXiv:2306.07580*。Yang, C., Yuan, K., Zhu, Q., Yu, W., 和 Li, Z. (2020)。自适应腿式运动的多专家学习。科学机器人学, 5(49): eabb2174。Yang, Y., Zhang, T., Coumans, E., Tan, J., 和 Boots, B. (2022)。通过学习到的步态转换实现快速高效运动。见机器人学习会议, 第773–783页。PMLR。Yu, W., Yang, C., McGreavy, C., Triantafyllidis, E., Bellegarda, G., Shafiee, M., Ijspeert, A. J., 和 Li, Z. (2023)。识别学习运动技能的重要感觉反馈。自然机器智能, 5(8): 919–932。Zhuang, Z., Fu, Z., Wang, J., Atkeson, C., Schwertfeger, S., Finn, C., 和 Zhao, H. (2023)。机器人跑酷学习。见机器人学习会议, 第73–92页。PMLR。