

在危险地形上学习敏捷运动

张翀¹, Nikita Rudin¹, David Hoeller¹, Marco Hutter¹

摘要——四足机器人通过强化学习已在各种地形上展现出卓越的移动能力。然而，在存在稀疏立足点和危险地形（如踏脚石和平衡木）的情况下，这些地形需要精确的落脚点以避免摔倒，通常采用基于模型的方法。在本文中，我们表明端到端强化学习也能使机器人以动态运动穿越危险地形。为此，我们的方法包括先在杂乱且稀疏的踏脚石上训练一个用于敏捷运动的通用策略，然后通过从中微调专家策略，将其可复用知识迁移到各种更具挑战性的地形上。鉴于机器人需要在这些地形上快速调整其速度，我们将任务表述为导航任务，而非常用的会约束机器人行为的速度跟踪，并提出一种探索策略来克服稀疏奖励并实现高鲁棒性。我们通过在ANYmal-D机器人上进行的仿真和真实世界实验验证了所提出的方法，在稀疏踏脚石和狭窄平衡木上达到了 ≥ 2.5 米/秒的峰值前进速度。视频：youtu.be/Z5X0J8OH6z4

I. 引言

四足机器人需要在崎岖复杂的地形上具备感知运动能力，包括具有稀疏立足点的危险地形，如踏脚石和平衡木。现有工作通常采用基于模型的控制[1]–[6]，这些控制器在仿真或实验室条件下表现良好。然而，由于模型失配和意外滑移[7], [8]，它们在实际野外部署中经验上较为困难，并且通常需要专门设计（例如运动参考[9]以及诸如地形粗糙度和姿态安全[3]等手工启发式规则）来实现特定运动。此外，动力学模型需要简化，尤其是对于肢体[2], [4]，而且由于计算负担沉重，重规划往往很慢[3], [5]。

另一方面，基于无模型强化学习（RL）的方法通过域随机化和大量训练数据在野外展现出卓越的鲁棒性[10], [11]。然而，现有工作尚未使用端到端强化学习来处理高度危险地形上的稀疏立足点，在这些地形中，精确的动作对于避免失败至关重要，而由于失败方式众多，探索也颇具挑战。首次尝试使用端到端学习解决此类运动挑战的方法显示出令人鼓舞的结果，但仍受限于地形复杂度[12]或需要精确知道应踩踏哪些石头[13]。另一项工作为立足点规划与执行训练了解耦策略[14]，但该方法无法在危险地形上实现动态运动，且




图1. ANYmal-D 机器人在踏脚石、带间隙的平衡木和踏脚梁上执行学习到的强化学习策略。左上：踏脚石宽20厘米，仅占整个区域的 $\sim 10\%$ ，高低石头之间的高度差为12厘米。机器人从左到右穿越石头时达到了2.7米/秒的前进速度峰值。右上：地形由两根100厘米 $\times$ 20厘米的横梁和三个间隙组成。机器人从右到左的前进速度峰值为2.5米/秒。底部：踏脚梁的宽度在 [12 厘米, 17厘米] 之间变化，两根梁之间的水平距离在 [30 厘米, 60厘米] 之间变化，垂直距离在 [0 厘米, 20厘米] 之间变化。出于实际原因，我们仅在仿真中测试了该策略，机器人从左到右的前进速度峰值达到了1.5米/秒。

解耦规划与控制本质上会限制可表达的行为范围 [15]。

一些现有工作将强化学习与基于模型的控制相结合。例如，[16] 使用强化学习生成期望的足部位置，随后由全身运动控制器进行跟踪，并辅以校正关节力矩以实现域自适应跟踪。另一项工作使用强化学习生成基座的期望加速度，并通过基于模型的控制[17]进行跟踪。然而，所有这些方法在速度 $\leq 0.5\text{m/s}$ 下展现的敏捷性有限。另一项近期工作 [18] 开辟了新途径，通过强化学习策略跟踪基于模型的规划器生成的轨迹，并展现出卓越的性能，但这些运动受限于规划器，且无法从故障中恢复。

在本文中，我们探讨了如何通过端到端强化学习在高度危险的地形上实现四足机器人的动态运动。我们首先训练一个通用策略，使其在稀疏且无序的踏脚石上学习可复用的感觉运动技能。然后，我们从通用策略出发，在各种更具挑战性的地形上微调多个专家策略，并成功将其中两个专家策略迁移到真实世界的踏脚石和窄梁上。我们实现了峰值前进速度 ≥ 2.5 米/秒的高度敏捷动作，如图1所示。

¹ 作者隶属于苏黎世联邦理工学院机器人系统实验室，瑞士苏黎世8092。
邮箱: {chozhang, rudinn, dhoeller, mahutter}@ethz.ch




图2. 我们方法论的总览。左侧展示了学习系统。右侧列出了不同的组成部分。

基于常用的速度跟踪公式化（例如 [19] 和[12]中使用的）的传统学习方法无法完成这些具有挑战性的任务。在危险地形上，尤其是当机器人需要快速调整速度时，为其分配合适的速度指令是难以处理的，而且与非危险地形相比，可行解非常稀少且难以探索。因此，本文的关键思想是像 [20], 中那样将任务表述为一个导航问题，尽管危险环境和稀疏奖励使得探索更加困难。

为了克服导航公式中的困难探索问题，我们改进了 [20], 中的课程学习设计，并融入了好奇心驱动的内在奖励 [21]。我们还采用了基于 [22], 的基于对称性的数据增强，利用我们机器人的左右和前后对称性来提高数据效率。这些改进形成了一种能够学习鲁棒通用策略的探索策略。

尽管如此，我们发现上述探索策略仍不足以在图1中的地形上从头训练专家策略。此外，我们希望学习到的感觉运动技能能够在新地形上复用。为此，我们将训练流程分为两个阶段，第一阶段是在稀疏且无序的踏脚石上学习一个通用的通用策略，第二阶段是从该通用策略出发，在不同地形上微调不同的专家策略。通过这种方式，通用策略可以学习到一些在不同地形上可复用的基本运动技能，而专家策略则可以受益于第一阶段的预训练。这种通用-专家训练流程使得学习敏捷运动技能成为可能，并随后将这些技能迁移到危险地形上的真实机器人。

还值得一提的是，本文不关注感知问题，因此在真实世界部署中使用真值地图和动作捕捉系统进行状态估计。尽管如此，也可以结合 [23] 中提出的技术使用机载传感器。

综上所述，我们的贡献包括：

- 1) 将导航公式化扩展到 [20] 具有挑战性的危险地形；
- 2) 一种由课程、内在奖励和基于对称性的数据增强组成的探索策略；

- 3) 在困难探索条件下训练通用策略并微调专家策略的方法论；
- 4) 在具有挑战性的踏脚石和平衡木上成功实现学习到的敏捷动作的仿真到现实迁移。

II. 方法论

本文中的所有实现均基于PPO算法 [24]，并借助基于GPU的仿真器Isaac Gym [25]实现大规模并行仿真 [19]。整体概览如图2所示。

A. 将运动控制公式化为导航任务

本文将问题公式化为导航任务：机器人应接近地形上指定的目标以获得高任务奖励。当速度指令难以直接指定时，例如机器人在迷宫[26]中行走或需要先从跌倒中恢复再行走 [27]时，导航公式化展现出巨大潜力。在 [20], 中，跳跃大间隙和攀爬高台等高级运动技能通过导航公式化得以学习，而基于速度的跟踪无法实现这些期望行为。

在本工作中，考虑到机器人应适应地形调整自身速度，且不恰当的速度指令可能产生误导，我们也采用了导航公式化。我们基于 [20], 部署了图2所示的系统，并向机器人分配位置和航向指令。对这些指令的跟踪主导了奖励，具体如下：

$$r_{\text{task}} = \begin{cases} \frac{c_{\text{task}}}{T_r} \cdot \frac{1}{1 + \|\chi_t - \chi^*\|^2}, & \text{if } t > T - T_r \\ 0, & \text{otherwise,} \end{cases} \quad (1)$$

其中 χ 和 χ^* 分别是基座的当前和目标位置（或航向）， t 是当前时间， T 是最大回合长度， T_r 定义了奖励的持续时间。通过这种方式，只要机器人在回合接近结束时到达目标，策略就可以自由调节机器人的运动。

B. 探索策略

我们的探索策略在三个方面改进了先前工作 [20]：课程学习设计、内在

奖励以及数据增强。所提出的方法能够在稀疏奖励下经验性地训练出更稳健的策略，并在第IV-B节的消融研究进行了实验分析。

1) 课程设计：课程学习是在具有挑战性的危险地形上学习运动技能的常用技术 [7], [10], [19], [20]。在 Isaac Gym 中，课程学习的典型实现方式是在训练前生成所有不同难度等级的地形，并将机器人分布在不同地形上 [19], [20]。基于此，[20] 中的课程设计被表述为：1) 如果策略表现良好，则进入更高难度等级；2) 如果策略表现不佳，则进入更低难度等级；3) 如果策略在最高难度等级上表现良好，则进入随机难度等级。

然而，我们发现这种课程由于地形极具挑战性和危险性，存在稀疏奖励和等级间难度差距的问题。在低难度地形上表现良好的策略很难在更高难度的地形上发挥作用，导致较大的奖励差异，而难度无关优化器可能会错误地将这种差异归因于不同的动作，从而误导优化过程。为了缓解这一问题，我们提出放宽课程更新机制：只有当策略在到目标的剩余距离上无法优于随机动作时，机器人才会被降级。通过这种方式，机器人可以持续与同一等级交互，直到克服该等级。

2) 内在好奇心奖励：在激励机器人到达目标的任务奖励之上，我们还使用基于好奇心的内在奖励，以鼓励机器人在训练过程中探索新颖的状态-动作对。在许多变体中，[21], [28], [29]，我们采用随机网络蒸馏 (RND) [21]，其版本来自 [30]，因为它实现简单且性能优于其他变体。具体而言，好奇心奖励定义为

$$r_{\text{curio}}(s, a) = c_{\text{curio}} \cdot |M_1(s, a) - M_2(s, a)|, \quad (2)$$

其中 M_1 和 M_2 是两个随机初始化的神经网络，以状态-动作 (s, a) 对作为输入， M_1 可被训练，而 M_2 保持冻结。通过使用已访问的状态-动作对将 M_1 拟合至 M_2 的输出，对于不熟悉的状态-动作对，好奇心奖励会很高，而对于熟悉的状态-动作对则会衰减至0。

值得一提的是，虽然好奇心奖励通常被用来提升数据效率，但我们并未观察到学习曲线的显著变化。相反，我们通过实验发现它可以提高所学策略的鲁棒性，如第IV-B节所讨论。这可能归因于状态空间覆盖范围的扩大，正如 [31]所建议的，更大的状态空间覆盖可以提高某些学习到的运动技能的鲁棒性。

3) 基于对称性的数据增强：为了提高数据效率并减少运动过程中的基底倾斜，我们利用机器人的对称设计来增强采样数据，如 [22]中所提出的方法，该方法是对 [32]中复制方法的改编。具体而言，一个状态-动作对可以通过左右和

前后对称性增强为四个状态-动作对。增强状态-动作对被赋予与原始状态-动作对相同的目标值、优势函数和折扣回报。通过这种方式，演员与评论家网络被强制学习对称的动作和值。

C. 两阶段通才-专才训练

在本文中，我们实现了在具有稀疏立足点的多样挑战性地形上的敏捷运动，如图1所示。然而，即使采用了上述所有技术，由于奖励极度稀疏，这些动作也无法从头训练。为解决这一问题，我们首先在相对简单的踏脚石上训练一个通用策略（见第III-A节）。然后，将学习到的策略及其评论家网络在新地形上进行微调，从而实现敏捷动作的数据高效学习，其中通用策略可作为预训练模型。

除了数据效率之外，通用策略还被不同的专家策略共享，这意味着学习到的感觉运动技能是可复用的。因此，成本高昂的通用训练阶段仅需进行一次，对于新地形只需进行数据高效的微调即可。

III. 实验设置

我们在 Isaac Gym 中创建了4种不同类型的地形，每种地形有10个难度级别。其中，“Stones-Everywhere”用于通用策略训练和基准测试，而其他三种（“Stones-2Rows”、“Balance-Beams”和“Stepping-Beams”）用于微调。这些地形在第III-A节中描述。第III-B节和第III-C节分别介绍了每种地形类型的特定奖励和与任务相关的随机化设置。

A. 地形

四种地形类型如图3所示，并在以下段落中加以描述。由于“Stones-Everywhere”类型用于基准测试不同学习方法的性能，我们将对其进行详细介绍，而其他地形类型则简要介绍。

1) *Stones-Everywhere*：这是用于训练通用策略并基准测试消融研究的地形类型。每块石头被分配一个网格方块，并具有从方块中心随机偏移的X-Y平面偏移的随机高度。通过这种方式可以生成高度无序且稀疏的踏脚石。不同级别的参数包括石头尺寸 w_{stone} 、石头间隙 w_{gap} 、最大偏移 s_{max} 和最大高度 h_{max} 。石头尺寸是方形石头的宽度，石头间隙是网格尺寸减去石头尺寸，即两块零偏移石头之间的间隙大小。X偏移和Y偏移均从 $[-s_{\text{max}}, s_{\text{max}}]$ 中均匀采样，石头高度从 $[-h_{\text{max}}, h_{\text{max}}]$ 中均匀采样。


参数见表I，其中稀疏度表示不可踏区域占整个地形的比例。

2) *Stones-2Rows*：此类地形包含1、2或3行踏脚石，与我们在实验室中可搭建的结构相匹配。通过这种方式，我们可以获得一个不会过度拟合特定步态模式的策略。

石头-无处不在，用于通用训练和基准测试



Stones-2Rows，用于具有仿真到现实迁移的专家微调



Balance-Beams，用于具有仿真到现实迁移的专家微调



Stepping-Beams，用于专家微调



图3. 从左到右依次为难度等级0、5和9的不同类型地形。一种地形类型可以有强调不同特征的不同子类型，如第III-A节所述。

3) *Balance-Beams*: 此类地形的踏脚石随着难度等级提升，从两行逐渐合并为一行。地形中还会随机添加间隙。这种逐渐演变的石头可以引导策略学习类似猫步的运动。逐渐变窄的横梁可能是一个更直观的选择，但这可能导致图4中不可行的爬行运动，即一种仅适用于宽横梁的局部最小值。

4) *Stepping-Beams*: 此类地形具有一系列可供踩踏的横梁，在更高等级中横梁更窄且更随机。这种地形类型难以在实验室中搭建，因此我们仅在仿真中尝试了它，以表明微调可以适用于各种不同的地形。

B. 奖励

相同的奖励函数可以在仿真中的所有地形上工作，但为了实现真实世界中的优雅动作，需要根据地形进行细微的调整。我们在附录的表IV中展示了奖励项，并标注了特殊任务中权重的变化。对于每种地形上的每个任务，奖励函数是所有项的总和。

在这些奖励中，我们使用位置跟踪和航向跟踪来衡量任务表现。我们使用惩罚项来处理提前终止和碰撞。我们还对关节速度、基座加速度、脚部加速度以及动作进行正则化处理，

表I “STONES-EVERYWHERE”地形的参数

难度等级	石头尺寸 宽 _{stone} (厘米)	石头间隙 宽 _{gap} (厘米)	最大偏移 间距 _{max} (厘米)	最大高度 高 _{max} (厘米)	稀疏度 (%)
0	92	8	3.6	1	15.4
...	...	...	...	...	...
5	52	18	8.2	6	44.8
...	...	...	...	...	...
9	20	26	11.8	10	81.1

*除计算出的稀疏度外，所有参数均随等级线性变化，因此我们仅列出等级0、5和9。

** 作为参考，[12] 构建了 ~ 65%稀疏度的踏脚石，未设置随机高度和显著偏移。



图4. 由于不恰当的地形课程设计，机器人在平衡木上学习到了不可行的爬行运动。此处展示的地形远不如真实世界中的地形具有挑战性，但机器人仍无法穿越。当横梁较窄时，机器人无法在横梁上找到下一步的落点。

包括动作变化率、扭矩和接触力。我们按照 [20], 中的方法，使用“不要等待”和“按方向移动”奖励来引导探索，并提供“保持静止”奖励，使机器人在到达目标后保持静止。

我们对“Stones-2Rows”和“Balance-Beams”上的激进运动进行正则化，并进一步对“Balance-Beams”上的扭矩进行正则化。我们还在“Stones-2Rows”和“Balance-Beams”上添加了“站立姿态”奖励，以便为机器人进一步的重复测试做好准备。

C. 域随机化

我们使用域随机化来提高鲁棒性并促进仿真到现实迁移 [33], [34]。与任务相关的随机化设置见附录中的表III。我们略微延长了回合长度，以减缓“Stones-2Rows”和“Balance-Beams”上的激进运动。对于“Balance-Beams”，质心被大幅随机化，以减少基座在横梁上的危险晃动。

IV. 仿真结果

A. 仿真中学习到的运动

我们学习到的策略在仿真中的“Stones-Everywhere”上展现了许多有趣的行为。在图5中，我们通过提供一系列航路点作为目标位置和航向，使机器人在踏脚石上行走，展示了我们的方法学习到的全向运动能力。在运动过程中，机器人还在不同情况下表现出不同的步态模式和接触模式。

我们还发现，该策略能够在仿真中从失足中恢复，如图6所示。~ 50 公斤的机器人能够快速应对外力干扰，即使所有脚上的力达到~ 100 牛，也能继续行走。




图5. 机器人在仿真中最困难的“Stones-Everywhere”地形上行走。黄色方框表示我们提供给机器人以实现全方位运动的一系列目标位置和航向。机器人在不同情况下采用不同的步态模式，例如，当前方容易找到安全落脚点时采用三足接触行走或两足接触快步态，否则采用两足接触踱步步态。与地形接触脚已标记。




图6. 在仿真中行走于踏脚石上时，机器人能够从外力干扰导致的踏空步态中动态恢复。左上：机器人在从左向右穿越石头时，其四只脚受到持续0.4秒的外力。右上：机器人因外力而踏空一步。左下：机器人通过用腿按压石头将自身向上和向前拉动，从踏空步态中恢复。右下：机器人在踏空后继续行走。

B. 基准消融研究

我们比较了不同设置，并分析了学习到的策略在“Stones-Everywhere”上的鲁棒性。比较的设置包括：

- 1) 无导航：使用基于 [19] 的速度跟踪公式化，并配合相应的课程，同时应用内在奖励和基于对称性的数据增强；
- 2) 无课程：使用本文提出的除改进课程外的所有技术，课程采用 [20] 中的方案；
- 3) 无好奇心：使用本文提出的除内在好奇心奖励外的所有技术；
- 4) 无增强：使用本文提出的除数据增强外的所有技术；
- 5) 所提出的方法：使用本文提出的所有技术。

我们使用两个指标来比较性能和鲁棒性。第一个指标是在不同难度等级下穿越6米距离的成功率，如图7所示。在稀疏度为 $\sim 40\%$ 的第4级之后，速度跟踪的平均成功率低于90%，并随着难度等级的升高而迅速下降。相比之下，




图7. 在不同等级的“Stones-Everywhere”上穿越6米的成功率。基于导航公式化的设置在性能上远超速度跟踪设置。每种设置进行了三次运行（使用不同随机种子训练的策略），以计算平均值（线）和标准差（阴影区域）的值，以及8000次迭代的检查点。

（全部收敛）被使用。用于测试速度跟踪的速度指令为0.8米/秒前进，这在仿真中经验性地表现出最高的鲁棒性。每个策略的成功率是根据100个多样化的随机地形上的1000次试验计算得出的。




图8. 在“Stones-Everywhere”最难级别上穿越不同距离的成功率。我们所提出的方法能够在长距离上稳定地学习鲁棒策略。阴影区域表示标准差的值。

导航公式化能够实现较高的成功率，尽管“无增强”设置在地形难度较低时表现不佳。这可以解释为：没有数据增强，策略无法克服最困难的地形，而当机器人卡在困难地形上时，神经网络策略会遗忘低难度地形上的样本。

第二个指标是在最高难度等级下穿越不同距离的成功率，如图8所示，该指标在基于导航公式的方法之间呈现出更清晰的趋势。我们策略中的所有技术都对提升鲁棒性有显著贡献，其中基于对称性的数据增强最为关键。改进后的课程设计和好奇心奖励的影响相对较小。此外，基于对称性的数据增强还使运动更加平衡，基底倾斜更小。

		测试地形			
		石头-无处不在	石头-两行	平衡-横梁	跨越-横梁
Training Terrains	石头-无处不在	9/9	6/9	<0/9	2/9
	石头-两行	9/9	9/9	3/9	6/9
	平衡-横梁	3/9	<0/9	9/9	<0/9
	踏步-横梁	4/9	7/9	<0/9	9/9

图 9. 我们学习到的策略的迁移性矩阵。矩阵中的值（“/9”之前）表示在测试地形上能够以80%的成功率穿越3.5米的最大难度（0~9 其中9为最难）。对于“<0”对应的值，在等级0上的成功率在 [50%,80%)之间。

C. 微调与从头训练

我们通过对已学习的通用策略进行微调，在图1和图3所示的多个具有挑战性的地形上训练专家策略。通用策略训练了8000次迭代，“Stones-2Rows”策略训练了2000次迭代，“Balance-Beams”策略训练了3000次迭代，“Stepping-Beams”策略训练了1000次迭代。相比之下，当专家策略从零开始为每个任务训练10000次迭代时，机器人无法学会穿越这些地形，因为我们设计这些地形的难度相当高。

D. 策略的可迁移性

我们还测试了在不同地形上训练的策略是否可以迁移到其他地形。图9展示了我们学习到的策略的可迁移性矩阵。由于地形的相似性，在“Stones-Everywhere”和“Stones-2Rows”上训练的策略可以相互迁移，后者也可以与“Stepping-Beams”相互迁移。对于其他地形组合，策略迁移效果不佳。这些结果表明，尽管学习到的策略源自同一个通用策略，但由于训练数据的不同，它们之间产生了显著差异。因此，如果我们希望获得一个能在各种地形上表现良好的统一策略，就必须对机器人可能遇到的所有地形进行随机化。否则，学习到的策略无法很好地泛化。

V. 真实世界结果

出于实际原因，我们仅在真实世界中搭建了两种植地：踏脚石和平衡木，并成功迁移了学习到的“Stones-2Rows”和“Balance-Beams”策略。为了最小化仿真到现实的差距并专注于运动问题，我们使用动作捕捉系统获取机器人的状态和地形信息。

A. 敏捷动作

学习到的策略在真实地形上的运动如图10和图11所示。这些运动涉及多次跳跃和快速变化的速度，这些通过速度跟踪难以实现。为了在给定的回合长度内完成任务，机器人采取了不同的策略，




图 10. 在真实世界实验中，机器人在踏脚石上学习到的敏捷动作。机器人频繁地向上和向前跳跃，以穿越地形。机器人位置由世界坐标系中的动作捕捉系统采样获得，速度通过对位置求导得到。




图11. 真实世界实验中平衡木上的学习型敏捷动作。机器人首先缓慢调整自身与横梁中心对齐，然后落在横梁上。随后，机器人快速交替切换左右对角线，并产生速度爆发（图中3~5秒处）以穿越横梁。

表II 真实地形上的重复鲁棒性测试结果

真实地形	Stones-2Rows	Balance-Beams
成功率	8/10	5/5
存活率	10/10	5/5

针对不同的地形。在踏脚石上，它持续跳跃，而在平衡木上，它首先缓慢地将自身对准中心，然后进行速度爆发以快速穿越地形。

B. 鲁棒性测试

我们对这两种策略进行了重复鲁棒性测试（另见视频附件），结果如表II所示。成功率统计的是完美完成的试验次数，而存活率还统计了机器人踩空但成功恢复的情况。

我们的方法也与基于模型的控制不同，机器人能够快速应对意外的踏空并存活下来，如第IV-A节所讨论。我们请读者

参阅视频附件以观察涌现行为。值得一提的是，我们的控制器容易受到映射漂移的影响，5厘米的里程计漂移就可能导致机器人摔倒，尽管这部分归因于高度危险的地形。

六、局限性与讨论

尽管我们能够在各种地形上实现敏捷运动，但由于不同地形上的学习进度可能不同且相互干扰，我们难以训练一个适用于所有地形的统一策略。此外，我们针对不同的专家任务使用了略有不同的设置，并借助人工经验来帮助仿真到现实迁移。奖励函数的调参可能十分繁琐，且罕见的失败案例难以解释。

具体而言，任务奖励函数是多种动机的“平衡点”。首先，由于我们希望机器人能够在没有人工先验的情况下自动发现到达目标的方式，因此较短的奖励持续时间是更可取的，但这也可能导致稀疏奖励和困难的探索。其次，较长的回合长度可以使动作在仿真到现实迁移中不那么激进，但也会使任务奖励变得稀疏。因此，奖励调参十分繁琐，而我们在本文中通过预训练和微调部分规避了这些权衡。

关于失败案例，要达到100%的成功率总是困难的，罕见的失败案例确实存在。然而，与基于模型的控制器（其失败案例易于理解，例如漏步、打滑或意外碰撞）相比，我们的控制器的失败案例更难解释。在这些罕见情况下，机器人可能会在存在可行落脚点时将脚悬空放置，这可能是由于神经网络的奇异性[35]所致。我们相信，对比学习[36]等表示学习技术可能有助于解决这一问题。

七、结论与未来工作

在本文中，我们实现了在具有挑战性的危险地形上进行敏捷四足运动的端到端学习。为此，我们提出使用导航公式化以及一种在先前工作基础上进行了多项改进的探索策略。我们应用两阶段训练来克服挑战性地形上的探索难题，其中针对不同地形的专家策略是从一个通用策略微调而来的。

我们的未来工作将包括：1) 基于在线表示技术（如[23]中的方法）实现地形感知的机载化；2) 训练一个适用于所有类型地形的统一策略以进行运动控制；以及3) 使学习到的策略更具可解释性和鲁棒性。

附录

A. 任务规格

与任务相关的域随机化设置见表III，使用的符号和奖励项见表IV。

表III 不同任务中的域随机化设置

参数	随机化范围
Stones-Everywhere	
回合时长（秒）	[5, 7]
目标距离（米）	[1.5, 4.9]
Stones-2Rows	
回合时长（秒）	[6, 8]
目标距离（米）	[3.5, 4.5]
高度图扫描漂移（米）	[-0.05, 0.05]
Balance-Beams	
回合时长（秒）	[8, 10]
目标距离（米）	[3.5, 4.5]
高度图扫描漂移（米）	[-0.025, 0.025]
质心偏移（米）	x: [-0.15, 0.15] y: [-0.05, 0.05] z: [-0.1, 0.2]
Stepping-Beams	
回合时长（秒）	[5, 7]
目标距离（米）	[2.5, 4.0]

表IV 使用的符号和奖励函数项

符号	描述
t 和 T	当前时间步，以及回合总长度
p 以及 p^*	机器人的二维位置和目标位置
ψ 和 ψ^*	机器人的航向和目标航向
q , $\dot{q}$, 以及 $\ddot{q}$	关节位置、关节速度以及关节速度限制
v , v^H , 以及 ω	线速度、水平线速度以及角速度
z	机器人基座的高度
v_f 以及 F_f	第 f 只脚的线速度和接触力
τ 和 τ_{lim}	动作，即目标关节位置
g	关节的扭矩和扭矩限制
$\delta_T(t_0)$	机器人基座上的投影重力 $= \frac{1}{\tau} \cdot \mathbb{1}(t > T - \tau)$ ，最后一段时间的奖励持续时间掩码
$\delta_p(d_0)$	$\mathbb{1}(\ p_t - p_t^*\ < d_0)$ ，机器人位置掩码
$\delta_\psi(\theta_0)$	$\mathbb{1}(\ \psi_t - \psi_t^*\ < \theta_0)$ ，机器人航向掩码
“S2”	“Stones-2Rows”的缩写
“BB”	“Balance-Beams”的缩写

奖励项	表达式	权重
位置跟踪	$\frac{1}{1 + \ p_t - p_t^*\ ^2}$	$10\delta_T(2)$
	对于“S2”和“BB”	$25\delta_T(4)$
航向跟踪	$\frac{1}{1 + \ \psi_t - \psi_t^*\ ^2}$	$5\delta_p(2)\delta_T(4)$
	对于“S2”和“BB”	$12\delta_p(2.5)\delta_T(4)$
终止惩罚	提前终止的常数	-200
碰撞惩罚	大腿和小腿的常数	-1
关节速度惩罚	$\ q\ ^2$	-0.001
关节速度限制	$\sum_{i=1}^{12} \max(\ q_{i,x}\ - 0.9 \cdot q_{\text{lim},0})$	-1
基座加速度惩罚	$\ v_t\ ^2 + 0.02\ \ddot{q}_t\ ^2$	-0.001
脚部加速度惩罚	$\sum_{f=1}^4 \ \ddot{v}_f\ $	-0.0005
动作速率惩罚	$\ -\dot{q}_t - \dot{q}_{t-1}\ ^2$	-0.01
扭矩惩罚	$\ \tau_t\ ^2$	-0.00001
	针对“BB”	-0.00002
扭矩限制	$\sum_{i=1}^{12} \max(\ \tau_{i,x}\ - \tau_{\text{lim},0})$	-0.2
	对于“BB” w/ $\tau_{\text{lim}} = 0.8\tau_{\text{lim}}$	-0.5
接触力惩罚	$\sum_{f=1}^4 \text{clip}(\ F_{f,x}\ - 700, 0, 700)^2$	-0.000025
不要等待	$\mathbb{1}(\ v_t\ < 0.2)$	$-(1 - \delta_p(1))$
按方向移动	$\cos\langle v_t, p_t^* - p_t \rangle$	前150次迭代为1
保持静止	$2.5\ v_t\ + 1\ \ddot{q}_t\ $	$-\delta_p(0.25)\delta_\psi(0.5)\delta_T(1)$
激进运动	$(v_t^H - 1)^2 \cdot \mathbb{1}(v_t^H > 1)$	0
	用于“S2”和“BB”	-5
站立姿态	$\ z_t - 0.6\ + g_{z_t}^2 + g_{v_z}^2$	0
	对于“S2”和“BB”	$-5\delta_p(0.25)\delta_\psi(0.5)\delta_T(1)$

B. 学习设置

表V中展示了一些与学习相关的设置。

表V 学习设置

配置	值
演员与评论家	多层感知机, 隐藏层大小 (512,256,128)
外部感知	所有观测展平
机器人数量	25 × 16 高度图, 7厘米网格大小
每次迭代的策略步数	4096
将负奖励裁剪为0?	48
随机网络蒸馏 M1	No
随机网络蒸馏 M2	多层感知机, 隐藏层大小 (128,128)
随机网络蒸馏奖励权重	多层感知机, 隐藏层大小 (256,256)
随机网络蒸馏优化权重	1.0
随机网络蒸馏 M1 的损失	1.0
	平均L1损失

致谢

这项工作部分得到了欧盟地平线2020计划资助协议编号852044的支持。

参考文献

[1] A. W. Winkler, C. D. Bellicoso, M. Hutter和J. Buchli, “基于相位末端执行器参数化的腿式系统步态与轨迹优化”, *IEEE机器人与自动化快报*, 第3卷, 第3期, 2018年。[2] F. Jenelten, R. Grandia, F. Farshidian和M. Hutter, “Tamols: 面向腿式系统的地形感知运动优化”, *IEEE机器人学汇刊*, 第38卷, 第6期, 第3395–3413页, 2022年。[3] S. Fahmi, V. Barasuol, D. Esteban, O. Villarreal和C. Semini, “Vital: 基于视觉的地形感知运动用于腿式机器人”, *IEEE机器人学汇刊*, 2022年。[4] R. Grandia, F. Jenelten, S. Yang, F. Farshidian和M. Hutter, “通过非线性模型预测控制实现感知运动”, *IEEE机器人学汇刊*, 2023年。[5] O. Melon, R. Orsolino, D. Surovik, M. Geisert, I. Havoutis和M. Fallon, “基于学习初始化的动态腿式运动滚动时域感知轨迹优化”, 载于2021年IEEE国际机器人与自动化会议 (ICRA)。IEEE, 2021年, 第9805–9811页。[6] F. Jenelten, T. Miki, A. E. Vijayan, M. Bjelonic和M. Hutter, “崎岖地形中的感知运动——在线立足点优化”, *IEEE机器人与自动化快报*, 第5卷, 第4期, 2020年。[7] J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun和M. Hutter, “在挑战性地形上学习四足运动”, *Science Robotics*, 第5卷, 第47期, 第eabc5986页, 2020年。[8] F. Jenelten, J. Hwangbo, F. Tresoldi, C. D. Bellicoso和M. Hutter, “湿滑地面上的动态运动”, *IEEE机器人与自动化快报*, 第4卷, 第4期, 2019年。[9] Z. Zhou, B. Wingo, N. Boyd, S. Hutchinson和Y. Zhao, “面向敏捷四足运动的动量感知轨迹优化与控制”, *IEEE机器人与自动化快报*, 第7卷, 第3期, 2022年。[10] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun和M. Hutter, “在野外学习四足机器人的鲁棒感知运动”, *Science Robotics*, 第7卷, 第62期, 第eabk2822页, 2022年。[11] M. Tranzatto, T. Miki, M. Dharmadhikari, L. Bernreiter, M. Kulkarni, F. Mascarich, O. Andersson, S. Khattak, M. Hutter, R. Siegwart, 等, “Cerberus在DARPA地下挑战赛中”, *Science Robotics*, 第7卷, 第66期, 第eabp9742页, 2022年。[12] A. Agarwal, A. Kumar, J. Malik和D. Pathak, “使用自我中心视觉在挑战性地形中实现腿式运动”, 载于第六届机器人学习年度会议, 2022年。[13] Z. Xie, H. Y. Ling, N. H. Kim和M. van de Panne, “Allsteps: 踏脚石技能的课程驱动学习”, 载于计算机图形学论坛, 第39卷, 第8期。Wiley在线图书馆, 2020年, 第213–224页。[14] V. Tsounis, M. Alge, J. Lee, F. Farshidian和M. Hutter, “Deepgait: 使用深度强化学习的四足步态规划与控制”, *IEEE机器人与自动化快报*, 第5卷, 第2期, 2020年。

[15] Y. Song, A. Romero, M. Müller, V. Koltun和D. Scaramuzza, “《自主竞速的极限: 最优控制与强化学习》”, *《Science Robotics》*, 第8卷, 第1462期, 2023年, 第82卷, 第eadg页。[16] S. Gangapurwala, M. Geisert, R. Orsolino, M. Fallon和I. Havoutis, “Rloc: 基于强化学习与最优控制的地形感知腿部运动”, *《IEEE机器人学汇刊》*, 2022年。[17] Z. Xie, X. Da, B. Babich, A. Garg和M. v. de Panne, “Glide: 基于质心模型的可泛化四足运动”, 载于《机器人算法基础国际研讨会》。施普林格, 2023年, 第523–539页。[18] F. Jenelten, J. He, F. Farshidian和M. Hutter, “Dtc: 深度跟踪控制”, *《Science Robotics》*, 第9卷, 第86期, 第eadh5401页, 2024年。[19] N. Rudin, D. Hoeller, P. Reist和M. Hutter, “《利用大规模并行深度强化学习在数分钟内学会行走》”, 载于《机器人学习会议》。P MLR, 2022年, 第91–100页。[20] N. Rudin, D. Hoeller, M. Bjelonic和M. Hutter, “《通过端到端学习运动与局部导航的高级技能》”, 载于《2022年IEEE/RSJ智能机器人与系统国际会议 (IROS 2022) 》。IEEE, 2022年。[21] Y. Burda, H. Edwards, A. J. Storkey和O. Klimov, “《基于随机网络蒸馏的探索》”, 载于《第七届国际学习表征会议》, 2019年。[22] D. Hoeller, N. Rudin, D. Sako和M. Hutter, “Anymal跑酷: 学习四足机器人的敏捷导航”, *《Science Robotics》*, 第9卷, 第88期, 第eadi7566页, 2024年。[23] D. Hoeller, N. Rudin, C. Choy, A. Anandkumar和M. Hutter, “结构化地形上运动的神经场景表征”, *《IEEE机器人与自动化快报》*, 第7卷, 第4期, 2022年。[24] J. Schulman, F. Wolski, P. Dhariwal, A. Radford和O. Klimov, “近端策略优化算法”, arXiv预印本arXiv:1707.06347, 2017年。[25] V. Makovychuk, L. Wawrzyniak, Y. Guo, M. Lu, K. Storey, M. Macklin, D. Hoeller, N. Rudin, A. Allshire, A. Handa和G. State, “Isaac Gym: 用于机器人学习的高性能基于GPU的物理仿真”, 载于《第三十五届神经信息处理系统大会数据集与基准测试轨道 (第二轮) 》, 2021年。[26] E. Chane-Sane, C. Schmid和I. Laptev, “基于想象子目标的目标条件强化学习”, 载于《国际机器学习大会》。PMLR, 2021年, 第1430–1440页。[27] C. Yang, K. Yuan, Q. Zhu, W. Yu和Z. Li, “自适应腿部运动的多专家学习”, *《Science Robotics》*, 第5卷, 第49期, 第eabb2174页, 2020年。[28] D. Pathak, P. Agrawal, A. A. Efros和T. Darrell, “基于自监督预测的好奇心驱动探索”, 载于《国际机器学习大会》。PMLR, 2017年, 第2778–2787页。[29] Y. Burda, H. Edwards, D. Pathak, A. Storkey, T. Darrell和A. A. Efros, “《好奇心驱动学习的大规模研究》”, 载于《国际学习表征会议》, 2019年。[30] H. Sun, L. Han, R. Yang, X. Ma, J. Guo和B. Zhou, “基于线性奖励塑形的乐观好奇心探索与保守利用”, 载于《神经信息处理系统大会进展》, 2022年。[31] C. Zhang, W. Yu和Z. Li, “基于可达性的聚类用于高效学习运动技能”, 载于《2022年国际机器人与自动化会议 (ICRA) 》。IEEE, 2022年, 第1600–1606页。[32] F. Abdolhosseini, H. Y. Ling, Z. Xie, X. B. Peng和M. Van de Panne, “论对称运动的学习”, 载于《第12届ACM SIGGRAPH运动、交互与游戏会议论文集》, 2019年, 第1–10页。[33] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba和P. Abbeel, “用于将深度神经网络从仿真迁移到真实世界的域随机化”, 载于《2017年IEEE/RSJ智能机器人与系统国际会议 (IROS) 》。IEEE, 2017年, 第23–30页。[34] Z. Xie, X. Da, M. Van de Panne, B. Babich和A. Garg, “动力学随机化再探: 四足运动案例研究”, 载于《2021年IEEE国际机器人与自动化会议 (ICRA) 》。IEEE, 2021年, 第4955–4961页。[35] E. Orhan和X. Pitkow, “跳跃连接消除奇异性”, 载于《国际学习表征会议》, 2018年。[36] M. Laskin, A. Srinivas和P. Abbeel, “CURL: 用于强化学习的对比无监督表征”, 载于《国际机器学习大会》。PMLR, 2020年, 第5639–5650页。