

基于强化学习的腿式与轮腿式机器人盲态爬楼梯

Simon Chamorro^{1,2}, Victor Klemm³, Miguel de la Iglesia Valls⁴, Christopher Pal¹和 Roland Siegwart²

摘要——近年来，腿式与轮腿式机器人在各种主要为人类设计的环境中执行任务时日益受到重视。这些机器人面临的重大挑战之一是爬楼梯能力有限，这限制了它们在多层环境中的功能。本研究提出了一种旨在解决这一局限的方法，利用强化学习开发一种适用于多种机器人的通用控制器。与传统基于速度的控制器不同，我们的方法基于强化学习任务的基于位置的公式化，我们证明这对爬楼梯至关重要。此外，该方法利用非对称演员-评论家结构，在训练期间能够利用模拟环境中的特权信息，同时在现实世界部署中消除对外部感受传感器的依赖。所提出方法的另一个关键特征是控制器中引入布尔观测，从而能够激活或停用爬楼梯模式。我们在不同四足机器人和双足机器人的仿真中展示了结果，并展示了我们的方法如何使平衡机器人Ascento在现实世界中攀爬15厘米高的楼梯，而这一任务此前对该机器人来说是不可能完成的。

I. 引言

移动地面机器人已被广泛研究和应用于各种任务，如配送、检查和安保，[1]。虽然轮式机器人在长距离行驶方面效率很高，但它们缺乏穿越楼梯等障碍物的敏捷性。相比之下，腿式系统更加敏捷，但缺乏效率和速度[2]。混合轮腿系统已被开发出来，以利用这两种技术的优势，但由于其复杂动力学，给控制带来了重大挑战[3]。近年来，强化学习（RL）已成为控制这些复杂机器人系统的一种有前景的技术。特别是，利用强化学习为轮腿四足机器人开发控制器已取得了令人瞩目的成果[4], [5]。

在这项工作中，我们研究了腿式机器人和轮腿式机器人的爬楼梯问题。这对双足机器人来说尤其困难，因为它在迈步时需要保持仅在一个接触点上的平衡，这要求非常动态的运动。我们提出了一种方法，通过利用特权地形信息在非对称演员-评论家架构中开发步态反射，使腿式机器人和轮腿式机器人都能爬楼梯。

¹计算机与软件工程系，蒙特利尔综合理工学院，2900 Boul. Edouard-Montpetit, 魁北克省，加拿大。电子邮件：simon.chamorro@polymtl.ca²自主系统实验室，苏黎世联邦理工学院，瑞士。³机器人系统实验室，苏黎世联邦理工学院，瑞士。⁴Ascento Robotics, 苏黎世，瑞士。补充视频：<https://youtu.be/Ec6ar8BVJh4>。




图1: 提出方法: Ascento机器人、宇树Go1、Cassie和轮式ANYmal攀爬台阶。

在[6]中，Lee等人展示了在四足机器人上实现的令人感兴趣的反射行为[7]。Siekmann等人也证明了使用Cassie机器人可以盲目地穿越楼梯[8]。此外，我们研究了布尔模式切换的概念用于爬楼梯，从而允许同一控制策略在常规地形和楼梯攀登上都表现出良好的性能。我们的控制器仅使用这种布尔观测作为其唯一的外部感知信息，并且不依赖定位系统。我们的主要贡献如下：

- 1) 我们提出了一种强化学习任务公式化方法，用于训练四足机器人、双足机器人和轮腿平衡机器人攀爬楼梯的策略。
- 2) 我们的方法不需要任何感知数据或定位系统（如同步定位与地图构建（SLAM）或全球定位系统（GPS）），因此可以轻松集成到标准控制栈中。
- 3) 我们提出的系统能够成功迁移到现实世界，并允许轮式双足机器人Ascento攀爬15厘米高的台阶。

II. 文献综述

A. 基于强化学习的腿式运动

依赖优化的基于模型的控制方法，如模型预测控制（MPC）和轨迹优化，在过去[9]中已广泛应用于腿式运动问题。然而，这些方法在执行过程中需要系统的动力学模型，导致高维系统的复杂度较高。近年来，强化学习




图2: 训练与部署期间的系统概览: 在每个训练步骤中, 算法接收观测和特权信息。Actor为下一个仿真步长输出动作。在部署期间, Actor仅接收观测并为机器人输出要执行的动作。

已成为控制腿式系统的一种有前景的替代方案, 展现出前所未有的鲁棒性。多项近期工作已成功利用无模型强化学习解决了ANYmal机器人 [10] 的运动问题。

2019年, Hwuangbo等人 [11] 提出了使用信任区域策略优化 (TRPO) [12], 和执行器网络来更精确地在仿真中建模电机的强化学习控制策略。该策略以期望的基座速度为条件, 并输出关节位置目标。另一项由Lee等人 [7], 提出的工作在此基础上构建, 并提出了一种师生架构, 以在训练过程中纳入外部感知信息。教师策略使用强化学习和特权信息进行训练, 输出关节位置目标。随后, 学生策略仅通过以本体感觉数据为输入的模仿学习进行训练。最后, 在2022年, Miki等人 [13] 对该方法进行了扩展, 通过信念编码器纳入本体感觉和外部感知信息, 实现了更高效的崎岖地形导航。总体而言, 这些工作的成果是一个能够可靠地导航崎岖地形的稳健控制器。然而, 这些方法的一个缺点是学习策略所需的训练时间。

最近, Rudin等人 [14] 提出了一种新环境, 能够利用单个图形处理器 (GPU) 并行模拟数千个机器人。利用这一框架和标准的近端策略优化 (PPO) 实现来学习运动策略, 他们在不到20分钟的训练时间内取得了可迁移至现实世界的稳定结果。此外, Rudin等人 [15] 提出了一种端到端策略, 用于在陡峭楼梯和地形大间隙等挑战性环境中进行局部导航, 克服了传统路径规划和运动控制的局限性。主要贡献在于他们提出的任务制定方法, 该方法在回合结束前为智能体提供一个位置目标, 而非连续的速度曲线进行跟踪。这使得路径和运动步态的选择更加灵活。该方法使机器人能够学习跳跃等复杂行为。我们基于这一制定方法进行构建, 并证明其对平衡型机器人的越障尤为有效。然而, 该方法在部署时需要定位系统和环境映射来获取地形信息。我们通过非对称演员-评论家制定方法解决了这一局限性。

我们通过非对称演员-评论家制定方法解决了这一局限性。

B. 混合轮腿运动

混合轮腿式机器人旨在结合腿式机器人的敏捷性与轮式机器人的效率。近年来, 已有大量工作致力于利用模型预测控制 (MPC) 和轨迹优化等其他方法为这些机器人开发控制算法 [16], [17], [18], [19], [20]。然而, 由于所涉及的高度非线性系统动力学的复杂性, 这些方法的开发极具挑战性。与纯腿式机器人的情况类似, 强化学习 (RL) 作为一种替代方法已展现出非常有前景的结果。2022年, Lee等人 [4] 提出了一种在仿真中训练的无模型强化学习方法, 以学习基于速度的控制器。此外, Vollenweider等人 [5] 提出了一个利用运动先验和强化学习来学习复杂运动 (如两轮站立和坐回原位) 的框架。他们还展示了机器人在保持该构型的同时, 能够实现两轮平衡并跟踪速度指令的能力。然而, 该方法仅能在平坦地形和非常小的障碍物上导航。

III. 方法论

图2展示了所提出架构在训练和部署过程中的概览。在以下章节中, 我们将介绍用于训练的学习环境、强化学习任务公式化、训练流程以及包括部署细节在内的仿真到现实迁移工作。

A. 学习环境

1) 仿真器: 我们使用Isaac Gym [21] 作为训练平台, 该平台专为强化学习应用而设计。与其他广泛使用的仿真器 (如Raisim [22] 和MuJoCo [23],) 相比, Isaac Gym的GPU加速架构凭借其高度并行化能力, 能够显著加快智能体的训练速度。Isaac Gym支持域随机化技术 [24], 该技术通过在训练过程中引入环境变化来增强强化学习智能体的鲁棒性, 从而有助于将学习到的策略迁移到现实世界。




图3: 不同训练地形: 第一行从左到右: 单级台阶、楼梯、平滑金字塔。第二行: 粗糙金字塔、离散障碍物、平滑斜坡。

2) 学习算法: 我们使用强化学习算法PPO, 并采用非对称演员-评论家结构 [25]。这是强化学习中标准演员-评论家算法的一种变体, 其中演员和评论家使用独立的网络, 使它们能够独立更新 [26], [27]。在本工作中, 我们使用了苏黎世联邦理工学院机器人系统实验室 (RSL) 发布的开源PPO实现 [14]¹。由于我们处理的是有限时域任务表述 [15], 因此移除了该实现中的自举 (bootstrapping) 元素。我们所有的实验均在5k次学习迭代后收敛。对于所有的训练和实验, 我们使用了一块Nvidia DGX A100 GPU, 配备16 GB内存。

3) 地形: 我们的环境被划分为6米 $\times$ 6米的地形。共有六列: 两列为楼梯, 其余四种地形各一列。共有十二行, 用于增加课程难度。我们注意到, 当智能体暴露在更多种类的障碍物中时, 其策略更加稳健。我们使用以下类型的地形, 如图3所示:

楼梯: 楼梯列分为两个部分。前半部分, 即六行, 是包含一个台阶且高度逐渐增加的地形。台阶前后留有空间。这些地形旨在让智能体在应对连续楼梯地形之前, 先学习上台阶的基本动作。后半部分的行包含连续的五级台阶楼梯段。台阶高度和宽度根据我们训练的机器人而变化。

平滑斜坡: 平滑斜坡是倾斜平面。这些地形在训练轮式机器人以减少漂移、迫使其保持稳定位置时尤为重要。斜坡的倾斜度范围从0度到8.5度。

离散障碍物: 离散障碍物是在平坦地形上生成的随机矩形障碍物。其高度最高可达10厘米, 长度和宽度的尺寸在1米到2米之间变化。

平滑与粗糙金字塔斜坡: 这些环境是中间带有平坦平台的金字塔。其倾斜度从0度到8.5度不等。对于粗糙金字塔, 其地形高度带有高达5厘米的随机噪声, 使其表面崎岖不平。

4) 机器人模型: 我们在四种不同的机器人上评估我们的方法: 宇树Go1四足机器人 [28], 双足

表 I: 观测与特权信息。

符号	观测	单位	系数大小噪声 (%)		
$\vec{\theta}$	角速度	弧度/秒	0.25	3	± 20
$\vec{\gamma}$	投影重力	N/A	1.0	3	± 5
$\vec{g}_{dir}$	目标方向	N/A	1.0	2	± 0
θ_{err}	航向误差	rad	1.0	1	± 0
h_{target}	高度指令	m	1.0	1	± 0
b	地形布尔值	N/A	1.0	1	± 0
$\vec{q}$	关节位置	rad	1.0	4	± 1
$\vec{\dot{q}}$	关节速度	弧度/秒	0.05	6	± 150
$\vec{a}_{last}$	最后动作	弧度 & 弧度/秒	1.0	6	± 0
符号	特权信息	单位	系数大小噪声 (%)		
v_x	线速度	m/s	0.25	1	-
h	基座高度	m	1.0	3	-
$\vec{g}_{rel}$	相对目标位置	m	1.0	3	-
$H_{terrain}$	地形高度	m	5.0	187	-
f_{wheels}	接触力	N	0.01	6	-
μ	摩擦系数	N/A	1.0	1	-

机器人Cassie [29], 轮腿式平衡机器人Ascento [30] 以及轮腿四足机器人ANYmal on Wheels [16], 如图1所示。对于ANYmal on Wheels, 我们在四足模式和双足模式下进行实验。

B. 任务制定

我们受Rudin等人 [15]的启发, 将强化学习任务制定为基于位置的导航任务。每个回合持续6秒 ($T = 6s$), 要完成任务, 机器人基座需要在回合结束前到达目标位置。对于台阶和楼梯地形, 机器人总是在台阶底部生成, 距离台阶0.3至1米, 并大致面向台阶 ($\pm 0.1rad$)。目标在顶部采样, 其航向也在相同范围内。对于其他地形, 机器人在地形中间生成, 目标在1米半径内以随机朝向采样。图4展示了我们在台阶环境中的强化学习任务。

1) 状态: 我们采用非对称演员-评论家结构, 因此将状态分为两部分: 观测, 演员和评论家均可访问; 以及特权信息, 仅在训练期间评论家可访问。表I列出了演员在训练和部署期间使用的观测以及特权信息。首先, 特权信息包含机器人的线速度和绝对基座高度。这些值在真实机器人上不易获取, 因此未包含在演员的观测中。它还包含目标相对位置在 x, y, z , 而不仅仅是 x, y 平面中的二维方向。最后, 我们提供来自仿真器的真实信息, 如地形高度测量、接触力和地形摩擦系数。这使得评论家能够定位楼梯并为演员提供更好的指导。高度测量从机器人周围 $1.6 \times 1.0m$ 网格中等间距采样。接触力使用窗口为5个时间步 (相当于0.1秒) 的平均滑动窗口进行滤波。此外, 观测包含均匀噪声供演员使用, 而评论家则没有。

¹https://github.com/leggedrobotics/rsl_rl





图4: **任务设置:** a)目标位姿以绿色和红色标记。黄色点表示地形高度测量, 这些测量属于关于地形的特权信息的一部分。b) 训练课程: 不同的训练地形, 参见第III-A.3节。从左到右难度逐渐增加。楼梯地形, 在训练期间地形布尔值设置为1, 以绿色标出。在其他地形中, 此观测设置为0。

2) 动作: 动作是机器人相关维度的向量。对于关节, 指令直接解释为由低级PD控制器跟踪的目标位置。类似地, 动作被解释为轮式关节的目标角速度。

3) 奖励: 我们的任务特定奖励在表II中呈现。基于位置的任务表述背后的主要思想是给予Actor更多自由去探索不同的策略来攀爬台阶, 并找到可能难以通过手动设计获得的良好解决方案。因此, 我们任务的主要奖励, 奖励#1, 仅在回合的最后2秒内生效 ($T_r = 2s$)。该奖励鼓励机器人在回合结束时处于目标位置, 而不添加任何进一步约束。为了帮助收敛, 奖励#2是一个临时奖励, 在智能体达到奖励#1最佳可能性能的一半之前给予。它为机器人提供了朝向目标运动的激励。另一方面, 奖励#3惩罚停滞, 除非机器人已经接近目标。最后, 奖励#4鼓励机器人面向目标。除了这些奖励之外, 我们使用标准的机器人特定塑形奖励来鼓励平滑稳定运动, 例如奖励脚部腾空时间和惩罚腿式机器人的关节加速度 [14]。

表 II: 奖励。

#	奖励	公式	系数
1	$r_{position}$	$\frac{1}{T_r + 1 - \ \vec{x} - \vec{r}_{goal}\ ^2}$ 如果 $t > T - T_r$	10.0
2	$r_{pos.bias}$	$\frac{\vec{x} \cdot (\vec{r}_{goal} - \vec{x})}{\ \vec{x}\ \ \vec{r}_{goal} - \vec{x}\ }$	1.0
3	r_{stall}	-1 如果 $\ \vec{x}\ < 0.1m/s$ 并且 $\ \vec{x} - \vec{r}_{goal}\ > 0.5m$	1.0
4	$r_{face.goal}$	$-\ \theta - \theta_{goal}\ $ 如果 $\ \vec{x} - \vec{r}_{goal}\ > 0.5m$	0.1

4) 课程学习: 我们在环境中生成4096个机器人, 它们均匀分布在各类型地形上, 并从最简单的关卡开始。我们采用了 [14]中的游戏启发式课程学习。如果机器人距离目标在20厘米以内, 则将其提升一个关卡; 如果机器人距离目标超过50厘米, 则将其降级, 除非它已经处于最低

关卡。如果机器人达到最高关卡, 我们则进行随机分配以避免灾难性遗忘。图4展示了环境的俯视图。

C. 仿真到现实迁移

在训练过程中, 我们使用域随机化来促进向现实世界的迁移。首先, 我们对地形的摩擦力进行随机化。对于轮腿式机器人, 我们注意到如果摩擦力过高, 机器人会学会利用轮子与台阶之间的抓力来攀爬。虽然这种策略在仿真器的接触模型下有效, 但由于未建模的轮胎动力学, 它无法迁移到现实世界。在现实世界中, 轮胎的反弹和轮胎轮廓的不规则性可能导致滑移, 因为轮子会瞬间失去与台阶的接触, 这将在IV-B中进一步讨论。此外, 我们采用了文献中的标准域随机化技术 [31], [32], 并通过在训练过程中不定期地随机分配基座线速度来对机器人施加随机“推力”。速度在0到0.5米/秒之间变化, 并且最多每3秒施加一次。这有助于提高对扰动和期望轨迹偏差的整体鲁棒性。最后, 模拟控制回路中的延迟尤为重要 [33]。我们通过以50%的概率随机使用前一时间步的状态来计算后续动作来实现这一点。这模拟了20毫秒的延迟。

1) 现实世界部署: 与仿真中的部署不同, 在仿真中观测可以直接从仿真器获取, 而在现实世界部署中, 我们需要测量并估计所需的数量。我们将策略部署在最新的Ascento机器人原型上。在现实世界部署期间, 我们不再需要特权信息或Critic。为了使用学习策略(即演员网络)控制机器人, 我们按如下方式重构观测:

本体感觉状态: 本体感觉状态包括关节信息以及姿态信息。关节位置通过关节编码器测量, 关节速度则根据上一个控制迭代期间关节位置的变化进行数值计算。角速度和投影重力由惯性测量单元 (IMU) 数据计算得出。

表III：台阶攀爬的仿真结果。

机器人	Exp.	成功率 (%)					
台阶高度		14cm	18cm	22cm	26cm	30cm	其他地形
宇树Go1	布尔开启	99.7	99.7	98.5	43.1	*0.0	97.7
	布尔关闭	98.8	98.3	93.5	19.1	*0.0	98.6
	无布尔	100.0	99.8	99.6	56.4	*0.0	98.7
	无特权信息	15.4	12.9	8.8	3.9	*1.0	95.3
Cassie	布尔开启	100.0	100.0	99.7	99.0	98.3	98.8
	布尔关闭	97.4	92.2	87.8	78.2	64.7	98.1
	无布尔	99.2	97.2	90.6	79.6	74.3	69.4
	无特权信息	0.0	0.0	0.0	0.0	0.0	22.3
Ascento	布尔开启	87.6	82.3	69.4	*31.4	*1.4	97.7
	布尔关闭	23.2	18.6	9.6	*0.1	*0.0	98.1
	无布尔	87.9	82.5	47.9	*4.4	*0.0	62.5
	无特权信息	0.0	0.0	0.0	*0.0	*0.0	80.2
ANYmal轮式(四足)	布尔开启	93.2	93.8	90.2	61.1	18.7	95.9
	布尔关闭	73.8	40.8	18.9	4.8	0.5	97.7
	无布尔	34.3	37.9	26.4	34.4	14.8	20.9
	无特权信息	0.3	0.0	0.0	0.0	0.0	62.7
ANYmal轮式(双足)	布尔开启	93.9	92.8	93.6	93.6	93.4	85.0
	布尔关闭	71.0	45.4	27.8	14.2	6.2	94.9
	无布尔	68.9	70.0	58.2	35.0	34.4	85.7
	无特权信息	0.0	0.0	0.0	0.0	0.0	78.8

实验：布尔开启：我们提出的方法，地形布尔值设为1。布尔关闭：我们提出的方法，地形布尔值设为0。无布尔：消融实验，训练时不使用地形布尔观测。无特权信息：消融实验，训练时不使用特权信息。**图例：**成功表示机器人到达目标 ± 20 厘米处。***注：**该高度超过了机器人训练时的台阶高度。

指令：指令包括目标方向、基座高度目标、航向误差、地形布尔值和最后动作。在我们的实验中，我们使用遥控器提供所有这些指令，最后动作除外，它们存储在内存中。在用户体验方面，对前进位置和航向误差的指令控制与基于速度的控制器操作方式类似，其额外优势在于机器人可以略微偏离指令以成功克服障碍物。

IV. 实验与结果

A. 仿真结果

我们在所有机器人上评估了我们的方法，并进行了消融研究，以展示使用特权信息的非对称演员-评论家结构以及地形布尔观测的重要性。表III显示了每种机器人攀爬单级台阶的成功率。每个实验对每种机器人进行了2000次试验。首先，我们得出结论，特权信息对于成功学习任务至关重要。我们主要将此归因于地形信息，它有助于引导Actor形成地形谨慎行为。另一方面，所提出的布尔观测对双足机器人尤为重要，因为它使它们能够在学习导航其他地形的稳健通用策略的同时，学习攀爬楼梯的不同技能。这一点将在第IV-A.2节中进一步讨论。

1) 位置控制分析：所有训练后的机器人使用我们的方法在18cm标准高度台阶上均实现了高于75%的成功率。图5展示了Ascento机器人使用我们的策略在仿真中登上20cm台阶时的速度曲线示例。可以看出，控制器采用了高度非线性的速度曲线。




图5：上台阶动作：使用我们方法的上台阶动作速度曲线。

机器人在轨迹起始阶段加速以接近目标。然而，当它到达台阶时，会减速并执行学习到的上台阶动作，随后再次加速以到达目标。我们无法通过纯基于速度的方法获得这种行为，因为这类方法中机器人被约束为遵循特定速度。在这里，我们仅提供朝向目标的方向，机器人可以自由调整其速度和路径以克服途中的台阶。此外，需要牢记的是，控制器除了布尔观测外不使用任何感知信息，并且它不知道目标的确切位置。台阶的检测通过本体感觉实现。Ascento机器人学会了一条腿略微领先于另一条腿前进，这使得它在碰到台阶时能够推断出台阶的存在，从而引发踏步反射。我们的任务制定以及非对称演员-评论家的使用，是发现这一行为的关键要素。事实上，教师-学生架构未能实现踏步反射，因为学习到的教师策略严重依赖通过感知来检测台阶的精确定位。

2) 地形布尔值重要性：地形布尔观测对于所提方法的重要性，在应用于双足机器人和轮式腿机器人时尤为明显。事实上，它使机器人能够学习爬楼梯技能的专业知识，同时不损害在崎岖地形上的性能。表III显示，Cassie、Ascento和轮式ANYmal在楼梯上的成功率，在布尔开启实验中高于无布尔消融实验，而Bool Off变体在其他地形上表现更优。同一策略成功地在布尔观测条件下学习了这两种行为。例如，我们注意到为Cassie学习到的策略在存在地形布尔值时采用较慢的步态和更高的步幅。这使其在脚部碰撞台阶时能够保持更高的稳定性并翻越台阶。当关闭布尔值时，它采用更快的步态，这在其他地形上更为高效。类似地，Ascento在楼梯模式下展现出更大的腿部劈叉，这种姿势使其能够在本体感觉检测到台阶时抬起前腿。在无布尔消融实验中省略地形布尔值时，必须做出妥协以最大化在所有地形上的性能，




图6: 真实世界结果: Ascento机器人使用我们的学习策略登上15厘米台阶。图像以4 Hz频率拍摄。

这导致策略不够专门化。另一方面, 完全训练独立的策略会导致鲁棒性降低, 因为它们无法受益于所有模拟经验。最后, 轮式ANYmal也表现出有趣的行为。在四足和双足模式下, 它学会主要使用轮子移动, 并在遇到台阶时迈步。这种行为在没有布尔值的情况下不会形成, 因此成功率较低。

B. 真实世界结果

我们的策略使Ascento能够攀爬15厘米的台阶。图6逐步展示了其行为, 我们还在补充视频²中展示了成功的攀爬过程。可以看到, 机器人以轻微的腿部劈叉和一定的速度驶向台阶。左轮首先接触台阶, 在一定的抓地力作用下开始向上移动。车轮与台阶之间存在一定的滑移, 但随着机器人从本体感觉状态中推断出台阶的存在, 它抬起左腿。随后, 右腿跟上, 机器人在台阶顶部稳定下来。这些结果表明, 我们的方法对于诸如爬楼梯之类的复杂任务具有很好的前景, 因为此版本的Ascento机器人此前无法使用任何控制器克服这一高度的台阶。在实验过程中, 我们注意到, 在利用速度和抓地力接触台阶的行为与仅依赖逐条腿迈上台阶的行为之间取得折衷非常重要。我们通过调整第III-B.3节中描述的塑形奖励来实现这一点。一方面, 采用前述行为的策略会因回踢过程中的滑移而失败。与台阶碰撞会导致瞬间失去接触, 因此无法向上攀爬, 因为仿真中并未完美建模与台阶边缘的碰撞和摩擦力。另一方面, 仅依赖逐条腿迈上台阶的行为会因激进机动中驱动响应的仿真到现实差距而失败。³

C. 仿真到现实迁移

如第III-C节所述, 在现实世界中部署学习策略时, 存在仿真中未捕捉到的延迟 [33]。这对于攀爬台阶尤为重要, 因为这是一个非常动态的动作, 时机至关重要。在我们的补充材料视频中, 我们展示了未考虑这种仿真到现实差距的学习策略非常不稳定。它们不

能抵抗扰动, 并且在登上台阶时表现出非常急促的行为。当使用Ascento攀爬台阶时, 关节会出现高频振荡, 部分关节速度峰值达到15弧度/秒。在加入延迟随机化后, 我们可以看到策略变得更加稳健和平滑, 成功攀爬同一台阶时没有任何关节速度超过1.5弧度/秒。

V. 结论

总之, 我们提出了一种利用强化学习训练控制器的方法, 使腿式机器人和轮腿式机器人具备爬楼梯能力。我们提出的方法不同于传统的基于速度的方法, 而是采用基于位置的强化学习任务。我们使用非对称 Actor-Critic架构, 在训练期间利用特权信息, 并在部署时无需这些数据。我们引入了一个布尔观测作为爬楼梯的模式切换, 这一特性在双足机器人的其他地形上保持鲁棒性的同时, 对在该任务上取得良好效果起到了关键作用。这些技术和方法的运用催生了一个“盲”控制器, 它不需要感知传感器信息或定位系统。我们的方法使Ascento能够攀爬15厘米高的台阶, 这是该机器人原型此前无法实现的成就。

A. 局限性与未来工作

尽管我们的强化学习控制器在实现和实际应用方面取得了成功, 为后续的改进和扩展奠定了坚实基础, 但仍存在一些局限性。首先, 虽然我们的方法不需要关于周围地形的精确信息, 但它确实需要访问所提出的地形布尔值。未来一个有趣的研究方向可以探索从原始感知数据(如图像)中推断该布尔观测的可能性。地形布尔值的概念可以进一步扩展, 以包含多个独热编码地形, 甚至是一个近似的潜在表示。这一概念与快速运动适应相关, 其中策略学习从机器人的状态历史中推断物理参数的表示 [34], [35]。或者, 可以将深度图像等原始传感器信息添加到观测中, 类似于 [36]。然而, 这将增加复杂性和对感知的依赖。

致谢

这项工作得到了魁北克研究基金(FRQNT)、数据价值化研究所(IVADO)以及Mitacs通过其Globalink项目的资助。

²视频链接: <https://youtu.be/Ec6438arBVJh> 在训练过程中使用基于真实世界数据的执行器模型, 如 [11], 所述, 未来可进一步促进仿真到现实迁移。

参考文献

- [1] F. J. Rubio Montoya, F. J. Valero Cabello和C. Llopis Albert, “移动机器人综述: 概念、方法、理论框架及应用,” 国际先进机器人系统杂志, 第16卷, 第2期, 第1–22页, 2019年。[2] P. Biswal和P. K. Mohanty, “四足步行机器人发展综述,” 艾因夏姆斯工程杂志, 第12卷, 第2期, 第2017–2031页, 2021年。[3] M. Bjelonic, V. Klemm, J. Lee和M. Hutter, “轮腿式机器人综述,” 自然环境中的机器人技术: *CLAWAR 2022*, 第83–94页, 2022年。[4] J. Lee, M. Bjelonic和M. Hutter, “基于深度强化学习的轮腿式四足机器人控制,” 载于自然环境中的机器人技术: *CLAWAR 2022*. Springer, 2022年, 第119–127页。[5] E. Vollenweider, M. Bjelonic, V. Klemm, N. Rudin, J. Lee和M. Hutter, “通过强化学习中的多重对抗运动先验实现高级技能,” *arXiv预印本arXiv:2203.14912*, 2022年。[6] Y. Ma, F. Farshidian和M. Hutter, “学习腿式移动操作机器人的机械臂辅助跌倒损伤减轻与恢复,” 载于2023年IEEE国际机器人与自动化会议 (ICRA), 2023年, 第12149–12155页。[7] J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun和M. Hutter, “在复杂地形上学习四足运动,” 科学机器人, 第5卷, 第47期, 第eabc5986页, 2020年。[8] J. Siekmann, K. Green, J. Warila, A. Fern和J. Hurst, “通过仿真到现实的强化学习实现无视觉双足楼梯穿越,” *arXiv预印本arXiv:2105.08328*, 2021年。[9] P. M. Wensing, M. Posa, Y. Hu, A. Escande, N. Mansard和A. Del Prete, “动态腿式机器人的基于优化控制,” *arXiv预印本arXiv:2211.11644*, 2022年。[10] M. Hutter, C. Gehring, D. Jud, A. Lauber, C. D. Bellicoso, V. Tsounis, J. Hwangbo, K. Bodie, P. Fankhauser, M. Bloesch, 等, “ANYmal——一种高机动性动态四足机器人,” 载于2016年IEEE/RSJ智能机器人与系统国际会议 (IROS)。IEEE, 2016年, 第38–44页。[11] J. Hwangbo, J. Lee, A. Dosovitskiy, D. Bellicoso, V. Tsounis, V. Koltun和M. Hutter, “为腿式机器人学习敏捷动态运动技能,” 科学机器人, 第4卷, 第26期, 第eaau5872页, 2019年。[12] J. Schulman, S. Levine, P. Abbeel, M. Jordan和P. Moritz, “信任区域策略优化,” 载于国际机器学习大会。PMLR, 2015年, 第1889–1897页。[13] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun和M. Hutter, “在野外学习四足机器人的鲁棒感知运动,” 科学机器人, 第7卷, 第62期, 第eabk2822页, 2022年。[14] N. Rudin, D. Hoeller, P. Reist和M. Hutter, “利用大规模并行深度强化学习在几分钟内学会行走,” 载于机器人学习会议。PMLR, 2022年, 第91–100页。[15] N. Rudin, D. Hoeller, M. Bjelonic和M. Hutter, “通过端到端学习运动与局部导航实现高级技能,” 载于2022年IEEE/RSJ智能机器人与系统国际会议 (IROS)。IEEE, 2022年, 第2497–2503页。[16] M. Bjelonic, C. D. Bellicoso, Y. de Viragh, D. Sako, F. D. Tresoldi, F. Jenelten和M. Hutter, “继续滚动——轮式四足机器人的全身运动控制与规划,” IEEE机器人与自动化快报, 第4卷, 第2期, 第2116–2123页, 2019年。[17] M. Bjelonic, P. K. Sankar, C. D. Bellicoso, H. Vallery和M. Hutter, “深入滚动——基于在线轨迹优化的轮腿式机器人混合运动,” IEEE机器人与自动化快报, 第5卷, 第2期, 第3626–3633页, 2020年。[18] M. Bjelonic, R. Grandia, O. Harley, C. Galliard, S. Zimmermann和M. Hutter, “全身模型预测控制与在线步态序列生成, 用于轮腿式机器人,” 载于2021年IEEE/RSJ智能机器人与系统国际会议 (IROS)。IEEE, 2021年, 第8388–8395页。[19] V. Klemm, A. Morra, L. Gulich, D. Mannhart, D. Rohr, M. Kamel, Y. de Viragh, 和 R. Siegwart, “具有运动学闭环的轮式双足机器人的LQR辅助全身控制,” IEEE机器人与自动化快报, 第5卷, 第2期, 第3745–3752页, 2020年。[20] V. Klemm, Y. de Viragh, D. Rohr, R. Siegwart, 和 M. Tognon, “具有接触切换和冲击的轮式平衡机器人的非光滑轨迹优化,” 已接收至IEEE机器人学汇刊, 2024年。[21] V. Makoviychuk, L. Wawrzyniak, Y. Guo, M. Lu, K. Storey, M. Macklin, D. Hoeller, N. Rudin, A. Allshire, A. Handa, 等人, “Isaac Gym: 用于机器人学习的高性能基于GPU的物理仿真,” *arXiv预印本arXiv:2108.10470*, 2021年。[22] J. Hwangbo, J. Lee, 和 M. Hutter, “用于求解接触动力学的逐接触点迭代法,” IEEE机器人与自动化快报, 第3卷, 第2期, 第895–902页, 2018年。[23] E. Todorov, T. Erez, 和 Y. Tassa, “MuJoCo: 用于基于模型的控制的物理引擎,” 载于2012年IEEE/RSJ智能机器人与系统国际会议。IEEE, 2012年, 第5026–5033页。[24] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, 和 P. Abbeel, “用于将深度神经网络从仿真迁移到现实世界的域随机化,” 载于2017年IEEE/RSJ智能机器人与系统国际会议 (IROS)。IEEE, 2017年, 第23–30页。[25] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, 和 O. Klimov, “近端策略优化算法,” *arXiv预印本arXiv:1707.06347*, 2017年。[26] V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver, 和 K. Kavukcuoglu, “深度强化学习的异步方法,” 载于国际机器学习大会。PMLR, 2016年, 第1928–1937页。[27] I. Grondman, L. Busoniu, G. A. D. Lopes, 和 R. Babuska, “演员-评论家强化学习综述: 标准与自然策略梯度,” IEEE系统、人与控制论汇刊, C部分 (应用与综述), 第42卷, 第6期, 第1291–1307页, 2012年。[28] 宇树, “宇树Go1,” <https://www.unitree.com/go1/>, 访问时间: 2023年。[29] Agility Robotics, “Cassie,” <https://agilityrobotics.com/>, 访问时间: 2023年。[30] V. Klemm, A. Morra, C. Salzmann, F. Tschopp, K. Bodie, L. Gulich, N. Kung, D. Mannhart, C. Pfister, M. Vierneisel, 等人, “Ascento: 一种两轮跳跃机器人,” 载于2019年国际机器人与自动化会议 (ICRA)。IEEE, 2019年, 第7515–7521页。[31] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, 和 P. Abbeel, “用于将深度神经网络从仿真迁移到现实世界的域随机化,” 载于2017年IEEE/RSJ智能机器人与系统国际会议 (IROS), 2017年, 第23–30页。[32] J. Tan, T. Zhang, E. Coumans, A. Iscen, Y. Bai, D. Hafner, S. Bohez, 和 V. Vanhoucke, “仿真到现实迁移: 学习四足机器人的敏捷运动,” *arXiv预印本arXiv:1804.10332*, 2018年。[33] A. Rupam Mahmood, D. Korenkevych, B. J. Komer, 和 J. Bergstra, “使用真实世界机器人设置强化学习任务,” 载于2018年IEEE/RSJ智能机器人与系统国际会议 (IROS), 2018年, 第4635–4640页。[34] A. Kumar, Z. Fu, D. Pathak, 和 J. Malik, “RMA: 腿式机器人的快速电机适应,” *arXiv预印本arXiv:2107.04034*, 2021年。[35] Z. Fu, X. Cheng, 和 D. Pathak, “深度全身控制: 学习用于操作和运动的统一策略,” 载于机器人学习会议。PMLR, 2023年, 第138–149页。[36] X. Cheng, K. Shi, A. Agarwal, 和 D. Pathak, “腿式机器人的极限跑酷,” *arXiv预印本arXiv:2309.14341*, 2023年。