

学习恢复：跌倒机器人的动态奖励塑形与轮腿协调

邓博元^{1,2,*}, Luca Rossini¹, 王金¹, 王伟杰¹ 和 Nikolaos Tsagarakis¹

摘要— 从跌倒事件中自适应恢复是轮腿机器人实际部署中的关键技能，这类机器人独特地结合了腿部的敏捷性与轮子的速度，以实现快速恢复。然而，依赖预规划恢复动作、简化动力学或稀疏奖励的传统方法往往难以产生鲁棒的恢复策略。本文提出了一种基于学习的框架，整合了基于回合的动态奖励塑形与课程学习，动态平衡多样化恢复动作的探索与精确姿态修正。非对称演员-评论家架构通过在仿真中利用特权信息加速训练，而噪声注入观测增强了对不确定性的鲁棒性。我们进一步证明，协同的轮腿协调通过能量传递机制将关节扭矩消耗降低了15.8% 和26.2% ，并改善了稳定化。在两个不同的四足平台上进行的广泛评估实现了高达99.1% 和97.8% 的恢复成功率，且无需平台特定调参。补充材料可在 <https://boyuandeng.github.io/L2R-WheelLegCoordination/> 获取

I. 引言

轮腿机器人凭借其集成的轮腿结构，在复杂环境中展现出独特的机动优势，已成为巡检和勘探等长时间任务的关键平台[1][2], [3], [15]。然而，由动态扰动（如碰撞、打滑）导致的意外摔倒常常中断任务，现有系统通常依赖人工干预进行恢复或采用预规划恢复动作，虽然这些方法在平坦地形上可能有效，但面对多样化的地形几何时鲁棒性不足，严重限制了运行效率和自主性。因此，在鲁棒且自主的跌倒后恢复方面取得突破，对于实现完全自主的任务至关重要 [5]

本质上，摔倒后的恢复是一个高度复杂的运动规划与控制问题，需要通过多个不连续接触事件进行精确的姿态调整[9]，而地面特定几何形状可能带来额外的接触不确定性挑战，这些都可能影响摔倒恢复动作的成功执行。对于控制器而言，推导出最优或接近最优的动作序列极具挑战性。由于轮腿机器人具有高度非线性的动力学特性，基于优化的方法往往依赖于简化系统模型和精确的状态估计。因此，现有的大多数研究

*本工作未获得任何组织资助¹意大利技术研究院人形与以人为本机电一体化实验室（HHCM），Via Morego 30, Genoa, 16163, Italy²国家利益机器人与智能机器博士项目（DRIM），热那亚大学，16126 Genoa, Italy *通讯作者：boyuan.deng@iit.it




图1: KYON轮腿机器人模型：轮与关节协调实现关节复位及恢复过程中的质心调整。所示模型对应意大利技术研究院仿人与以人为机电一体化实验室正在开发的一款新型机器人。

主要集中在纯腿部恢复[4]，且主要是在平坦地形上进行的演示，轮腿协同恢复的全部潜力在很大程度上尚未被探索。相比之下，强化学习领域的最新进展在解决这一问题上展现了显著的进步，为更灵活、更稳健的恢复策略提供了新的技术路径。本文探索了一种广泛使用的基于学习的方法，通过利用轮子来促进轮腿机器人的快速跌倒后恢复。我们采用了一种非对称的近端策略优化

（PPO）框架，该框架整合了回合的动态探索和课程学习来训练网络。这种设计减轻了恢复和平滑度权重参数的敏感性，同时避免了过于保守的策略倾向。本研究的主要贡献总结如下：

- 我们提出了一种基于回合的动态奖励整形机制，结合课程学习以平衡勘探与策略收敛。该框架能够在训练早期实现对多样化恢复动作的广泛勘探，同时逐步优化姿态控制以趋向目标构型，有效克服了稀疏奖励设计的局限性。
- 我们系统性地验证了轮驱动在降低关节力矩负担和改善恢复过程中稳定化方面的关键作用。轮子动力学与腿部调整之间的协同作用通过跨平台实验得到了严格量化，为理解轮子如何主动辅助直立恢复过程提供了新的

关于轮子如何主动协助直立恢复过程的见解。

- 在两个不同的轮腿式平台（KYON 和 Unitree Go2-W[11]）上进行的大量实验验证表明，所提出的方法对不同的硬件配置具有很高的适应性，无需平台特定调参即可实现更高的成功率和更低的扭矩使用，凸显了其鲁棒性和可扩展性。

II. 相关工作

跌倒后恢复过程通常要求机器人执行一系列动作，从初始跌倒状态逐步过渡到最终的站立姿态。该过程可以表述为最小化当前状态与目标状态（例如基座高度、关节角度）之间的差异。由于腿式机器人具有高度非线性的运动学和动力学特性，以及恢复任务本身的非凸性质，一些基于优化的方法已借助预定义运动序列[14], [4]或简化模型[13]来降低优化复杂度，同时实现动态响应性和稳定平衡。然而，这些启发式方法通常严重依赖模型精度和大量人工投入，并且往往缺乏跨平台或跨任务的可移植性。

近年来，基于学习的方法因其无模型特性以及通过与环境的交互直接学习策略的能力，展现出作为替代方案的巨大潜力。例如，Lee等人[7]采用分层机制将任务分解为两个控制器：一个用于自扶正，一个用于站立。Hwangbo等人[6]提出使用单一控制器来优化基座高度，并辅以辅助奖励以生成更自然的恢复动作。他们的工作还引入了课程学习，并在仿真中利用网络执行器来弥合仿真与真实世界性能之间的差距。最近，[9]将机械臂纳入恢复过程，并将其构建为有限时域任务，这不仅提高了恢复成功率，还降低了关节扭矩消耗。虽然这些方法专注于平坦地形，但我们后续的实验将验证扩展到非平坦场景，以应对不平整地面条件带来的挑战。

在基于强化学习的方法中，仅依赖最终目标姿态作为主要任务奖励往往会导致稀疏反馈导致勘探不足和成功率较低。为应对这一挑战，本研究引入了基于回合的动态奖励塑形机制，以平衡勘探与收敛。该方法在早期阶段扩大勘探空间，同时确保策略有效收敛到期望的恢复行为。

III. 方法

图3展示了我们训练流程的概览。本工作的实现基于Isaac Lab框架[10]。下面，我们概述训练过程的主要组成部分。




图2: (a)-(c)对应不同回合的初始状态。




图3: 基于非对称PPO的强化学习训练框架

A. 状态初始化与rollout

在执行各种任务的过程中，轮腿机器人可能会摔倒甚至完全翻滚；因此，恢复控制器必须适应多样的初始条件。为了模拟不同的跌倒状态，我们随机初始化机器人的基座朝向和关节角度，将关节力矩设为零，并让机器人从1.1米的高度自由落体2秒。选择这一时长是为了确保机器人完全倒在地上，如图2所示，这有助于避免动力学变得不真实的情况[6]。多样化的观测状态提高了策略的泛化能力和适应性。每个回合的固定时长为4秒，且不会提前终止。

B. 基于特权信息的Actor-Critic

我们采用了一个具有非对称演员-评论家架构的PPO框架，其中评论家网络利用特权信息来产生更准确的Q值估计，从而加速训练。演员和评论家的观测输入如下：

演员观测：策略网络观测机器人的状态，包括基座的线速度、角速度、朝向、关节位置、关节速度和轮速的当前及历史读数（时间间隔为0.01秒）。这种时间信息使机器人能够更好地评估其接触状态[6]。演员还接收先前采取的动作。除最近的动作和关节位置外，观测值中添加了高斯噪声，以考虑摔倒后出现的状态估计不准确性。与[5]类似，我们

对关节速度以及基座的线速度和角速度特别施加更高的噪声水平。

评论家观测：特权信息包含仅在仿真中可访问的数据（在现实世界部署中不可用）。通过使用这些信息，评论家可以在训练阶段更准确地估计Q值，从而更有效地指导演员的动作。特权观测包括碰撞状态，以避免可能导致破坏性地面冲击的不切实际动作，以及VTG信息[16]以加速学习。

C. 动作

关节位置和轮速的目标值分别计算为 $s_p \cdot \mathbf{a}_p + \mathbf{q}$ 和 $s_v \cdot \mathbf{a}_v + \mathbf{q}_v$ 。其中 s_p 和 s_v 是缩放因子， $\mathbf{a}$ 表示策略网络输出分布中概率最高的动作，而 $\mathbf{q}$ 和 $\mathbf{q}_v$ 分别代表默认关节角度和默认轮速。计算得到的关节位置指令被发送到驱动器位置PD控制器，而轮速指令则传输至电机速度控制器。

在我们的实验中，我们观察到当 $s_v > 1.0$ 时，动作值对速度控制的变化高度敏感，导致明显的车轮振荡。因此，我们选择 $s_v < 1.0$ 以降低对指令变化的敏感性并增强运动稳定性。

D. 动态探索策略

在现有奖励结构的基础上，本研究引入了动态回合因子以增强探索，从而扩展了先前的工作[5], [9], [6], [16]。与传统的稀疏奖励相比，我们的方法允许在早期阶段出现较大的姿态偏差，使机器人能够探索各种翻转或滚动动作；随后在后期阶段逐步对目标姿态施加更严格的约束，以引导策略走向稳健的跌倒恢复解决方案。实证结果表明，该方法训练出了更具韧性的策略，如第IV-B节中的消融研究所示。

1) 动态奖励塑形：在先前的研究中，跌倒后的恢复过程常被简化为“最终姿态追踪”任务，通常采用基于关节角度、身体高度或方向误差的相对固定的奖励或惩罚项。然而，在从俯卧位置过渡到站立的过程中，轮腿机器人可能需要进行大幅度的——有时甚至是反直觉的——滚动或摆动动作。过度惩罚终端姿态会限制对多样化状态-动作对的探索，如图2所示。为了平衡早期阶段的自由探索与后期阶段的精确姿态控制，我们提出了基于回合的动态奖励塑形（DS），其正式定义如下：

$$DS = \left(\frac{a \cdot t}{T} \right)^k \quad (1)$$

其中 t 是回合中的当前步骤， $t \in [0, T]$ 。T是每个回合的总步数， k 作为增长率，而 a 是基线系数。在我们的实验中，

表I：奖励项摘要

奖励项	定义	规模
站立关节位置	$e^{-\frac{\sum_j (\mathbf{q}_j^* - \mathbf{q}_j[t])^2}{\sigma_p N_j}}$	42
基座高度	$e^{-\frac{\max(h^* - h_b[t], 0)^2}{\sigma_h}}$	120
基座朝向	$(\mathbf{g}_b - \mathbf{e}_z)^2$	50
身体碰撞	$\sum_{b \in B} \ \lambda_b[t]\ ^2$	-5×10^{-2}
动作速率	$\sum_t (\mathbf{a}[t] - \mathbf{a}[t-1])^2$	-1×10^{-2}
关节速度	$\sum_j \dot{\mathbf{q}}_j^2$	-2×10^{-2}
力矩	$\sum_j \tau_j^2$	-2.5×10^{-5}
加速度	$\sum_j \ddot{\mathbf{q}}_j^2$	-2.5×10^{-7}
轮速	$\sum_k \dot{\mathbf{q}}_k^2$	-2×10^{-2}

我们根据预期恢复时间 $k = 3$ 设置 $a = \frac{T}{2}$ 。每个时间步的即时奖励由下式给出：

$$r_t = DS \cdot R(s_t, a_t) \quad (2)$$

此处， $R(s_t, a_t)$ 是原始的基线奖励函数。当 t 接近0时，智能体可以进行大幅度的姿态调整，任何成功的状态-动作对都会被保留并在策略网络中得到强化。随着 t 接近回合的最大长度，对最终目标姿态精细调整的重视程度逐渐增加。这种渐进机制在每回合早期促进了动作多样性，并在后期确保了站立姿态的稳定性。

我们观察到这种动态奖励调制可能会降低学习效率。然而，如第III-B节所讨论的，实证结果表明它增强了学习到的策略的鲁棒性。这种效果部分归因于对状态空间更广泛的覆盖[17]，这意味着训练过程中探索了更多的状态-动作组合，从而提高了策略对各种摔倒场景的泛化能力。

2) 课程学习：为了进一步提高训练效率并缓解动态回合因子导致的学习速度下降，我们引入了课程学习[6], [8], [12]。课程权重（CW）定义如下：

$$CW = CW^\beta \quad (3)$$

其中 β 是学习率。我们将辅助奖励乘以该权重，并在每次环境重置前更新它。这种方法确保了在早期阶段快速获得任务相关行为，在后期阶段实现更平滑的运动，从而在效率和可行性之间取得平衡。

E. 奖励函数

我们将奖励分为任务奖励和行为奖励，分别用于激励正确的动作并约束过于激进的行为。计算这些奖励所需的所有机器人状态变量（如身体加速度和接触力）均直接从仿真环境中获取。奖励分类如下：

1) 任务奖励：为了鼓励机器人快速准确地达到目标姿态，我们定义了以下三个主要子奖励：




图4：在相同初始姿态下使用两种不同策略的恢复过程。(a)–(d)展示了DS策略成功恢复。(e)–(h)展示了基线策略，该策略调整关节位置和基座高度，但未能优化基座朝向，陷入局部最优而未能完全恢复。

基座高度：对基座高度与期望高度之间的偏差进行惩罚，以确保机器人直立站立。

基座朝向：对重力投影的偏差进行惩罚，以纠正横滚角和俯仰角。

关节位置：对偏离默认关节角度的偏差进行惩罚。

2)行为奖励：为促进更平滑的恢复过程，行为奖励对动作速率和关节加速度等指标进行惩罚。在计算动作速率时，轮子动作被排除在外，以使机器人能够更灵活地使用轮子进行恢复。我们还引入了身体碰撞惩罚，以防止与地面的剧烈撞击或可能损坏机器人结构的自接触。此外，为使机器人在直立后保持稳定，我们对支撑状态提供奖励，该状态定义为四个轮子同时与地面接触的条件。

表I总结了所有奖励项及其缩放。在奖励定义中， $\mathbf{q}_j$ 、 $\dot{\mathbf{q}}_j$ 和 $\ddot{\mathbf{q}}_j$ 分别表示每个关节的角位置、速度和加速度。 $\mathbf{g}_b$ 是投影到机器人基座坐标系上的重力向量。 B 表示选定的机器人连杆集合，包括小腿、大腿和基座。 λ_b 表示机体 b 的接触力。

最后，每个时间步的总奖励定义为：

$$r_t = DS \cdot r_{joint_pos} + r_{base_height} + r_{base_ori} + CW \cdot (r_{collision} + DS \cdot (r_{action_rate} + r_{joint_vel} + r_{torque} + r_{joint_acc})) + r_{wheelvel} \quad (4)$$

IV. 结果

A. 实验设置

所有实验均在Isaac Sim仿真器中使用KYON和宇树Go2-W[11] 机器人模型进行。为增强策略鲁棒性，采用了广泛的域随机化：每个回合开始时，机器人的基座质量被扰动 $\pm 5.0\text{kg}$ ，连杆质量相对其标称值变化 $\pm 10\%$ 。此外，通过从 $[0.7, 1.3]$ 中均匀采样静态摩擦系数来随机化接触动力学，同时执行器刚度和阻尼分别被扰动 ± 15.0 和 ± 2.0 。

此外，还加入了由零均值和标准差为0.02表征的动作噪声。

每个回合持续4秒（控制频率为100Hz），并仅在超时终止。训练框架采用非对称PPO算法，学习率为0.001，折扣因子为 $\gamma = 0.99$ 。此外，集成了课程学习，从难度因子0.3开始，以0.968的速率指数衰减，以逐步增强策略探索。

B. 恢复成功率的基线对比

为验证基于回合的动态奖励塑形（DS）的有效性，我们在相同的奖励函数和超参数框架下，将DS策略与基线的恢复性能进行了对比。恢复被定义为：在回合的最终时间步，基座高度超过0.42m，关节角度与默认配置的偏差不超过0.5rad，且最大关节速度低于0.1 rad/s。在2048个随机生成的初始条件下进行测试，DS策略的成功率达到99.1%，较基线的96.4%提升了2.7个百分点。

进一步分析显示，基线的失败案例主要与前腿关节角度随机化程度较低的场景相关，如图4所示。为说明这一点，我们从基线的一个失败案例中选取了一个具有代表性的初始状态，并将其作为DS策略的起始状态，以比较所产生的动作序列。实验表明，由于对关节角度偏差施加了惩罚，基线抑制了前腿运动，并试图仅通过后腿调整基座高度，最终陷入局部最优。

这一现象与动作空间的探索能力差异直接相关。对2048次实验中的动作序列进行了主成分分析（PCA），所得可视化结果图5显示，DS-Policy ($\sigma_{PC1}^2 = 20.91$, $\sigma_{PC2}^2 = 9.72$) 沿主成分的方差显著高于基线 ($\sigma_{PC1}^2 = 17.33$, $\sigma_{PC2}^2 = 5.22$)。这些发现证实了动态奖励塑形机制，

通过扩大探索边界并生成更不保守的动作序列，增强了复杂场景下的恢复鲁棒性。




图5：基于PCA的DS策略与基线策略在2048个环境中单回合动作分布对比。

C. 轮式辅助恢复

为评估轮式驱动在恢复过程中的动态贡献，我们比较了轮腿协同模式与纯腿式模式之间的性能差异。在实验设置中，纯腿式组通过修改机器人描述文件，将轮关节从连续驱动改为固定约束，并移除轮速惩罚项以消除策略偏差；其余所有超参数和奖励函数均与轮腿协同组保持一致。对2048个随机初始状态的测试表明，轮腿协同模式显著提升了恢复稳定性，并优化了关节力矩分布。如图6所示，尽管两种策略的基座高度轨迹均在 $0.42m$ 内收敛至目标高度（ $0.7s$ ），但轮腿协同组在恢复阶段（ $t < 0.7s$ ）和稳定阶段（ $0.7s < t < 1.5s$ ）均表现出更低的方差。相比之下，纯腿式组在稳定阶段波动较大，方差为 0.102 at $t = 1s$ 。




图6：在2048个环境中，单回合内纯腿模式与轮腿协调模式下基座高度动态（以均值和方差量化）的比较。

对图7所示关节力矩特性的进一步分析显示，轮腿协作组的平均关节力矩为 $35.776N \cdot m$ ，与纯腿组（ $42.515N \cdot m$ ）相比降低了15.85%。

这一降低可能归因于通过轮式滚动将轮动能转化为关节势能，从而减少了关节抵抗重力所需的能量消耗。也可能是因为主动轮允许腿接触滑动，有利于减少内力，而在固定轮情况下腿接触无法滑动时，内力可能较大并额外增加腿关节的负担，从而验证了轮辅助在恢复控制中的作用。




图7：在2048个环境中，单回合内KYON在纯腿模式与轮腿协调模式下的平均关节扭矩比较。

D. 不同机器人上的跨平台验证

为验证DS策略的跨平台泛化能力，我们将其部署在配置参数显著不同的宇树Go2-W[11]平台上，并与基线方法的性能进行了比较。实验结果表明，尽管存在质量分布和关节驱动限制等硬件差异，DS策略仍保持了稳健的恢复性能，并展现了轮腿协作机制的优势。如图11所示，在轮子驱动的情况下，Go2-W机器人利用主动轮旋转来缓冲其姿态，从而显著降低了髌关节所需的扭矩调整幅度。与基线策略相比，其恢复成功率提高了3.7个百分点（见表II），平均关节扭矩相对于固定轮配置降低了26.2%（见表III和图8）。

这些发现与KYON平台上的实验结果一致，表明DS策略通过动态奖励塑形持续生成针对局部自由度优化的动作序列，且轮式辅助接触力调节机制有效降低了关节负载。我们还对两台机器人的关节运动参数进行了定量分析。如图9所示，通过计算每个关节峰值速度的均值和标准差，我们验证了控制策略生成的驱动指令符合机器人描述文件中规定的最大速度阈值（KYON： $7.6rad/s$ ，宇树Go2-W： $20.3rad/s$ ）。此外，我们还评估了每个关节力矩的均值和标准差，如图10所示。对于宇树Go2-W机器人，大多数关节的最大力矩为 $23.7N \cdot m$ ，其中小腿关节（KFE）可达 $35.55N \cdot m$ 。相比之下，KYON机器人的所有关节




图8: 在2048个环境中, 单个回合内, 宇树Go2-W[11]在纯腿式与轮腿协调模式下的平均关节力矩对比。




图9: 两种机器人在不同驱动模式下最大关节速度的均值 $\pm$ 标准差 (2048个环境)。

最大关节力矩为 $185N \cdot m$ 。所有运动均保持在允许的关节范围限制内, 证实了基于仿真的控制策略生成的动作确实可应用于真实世界实验。

表II: 恢复成功率对比

平台	策略	成功率 (%)
KYON	DS	99.1
	基线	96.4
宇树Go2-W[11]	DS	97.8
	基线	94.1

表III: 平均关节力矩对比

平台	配置	平均扭矩 (N·m)	降低 (%)
KYON	主动轮模式	35.776	15.85
	固定轮模式	42.515	
宇树Go2-W[11]	主动轮模式	7.123	26.24
	固定轮模式	9.657	

E. 未见地形上的恢复适应性

为了探究我们方法所展现出的涌现地形适应能力, 我们还在五种程序化生成的不平坦地形上对策略进行了评估:

- 1) 随机箱子: 具有0.05–0.2m 高度变化的不连续平台。
- 2) 粗糙地形: 高频不平整度 ($\delta = 0.02\text{--}0.10m$)。
- 3) 斜坡金字塔: 具有20–60%坡度的倾斜表面。
- 4) 金字塔楼梯: 台阶高度为0.05–0.23m的上升/下降楼梯。
- 5) 倒金字塔楼梯: 与金字塔楼梯相反。




图10: 两种机器人在不同驱动模式下, 2048个环境中关节扭矩的均值 $\pm$ 标准差。




图11: 宇树Go2-W[11] 从俯卧到站立的恢复过程关键阶段。在(b)中, 机器人站立后向后倾斜, 后轮旋转缓冲倾斜以防止翻倒。一旦质心在(c)中稳定, 前轮旋转快速调整基座高度和关节构型。

值得注意的是, 该策略表现出部分零样本泛化能力: 尽管缺乏明确的地形感知, 机器人仍能通过受控的轮腿协调保持稳定。我们比较了DS策略和基线策略在非平坦环境中部署于KYON机器人上的恢复成功率, 将恢复定义为关节角度与默认配置的偏差不超过 $0.5rad$, 且基座姿态误差——计算为机器人投影重力矢量与理想方向 $[0, 0, -1]$ 之差的绝对值之和——小于0.1, 成功率如表IV所示。

然而, 在这些条件下, 恢复成功率显著下降, 且频繁观察到二次摔倒——尤其是在楼梯地形上。这些不良行为削弱了现实世界部署的可行性, 可归因于两个未解决的挑战: 首先, 策略的反应性调整缺乏对地形几何的感知; 其次, 它未能根据局部地形特征最优地调整其恢复姿态。




图12: DS策略在KYON机器人上于不规则地形中的评估。

表IV: 非平坦地形上恢复成功率的比较

平台	策略	成功率 (%)
KYON	DS	78.6
	基线	61.8

五、结论

本文提出了一种基于回合的动态奖励塑形方法，用于轮腿机器人在跌倒状态下实现稳健且自适应的恢复。通过整合动态奖励塑形与课程学习，所提方法有效解决了稀疏奖励强化学习固有的勘探-收敛困境。实验结果表明，DS在多种平台上实现了超过97%的恢复成功率，比基线方法高出3个百分点。关键创新在于轮式辅助运动与腿部关节运动的协同：轮子通过受控滚动实现质心的快速调整，而腿部则实现精确的姿态稳定化，二者共同作用，与固定轮配置相比，关节扭矩需求降低了15 – 26%。在具有不同运动学与动力学参数的平台（KYON和宇树Go2-W[11]）上的跨平台验证进一步证实了该框架的泛化能力，其中DS无需手动调参即可自主适应硬件特定约束。这些发现凸显了轮腿协调作为混合运动系统中恢复控制的通用策略的潜力。

未来的工作将集中于扩展该框架以应对更复杂的地形（如斜坡、砾石），并整合真实世界的传感器噪声模型以弥合仿真与现实的差距。此外，动态奖励塑形的原理可应用于其他不连续接触任务，例如多机器人协作恢复或面向操作的姿态调整。

致谢

我们感谢Andrea Patrizi、Despoina Mali-gianni、Rui Dai、YifangZhang Maolin Lei、Jingcheng Jiang、Kuanqi Cai和Carlo Rizzardo的有益讨论。

参考文献

- [1] C Dario Bellicoso, Marko Bjelonic, Lorenz Wellhausen, Kai Holtmann, Fabian G`unther, Marco Tranzatto, Peter Fankhauser, and Marco Hutter. 腿式机器人实际应用的最新进展. *Journal of Field Robotics*, 35(8):1311–1326, 2018.
- [2] Marko Bjelonic, Victor Klemm, Joonho Lee, and Marco Hutter. 轮腿机器人综述. In *Climbing and Walking Robots Conference*, pages 83–94. Springer, 2022.
- [3] Amanda Bouman, Muhammad Fadhil Ginting, Nikhilesh Alatur, Matteo Palieri, David D Fan, Thomas Touma, Torkom Pailevanian, Sung-Kyun Kim, Kyohei Otsu, Joel Burdick, et al. 自主Spot: 基于腿式运动在极端环境中进行长距离自主勘探. In *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 2518–2525. IEEE, 2020.
- [4] Juan Alejandro Castano, Chengxu Zhou, and Nikos Tsagarakis. 利用稳定性特征空间设计轮腿四足机器人的摔倒恢复策略. In *2019 IEEE International Conference on Robotics and Biomimetics (ROBIO)*, pages 41–46. IEEE, 2019.
- [5] Henrik Christensen, Nancy Amato, Holly Yanco, Maja Mataric, Howie Choset, Ann Drobnis, Ken Goldberg, Jessy Grizzle, Gregory Hager, John Hollerbach, et al. 美国机器人技术路线图——从互联网到机器人技术 2020 424, 2021 8 4 307版. *Foundations and Trends® in Robotics*, (): –.
- [6] Jemin Hwangbo, Joonho Lee, Alexey Dosovitskiy, Dario Bellicoso, Vassilios Tsounis, Vladlen Koltun, and Marco Hutter. 学习腿式机器人的敏捷和动态运动技能. *Science Robotics*, 4(26):eaau5872, 2019.
- [7] Joonho Lee, Jemin Hwangbo, and Marco Hutter. 基于深度强化学习的四足机器人鲁棒恢复控制器. *arXiv preprint arXiv:1901.07517*, 2019.
- [8] Joonho Lee, Jemin Hwangbo, Lorenz Wellhausen, Vladlen Koltun, and Marco Hutter. 在具有挑战性的地形上学习四足运动. *Science robotics*, 5(47):eabc5986, 2020.
- [9] Yuntao Ma, Farbod Farshidian, and Marco Hutter. 学习利用机械臂辅助减少腿式移动机械臂摔倒损伤并进行恢复. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 12149–12155. IEEE, 2023.
- [10] Mayank Mittal, Calvin Yu, Qinxi Yu, Jingzhou Liu, Nikita Rudin, David Hoeller, Jia Lin Yuan, Ritvik Singh, Yunrong Guo, Hammad Mazhar, Ajay Mandilekar, Buck Babich, Gavriel State, Marco Hutter, and Animesh Garg. Orbit: 面向交互式机器人学习环境的统一仿真框架. *IEEE Robotics and Automation Letters*, 8(6):3740–3747, 2023.
- [11] 宇树科技. 宇树Go2-W, 2024.
- [12] Nikita Rudin, David Hoeller, Philipp Reist, and Marco Hutter. 利用大规模并行深度强化学习在数分钟内学会行走. In *Conference on Robot Learning*, pages 91–100. PMLR, 2022.
- [13] Uluc Saranlı, Alfred A Rizzi, and Daniel E Koditschek. 六足机器人基于模型的动态自扶正动作. *The International Journal of Robotics Research*, 23(9):903–918, 2004.
- [14] Claudio Semini, Jake Goldsmith, Bilal Ur Rehman, Marco Frigerio, Victor Barasuol, Michele Focchi, and Darwin G Caldwell. 液压四足机器人设计概述. In *The fourteenth Scandinavian international conference on fluid power*, pages 20–22. sn, 2015.
- [15] Marco Tranzatto, Frank Mascarich, Lukas Bernreiter, Carolina Godinho, Marco Camurri, Shehryar Khattak, Tung Dang, Victor Reijgwart, Johannes Loeje, David Wisth, et al. Cerberus: DARPA地下挑战赛隧道和城市赛道中的自主腿式与空中机器人勘探. *arXiv preprint arXiv:2201.07067*, 3, 2022.
- [16] Ted Xiao, Eric Jang, Dmitry Kalashnikov, Sergey Levine, Julian Ibarz, Karol Hausman, and Alexander Herzog. 边思考边移动: 并发控制的深度强化学习. *arXiv preprint arXiv:2004.06089*, 2020.
- [17] Chong Zhang, Wanming Yu, and Zhibin Li. 基于可达性的聚类方法用于高效学习运动技能. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 1600–1606. IEEE, 2022.