



开放获取

编辑Giovanni Iacca, 意大利特伦托大学

审稿人Shubham Singh, 美国德克萨斯大学奥斯汀分校; Mátyás Vincze, 意大利布鲁诺·凯斯勒基金会 (FBK)

\*通讯作者Zeang Zhao,  
zza@pku.edu.cnShengyu  
Duan,  
shengyu\_duan@126.com

收稿日期 2026年1月15日 修回日期  
2026年2月11日接受日期 2026年  
2月11日发布日期 2026年2月25日

引用

He P, Zhao Z, Duan S, Wang P 和  
Lei H (2026) 通过稀疏专家混合深度强  
化学习实现双足轮腿机器人的自适应多  
模式运动。Front. Robot. AI  
13:1788395.doi:  
10.3389/frobt.2026.1788395

版权

© 2026 He, Zhao, Duan, Wang和  
Lei。这是一篇根据知识共享署名许可协  
议 (CC BY) 条款发布的开放获取文章。  
允许在其他论坛使用、分发或复制, 前提  
是按照公认的学术实践, 注明原作者和版  
权所有者的署名, 并引用本期刊的原始出  
版物。不符合这些条款的使用、分发或复  
制均不被允许。

# 通过稀疏专家混合深度强化学习实现双足轮腿机器人的自适应多模式运动

Pan He、Zeang Zhao\*、Shengyu Duan\*、Panding Wang 和  
Hongshuai Lei

先进结构技术研究所, 北京理工大学, 北京

g, 中国

双足轮腿机器人结合了轮式运动的高能效与腿部运动的地形适应性。然而, 在统一控制框架内实现这两种异构运动模式之间的平滑过渡仍然具有挑战性。本研究提出了一种集成专家混合 (MoE) 架构的强化学习控制框架。该方法采用“分而治之”策略, 通过引入动态门控网络和Top-K稀疏激活机制, 自动将不同的运动模式分配给特定的专家子网络, 有效解耦了梯度冲突。仿真结果表明, 与单网络PPO方法相比, MoE增强算法在训练稳定性和奖励方面表现出显著提升。学习策略成功实现了在平坦表面上的平滑滚动, 并在遇到障碍物时过渡到动态抬腿步态。在各种测试地形中, 其成功率明显高于单网络PPO方法。

关键词

双足轮腿机器人, 课程学习, 梯度冲突, 专家混合, 强化学习

## 1 引言

轮式效率与腿式多功能性之间的权衡是移动机器人领域的一个重要问题。轮式机器人在平坦地形上表现出色, 而腿式机器人则能适应非结构化环境, 双足轮腿机器人作为一种有前景的混合方案应运而生, 旨在结合两者的优势 (Klemm 等人, 2019; Wang 等人, 2021; Guo 等人, 2022; He 等人, 2025; Wang 等人, 2025)。这些系统可以在连续滚动巡航与离散踏步或跳跃越障之间切换 (Klemm 等人, 2020; Cui 等人, 2021; Lee 等人, 2024)。然而, 要释放这一潜力, 需要一种能够同时掌握这些不同模式的控制策略。传统的轮腿机器人控制通常依赖于基于模型的优化。例如, 研究人员推导了刚体接触动力学的解析二阶导数, 以增强多重打靶微分动态规划 (DDP) 算法 (Singh 等人, 无日期), 从而为处理人形和混合运动机器人中的复杂接触交互提供了一种高效方法。虽然这种轨迹优化方法基于解析梯度能够实现精确的控制性能, 但强化学习 (RL) 提供了一种替代方案, 通过试错学习鲁棒策略, 能够更好地适应非结构化环境。

由于高精度滚动 (Bouton 等人, 2020; García 和 Duarte, 2024) 与跳跃等高频机动 (Hwangbo 等人, 2019; Lee 等人, 2020; Zheng 等人, 2025) 之间存在异构动力学, 开发统一控制策略颇具挑战。试图在单体强化学习智能体内掌握这些多样化技能, 往往会引发严重的梯度冲突 (Yu 等人, 2020), 即一种模式的更新会干扰另一种模式的优化。因此, 智能体只能退而求其次, 采用折中策略, 并遭受灾难性遗忘或不稳定收敛的困扰 (Kirkpatrick 等人, 2017; Schaul 等人, 2019)。

为了解决这些局限性, 本研究提出了一种将专家混合 (MoE) 架构集成到PPO框架中的方法, 有效解决了梯度冲突问题 (Shazeer 等人, 2017; Celik 等人, 2024; Li 等人, 2024; Obando-Ceron 等人, 2024; Akrouer 等人, 2022)。我们方法的核心概念是“分而治之”。我们不是强迫单一神经网络编码所有运动基元, 而是采用动态门控机制, 根据机器人的状态选择特定的专家子网络。这种架构有效地解耦了梯度冲突。一个专家可以专注于稳态滚动, 而另一个专家专注于动态抬腿, 门控网络学习最优的切换逻辑。除了算法架构的创新外, 我们还提出了一种分阶段课程学习策略 (Kumar 等人, 2021; Lee 等人, 2024)。训练过程分为两个阶段。在第一阶段, 智能体在特定地形上进行训练, 专注于获取垂直机动技能。在第二阶段, 策略在随机混合地形上进行泛化。盲态运动仅依靠本体感觉历史实现, 无需特权地形信息。

基于Diablo双足轮腿机器人平台, 我们验证了所提出的MoE增强框架相较于单网络PPO方法的优越性。实验结果突出了三个关键贡献:

- 训练稳定性: 引入了一种与专家混合 (MoE) 架构集成的强化学习框架, 该框架有效解决了多模态运动任务中的梯度冲突, 与单网络PPO相比, 显著提升了训练稳定性并缓解了灾难性遗忘。
- 更高性能: 引入了动态门控网络与Top-K稀疏激活机制相结合的设计。该设计自动解耦异构运动模式, 实现专家子网特化, 并获得更高的奖励峰值, 以实现更好的稳定性-敏捷性平衡。
- 增强越障能力: 设计了一种两阶段课程学习策略, 从确定性地形逐步过渡到噪声复杂环境。该方法确保了鲁棒泛化, 使机器人具备在非结构化障碍物上更强的越障能力。

这项工作为双足轮腿机器人的通用运动学习提供了一种新颖的解决方案, 为在复杂环境中部署敏捷混合运动提供了一条可扩展的路径。

## 2 方法

### 2.1 总体控制框架

本研究所使用的机器人平台是双足轮腿机器人Diablo (中国Direct Drive Tech公司), 仿真在Isaac Gym环境中进行 (Hwangbo 等人, 2019; Lee 等人, 2020; Kumar 等人, 2021; Nahrendra 等人, 2023)。整体控制框架包括一个高层决策控制器和一个底层PD控制器 (图1A)。高层决策控制器计算机器人各关节在给定时间的目标位置, 这些目标位置随后被缩放并传输至底层PD控制器。PD控制器计算跟踪这些目标位置所需的关节力矩, 从而驱动物理仿真。

### 2.2 基于PPO算法的控制器设计

我们最初使用标准强化学习方法训练机器人, 目标是在单一决策网络中实现多步态能力。在本节中, 我们采用PPO算法 (Schulman 等人, 2017) 来训练机器人, Actor和Critic均由维度为[512, 256, 128]的神经网络组成。

#### 2.2.1 仿真环境设置

训练环境构建于NVIDIA Isaac Gym仿真平台上, 使用NVIDIA GeForce RTX 3090 Ti显卡, 并配置了4,096个并行环境以高效训练Diablo机器人, 最大回合时长为20秒。该环境包含特定的地形, 迫使机器人从滚动状态过渡到行走状态。

#### 2.2.2 状态空间

在本研究中, 状态空间 $S$ 被构建为维度为 $R^{153}$ 的高维复合向量。其目标是将时间信息空间化, 使标准多层感知机 (MLP) 网络能够有效感知系统的动态趋势, 如加速度变化和接触状态变化。该向量由实时本体感觉观测与历史关节数据拼接而成。至关重要, 为确保真正的盲行走策略, 输入状态 $S$ 严格依赖于机载本体感觉传感器 (IMU、关节编码器和指令输入) 以及最近10帧的历史序列。我们明确将任何外部感觉数据或特权地形高度图排除在策略输入之外。该配置在训练和测试阶段保持一致, 以验证机器人仅利用本体感觉的适应性。

对于本体感觉观测 $O_{base}$ , 该组件表示为 $R^{33}$ 中的向量, 反映机器人当前的物理状态和任务目标。如公式1所示, 具体元素包括: 机体坐标系中机器人基座的线速度 $v_t \in R^3$ ; 角速度 $w_t \in R^3$ ; 重力向量在机体轴上的投影 $g^{proj}_t \in R^3$ ; 指令 $c_t \in R^6$ , 其中包括目标线速度 $v_x$ ,




图1机器人控制算法框架。(A) 机器人训练过程的整体控制框架。(B) MoE 算法控制器的组成与原理。

$v_y$  和偏航角速度  $w_{yaw}$ ，以及跳跃高度目标  $h_{jump}$  和左右腿的调整角度  $\theta_{left}$ ,  $\theta_{right}$ ；关节的当前位置误差  $e_t = (q_t - q_{default}) \in R^6$ ；关节速度  $\dot{q}_t \in R^6$ ；以及来自上一个时间步的动作向量  $a_{t-1} \in R^6$ 。

的公式如下：

$$S_t = \langle O_{base}, h_{pos}, h_{vel} \rangle \quad (2)$$

$$O_{base} = \langle v_t, w_t, g_t^{proj}, c_t, e_t, \dot{q}_t, a_t \rangle \quad (1)$$

历史观测  $O_{hist}$  表示为向量  $R^{120}$ ，其中存储了最近10帧的关节数据，对应物理仿真中的连续时间段。这包括机器人六个关节的历史位置误差  $h_{pos} = [e_{t-10}, \dots, e_{t-1}] \in R^{60}$  以及历史速度  $h_{vel} = [\dot{q}_{t-10}, \dots, \dot{q}_{t-1}] \in R^{60}$ 。在任意给定时间  $t$ ，输入状态向量

### 2.2.3 动作空间

在本研究中，我们采用连续动作空间  $A \in R^6$  来实现对双足轮腿机器人两侧六自由度的精确控制。策略网络并不直接输出力矩，而是生成一个归一化位置偏差向量  $a_t \in R^6$ ，该向量通过线性映射转换为目标关节位置  $q_t^*$ ，如公式3所示。此处， $q_{nom}$  表示机器人的初始姿态，而  $\sigma$  为动作缩放

表 1 具体奖励参数及计算方法。

| 类别          | 奖励项<br>name | 尺度     | 计算<br>方法                                                           |
|-------------|-------------|--------|--------------------------------------------------------------------|
| 任务目标奖励      | 跟踪线速度       | 5.5    | $r_{lin\_vel} = \exp(-\ v_{xy} - v_{xy}^{com}\ ^2 / \sigma_{lin})$ |
|             | 跟踪角速度       | 5.5    | $r_{ang\_vel} = \exp(-(w_{yaw} - w_{yaw}^{com})^2 / \sigma_{ang})$ |
|             | 基座高度        | -0.25  | $r_{height} = -(h_{base} - h_{base}^{com} \text{ 参数目标})^2$         |
| 步态诱导与约束奖励   | 抬腿          | 20     | $r_{leg\_lift} = \text{mean}( z_{wheel-L} - z_{wheel-R} )$         |
|             | 禁止飞行        | 0.25   | $r_{no\_fly} = 1(\text{if } \sum \text{接触} = 2)$                   |
|             | 禁止月球漫步      | -2.5   | $r_{no\_moonwalk} = -(P_{proj\_L} + P_{proj\_R})^2$                |
| 稳定性与物理约束奖励  | 方向          | -5.5   | $r_{orientation} = \ g_{xy}^{proj}\ $                              |
|             | 线速度z        | -0.1   | $r_{lin\_vel\_z} = v_z^2$                                          |
|             | 角速度xy       | -0.25  | $r_{ang\_vel\_xy} = w_x^2 + w_y^2$                                 |
| 运动平滑性与安全性奖励 | 碰撞          | -180   | $r_{collision} = -1(\text{if } body\_接触 > 0.1)$                    |
|             | 自由度位置限制     | -0.5   | $r_{dof\_limit} = -\sum \text{clip}(q - q_{limit})$                |
|             | 动作速率        | -0.008 | $r_{action\_rate} = -\ a - a'\ ^2$                                 |
|             | 力矩          | -1e-5  | $r_{torque} = -\ \tau\ ^2$                                         |

因子。这些高层位置指令随后传递给低层PD控制器，以计算最终的执行力矩  $\tau_t$ ，计算方法详见 [公式4](#)。在此上下文中， $q_t$  和  $\dot{q}_t$  分别表示当前关节位置和速度，而  $K_p$  和  $K_d$  分别代表指定的位置刚度和速度阻尼增益。

$$q_t^* = q_{nom} + \sigma \cdot a_t$$

(3)

$$\tau_t = clip(K_p(q_t^* - q_t) - K_d\dot{q}_t, -\tau_{max}, \tau_{max})$$

(4)

2.2.4 奖励函数

奖励函数  $R$  由四个部分组成：任务目标奖励、步态诱导与约束奖励、稳定性与物理约束奖励，以及运动平滑性与安全性奖励。这些奖励组件的具体参数和计算方法详见[表 1](#)。在步态诱导与约束奖励中，值得注意的是，“抬腿奖励”和“无月球漫步奖励”在功能上互为补充。具体而言，正向的“抬腿奖励”旨在诱导机器人左右腿轮毂中心之间产生垂直高度差，从而促使抬腿迈步步态的产生，同时防止训练过程收敛到纯滚动运动的局部最优解。相反，负向的“无月球漫步奖励”则用于消除左右腿轮毂中心之间的水平偏移，有效抑制沿前进方向出现交错轮位的不良步态。

2.2.5 域随机化与终止条件

为增强策略的鲁棒性，本研究实施了一个全面的域随机化框架，包括

环境动力学随机化、初始状态扰动、传感器噪声注入和外部机械冲击。物理引擎的地面摩擦系数  $\mu$  在每次重置时独立地从均匀分布  $U(0.5, 1.25)$  中采样，且基座的水平位置在  $\pm 1$  m 范围内随机偏移。观测空间增加了参数化的加性噪声，如 [公式 5](#)所示，其中  $n \sim U(-s, s)$ ，噪声幅度  $s$  设置了差异化强度，具体数值见 [补充表S4](#) 中的 [补充材料](#)。此外，每15秒施加一次 1.0 m/s 的随机水平速度冲击，以强制实现平衡恢复。终止条件  $d_t$  由时间截断和物理接触共同触发。

$$O_{noisy} = O_{origin} + n$$

(5)

2.3 MoE控制器的设计

基于原始PPO框架，我们在Actor中引入了MoE机制。该算法的示意图见[图1B](#)。新算法在状态空间、动作空间和奖励函数方面与原始PPO算法保持一致。对于融合了MoE的新算法，Actor由维度为[128, 64]的门控网络和两个大小为 [512, 256, 128]的专家网络组成。在每个时间步，Actor的最终动作输出对应于权重最高的专家网络。

2.3.1 损失函数的组成

损失函数  $L_{base}$  基础PPO算法的损失函数如[公式6](#)所示。其中， $L^{clip}(\theta)$ 表示裁剪替代损失，用于限制策略更新的幅度， $L^{value}(\theta)$ 表示用于评估状态值的平方误差损失，而 $H[\pi_\theta]$ 是熵的线性组合，用于鼓励策略



探索。系数 $c_1$ 和 $c_2$ 用于调整后两项损失的贡献。

$$L_{base} = L^{clip}(\theta) + c_1 \cdot L^{value}(\theta) - c_2 \cdot H[\pi_\theta] \quad (6)$$

在引入 MoE 机制后，我们将总损失函数扩展为  $L_{total}$ ，如 公式 7 所示，以防止专家网络中出现模式坍塌。新增项为负载均衡辅助损失  $L_{aux}$ ，由系数  $c_{moe}$  调节。该损失的计算方法详见 公式 8，其中  $w_i$  表示当前训练批次中第  $i$  个专家的平均门控权重， $N$  表示专家总数。该项通过最小化平均权重的负熵和平均绝对偏差，强制所有专家被均匀激活和利用。

$$L_{base} = L_{base} + c_{moe} \cdot L_{aux} \quad (7)$$

$$L_{aux} = \sum_{i=1}^N w_i \ln w_i + 0.5 \cdot \frac{1}{N} \sum_{i=1}^N \left| w_i - \frac{1}{N} \right| \quad (8)$$

### 2.3.2 MoE 框架中的 Top-K 机制

为了实现计算稀疏性并促使策略网络在不同运动模式之间清晰切换，我们在策略框架中引入了 Top-K 门控机制（Chen 等人，2025；D'Souza 等人，2025；Huang 等人，2025；Xu 等人，2025；Vincze 等人，2025）。对于状态输入  $S_t$ ，门控网络  $G_\phi$  通过 Softmax 为  $N$  个专家生成概率分布  $g \in \mathbb{R}^N$ （公式 9）。随后，截断操作仅保留前  $k$  个专家以形成激活集  $K$ （公式 10）。选中的权重会被重新归一化，以确保有效的梯度传播。最终输出  $\mu_t$  是这  $k$  个激活专家的输出  $E_{\theta-i}(S_t)$  的线性组合（公式 11），从而实现稀疏激活，并允许每个专家专注于特定的子任务。在本研究中，门控网络和专家网络接收相同的输入  $S_t$ （公式 2）。同时，我们将每个时间步激活的专家数量  $K$  固定为 1，从而确保在任何给定时刻只有最相关的专家被激活，以最大化运动基元的解耦。

$$g = \text{Softmax}(W_g \cdot S_t + b_g) \quad (9)$$

$$K = \{i | g_i \in \text{top-}k(g)\} \quad (10)$$

$$\mu_t = \sum_{i \in K} w_i \cdot E_{\theta_i}(S_t) \quad (11)$$

## 2.4 分阶段训练设计

对于双足轮腿机器人，学习过程始于掌握平面上的基本平衡，随后通过滚动运动跟踪速度指令。接着，机器人利用抬腿步态在复杂地形上应对斜坡并克服垂直障碍物。最终，它掌握了在滚动和抬腿模式之间动态切换的能力。为此，我们

设计了一个渐进式训练框架，以按顺序引导这些技能。该方法核心理念是如图2A所示的两阶段训练流程图2A，其中每个阶段具有针对特定技能量身定制的地形组成和复杂度水平。第一阶段仅包含平地、斜坡和垂直楼梯。定义了一个倾斜阈值，使得超过该值的斜坡在仿真中被渲染为垂直楼梯。此过程将初始策略  $\pi_0$  演化为具备障碍物应对能力的策略  $\pi_1$ 。第二阶段涉及将策略  $\pi_1$  迁移至综合地形集进行再训练。为增加地形复杂度，第二阶段将波浪地形和离散地形纳入训练集，并添加Perlin噪声以引入不规则表面扰动。该阶段作为混合运动切换和动态平衡的综合训练场。基于第一阶段的成果，此过程最终形成通用的最终策略  $\pi_2$ 。


## 2.5 课程学习设计

先前研究表明，课程学习——即任务难度逐步递增——是训练复杂运动策略的一种高效策略。因此，我们提出了一种自适应地形课程，旨在促进双足轮腿机器人在非结构化环境中的有效学习。训练开始时，机器人均匀分布在每种地形类型的最低难度等级中，地形难度等级根据机器人的实时表现动态更新。如果机器人在固定时间内成功穿越超过一半的地形长度，则视为已掌握当前难度。因此，在下次重置时，地形等级会递增。相反，如果难度等级降低，机器人可以在较简单地形上巩固基本技能。为了缓解灾难性遗忘，达到最大难度等级的机器人会被随机重新分配到中等难度的地形中。

## 3 结果

### 3.1 训练表现

由于MoE增强算法中的Actor包含两个大小为 [512, 256, 128] 的网络，其总参数量约为标准PPO基线的两倍。为排除网络容量增加的影响，本研究额外引入了一个与MoE增强算法参数量相近的大型PPO基线。大型PPO基线的网络大小为 [768, 384, 192]，相当于将标准PPO基线中Actor的每一层缩放1.5倍。在两个训练阶段中，三种算法均使用相同的超参数进行训练，包括奖励项权重、地形设置、随机化参数和总训练迭代次数。第一阶段中，地形不施加Perlin噪声；第二阶段中，则添加Perlin噪声以引入不规则表面扰动，如图3A所示。两个阶段均包含6,000次训练迭代，并比较平均奖励值，结果分别如图3B、C所示。第一阶段中，三种算法均未出现明显的训练崩溃。在约1,600次迭代之前，它们的奖励值和收敛速度几乎相同。1,600次迭代之后，奖励曲线



出现显著分化：MoE增强算法的奖励稳步上升，而标准PPO基线的奖励持续下降。尽管大型PPO基线的奖励没有明显下降，但也未呈现上升趋势。第一阶段结束时，MoE增强算法的奖励显著高于另外两个基线。初始阶段，地形主要包括平地、斜坡和低台阶，其动力学特性差异较小。对于低台阶，机器人甚至可以通过纯滚动方式通过，其动力学与正常的平地运动和斜坡穿越相似。随着训练推进和台阶高度增加，最高达到14厘米，远大于车轮半径，机器人只能通过跳跃或抬腿踏步来克服此类障碍物，其动力学特性与纯滚动差异很大。使用单一网络进行训练容易产生梯度更新干扰：在学习抬腿踏步或跳跃后，机器人会部分遗忘纯滚动技能；同样，改进纯滚动也会导致越障技能的部分遗忘。因此，单一网络学习到的策略是一种折中方案。面对更高台阶时，其表现不足，导致奖励停滞甚至严重下降。

在第二阶段，将振幅为 6 cm 的 Perlin 噪声引入地形中，并将地形类型扩展至全地形。在这些条件下，标准PPO基线和大型PPO基线均表现出严重的训练不稳定性：

奖励曲线无法收敛，训练崩溃频繁发生。主要原因是Perlin噪声增加了地形表面不平整度，导致机器人在每个时间步的状态观测出现较大波动。策略不断追逐变化的最优行为，导致奖励波动。如果地形变化的频率超过策略的适应速度，就会发生训练崩溃。对于单网络算法，有限的学习能力导致权衡困境，使其在粗糙地形上无法进行稳定训练，也无法获得稳健的最终策略。相比之下，MoE增强算法在整个训练过程中保持了良好的奖励曲线。在第一阶段，其策略逐渐适应不断增加的台阶高度，奖励持续上升。在第二阶段，由于两个专家网络的技能在第一阶段已专门化，每个专家负责不同的步态任务，即使在粗糙地形表面上，也可以通过在不同专家之间交替来实现稳定运动，从而确保训练稳定性。为了进一步验证MoE增强算法的稳定性，我们使用不同的随机种子训练了所有三种算法。结果如补充图S1的补充材料所示。结果表明，MoE增强算法在不同种子下表现稳定，而单网络标准PPO和大型PPO基线在不同种子间表现出显著差异，且难以学习到稳定的策略。总体而言，这些结果初步




图3地形环境与爬楼梯测试。(A) 添加Perlin噪声后的训练地形。(B) 第一阶段训练中标准PPO基线、大型PPO基线与MoE的训练奖励曲线对比。(C) 第二阶段训练中标准PPO基线、大型PPO基线与MoE的训练奖励曲线对比。(D) 两个专家网络在整个训练过程中的平均权重变化。(E) 机器人使用训练后的运动策略爬楼梯的结果，并展示了正面和侧面视图的动作分解。

验证了单网络结构在处理复杂环境中的多模式运动任务时的固有局限性。MoE增强算法的性能提升主要源于其内在机制，而非总网络参数的增加。

3.2 训练期间的专家贡献

在MoE增强算法的训练过程中，提取了专家平均权重的变化，结果见图3D。可以看出，在第一阶段，两个专家之间的调用频率存在显著差异

网络；然而，这种差异在第二阶段显著减小。这一变化的主要原因可归因于第一阶段相对简单的地形，该阶段仅包含平坦表面、斜坡和垂直楼梯，未添加任何Perlin噪声。在这种情况下，仅在穿越垂直楼梯时才需要使用抬腿步态。当遇到垂直楼梯时，机器人需要在台阶上滚动一定距离后才能过渡到下一级，这意味着对负责抬腿步态的专家的调用并不频繁，仅在从一个楼梯过渡到下一个楼梯时发生，而大部分时间则涉及纯滚动。因此，在训练的第一阶段，抬腿步态专家（图中专家2）的调用频率显著低于






图 4障碍物导航测试。成功的定义是机器人从“起点”行驶到“终点”，且不与地面碰撞、不偏离 10 米宽的测试区域。每项测试统计中，500 台机器人独立测试，并计算这 500 台机器人的最终成功率。(A) 障碍物测试区域设置。(B) 最大垂直高度为 6 cm 时三种算法的成功率比较。(C) 最大垂直高度为 8 cm 时三种算法的成功率比较。(D) 最大垂直高度为 10 cm 时三种算法的成功率比较。(E) 最大垂直高度为 12 cm 时三种算法的成功率比较。

负责纯滚动的专家（专家1），导致随着训练轮次的增加，两者的平均权重出现显著差异。相比之下，第二阶段引入了离散地形，需要在纯滚动和抬腿步态之间频繁切换，同时增加了Perlin噪声，加剧了地形表面的不规则性。这提高了对抬腿步态的需求。在这些地形条件下，第二阶段中专家2的调用频率明显增加，以适应起伏的地面。随着第二阶段训练轮次的增加，两位专家之间的平均权重差异显著缩小。

### 3.3 爬楼梯测试

基于MoE增强算法推导出的运动策略在上楼梯场景中进行了测试，结果如图3E所示。面对垂直高度为12厘米的楼梯时，机器人成功执行了理想的抬腿步态。从正面和侧面视图对运动过程进行了分解分析，如图3E所示。在速度指令设定为0.6米/秒的情况下，机器人约用时0.4秒越过台阶。在上楼过程中，机器人先将左腿抬至下一级台阶，随后再抬起右腿，从而有效利用了

抬腿步态完成爬楼梯任务。一般而言，对于遇到垂直障碍物的双足机器人，常见的运动策略包括跳跃或采用抬腿步态。然而，在本研究中，由于引入了显著的抬腿奖励，最终形成的障碍物协商策略仅为抬腿步态。仅采用抬腿步态进行障碍物协商，能够有效解决跳跃带来的若干问题，例如与身体稳定性相关的难题，以及可能影响机器人内部组件的冲击和振动。

### 3.4 障碍物导航测试

为测试两种策略的越障成功率，我们建立了一个专门设计的测试环境（图4A），其中包含三种地形：粗糙地形、离散地形和垂直楼梯。每种地形均设置在方形区域内，粗糙地形使用振幅为6 cm的Perlin噪声生成，离散地形和垂直楼梯的最大垂直高度设置在6至12 cm之间。测试过程中，一次成功的试验要求机器人全程保持直立、不超出地形边界并到达终点。针对每种不同难度的地形进行重复测量，每次单项测试使用500个机器人进行统计



分析。结果如图4B、C所示。从结果可以看出，由MoE增强算法训练的运动策略显著优于标准PPO基线和大型PPO基线。在所有难度等级的地形中，其成功率在所有速度指令下均超过50%。对于标准PPO基线，可以明显观察到其越障性能不足，尤其是在低速度指令下。即使在障碍物高度为6 cm的最简单地形中，其成功率仍然较低。在高度为12 cm的地形中，它在所有速度指令下均表现不佳。大型PPO基线相比MoE增强算法也存在相当大的性能差距，且随着地形难度的增加，这一差距愈发明显。特别是当最大垂直障碍物高度达到12 cm时，大型PPO基线的成功率普遍低于50%。总体而言，这些结果进一步证明，MoE增强算法的优越性主要源于MoE的固有机理，而不受网络参数具体数量的显著影响。

基于该实验，我们进一步开展了消融实验，以分析混合专家（MoE）和分阶段训练的效果。我们建立了一个额外的基线，该基线直接训练12,000次迭代，不进行分阶段。同样，我们使用两个指标来评估这两种训练方案：平均训练奖励和在不同高度地形上的越障成功率。首先，关于平均奖励，我们使用四种不同的随机种子进行训练，并对奖励结果进行了统计分析，如补充图S2在补充材料中所示。可以清楚地观察到，MoE增强算法在分阶段训练下获得的奖励值高于非分阶段训练。随后，对两种训练方法获得的运动策略进行了越障成功率测试，结果见补充图S3在补充材料中。结果表明，在相对简单地形上，两种策略的性能差异不显著。当障碍物的最大垂直高度达到12厘米时，采用分阶段训练的策略的成功率显著高于非分阶段策略。这验证了分阶段训练可以提高越障性能的上界。结合与使用单一网络的PPO算法的对比结果，可以得出结论：在本研究提出的MoE增强算法中，MoE机制本身起主导作用，而分阶段训练作为辅助方法，进一步提升了算法的性能。

## 4 结论

本研究提出了一种针对双足轮腿机器人的强化学习控制框架，该框架集成了专家混合（MoE）。通过将MoE引入PPO算法的Actor网络，我们利用稀疏门控机制为纯滚动和抬腿任务解耦参数，有效解决了单网络多任务学习中的梯度冲突问题。仿真测试结果表明，该方法不仅消除了灾难性遗忘，还显著提升了训练稳定性。为确保策略的鲁棒性和泛化能力，我们实施了一个两阶段

课程学习策略，该策略从特定地形过渡到带有Perlin噪声的复杂地形。MoE增强策略在导航复杂地形时表现出卓越的适应性，能够根据地形的起伏自动调整专家权重，从而实现从平地滚动到动态障碍物协商的平滑过渡。值得注意的是，在高难度障碍物测试中，该策略在穿越12厘米垂直楼梯时的成功率远超单网络PPO算法。未来的工作将聚焦于几个关键领域：认识到高速运动中碰撞力对平衡的显著影响，进一步研究将旨在增强系统在极端物理接触和外部扰动下的主动安全和自恢复能力。此外，我们将在更多样化和非结构化的户外环境中进行实际部署测试，以验证和优化该方法在实际应用中的长期可靠性。

## 数据可用性声明

支持本文结论的原始数据将由作者提供，无需过多保留。

## 作者贡献

PH：写作——审阅与编辑，写作——初稿。ZZ：写作——审阅与编辑，写作——初稿。SD：方法论，概念化，写作——审阅与编辑。PW：写作——审阅与编辑，调查。HL：项目管理，方法论，写作——审阅与编辑。

## 资金

作者声明，本研究及/或其出版获得了财务支持。国家自然科学基金委员会（资助编号：12372162和12302078）。

## 致谢

我们感谢Direct Drive Tech在机器人硬件和控制方面提供的技术协助。一般说明：感谢他人的任何贡献。

## 利益冲突

作者声明，本工作是在不存在任何可能被解释为潜在利益冲突的商业或财务关系的情况下进行的。

## 生成式AI声明

作者声明，本手稿的创作过程中未使用生成式AI。

本文中图片附带的任何替代文本 (alt text) 均由 Frontiers 在人工智能的支持下生成, 并已尽合理努力确保其准确性, 包括尽可能由作者进行审核。如果您发现任何问题, 请联系我们。

## 出版商注

本文所表达的所有观点仅代表作者本人, 并不一定代表其所属机构、

## 参考文献

- Akrour, R., Tateo, D., 和 Peters, J. (2022). 基于可解释专家混合的连续动作强化学习。 *IEEE 模式分析与机器学习汇刊* 44, 6795–6806. doi:10.1109/TPAMI.2021.3103132. doi:10.1109/TPAMI.2021.3103132.
- Bouton, A., Grand, C., 和 Benamar, F. (2020). 适应不平地形的柔性轮腿式探测车设计与控制。 *IEEE/ASME 机电一体化汇刊* 25, 2354–2363. doi:10.1109/TMECH.2020.2973752. doi:10.1109/TMECH.2020.2973752.
- Celik, O., Taranovic, A., 和 Neumann, G. (2024). 利用专家混合的课程强化学习获取多样化技能。 doi:10.48550/arXiv.2403.06966
- Chen, F., Wan, R., Liu, P., 郑, N., 和 Zhou, B. (2025). VMTS: 用于双足机器人多地形运动的视觉辅助师生强化学习。 doi:10.48550/arXiv.2503.07049
- 崔, L., 王, S., 张, J., 张, D., 赖, J., 郑, Y., 等. (2021). 学习 - 基于学习的轮腿机器人平衡控制。 *IEEE Robot. Autom. Lett.* 6, 7667–7674. doi:10.1109/LRA.2021.3100269
- 德苏扎, L., 卡尔蒂基扬, A., Pant, Y., 以及 Fischmeister, S. (2025). SAC-MoE: 基于专家混合的强化学习用于不确定性混合动力系统的控制。 doi:10.48550/arXiv.2511.12361
- García, J. M., 以及 Duarte, F. G. (2024). 用于克服障碍物的移动滚动机器人: 综述。 *Forces Mech.* 16, 100283. doi:10.1016/j.fnmec. 2024.100283
- Guo, T., Liu, J., Liang, H., Zhang, Y., Chen, W., Xia, X., 等 (2022). 复杂地形环境中跳跃轮腿机器人的设计与动力学分析。 *Front. Neurorobot.* 16, 1066714. doi:10.3389/fnbot. 2022.1066714
- He, S., Liu, S., Li, X., Ye, M., Wu, H., 和 Song, J. (2025). 综述: 探索生物机器人的设计。 *Soft Sci.* 0–23. doi:10.20517/ss.2024.50
- Huang, S., Zhang, Z., Liang, T., Xu, Y., Kou, Z., Lu, C., 等 (2025). MENTOR: 基于任务导向扰动的专家混合网络用于视觉强化学习。 doi:10.48550/arXiv.2410.14972
- Hwangbo, J., Lee, J., Dosovitskiy, A., Bellicoso, D., Tsounis, V., Koltun, V., 等 (2019). 学习腿式机器人的敏捷动态运动技能。 *Sci. Robot.* 4, eaau5872. doi:10.1126/scirobotics.aau5872
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., 等 (2017). 克服神经网络中的灾难性遗忘。 *Proc. Natl. Acad. Sci.* 114, 3521–3526. doi:10.1073/pnas.1611835114
- Klemm, V., Morra, A., Salzmann, C., Tschopp, F., Bodie, K., Gulich, L., 等 (2019). “Ascento: 一种两轮跳跃机器人,” 见 2019 年国际机器人与自动化会议 (ICRA) (蒙特利尔, 魁北克: IEEE), 7515–7521. doi:10.1109/ICRA.2019.8793792
- Klemm, V., Morra, A., Gulich, L., Mannhart, D., Rohr, D., Kamel, M., 等 (2020). 具有运动学回路的轮式双足机器人的 LQR 辅助全身控制。 *IEEE Robot. Autom. Lett.* 5, 3745–3752. doi:10.1109/LRA. 2020.2979625
- Kumar, A., Fu, Z., Pathak, D., 和 Malik, J. (2021). RMA: 腿式机器人的快速运动适应。 doi:10.48550/arXiv.2107.04034

出版商、编辑和审稿人的观点。本文中可能被评估的任何产品, 或其制造商可能提出的任何声明, 均未得到出版商的保证或认可。

## 补充材料

本文的补充材料可在以下网址在线获取:

<https://www.frontiersin.org/articles/10.3389/frobt.2026.1788395/full#supplementary-material>

Lee, J., Hwangbo, J., Wellhausen, L., Koltun, V., 和 Hutter, M. (2020). 在具有挑战性的地形上学习四足运动。 *Sci. Robot.* 5, eabc5986. doi:10.1126/scirobotics.abc5986

Lee, J., Bjelonic, M., Reske, A., Wellhausen, L., Miki, T., 以及 Hutter, M. (2024). 学习轮腿机器人的鲁棒自主导航与运动控制。 *Sci. Robot.* 9, eadi9641. doi:10.1126/scirobotics.adi9641

Li, K., Cucuringu, M., Sánchez-Betancourt, L., 和 Willi, T. (2024). “用于订单执行中神经网络扩展的专家混合,” 载于第五届 ACM 国际人工智能金融会议论文集 (布鲁克林, 纽约: ACM), 669–676. doi:10.1145/3677052.3698691

Nahrendra, I. M. A., Yu, B., 和 Myung, H. (2023). DreamWaQ: 通过隐式地形想象学习鲁棒的四足运动, 结合深度强化学习。 doi:10.48550/arXiv.2301.10602

Obando, F., Gerstner, J., 和 Wang, Q. (2024). Will 专家混合解锁深度强化学习的参数缩放。 doi:10.48550/arXiv.2402.08609

Schaul, T., Borsa, D., Modayil, J. 和 Pascanu, R. (2019). 射线干扰: 深度强化学习中平台期的来源。 doi:10.48550/arXiv.1904.11455

Schulman, J., Wolski, F., Dhariwal, P., Radford, A. 和 Klimov, O. (2017). 近端策略优化算法。 doi:10.48550/arXiv.1707.06347

Shazeer, N., Mirhoseini, A., Maziarz, K., Davis, A., Le, Q., Hinton, G., 等 (2017). 超大神经网络: 稀疏门控专家混合层。 doi:10.48550/arXiv.1701.06538

Singh, S., Russell, R. P. 和 Wensing, P. M. (未注明日期). 刚体接触动力学的解析二阶导数: 应用于多重打靶微分动态规划。 doi:10.1109/Humanoids57100.2023.10375214

Vincze, M., Ferrarotti, L., Custode, L. L., Lepri, B. 和 Iacca, G. (2025). SMOSE: 用于连续控制任务中可解释强化学习的稀疏浅层专家混合。 *Proc. AAAI Conf. Artif. Intell.* 39, 20982–20990. doi:10.1609/aaai.v39i20.35394

王, S., 崔, L., 张, J., 赖, J., 张, D., 陈, K., 等 (2021). “一种新型轮腿机器人的平衡控制: 设计与实验,” 载于 2021 年 IEEE 国际机器人与自动化会议 (ICRA), (中国西安: IEEE), 6782–6788. doi:10.1109/ICRA48506.2021.9561579

王, K., 侯, J., 周, S., 魏, D., 徐, W., 王, Y., 等 (2025). 高原环境中多地形运动的轮腿机器人。 *Biomim. Intell. Rob.* 5, 1002561010162025100256. doi:10.1109/birob.2025.1002561

徐, L., 于, J., 彭, X., 陈, Y., 李, W., Yoo, J., 等 (2025). MoSE: 用于具身自主机器的逐技能专家混合学习。 doi:10.48550/arXiv.2507.07818

Yu, T., Kumar, S., Gupta, A., Levine, S., Hausman, K. 和 Finn, C. (2020). 多任务学习的梯度手术。 0–14. 郑, Y., Asano, F., 严, C., 李, L. 和 Tokuda, I. T. (2025). 基于张拉整体的腿式机器人根据环境产生被动行走、跳跃和爬行步态。 *IEEE/ASME 机电一体化汇刊* 30, 1–12. doi:10.1109/TMECH.2024.3522904