

MUJICA：轮腿机器人的多技能统一联合控制架构

李宇琪¹, 翟鹏^{1,*}, 张悦琪¹, 魏晓艺¹, 钱全成¹, 何正旭², 于千翔² 和张丽华^{1,*}, 项目页面:
<https://hyzenthlayer.github.io/mujica/>

摘要——轮腿机器人在穿越复杂地形方面具有巨大潜力, 并且相比腿式机器人具有更优越的机动性。然而, 轮腿机器人必须有效平衡轮式驱动和腿部控制。此外, 由于本体感觉噪声和真实世界的电机约束, 在电机峰值性能下实现鲁棒自适应运动仍然具有挑战性。我们提出了多技能统一联合控制架构 (MUJICA), 这是一种用于轮腿机器人的统一的全本体感觉控制框架, 将多种低级技能——包括全向移动、高台攀爬和跌倒恢复——集成于单一策略中。所有技能通过独特的指示变量进行区分, 并在精确的直流电机约束建模下联合训练。此外, 我们还学习了一个高层技能选择器, 仅基于本体感觉动态选择最优技能, 从而实现对周围环境的自适应响应。因此, MUJICA增强了仿真到现实的鲁棒性, 并实现了不同运动模式之间的无缝切换, 促进了对环境的自主调整。我们在宇树 Go2-W 机器人上进行了仿真和真实世界实验验证, 结果表明在非结构化环境中适应性和任务成功率均有显著提升。

I. 引言

随着电机扭矩和硬件计算能力的显著进步, 腿式机器人在穿越具有挑战性的环境方面取得了令人瞩目的进展。它们适应不平坦地形和从扰动中恢复的能力使其适用于巡检和灾害响应等现实任务 [1]。尽管取得了这些进展, 为腿式机器人设计控制算法仍然具有挑战性。控制器必须同时实现运动多样性、对不同地形的适应性以及在现实驱动约束下的安全部署。已有多种方法被提出, 并在爬楼梯、斜坡穿越和扰动恢复等任务中展示了鲁棒性 [2]–[6]。然而, 由于机器人结构的固有局限性, 腿部运动在平坦地面上的效率和速度往往受限, 并且缺乏穿越某些具有挑战性的地形 (如高台) 的能力。




图1: 轮腿机器人上MUJICA的真实世界演示。顶行: 连续运动过程中的自动技能切换。中间行: 执行三种代表性技能, 包括高台攀爬、上楼梯和跌倒恢复。底行: 机器人攀爬至1米高平台的快照。结果突显了MUJICA在执行多样化技能以及无需外部感知即可在技能间无缝切换的能力。

轮腿机器人通过结合轮子的高效性与腿部跨越障碍物的能力, 提供了一种有前景的替代方案。这种混合设计使得在平坦表面上能够快速移动, 同时保留处理崎岖地形和障碍物 [7] 的能力。然而, 轮腿机器人在复杂真实环境中的全部潜力尚未得到充分发挥, 因为大多数现有的轮腿机器人控制框架都是从腿式运动方法 [7], [8], 修改而来, 因此继承了它们的局限性。

我们识别出当前腿部运动和轮腿运动方法中的三个关键局限性。首先, 大多数仅基于本体感觉的多技能盲控制器只能处理范围狭窄的相似技能, 运动多样性有限, 例如在平坦或倾斜地形上行走, 或处理难度相对较低的技能, 如爬楼梯和斜坡 [2]–[4], [9]。其次, 对于处理具有不同动力学的异质技能, 如疾驰、缓行和爬行, 控制器通常依赖手动切换 [10], [11]。此外, 这些方法主要旨在展示多技能学习范式, 而非适应多样化和复杂的地形。第三, 在

¹李宇琪、张悦琪、魏晓艺、钱全成、翟鹏和张丽华就职于复旦大学智能机器人及先进制造学院, 上海 200433, 中国 {yuqili24, zhangyq23, weixy23, qcqian24}@m.fudan.edu.cn; {pzhai, lihuazhang}@fudan.edu.cn ²何正旭和于千翔就职于中国电建华东勘测设计研究院有限公司, 杭州, 中国 {hezx, yuqx1}@hdec.com* 通讯作者。

为了确保在真实世界中的安全部署，机器人关节的限制至关重要。在强化学习（RL）的背景下，这些物理限制通常被转化为动作惩罚或作为约束纳入优化问题中 [12]–[14]。然而，大多数基于学习的方法采用简化的驱动约束，忽略了直流（DC）电机的速度和位置相关的力矩限制。像 [15] 这样的方法仅对期望力矩和测量力矩之间的关系进行建模。缺乏精确的电机约束既限制了电机性能的充分利用，也影响了仿真到现实迁移的安全性。因此，这些问题限制了轮腿运动在具有挑战性的地形上的性能和安全性。

为了解决这些问题，我们提出了用于轮腿机器人的多技能统一联合控制架构（MUJICA），这是一种本体感觉驱动的控制框架，在单一网络内统一了多种运动技能——包括全向移动、高台攀爬和跌倒恢复。MUJICA的一个核心特点是强调安全感知学习和可靠的仿真到现实迁移。我们明确地将电机速度与最大力矩之间的关系建模为硬性直流电机约束，以防止部署过程中的不安全行为，并使机器人在具有挑战性的机动中更有效地利用其电机。此外，我们引入了一个高层选择器，利用本体感觉反馈来自动化技能转换，实现跨任务的无缝自适应切换，而无需外部感知。

本研究的主要贡献如下：

- 我们提出了一种统一控制架构，在单一策略中联合学习多样且具有挑战性的技能，包括全向运动、高台攀爬和跌倒恢复。
- 我们提出了一种基于硬直流电机约束的安全感知学习框架，以确保从仿真到真实世界的成功迁移。
- 我们训练了一个高层技能选择器，基于本体感觉和统一的速度跟踪奖励来自动化技能迁移。
- 我们通过在宇树Go2-W机器人上的广泛仿真和真实世界实验验证了MUJICA的有效性。

II. 相关工作

A. 基于学习的腿式机器人盲控制

机器人

由于仅有少数研究聚焦于轮腿运动，且多数与腿部控制相似，本节主要关注腿部运动。盲控制方法仅依赖本体感觉反馈，如关节状态和IMU数据，而不使用外部传感器。早期工作展示了四足机器人在平坦室内表面上行走的端到端深度强化学习策略 [16]。策略在仿真中训练，并在真实机器人上零样本部署。为了提高在非结构化地形上的性能，特权信息在策略训练中被广泛应用。RMA [17]利用自适应模块来模仿

特权基础策略，而DreamWaQ [4] 实现了非对称演员-评论家，通过具有特权观测的评论家更好地训练策略。另一项工作通过历史观测估计不可观测状态，从而实现更好的地形适应。DreamWaQ [4] 和HIM [18] 都估计基座线速度和潜在状态向量，以增强运动的鲁棒性，FR-Net [5]预测机器人碰撞概率和质量分布，以避免不良碰撞并实现在多样化机器人上的部署。然而，这些方法并未纳入统一的具身状态估计来捕获多样化的机器人特定信息，限制了它们在多技能策略部署中的适用性。

另一方面，在仿真中表现良好的策略并不一定能保证真实世界中的安全性能，因为环境和机器人动力学存在差异。因此，在训练过程中强制执行物理约束对于确保安全可靠的部署至关重要。约束强化学习的最新进展催生了多种创新方法，以应对约束条件下的策略优化挑战。为了增强计算可处理性并简化奖励设计，一些方法将传统的约束策略迭代过程重构为等效的无约束优化公式 [12], [13]。从另一个角度来看，CaT [19] 巧妙地将硬约束重新解释为概率性终止机制，在保持计算效率的同时实现了稳健的约束满足。然而，Dadiotis等人 [20] 和ALARM [21] 的研究仅通过最大允许值来约束关节力矩，忽略了直流电机的最大扭矩输出在高速时会下降的事实，而 [15] 仅建模了期望力矩与测量力矩之间的关系。这一疏忽限制了机器人在极端运行条件下的安全性能。对于轮腿机器人而言，结合轮腿协调来利用极限电机能力对于最大化性能至关重要，这进一步凸显了精确力矩建模的必要性。

B. 机器人多任务学习

机器人多任务学习的目标是通过统一策略使机器人能够完成不同任务或获得各种技能。尽管 [4], [18] 使机器人能够穿越楼梯和平坦地形，但这些技能的动作空间并无显著差异。因此，需要多任务框架来处理差异较大的任务，并使机器人能够学习不同的技能。现有框架主要分为两类：师生策略蒸馏和分层强化学习。师生策略蒸馏首先训练多个专家策略，每个策略专门负责单一任务，然后利用监督学习训练学生策略以模仿这些专家 [22], [23]。分层强化学习也采用两阶段训练方案，首先训练多个低级单技能专家策略。对于高级策略，一些研究采用混合专家（MOE）框架来实现多技能学习，如跌倒恢复、四足行走和双足行走，其中训练一个门控网络来计算这些专家的加权组合，从而产生融合各种技能特征的混合策略 [4], [18]。相比之下，有些方法使用高级策略仅选择一个专家策略来执行。然而，蒸馏框架和MOE框架无法解决低级行为之间的冲突（例如左转和右转的冲突动作）[22]。此外，依赖训练多个独立策略的方法往往会增加网络复杂性并降低训练效率。其他方法采用从多样化参考运动中学习模仿 [23]，但这些方法主要强调多技能学习范式，对跨多样化和具有挑战性的地形的适应性关注有限。Chamorro等人专注于轮腿式爬楼梯，并在观测中添加地形布尔变量以区分楼梯与其他地形。然而，这两个任务相对简单，无法充分发挥轮腿机器人的全部潜力，轮腿机器人中多技能学习的挑战仍未得到解决。




图2: MUJICA框架概述。每个任务都与一个独特的技能指示器相关联。在训练阶段S1中, 状态估计器学习从本体感觉预测潜在状态向量、基座线速度、轮地距离和机器人段碰撞。随后, actor将估计结果和当前观测作为输入并生成动作。奖励评论家和约束评论家通过特权观测评估状态值和约束违反。在训练阶段S2中应用技能选择器以学习技能迁移, 努力适应不同的地形和状态。

行走和双足行走, 其中训练一个门控网络来计算这些专家的加权组合, 从而产生融合各种技能特征的混合策略 [2], [24], [25]。相比之下, 有些方法使用高级策略仅选择一个专家策略来执行。然而, 蒸馏框架和MOE框架无法解决低级行为之间的冲突 (例如左转和右转的冲突动作) [3], [9]。此外, 依赖训练多个独立策略的方法往往会增加网络复杂性并降低训练效率。其他方法采用从多样化参考运动中学习模仿[11], [26], 但这些方法主要强调多技能学习范式, 对跨多样化和具有挑战性的地形的适应性关注有限。Chamorro等人 [8]专注于轮腿式爬楼梯, 并在观测中添加地形布尔变量以区分楼梯与其他地形。然而, 这两个任务相对简单, 无法充分发挥轮腿机器人的全部潜力, 轮腿机器人中多技能学习的挑战仍未得到解决。

III. 问题表述

A. C-POMDP框架

轮腿机器人在非结构化环境中运行, 由于传感器噪声, 完全状态可观测性往往难以实现。同时, 必须满足安全关键约束 (如接触力、电机限制), 以确保在真实世界中的可靠部署。因此, 我们将问题建模为约束部分可观测马尔可夫决策过程 (C-POMDP), 寻求策略 π^* , 该策略在满足所有约束的同时最大化长期回报:

$$\max \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t, s_{t+1}) \right] \quad (1)$$

$$\text{s.t. } \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t C_i(s_t, a_t, s_{t+1}) \right] \leq \delta_i, \forall i \in \{1, \dots, k\}$$

其中 R 表示奖励, C_i 表示第 i 个约束, 其对应限制为 δ_i , 具体将在第 IV-C 节中详述。

B. 观测空间与状态空间

由于所提出的框架是为无视觉策略设计的, 该策略仅基于包含本体感觉的观测空间进行条件设定。同时, 我们将状态空间定义为特权观测空间, 包含与任务相关且具有物理信息量的数据, 评论家网络从中接收输入 (详见第IV-B节)。因此, 在时间 t 的观测和特权观测定义如下:

$$o_t = [\omega_t^b, g_t^b, cmd_t, q_t, \dot{q}_t, a_t, \zeta_t]^T \quad (2)$$

$$s_t \triangleq o_t^{priv} = [o_t, v_t, c_t, u_t, h_t]^T \quad (3)$$

C. 动作空间

动作空间定义为所有关节电机的控制指令。对于每个腿部关节, 动作对应于相对于预定义默认姿态的角度偏移, 而对于轮关节, 动作指定期望电机速度。在每个时间步, 策略输出一个动作向量 a_t , 该向量随后通过PD控制器转换为电机扭矩, 公式如下:

$$\tau_t^i = \begin{cases} K_d^i (\dot{q}_t^i - a_t^i), & \text{if } i = \text{wheel} \\ K_p^i (q_t^i - a_t^i) - K_d^i \dot{q}_t^i, & \text{otherwise} \end{cases} \quad (4)$$

其中 τ_t^i 是第 i 个电机输出的目标扭矩。 K_p^i 和 K_d^i 分别表示刚度和阻尼。

IV. 方法

在本节中，我们详细介绍了所提出的MUJICA框架的方法。整体架构如图2所示。

A. 状态估计器

仅依靠本体感觉，机器人无法直接获取对技能执行至关重要的地形几何或接触条件信息。因此，为了推断周围环境，受HIM [18]，构建内部模型以预测系统对扰动响应的启发，我们开发了一种基于历史观测缓冲区的状态估计器。为了捕捉时间依赖性，该估计器利用在线编码器通过基于GRU的网络处理过去 $H=6$ 帧的观测数据。除了估计潜在状态向量 $\hat{e}_t$ 和机器人基座线速度 $\hat{v}_t$ 之外，我们还预测每个机器人部件的碰撞概率 $\hat{c}_t$ 以及轮地距离 $\hat{u}_t$ 。显式预测速度有助于机器人理解运动动力学，并区分稳定与不稳定的运动状态。轮地距离估计反映了地形粗糙度，使机器人能够在平坦地面上抑制不必要的抬腿动作，并更好地协调轮腿交互。推断碰撞概率有助于机器人检测与障碍物的接触，例如利用头部碰撞感知即将攀爬的台阶边缘，并实现适应地形的恢复行为。

估计过程可以表述如下：

$$\mathbf{f}_t = \text{GRU}(\text{NN}(\mathbf{o}_{t-H:t}), \mathbf{f}_{t-1}) \quad (5)$$

其中 $\mathbf{f}_t = [\hat{v}_t, \hat{c}_t, \hat{u}_t, \hat{e}_t]^T$ ，而 NN 表示全连接层。

为了有效训练在线编码器，我们引入了一个参考编码器，将后继观测 $\mathbf{o}_{t+1}$ 映射到潜在状态 $\mathbf{e}_t$ 作为监督目标，并应用对比学习损失。

综上所述，估计器损失可以表述为：

$$\mathcal{L}^{\text{Estimate}} = \mathcal{L}^{\text{Pred}} + \mathcal{L}^{\text{SwAV}}(\mathbf{e}_t, \hat{\mathbf{e}}_t) \quad (6)$$

$$\mathcal{L}^{\text{Pred}} = \mathcal{L}_{\text{MSE}}(\mathbf{v}_t, \hat{\mathbf{v}}_t) + \mathcal{L}_{\text{BCE}}(\mathbf{c}_t, \hat{\mathbf{c}}_t) + \mathcal{L}_{\text{MSE}}(\mathbf{u}_t, \hat{\mathbf{u}}_t) \quad (7)$$

其中 $\mathcal{L}_{\text{MSE}}$ 等于均方误差损失， $\mathcal{L}_{\text{BCE}}$ 等于二元交叉熵损失，而 SwAV 是遵循 [27] 的对比学习损失。

B. 非对称演员-评论家框架

如第III-B节所述，轮腿机器人在部署过程中处于部分可观测性条件下运行，但仍需基于不可观测的地形属性进行安全评估。与此同时，能够获取完整状态信息的评论家可以更快地学习价值函数，从而更好地引导 actor [28] 的学习。因此，MUJICA提出了一种非对称 actor-critic 框架。策略网络 π_θ 接收来自在线编码器的历史嵌入观测 $\mathbf{f}_t$ 以及当前观测 $\mathbf{o}_t$ 作为输入。

同时，为了解决公式(1)中的约束优化问题，我们采用 P3O [12] 框架，该框架使用奖励评论家

和约束评论家。这两个评论家均

以特权观测 $\mathbf{o}_t^{\text{priv}}$ 为条件，分别评估状态值和约束违反情况。

P3O通过基于惩罚的迭代方法将约束优化问题转化为无约束目标。

因此，P3O损失可以表示为：

$$\mathcal{L}^{\text{P3O}}(\theta) = \mathcal{L}_R^{\text{CLIP}}(\theta) + \kappa \sum_{i=1}^k \max\{0, \mathcal{L}_{C_i}^{\text{CLIP}}(\theta)\} \quad (8)$$

$$\mathcal{L}_R^{\text{CLIP}}(\theta) = \mathbb{E}_{\substack{s \sim d^\pi \\ a \sim \pi}} [-\min\{r(\theta)A_R^\pi(s, a), \text{clip}(r(\theta), 1 - \epsilon, 1 + \epsilon)A_R^\pi(s, a)\}] \quad (9)$$

$$\mathcal{L}_{C_i}^{\text{CLIP}}(\theta) = \mathbb{E}_{\substack{s \sim d^\pi \\ a \sim \pi}} [\max\{r(\theta)A_{C_i}^\pi(s, a), \text{clip}(r(\theta), 1 - \epsilon, 1 + \epsilon)A_{C_i}^\pi(s, a)\} + (1 - \gamma)(J_{C_i}(\pi) - \delta_i)] \quad (10)$$

其中 $r(\theta)$ 是新旧策略之间的重要性采样比率， A_R^π 和 $A_{C_i}^\pi$ 分别是奖励优势和 i 个约束优势， $d^\pi(s)$ 是折扣未来状态分布， κ 是惩罚因子。 $\mathcal{L}_R^{\text{CLIP}}$ 是裁剪的 PPO 替代目标 [29]，确保奖励驱动的稳定更新，而 $\mathcal{L}_{C_i}^{\text{CLIP}}$ 则编码了带有裁剪的约束特定损失，以防止过于激进的更新。 $(J_{C_i}(\pi) - \delta_i)$ 对超过 δ_i 的期望约束成本进行惩罚，并按 $(1 - \gamma)$ 进行缩放。将所有约束求和后，P3O 目标在最大化奖励的同时抑制不安全行为，从而产生既高效又安全的策略。为了使机器人能够逐步获得更高难度的技能，我们设计了一种课程学习方案来训练 actor-critic 网络（详见第 V-A 节）。




图3: (a) 所有关节的速度相关扭矩限制。小腿关节极限也受关节位置影响。(b) 小腿关节的基于位置的扭矩限制。

C. 多任务奖励与约束

为了在单一策略中学习多种技能，我们提出了技能指示器 ζ_t 。每个技能都与一个独特的指示变量相关联，使得个体技能的观测空间能够沿着这一特定维度进行解耦。因此，通过技能指示器 ζ_t ，我们提出的架构可以扩展到各种轮腿式任务中。在本研究中，我们设计了三个具有代表性和挑战性的任务：(i) 在普通地形上的全向移动，(ii) 高台攀爬，以及 (iii) 跌倒恢复。全向运动技能需要跟踪线




图4: 不同算法在代表性任务的所有难度等级上的成功

代表性任务。

速度和角速度，而高台攀爬技能仅需跟踪线速度。对于跌倒恢复，机器人需要学习从任意姿态翻转起身。

简化了底层学习，并通过灵活的技能组合提升了泛化能力。

V. 实验

我们在多样化的地形上训练MUJICA，并在仿真和真实世界中开展广泛实验，以验证其有效性和峰值性能。具体而言，以下实验旨在解决：

- MUJICA能否有效完成多样化任务，其性能与基线方法和消融变体相比如何？（见第V-B节）
- 所提出的技能选择器能否在特性差异较大的任务间实现可靠切换，从而提升顺序任务成功率？（见第V-C节）
- MUJICA策略能否迁移到真实轮腿机器人上，展示零样本仿真到现实迁移的性能？（见第V-D节）

A. 训练

1) 设置：所有仿真实验均在IsaacLab平台上进行，使用单个NVIDIA RTX 4090 GPU运行4,096个并行环境。我们选择图2所示的宇树Go2-W来验证所提出的架构。底层控制器和高层选择器均以50 Hz的频率工作，而物理仿真以200 Hz执行。底层训练过程进行30,000次迭代，高层训练进行10,000次迭代。在跌倒恢复任务中，每个回合持续6秒，包括2秒从空中以随机姿态自由落体和4秒用于恢复，期间任务不会终止。对于其他任务，每个回合持续20秒，并在发生基座碰撞时终止。

2) 课程学习：为了使机器人能够逐步探索适应具有挑战性的地形的运动，按照[31]，我们采用了课程学习框架。

我们构建了一个 33×20 网格状多任务环境，其中4,096个机器人被分配到不同的行，每一行对应一个特定的地形及其相应的任务，而每一列代表一个课程难度等级。

在训练阶段S1中，我们根据分配给每个机器人的任务明确设置正确的技能指示器。对于全向运动和跌倒恢复，地形设置为楼梯、斜坡、离散地形和崎岖地形。对于高台攀爬，地形设置为地面上的大型凹陷，要求机器人攀爬出来，并支持任意方向的攀爬。

表I: MUJICA的主要奖励与约束

奖励 R_t 或约束 C_t	公式	适用 任务
$R_{cmd_{xy}, t}$	实验 $(-\ cmd_{xy, t} - v_{xy, t}\ ^2 / \sigma^2)$	i, ii
$R_{cmd_{\omega}, t}$	实验 $(-\ cmd_{\omega, t} - \omega_{z, t}\ ^2 / \sigma^2)$	i
$R_{gravity, t}$	实验 $(-\angle(\mathbf{g}_t^b, \mathbf{g}^{world}) / \sigma^2)$	iii
$R_{poserr, t}$	$\exp(-\ \mathbf{q} - \mathbf{q}_{stand}\ ^2 / \sigma^2)$ 如果 $ \angle(\mathbf{g}_t^b, \mathbf{g}^{world}) < \epsilon$	iii
$C_{DC-motor, t}$	$\sum_{i=1}^{16} \mathbf{1}_{ \tau_i \geq \tau^{\text{限制}}}$	i, ii, iii
$C_{collision, t}$	$\sum_i c_{i, t}^i$, i = 大腿, 小腿	i, ii

主要且与任务相关的奖励和约束列于表I中，其余部分在视频中补充说明。值得注意的是，对大腿和小腿施加了碰撞约束，以鼓励机器人使用轮子而非腿部与环境交互。此外，考虑到电机在物理上的限制，我们在所有任务中引入了直流电机约束。具体而言，受 [30], 图3所示电机工作区域的启发，每个执行器都受到速度相关扭矩限制的约束，其中最大扭矩在低速时保持恒定，但在高速时随速度增加而线性下降。小腿关节连接大腿和小腿连杆，因此其扭矩同时受关节速度和关节位置的影响，在固定速度下，最大扭矩对关节位置表现出余弦依赖，而其他关节电机仅受关节速度影响。具体数值来自宇树官方电机手册。

D. 技能选择器

在训练多种稳健的运动技能（训练阶段S1）之后，为了在多种地形上实现自适应行为，我们采用了一种基于本体感觉的高层技能选择器，它能够自动激活底层运动策略，即自动选择合适的 ζ_t 。具体而言，高层选择器将最近的 H 个观测 $\mathbf{o}_{t-H:t}$ （不包括 ζ_t ）作为输入，并输出对预定义运动技能集的概率分布。我们实现了一个非对称演员-评论家网络，通过统一速度跟踪奖励（训练阶段S2）在冻结技能策略之上训练技能选择器。这种分层设计

考虑到这三种技能的目标，对于全向运动和高台攀爬，当机器人成功维持速度跟踪一段时间后，课程进度推进；如果机器人的行进距离远低于理论距离，则课程进度回退。对于跌倒恢复，当机器人处于标准站立姿态的一定范围内时，课程进度推进，否则回退。对应的地形如下，地形等级为 $l \in [1, 20]$ ：

- 楼梯：台阶宽度为0.3米，台阶高度为 $0.05 + 0.18 \times l/20$ 米；
- 斜坡：坡度为 $0.5 \times l/20 \times 100\%$ ；
- 离散地形：地面上有30个矩形凸起，宽度范围为1米至2米，高度由 $0.05 + 0.17 \times l/20$ 米给定；
- 粗糙地形：高度从[0.04, 0.12] 米均匀采样；
- 坑：地面上的一个矩形坑，尺寸为 $2\text{米} \times 4\text{米}$ （长 $\times$ 宽），深度为 $0.05 + l/20$ 米。

在训练阶段S2中，所有环境均被同等对待，期望机器人能够自行学习选择技能，以持续跟踪速度指令。

表II：随机化仿真参数

参数	随机化范围
静摩擦	[0.6, 1.0]
动摩擦	[0.4, 0.8]
基座质量偏差	[-1.0, 3.0] 千克
外力	每2-3秒施加 [-10.0, 10.0] 牛
推机器人	每8-12秒以 [-1.0, 1.0] 米/秒沿 x 或 y 方向
电机增益倍数	[0.8, 1.2]

3) 域随机化：为了提高我们提出方法的鲁棒性，并确保从仿真到现实的无缝迁移，我们在训练过程中广泛实施了域随机化。表II列出了随机化变量及其均匀采样的范围。

B. 对比与消融实验

1) 基线对比与状态估计器消融：我们首先将我们的方法与若干基线和消融变体在各项技能上的表现进行比较，具体如下：

- MUJICA（我们的方法）：使用所有模块进行训练。
- MUJICA无速度：不进行基座线速度估计的训练。
- MUJICA无轮高：训练时不使用轮地距离估计。
- MUJICA无碰撞：训练时不使用机器人分段碰撞估计。
- DreamWaQ [4] + P3O [12]：一种在约束条件下训练的框架，它显式估计基座线速度，并利用上下文辅助的VAE估计器网络隐式推断特权状态。

- Vanilla PPO [29]：仅使用本体感觉进行训练。

上述所有方法均在相同的地形课程和奖励函数下进行训练。为评估策略的有效性和鲁棒性，我们选择了5个代表性任务，并设计了10个递增的难度等级，等级间隔相对于训练时加倍。全向运动的成功标准为以1 m/s的目标速度维持20秒；恢复任务的成功标准为在4秒内达到与标称姿态相似的稳定站立姿态；高台攀爬的成功标准为在3秒内攀上平台并保持稳定。所有方法均使用4个随机种子进行测试，并报告平均成功率及标准差。

结果如图4所示。首先，除Vanilla PPO外，所有方法都能在所有难度下从斜坡中恢复，因为滚动使机器人能够利用光滑斜坡表面上的外力。就整体性能而言，我们利用基座速度、轮地距离和碰撞估计的MUJICA框架在所有任务中始终优于所有基线和消融变体。值得注意的是，在较高难度等级下，性能差距显著扩大，这证明了我们提出的架构在增强鲁棒性方面的有效性。消融结果表明，移除三个估计组件中的任何一个都会导致性能明显下降，这凸显了对周围环境的准确评估需要三者联合预测。此外，省略速度估计对非恢复任务尤为不利，这强调了其对适应动态环境的重要性。

与同样采用带约束的估计框架的DreamWaQ [4] + P3O [12]，相比，我们的方法表现出更优越的性能。这表明我们在估计目标和网络架构上的特定选择，能更有效地捕捉轮腿机器人多样化任务所需的信息。值得注意的是，由于轮腿机器人卓越的机动性，即使使用最简单的PPO基线算法训练的策略也能成功完成斜坡穿越任务。然而，由于缺乏状态估计，PPO无法学习任何跌倒恢复技能。

2) 直流电机约束消融：为了进一步研究直流电机约束的作用，我们分析了仿真中不同地形下大腿关节的扭矩-速度分布。如图5所示，在无约束情况下（图5a-d），关节表现出严重的违规行为，超过90%的样本位于可行电机区域之外。为清晰起见，图中截断至 $\pm 100\text{N}\cdot\text{m}$ ，但仍存在许多幅值更高的离群点。此外，在没有直流电机约束的情况下，关节持续振荡，在高台攀爬过程中，后大腿关节频繁触及正向关节极限。在此极限状态下，当关节推压地面时会产生大扭矩，这直接触发真实机器人上的电机故障（如图6所示）。相比之下，在强制执行直流电机约束的情况下（图5e-h），我们的方法有效将分布保持在可行区域内，将违规率降至3.5%以下，并确保稳定、




图5：多种地形下大腿关节的扭矩-速度分布。绿色区域表示符合直流电机约束。蓝色点是位于绿色区域内的电机状态，而红色叉号则不在其中。(a)–(d) 显示未施加直流电机约束的结果，(e)–(h) 显示施加约束后的结果。



图6：无直流电机约束下的高台攀爬。后大腿关节处于关节极限，将产生较大扭矩以高高跳起。(a) 仿真中 (b) 真实世界中。

硬件可执行的关节行为。值得注意的是，零速度处的密集点簇主要源于机器人从外部跳入坑中时产生的冲击，这些冲击对大腿关节施加了大冲量。

表III：连续地形上的分阶段成功率

方法	楼梯恢复	爬楼梯	高台攀爬
无指示器 (共享奖励)	✗	✗	✗
无指示器 (分离奖励)	72%	72%	38%
带技能选择器 (我们的方法)	95%	95%	91%

C. 技能选择器评估

为验证高层技能选择器能否自主切换技能以应对复杂环境，我们在单集任务中评估了三种变体，该单集按顺序串联了三个中等难度（即10级中的第5级）的任务：

(i) 楼梯恢复，(ii) 爬楼梯，以及 (iii) 高台攀爬。每次运行必须完成全部三个任务

序列方视为成功。我们使用相同地形和手动提供的指令执行了100个回合。失败定义为在爬楼梯或高台攀爬过程中发生基座碰撞，或在调整指令后3秒内无法达成任务目标。

我们将我们的方法与以下两种基线进行比较：

- 无指示器（统一奖励）：不使用技能指示器，并在所有任务上使用统一奖励进行训练。
- 无指示器（分离奖励）：不使用技能指示器，且奖励项因任务而异地进行训练。

结果如表III所示。没有技能指示器的策略可能会混淆不同任务之间的行为，从而损害单任务性能。特别是，统一奖励训练方案经常崩溃（即无法学习技能），而分离奖励方案在中等难度任务上的成功率仍低于所提出的分层控制架构。这凸显了仅靠奖励工程不足以实现多技能集成。没有显式指示器，策略难以理清任务特定策略并在异构目标之间进行泛化。相比之下，引入技能指示器和高层技能选择器能够实现清晰的任务区分、稳定训练，并最终支持在复杂场景中可靠的顺序执行。

D. 真实世界实验

为了验证MUJICA的零样本仿真到真实世界的性能，我们将策略部署到真实世界中的宇树Go2-W机器人上。所有机载计算均在NVIDIA Jetson Orin NX上执行。这些实验旨在评估个体技能的鲁棒性以及技能选择器在自主多技能执行中的有效性。

1) 个体技能验证：我们首先在普通和挑战性条件下评估每项技能。在楼梯恢复



图7：个体技能的真实世界评估。**顶行**：楼梯上的跌倒恢复。**中间行**：攀爬20厘米高楼梯。**底行**：攀爬80厘米高平台。

（图7 顶行）中，机器人成功从30°楼梯上的倒置状态恢复，利用小腿撞击产生扭矩并旋转基座，展示了在随机关节位置的不平坦地形上的鲁棒性。在爬楼梯（图7 中行）中，机器人稳定攀爬具有不同台阶高度和不规则边缘的楼梯。对于高台攀爬，机器人越过80厘米高的室外平台（图7 底行），并实现了具有挑战性的1米高室内平台（图1 底行），接近其机械与驱动极限。该动作需要下蹲后腿髋关节以储存能量，伸展前腿钩住箱子，并协调抬起后腿，充分展示了轮腿协同。据我们所知，此前没有任何工作能使轮腿机器人完成这一极限任务。在所有任务中，电机保护机制——该机制会在过电流或过热时触发——始终保持未激活状态，表明该算法充分发挥了轮腿运动的全部潜力。

2) 多技能切换测试：随后，我们评估了MUJICA在连续真实世界任务中自主整合多种技能的能力（图1顶行）。在一项演示中，机器人从随机跌倒姿态开始，执行恢复，攀爬楼梯和坡道，最后攀爬60厘米高平台。高层技能选择器基于本体感觉无缝切换策略，无需人工干预：检测到跌倒姿态即触发恢复，恢复直立姿态后切换至全向移动，遇到箱子则激活高台攀爬技能。真实世界实验的完整演示见补充视频。

六、结论

在这项工作中，我们介绍了MUJICA，一种统一控制架构，使轮腿机器人能够在单一本体感觉策略内获取并整合多种具有挑战性的运动技能。

通过引入技能选择器和带有精确直流电机约束的安全感知学习框架，MUJICA在全向运动、高台攀爬和跌倒恢复等多样化任务中实现了平滑切换。大量实验表明，所提出的方法不仅相比基线和消融变体提升了鲁棒性，还实现了可靠的零样本仿真到现实迁移。这些结果凸显了MUJICA在提升复杂真实世界环境中轮腿机器人自主性和适应性方面的潜力。未来工作将探索将该框架扩展到更广泛的运动技能，并在非结构化地形上实现自适应协调。

参考文献

- [1] C. Tang, B. Abbatematteo, J. Hu, R. Chandra, R. Martín-Martín and P. Stone, “面向机器人学的深度强化学习：真实世界成功案例综述”，载于AAAI人工智能会议论文集，第39卷，第27期，2025年，第28694–28698页。
- [2] R. Huang, S. Zhu, Y. Du and H. Zhao, “Moe-loco: 面向多任务运动的专家混合”，*arXiv预印本arXiv:2503.08564*, 2025年。
- [3] W. Zhang and K. Wang, “专家混合控制系统中的深度强化学习用于盲式轮腿四足运动”，载于2024年国际先进机器人与智能系统会议（ARIS）。IEEE, 2024年，第1–5页。
- [4] I. Nahrendra, B. Yu and H. Myung, “DreamWaQ: 通过深度强化学习结合隐式地形想象实现鲁棒的四足运动”，*arXiv预印本arXiv:2301.10602*, 2023年。
- [5] Y. Lu, Y. Dong, J. Zhang, J. Ma and P. Lu, “FR-Net: 通过质量接触预测在具有挑战性的地形上学习鲁棒的四足跌倒恢复”，*IEEE机器人与自动化快报*, 2025年。
- [6] Y. Zhang, Q. Qian, T. Hou, P. Zhai, X. Wei, K. Hu, J. Yi and L. Zhang, “Renet: 视觉崩溃下基于冗余估计器网络的四足机器人容错运动控制”，*IEEE机器人与自动化快报*, 第1–8页，2025年。
- [7] J. Lee, M. Bjelonic, A. Reske, L. Wellhausen, T. Miki and M. Hutter, “学习轮腿机器人鲁棒的自主导航与运动”，*科学机器人学*, 第9卷，第89期，第eadi9641页，2024年。
- [8] S. Chamorro, V. Klemm, M. d. L. I. Valls, C. Pal and R. Siegwart, “面向腿式与轮腿机器人的盲式爬楼梯强化学习”，载于2024年IEEE国际机器人与自动化会议（ICRA）。IEEE, 2024年，第8081–8087页。

[9] N. Shah、K. Tiwari和A. Bera, “Mtac: 基于分层强化学习的多步态地形自适应四足控制器”, arXiv预印本arXiv:2401.03337, 2023年。

[10] G. Bellegarda、M. Shafiee和A. Ijspeert, “Allgaits: 学习所有四足步态及其转换”, 载于2025年IEEE国际机器人与自动化会议 (ICRA)。IEEE, 2025年, 第15 929–15 935页。[11] C. Li、S. Blaes、P. Koley、M. Vlastelica、J. Frey和G. Martius, “通过未标记混合运动的自监督对抗模仿实现多功能技能控制”, 载于2023年IEEE国际机器人与自动化会议 (ICRA)。IEEE, 2023年, 第2944–2950页。[12] L. Zhang、L. Shen、L. Yang、S. Chen、B. Yuan、X. Wang和D. Tao, “用于安全强化学习的惩罚近端策略优化”, arXiv预印本arXiv:2205.11814, 2022年。[13] Y. Kim、H. Oh、J. Lee、J. Choi、G. Ji、M. Jung、D. Youm和J. Hwangbo, “不仅是奖励还有约束: 在腿式机器人运动中的应用”, IEEE机器人学汇刊, 第40卷, 第2984–3003页, 2024年。[14] S. Gangapurwala、A. Mitchell和I. Havoutis, “用于动态四足机器人运动的引导约束策略优化”, IEEE机器人与自动化快报, 第5卷, 第2期, 第3642–3649页, 2020年。[15] Y. Yang、G. Shi、C. Lin、X. Meng、R. Scalise、M. G. Castro、W. Yu、T. Zhang、D. Zhao、J. Tan等人, “不连续地形中的敏捷连续跳跃”, arXiv预印本arXiv:2409.10923, 2024年。[16] J. Tan、T. Zhang、E. Coumans、A. Iscen、Y. Bai、D. Hafner、S. Bohez和V. Vanhoucke, “仿真到现实: 学习四足机器人的敏捷运动”, arXiv预印本arXiv:1804.10332, 2018年。[17] A. Kumar、Z. Fu、D. Pathak和J. Malik, “RMA: 腿式机器人的快速电机自适应”, arXiv预印本arXiv:2107.04034, 2021年。[18] J. Long、Z. Wang、Q. Li、J. Gao、L. Cao和J. Pang, “混合内模: 利用仿真机器人响应学习敏捷腿式运动”, arXiv预印本arXiv:2312.11460, 2023年。[19] E. Chane-Sane、P.-A. Leziart、T. Flayols、O. Stasse、P. Souères和N. Mansard, “CaT: 将约束作为腿式运动强化学习的终止条件”, 载于2024年IEEE/RSJ智能机器人与系统国际会议 (IROS)。IEEE, 2024年, 第13 303–13 310页。[20] I. Dadiotis、M. Mittal、N. Tsagarakis和M. Hutter, “通过无模型约束强化学习实现移动机械臂推动动态物体目标”, arXiv预印本arXiv:2502.01546, 2025年。[21] Q. Zhou、H. Ding、T. Chen、L. Man、H. Jiang、G. Zhang、B. Li、X. Rong和Y. Li, “ALARM: 具有可靠模仿的安全强化学习用于稳健腿式运动”, IEEE机器人与自动化快报, 2025年。[22] E. Parisotto、J. L. Ba和R. Salakhutdinov, “Actor-mimic: 深度多任务与迁移强化学习”, arXiv预印本arXiv:1511.06342, 2015年。[23] Y. Teh、V. Bapst、W. M. Czarnecki、J. Quan、J. Kirkpatrick、R. Hadsell、N. Heess和R. Pascanu, “Distral: 稳健的多任务强化学习”, 神经信息处理系统进展, 第30卷, 2017年。[24] C. Yang、K. Yuan、Q. Zhu、W. Yu和Z. Li, “自适应腿式运动的多专家学习”, 科学机器人学, 第5卷, 第49期, 第eabb2174页, 2020年。[25] W. Yu、F. Acero、V. Atanassov、C. Yang、I. Havoutis、D. Kanoulas和Z. Li, “学习敏捷四足运动的技能切换标准发现”, arXiv预印本arXiv:2502.06676, 2025年。[26] C. Li、S. Blaes、P. Koley、M. Vlastelica、J. Frey和G. Martius, “通过未标记混合运动的自监督对抗模仿实现多功能技能控制”, arXiv预印本arXiv:2209.07899, 2022年。[27] M. Caron、I. Misra、J. Mairal、P. Goyal、P. Bojanowski和A. Joulin, “通过对比聚类分配无监督学习视觉特征”, 神经信息处理系统进展, 第33卷, 第9912–9924页, 2020年。[28] L. Pinto、M. Andrychowicz、P. Welinder、W. Zaremba和P. Abbeel, “基于图像机器人学习的非对称actor评论家”, arXiv预印本arXiv:1710.06542, 2017年。[29] J. Schulman、F. Wolski、P. Dhariwal、A. Radford和O. Klimov, “近端策略优化算法”, arXiv预印本arXiv:1707.06347, 2017年。[30] Y.-H. Shin、T.-G. Song、G. Ji和H.-W. Park, “高速四足运动的执行器约束强化学习”, arXiv预印本arXiv:2312.17507, 2023年。[31] N. Rudin、D. Hoeller、P. Reist和M. Hutter, “学习行走

在几分钟内使用大规模并行深度强化学习,” 发表于机器人学习会议。PMLR, 2022年, 第91–100页。